## Mark Pilgrim



© 2010 Mark Pilgrim

Ponořme se do Python(u) 3

Dive Into Python 3

Vydal CZ.NIC, z. s. p. o. Americká 23, 120 00 Praha 2 www.nic.cz

ISBN: 978-80-904248-2-1

Edice CZ.NIC



## Ponořme se do Python(u) 3 Dive Into Python 3

| Dřadmi | 11170 6 | odiční   | poznám   | ادم |
|--------|---------|----------|----------|-----|
| FIRMI  | เบงส ธ  | ı earanı | DUZHAIII | ĸа  |

Předmluva a ediční poznámka

#### Vážení čtenáři,

po úspěchu naší předchozí publikace ProGit jsme se rozhodli, že třetí kniha v Edici CZ.NIC bude tak trochu na podobné téma a v podobném duchu. Opět jde o překlad velice kvalitní zahraniční publikace a také v tomto případě se dá očekávat, že jej ocení hlavně programátoři. Samozřejmě jsme i tentokrát sáhli po knize, která je pod volnou licencí a tedy filozofie její distribuce je blízká naší edici.

Podobně jako v případě nástroje Git je i Python technologie, která je mým kolegům velice dobře známa. Právě v programovacím jazyce Python je napsána podstatná část našeho centrálního registru pro správu domén, který se jmenuje FRED. Toto je jen jeden z mnoha důkazů, proč je nutné se tímto programovacím jazykem vážně zabývat.

Autor knihy **Mark Pilgrim** není ve světě Pythonu rozhodně žádným neznámým jménem. Své renomé si vybudoval již napsáním předchůdce této knihy s téměř stejným jménem. Právě úspěch dřívějšího díla je pro nás zárukou, že i tato verze si najde své čtenáře.

Ať už jste tedy v Pythonu nováčky nebo si jen chcete rozšířit své dosavadní znalosti, přeji Vám příjemnou četbu.

#### Ondřej Filip

Praha 17. listopadu 2010

#### Ediční poznámka autora

**Ponořme se do Pythonu 3** pokrývá vlastnosti jazyka Python 3 a popisuje rozdíly proti jazyku Python 2. Ve srovnání s **Dive Into Python** zde naleznete asi 20 % revidovaného textu a asi 80 % nového materiálu. Knihu považuji za dokončenou, ale zpětná vazba je vždy vítána.

## Obsah

— Obsah

#### Přehled kapitol

- -1. Co najdete v "Ponořme se do Pythonu 3" nového 17
- 0. Instalujeme Python 21
- 1. Váš první pythonovský program 45
- 2. Přirozené datové typy 61
- 3. Generátorová notace 91
- 4. Řetězce 105
- 5. Regulární výrazy 123
- 6. Uzávěry a generátory 143
- 7. Třídy a iterátory 159
- 8. Iterátory pro pokročilé 173
- 9. Unit Testing 193
- 10. Refaktorizace 219
- 11. **Soubory** 235
- 12. XML 255
- 13. Serializace pythonovských objektů 277
- 14. Webové služby nad HTTP 297
- 15. Případová studie: Přepis chardet pro Python 3 329
- 16. Balení pythonovských knihoven 359
- A. Přepis kódu do Python 3 s využitím 2to3 377
- B. Jména speciálních metod 405
- C. Čím pokračovat 423
- D. Odstraňování problémů 427

| -1.    | —<br>Co najdete v "Ponořme se                 | 2.3.5. | Čísla v booleovském kontextu — <b>68</b>      |
|--------|---|--------|---|
|        | do Pythonu 3" nového — 17                     | 2.4.   | Seznamy — <b>69</b>                           |
| -1.1.  | aneb "záporná úroveň" — <b>19</b>             | 2.4.1. | Vytvoření seznamu — 69                        |
|        | _   | 2.4.2. | Vytváření podseznamů — <b>70</b>              |
| Ο.     | Instalujeme Python — 21                       | 2.4.3. | Přidávání položek do seznamu — <b>71</b>      |
| 0.1.   | Ponořme se — <b>23</b>                        | 2.4.4. | Vyhledávání hodnoty v seznamu — <b>73</b>     |
| 0.2.   | Který Python je pro vás                       | 2.4.5  | Odstraňování položek ze seznamu — <b>74</b>   |
|        | ten správný? — <b>23</b>                      | 2.4.6. | Odstraňování položek ze seznamu:              |
| 0.3.   | Instalace pod Microsoft Windows — <b>24</b>   |        | Bonusové kolo — <b>75</b>                     |
| 0.4.   | Instalace pod Mac OS X — <b>29</b>            | 2.4.7. | Seznamy v booleovském kontextu — <b>75</b>    |
| 0.5.   | Instalace pod Ubuntu Linux — <b>36</b>        | 2.5.   | N-tice — <b>76</b>                            |
| 0.6.   | Instalace na jiných platformách — <b>40</b>   | 2.5.1. | N-tice v booleovském kontextu — <b>78</b>     |
| 0.7.   | Použití Python Shell — <b>41</b>              | 2.5.2. | Přiřazení více hodnot najednou — <b>78</b>    |
| 0.8.   | Editory a vývojová prostředí                  | 2.6.   | Množiny — <b>79</b>                           |
|        | pro Python — <b>43</b>                        | 2.6.1. | Vytvoření množiny — <b>79</b>                 |
|        | _   | 2.6.2. | Úprava množiny — <b>81</b>                    |
| 1.     | Váš první pythonovský program — 45            | 2.6.3. | Odstraňování položek z množiny — <b>82</b>    |
| 1.1.   | Ponořme se — <b>47</b>                        | 2.6.4. | Běžné množinové operace — <b>83</b>           |
| 1.2.   | Deklarace funkcí — 48                         | 2.6.5. | Množiny v booleovském kontextu — <b>85</b>    |
| 1.2.1. | Nepovinné a pojmenované                       | 2.7.   | Slovníky — <b>86</b>                          |
|        | argumenty — <b>49</b>                         | 2.7.1. | Vytvoření slovníku — 86                       |
| 1.3.   | Psaní čitelného kódu — <b>51</b>              | 2.7.2. | Úprava slovníku — <b>87</b>                   |
| 1.3.1. | Dokumentační řetězce — 51                     | 2.7.3. | Slovníky se smíšeným obsahem — <b>87</b>      |
| 1.4.   | Vyhledávací cesta pro import — <b>52</b>      | 2.7.4. | Slovníky v booleovském kontextu — 88          |
| 1.5.   | Všechno je objekt — <b>53</b>                 | 2.8.   | None — <b>89</b>                              |
| 1.5.1. | Co to vlastně je objekt? — <b>54</b>          | 2.8.1. | None v booleovském kontextu — 90              |
| 1.6.   | Odsazování kódu — <b>54</b>                   | 2.9.   | Přečtěte si — <b>90</b>                       |
| 1.7.   | Výjimky — <b>55</b>                           |        | <del>_</del>                                  |
| 1.7.1. | Obsluha chyb importu — <b>57</b>              | 3.     | Generátorová notace — 91                      |
| 1.8.   | Volné proměnné — 58                           | 3.1.   | Ponořme se — <b>93</b>                        |
| 1.9.   | Vše je citlivé na velikost písmen — <b>58</b> | 3.2.   | Práce se soubory a s adresáři — 93            |
| 1.10.  | Spouštění skriptů — <b>59</b>                 | 3.2.1. | Aktuální pracovní adresář — 93                |
| 1.11.  | Přečtěte si — <b>60</b>                       | 3.2.2. | Práce se jmény souborů a adresářů — <b>94</b> |
|        | <del>_</del>                                  | 3.2.3. | Výpis adresářů — <b>96</b>                    |
| 2.     | Přirozené datové typy — 61                    | 3.2.4. | Získání dalších informací                     |
| 2.1.   | Ponořme se — <b>63</b>                        |        | o souboru — <b>97</b>                         |
| 2.2.   | Booleovský typ — <b>63</b>                    | 3.2.5. | Jak vytvořit absolutní cesty — <b>98</b>      |
| 2.3.   | Čísla — <b>64</b>                             | 3.3.   | Generátorová notace seznamu — 98              |
| 2.3.1. | Vynucení převodu celých čísel                 | 3.4.   | Generátorová notace slovníku — 100            |
|        | na reálná a naopak — <b>65</b>                | 3.4.1. | Další legrácky s generátorovou                |
| 2.3.2. | Běžné operace s čísly — <b>66</b>             |        | notací slovníků — 102                         |
| 2.3.3. | Zlomky — <b>67</b>                            | 3.5.   | Generátorová notace množin — 103              |
| 2.3.4. | Trigonometrie — <b>67</b>                     | 3.6.   | Přečtěte si — 103                             |

|        | <u> </u>                                    |        | _  |
|--------|---|--------|--|
| 4.     | Řetězce — 105                               | 7.     | Třídy a iterátory — 159                        |
| 4.1.   | Pár nudných věcí, kterým musíme             | 7.1.   | Ponořme se — 161                               |
|        | rozumět dříve, než se budeme                | 7.2.   | Definice tříd — <b>161</b>                     |
|        | moci ponořit — 107                          | 7.2.1. | Metodainit() — <b>162</b>                      |
| 4.2.   | Unicode — 109                               | 7.3.   | Vytváření instancí tříd — 163                  |
| 4.3.   | Ponořme se — 111                            | 7.4.   | Členské proměnné — <b>163</b>                  |
| 4.4.   | Formátovací řetězce — 111                   | 7.5.   | Fibonacciho iterátor — <b>164</b>              |
| 4.4.1. | Složená jména oblastí — 113                 | 7.6.   | Iterátor pro pravidla                          |
| 4.4.2. | Specifikátory formátu — 114                 |        | množného čísla — <b>166</b>                    |
| 4.5.   | Další běžné metody řetězců — 115            | 7.7.   | Přečtěte si — 172                              |
| 4.5.1. | Vykrajování podřetězců — 117                |        | <u> </u>                                       |
| 4.6.   | Řetězce vs. bajty — 117                     | 8.     | lterátory pro pokročilé — 173                  |
| 4.7.   | Závěrečná poznámka: Kódování znaků          | 8.1.   | Ponořme se — 175                               |
|        | v pythonovském zdrojovém textu — <b>120</b> | 8.2.   | Nalezení všech výskytů vzorku — 176            |
| 4.8.   | Přečtěte si — 121                           | 8.3.   | Nalezení jedinečných prvků                     |
|        | _   |        | posloupnosti — <b>177</b>                      |
| 5.     | Regulární výrazy — 123                      | 8.4.   | Činíme předpoklady — 178                       |
| 5.1.   | Ponořme se — <b>125</b>                     | 8.5.   | Generátorové výrazy — <b>179</b>               |
| 5.2.   | Případová studie: Adresa ulice — <b>125</b> | 8.6.   | Výpočet permutací (pro lenochy) — <b>180</b>   |
| 5.3.   | Případová studie: Římská čísla — <b>128</b> | 8.7.   | Další legrácky v modulu itertools — <b>182</b> |
| 5.3.1. | Kontrola tisícovek — <b>128</b>             | 8.8.   | Nový způsob úpravy řetězce — <b>185</b>        |
| 5.3.2. | Kontrola stovek — 129                       | 8.9.   | Vyhodnocování libovolných řetězců              |
| 5.4.   | Využití syntaxe {n,m} — 131                 |        | zachycujících pythonovské výrazy — 187         |
| 5.4.1. | Kontrola desítek a jednotek — <b>132</b>    | 8.10.  | Spojme to všechno dohromady — <b>190</b>       |
| 5.5.   | Víceslovné regulární výrazy — <b>134</b>    | 8.11.  | Přečtěte si — <b>191</b>                       |
| 5.6.   | Případová studie:                           |        | _  |
|        | Analýza telefonních čísel — <b>136</b>      | 9.     | Unit Testing — 193                             |
| 5.7.   | Shrnutí — 141                               | 9.1.   | (Ne)ponořme se — <b>195</b>                    |
|        | _   | 9.2.   | Jediná otázka — <b>196</b>                     |
| 6.     | Uzávěry a generátory — 143                  | 9.3.   | "Zastav a začni hořet" — <b>202</b>            |
| 6.1.   | Ponořme se — <b>145</b>                     | 9.4.   | Více zastávek, více ohně — <b>206</b>          |
| 6.2.   | Já vím jak na to! Použijeme                 | 9.5.   | A ještě jedna věc — <b>209</b>                 |
|        | regulární výrazy! — 146                     | 9.6.   | Symetrie, která potěší — <b>211</b>            |
| 6.3.   | Seznam funkcí — 148                         | 9.7.   | Více špatných vstupů — <b>215</b>              |
| 6.4.   | Seznam vzorků — 150                         |        | _  |
| 6.5.   | Soubor vzorků — 152                         | 10.    | Refaktorizace — 219                            |
| 6.6.   | Generátory — <b>154</b>                     | 10.1.  | Ponořme se — <b>221</b>                        |
| 6.6.1. | Generátor Fibonacciho                       | 10.2.  | Zvládání měnících se požadavků — 223           |
|        | posloupnosti — <b>155</b>                   | 10.3.  | Refaktorizace — <b>228</b>                     |
| 6.6.2. | Generátor pravidel pro množné               | 10.4.  | Shrnutí — <b>232</b>                           |
|        | číslo — <b>156</b>                          |        |  |
| 6.7.   | Přečtěte si — <b>158</b>                    |        |  |

| 11.     | Soubory — 235                               | 13.2.   | Uložení dat do "pickle souboru" — <b>280</b>    |
|---------|---|---------|---|
| 11.1.   | Ponořme se — <b>237</b>                     | 13.3.   | Načítání dat z "pickle souboru" — <b>281</b>    |
| 11.2.   | Čtení z textových souborů — <b>237</b>      | 13.4.   | "Piklení" bez souboru — <b>283</b>              |
| 11.2.1. | Kódování znaků vystrkuje                    | 13.5.   | Bajty a řetězce znovu zvedají                   |
|         | svou ošklivou hlavu — <b>237</b>            |         | své ošklivé hlavy — <b>284</b>                  |
| 11.2.2. | Objekty typu stream — 238                   | 13.6.   | Ladění "pickle souborů" — <b>284</b>            |
| 11.2.3. | Čtení dat z textového souboru — 239         | 13.7.   | Serializace pythonovských objektů               |
| 11.2.4. | Zavírání souborů — <b>241</b>               |         | pro čtení z jiných jazyků — <b>286</b>          |
| 11.2.5. | Automatické zavírání souborů — <b>242</b>   | 13.8.   | Uložení dat do JSON souboru — <b>287</b>        |
| 11.2.6. | Čtení dat po řádcích — <b>243</b>           | 13.9.   | Zobrazení pythonovských datových                |
| 11.3.   | Zápis do textových souborů — <b>245</b>     |         | typů do JSON— <b>289</b>                        |
| 11.3.1. | A znovu kódování znaků — <b>246</b>         | 13.10.  | Serializace datových typů, které                |
| 11.4.   | Binární soubory — <b>246</b>                |         | JSON nepodporuje — <b>289</b>                   |
| 11.5.   | Objekty typu stream                         | 13.11.  | Načítání dat z JSON souboru — <b>293</b>        |
|         | z nesouborových zdrojů — <b>247</b>         | 13.12.  | Přečtěte si — <b>295</b>                        |
| 11.5.1. | Práce s komprimovanými soubory — <b>249</b> |         | _   |
| 11.6.   | Standardní vstup, výstup                    | 14.     | Webové služby nad HTTP — 297                    |
|         | a chybový výstup — <b>250</b>               | 14.1.   | Ponořme se — <b>299</b>                         |
| 11.6.1. | Přesměrování standardního                   | 14.2.   | Vlastnosti HTTP — <b>300</b>                    |
|         | výstupu — <b>251</b>                        | 14.2.1. | Používání mezipaměti — <b>300</b>               |
| 11.7.   | Přečtěte si — <b>254</b>                    | 14.2.2. | Kontrola Last-Modified — <b>301</b>             |
|         | _   | 14.2.3. | Kontrola ETag — <b>303</b>                      |
| 12.     | XML — 255                                   | 14.2.4. | Komprese — <b>304</b>                           |
| 12.1.   | Ponořme se — <b>257</b>                     | 14.2.5. | Přesměrování — <b>304</b>                       |
| 12.2.   | Pětiminutový rychlokurz XML — <b>258</b>    | 14.3.   | Jak se nedostat k datům                         |
| 12.3.   | Struktura Atom Feed — <b>261</b>            |         | přes HTTP — <b>305</b>                          |
| 12.4.   | Analýza XML — <b>263</b>                    | 14.4.   | Co že to máme na drátě? — 306                   |
| 12.4.1. | Elementy jsou reprezentovány                | 14.5.   | Představujeme httplib2 — <b>309</b>             |
|         | seznamy — 264                               | 14.5.1. | Krátká odbočka vysvětlující, proč               |
| 12.4.2. | Atributy jsou reprezentovány                |         | httplib2 vrací bajty místo řetězců — <b>311</b> |
|         | slovníky — <b>264</b>                       | 14.5.2. | Jak httplib2 zachází s mezipamětí — <b>312</b>  |
| 12.5.   | Vyhledávání uzlů v XML                      | 14.5.3. | Jak httplib2 zachází s hlavičkami               |
|         | dokumentu — <b>265</b>                      |         | Last-Modified a ETag — <b>315</b>               |
| 12.6.   | lxml jde ještě dál — <b>268</b>             | 14.5.4. | Jak http21ib pracuje s kompresí — <b>318</b>    |
| 12.7.   | Generování XML — 270                        | 14.5.5. | Jak httplib2 řeší přesměrování — <b>318</b>     |
| 12.8.   | Analýza porušeného XML — <b>273</b>         | 14.6.   | Za hranicemi HTTP GET — <b>322</b>              |
| 12.9.   | Přečtěte si — <b>275</b>                    | 14.7.   | Za hranicemi HTTP POST — 326                    |
|         | _   | 14.8.   | Přečtěte si — <b>328</b>                        |
| 13.     | Serializace pythonovských                   |         | _   |
|         | objektů — 277                               | 15.     | Případová studie:                               |
| 13.1.   | Ponořme se — <b>279</b>                     |         | Přepis chardet pro Python 3 — 329               |
| 13.1.1. | Stručná poznámka k příkladům                | 15.1.   | Ponořme se — <b>331</b>                         |
|         | v této kapitole — <b>279</b>                | 15.2.   | Co se rozumí autodetekcí                        |
|         |   |         | znakového kódování? — 331                       |

| 15.2.1. | Není to náhodou neproveditelné? — 331       | 16.7.   | Kontrola chyb v našem instalačním             |
|---------|---|---------|---|
| 15.2.2. | Existuje takový algoritmus? — <b>332</b>    |         | skriptu — <b>369</b>                          |
| 15.3.   | Úvod do modulu chardet — <b>332</b>         | 16.8.   | Vytvoření distribuce obsahující               |
| 15.3.1. | UTF-N ${ m s}$ BOM — 332                    |         | zdrojové texty — <b>369</b>                   |
| 15.3.2. | Kódování escape sekvencemi — <b>333</b>     | 16.9.   | Vytvoření grafického instalačního             |
| 15.3.3. | Vícebajtová kódování — <b>333</b>           |         | programu — <b>371</b>                         |
| 15.3.4. | Jednobajtová kódování — <b>334</b>          | 16.9.1. | Tvorba instalačních balíčků                   |
| 15.3.5. | windows-1252 — <b>334</b>                   |         | pro jiné operační systémy — <b>373</b>        |
| 15.4.   | Spouštíme 2to3 — <b>335</b>                 | 16.10.  | Přidání našeho softwaru                       |
| 15.5.   | Krátká odbočka k vícesouborovým             |         | do Python Package Index — <b>373</b>          |
|         | modulům — 338                               | 16.11.  | Více možných budoucností                      |
| 15.6.   | Opravme, co 2to3 neumí — <b>340</b>         |         | balení pythonovských produktů — <b>375</b>    |
| 15.6.1. | False je syntaktická chyba — <b>340</b>     | 16.12.  | Přečtěte si — <b>375</b>                      |
| 15.6.2. | Nenalezen modul constants — 341             |         | _   |
| 15.6.3. | Jméno 'file' není definováno — <b>342</b>   | Α.      | Přepis kódu do Pythonu 3                      |
| 15.6.4. | Řetězcový vzorek nelze použít               |         | s využitím 2to3 — 377                         |
|         | pro bajtové objekty — <b>343</b>            | A.1.    | Ponořme se — <b>379</b>                       |
| 15.6.5. | Objekt typu 'bytes' nelze implicitně        | A.2.    | Příkaz print — <b>379</b>                     |
|         | převést na str — <b>345</b>                 | A.3.    | Literály Unicode řetězců — 380                |
| 15.6.6. | Nepodporované typy operandů                 | A.4.    | Globální funkce unicode() — <b>380</b>        |
|         | pro +: 'int' a 'bytes' — <b>348</b>         | A.5.    | Datový typ long — <b>380</b>                  |
| 15.6.7. | Funkce ord() očekávala řetězec              | A.6.    | Porovnání <> — <b>381</b>                     |
|         | o délce 1, ale byl nalezen int — <b>350</b> | A.7.    | Slovníková metoda has_key() — <b>381</b>      |
| 15.6.8. | Neuspořádatelné datové typy:                | A.8.    | Slovníkové metody, které vracejí              |
|         | int() >= str() — <b>352</b>                 |         | seznamy — <b>382</b>                          |
| 15.6.9. | Globální jméno 'reduce'                     | A.9.    | Moduly, které byly přejmenovány               |
|         | není definováno — <b>355</b>                |         | nebo reorganizovány — <b>383</b>              |
| 15.7.   | Shrnutí — <b>357</b>                        | A.9.1.  | http — <b>383</b>                             |
|         | _   | A.9.2.  | urllib — <b>384</b>                           |
| 16.     | Balení pythonovských                        | A.9.3.  | dbm — <b>385</b>                              |
|         | knihoven — 359                              | A.9.4.  | xmlrpc — <b>385</b>                           |
| 16.1.   | Ponořme se — <b>361</b>                     | A.9.5.  | Ostatní moduly — <b>386</b>                   |
| 16.2.   | Věci, které za nás Distutils                | A.10.   | Relativní importy uvnitř balíčku — 387        |
|         | neudělají — <b>362</b>                      | A.11.   | Metoda iterátoru next() — 388                 |
| 16.3.   | Struktura adresáře — <b>363</b>             | A.12.   | Globální funkce filter() — 388                |
| 16.4.   | Píšeme svůj instalační skript — <b>364</b>  | A.13.   | Globální funkce map() — 389                   |
| 16.5.   | Přidáváme klasifikaci našeho                | A.14.   | Globální funkce reduce() — <b>390</b>         |
|         | balíčku — <b>366</b>                        | A.15.   | Globální funkce apply() — <b>390</b>          |
| 16.5.1. | Příklady dobrých klasifikátorů              | A.16.   | Globální funkce intern() — 390                |
|         | balíčků — <b>367</b>                        | A.17.   | Příkaz exec — <b>391</b>                      |
| 16.6.   | Určení dalších souborů                      | A.18.   | Příkaz execfile — <b>391</b>                  |
|         | prostřednictvím manifestu — <b>368</b>      | A.19.   | repr-literály (zpětné apostrofy) — <b>392</b> |
|         |   | A.20.   | Příkaz tryexcept — <b>392</b>                 |

| A.21.   | Příkaz raise — <b>393</b>                        | В.6.  | Třídy, které se chovají                         |
|---------|--|-------|---|
| A.22.   | Metoda generátorů throw — <b>393</b>             |       | jako množiny — <b>412</b>                       |
| A.23.   | Globální funkce xrange() — <b>394</b>            | B.7.  | Třídy, které se chovají                         |
| A.24.   | Globální funkce raw_input()                      |       | jako slovníky — <b>413</b>                      |
|         | a input() — <b>395</b>                           | B.8.  | Třídy, které se chovají jako čísla — <b>414</b> |
| A.25.   | Atributy funkcí func_* — <b>395</b>              | B.9.  | Třídy, které se dají porovnávat — <b>417</b>    |
| A.26.   | Metoda xreadlines()                              | B.10. | Třídy, které podporují serializaci — 418        |
|         | V/V objektů — 396                                | B.11. | Třídy, které mohou být použity                  |
| A.27.   | lambda funkce, které akceptují                   |       | v bloku with — <b>418</b>                       |
|         | n-tici místo více parametrů — <b>396</b>         | B.12. | Opravdu esoterické věci — <b>420</b>            |
| A.28.   | Atributy speciálních metod — <b>397</b>          | B.13. | Přečtěte si — <b>420</b>                        |
| A.29.   | Speciální metodanonzero — <b>397</b>             |       | <u> </u>  |
| A.30.   | Oktalové literály — <b>398</b>                   | C.    | Čím pokračovat — 423                            |
| A.31.   | sys.maxint — <b>398</b>                          | C.1.  | Doporučuji k přečtení — <b>425</b>              |
| A.32.   | Globální funkce callable() — <b>399</b>          | C.2.  | Kde hledat kód kompatibilní                     |
| A.33.   | Globální funkce zip() — <b>399</b>               |       | s Pythonem 3 — <b>426</b>                       |
| A.34.   | Výjimka StandardError — <b>399</b>               |       | <del>_</del>                                    |
| A.35.   | Konstanty modulu types — 400                     | D.    | Odstraňování problémů — 427                     |
| A.36.   | Globální funkce isinstance() — 400               | D.1.  | Ponořme se — <b>429</b>                         |
| A.37.   | Datový typ basestring — <b>401</b>               | D.2.  | Jak se dostat k příkazovému řádku — <b>429</b>  |
| A.38.   | itertools module — 401                           | D.3.  | Spuštění Pythonu z příkazového                  |
| A.39.   | <pre>sys.exc_type, sys.exc_value,</pre>          |       | řádku — <b>429</b>                              |
|         | sys.exc_traceback — <b>401</b>                   |       |   |
| A.40.   | Generátory seznamů nad n-ticemi — <b>402</b>     |       |   |
| A.41.   | Funkce os.getcwdu() — <b>402</b>                 |       |   |
| A.42.   | Metatřídy — <b>402</b>                           |       |   |
| A.43.   | Věci týkající se stylu — <b>403</b>              |       |   |
| A.43.1. | Množinové literály (set();                       |       |   |
|         | explicitně) — 403                                |       |   |
| A.43.2. | Globální funkce buffer()                         |       |   |
|         | (explicitně) — 403                               |       |   |
| A.43.3. | Bílé znaky kolem čárek                           |       |   |
|         | (explicitně) — 404                               |       |   |
| A.43.4. | Běžné obraty (explicitně) — <b>404</b>           |       |   |
| В.      | –<br>Jména speciálních metod — 405               |       |   |
| B.1.    | Ponořme se — <b>407</b>                          |       |   |
| B.2.    | Základy — <b>407</b>                             |       |   |
| B.3.    | Třídy, které se chovají                          |       |   |
|         | jako iterátory — <b>407</b>                      |       |   |
| B.4.    | Vypočítávané atributy — <b>408</b>               |       |   |
| B.5.    | Třídy, které se chovají jako funkce — <b>411</b> |       |   |
|         |  |       |   |

"Isn't this where we came in?"

— Pink Floyd, The Wall

# -1. Co najdete v "Ponořme se do Pythonu 3" nového

Obsah kapitoly

- -1. Co najdete v "Ponořme se do Pythonu 3" nového 17
- -1.1. aneb "záporná úroveň" 19

### -1.1. aneb "záporná úroveň"

Už jste v jazyce Python programovali? Četli jste originální publikaci "Dive Into Python"? Koupili jste si ji v knižní podobě? (Pokud ano, díky!) Jste připraveni ponořit se do jazyka Python 3?... Pokud tomu tak je, čtěte dál. (Pokud nic z toho neplatí, měli byste raději začít od začátku.)

- Kap. Python 3 se dodává se skriptem nazvaným 2to3. Naučte se jej. Milujte jej. Používejte jej. Přepis kódu do Pythonu 3 s využitím 2to3 je referenční příručkou ke všem věcem, které skript 2to3 umí opravit automaticky. A protože řada těchto věcí souvisí se změnami syntaxe, je tato příručka dobrým výchozím bodem ke studiu syntaktických změn, které Python 3 přináší. (Z příkazu print se stala funkce, obrat 'x' přestal fungovat atd.)
- Kap. Případová studie: Přepis chardet pro Python 3 popisuje mé (nakonec úspěšné) úsilí o přepis netriviální knihovny z Pythonu 2 do Pythonu 3. Možná vám tato studie pomůže, možná ne. Učící křivka je zde poměrně strmá, protože nejdříve musíte porozumět knihovně samotné. Teprve potom můžete rozumět tomu, proč přestala fungovat a jakým způsobem jsem ji opravil. Řada problémů se váže na řetězce. Když už o nich mluvíme...

Řetězce. Uffff. Kde mám začít? Python 2 používal "řetězce" a "řetězce v Unicode". Python 3 rozlišuje "bajty" a "řetězce". Všechny řetězce se nyní stávají řetězci v Unicode. Pokud s obsahem chceme zacházet jako s bajty, musíme použít nový datový typ nazvaný bytes. Python 3 *nikdy* skrytě nepřevádí řetězce na bajty a naopak. Takže pokud si v každém momentě nejste jistí, zda používáte ten či onen typ, kód vašeho programu téměř jistě přestane fungovat. Další podrobnosti naleznete v kapitole Řetězce.

Problém bajty versus řetězce se v textu této knihy vynořuje znovu a znovu.

- V kapitole <u>Soubory</u> se seznámíte s rozdílem mezi čtením souborů v "binárním" a "textovém" režimu. Při čtení (ale také při zápisu) souborů v textovém režimu se vyžaduje zadání parametru určujícího kódování (encoding). Některé metody textových souborů počítají znaky, ale jiné metody zase počítají bajty. Pokud ve svém zdrojovém kódu předpokládáte, že se jeden znak rovná jednomu bajtu, pak to při přechodu na vícebajtové znaky *přestane fungovat*.
- V kapitole <u>Webové služby nad HTTP</u> čte modul httplib2 hlavičky a data prostřednictvím protokolu HTTP. Hlavičky se vracejí v podobě řetězců, ale těla se vracejí jako bajty.
- V kapitole <u>Serializace pythonovských objektů</u> se naučíte, proč modul pickle pro Python 3 definuje nový datový formát, který je zpětně nekompatibilní s verzí pro Python 2. (Nápověda: Důvodem jsou bajty a řetězce.) Python 3 podporuje také serializaci objektů do a z json, který dokonce nepracuje s typem bytes. Ukážeme si, jak se to dá obejít.
- V části <u>Případová studie: Přepis chardet pro Python 3</u> se setkáte se zatraceným zmatkem mezi bajty a řetězci úplně všude.

Dokonce i kdyby vás Unicode nechával úplně chladné (ale ne, nenechá), budete si určitě chtít něco přečíst o formátování řetězců v jazyce Python 3. Zcela se liší od předpisu formátování řetězců v jazyce Python 2.

S iterátory se v Pythonu 3 setkáte všude. A teď už jim rozumím mnohem víc, než tomu bylo před pěti lety, kdy jsem napsal "Dive Into Python". Snažte se jim porozumět také, protože mnoho funkcí, které v jazyce Python 2 vracely seznamy, vrací v Pythonu 3 právě iterátory. Přinejmenším byste si měli přečíst druhou polovinu kapitoly Iterátory a druhou polovinu kapitoly Iterátory pro pokročilé.

Kap. Na přání čtenářů jsem přidal přílohu <u>Jména speciálních metod</u>, která se podobá kapitole <u>Data Model</u> (<u>Datový model</u>) uvedené v dokumentaci jazyka Python.

V době, kdy jsem psal "Dive Into Python", měly všechny dostupné knihovny pro práci s XML mizernou kvalitu. Pak ale Fredrik Lundh napsal modul **ElementTree**, který není *ale vůbec mizerný*. Pythonovští bohové moudře začlenili ElementTree do standardní knihovny, a tak se tento modul stal základem mé nové kapitoly o XML. Starší způsoby zpracování XML jsou stále podporované, ale měli byste se jim vyhnout, protože jsou zkrátka mizerné!

V Pythonu je nové také to — ne v jazyce, ale v komunitě uživatelů —, že se objevila úložiště kódu, jako je **Python Package Index (PyPI)**. Python se dodává s utilitami k zabalení vašeho kódu do standardního formátu a tyto balíčky pak mohou být zveřejněny na PyPI. O podrobnostech se dočtete v kapitole <u>Balení pythonovských knihoven</u>.

0. Kapitola

- "Tempora mutantur nos et mutamur in illis." (Časy se mění a my se měníme s nimi.)
- přísloví ze starého Říma

## O. Instalujeme Python

#### 0. Instalujeme Python — 21

- 0.1. Ponořme se **23**
- 0.2. Který Python je pro vás ten správný? 23
- 0.3. Instalace pod Microsoft Windows 24
- 0.4. Instalace pod Mac OS X 29
- 0.5. Instalace pod Ubuntu Linux **36**
- 0.6. Instalace na jiných platformách 40
- 0.7. Použití Python Shell 41
- 0.8. Editory a vývojová prostředí pro Python 43

- 0.1. Ponořme se
- 0.2. Který Python je pro vás ten správný?

#### 0.1. Ponořme se

Než začneme programovat v jazyce Python 3, musíme si jej nainstalovat. Nebo ne?

#### 0.2. Který Python je pro vás ten správný?

Pokud používáte účet na hostovaném serveru, mohl být Python 3 již nainstalován jeho správcem. Pokud provozujete Linux doma, můžete mít Python 3 již také k dispozici. Nejpopulárnější distribuce systému GNU/Linux obsahují v základní instalaci Python 2. Malá, ale zvětšující se skupina distribucí obsahuje také Python 3. Mac OS X se dodává s Pythonem 2 (verze spouštěná přes příkazový řádek), ale v době psaní této knihy neobsahoval Python 3. Microsoft Windows se nedodává s žádnou verzí Pythonu. Ale nepropadejte zoufalství! Nezávisle na tom, jaký operační systém používáte, můžete Python nainstalovat na několik kliknutí.

Nejjednodušší způsob ověření si, zda máte k dispozici Python 3 na svém systému Linux nebo Mac OS X, začíná tím, že se dostanete na příkazový řádek. Jakmile se nacházíte za vyzývacím řetězcem příkazového řádku, napište jednoduše python3 (vše malými písmeny, bez mezer), stiskněte ENTER a uvidíte, co se stane. Na svém domácím systému Linux už mám Python 3.1 nainstalovaný. Uvedeným příkazem vstoupím do *pythonovského interaktivního shellu*.

```
mark@atlantis:~$ python3
Python 3.1 (r31:73572, Jul 28 2009, 06:52:23)
[GCC 4.2.4 (Ubuntu 4.2.4-1ubuntu4)] on linux2
Type "help", "copyright", "credits" or "license" for more information.
>>>
```

(Až budete chtít pythonovský interaktivní shell opustit, napište exit() a stiskněte ENTER.)

Můj poskytovatel webového prostoru používá také Linux a umožňuje přístup přes příkazový řádek, ale Python 3 není na serveru nainstalován. (Béééé!)

```
mark@manganese:~$ python3
bash: python3: command not found
```

Takže zpět k otázce, kterou jsme tuto podkapitolu zahájili: "Který Python je pro vás ten správný?" Ten, který poběží na počítači, který máte k dispozici.

Následuje návod pro instalaci pod Windows, nebo přeskočte na Instalace pod Mac OS X, Instalace pod Ubuntu Linux nebo Instalace na jiných platformách.

#### 0.3. Instalace pod Microsoft Windows

V dnešní době se Windows dodávají ve dvou architekturách: 32bitové a 64bitové. Máme tu samozřejmě řadu různých verzí Windows — XP, Vista, Windows 7 —, ale Python běží na všech. Rozlišení mezi 32bitovou a 64bitovou architekturou je důležitější. Pokud nemáte vůbec tušení, jakou architekturu používáte, pak je to pravděpodobně 32bitová.

Přejděte na stránku python.org/download/ a stáhněte si windowsovský instalátor Python 3, který se hodí pro vaši architekturu. Možnosti vaší volby budou vypadat nějak takto:

- Python 3.1 Windows installer (Windows binary does not include source)
- Python 3.1 Windows AMD64 installer (Windows AMD64 binary does not include source)

Nechci zde uvádět konkrétní odkazy, protože Python neustále prochází drobnými úpravami a nechci být zodpovědný za to, že jste nějakou důležitou úpravu prošvihli. Vždy byste měli nainstalovat co nejnovější verzi Pythonu 3.x, tedy pokud nemáte nějaké esoterické důvody k tomu, abyste tak neučinili.

Jakmile se stahování dokončí, poklepejte na soubor s příponou .msi. Protože se snažíte o spuštění programu, zobrazí Windows bezpečnostní varování. Oficiální instalátor Pythonu je digitálně podepsán jménem organizace *Python Software Foundation*, která dohlíží na vývoj jazyka Python. Nepřijímejte imitace!

Instalaci Pythonu 3 zahájíme stisknutím tlačítka Run.



Nejdříve se vás instalátor zeptá, zda chcete Python 3 nainstalovat pro všechny uživatele, nebo jen pro sebe. Volba "instalovat pro všechny uživatele" je přednastavena. Pokud nemáte nějaký dobrý důvod pro jinou volbu, pak toto je ta nejlepší. (Jeden možný důvod, proč byste mohli chtít "instalovat jen pro mne", je ten, že si chcete nainstalovat Python na počítači v práci a váš účet ve Windows nemá oprávnění administrátora. Ale proč byste v takovém případě chtěli instalovat Python bez svolení svého správce Windows? Ne abyste mě dostali do potíží!)

Svoji volbu způsobu instalace potvrdíte stiskem tlačítka Next.



Instalátor vás poté vyzve k výběru instalačního adresáře. Pro všechny verze Python 3.1.x je přednastavena hodnota C:\Python31\, která by měla vyhovovat většině uživatelů. Pokud ovšem nemáte zvláštní důvod cestu změnit. Pokud instalujete všechny aplikace na disk označený jiným písmenem, můžete příslušnou cestu vybrat příslušnými ovládacími prvky. Nebo prostě cestu k adresáři napíšete do spodního pole. Python nemusíte instalovat jen na disk C:. Můžete si jej nainstalovat na libovolný disk a do libovolného adresáře.

Volbu cílového adresáře potvrdíte stiskem tlačítka Next.



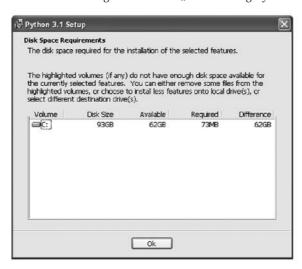
Další dialogová stránka vypadá komplikovaně, ale ve skutečnosti není. V případě Pythonu 3 máte možnost neinstalovat úplně všechny jeho komponenty — podobně jako u jiných instalačních programů. Pokud máte obzvlášť málo místa na disku, můžete některé komponenty vynechat.



- Volba Register Extensions (asociovat přípony) vám zajistí možnost spouštět pythonovské skripty (soubory s příponou .py) poklepáním na jejich ikonu. Je to sice doporučeno, ale není to nezbytné. (Tato volba nevyžaduje žádný diskový prostor, takže její potlačení není výhodné.)
- Tcl/Tk je grafická knihovna, kterou využívá pythonovský shell. Ten budeme používat v celé knize. Velmi doporučuji, abyste tuto volbu ponechali zapnutou.
- Volba Documentation vede k instalaci souborů s nápovědou, která obsahuje mnohé z informací
  uvedených na docs.python.org. Pokud máte omezený přístup k internetu nebo pokud používáte vytáčené připojení, doporučuji volbu ponechat zapnutou.
- Volba Utility Scripts v sobě zahrnuje i instalaci skriptu 2to3.py, o kterém se budeme učit v této knize později. Pokud se chcete naučit přepisování existujícího kódu napsaného pro Python 2 do podoby pro Python 3, pak se zapnutí této volby vyžaduje. Pokud nemáte žádné programy napsané pro Python 2, můžete tuto volbu vypnout.
- Volba Test Suite zajistí instalaci sady skriptů, které se používají pro testování funkčnosti interpretu jazyka Python. V této knize je nebudeme používat. A nepoužíval jsem je nikdy ani během výuky programování v Pythonu. Volba je zcela na vás.

Pokud si nejste jisti, kolik máte místa na disku, klikněte na tlačítko Disk Usage. Instalátor zobrazí seznam písmen vašich disků, zjistí, kolik místa je na každém z nich, a vypočítá, kolik místa na nich zbude po instalaci.

Stiskem tlačítka OK se dostaneme na dialogovou stránku "Customizing Python".

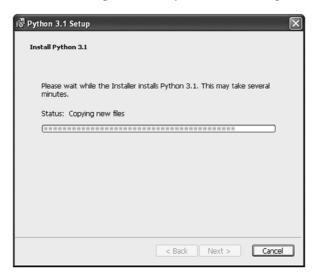


Pokud se rozhodnete volbu vynechat, stiskněte tlačítko pro rozbalení seznamu a vyberte "Entire feature will be unavailable" (celá část bude nedostupná). Vynecháním Test Suite ušetříte na disku pěkných 7908 kb.

Výběr voleb potvrdíte stiskem tlačítka Next.



Instalátor nakopíruje všechny nezbytné soubory do vámi vybraného adresáře. (Proběhne to tak rychle, že jsem to musel zkusit třikrát, než se mi podařilo zachytit obrázek tohoto procesu.)

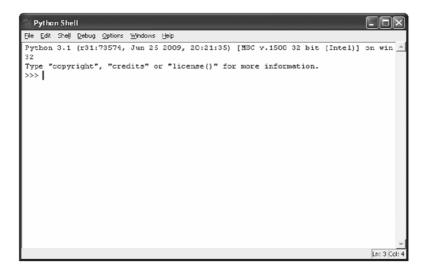


Stiskem tlačítka Finish ukončíme činnost instalátoru.



Ve vašem menu Start by se měla objevit položka s názvem Python 3.1. V ní se nachází program IDLE. Výběrem této položky spustíte interaktivní pythonovský shell. (Poznámka překladatele: Někdy ho autor označuje jako "grafický" interaktivní shell. Jde o obdobu interaktivního pythonovského shellu, který se spouští v konzolovém okně. Tentokrát ale využívá prostředky grafického uživatelského

rozhraní (GUI) a v menu okna nalezneme i položky pro spuštění editoru nebo pro spuštění ladicího režimu. Dalo by se říct, že je to nástroj "téměř úplně, ale ne zcela naprosto nepodobný..." klasickým IDE (integrované vývojové prostředí). Jenže to není soustředěné kolem editoru, ale spíš kolem shellu. Je to prostě IDLE. No zkrátka se na to podívejte a rozhodněte se sami, jak tomu budete říkat.)



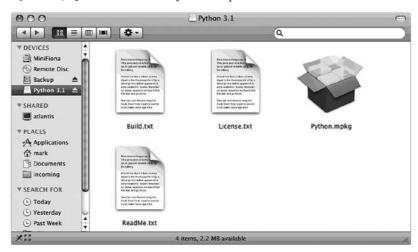
#### 0.4. Instalace pod Mac OS X

Všechny moderní počítače Macintosh používají procesor firmy Intel (stejný jako většina osobních počítačů s Windows). Starší počítače Mac používají procesory PowerPC. Rozdílům rozumět nemusíte, protože existuje jen jeden jediný instalátor Pythonu pro všechny počítače Macintosh.

Přejděte na stránku python.org/download/ a stáhněte si příslušný instalátor pro Mac. Bude u něj napsáno něco ve stylu **Python 3.1 Mac Installer Disk Image**, ačkoliv číslo verze se může lišit. Ujistěte se, že stahujete verzi 3.x a ne 2.x.

Váš prohlížeč by měl automaticky připojit obraz disku a otevřít okno Finder zobrazující jeho obsah. (Pokud se tak nestane, budete muset najít obraz disku ve svém adresáři pro stažené soubory a připojit jej poklepáním. Jmenuje se python-3.1. dmg nebo podobně.) Obraz disku obsahuje řadu textových souborů (Build.txt, License.txt, ReadMe.txt) a také skutečný instalační balík Python.mpkg.

Poklepejte na Python.mpkg a instalátor Mac Python se spustí.



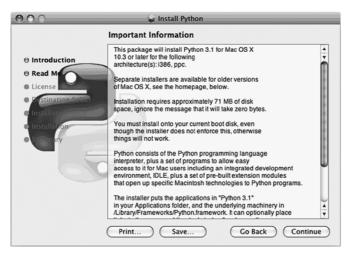
Na první stránce naleznete stručný popis jazyka Python a pro více detailů jste odkázáni na soubor ReadMe.txt. (...který jste nečetli. Nebo četli?)

Dál se posuneme stiskem tlačítka Continue.



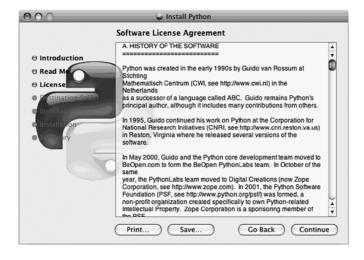
Následující stránka dialogu obsahuje některé důležité informace: Python vyžaduje Mac OS X 10.3 nebo novější. Pokud stále používáte Mac OS X 10.2, budete jej muset aktualizovat na vyšší verzi. Společnost Apple už pro váš operační systém neposkytuje bezpečnostní aktualizace a už při pouhém připojení na internet vystavujete svůj počítač riziku. A navíc nemůžete používat Python 3.

Pokračujeme stiskem tlačítka Continue.



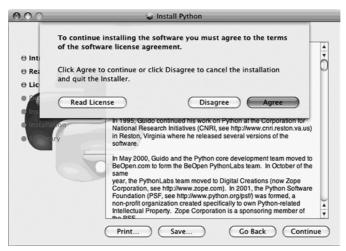
Tak jako všechny dobré instalátory, i ten pythonovský zobrazí licenční ujednání. Python je open source a jeho licence je schválena společností Open Source Initiative. Během historického vývoje měl Python řadu vlastníků a sponzorů. Každý z nich zanechal v jeho licenci svůj otisk. Ale konečný výsledek vypadá takto: Python je open source, můžete jej používat na libovolné platformě, pro libovolný účel, zdarma a bez závazku k protislužbě.

Stiskněte tlačítko Continue ještě jednou.



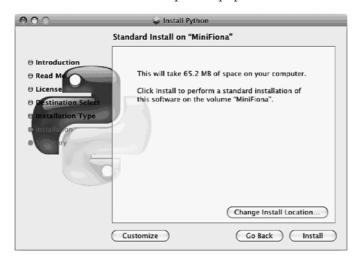
Abyste mohli instalaci dokončit, musíte kvůli manýrům v jádru applovského instalátoru projevit "souhlas" se softwarovou licencí. Ale protože Python je open source, ve skutečnosti "souhlasíte" s tím, že vám licence zaručuje práva navíc, než aby vás omezovala.

Pokračujeme stiskem tlačítka Agree.



Na další obrazovce můžete změnit umístění instalace. Python musíte instalovat na zaváděcí disk, ale kvůli omezením instalátoru to není vynuceno. Popravdě řečeno, nikdy jsem nepociťoval potřebu umístění instalace měnit.

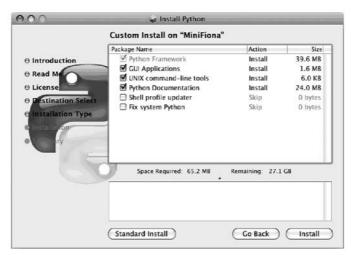
Na této obrazovce také můžete instalaci upravit vyloučením komponent, které nepotřebujete. Pokud tak chcete učinit, stiskněte tlačítko Customize. V opačném případě stiskněte tlačítko Install.



Pokud zvolíte uživatelskou úpravu instalace (Custom Install), nabídne vám instalátor následující seznam:

- Python Framework. Jde o jádro Pythonu. Proto je tato možnost předvolena a současně je zakázáno ji měnit. Tato část se nainstalovat musí.
- GUI Applications v sobě zahrnuje IDLE, což je grafický pythonovský shell. Budeme jej používat během celé knihy. Velmi doporučuji, abyste tuto volbu ponechali zapnutou.
- UNIX command-line tools v sobě obsahuje konzolovou aplikaci python3. Velmi doporučuji, abyste také tuto volbu ponechali zapnutou.
- Python Documentation obsahuje mnohé z informací uvedených na docs.python.org. Pokud máte omezený přístup k internetu nebo pokud používáte vytáčené připojení, doporučuji volbu ponechat zapnutou.
- Shell profile updater kontroluje, zda je nutné aktualizovat váš shellovský profil (použitý v Terminal.app) tak, aby bylo zajištěno, že umístění instalované verze Pythonu bude součástí prohledávaných cest. Tuto volbu pravděpodobně nebudete potřebovat měnit.
- Volbu Fix system Python byste měnit neměli. (Říká vašemu počítači, aby byl Python 3 použit jako preferovaný Python pro spouštění všech skriptů, včetně zabudovaných skriptů dodávaných firmou Apple. Dopadlo by to velmi špatně, protože většina těchto skriptů byla napsána pro Python 2 a pod verzí Python 3 by neběžely správně.)

Pokračujeme stiskem tlačítka Install.



Instalátor se vás zeptá na heslo správce, protože systémové binární soubory a nástroje se instalují do adresáře /usr/local/bin/. Bez administrátorských oprávnění Mac Python zkrátka nenainstalujete.

Stiskem tlačítka OK zahájíme instalaci.



Během instalace částí, které jste si vybrali, instalátor indikuje postup instalace.



Pokud šlo všechno dobře, oznámí vám instalátor úspěšné dokončení instalace zobrazením zelené "fajfky".



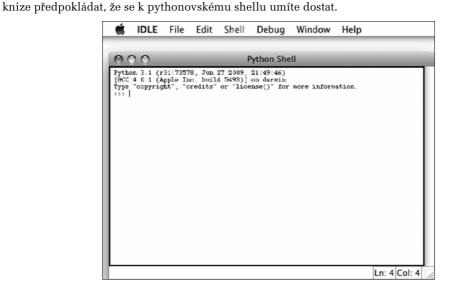


Za předpokladu, že jste nezměnili umístění instalace, najdete nově nainstalované soubory v podadresáři Python 3.1 uvnitř adresáře /Applications. Nejdůležitější součástí je zde grafický pythonovský shell zvaný idle.

Poklepejte na něj a pythonovský shell se spustí.

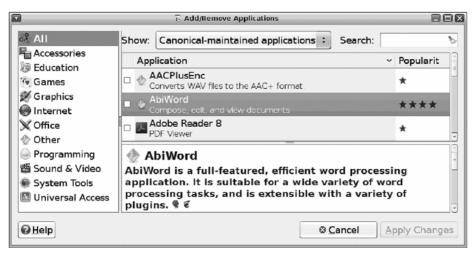


V pythonovském shellu strávíte při průzkumu jazyka Python nejvíce času. U příkladů budeme v této



#### 0.5. Instalace pod Ubuntu Linux

Moderní distribuce systému Linux jsou podepřeny ohromnými úložišti předkompilovaných aplikací, které jsou připraveny k okamžité instalaci. Detaily se pro konkrétní distribuce liší. Nejsnadnější způsob instalace Pythonu 3 pod Ubuntu Linux spočívá v použití nástroje Add/Remove, který najdete v menu Applications.



Když poprvé spustíte aplikaci Add/Remove, zobrazí vám seznam předvybraných aplikací v různých kategoriích. Některé z nich jsou již nainstalované, ale většina z nich ne. Protože úložiště obsahuje přes 10 tisíc aplikací, můžete pomocí různých filtrů omezit zobrazení jen na jeho malé části. Základem je filtr "Canonical-maintained applications", což je malá podmnožina z celkového množství aplikací, které jsou oficiálně podporovány společností Canonical, která vytvořila a udržuje distribuci Ubuntu Linux.

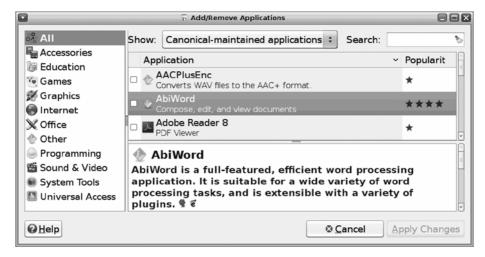
Python 3 není společností Canonical udržován, takže jako první krok potlačíme činnost tohoto filtru a vybereme "All Open Source applications" (všechny open source aplikace).



Jakmile změníte nastavení filtru tak, aby zahrnoval všechny open source aplikace, použijte k vyhledání Pythonu 3 vyhledávací box nacházející se hned za nabídkou filtru.



V tom okamžiku se seznam aplikací zúží jen na ty, které souvisejí s Pythonem 3. Poté vybereme dva balíčky. Tím prvním je Python (v3.0). Obsahuje vlastní interpret jazyka Python.



Druhý požadovaný balíček se nachází bezprostředně nad ním: IDLE (using Python-3.0). Jde o grafický pythonovský shell, který budeme používat během celé knihy.

Po označení uvedených dvou balíčků pokračujte stiskem tlačítka Apply Changes.



Správce balíčků vás požádá o potvrzení, že chcete přidat jak IDLE (using Python-3.0), tak Python (v3.0). Pokračujeme stiskem tlačítka Apply.



Během stahování potřebných balíčků z internetového úložiště společnosti Canonical zobrazuje správce balíčků indikátor postupu stahování.

Jakmile jsou balíčky staženy, zahájí správce balíčků automaticky jejich instalaci.



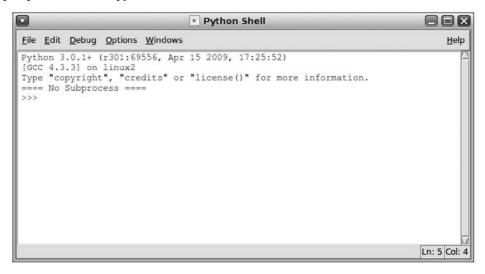


Pokud šlo všechno dobře, potvrdí správce balíčků, že byly oba úspěšně nainstalovány. V tomto okamžiku můžete poklepáním na IDLE spustit pythonovský shell, nebo můžete stiskem tlačítka Close ukončit činnost správce balíčků.

Pythonovský shell můžete spustit kdykoliv tím způsobem, že v menu Applications a v podmenu Programming vyberete IDLE.



V pythonovském shellu strávíte při průzkumu jazyka Python nejvíce času. U příkladů budeme v této knize předpokládat, že se k pythonovskému shellu umíte dostat.



### 0.6. Instalace na jiných platformách

Python 3 je dostupný pro řadu různých platforem. Abychom byli konkrétnější, je dostupný pro prakticky každou distribuci systému Linux, BSD a pro distribuce založené na systému Solaris. Takže například RedHat Linux používá správce balíčků yum. FreeBSD má svou sbírku ports and packages collection, SUSE má zypper a Solaris má pkgadd. Když zkusíte zběžně prohledat web při zadání Python 3 + váš operační systém, dozvíte se, zda je balík s Pythonem 3 dostupný, a pokud ano, jak jej můžete nainstalovat.

### 0.7. Použití Python Shell

Python Shell (kvůli skloňování a zobecnění pohledu mu budeme říkat také *pythonovský shell*) bude nástrojem pro studium syntaxe jazyka Python, zdrojem interaktivní nápovědy k příkazům a prostředkem pro ladění krátkých programů. Grafický pythonovský shell (pojmenovaný IDLE) obsahuje navíc ucházející textový editor, který podporuje barevné zvýrazňování syntaxe a zajišťuje spolupráci s (konzolovým) pythonovským shellem. Pokud již nemáte nějaký svůj oblíbený textový editor, měli byste si IDLE vyzkoušet.

Ale proberme nejdříve hlavní věci. Samotný Python Shell je úžasné interaktivní prostředí, se kterým si vyhrajete. V celé knize se budete setkávat s příklady, jako je tento:

```
>>> 1 + 1
2
```

Tři úhlové závorky (>>>) jsou vyzývacím řetězcem pythonovského shellu. Tuto část neopisujte. Vyjadřuji tím to, že byste si příklad měli vyzkoušet v pythonovském shellu.

Vy budete psát pouze část 1 + 1. V pythonovském shellu můžete napsat jakýkoliv platný pythonovský výraz nebo příkaz. Nestyďte se! Nekousne vás to! Přinejhorším se stane to, že se vám zobrazí chybové hlášení. Příkazy se provádějí okamžitě (jakmile stisknete ENTER). Také výrazy jsou vyhodnoceny okamžitě a pythonovský shell vytiskne jejich výsledek.

Takže zobrazená část 2 je výsledkem vyhodnocení předchozího výrazu. Protože se tak stalo, je 1 + 1 zjevně platným pythonovským výrazem. Jeho výsledek je samozřejmě 2.

Vyzkoušejme něco dalšího.

```
>>> print('Hello world!')
Hello world!
```

Docela jednoduché, že? Ale v pythonovském shellu toho můžete dělat mnohem víc. Když se někdy zadrhnete — když si nemůžete vzpomenout na nějaký příkaz nebo si nemůžete vzpomenout na správné argumenty předávané nějaké funkci —, můžete se v pythonovském shellu dostat k interaktivní nápovědě. Napište prostě help a stiskněte ENTER.

```
>>> help
Type help() for interactive help, or help(object) for help about object.
```

Nápovědu můžeme používat ve dvou režimech. Můžeme získat nápovědu pro jeden objekt. Vytiskne se prostě jeho dokumentace a vrátíte se na vyzývací řádek pythonovského shellu. Nebo můžeme vstoupit do *režimu nápovědy*, ve kterém místo vyhodnocování pythonovských výrazů píšeme klíčová slova nebo jména příkazů a Python zobrazuje vše, co o těchto příkazech ví.

Pro vstup do interaktivního režimu nápovědy napište help() a stiskněte ENTER.

```
>>> help()
```

Welcome to Python 3.0! This is the online help utility.

If this is your first time using Python, you should definitely check out the tutorial on the Internet at http://docs.python.org/tutorial/.

Enter the name of any module, keyword, or topic to get help on writing Python programs and using Python modules. To quit this help utility and return to the interpreter, just type "quit".

To get a list of available modules, keywords, or topics, type "modules", "keywords", or "topics". Each module also comes with a one-line summary of what it does; to list the modules whose summaries contain a given word such as "spam", type "modules spam".

help>

Všimněte si, že se vyzývací řetězec změnil z >>> na help>. Má vám to připomenout, že se nacházíte v interaktivním režimu nápovědy. V tomto okamžiku můžete napsat libovolné klíčové slovo, příkaz, jméno modulu, jméno funkce — v podstatě cokoliv, čemu Python rozumí — a přečtete si k tomu zobrazenou dokumentaci.

```
help> print
Help on built-in function print in module builtins:

print(...)
    print(value, ..., sep=' ', end='\n', file=sys.stdout)

Prints the values to a stream, or to sys.stdout by default.
    Optional keyword arguments:
    file: a file-like object (stream); defaults to the current sys.stdout.
    sep: string inserted between values, default a space.
    end: string appended after the last value, default a newline.

help> PapayaWhip
no Python documentation found for 'PapayaWhip'

help> quit
```

You are now leaving help and returning to the Python interpreter. If you want to ask for help on a particular object directly from the

interpreter, you can type "help(object)". Executing "help('string')" has the same effect as typing a particular string at the help> prompt. >>>

[4]

- [1] Abyste dostali dokumentaci k funkci print(), napište print a stiskněte ENTER. V interaktivním režimu nápovědy se zobrazí něco podobného jako manovská stránka: jméno funkce, stručný popis, argumenty funkce a jejich přednastavené hodnoty a tak dále. Pokud se vám zdá obsah dokumentace nejasný, nepropadejte panice. V následujících několika kapitolách se o těchto věcech dozvíte více.
- V interaktivním režimu nápovědy se samozřejmě nedozvíte všechno. Pokud zde napíšete něco, [2] co není pythonovským příkazem, modulem, funkcí nebo nějakým zabudovaným klíčovým slovem, režim interaktivní nápovědy prostě pokrčí svými virtuálními rameny.
- Interaktivní režim nápovědy ukončíte tím, že napíšete quit a stisknete ENTER. [3]
- [4] Vyzývací řádek se změní zpět na >>>, čímž se dozvíte, že jste opustili režim interaktivní nápovědy a vrátili jste se do pythonovského shellu.

Grafický pythonovský shell IDLE navíc obsahuje textový editor šitý na míru jazyku Python.

# Editory a vývojová prostředí pro Python

Pokud jde o psaní programů v jazyce Python, nepředstavuje idle jedinou možnost. Jakkoliv může být užitečný při seznamování se s jazykem jako takovým, mnozí vývojáři dávají přednost jiným textovým editorům nebo integrovaným vývojovým prostředím (Integrated Development Environment, čili IDE). Nebudu se zde jimi zabývat, ale komunita uživatelů jazyka Python udržuje seznam editorů podporujících jazyk Python, který pokrývá široké rozpětí podporovaných platforem a softwarových licencí.

Možná chcete nahlédnout i do seznamu ide podporujících jazyk Python, i když zatím pouze nemnohé z nich podporují Python 3. Jedním z těch, které jej podporují, je PyDev, zásuvný modul pro Eclipse, který změní Eclipse na plnohodnotné pythonovské integrované vývojové prostředí. Jak Eclipse, tak PyDev jsou multiplatformní a open source.

Z komerčních produktů jmenujme Komodo IDE společnosti ActiveState. Licence je vázána na uživatele. Studenti mohou získat slevu a k dispozici je i zkušební, časově omezená verze.

V jazyce Python programuji už devět let. Své programy edituji v prostředí GNU Emacs a ladím je v konzolovém pythonovském shellu. Při vývoji v jazyce Python není žádná cesta správnější nebo vyloženě špatná. Najděte si způsob, který vyhovuje právě vám!

1. Kapitola

- "Don't bury your burden in saintly silence. You have a problem? Great. Rejoice, dive in, and investigate." (Neutápějte své břímě ve svatém mlčení. Máte problém? Paráda. Radujte se,
  - Ven. Henepola Gunaratana

ponořte se do něj, bádejte.)

# 1. Váš první pythonovský program

| 1.     | Váš první pythonovský program — 45            |
|--------|---|
| 1.1.   | Ponořme se — <b>47</b>                        |
| 1.2.   | Deklarace funkcí — 48                         |
| 1.2.1. | Nepovinné a pojmenované argumenty — 49        |
| 1.3.   | Psaní čitelného kódu — <b>51</b>              |
| 1.3.1. | Dokumentační řetězce — <b>51</b>              |
| 1.4.   | Vyhledávací cesta pro import — <b>52</b>      |
| 1.5.   | Všechno je objekt — <b>53</b>                 |
| 1.5.1. | Co to vlastně je objekt? — <b>54</b>          |
| 1.6.   | Odsazování kódu — <b>54</b>                   |
| 1.7.   | Výjimky — <b>55</b>                           |
| 1.7.1. | Obsluha chyb importu — <b>57</b>              |
| 1.8.   | Volné proměnné — 58                           |
| 1.9.   | Vše je citlivé na velikost písmen — <b>58</b> |

Spouštění skriptů — **59** 

Přečtěte si — 60

1.10.1.11.

### 1.1. Ponořme se

Konvence nám diktuje, že bych vás teď měl otravovat základními stavebními kameny, které s programováním souvisejí. A z nich bychom pak měli pomalu budovat něco užitečného. Přeskočme to. Tady máte úplný a funkční pythonovský program. Pravděpodobně vám bude zcela nepochopitelný. Žádné strachy. Rozpitváme ho řádek po řádku. Ale nejdříve si jej celý přečtěte a zjistěte, co z něj chápete (pokud vůbec něco).

```
SUFFIXES = {1000: ['KB', 'MB', 'GB', 'TB', 'PB', 'EB', 'ZB', 'YB'],
            1024: ['KiB', 'MiB', 'GiB', 'TiB', 'PiB', 'EiB', 'ZiB', 'YiB']}
def approximate_size(size, a_kilobyte_is_1024_bytes=True):
    '''Convert a file size to human-readable form.
    Keyword arguments:
    size -- file size in bytes
    a_kilobyte_is_1024_bytes -- if True (default), use multiples of 1024
                                 if False, use multiples of 1000
    Returns: string
    . . .
    if size < 0:
        raise ValueError('number must be non-negative')
    multiple = 1024 if a_kilobyte_is_1024_bytes else 1000
    for suffix in SUFFIXES[multiple]:
        size /= multiple
        if size < multiple:</pre>
            return '{0:.1f} {1}'.format(size, suffix)
    raise ValueError('number too large')
if __name__ == '__main__':
    print(approximate_size(100000000000, False))
    print(approximate_size(100000000000))
Spusťme program z příkazového řádku. Pod Windows to bude vypadat nějak takto:
```

```
c:\home\diveintopython3\examples> c:\python31\python.exe humansize.py
1.0 TB
931.3 GiB
```

Pod Mac OS X nebo pod Linuxem to bude vypadat zase takhle:

you@localhost:~/diveintopython3/examples\$ python3 humansize.py
1.0 TB
931.3 GiB

Co se to vlastně stalo? Spustili jste svůj první pythonovský program. Z příkazového řádku jste zavolali interpret jazyka Python a předali jste mu jméno skriptu, který měl být proveden. Uvedený skript definuje jedinou funkci, approximate\_size(), která přebírá přesnou velikost souboru v bajtech a vypočítá velikost "v hezčím tvaru" (ale přibližnou). (Pravděpodobně už jste něco podobného viděli v Průzkumníku Windows, v okně Finder na Mac OS X nebo v aplikacích Nautilus nebo Dolphin nebo Thunar na Linuxu. Když si necháte složku s dokumenty zobrazit v podobě vícesloupcového seznamu, uvidíte v tabulce ikonu dokumentu, jméno dokumentu, velikost, typ, datum poslední změny a tak dále. Pokud složka obsahuje soubor se jménem TODO a s velikostí 1093 bajtů, nezobrazí váš správce souborů TODO 1093 bytes. Místo toho se ukáže něco jako TODO 1 KB. A právě tohle dělá funkce approximate\_size().)

Podívejte se na konec skriptu a uvidíte dva řádky s voláním print(approximate\_size(argumenty)). Jde o volání funkcí. Nejdříve se volá funkce approximate\_size() a předávají se jí argumenty. Její návratová hodnota se předává přímo funkci print(). Funkce print() patří mezi zabudované (built-in). Její deklaraci nikdy neuvidíte. Můžete ji ale používat — kdykoliv a kdekoliv. (Zabudovaných funkcí existuje celá řada. A ještě mnohem více se jich nachází v různých modulech. Jen klid...)

Takže proč vlastně spuštěním skriptu z příkazového řádku získáme pokaždé stejný výstup? K tomu se ještě dostaneme. Nejdříve se podíváme na funkci approximate\_size().

### 1.2. Deklarace funkcí

Python pracuje s funkcemi podobně jako většina dalších jazyků, ale neodděluje hlavičkové soubory jako c++ nebo sekce rozhraní/implementace jako Pascal. Pokud potřebujete nějakou funkci, prostě ji deklarujete, jako třeba zde:

def approximate\_size(size, a\_kilobyte\_is\_1024\_bytes=True):

Deklarace funkce začíná klíčovým slovem def. Následuje jméno funkce a v závorce pak argumenty. Více argumentů se odděluje čárkami.

Pokud potřebujete nějakou funkci, prostě ji deklarujte.

Všimněte si, že funkce nedefinuje typ návratové hodnoty. Funkce v jazyce Python neurčují datový typ návratové hodnoty. Neurčují dokonce ani to, jestli vracejí hodnotu nebo ne. (Ve skutečnosti každá pythonovská funkce vrací hodnotu. Pokud funkce provede příkaz return, vrátí v něm uvedenou hodnotu. V ostatních případech vrací None, což je pythonovský ekvivalent hodnoty null, nil, nic, žádná hodnota.)

V některých jazycích funkce (které vracejí hodnotu) začínají slovem function a podprogramy (které nevracejí hodnotu) začínají slovem sub. Jazyk Python žádné podprogramy nezná. Vše jsou funkce, všechny funkce vracejí hodnotu (i když někdy je to None) a všechny funkce začínají slovem def.

Funkce approximate\_size() přebírá dva argumenty — size a a\_kilobyte\_is\_1024\_bytes —, ale u žádného z nich není určen datový typ. V jazyce Python nemají proměnné explicitně určen typ nikdy. Python zjistí, jakého typu proměnná je, a vnitřně si to eviduje.

V jazyce Java a v dalších jazycích se statickými datovými typy musíme určovat datový typ návratové hodnoty funkce a každého argumentu funkce. V jazyce Python nikdy explicitně neurčujeme datový typ čehokoliv. Python vnitřně sleduje datový typ podle toho, jakou hodnotu jsme přiřadili.

## 1.2.1. Nepovinné a pojmenované argumenty

Python umožňuje nastavit argumentům funkce implicitní hodnotu. Pokud funkci zavoláme bez zadání argumentu, získá argument svou implicitní hodnotu. Pokud použijeme pojmenované argumenty, můžeme je navíc (při volání funkce) zadat v libovolném pořadí.

Teď se na deklaraci funkce approximate\_size() podíváme ještě jednou:

```
def approximate_size(size, a_kilobyte_is_1024_bytes=True):
```

U druhého argumentu, a\_kilobyte\_is\_1024\_bytes, je uvedena implicitní hodnota True. To znamená, že tento argument je *nepovinný*. Funkci můžeme zavolat, aniž bychom ho zadali. Python se bude chovat, jako kdybychom při volání funkce zadali na místě druhého argumentu hodnotu True.

Teď se podívejte na konec skriptu:

Zde se funkce approximate\_size() volá s dvěma argumenty. Protože jsme druhému argumentu explicitně předali hodnotu False, nabývá a\_kilobyte\_is\_1024\_bytes uvnitř funkce approximate\_size() hodnotu False.

Zde se funkce approximate\_size() volá pouze s jedním argumentem. Ale je to v pořádku, protože druhý argument je volitelný! A protože ho volající neurčil, nabývá druhý argument implicitní hodnoty True — přesně jak bylo určeno v deklaraci funkce.

Hodnotu argumentu můžeme do funkce předat také jako pojmenovanou.

```
>>> from humansize import approximate_size
>>> approximate_size(4000, a_kilobyte_is_1024_bytes=False)
                                                                   [1]
'4.0 KB'
>>> approximate_size(size=4000, a_kilobyte_is_1024_bytes=False)
                                                                   [2]
'4.0 KB'
>>> approximate_size(a_kilobyte_is_1024_bytes=False, size=4000)
                                                                   [3]
'4.0 KB'
>>> approximate_size(a_kilobyte_is_1024_bytes=False, 4000)
                                                                   [4]
  File "<stdin>", line 1
SyntaxError: non-keyword arg after keyword arg
>>> approximate_size(size=4000, False)
                                                                   [5]
  File "<stdin>", line 1
SyntaxError: non-keyword arg after keyword arg
```

- Zde se funkce approximate\_size() volá s hodnotou prvního argumentu 4000 (size) a s hodnotou False pro pojmenovaný argument a\_kilobyte\_is\_1024\_bytes. (Shodou okolností je to druhý argument, ale na tom nezáleží jak uvidíte o chvíli později.)
- Zde se funkce approximate\_size() volá s hodnotou 4000 pro pojmenovaný argument size a s hodnotou False pro pojmenovaný argument a\_kilobyte\_is\_1024\_bytes. (Pojmenované argumenty jsou zde shodou okolností uvedeny ve stejném pořadí, v jakém jsou uvedeny v deklaraci funkce, ale na tom rovněž nezáleží.)
- Zde se funkce approximate\_size() volá s hodnotou False pro pojmenovaný argument a\_kilobyte\_is\_1024\_bytes a s hodnotou 4000 pro pojmenovaný argument size. (Vidíte? Já jsem vám říkal, že na pořadí nezáleží.)
- Toto volání selhalo, protože jsme použili pojmenovaný argument a teprve po něm následoval nepojmenovaný (poziční) argument. Tohle nefunguje nikdy. Při čtení seznamu argumentů zleva doprava se po použití prvního pojmenovaného argumentu musí všechny následující argumenty uvést také jako pojmenované.
- Toto volání rovněž selhává ze stejného důvodu jako předchozí volání. Je to tak překvapivé? Když se to tak vezme, předáváme hodnotu 4000 pro pojmenovaný argument size a je "zřejmé", že hodnota False byla myšlena jako hodnota argumentu a\_kilobyte\_is\_1024\_bytes. Ale Python tímto způsobem nefunguje. Jakmile použijeme pojmenovaný argument, všechny argumenty uvedené napravo od něj musí být také pojmenované.

#### 1.3. Psaní čitelného kódu

Nebudu vás zde nudit dlouhým proslovem o důležitosti dokumentování vašeho kódu. Jen si uvědomte, že kód se píše jednou, ale čte se mnohokrát. A nejdůležitějším čtenářem vašeho zdrojového textu budete vy sami — šest měsíců poté, co jste jej napsali (to znamená poté, co už jste o něm všechno zapomněli a máte v něm něco opravit). V jazyce Python se čitelný kód píše snadno, takže toho využijte. Za šest měsíců mi poděkujete.

#### 1.3.1. Dokumentační řetězce

Pythonovskou funkci můžete zdokumentovat tím, že jí přidělíte dokumentační řetězec (zkráceně docstring). V našem programu je u funkce approximate\_size() dokumentační řetězec uveden:

# Každá funkce si zaslouží decentní docstring.

Tři apostrofy uvozují víceřádkový řetězec. Vše mezi počátečními a koncovými apostrofy (nebo uvozovkami) se stává součástí jediného řetězce, včetně konců řádků, úvodních bílých znaků a jednoduchých apostrofů. Víceřádkové řetězce můžete použít kdekoliv, ale nejčastěji se s nimi setkáte při zápisech dokumentačních řetězců.

> Použití ztrojených apostrofů představuje rovněž jednoduchý způsob pro zápis řetězců, ve kterých se vyskytují jak apostrofy, tak uvozovky. Chovají se jako zápis qq/.../ v jazyce Perl 5.

Vše, co se nachází mezi ztrojenými apostrofy, je dokumentační řetězec, který popisuje, co funkce dělá. Pokud docstring existuje, pak to musí být první věc, která se v těle funkce objeví. (To znamená, že musí být uveden na řádku následujícím za deklarací funkce.) Z technického pohledu není nutné docstring funkci vůbec přidělovat, ale prakticky byste to měli udělat vždy. Já vím, že jste o tom slyšeli v každém kurzu programování, který jste navštěvovali. Ale u jazyka Python máme jeden motivační faktor navíc: docstring je dostupný za běhu programu v podobě atributu (vlastnosti) funkce.

1.4. vyme

Kap.

> Mnohá pythonovská integrovaná vývojová prostředí používají docstring pro účely kontextově citlivé nápovědy. To znamená, že po napsání jména funkce se její docstring zobrazí v podobě tooltipu (tj. malého informačního okénka zobrazovaného poblíž daného místa). Může to být velmi užitečné, ale bude to dobré jen tak, jak dobře napíšete dokumentační řetězce.

# 1.4. Vyhledávací cesta pro import

Než půjdeme dál, chtěl bych se stručně zmínit o vyhledávací cestě pro knihovny (library search path). Když se pokoušíte importovat modul, hledá jej Python na několika místech. Přesněji řečeno, hledá jej ve všech adresářích, které jsou definovány proměnnou sys.path. Jde o běžný seznam a jeho obsah můžete snadno zobrazit nebo měnit prostřednictvím standardních metod seznamu. (O seznamech se dozvíme více v kapitole Přirozené datové typy.)

```
>>> import sys
                                                                 [1]
>>> sys.path
                                                                  [2]
 '/usr/lib/python31.zip',
 '/usr/lib/python3.1',
 '/usr/lib/python3.1/plat-linux2@EXTRAMACHDEPPATH@',
 '/usr/lib/python3.1/lib-dynload',
 '/usr/lib/python3.1/dist-packages',
 '/usr/local/lib/python3.1/dist-packages']
>>> sys
                                                                 [3]
<module 'sys' (built-in)>
>>> sys.path.insert(0, '/home/mark/diveintopython3/examples')
                                                                 [4]
>>> sys.path
                                                                  [5]
['/home/mark/diveintopython3/examples',
 '/usr/lib/python31.zip',
 '/usr/lib/python3.1',
 '/usr/lib/python3.1/plat-linux2@EXTRAMACHDEPPATH@',
 '/usr/lib/python3.1/lib-dynload',
 '/usr/lib/python3.1/dist-packages',
 '/usr/local/lib/python3.1/dist-packages']
```

- [1] Importováním modulu sys zpřístupníme všechny jeho funkce a atributy.
- sys.path je seznam adresářů, které tvoří aktuální vyhledávací cestu. (U vás to bude vypadat jinak v závislosti na vašem operačním systému, na verzi Pythonu, který používáte, a na tom, kam byl nainstalován.) Pokud se pokoušíte o import, hledá Python soubor s daným jménem a příponou .py právě v těchto adresářích (v uvedeném pořadí).
- No, ve skutečnosti jsem trochu zalhal. Pravda je o něco komplikovanější, protože ne všechny moduly jsou uloženy v podobě souborů s příponou .py. U některých jde o *zabudované* (built-in)

- moduly. Ve skutečnosti jsou součástí programu Python. Zabudované moduly se chovají úplně stejně jako běžné moduly, ale není k nim k dispozici pythonovský zdrojový kód, protože nejsou napsány v jazyce Python! Zabudované moduly jsou napsány v jazyce C, stejně jako samotný Python.
- K pythonovské vyhledávací cestě můžete za běhu přidat nový adresář tím, že jeho jméno přidá-[4] te do sys.path. Kdykoliv se od toho okamžiku pokusíte importovat nějaký modul, Python bude prohledávat i tento adresář. Efekt trvá tak dlouho, dokud Python běží.
- Použitím příkazu sys.path.insert(0, new\_path) jsme vložili nový adresář jako první polož-[5] ku seznamu sys. path, coż znamená, že se ocitla na začátku pythonovské vyhledávací cesty. Většinou potřebujeme právě tohle. V případě konfliktu jmen (například když se Python dodává s konkrétní knihovnou verze 2, ale my chceme použít tutéž knihovnu ve verzi 3) uvedeným obratem zajistíme, že námi požadované moduly budou nalezeny dříve než moduly dodané s Pythonem.

#### 1.5. Všechno je objekt

Pokud vám to náhodou uniklo, řekli jsme si, že pythonovské funkce mají atributy a tyto atributy jsou přístupné za běhu programu. Funkce, stejně jako všechno ostatní v Pythonu, je objektem.

Spusťme interaktivní pythonovský shell a vyzkoušejme si:

```
>>> import humansize
                                                    [1]
>>> print(humansize.approximate_size(4096, True))
                                                    [2]
4.0 KiB
>>> print(humansize.approximate_size.__doc__)
                                                    [3]
Convert a file size to human-readable form.
    Keyword arguments:
    size -- file size in bytes
    a_kilobyte_is_1024_bytes -- if True (default), use multiples of 1024
                                 if False, use multiples of 1000
    Returns: string
```

- [1] Na prvním řádku importujeme program humansize jako modul — kus kódu, který můžeme používat interaktivně nebo z většího pythonovského programu. Jakmile je import modulu proveden, můžeme se odkazovat na jeho veřejné funkce, třídy nebo atributy. Moduly mohou dělat totéž, čímž si zpřístupňují funkčnost z jiných modulů. A my to můžeme udělat v interaktivním pythonovském shellu také. Tato koncepce je důležitá a v knize se s ní potkáme ještě mnohokrát.
- Pokud chceme použít funkce definované v importovaných modulech, musíme uvést i jméno mo-[2] dulu. Takže nestačí napsat jen approximate\_size. Musíme uvést humansize.approximate\_size. Pokud jste používali třídy v jazyce Java, mělo by vám to něco připomínat.

1.6.

- Zde se místo očekávaného volání funkce ptáme na jeden z jejích atributů, který je nazván \_\_doc\_\_.
- > Pythonovský příkaz import se podobá příkazu require v jazyce Perl. Jakmile provedeme import pythonovského modulu, vyjadřujeme přístup k jeho funkcím zápisem modul.funkce. Jakmile v jazyce Perl provedeme příkaz require, dostaneme se na jeho funkce zápisem modul:funkce.

### 1.5.1. Co to vlastně je objekt?

V Pythonu je objektem všechno. A vše může mít atributy a metody. Všechny funkce mají zabudovaný atribut \_\_doc\_\_, který vrací dokumentační řetězec funkce definovaný ve zdrojovém souboru. Modul sys je objekt, který (mimo jiné) má atribut zvaný path. A tak dále.

Tím ale stále neodpovídáme na základnější otázku: Co je to vlastně objekt? Různé programovací jazyky definují "objekt" různým způsobem. V některých jazycích to znamená, že všechny objekty musí mít atributy a metody. V jiných jazycích to znamená, že všechny objekty lze rozdělit do tříd. Jazyk Python definuje objekt volněji. Některé objekty nemusí mít ani atributy ani metody, ale mohou je mít. Ne všechny objekty mají svou třídu. Ale vše je objektem v tom smyslu, že to může být přiřazeno do proměnné nebo předáno jako argument funkce.

V jiných souvislostech s programováním jste už možná slyšeli pojem "prvotřídní objekt" ("first-class object"). Kvůli lepší srozumitelnosti mu říkejme (opisem) *plnohodnotný objekt.* V jazyce Python je *plnohodnotným objektem* i funkce. Funkci můžeme předat jako argument jiné funkci. Moduly jsou rovněž *plnohodnotnými objekty.* Funkci můžeme předat jako argument celý modul. Třídy jsou také plnohodnotné objekty a jednotlivé instance třídy jsou rovněž plnohodnotnými objekty.

To je velmi důležité, takže pro případ, že by vám to na začátku párkrát uteklo, zopakuji znovu: *V jazyce Python je všechno objektem.* Řetězce jsou objekty. Seznamy jsou objekty. Funkce jsou objekty. Třídy jsou objekty. Instance tříd jsou objekty. Dokonce moduly jsou objekty.

#### 1.6. Odsazování kódu

V jazyce Python se pro označování míst, kde kód funkce začíná a kde končí, nepoužívají slova begin a end a ani žádné složené závorky. Jediným oddělovačem těla je dvojtečka (:) a odsazení kódu.

```
def approximate_size(size, a_kilobyte_is_1024_bytes=True): [1]
    if size < 0: [2]
        raise ValueError('number must be non-negative') [3]</pre>
```

```
multiple = 1024 if a_kilobyte_is_1024_bytes else 1000
for suffix in SUFFIXES[multiple]:
    size /= multiple
    if size < multiple:
        return '{0:.1f} {1}'.format(size, suffix)

raise ValueError('number too large')</pre>
```

- Bloky kódu (bloky zdrojového textu) jsou určeny jejich odsazením. "Blokem kódu" zde rozumím volání funkcí, příkazy if, cykly for, cykly while a další. Blok je zahájen odsazením
  (odskočením řádku vpravo) a končí předsazením (odskočením následujícího řádku vlevo).
  Nenajdeme zde žádné explicitní závorky nebo klíčová slova. To ale znamená, že používání
  bílých znaků má svůj význam a že je musíme užívat důsledně. V tomto příkladu je kód funkce
  odsazen o čtyři mezery. Nemusí to být zrovna čtyři mezery, ale musíme použít stejné odsazení.
  První řádek, který není odsazený, označuje konec funkce.
- V Pythonu za příkazem if následuje blok kódu. Pokud výraz za if nabývá hodnoty true, provede se následující odsazený blok. V opačném případě se provede blok za else (pokud je uveden). Povšimněte si, že kolem výrazu chybí závorky.
- Tento řádek se nachází v bloku kódu, který je uvnitř příkazu if. Příkaz raise vyvolá výjimku (typu ValueError), ale jen v případě, kdy platí size < 0.
- Zde ještě není konec funkce. Zcela prázdné řádky se nepočítají. Díky nim může být kód čitelnější, ale nepovažují se za oddělovače bloků kódu. Na dalším řádku funkce pokračuje.
- Rovněž příkaz cyklu for zahajuje blok kódu. Bloky kódu se mohou skládat z mnoha řádků, ale všechny musí být odsazeny stejně. Tento cyklus for má blok s třemi řádky kódu. Pro víceřádkové bloky kódu se nepoužívá žádná jiná zvláštní syntaxe. Prostě odsadíme a jedeme dál.

Po počátečních protestech a sarkastických přirovnáních k Fortranu si na to zvyknete a zjistíte, jaké to má výhody. Jedna z největších výhod spočívá v tom, že všechny pythonovské programy vypadají podobně, protože odsazování je vynuceno samotným jazykem a není jen věcí stylu. Pythonovský kód napsaný někým jiným se proto snadněji čte a je srozumitelnější.

Python používá k oddělování příkazů konec řádku. Oddělení bloku kódu se vyjadřuje dvojtečkou a odsazením. Jazyky c++ a Java používají k oddělování příkazů středník a k oddělování bloku kódu složené závorky.

# 1.7. Výjimky

V jazyce Python najdete výjimky všude. Používá je prakticky každý modul standardní pythonovské knihovny a samotný Python je vyvolává při mnoha různých okolnostech. V celé této knize se s nimi budete opakovaně setkávat.

Co to vlastně je výjimka? Obvykle jde o projev nějaké chyby. Vyjadřuje, že něco nedopadlo dobře. (Ne všechny výjimky jsou vyjádřením chyby. Ale v tomto okamžiku na tom nezáleží.) V některých programovacích jazycích jsme vedeni k používání návratových chybových kódů, které pak *kontrolujeme*. Python nás vede k používání výjimek, které pak *obsluhujeme*.

Když se v pythonovském shellu objeví chyba, vypíše nějaké podrobnosti o výjimce a jak k ní došlo. A to je právě ono. Říkáme tomu *neobsloužená* výjimka. V okamžiku vyvolání výjimky se v okolí nenacházel žádný kód, který by si toho všímal a který by se jí zabýval. Takže výjimka probublala zpět až do horních úrovní pythonovského shellu. Ten vyplivnul nějaké ladicí informace a považoval to za vyřešené. Pokud se to stane při práci v shellu, není to žádná pohroma. Ale pokud by se to stalo u vašeho skutečného pythonovského programu, pak by za předpokladu, že výjimku nic neobsloužilo, došlo ke skřípavému zastavení jeho běhu. Možná by vám to vyhovovalo, možná ne.

> V Pythonu nemusí funkce deklarovat, jaké výjimky mohou vyvolat — na rozdíl od jazyka Java. Rozhodnutí o tom, jaké možné výjimky potřebujete odchytávat, záleží zcela na vás.

Ale výjimka nemusí vést k úplnému krachu programu. Výjimky mohou být *obslouženy*. Někdy je výjimka opravdu důsledkem chyby ve vašem programu (když se například pokoušíte použít proměnnou, která neexistuje), ale někdy je výjimka výsledkem něčeho, co se dalo předvídat. Když otvíráte soubor, nemusí třeba existovat. Když importujete modul, nemusel být nainstalován. Když se připojujete k databázi, může být nedostupná nebo k ní nemůžete přistupovat kvůli nedostatečným bezpečnostním oprávněním. Pokud víte, že na nějakém řádku může vzniknout výjimka, měli byste ji obsloužit pomocí konstrukce try...except.

> Python používá bloky try...except k obsluze výjimek. Příkaz raise používá k jejich generování. Jazyky Java a c++ používají k obsloužení výjimek bloky try...catch. K jejich generování používají příkaz throw.

Funkce approximate\_size() vyvolává výjimky ve dvou různých případech: když je zadaná velikost (size) větší, než pro jakou byla funkce navržena, nebo když je zadaná velikost menší než nula.

```
if size < 0:
    raise ValueError('number must be non-negative')</pre>
```

Syntaxe pro vyvolání výjimky je poměrně jednoduchá. Použijeme příkaz raise, za kterým uvedeme jméno výjimky a nepovinný, pro člověka srozumitelný řetězec usnadňující ladění. Zápis se podobá volání funkce. (Ve skutečnosti jsou výjimky implementovány jako třídy. Příkaz raise zde vytváří instanci třídy ValueError a její inicializační metodě předává řetězec 'number must be non-negative' (číslo nesmí být záporné). Ale nepředbíhejme!)

Výjimka nemusí být obsloužena ve funkci, která ji vyvolala. Pokud ji jedna funkce neobslouží, výjimka bude předána volající funkci, pak funkci, která vyvolala zase ji a tak dále, "nahoru po zásobníku". Pokud není výjimka obsloužena vůbec, program zhavaruje a Python vypíše "traceback" (trasovací výpis) na standardní chybový výstup a tím to končí. Znovu opakuji, možná takové chování požadujeme. Záleží to na tom, k čemu je náš program určen.

## 1.7.1. Obsluha chyb importu

Jednou ze zabudovaných výjimek jazyka Python je ImportError. Ta je vyvolána v okamžiku, kdy se pokoušíme o import modulu a tato operace selže. Může k tomu dojít z různých důvodů, ale v nejjednodušším případě modul nebyl nalezen ve vaší vyhledávací cestě pro import. Toho můžete využít pro zabudování nepovinných vlastností svého programu. Tak například knihovna chardet umožňuje autodetekci znakového kódování. Možná byste chtěli, aby váš program tuto knihovnu využil v případě, že existuje. Pokud ji uživatel nemá nainstalovanou, měl by program bez mrknutí oka pokračovat. Můžeme toho dosáhnout použitím bloku try..except.

```
try:
   import chardet
except ImportError:
   chardet = None

Později můžete otestovat, zda je modul chardet přítomen — jednoduše, příkazem if:

if chardet:
   # do something
else:
   # continue anyway
```

Další běžný případ použití výjimky ImportError souvisí se situací, kdy dva moduly implementují společné aplikační programové rozhraní (API), ale jeden z nich chceme používat přednostně. (Možná je rychlejší nebo používá méně paměti.) Můžeme zkusit importovat jeden modul, ale pokud import selže, vezmeme zavděk tím druhým. Tak například kapitola o XML pojednává o dvou modulech, které implementují společné rozhraní zvané ElementTree. Prvním z nich je lxml, což je modul třetí strany, který si musíte sami stáhnout a nainstalovat. Tím druhým je xml.etree. ElementTree, který je sice pomalejší, ale je součástí standardní knihovny jazyka Python 3.

```
try:
    from lxml import etree
except ImportError:
    import xml.etree.ElementTree as etree
```

Na konci bloku try. .except máte zpřístupněný některý z těchto modulů a máte jej pojmenovaný etree. Protože oba moduly implementují stejné rozhraní (API), nemusíte ve zbytku svého kódu neustále testovat, který modul se vlastně naimportoval. A protože se modul, který se opravdu naimportoval, vždy jmenuje etree, nemusí být zbytek vašeho kódu zaneřáděný příkazy if, ve kterých se volají různě pojmenované moduly.

- 1.8. Volné proměnné
- 1.9. Vše je citlivé na velikost písmen

### 1.8. Volné proměnné

Podívejme se znovu na následující řádek kódu funkce approximate\_size():

```
multiple = 1024 if a_kilobyte_is_1024_bytes else 1000
```

Proměnnou multiple (násobek) jsme nikde nedeklarovali. Pouze jsme do ní přiřadili hodnotu. To je v pořádku, protože Python vám tohle dovolí. Co už vám ale Python *nedovolí*, je pokus o odkaz na proměnnou, které nebyla nikdy přiřazena hodnota. Pokud se o to pokusíme, bude vyvolána výjimka NameError.

```
>>> x
Traceback (most recent call last):
   File "<stdin>", line 1, in <module>
NameError: name 'x' is not defined
>>> x = 1
>>> x
1
```

Jednoho dne za to Pythonu poděkujete.

### 1.9. Vše je citlivé na velikost písmen

V jazyce Python je zápis všech jmen citlivý na velikost písmen. Týká se to jmen proměnných, jmen funkcí, jmen tříd, jmen modulů, jmen výjimek. Pokud to můžete zpřístupnit, nastavit, zavolat, importovat nebo to vyvolat, je to citlivé na velikost písmen.

```
>>> an_integer = 1
>>> an_integer
1
>>> AN_INTEGER
Traceback (most recent call last):
    File "<stdin>", line 1, in <module>
NameError: name 'AN_INTEGER' is not defined
>>> An_Integer
Traceback (most recent call last):
    File "<stdin>", line 1, in <module>
NameError: name 'An_Integer' is not defined
>>> an_inteGer
Traceback (most recent call last):
    File "<stdin>", line 1, in <module>
NameError: name 'an_inteGer' is not defined
>>> nameError: name 'an_inteGer' is not defined
```

A tak dále.

### 1.10. Spouštění skriptů

# V Pythonu je objektem všechno.

V Pythonu je objektem i modul a moduly definují několik užitečných atributů. Při psaní vašich modulů toho můžeme využít k jejich snadnému testování. Vložíme do nich speciální blok kódu, který se provede v případě, kdy pythonovský soubor spustíte z příkazového řádku. Podívejte se na poslední řádky v souboru humansize.py:

```
if __name__ == '__main__':
    print(approximate_size(100000000000, False))
    print(approximate_size(100000000000))
```

> Python — stejně jako jazyk c — používá == pro porovnání a = pro přiřazení. Na rozdíl od jazyka C ale Python nepodporuje přiřazovací výraz, takže odpadá možnost nechtěného přiřazení hodnoty v situaci, kdy jste měli na mysli test na rovnost.

Takže čím je vlastně tento příkaz i f zvláštní? Tak tedy, moduly jsou objekty a všechny moduly mají zabudovaný atribut \_\_name\_\_. Jeho hodnota závisí na tom, jakým způsobem modul používáte. Pokud provádíte import modulu, pak je v atributu \_\_name\_\_ zachyceno jméno jeho souboru bez cesty do adresáře a bez přípony.

```
>>> import humansize
>>> humansize.__name__
'humansize'
```

Ale modul můžete spustit také přímo, jako samostatný program. V takovém případě bude \_\_name\_\_ nabývat speciální přednastavené hodnoty \_\_main\_\_. Python tuto skutečnost otestuje příkazem if, zjistí, že výraz platí, a provede blok kódu uvnitř if. V našem případě se vytisknou dvě hodnoty.

```
c:\home\diveintopython3> c:\python31\python.exe humansize.py
1.0 TB
931.3 GiB
```

A tohle všechno dělá váš první pythonovský program!

#### 1.11. Přečtěte si

- PEP 257: Docstring Conventions. Najdete zde vysvětlení, čím se liší dobrý docstring od vynikajícího docstringu.
   (http://www.python.org/dev/peps/pep-0257/)
- **Python Tutorial: Documentation Strings** dotýká se stejného tématu. (http://docs.python.org/py3k/tutorial/controlflow.html)
- PEP 8: Style Guide for Python Code pojednává o vhodných způsobech odsazování. (http://www.python.org/dev/peps/pep-0008/)
- Python Reference Manual vysvětluje co to znamená, když se řekne, že vše v Pythonu je objekt, protože někteří lidé jsou puntičkáři a rádi o takových věcech dlouze diskutují.
   (http://docs.python.org/py3k/reference/)

2. Kapitola

- "Wonder is the foundation of all philosophy, inquiry its progress, ignorance its end."
  (Zvědavost je základem celé filozofie, hledání odpovědí na otázky ji žene vpřed, ignorance ji zabíjí.)
  - Michel de Montaigne

# 2. Přirozené datové typy

#### 2. Přirozené datové typy — 61 Ponořme se — 63 2.1. 2.2. Booleovský typ — 63 2.3. Čísla — **64** 2.3.1. Vynucení převodu celých čísel na reálná a naopak — 65 2.3.2. Běžné operace s čísly — 66 2.3.3. Zlomky — 67 Trigonometrie — 67 2.3.4. Čísla v booleovském kontextu — 68 2.3.5. 2.4. Seznamy — 69 2.4.1. Vytvoření seznamu - 69 Vytváření podseznamů — 70 2.4.2. Přidávání položek do seznamu — 71 2.4.3. Vyhledávání hodnoty v seznamu — 73 2.4.4. 2.4.5 Odstraňování položek ze seznamu - 74 Odstraňování položek ze seznamu: Bonusové kolo — 75 2.4.6. 2.4.7. Seznamy v booleovském kontextu — 75 N-tice — 76 2.5. 2.5.1. N-tice v booleovském kontextu — 78 2.5.2. Přiřazení více hodnot najednou — 78 Množiny — 79 2.6. Vytvoření množiny — 79 2.6.1. 2.6.2. Úprava množiny — 81 2.6.3. Odstraňování položek z množiny — 82 2.6.4. Běžné množinové operace — 83 2.6.5. Množiny v booleovském kontextu — 85 Slovníky - 86 2.7. Vytvoření slovníku - 86 2.7.1. 2.7.2. Úprava slovníku — 87 2.7.3. Slovníky se smíšeným obsahem - 87 Slovníky v booleovském kontextu — 88 2.7.4. 2.8. None — 89

None v booleovském kontextu — 90

Přečtěte si - 90

2.8.1.

2.9.

- 2.1. Ponořme se
- 2.2. Booleovský typ

### 2.1. Ponořme se

Datové typy. Přestaňme si na chvíli všímat našeho prvního pythonovského programu a pojďme si popovídat o datových typech. Každá hodnota v Pythonu je určitého datového typu, ale u proměnných nemusíme datový typ deklarovat. Jak to tedy funguje? Při každém přiřazení hodnoty do proměnné si Python zjistí, jakého typu hodnota je, a vnitřně si to eviduje.

Python používá mnoho přirozených datových typů (ve smyslu "přirozených pro Python"). Uveďme zde ty hlavní:

- 1. **Boolean** (booleovský typ) nabývá buď hodnoty True nebo False.
- 2. **Čísla** mohou být celá (integer; 1 a 2), reálná (float; 1.1 a 1.2), zlomky (fraction; 1/2 and 2/3), nebo dokonce čísla komplexní.
- 3. Řetězce jsou posloupnosti Unicode znaků. Tuto podobu může mít například HTML dokument.
- 4. Bajty a pole bajtů, například soubor s obrázkem ve formátu JPEG.
- 5. **Seznamy** jsou uspořádané posloupnosti hodnot.
- 6. **N-tice** jsou uspořádané, neměnné posloupnosti hodnot.
- 7. Množiny jsou neuspořádané kolekce hodnot.
- 8. Slovníky jsou neuspořádané kolekce dvojic klíč-hodnota.

Těch typů je samozřejmě víc. V Pythonu je vše objektem, proto musí existovat také typy jako *modul, funkce, třída, metoda, soubor,* a dokonce *přeložený kód.* S některými z nich už jsme se setkali: moduly Kap. mají jména, funkce mají docstring atd. O třídách se dozvíte v kapitole <u>Třídy a iterátory</u>, o souborech v kapitole <u>Soubory</u>.

Řetězce a bajty jsou důležité do té míry — a jsou také dost komplikované —, že jim je věnována samostatná kapitola. Nejdříve se podívejme na ty zbývající.

### 2.2. Booleovský typ

Objekt booleovského typu nabývá buď hodnoty true (pravda) nebo false (nepravda). Pro přímé přiřazení booleovských hodnot definuje Python dvě konstanty, příhodně pojmenované True a False. Booleovská hodnota může vzniknout také vyhodnocením výrazu. Na některých místech (jako u příkazu if) Python dokonce předpokládá, že se výraz vyhodnotí do podoby booleovské hodnoty. Těmto místům

V booleovském kontextu můžete použít téměř libovolný výraz. se říká *booleovský kontext*. V booleovském kontextu můžeme použít téměř libovolný výraz. Python se pokusí získat jeho pravdivostní hodnotu. Pravidla, podle kterých se v booleovském kontextu výsledek chápe jako pravdivý nebo nepravdivý (true nebo false), jsou pro různé datové typy různá. (Jakmile uvidíte dále v této kapitole konkrétní příklady, bude vám to dávat větší smysl.)

Vezměme si například následující úryvek z humansize.py:

```
if size < 0:
    raise ValueError('number must be non-negative')</pre>
```

Proměnná size obsahuje celé číslo, 0 je celé číslo a < je číselný operátor. Výsledek výrazu size < 0 má vždy booleovskou hodnotu. V pythonovském shellu si vyzkoušejte následující:

```
>>> size = 1
>>> size < 0
False
>>> size = 0
>>> size < 0
False
>>> size < 0
False
>>> size = -1
>>> size < 0
True
```

V důsledku problematického dědictví z Pythonu 2 se s booleovskými hodnotami může zacházet jako s čísly. True je 1; False je 0.

```
>>> True + True
2
>>> True - False
1
>>> True * False
0
>>> True / False
Traceback (most recent call last):
   File "<stdin>", line 1, in <module>
ZeroDivisionError: int division or modulo by zero
```

Ajajaj! Takové věci nedělejte. Zapomeňte, že jsem se o tom vůbec zmínil.

### 2.3. Čísla

Čísla jsou obdivuhodná. Můžete si je vybrat z tak ohromného množství. Python podporuje jak celá čísla (integer), tak čísla reálná (floating point). Nerozlišují se deklarací datového typu. Python je od sebe poznává podle přítomnosti nebo nepřítomnosti desetinné tečky.

```
>>> type(1) [1]
<class 'int'>
>>> isinstance(1, int) [2]
True
>>> 1 + 1 [3]
2
>>> 1 + 1.0 [4]
2.0
>>> type(2.0)
<class 'float'>
```

- Pro ověření typu libovolné hodnoty nebo proměnné můžeme použít funkci type(). Jak se dalo čekat, hodnota 1 je typu int.
- [2] Podobně můžeme voláním funkce isinstance() ověřit, zda hodnota či proměnná odpovídá zadanému typu.
- [3] Přidáním int k int vzniká výsledek typu int.
- Přidáním int k float vzniká výsledek typu float. Aby mohl Python provést sčítání, vynutí si převod typu int na float. Poté vrátí výsledek typu float.

### 2.3.1. Vynucení převodu celých čísel na reálná a naopak

Jak jste zrovna viděli, některé operátory (například sčítání) mohou podle potřeby vynutit převod celého čísla na číslo reálné. Ale k převodu je můžete donutit taky vy sami.

```
>>> float(2) [1]
2.0
>>> int(2.0) [2]
2
>>> int(2.5) [3]
2
>>> int(-2.5) [4]
-2
>>> 1.12345678901234567890 [5]
1.1234567890123457
>>> type(100000000000000) [6]
<class 'int'>
```

- Voláním funkce float() můžeme explicitně vynutit převod int (typ pro celé číslo) na float (typ pro reálné číslo).
- [2] A nebude asi moc překvapivé, že voláním int() můžeme vynutit převod float na int.
- [3] Funkce int() nezaokrouhluje, ale odsekává.
- [4] Funkce int() odsekává desetinnou část u záporných čísel směrem k nule. Jde o funkci

- opravdového odsekávání, ne o funkci floor (tj. u záporných čísel dojde ke zvětšení čísla, protože například -2.5 se změní na -2).
- Čísla typu float jsou uložena s přesností na 15 desetinných míst.
- [6] Celá čísla mohou být libovolně velká.
- > Python 2 měl oddělené typy int a long. Datový typ int byl omezen konstantou sys.maxint, která byla platformově závislá, ale obvykle nabývala hodnoty 2<sup>32</sup>–1. Python 3 má pouze jeden celočíselný typ, který se chová většinou jako původní typ long z Pythonu 2. Detaily naleznete v PEP 237.

## 2.3.2. Běžné operace s čísly

S čísly můžete dělat všechno možné.

```
>>> 11 / 2
                  [1]
5.5
>>> 11 // 2
                  [2]
5
>>> -11 // 2
                  [3]
-6
>>> 11.0 // 2
                  [4]
5.0
>>> 11 ** 2
                  [5]
121
>>> 11 % 2
                  [6]
1
```

- Operátor / provádí dělení. Vrací výsledek typu float dokonce i v případě, že činitel i jmenovatel jsou typu int.
- Operátor // provádí svým způsobem podivné celočíselné dělení. Pokud je výsledek kladný, můžete o něm uvažovat, že vznikl odseknutím desetinných míst (tedy nikoliv zaokrouhlením). Ale pozor na to.
- Při celočíselném dělení záporných čísel provede operátor // zaokrouhlení "nahoru" k nejbližšímu celému číslu. Z matematického hlediska zaokrouhluje "dolů", protože -6 je menší než -5.

  Ale pokud byste očekávali, že dojde k odseknutí na -5, tak byste se nachytali.
- Operátor // nevrací celé číslo vždy. Pokud je čitatel nebo jmenovatel typu float, bude výsledek sice opět zaokrouhlen na celé číslo, ale výsledná hodnota bude typu float.
- [5] Operátor \*\* znamená "umocněno na". 11² je 121.
- [6] Operátor % vrací zbytek po celočíselném dělení. 11 děleno 2 je 5 a zbytek je 1. Takže výsledkem bude 1.
- V Pythonu 2 obvykle operátor / prováděl celočíselné dělení. Ale když jste ve svém kódu použili speciální direktivu, mohli jste jeho význam přepnout na reálné dělení. V Pythonu 3 operátor /

vyjadřuje vždy dělení s reálným výsledkem (floating point division). Na detaily se podívejte do PEP 238.

# 2.3.3. Zlomky

Python vás neomezuje jen na celá a reálná čísla. Zvládne celou tu fantastickou matiku, kterou jste se učili na střední škole a rychle jste ji zapomněli.

```
>>> import fractions
                                          [1]
>>> x = fractions.Fraction(1, 3)
                                          [2]
>>> x
Fraction(1, 3)
>>> x * 2
                                          [3]
Fraction(2, 3)
>>> fractions.Fraction(6, 4)
Fraction(3, 2)
>>> fractions.Fraction(0, 0)
                                          [5]
Traceback (most recent call last):
  File "<stdin>", line 1, in <module>
  File "fractions.py", line 96, in __new__
    raise ZeroDivisionError('Fraction(%s, 0)' % numerator)
ZeroDivisionError: Fraction(0, 0)
```

- [1] Používání zlomků zahájíme importem modulu fractions.
- [2] Zlomek definujeme tak, že vytvoříme objekt třídy Fraction a předáme mu čitatele a jmenovatele.
- Se zlomky můžeme provádět obvyklé matematické operace. Ty vracejí nový objekt třídy Fraction. 2 \* (1/3) = (2/3)
- Objekt třídy Fraction zlomky automaticky krátí. (6/4) = (3/2)
- Python má dost rozumu na to, aby nevytvořil zlomek s nulovým jmenovatelem.

### 2.3.4. Trigonometrie

Python zvládne i základy trigonometrie.

- Modul math definuje konstantu տ, čili poměr mezi obvodem kružnice a jejím průměrem.
- [2] Modul math zvládá všechny základní trigonometrické funkce včetně sin(), cos(), tan() a varianty jako asin().

#### 2.3.5. Čísla v booleovském kontextu

# Nulová hodnota se interpretuje jako false, nenulová jako true.

Čísla můžete použít v booleovském kontextu — například v příkazu if. Nulové hodnoty se interpretují jako false, nenulové jako true.

```
>>> def is_it_true(anything):
                                           [1]
      if anything:
        print("yes, it's true")
      else:
        print("no, it's false")
>>> is_it_true(1)
                                           [2]
yes, it's true
>>> is_it_true(-1)
yes, it's true
>>> is_it_true(0)
no, it's false
>>> is_it_true(0.1)
                                           [3]
yes, it's true
>>> is_it_true(0.0)
no, it's false
>>> import fractions
>>> is_it_true(fractions.Fraction(1, 2)) [4]
yes, it's true
>>> is_it_true(fractions.Fraction(0, 1))
no, it's false
```

- A to víte, že své vlastní funkce můžete definovat i v pythonovském interaktivním shellu? Stačí zmáčknout ENTER na konci každého řádku a vše ukončit stiskem ENTER na prázdném řádku.
- [2] V booleovském kontextu se nenulová celá čísla chápou jako true a nula jako false.
- Nenulová reálná čísla se chápou jako true, 0.0 se chápe jako false. Ale bacha na tu poslední hodnotu! Pokud dojde k sebemenší zaokrouhlovací chybě (což není nemožné, jak jste si

mohli všimnout v předchozí podkapitole), pak bude Python testovat místo nuly například 0.0000000000001 a vrátí hodnotu True.

Zlomky můžeme také použít v booleovském kontextu. Hodnota Fraction (0, n) se pro všechny [5] hodnoty n vyhodnotí jako false. Všechny ostatní zlomky se vyhodnotí jako true.

#### Seznamy 2.4.

Seznamy jsou v Pythonu nejpoužívanějšími datovými typy. Když řeknu "seznam" (anglicky list [list]), může vás napadnout "pole, jehož velikost musím předem deklarovat, které může obsahovat jen prvky stejného typu atd.". Tímto směrem neuvažujte. Seznamy jsou mnohem lepší.

- Pythonovský seznam se podobá poli (array) v Perl 5. Proměnné polí v jazyce Perl 5 vždycky > začínají znakem @. Pythonovské proměnné můžou být pojmenovány zcela libovolně. Python si vnitřně eviduje jejich datový typ.
- Pythonovský seznam má větší možnosti než pole (array) v jazyce Java. (Ačkoliv pokud je > to vše, co od života očekáváte, můžete jej tímto způsobem používat.) Podobnější je mu třída ArrayList, která umožňuje uchovávání libovolných objektů a při přidání nových položek se může dynamicky zvětšit.

#### 2.4.1. Vytvoření seznamu

Seznam můžeme vytvořit snadno. Čárkami oddělené hodnoty uzavřeme do hranatých závorek.

```
>>> a_list = ['a', 'b', 'mpilgrim', 'z', 'example'] [1]
>>> a_list
['a', 'b', 'mpilgrim', 'z', 'example']
>>> a_list[0]
                                                         [2]
'a'
>>> a_list[4]
                                                         [3]
'example'
>>> a_list[-1]
                                                         [4]
'example'
>>> a_list[-3]
                                                         [5]
'mpilgrim'
```

- [1] Nejdříve jsme nadefinovali seznam s pěti položkami. Všimněte si, že zachovávají své původní pořadí. Není to náhoda. Seznam je uspořádaná kolekce položek.
- Seznam můžeme používat jako pole s indexováním od nuly. První prvek každého neprázdného [2] seznamu zpřístupníme vždy zápisem a\_list[0].
- Poslední prvek tohoto pětiprvkového seznamu je a\_list[4], protože indexování začíná nulou. [3]

- Záporným indexem zpřístupňujeme položky ve směru od konce seznamu k začátku.
  Poslední prvek každého neprázdného seznamu zpřístupníme vždy zápisem a\_list[-1].
- Pokud se vám zdá použití záporného indexu matoucí, uvažujte o něm takto:

  a\_list[-n] == a\_list[len(a\_list) n]. Takže pro náš seznam pak platí

  a\_list[-3] == a\_list[5 3] == a\_list[2].

# 2.4.2. Vytváření podseznamů

# a\_list[0] je vždy první položkou seznamu a\_list.

Jakmile máme vytvořen seznam, můžeme získat jakoukoliv jeho část. Anglicky se tomu říká "slicing the list", což můžeme přeložit jako "vykrajování ze seznamu" nebo "výřez ze seznamu" nebo — z pohledu abstraktního záměru — vytváření podseznamu.

```
>>> a_list
['a', 'b', 'mpilgrim', 'z', 'example']
>>> a_list[1:3]
                                           [1]
['b', 'mpilgrim']
>>> a_list[1:-1]
                                           [2]
['b', 'mpilgrim', 'z']
>>> a_list[0:3]
                                           [3]
['a', 'b', 'mpilgrim']
>>> a_list[:3]
                                           [4]
['a', 'b', 'mpilgrim']
>>> a_list[3:]
                                           [5]
['z', 'example']
>>> a_list[:]
                                           [6]
['a', 'b', 'mpilgrim', 'z', 'example']
```

- Část seznamu, výřez (slice), můžeme získat zadáním dvou indexů. Návratovou hodnotou je nový seznam, který obsahuje položky od prvního indexu výřezu (v tomto případě a\_list[1]) až po položku (ale vyjma) s druhým indexem výřezu (v našem případě a\_list[3]).
- Výřez funguje i v případě, kdy je hodnota jednoho nebo obou indexů výřezu záporná. Můžete si pomoci následujícím způsobem uvažování. Když se na seznam díváme zleva doprava, pak první index výřezu určuje první položku, kterou chceme, a druhý index výřezu určuje první položku, kterou nechceme. Vrací se vše mezi tím.
- Seznamy se indexují od nuly, takže zápis a\_list[0:3] vrací první tři položky seznamu počínaje položkou a\_list[0] až po a\_list[3] vyjma (ta už se nevrací).
- Pokud je levý index výřezu roven nule, můžeme nulu vynechat a Python si ji tam dosadí. Takže zápis a\_list[:3] vede ke stejnému výsledku jako a\_list[0:3], protože počáteční nula se dosadí jako implicitní hodnota.

- Podobně, pokud by pravý index výřezu měl mít hodnotu rovnou délce seznamu, můžeme jej vynechat. Protože náš seznam má pět položek, vede zápis a\_list[3:] ke stejnému výsledku jako a\_list[3:5]. A najdeme zde potěšitelnou symetrii. V našem pětiprvkovém seznamu vrací zápis a\_list[:3] první tři položky a a\_list[3:] vrací zbývající dvě. Obecně platí, že a\_list[:n] vždy vrátí prvních n položek a a\_list[n:] vrátí zbytek nezávisle na délce seznamu.
- Pokud vynecháme oba indexy výřezu, jsou ve výsledku zahrnuty všechny položky původního seznamu. Ale není to totéž jako původní proměnná a\_list. Jde o nový seznam, který má shodou okolností stejné položky. Zápis a\_list[:] je tedy zkratkou pro získání úplné kopie seznamu.

# 2.4.3. Přidávání položek do seznamu

Položku můžeme do seznamu přidat čtyřmi způsoby.

```
>>> a_list = ['a']
>>> a_list = a_list + [2.0, 3]
                                              [1]
>>> a_list
                                              [2]
['a', 2.0, 3]
>>> a_list.append(True)
                                              [3]
>>> a_list
['a', 2.0, 3, True]
>>> a_list.extend(['four', '\Omega'])
                                              [4]
>>> a_list
['a', 2.0, 3, True, 'four', '\Omega']
>>> a_list.insert(0, '\Omega')
                                              [5]
>>> a_list
['\Omega', 'a', 2.0, 3, True, 'four', '\Omega']
```

- Operátor + spojí seznamy a vytvoří nový seznam. Seznam může obsahovat libovolný počet položek. Neexistuje zde žádný limit (pouze velikost dostupné paměti). Ale co se týká paměti, měli bychom si dát pozor na to, že spojením seznamů vzniká v paměti další seznam. V našem případě je nový seznam ihned přiřazen do existující proměnné a\_list. Takže tento řádek kódu ve skutečnosti představuje dvoufázový proces spojení (konkatenace) a přiřazení —, který může u rozsáhlých seznamů (dočasně) spotřebovat velké množství paměti.
- Seznam může obsahovat položky libovolného datového typu a v jednom seznamu nemusí být všechny položky stejného typu. V našem případě máme seznam obsahující řetězec, reálné číslo a celé číslo.
- Metoda append() přidává jednu položku na konec seznamu. (Teď už máme v seznamu položky se *čtyřmi* rozdílnými datovými typy!)
- Seznamy jsou implementovány formou třídy. "Vytvoření" seznamu tedy znamená vytvoření instance třídy. V tomto smyslu mají seznamy metody, které nad nimi pracují. Metoda extend() přebírá jeden argument, kterým je seznam. Každý jeho prvek připojí na konec původního seznamu (append).

- [5] Metoda insert() vloží do seznamu jednu položku. Prvním argumentem je index první položky seznamu, která bude z této pozice odsunuta. Položky seznamu nemusí být jedinečné. Například v našem případě teď seznam obsahuje dvě samostatné položky s hodnotou 'Ω': první položku (a\_list[0]) a poslední položku (a\_list[6]).
- Volání metody a\_list.insert(0, value) se podobá použití funkce unshift() v jazyce Perl.
  Vloží prvek na začátek seznamu a index všech ostatních položek se zvýší, aby vzniklo potřebné místo.

Podívejme se podrobněji na rozdíly mezi append() a extend().

```
>>> a_list = ['a', 'b', 'c']
>>> a_list.extend(['d', 'e', 'f'])
                                          [1]
>>> a_list
['a', 'b', 'c', 'd', 'e', 'f']
>>> len(a_list)
                                          [2]
>>> a_list[-1]
'f'
>>> a_list.append(['g', 'h', 'i'])
                                          [3]
>>> a_list
['a', 'b', 'c', 'd', 'e', 'f', ['g', 'h', 'i']]
>>> len(a_list)
>>> a_list[-1]
['g', 'h', 'i']
```

- [1] Metoda extend() přebírá jeden argument, kterým je vždy seznam, a přidá každý jeho prvek do seznamu a\_list.
- Pokud začnete se seznamem o třech položkách a rozšíříte jej voláním extend() o seznam s dalšími třemi položkami, dostanete seznam s šesti položkami.
- Ve srovnání s tím metoda append() přebírá jeden argument, který může být libovolného datového typu. Na tomto řádku předáváme metodě append() seznam s třemi položkami.
- Pokud jsme začali se seznamem o šesti položkách a předaný seznam připojíme na konec, dostaneme seznam se sedmi položkami. Proč se sedmi? Protože poslední položkou (kterou jsme právě připojili) je *celý seznam*. Seznam může obsahovat data libovolného typu, včetně seznamu. Může to být právě to, co jste chtěli. Nebo možná nechtěli. Každopádně jste si o to řekli, a proto jste to dostali.

### 2.4.4. Vyhledávání hodnoty v seznamu

```
>>> a_list = ['a', 'b', 'new', 'mpilgrim', 'new']
>>> a_list.count('new')
>>> 'new' in a_list
                                          [2]
True
>>> 'c' in a_list
False
>>> a_list.index('mpilgrim')
                                          [3]
3
>>> a_list.index('new')
                                          [4]
>>> a_list.index('c')
                                          [5]
Traceback (innermost last):
  File "<interactive input>", line 1, in ?
ValueError: list.index(x): x not in list
```

- [1] Metoda count() vrací počet výskytů určité hodnoty v seznamu (což se dalo čekat).
- Pokud se chcete dozvědět jen to, jestli nějaká hodnota v seznamu je nebo ne, pak je použití operátoru in o něco rychlejší než volání metody count(). Operátor in vždy vrací True nebo False.

  Neřekne vám, kolikrát se daná hodnota v seznamu vyskytuje.
- Ani operátor in ani metoda count() vám ale neřeknou, kde se v seznamu hodnota vyskytuje. Pokud chcete zjistit, kde se hodnota v seznamu nachází, použijte metodu index(). Pokud neřeknete jinak, bude prohledávat celý seznam. Ale nepovinným druhým argumentem můžete zadat index (od nuly), na kterém má hledání začít. A můžeme dokonce zadat nepovinný třetí argument s indexem místa, kde má hledání skončit.
- [4] Metoda index() najde *první* výskyt zadané hodnoty v seznamu. V tomto případě se hodnota 'new' vyskytuje v seznamu dvakrát: a\_list[2] a a\_list[4]. Ale metoda index() vrátí jen index prvního výskytu.
- Co byste ale možná *nečekali*, je to, že v případě nenalezení hodnoty v seznamu vyvolá metoda index() výjimku.

Počkat! Co? Je to tak. Pokud metoda index() nenajde v seznamu zadanou hodnotu, vyvolá výjimku. Jde o zjevně odlišné chování ve srovnání s jinými jazyky, které vracejí nějakou neplatnou hodnotu indexu (jako například -1). Ze začátku se vám to může zdát protivné, ale myslím, že to časem oceníte. Znamená to, že program zhavaruje v místě vzniku problému místo toho, aby potichu a divně selhal o chvíli později. Vzpomeňte si, že hodnota -1 je platným indexem prvku v seznamu. Kdyby metoda index() místo výjimky vracela hodnotu -1, mohlo by to vést k poměrně nezábavným zážitkům při ladění.

#### 2.4.5 Odstraňování položek ze seznamu

# V seznamech nikdy nevznikají díry.

Seznamy se mohou automaticky nafukovat a smršťovat. Jejich expanzi už jsme si ukázali. Odstraňování položek ze seznamu můžeme také provést několika způsoby.

```
>>> a_list = ['a', 'b', 'new', 'mpilgrim', 'new']
>>> a_list[1]
'b'
>>> del a_list[1] [1]
>>> a_list
['a', 'new', 'mpilgrim', 'new']
>>> a_list[1] [2]
'new'
```

- [1] Pro odstranění určené položky ze seznamu můžeme použít příkaz del.
- Pokud se pokoušíme o přístup k položce s indexem 1 poté, co jsme položku s indexem 1 odstranili, *nedojde* k chybě. Poziční index všech položek, které následují za rušenou položkou, bude posunut tak, aby byla vzniklá mezera zaplněna.

Že neznáte ten správný poziční index? Žádný problém. Odstranění položek můžete předepsat také jejich hodnotou.

```
>>> a_list.remove('new') [1]
>>> a_list
['a', 'mpilgrim', 'new']
>>> a_list.remove('new') [2]
>>> a_list
['a', 'mpilgrim']
>>> a_list.remove('new')
Traceback (most recent call last):
   File "<stdin>", line 1, in <module>
ValueError: list.remove(x): x not in list
```

- [1] K odstranění položky ze seznamu můžete použít metodu remove(). Metoda remove() přebírá zadanou *hodnotu* a odstraní ze seznamu její první výskyt. A opět. Všechny položky, které následují za rušenou položkou, budou posunuty tak, aby byla vzniklá mezera zaplněna. V seznamech nikdy nevznikají díry.
- [2] Metodu remove() můžete volat, kdykoliv se vám to hodí. Ale pokud se pokusíte o odstranění položky s hodnotou, která se v seznamu nevyskytuje, bude vyvolána výjimka.

#### 2.4.6. Odstraňování položek ze seznamu: Bonusové kolo

Další zajímavou metodou seznamu je pop(). Metoda pop() představuje další způsob odstraňování položek ze seznamu, ale s malou fintou.

```
>>> a_list = ['a', 'b', 'new', 'mpilgrim']
>>> a_list.pop()
'mpilgrim'
>>> a_list
['a', 'b', 'new']
>>> a_list.pop(1)
                                          [2]
'h'
>>> a_list
['a', 'new']
>>> a_list.pop()
'new'
>>> a_list.pop()
'a'
>>> a_list.pop()
                                          [3]
Traceback (most recent call last):
  File "<stdin>", line 1, in <module>
IndexError: pop from empty list
```

- Pokud voláme metodu pop() bez argumentů, odstraní poslední položku seznamu a *vrátí hodnotu*, která byla odstraněna.
- [2] Metodou pop() můžeme ze seznamu odstranit libovolnou položku. Jednoduše jí předáme poziční index. Odstraní požadovanou položku, posune následující položky tak, aby zaplnila mezeru, a vrátí odstraněnou hodnotu.
- [3] Pokud voláme pop() pro prázdný seznam, vznikne výjimka.
- Volání metody seznamu pop() bez argumentu se podobá volání funkce pop() v jazyce Perl. Odstraní poslední položku seznamu a vrátí hodnotu, která byla odstraněna. V jazyce Perl existuje také funkce shift(), která odstraní první položku a vrátí její hodnotu. Jde o ekvivalent pythonovského volání a\_list.pop(0).

#### 2.4.7. Seznamy v booleovském kontextu

Seznam můžeme použít také v booleovském kontextu,
jako například v příkazu if.
vyhodnocují jako false,
ostatní seznamy jako true.

```
>>> def is_it_true(anything):
... if anything:
... print("yes, it's true")
... else:
... print("no, it's false")
...
>>> is_it_true([]) [1]
no, it's false
>>> is_it_true(['a']) [2]
yes, it's true
>>> is_it_true([False]) [3]
yes, it's true
```

- [1] Prázdný seznam se v booleovském kontextu vyhodnocuje jako false.
- Libovolný seznam, který obsahuje aspoň jednu položku, se vyhodnocuje jako true.
- [3] Libovolný neprázdný seznam se vyhodnocuje jako true. Hodnota položek je nepodstatná.

#### 2.5. N-tice

N-tice (anglicky tuple) se chová jako neměnitelný seznam. Jakmile je n-tice jednou vytvořena, nedá se nijak změnit.

```
>>> a_tuple = ("a", "b", "mpilgrim", "z", "example") [1]
>>> a_tuple
('a', 'b', 'mpilgrim', 'z', 'example')
>>> a_tuple[0] [2]
'a'
>>> a_tuple[-1] [3]
'example'
>>> a_tuple[1:3] [4]
```

- N-tice se definuje stejným způsobem jako seznam. Jediný rozdíl spočívá v tom, že posloupnost prvků neuzavřeme do hranatých závorek, ale do kulatých.
- Prvky n-tice mají definované pořadí, stejně jako u seznamu. N-tice se indexují od nuly (jako seznam), takže první element neprázdné n-tice se zapisuje vždy a\_tuple[0].
- Záporné indexy se vyhodnocují od konce n-tice, stejně jako u seznamu.
- Dají se z nich získávat výřezy (slice), stejně jako u seznamů. Když získáte výřez se seznamu, má podobu nového seznamu. Když předepíšete výřez z n-tice, dostanete novou n-tici.

Hlavní rozdíl mezi n-ticemi a seznamy je ten, že n-tice nemohou být změněny. Z technického pohledu říkáme, že n-tice jsou neměnitelné (anglicky immutable). Prakticky se to projevuje tak, že neposkytu-

jí žádnou metodu, která by nám je dovolila změnit. Seznamy mají metody jako append(), extend(), insert(), remove() a pop(). N-tice žádnou z těchto metod nemají. Z n-tice můžeme vytvořit výřez (protože se vytváří nová n-tice), můžeme zjišťovat, zda n-tice obsahuje určitou hodnotu (protože tím ke změně n-tice nedochází) a... to je všechno.

#### # Pokračování předchozího příkladu

```
>>> a_tuple
('a', 'b', 'mpilgrim', 'z', 'example')
>>> a_tuple.append("new")
                                         [1]
Traceback (innermost last):
 File "<interactive input>", line 1, in ?
AttributeError: 'tuple' object has no attribute 'append'
>>> a_tuple.remove("z")
Traceback (innermost last):
  File "<interactive input>", line 1, in ?
AttributeError: 'tuple' object has no attribute 'remove'
>>> a_tuple.index("example")
4
>>> "z" in a_tuple
                                         [4]
True
```

- Do n-tice nemůžeme přidávat další prvky. N-tice nemají ani metodu append() ani extend().
- Z n-tice nemůžeme prvky odstranit. N-tice nemají žádnou z metod remove() nebo pop().
- [3] V n-tici můžeme prvky vyhledávat, protože tím nedochází k její změně.
- [4] Můžeme také použít operátor in pro testování, zda n-tice obsahuje zadaný prvek.

#### Takže na co jsou n-tice dobré?

- N-tice jsou rychlejší než seznamy. Pokud potřebujete nadefinovat konstantní sadu hodnot
  a vše, co s nimi budete kdy chtít dělat, bude jejich procházení, použijte místo seznamu n-tici.
- Pokud data nepotřebujete měnit a učiníte je "chráněnými proti zápisu", bude váš kód bezpečnější. Pokud použijete místo seznamu n-tici, je to, jako kdybyste použili příkaz assert, který by kontroloval, zda jsou data konstantní. Překonat to můžeme jen záměrně (a s využitím specifické funkce).
- Některé n-tice mohou být použity jako slovníkové klíče (přesněji řečeno, n-tice, které obsahují neměnitelné (immutable) hodnoty jako jsou řetězce, čísla a jiné n-tice). V roli slovníkových klíčů nemůžou nikdy vystupovat seznamy, protože seznamy nejsou neměnitelné (immutable).
- > N-tice mohou být převedeny na seznamy a naopak. Zabudovaná funkce tuple() může převzít seznam a vrací n-tici se stejnými prvky. A naopak funkce list() může převzít zadanou n-tici a vrací seznam. Z pohledu účinku tedy funkce tuple() seznam zmrazí a funkce naopak list() rozpustí n-tici.

#### 2.5.1. N-tice v booleovském kontextu

N-tice můžeme použít v booleovském kontextu, jako například v příkazu if.

```
>>> def is_it_true(anything):
      if anything:
        print("yes, it's true")
      else:
        print("no, it's false")
>>> is_it_true(())
                                  [1]
no, it's false
>>> is_it_true(('a', 'b'))
                                  [2]
yes, it's true
>>> is_it_true((False,))
                                  [3]
yes, it's true
>>> type((False))
                                  [4]
<class 'bool'>
>>> type((False,))
<class 'tuple'>
```

- [1] Prázdná n-tice se v booleovském kontextu vyhodnocuje jako false.
- [2] Libovolná n-tice s alespoň jednou položkou se vyhodnocuje jako true.
- Libovolná n-tice s alespoň jednou položkou se vyhodnocuje jako true. Hodnota položek je nepodstatná. Ale co tady dělá ta čárka?
- Pokud chceme vytvořit n-tici s jedinou položkou, pak musíme za hodnotu připsat čárku.

  Pokud bychom čárku nepřidali, Python by si myslel, že jsme jednoduše přidali nadbytečnou dvojici závorek. Je to sice neškodné, ale n-tice se tím nevytvoří.

#### 2.5.2. Přiřazení více hodnot najednou

Následuje parádní programátorská zkratka. V Pythonu můžete n-tici použít pro přiřazení více hodnot najednou.

```
>>> v = ('a', 2, True)
>>> (x, y, z) = v [1]
>>> x
'a'
>>> y
2
>>> z
True
```

v je n-tice o třech prvcích a (x, y, z) je n-tice s třemi proměnnými. Přiřazení jedné do druhé vede k přiřazení každé z hodnot n-tice v do jednotlivých proměnných v uvedeném pořadí.

Využít se toho dá všemožnými způsoby. Dejme tomu, že chcete pojmenovat řadu hodnot. K rychlému přiřazení po sobě jdoucích hodnot můžete využít zabudovanou funkci range() a vícenásobné přiřazení.

```
>>> (MONDAY, TUESDAY, WEDNESDAY, THURSDAY, FRIDAY, SATURDAY, SUNDAY) = range(7) [1]
>>> MONDAY
0
>>> TUESDAY
1
>>> SUNDAY
6
```

- Zabudovaná funkce range() vytváří posloupnost celých čísel. (Z technického hlediska nevrací funkce range() seznam ani n-tici, ale **iterátor**. Odlišnosti se naučíme později.) MONDAY, TUESDAY, WEDNESDAY, THURSDAY, FRIDAY, SATURDAY, a SUNDAY jsou proměnné, které definujeme. (Tento příklad pochází z modulu calendar, což je malý zábavný modul, který tiskne kalendář podobně jako unixový program cal. Modul calendar definuje pro dny v týdnu celočíselné konstanty.)
- V tomto okamžiku má každá z proměnných svou hodnotu: Proměnná MONDAY je rovna 0, TUESDAY má hodnotu 1 a tak dále.

Současného přiřazení více proměnným můžeme využít také pro vytváření funkcí, které vracejí více hodnot najednou. Jednoduše v nich vrátíme n-tici se všemi požadovanými hodnotami. Ve volajícím kódu se k výsledku můžeme chovat jako k jedné n-tici, nebo jej můžeme přiřadit do více jednotlivých proměnných. Tento obrat používá řada standardních pythonovských knihoven, včetně modulu os. O něm si něco řekneme v následující kapitole.

#### 2.6. Množiny

Množina (set) je neuspořádanou kolekcí jedinečných hodnot. Jedna množina může obsahovat hodnoty libovolného neměnitelného (immutable) datového typu. Pokud máme k dispozici dvě množiny, můžeme s nimi provádět standardní množinové operace, jako je sjednocení, průnik a rozdíl množin.

# 2.6.1. Vytvoření množiny

Ale nejdříve proberme základy. Množinu vytvoříme snadno.

- [1] Pokud chceme vytvořit množinu s jednou hodnotou, uzavřeme hodnotu do složených závorek ({ }).
- [2] Množiny jsou ve skutečnosti implementovány jako třídy, ale tím se teď nebudeme zatěžovat.
- Pokud chceme vytvořit množinu s více hodnotami, oddělíme hodnoty čárkami a vše uzavřeme do složených závorek.

Množinu můžeme vytvořit i ze seznamu.

```
>>> a_list = ['a', 'b', 'mpilgrim', True, False, 42]
>>> a_set = set(a_list) [1]
>>> a_set
{'a', False, 'b', True, 'mpilgrim', 42}
>>> a_list ['a', 'b', 'mpilgrim', True, False, 42]
```

- K vytvoření množiny ze seznamu použijeme funkce set(). (Puntičkáři, kteří vědí, jak jsou množiny implementovány, by zde podotkli, že ve skutečnosti nejde o volání funkce, ale o vytváření instance třídy. Já vám slibuji, že se o tomto rozdílu dozvíte v této knize později. Prozatím nám bude stačit vědět, že set() se chová jako funkce a že vrací množinu.)
- Jak už jsem se zmínil dříve, jedna množina může obsahovat hodnoty libovolného datového typu. A zmínil jsem se také, že množiny jsou *neuspořádané*. Tato množina si nepamatuje původní pořadí prvků v seznamu, který byl použit k jejímu vytvoření. Pokud byste do množiny přidávali další prvky, nebude si množina pamatovat pořadí, v jakém jste je vkládali.
- [3] Původní seznam zůstává nezměněn.

Že zatím nemáte k dispozici žádné hodnoty? Žádný problém. Můžeme vytvořit prázdnou množinu.

```
>>> a_set = set() [1]
>>> a_set [2]
set()
>>> type(a_set) [3]
<class 'set'>
>>> len(a_set) [4]
0
>>> not_sure = {} [5]
```

```
>>> type(not_sure)
<class 'dict'>
```

- [1] K vytvoření prázdné množiny zavoláme set() bez argumentů.
- Zobrazená reprezentace prázdné množiny vypadá trochu divně. Očekávali jste spíš něco jako {}? Tímto způsobem se vyjadřuje prázdný slovník a ne množina. O slovnících se dozvíme později, ale ještě v této kapitole.
- [3] Navzdory podivnosti zobrazené reprezentace to skutečně je množina...
- [4] ...a tato množina neobsahuje žádné prvky.
- Prázdnou množinu nelze vytvořit zápisem dvou složených závorek kvůli historickým způsobům přeneseným z Pythonu 2. Tímto způsobem se vyjadřuje prázdný slovník a ne množina.

## 2.6.2. Úprava množiny

Do existující množiny můžeme přidávat hodnoty dvěma různými způsoby: metodou add() a metodou update().

```
>>> a_set = {1, 2}
>>> a_set.add(4) [1]
>>> a_set
{1, 2, 4}
>>> len(a_set) [2]
3
>>> a_set.add(1) [3]
>>> a_set
{1, 2, 4}
>>> len(a_set) [4]
```

- [1] Metoda add() přebírá jeden argument, který může být libovolného datového typu, a přidává zadanou hodnotu do množiny.
- [2] Množina teď má tři členy.
- Množiny jsou kolekcemi jedinečných hodnot. Pokud do množiny zkusíme přidat hodnotu, která se v ní již nachází, neudělá to nic. Nevznikne chyba. Jde zkrátka o prázdnou operaci.
- [4] Množina má *pořád* jen tři členy.

```
>>> a_set = {1, 2, 3}
>>> a_set
{1, 2, 3}
>>> a_set.update({2, 4, 6})
>>> a_set
{1, 2, 3, 4, 6}
[1]
```

```
>>> a_set.update({3, 6, 9}, {1, 2, 3, 5, 8, 13}) [3]
>>> a_set
{1, 2, 3, 4, 5, 6, 8, 9, 13}
>>> a_set.update([10, 20, 30]) [4]
>>> a_set
{1, 2, 3, 4, 5, 6, 8, 9, 10, 13, 20, 30}
```

- [1] Metoda update() přebírá jeden argument, rovněž množinu, a přidá všechny její členy do původní množiny. Je to, jako kdybychom volali metodu add() pro všechny členy množiny předané argumentem.
- [2] Protože cílová množina nemůže obsahovat jednu hodnotu dvakrát, duplicitní hodnoty se ignorují.
- Ve skutečnosti můžete metodu update() volat s libovolným počtem argumentů. Pokud ji zavoláte s dvěma množinami, metoda update() přidá všechny členy z každé z předaných množin do původní množiny (duplicitní hodnoty se přeskočí).
- [4] Metoda update() umí zpracovat objekty různých datových typů, včetně seznamů. Pokud jí předáte seznam, pak metoda update() přidá do původní množiny všechny členy seznamu.

#### 2.6.3. Odstraňování položek z množiny

Jednotlivé hodnoty lze z množiny odstranit třemi způsoby. První dva, discard() a remove(), se liší v jedné malé drobnosti.

```
>>> a_set = {1, 3, 6, 10, 15, 21, 28, 36, 45}
>>> a_set
{1, 3, 36, 6, 10, 45, 15, 21, 28}
>>> a_set.discard(10)
                                                   [1]
>>> a_set
{1, 3, 36, 6, 45, 15, 21, 28}
>>> a_set.discard(10)
                                                   [2]
>>> a_set
{1, 3, 36, 6, 45, 15, 21, 28}
>>> a_set.remove(21)
                                                   [3]
>>> a_set
{1, 3, 36, 6, 45, 15, 28}
>>> a_set.remove(21)
                                                   [4]
Traceback (most recent call last):
  File "<stdin>", line 1, in <module>
KeyError: 21
```

- [1] Metoda discard() přebírá jeden argument a zadanou hodnotu odebere z množiny.
- Pokud metodu discard() voláme s hodnotou, která v množině neexistuje, neprovede se nic. Nevznikne chyba. Jde o prázdnou operaci.

- [3] Metoda remove() také přebírá hodnotu jediného argumentu a také odstraňuje hodnotu z množiny.
- Odlišnost se projeví v případě, kdy se zadaná hodnota v množině nenachází. V takovém případě metoda remove() vyvolá výjimku KeyError.

Množiny, stejně jako seznamy, podporují metodu pop().

```
>>> a_set = {1, 3, 6, 10, 15, 21, 28, 36, 45}
>>> a_set.pop()
                                                 [1]
>>> a_set.pop()
>>> a_set.pop()
36
>>> a_set
{6, 10, 45, 15, 21, 28}
>>> a_set.clear()
                                                 [2]
>>> a_set
set()
>>> a_set.pop()
                                                 [3]
Traceback (most recent call last):
  File "<stdin>", line 1, in <module>
KeyError: 'pop from an empty set'
```

- Metoda pop() odstraní jeden prvek z množiny a vrátí jeho hodnotu. Ale množiny jsou neuspořádané a neexistuje u nich nic takového jako "poslední" hodnota. Proto také neexistuje možnost ovlivnit, která hodnota bude odstraněna. Je to zcela náhodné.
- Metoda clear() *odstraní* všechny prvky množiny a množina se stane prázdnou. Ve výsledku je to stejné jako provedení příkazu a\_set = set(), který vytvoří novou prázdnou množinu a přepíše původní hodnotu proměnné a\_set.
- Pokus o volání metody pop() pro prázdnou množinu vede k vyvolání výjimky KeyError.

#### 2.6.4. Běžné množinové operace

Pythonovský datový typ set podporuje několik běžných množinových operací.

```
>>> a_set = {2, 4, 5, 9, 12, 21, 30, 51, 76, 127, 195}
>>> 30 in a_set
True
>>> 31 in a_set
False
>>> b_set = {1, 2, 3, 5, 6, 8, 9, 12, 15, 17, 18, 21}
```

```
>>> a_set.union(b_set) [2]
{1, 2, 195, 4, 5, 6, 8, 12, 76, 15, 17, 18, 3, 21, 30, 51, 9, 127}
>>> a_set.intersection(b_set) [3]
{9, 2, 12, 5, 21}
>>> a_set.difference(b_set) [4]
{195, 4, 76, 51, 30, 127}
>>> a_set.symmetric_difference(b_set) [5]
{1, 3, 4, 6, 8, 76, 15, 17, 18, 195, 127, 30, 51}
```

- Pokud chceme otestovat, zda je daná hodnota prvkem množiny, použijeme operátor in. Funguje stejným způsobem jako u seznamů.
- Metoda union() (sjednocení) vrací novou množinu, která obsahuje všechny prvky jak z jedné, tak z druhé množiny.
- [3] Metoda intersection() (průnik) vrací novou množinu, která obsahuje všechny prvky nacházející se v obou množinách současně.
- [4] Metoda difference() (rozdíl) vrací novou množinu obsahující všechny prvky, které se nacházejí v množině a\_set, ale nenacházejí se v množině b\_set.
- Metoda symmetric\_difference() (symetrický rozdíl) vrací novou množinu obsahující všechny prvky, které se nacházejí právě v jedné z množin.

Tři z těchto metod jsou symetrické.

#### # Pokračování předchozího příkladu

```
>>> b_set.symmetric_difference(a_set) [1]
{3, 1, 195, 4, 6, 8, 76, 15, 17, 18, 51, 30, 127}
>>> b_set.symmetric_difference(a_set) == a_set.symmetric_difference(b_set) [2]
True
>>> b_set.union(a_set) == a_set.union(b_set) [3]
True
>>> b_set.intersection(a_set) == a_set.intersection(b_set) [4]
True
>>> b_set.difference(a_set) == a_set.difference(b_set) [5]
False
```

- Symetrický rozdíl množin a\_set od b\_set *vypadá* jinak než symetrický rozdíl množin b\_set od a\_set. Ale pamatujte na to, že množiny jsou neuspořádané. Jakékoliv dvě množiny, jejichž všechny hodnoty se shodují (žádná nesmí být vynechána), se považují za shodné.
- [2] A přesně tento případ nastal zde. Nenechte se zmást reprezentacemi těchto množin zobrazenými pythonovským shellem. Obsahují stejné hodnoty, takže jsou shodné.
- [3] Sjednocení dvou množin je také symetrické.
- [4] Průnik dvou množin je rovněž symetrický.
- [5] Rozdíl dvou množin symetrický není. Ono to dává smysl. Podobá se to odčítání jednoho čísla od druhého. Na pořadí operandů zde záleží.

A nakonec tu máme několik otázek, které můžeme množinám položit.

```
>>> a_set = {1, 2, 3}
>>> b_set = {1, 2, 3, 4}
>>> a_set.issubset(b_set) [1]
True
>>> b_set.issuperset(a_set) [2]
True
>>> a_set.add(5) [3]
>>> a_set.issubset(b_set)
False
>>> b_set.issuperset(a_set)
False
```

- [1] Množina a\_set je podmnožinou množiny b\_set všechny prvky množiny a\_set jsou současně prvky množiny b\_set.
- Stejnou otázku můžeme položit obráceně. Množina b\_set je nadmnožinou množiny a\_set, protože všechny prvky množiny a\_set jsou současně prvky množiny b\_set.
- Jakmile do množiny a\_set přidáme hodnotu, která se v množině b\_set nenachází, oba testy vrátí hodnotu False.

## 2.6.5. Množiny v booleovském kontextu

Množiny můžeme použít v booleovském kontextu, například v příkazu if.

```
>>> def is_it_true(anything):
      if anything:
        print("yes, it's true")
      else:
        print("no, it's false")
. . .
. . .
>>> is_it_true(set())
                                            [1]
no, it's false
>>> is_it_true({ 'a'})
                                            [2]
yes, it's true
>>> is_it_true({False})
                                            [3]
yes, it's true
```

- [1] Prázdná množina se v booleovském kontextu vyhodnocuje jako false.
- [2] Libovolná množina s alespoň jedním prvkem se vyhodnocuje jako true.
- Libovolná množina s alespoň jedním prvkem se vyhodnocuje jako true. Hodnota prvků je nepodstatná.

### 2.7. Slovníky

Slovník (dictionary) je neuspořádaná kolekce dvojic klíč-hodnota. Když do slovníku přidáme klíč, musíme do něj současně přidat i hodnotu, která ke klíči patří. (Hodnotu můžeme v budoucnu kdykoliv změnit.) Pythonovské slovníky jsou optimalizované pro získávání hodnoty k zadanému klíči, ale ne naopak.

> Pythonovský slovník se chová jako hash (čti [heš]; vyhledávací tabulka) v Perl 5. V jazyce Perl 5 začínají proměnné typu hash vždy znakem %. Pythonovské proměnné mohou být pojmenovány zcela libovolně. Python si vnitřně eviduje jejich datový typ.

#### 2.7.1. Vytvoření slovníku

Slovník vytvoříme snadno. Syntaxe se podobá množinové, ale místo pouhé hodnoty zadáváme dvojice klíč-hodnota. Jakmile slovník existuje, můžeme v něm vyhledávat hodnoty podle jejich klíče.

```
>>> a_dict = {'server': 'db.diveintopython3.org', 'database': 'mysql'} [1]
>>> a_dict
{'server': 'db.diveintopython3.org', 'database': 'mysql'}
>>> a_dict['server'] [2]
'db.diveintopython3.org'
>>> a_dict['database'] [3]
'mysql'
>>> a_dict['db.diveintopython3.org'] [4]
Traceback (most recent call last):
    File "<stdin>", line 1, in <module>
KeyError: 'db.diveintopython3.org'
```

- Nejdříve vytvoříme slovník s dvěma položkami a přiřadíme ho do proměnné a\_dict. Každá položka je tvořena dvojicí klíč-hodnota a celý výčet položek je uzavřen ve složených závorkách.
- [2] Řetězec 'server' je zde klíčem a k němu přidruženou hodnotou, na kterou se odkážeme zápisem a\_dict['server'], je 'db.diveintopython3.org'.
- [3] Řetězec 'database' je zde klíčem. K němu přidruženou hodnotou, na kterou se odkážeme zápisem a\_dict['database'], je 'mysql'.
- [4] Hodnoty můžeme získat na základě klíče, ale klíče nemůžeme získat na základě znalosti hodnoty. Takže a\_dict['server'] obsahuje 'db.diveintopython3.org', ale a\_dict['db.diveintopython3.org'] vyvolá výjimku, protože 'db.diveintopython3.org' není klíčem.

### 2.7.2. Úprava slovníku

Slovníky nemají žádné předem určené omezení velikosti. Dvojici klíč-hodnota můžeme do slovníku přidat kdykoliv. Nebo můžeme měnit hodnotu příslušející ke klíči. Pokračování předchozího příkladu:

```
>>> a_dict
{'server': 'db.diveintopython3.org', 'database': 'mysql'}
>>> a_dict['database'] = 'blog'
>>> a_dict
{'server': 'db.diveintopython3.org', 'database': 'blog'}
>>> a_dict['user'] = 'mark'
>>> a_dict
{'server': 'db.diveintopython3.org', 'user': 'mark', 'database': 'blog'}
>>> a_dict['user'] = 'dora'
                                         [4]
>>> a_dict
{'server': 'db.diveintopython3.org', 'user': 'dora', 'database': 'blog'}
>>> a_dict['User'] = 'mark'
                                         [5]
>>> a dict
{'User': 'mark', 'server': 'db.diveintopython3.org', 'user': 'dora', 'database': 'blog'}
```

- Ve slovníku se nemohou nacházet duplicitní klíče. Pokud přiřadíme hodnotu k existujícímu klíči, dojde k přepsání původní hodnoty.
- Dvojici klíč-hodnota můžeme přidat kdykoliv. Tato syntaxe se shoduje s případem změny existujících hodnot.
- Nová položka slovníku (klíč 'user', hodnota 'mark') se objevila uprostřed. To, že se u prvního příkladu položky objevily seřazené, byla pouhá náhoda. Stejná náhoda je to, že se nyní jeví jako rozházené.
- [4] Přiřazení hodnoty k existujícímu klíči slovníku vede k prosté náhradě staré hodnoty novou.
- Změní se tímto příkazem hodnota klíče user zpět na "mark"? Nikoliv! Prohlédněte si klíč pořádně. V řetězci User je napsáno velké U. Klíče slovníků jsou citlivé na velikost písmen, takže tento příkaz vytváří novou dvojici klíč-hodnota a existující hodnotu nepřepíše. Klíč se vám sice může zdát podobný, ale z pohledu Pythonu je úplně jiný.

#### 2.7.3. Slovníky se smíšeným obsahem

Slovníky nejsou určeny jen pro řetězce. Hodnoty ve slovníku mohou být libovolného datového typu včetně celých čísel, booleovských hodnot, libovolných objektů nebo dokonce slovníků. Uvnitř jednoho slovníku nemusí být všechny hodnoty stejného typu. Můžeme je míchat podle potřeby. Klíče slovníků mají větší omezení, ale mohou být typu řetězec, celé číslo a několika dalších typů. Datové typy klíčů v jednom slovníku můžeme také míchat.

Se slovníky s neřetězcovými klíči a hodnotami jsme se vlastně už setkali v kapitole Váš první pythonovský program.

```
SUFFIXES = {1000: ['KB', 'MB', 'GB', 'TB', 'PB', 'EB', 'ZB', 'YB'],
1024: ['KiB', 'MiB', 'GiB', 'TiB', 'PiB', 'EiB', 'ZiB', 'YiB']}
```

Teď to v interaktivním shellu rozkucháme.

```
>>> SUFFIXES = {1000: ['KB', 'MB', 'GB', 'TB', 'PB', 'EB', 'ZB', 'YB'],
... 1024: ['KiB', 'MiB', 'GiB', 'TiB', 'PiB', 'EiB', 'ZiB', 'YiB']}
>>> len(SUFFIXES) [1]
2
>>> 1000 in SUFFIXES [2]
True
>>> SUFFIXES[1000] [3]
['KB', 'MB', 'GB', 'TB', 'PB', 'EB', 'ZB', 'YB']
>>> SUFFIXES[1024] [4]
['KiB', 'MiB', 'GiB', 'TiB', 'PiB', 'EiB', 'ZiB', 'YiB']
>>> SUFFIXES[1000][3] [5]
'TB'
```

- Funkce len(), podobně jako u seznamů a množin, vrací počet klíčů ve slovníku.
- A stejně jako u seznamů a množin můžeme použít operátor in k testování, zda je zadaný klíč ve slovníku definován.
- Číslo 1000 *je* klíčem ve slovníku SUFFIXES. Jeho hodnotou je seznam osmi položek (osmi řetězců, abychom byli přesní).
- A podobně i číslo 1024 je klíčem ve slovníku SUFFIXES. Jeho hodnotou je také seznam s osmi položkami.
- [6] A protože SUFFIXES[1000] obsahuje seznam, můžeme jeho jednotlivé prvky zpřístupňovat prostřednictvím indexu (od nuly).

#### 2.7.4. Slovníky v booleovském kontextu

Slovník můžeme použít v booleovském kontextu, jako například v příkazu if.

Prázdné slovníky se vyhodnocují jako false, všechny ostatní slovníky jako true.

```
>>> def is_it_true(anything):
... if anything:
... print("yes, it's true")
... else:
... print("no, it's false")
...
>>> is_it_true({})
no, it's false
>>> is_it_true({'a': 1})
yes, it's true
```

- [1] Prázdný slovník se v booleovském kontextu vyhodnocuje jako false.
- [2] Slovník s alespoň jednou dvojicí klíč-hodnota se vyhodnocuje jako true.

#### 2.8. None

None [nan] je speciální pythonovskou konstantou. Vyjadřuje žádnou hodnotu. Ale None není totéž co False. None není nula. None není prázdný řetězec. Pokud porovnáme None s čímkoliv jiným než s None, vždycky dostaneme False.

None je jedinou "žádnou" hodnotou. Má svůj vlastní datový typ (NoneType). Hodnotu None můžeme přiřadit do libovolné proměnné, ale nemůžeme vytvořit jiný objekt typu NoneType. Všechny proměnné, jejichž hodnota je None, jsou vzájemně shodné.

```
>>> type(None)
<class 'NoneType'>
>>> None == False
False
>>> None == 0
False
>>> None == ''
False
>>> None == None
True
>>> x = None
>>> x == None
True
>>> y = None
>>> x == y
True
```

#### 2.8.1. None v booleovském kontextu

V booleovském kontextu se None vyhodnocuje jako false a not None jako true.

```
>>> def is_it_true(anything):
... if anything:
... print("yes, it's true")
... else:
... print("no, it's false")
...
>>> is_it_true(None)
no, it's false
>>> is_it_true(not None)
yes, it's true
```

#### 2.9. Přečtěte si

- Boolean operations (booleovské operace)
- Numeric types (číselné typy)
- Sequence types (typy posloupností)
- **Set types** (množinové typy)
- Mapping types (mapovací typy, vyhledávací tabulky)
   (vše na http://docs.python.org/py3k/library/stdtypes.html)
- modul fractions (zlomky)
   (http://docs.python.org/py3k/library/fractions.html)
- modul math (matematický)
   (http://docs.python.org/py3k/library/math.html)
- PEP 237: Unifying Long Integers and Integers (sjednocení velkých celých čísel a celých čísel) (http://www.python.org/dev/peps/pep-0237/)
- PEP 238: Changing the Division Operator (změna operátoru dělení) (http://www.python.org/dev/peps/pep-0238/)

3. Kapitola

- "Our imagination is stretched to the utmost, not, as in fiction, to imagine things which are not really there, but just to comprehend those things which are." (Naše představivost je napjatá do krajnosti. Ne jako u fikce, abychom si představili věci, které zde nejsou, ale proto, abychom jen obsáhli věci, které jsou zde.)
  - Richard Feynman

# 3. Generátorová notace

| э.     | Generatorova notace — 91                     |
|--------|--|
| 3.1.   | Ponořme se — 93                              |
| 3.2.   | Práce se soubory a s adresáři — 93           |
| 3.2.1. | Aktuální pracovní adresář — 93               |
| 3.2.2. | Práce se jmény souborů a adresářů — $\bf 94$ |
| 3.2.3. | Výpis adresářů — <b>96</b>                   |
| 3.2.4. | Získání dalších informací o souboru — 9      |
| 3.2.5. | Jak vytvořit absolutní cesty — 98            |
| 3.3.   | Generátorová notace seznamu — 98             |
| 3.4.   | Generátorová notace slovníku — 100           |
| 3.4.1. | Další legrácky s generátorovou               |
|        | notací slovníků — 102                        |
| 3.5.   | Generátorová notace množin — 103             |

Přečtěte si — 103

3.6.

- 3.1. Ponořme se
- 3.2. Práce se soubory a s adresáři

### 3.1. Ponořme se

V každém programovacím jazyce najdeme určitý rys, který záměrně zjednodušuje nějakou komplikovanou věc. Pokud přicházíte se zkušenostmi z jiného jazyka, můžete to snadno přehlédnout, protože váš starý jazyk právě tu určitou věc nezjednodušoval (protože dalo práci místo toho zjednodušit něco jiného). V této kapitole se seznámíme s generátorovou notací seznamů (list comprehensions), s generátorovou notací slovníků (dictionary comprehensions) a s generátorovou notací množin (set comprehensions). Jde o tři související koncepty, jejichž jádrem je jedna velmi mocná technika. Ale nejdříve si uděláme malou odbočku ke dvěma modulům, které vám usnadní orientaci ve vašem lokálním souborovém systému.

### 3.2. Práce se soubory a s adresáři

Python 3 se dodává s modulem zvaným os, což je zkratka pro "operační systém". Modul os obsahuje spoustu funkcí pro získávání informací o lokálních adresářích, souborech, procesech a proměnných prostředí — a v některých případech s nimi umožňuje manipulovat. Python se snaží co nejlépe, aby pro všechny podporované operační systémy nabízel jednotné API (aplikační programové rozhraní). Cílem je, aby vaše programy běžely na libovolném počítači a aby přitom obsahovaly co nejméně kódu, který by byl závislý na platformě.

#### 3.2.1. Aktuální pracovní adresář

Pokud s Pythonem právě začínáte, strávíte ještě hodně času v pythonovském shellu. V celé knize se budete setkávat s příklady, jako je tento:

- 1. Importujte jeden z modulů nacházejících se v adresáři examples (příklady).
- 2. Zavolejte funkci z tohoto modulu.
- 3. Vysvětlete výsledky.

# Vždy existuje to, čemu se říká aktuální pracovní adresář.

Pokud o aktuálním pracovním adresáři nic nevíte, pak krok 1 pravděpodobně selže a objeví se výjimka ImportError. Proč? Protože Python se bude po modulu dívat ve vyhledávací cestě pro import, ale nenajde jej, protože adresář examples se v žádném adresáři z vyhledávací cesty nenachází. Aby to prošlo, můžete udělat jednu ze dvou věcí:

- 1. Adresář examples přidáte do vyhledávací cesty pro import.
- 2. Změníte aktuální pracovní adresář na examples.

Aktuální pracovní adresář je neviditelný údaj, který si Python neustále udržuje v paměti. Aktuální pracovní adresář existuje vždy — ať už jste v pythonovském shellu, spouštíte svůj vlastní pythonovský skript z příkazového řádku nebo spouštíte pythonovský CGI skript na nějakém webovém serveru.

Pro vypořádání se s aktuálním pracovním adresářem nabízí modul os dvě funkce.

```
>>> import os [1]
>>> print(os.getcwd()) [2]
C:\Python31
>>> os.chdir('/Users/pilgrim/diveintopython3/examples') [3]
>>> print(os.getcwd()) [4]
C:\Users\pilgrim\diveintopython3\examples
```

- [1] Modul os je součástí Pythonu. Můžete jej importovat kdykoliv a kdekoliv.
- Informaci o aktuálním pracovním adresáři získáte použitím funkce os.getcwd(). Pokud používáte grafický pythonovský shell, pak se aktuální pracovní adresář zpočátku nachází v adresáři, ve kterém je umístěn spustitelný program pythonovského shellu. Při práci pod Windows to záleží na tom, kam jste Python nainstalovali. Výchozí adresář je c:\Python31. Pokud používáte konzolový pythonovský shell, pak se aktuální pracovní adresář zpočátku nachází v adresáři, ve kterém jste spustili python3.
- [3] Aktuální pracovní adresář můžeme měnit použitím funkce os.chdir().
- Při volání funkce os.chdir() jsem použil cestu v linuxovém stylu (normální lomítka, žádné písmeno disku), i když pracuji pod Windows. To je právě jedno z míst, kde se Python snaží zamaskovat rozdíly mezi operačními systémy.

#### 3.2.2. Práce se jmény souborů a adresářů

Když už se bavíme o adresářích, chtěl bych vás upozornit na modul os.path. Ten obsahuje funkce pro manipulace se jmény souborů a adresářů.

```
>>> import os
>>> print(os.path.join('/Users/pilgrim/diveintopython3/examples/', 'humansize.py')) [1]
/Users/pilgrim/diveintopython3/examples/humansize.py
>>> print(os.path.join('/Users/pilgrim/diveintopython3/examples', 'humansize.py')) [2]
/Users/pilgrim/diveintopython3/examples\humansize.py
>>> print(os.path.expanduser('~')) [3]
c:\Users\pilgrim
>>> print(os.path.join(os.path.expanduser('~'), 'diveintopython3', 'examples', 'humansize.py')) [4]
c:\Users\pilgrim\diveintopython3\examples\humansize.py
```

Funkce os.path.join() sestaví cestu z jedné nebo více částí cesty. V tomto případě jednoduše spojí řetězce.

- Tento příklad už není tak jednoduchý. Funkce os.path.join() před napojením jména souboru [2] navíc přidá k cestě jedno lomítko. Místo obyčejného lomítka použila zpětné lomítko, protože jsem tento příklad pouštěl pod Windows. Pokud byste stejný příklad zkoušeli na systémech Linux nebo Mac OS X, použilo by se normální lomítko. Nepárejte se s lomítky. Používejte vždy os.path.join() a nechejte na Pythonu, aby udělal, co je správné.
- Funkce os.path.expanduser() rozepíše cestu, která pro vyjádření domácího adresáře aktuál-[3] ního uživatele používá znak ~. Funguje to na libovolné platformě, kde mají uživatelé přidělený svůj domácí adresář, tedy na Linuxu, Mac OS X a ve Windows. Vrácená cesta neobsahuje koncové lomítko, ale to funkci os.path.join() nevadí.
- Kombinováním těchto technik můžeme snadno konstruovat cesty do adresářů a k souborům, [4] které se nacházejí v uživatelově domácím adresáři. Funkce os.path.join() přebírá libovolný počet argumentů. Jakmile jsem to zjistil, skákal jsem radostí, protože při přípravě mých nástrojů v nějakém novém jazyce je addSlashIfNecessary() (přidejLomítkoPokudJeToNutné) jednou z těch otravných malých funkcí, které si musím vždy znovu napsat. V Pythonu takovou funkci nepište. Chytří lidé už se o to postarali za vás.

Modul os . path obsahuje také funkce, které umí rozdělit plné cesty, jména adresářů a souborů na jejich podstatné části.

```
>>> pathname = '/Users/pilgrim/diveintopython3/examples/humansize.py'
>>> os.path.split(pathname)
('/Users/pilgrim/diveintopython3/examples', 'humansize.py')
>>> (dirname, filename) = os.path.split(pathname)
                                                                     [2]
>>> dirname
                                                                      [3]
'/Users/pilgrim/diveintopython3/examples'
>>> filename
                                                                     [4]
'humansize.pv'
>>> (shortname, extension) = os.path.splitext(filename)
                                                                     [5]
>>> shortname
'humansize'
>>> extension
'.py'
```

- Funkce split rozdělí plnou cestu a vrátí n-tici, která obsahuje zvlášť cestu a zvlášť jméno souboru. [1]
- Pamatujete si, že jsme se bavili o možnosti vracet více hodnot z funkce přiřazením hodnot více [2] proměnným najednou? Funkce os.path.split() dělá přesně tohle. Výsledek funkce split přiřadíme do n-tice s dvěma proměnnými. Každá z proměnných získá hodnotu odpovídajícího prvku vracené dvojice.
- První proměnná, dirname, obdrží hodnotu prvního prvku n-tice, kterou vrací funkce os.path. [3] split(), a sice cestu k souboru.
- Druhá proměnná, filename, obdrží hodnotu druhého prvku n-tice vracené funkcí os.path. [4] split(), jméno souboru.

Modul os.path obsahuje také funkci os.path.splitext(), která rozdělí jméno souboru a vrací dvojici obsahující jméno souboru bez přípony a příponu. Pro jejich přiřazení do oddělených proměnných použijeme stejnou techniku.

# 3.2.3. Výpis adresářů

# Modul glob používá shellovské zástupné znaky.

Dalším nástrojem z pythonovské standardní knihovny je modul glob. Umožní nám z programu snadno získat obsah nějakého adresáře. Používá typ zástupných znaků (wildcards), které už asi znáte z práce na příkazovém řádku.

```
>>> os.chdir('/Users/pilgrim/diveintopython3/')
>>> import glob
>>> glob.glob('examples/*.xml')
                                                    [1]
['examples\\feed-broken.xml',
 'examples\\feed-ns0.xml',
 'examples\\feed.xml']
>>> os.chdir('examples/')
                                                    [2]
>>> glob.glob('*test*.py')
                                                    [3]
['alphameticstest.py',
 'pluraltest1.py',
 'pluraltest2.py',
 'pluraltest3.py',
 'pluraltest4.py',
 'pluraltest5.py',
 'pluraltest6.py',
 'romantest1.py',
 'romantest10.py',
 'romantest2.py',
 'romantest3.py'
 'romantest4.py',
 'romantest5.py',
 'romantest6.py',
 'romantest7.py'
 'romantest8.py',
 'romantest9.py']
```

Modul glob zpracovává masku se zástupným znakem a vrací cesty ke všem souborům a adresářům, které masce se zástupným znakem odpovídají. V tomto příkladu je maska složena z cesty do adresáře a z "\*.xml". Budou jí odpovídat všechny .xml soubory v podadresáři examples.

- [2] Teď jako aktuální pracovní adresář zvolíme podadresář examples. Funkce os.chdir() umí pracovat i s relativními cestami.
- Ve vzorku pro funkci glob můžeme použít více zástupných znaků. Tento příklad nalezne v aktuálním pracovním adresáři všechny soubory, které končí příponou .py a kdekoliv ve jméně souboru obsahují slovo test.

#### 3.2.4. Získání dalších informací o souboru

Každý moderní souborový systém ukládá o každém souboru metadata, jako jsou: datum vytvoření, datum poslední modifikace, velikost souboru atd. Pro zpřístupnění těchto metadat poskytuje Python jednotné API. Soubor se nemusí otevírat. Vše, co potřebujete znát, je jeho jméno.

```
>>> import os
>>> print(os.getcwd()) [1]
c:\Users\pilgrim\diveintopython3\examples
>>> metadata = os.stat('feed.xml') [2]
>>> metadata.st_mtime [3]
1247520344.9537716
>>> import time [4]
>>> time.localtime(metadata.st_mtime) [5]
time.struct_time(tm_year=2009, tm_mon=7, tm_mday=13, tm_hour=17, tm_min=25, tm_sec=44, tm_wday=0, tm_yday=194, tm_isdst=1)
```

- [1] Aktuálním pracovním adresářem je složka examples.
- [2] feed.xml je soubor ve složce examples. Voláním funkce os.stat() získáme objekt, který obsahuje několik různých typů informací o souboru (metadat).
- st\_mtime zachycuje čas poslední modifikace, ale není uložen ve tvaru, který by byl moc použitelný. (Z technického pohledu je to počet sekund od Epochy, kde Epocha je definována jako první sekunda 1. ledna 1970. Vážně!)
- [4] Modul time je součástí standardní pythonovské knihovny. Obsahuje funkce pro převody mezi různými reprezentacemi času, pro formátování času do řetězcové podoby a pro hraní si s časovými zónami.
- Funkce time.localtime() převádí hodnotu času ze sekund-od-Epochy (z položky st\_mtime objektu vraceného funkcí os.stat()) na použitelnější strukturu obsahující rok, měsíc, den, hodinu, minutu, sekundu atd. Tento soubor byl naposledy změněn 13. července 2009 přibližně v 17 hodin a 25 minut.

# pokračování předchozího příkladu

```
>>> metadata.st_size [1]
3070
>>> import humansize
>>> humansize.approximate_size(metadata.st_size) [2]
'3.0 KiB'
```

- Funkce os.stat() vrací také velikost souboru, a to v položce st\_size. Soubor feed.xml obsahuje 3070 bajtů.
- [2] Položku st\_size můžeme předat funkci approximate\_size().

#### 3.2.5. Jak vytvořit absolutní cesty

V předcházející podkapitole jsme voláním funkce glob.glob() získali seznam s relativními cestami. V prvním příkladu jsme získali cesty jako 'examples\feed.xml'. V druhém příkladu jsme získali dokonce ještě kratší relativní cesty jako 'romantest1.py'. Za předpokladu, že zůstaneme ve stejném pracovním adresáři, můžeme tyto relativní cesty používat pro otevření souborů nebo pro získávání jejich metadat. Ale pokud chceme vytvořit absolutní cestu — tj. takovou, která obsahuje jména všech adresářů až po kořenový adresář nebo včetně jména disku —, budeme potřebovat funkci os.path.realpath().

```
>>> import os
>>> print(os.getcwd())
c:\Users\pilgrim\diveintopython3\examples
>>> print(os.path.realpath('feed.xml'))
c:\Users\pilgrim\diveintopython3\examples\feed.xml
```

#### 3.3. Generátorová notace seznamu

Generátorová notace seznamu (anglicky list comprehension [list komprihenšn]) umožňuje stručný zápis vytvoření seznamu z jiného seznamu aplikováním funkce na všechny prvky zdrojového seznamu. (Poznámka překladatele: Pojem "list comprehension" je znám z deklarativních jazyků a má charakter

V generátorové notaci seznamu můžeme použít libovolný pythonovský výraz. syntaktické konstrukce. V jazyce Python se "vnitřku" deklarativního zápisu podobá generátorový výraz. Tímto způsobem byl odvozen český pojem "generátorová notace". Někdy je pojem "list comprehension" použit v procedurálním, dynamickém smyslu. V takové situaci můžeme uvažovat o pojmu "generátor seznamu". Pokud se bavíme o jeho výsledku, můžeme uvažovat i o pojmu "generovaný

seznam". Vzhledem k tomu, že zavedený český pojem pro tuto konstrukci asi neexistuje — studentům příslušných oborů vysokých škol přijde po krátké chvíli anglický pojem srozumitelný —, budu volněji používat některou z uvedených variant. Někdy budu poněkud dlouhý pojem "generátorová notace seznamu" zkracovat. Kritériem volby bude dobrá srozumitelnost.)

```
>>> a_list = [1, 9, 8, 4]

>>> [elem * 2 for elem in a_list] [1]

[2, 18, 16, 8]

>>> a_list [2]

[1, 9, 8, 4]

>>> a_list = [elem * 2 for elem in a_list] [3]

>>> a_list

[2, 18, 16, 8]
```

- Aby nám to začalo dávat smysl, podívejme se na zápis zprava doleva. Seznam a\_list je zde zdrojem zobrazení. Interpret jazyka Python prochází seznam a\_list po jednom prvku a dočasně přiřazuje jeho hodnotu do proměnné elem. Poté Python aplikuje funkci elem \* 2 a připojí výsledek na konec cílového seznamu.
- [2] Generátorová notace produkuje nový seznam. Původní seznam zůstává nezměněný.
- Výsledek generátoru seznamu můžeme bezpečně přiřadit do proměnné, která zachycovala původní seznam. Python nejdříve vytvoří nový seznam v paměti a teprve po dokončení jeho generování přiřadí výsledek do původní proměnné.

V generátorové notaci seznamu můžeme využít libovolný pythonovský výraz, včetně funkcí z modulu os, které slouží k manipulaci se soubory a adresáři.

```
>>> import os, glob
>>> glob.glob('*.xml') [1]
['feed-broken.xml', 'feed-ns0.xml', 'feed.xml']
>>> [os.path.realpath(f) for f in glob.glob('*.xml')] [2]
['c:\\Users\\pilgrim\\diveintopython3\\examples\\feed-broken.xml',
    'c:\\Users\\pilgrim\\diveintopython3\\examples\\feed-ns0.xml',
    'c:\\Users\\pilgrim\\diveintopython3\\examples\\feed.xml']
```

- [1] Toto volání vrací seznam všech . xml souborů v aktuálním pracovním adresáři.
- Tato generátorová notace přebírá předchozí seznam .xml souborů a transformuje jej na seznam jmen s plnou cestou.

Generátorová notace seznamu může navíc předepisovat i filtraci položek. To znamená, že může vyprodukovat výsledek, který bude kratší než původní seznam.

```
>>> import os, glob
>>> [f for f in glob.glob('*.py') if os.stat(f).st_size > 6000]
                                                                            [1]
['pluraltest6.py',
 'romantest10.py',
 'romantest6.py',
 'romantest7.py',
 'romantest8.py',
 'romantest9.py']
```

[1] Filtraci seznamu provedeme vložením podmínky if na konec generátorové notace. Pro každou položku seznamu bude vyhodnocen výraz za klíčovým slovem if. Pokud je výsledkem výrazu True, pak bude položka zahrnuta do výstupu. Tato generátorová notace seznamu předepisuje zpracování všech souborů s příponou .py v aktuálním adresáři. Výraz za if zajišťuje filtraci seznamu testováním, zda je velikost každého souboru větší než 6000 bajtů. Takových souborů je šest, takže generátorová notace produkuje seznam se šesti jmény souborů.

Všechny předchozí příklady generátorové notace seznamu používaly jen jednoduché výrazy — násobení čísla konstantou, volání jedné funkce, nebo jednoduše vracely původní položky seznamu (po filtraci). Ale generátorová notace seznamu může být libovolně složitá.

```
>>> import os, glob
>>> [(os.stat(f).st_size, os.path.realpath(f)) for f in glob.glob('*.xml')]
                                                                                        [1]
[(3074, 'c:\\Users\\pilgrim\\diveintopython3\\examples\\feed-broken.xml'),
 (3386, 'c:\\Users\\pilgrim\\diveintopython3\\examples\\feed-ns0.xml'),
 (3070, 'c:\\Users\\pilgrim\\diveintopython3\\examples\\feed.xml')]
>>> import humansize
>>> [(humansize.approximate_size(os.stat(f).st_size), f) for f in glob.glob('*.xml')] [2]
[('3.0 KiB', 'feed-broken.xml'),
 ('3.3 KiB', 'feed-ns0.xml'),
 ('3.0 KiB', 'feed.xml')]
```

- Tato generátorová notace nalezne v aktuálním pracovním adresáři všechny soubory s příponou [1] .xml, zjistí velikost každého z nich (voláním funkce os.stat()) a vytvoří dvojice obsahující jméno souboru a absolutní cestu k souboru (voláním funkce os.path.realpath()).
- Tento generátorový zápis seznamu vychází z předchozího. Pro velikost každého .xml souboru [2] se volá funkce approximate\_size().

#### Generátorová notace slovníku 3.4.

Generátorová notace slovníku (anglicky dictionary comprehension [dikšenri komprihenšn]) se podobá generátorové notaci seznamu, ale místo seznamu popisuje vytvoření slovníku.

```
>>> import os, glob
>>> metadata = [(f, os.stat(f)) for f in glob.glob('*test*.py')]
                                                                                    [1]
>>> metadata[0]
                                                                                    [2]
('alphameticstest.py', nt.stat_result(st_mode=33206, st_ino=0, st_dev=0,
 st_nlink=0, st_uid=0, st_gid=0, st_size=2509, st_atime=1247520344.
 st_mtime=1247520344, st_ctime=1247520344))
>>> metadata_dict = {f:os.stat(f) for f in glob.glob('*test*.py')}
                                                                                    [3]
>>> type(metadata_dict)
                                                                                    [4]
<class 'dict'>
>>> list(metadata_dict.keys())
                                                                                    [5]
['romantest8.py', 'pluraltest1.py', 'pluraltest2.py', 'pluraltest5.py',
 'pluraltest6.py', 'romantest7.py', 'romantest10.py', 'romantest4.py',
 'pluraltest6.py', 'romantest7.py', 'romantest10.py', 'romantest4.py',
 'romantest3.py', 'romantest5.py', 'romantest6.py', 'alphameticstest.py',
 'pluraltest4.pv']
>>> metadata_dict['alphameticstest.py'].st_size
                                                                                    [6]
2509
```

- Toto není generátorová notace slovníku, ale generátorová notace seznamu. Nalezne všechny soubory s příponou .py, které ve svém jméně obsahují podřetězec test. Pak se vytvoří dvojice obsahující jméno souboru a jeho metadata (voláním funkce os.stat()).
- [2] Každá položka výsledného seznamu je dvojice.
- Ale toto už je generátorová notace slovníku. Až na dva rozdíly se syntaxe podobá generátorové notaci seznamu. Zaprvé, místo do hranatých závorek je celá uzavřena do složených závorek. Zadruhé, pro každou položku místo jednoho výrazu obsahuje dva výrazy oddělené dvojtečkou. Výraz před dvojtečkou (v našem případě f) představuje klíč slovníku. Výraz za dvojtečkou (v našem případě os.stat(f)) je hodnota.
- [4] Generátorová notace slovníku produkuje slovník.
- Klíče uvedeného slovníku zachycují jména souborů, která se vrátila z volání glob.glob('\*test\*.py').
- Hodnotou přidruženou ke každému klíči je hodnota vrácená funkcí os.stat(). To znamená, že v tomto slovníku můžeme na základě jména souboru "vyhledat" jeho metadata. Jednou z částí metadat je st\_size, zachycující velikost souboru. Soubor alphameticstest.py obsahuje 2509 bajtů.

Také u generátorové notace slovníků (podobně jako u generátorové notace seznamů) můžeme přidat podmínku if, která zajistí filtraci vyhodnocením výrazu pro každou položku vstupní posloupnosti.

```
>>> import os, glob, humansize
>>> metadata_dict = {f:os.stat(f) for f in glob.glob('*')}
                                                                                              [1]
>>> humansize_dict = {os.path.splitext(f)[0]:humansize.approximate_size(meta.st_size) \
                      for f, meta in metadata_dict.items() if meta.st_size > 6000}
                                                                                              [2]
>>> list(humansize_dict.keys())
                                                                                              [3]
['romantest9', 'romantest8', 'romantest7', 'romantest6', 'romantest10', 'pluraltest6']
>>> humansize_dict['romantest9']
                                                                                              [4]
'6.5 KiB'
```

- [1] Tato generátorová notace konstruuje seznam všech souborů v aktuálním pracovním adresáři (glob.glob('\*')), získává metadata každého souboru (os.stat(f)) a vytváří slovník, jehož klíči jsou jména souborů a k nim přiřazené hodnoty jsou metadata každého souboru.
- Tato generátorová notace vychází z předchozí. Odfiltrovává soubory menší než 6000 bajtů [2] (if meta.st\_size > 6000) a takto přefiltrovaný seznam používá k vytvoření slovníku. Jeho klíče tvoří jména souborů bez přípony (os.path.splitext(f)[0]) a hodnotami jsou přibližné velikosti těchto souborů (humansize.approximate\_size(meta.st\_size)).
- [3] V předchozím příkladu jsme si ukázali, že těchto souborů je šest. Z toho vyplývá, že slovník bude mít šest položek.
- [4] Hodnotou každého klíče je řetězec vrácený funkcí approximate\_size().

#### Další legrácky s generátorovou notací slovníků 3.4.1.

Následující trik využívající generátorové notace slovníku se nám jednoho dne může hodit. Jde o vzájemnou záměnu klíčů a hodnot slovníku.

```
>>> a_dict = {'a': 1, 'b': 2, 'c': 3}
>>> {value:key for key, value in a_dict.items()}
{1: 'a', 2: 'b', 3: 'c'}
```

Bude to samozřejmě fungovat jen v případě, kdy jsou hodnoty ve slovníku neměnitelného typu (immutable), jako jsou řetězce nebo n-tice. Pokud totéž zkusíte se slovníkem, který obsahuje seznamy, dojde k velkolepé havárii.

```
>>> a_dict = {'a': [1, 2, 3], 'b': 4, 'c': 5}
>>> {value:key for key, value in a_dict.items()}
Traceback (most recent call last):
  File "<stdin>", line 1, in <module>
  File "<stdin>", line 1, in <dictcomp>
TypeError: unhashable type: 'list'
```

3.6. Přečtěte si

#### 3.5. Generátorová notace množin

Neměli bychom opomenout, že i syntaxe pro množiny zahrnuje generátorovou notaci. Pozoruhodně se podobá syntaxi pro generátorový zápis slovníků. Jediný rozdíl spočívá v tom, že množiny mají místo párů *klíč: hodnota* jen hodnoty.

```
>>> a_set = set(range(10))
>>> a_set
{0, 1, 2, 3, 4, 5, 6, 7, 8, 9}
>>> {x ** 2 for x in a_set} [1]
{0, 1, 4, 81, 64, 9, 16, 49, 25, 36}
>>> {x for x in a_set if x % 2 == 0} [2]
{0, 8, 2, 4, 6}
>>> {2**x for x in range(10)} [3]
{32, 1, 4, 2, 64, 8, 16, 128, 256, 512}
```

- Vstupem generátorové notace množiny může být množina. Tato generátorová notace množiny vyhodnocuje druhé mocniny prvků z množiny čísel od 0 do 9.
- Generátorové notace množin (stejně jako generátorové notace seznamů a slovníků) mohou obsahovat podmínku if, která vstupní položky před zařazením do výsledné množiny filtruje.
- Vstupem generátorové notace množiny ale nemusí být množina. Může jí být jakákoliv posloupnost.

#### 3.6. Přečtěte si

- modul os (standardní dokumentace) (http://docs.python.org/py3k/library/os.html)
- os Portable access to operating system specific features

  (přenositelné zpřístupnění specifických vlastností vázaných na operační systém)

  (http://www.doughellmann.com/PyMOTW/os/)
- modul os.path (standardní dokumentace)
   (http://docs.python.org/py3k/library/os.path.html)
- os.path Platform-independent manipulation of file names (platformově nezávislá manipulace se jmény souborů) (http://www.doughellmann.com/PyMOTW/ospath/)
- modul glob (standardní dokumentace) (http://docs.python.org/py3k/library/glob.html)
- **glob Filename pattern matching** (vyhledávání souborů podle vzorků) (http://www.doughellmann.com/PyMOTW/glob/)
- modul time (standardní dokumentace)
   (http://docs.python.org/py3k/library/time.html)

- **time Functions for manipulating clock time** (funkce pro manipulaci času hodin) (http://www.doughellmann.com/PyMOTW/time/)
- List comprehensions (standardní tutorial)
- Nested list comprehensions (vnořená generátorová notace seznamů; standardní tutorial)
- **Looping techniques** (techniky zápisu cyklů; standardní tutorial) (vše na http://docs.python.org/py3k/tutorial/datastructures.html)

"I'm telling you this 'cause you're one of my friends.

My alphabet starts where your alphabet ends!"

(Protože jedním z mých přátel jsi, tak říkám ti:

Má abeceda začíná tam, kde tvá končí!)

— Dr. Seuss, On Beyond Zebra!

# 4. Řetězce

## **4.** Řetězce — 105

- 4.1. Pár nudných věcí, kterým musíme rozumět dříve, než se budeme moci ponořit **107**
- 4.2. Unicode **109**
- 4.3. Ponořme se **111**
- 4.4. Formátovací řetězce 111
- 4.4.1. Složená jména oblastí 113
- 4.4.2. Specifikátory formátu 114
- 4.5. Další běžné metody řetězců 115
- 4.5.1. Vykrajování podřetězců 117
- 4.6. Řetězce vs. bajty 117
- 4.7. Závěrečná poznámka: Kódování znaků v pythonovském zdrojovém textu **120**
- 4.8. Přečtěte si **121**

4.1. Pár nudných věcí, kterým musíme rozumět dříve, než se budeme moci ponořit

# 4.1. Pár nudných věcí, kterým musíte rozumět dříve, než se budeme moci ponořit

Přemýšlí o tom jen málo lidí, ale text je neuvěřitelně komplikovaný. Začněme s abecedou. Obyvatelé Bougainville používají nejmenší abecedu na světě. Jejich abeceda Rotokas se skládá z pouhých 12 písmen: A, E, G, I, K, O, P, R, S, T, U a V. Na opačném konci spektra najdeme jazyky, jako jsou čínština, japonština a korejština, které používají tisíce znaků. Angličtina používá 26 písmen — nebo 52, pokud počítáte zvlášť malá a velká písmena — a k tomu pár interpunkčních znaků, jako jsou !@#\$%&.

Pokud v souvislosti s počítači mluvíte o "textu", pak pravděpodobně myslíte "znaky a symboly na počítačové obrazovce". Ale počítače nepracují se znaky a symboly. Pracují s bity a bajty. Každý kousek textu, který jste kdy spatřili na počítačové obrazovce, byl ve skutečnosti uložen v určitém znakovém kódování. Zhruba řečeno, kódování znaků zachycuje vztah mezi tím, co vidíte na obrazovce, a tím, co je ve skutečnosti uloženo v paměti počítače a na disku. Znakových kódování se používá velmi mnoho. Některá jsou optimalizována pro konkrétní jazyk, jakým je ruština, čínština nebo angličtina. Jiná kódování se mohou používat pro více jazyků.

Ve skutečnosti je to ještě mnohem komplikovanější. Řada znaků je společná pro více různých kódování, ale každé kódování může pro jejich uložení v paměti nebo na disku používat jinou posloupnost bajtů. Takže o znakovém kódování můžete uvažovat jako o dešifrovacím klíči. Kdykoliv vám někdo poskytne posloupnost bajtů — soubor, webovou stránku, cokoliv — a bude tvrdit, že to je "text", budete k úspěšnému dekódování bajtů na znaky chtít vědět také to, jaké kódování znaků bylo použito. Pokud vám někdo poskytne špatný klíč nebo vám dokonce nedá žádný, postaví vás před nevyhnutelný úkol rozlousknout kód sami. Může se stát, že při tom uděláte chybu a výsledek bude zmatený.

Vše, co jste si mysleli, že o řetězcích víte, je vám k ničemu. Určitě už jste viděli webové stránky s podivnými znaky podobnými otazníku na místech, kde měly být apostrofy. Obvykle to znamená, že autor stránky neuvedl jejich správné kódování a váš prohlížeč musel hádat. Výsledkem byla směs očekávaných a neočekávaných znaků. U anglického textu to vnímáme spíš jen rušivě, ale v jiných jazycích může být výsledek zcela nečitelný.

Každý význačný jazyk na světě má definováno své znakové kódování. Každé kódování znaků bylo kvůli rozdílům v jazycích optimalizováno pro konkrétní jazyk, protože paměťový a diskový prostor byly v minulosti velmi drahé. Mám tím na mysli to, že pro reprezentaci znaků jazyka používalo každé kódování stejný interval čísel (0–255). Pravděpodobně znáte například kódování ascii, které ukládá anglické znaky jako čísla z intervalu 0 až 127. (65 je velké "A", 97 je malé "a" atd.) Angličtina má velmi jednoduchou abecedu, která může být úplně vyjádřena méně než 128 čísly. Pro ty z vás, kteří umí počítat ve dvojkové soustavě, na to stačí 7 z 8 bitů v bajtu.

4.1. Pár nudných věcí, kterým musíme rozumět dříve, než se budeme moci ponořit

Západoevropské jazyky, jakou jsou francouzština, španělština a němčina, používají více znaků než angličtina. Přesněji řečeno, najdete v nich písmena kombinovaná s různými diakritickými značkami, jako například u znaku ñ používaného ve španělštině. Nejběžnějším kódováním je u těchto jazyků CP-1252. Označuje se také "windows-1252", protože se široce používá v Microsoft Windows. Kódování CP-1252 sdílí znaky v intervalu 0–127 s ASCII, ale rozpíná se i do intervalu 128–255. Nalezneme v něm takové znaky jako n-s-vlnkou (241), u-s-přehláskou (252) atd. Pořád ale jde o jednobajtové kódování. Největší možné číslo (255) se pořád vejde do jednoho bajtu.

Pak tu ale máme jazyky, jako je čínština, japonština a korejština, které používají takové množství znaků, že vyžadují vícebajtové znakové sady. Každý jejich "znak" je vyjádřen dvoubajtovým číslem v intervalu 0–65535. Ale u různých vícebajtových kódování se pořád setkáváme se stejným problémem, jako u různých jednobajtových kódování. Každé z nich používá stejná čísla pro vyjádření různých věcí. Používají jen širší interval čísel, protože musí vyjádřit mnohem více znaků.

Ve světě, který ještě nebyl propojen sítí a kde "text" bylo něco, co jste si sami napsali a příležitostně vytiskli, to většinou bylo přijatelné. "Prostého textu" jste ale moc nenašli. Zdrojové texty byly v ASCII a všichni ostatní používali textové procesory, které definovaly své vlastní (netextové) formáty. Ty si spolu s informacemi o stylu ukládaly také informaci o znakovém kódování. Lidé tyto dokumenty četli prostřednictvím stejných textových procesorů, jaké použil původní autor, takže všechno víceméně fungovalo.

Teď si představte vzestup globálních sítí s elektronickou poštou a s webem. Spousty "prostých textů" létají kolem zeměkoule — byly napsány na jednom počítači, přeneseny přes druhý a zobrazovány na třetím počítači. Počítače vidí jen čísla. Ale čísla mohou znamenat různé věci. Ach ne! Co budeme dělat? Takže systém musel být navržen tak, aby si každý "prostý text" s sebou nesl informaci o kódování. Připomeňme si, že jde o dešifrovací klíč, který převádí čísla srozumitelná počítači na znaky čitelné člověkem. Chybějící dešifrovací klíč vede ke zkreslenému textu, zmatkům nebo k něčemu horšímu.

Teď si představte, že bychom více kusů textu chtěli uložit na stejném místě, jako například ve stejné databázové tabulce uchovávající doručenou elektronickou poštu. Pro každý kousek musíme stejně uložit i znakové kódování, abychom text dokázali správně zobrazit. Myslíte si, že je to příliš tvrdý požadavek? Zkuste ve své e-mailové databázi vyhledávat. To znamená, že budete muset za běhu provádět převody mezi různými kódováními. Tady přestává legrace, že?

Teď si představte, že byste měli vícejazyčné dokumenty, ve kterých se znaky z různých jazyků vyskytu-jí vedle sebe, v tom samém dokumentu. (Nápověda: Programy, které se o to pokoušely, typicky používaly pomocné kódy (escape) pro přepínání "režimů". Prásk, teď jste v ruském režimu koi8-r, takže 241 znamená Я; bum, teď jste řeckém režimu pro Mac, takže 241 znamená ώ.) I *v takových* dokumentech byste samozřejmě chtěli umět vyhledávat.

Tak a teď plačte, protože vše, co jste si mysleli, že o řetězcích víte, je vám k ničemu. Nic takového jako "prostý text" neexistuje.

#### 4.2. Unicode

Vstupte do světa Unicode.

Unicode je systém navržený tak, aby bylo možné vyjádřit *každý* znak z *každého* jazyka. Každé písmeno, znak nebo ideogram se v Unicode vyjadřují jako 4bajtové číslo. Každé číslo vyjadřuje jedinečný znak, který se používá alespoň v jednom jazyce našeho světa. (Ne všechna čísla jsou využita, ale těch použitých je více než 65535. To znamená, že dva bajty nestačí.) Znaky, které se používají ve více jazycích, mají obvykle stejné číslo — pokud neexistuje dobrý etymologický důvod, aby tomu tak nebylo. Bez ohledu na další okolnosti je ale pro každý znak vyhrazeno jedno číslo a pro každé číslo jen jeden znak. Jedno číslo vždy znamená jedinou věc. Nepoužívají se žádné dříve zmíněné "režimy". U+0041 znamená vždy 'A', a to i v případech, pokud by váš jazyk 'A' nepoužíval.

Na první pohled to vypadá jako výborná myšlenka. Jedno kódování vládne všem. Více jazyků v jednom dokumentu. Už nikdy více "přepínání režimu" uprostřed textu jen kvůli přepnutí kódování. Ale už v této chvíli by vás měla napadnout zjevná otázka. Čtyři bajty? Pro každý jeden znak ? To vypadá jako hrozné plýtvání. Obzvlášť pro jazyky, jako jsou angličtina nebo španělština, které k vyjádření každého používaného znaku potřebují méně než jeden bajt (256 čísel). Ve skutečnosti je to plýtvání i pro jazyky založené na ideogramech (jako je čínština), které na jeden znak nepotřebují nikdy více než dva bajty.

Existuje kódování Unicode, které používá čtyři bajty na znak. Nazývá se UTF-32, podle počtu 32 bitů, což jsou 4 bajty. UTF-32 je přímočaré kódování. Každé číslo uložené na čtyřech bajtech se reprezentuje jako Unicode znak se stejným číslem. Má to své výhody. Nejdůležitější z nich je ta, že N-tý znak řetězce můžeme zpřístupnit v konstantním čase. N-tý znak totiž začíná na 4×N-tém bajtu. Ale má to i nevýhody. Ta nejzjevnější je, že na každý podělaný znak potřebujeme čtyři bajty.

Znaků je v Unicode velmi mnoho, ale ukazuje se, že většina lidí nepoužije nikdy žádný, který by ležel mimo prvních 65535. Takže tu máme další kódování Unicode. Nazývá se UTF-16 (protože 16 bitů jsou 2 bajty). V UTF-16 se každý znak s číslem z intervalu 0–65535 kóduje do dvou bajtů. Pokud opravdu potřebujeme vyjádřit zřídka používané Unicode znaky z "astrální roviny" (přesahující 65535), používá UTF-16 jisté špinavé triky. Nejzjevnější výhoda: UTF-16 je prostorově dvakrát efektivnější než UTF-32, protože pro uložení každého znaku potřebujeme jen dva bajty místo čtyř (s výjimkou těch, pro které to neplatí). A pokud budeme předpokládat, že řetězec neobsahuje žádné znaky z astrální roviny, můžeme snadno najít N-tý znak v konstantním čase. Ten předpoklad je docela dobrý, ale jen do doby, kdy to přestane platit.

Ale jak UTF-32, tak UTF-16 mají také méně zřejmé nevýhody. Různé počítačové systémy ukládají jednotlivé bajty různým způsobem. Tak například znak U+4E2D by mohl být v UTF-16 uložen buď jako 4E 2D nebo 2D 4E. Závisí to na tom, zda systém používá přístup big-endian (na menší adrese významnější bajt) nebo little-endian (na menší adrese méně významný bajt). (Pro UTF-32 existují dokonce ještě další možnosti uspořádání bajtů.) Pokud váš dokument nikdy neopustí váš počítač, je to v suchu — různé aplikace budou na stejném počítači používat stejné pořadí bajtů. Ale v okamžiku, kdy budete chtít dokument přenášet mezi systémy, třeba prostřednictvím webu nebo něčeho takového, budeme

potřebovat způsob, jak vyjádřit námi používané pořadí uložených bajtů. V opačném případě by cílový systém neuměl zjistit, zda dvoubajtová posloupnost 4E 2D znamená U+4E2D nebo U+2D4E.

Vícebajtová kódování Unicode pro vyřešení tohoto problému definují "Byte Order Mark" (značka pořadí bajtů; zkráceně BOM). Jde o speciální netisknutelný znak, který můžete vložit na začátek svého dokumentu, abyste dali najevo, v jakém pořadí jsou vaše bajty uvedeny. Pro UTF-16 je Byte Order Mark roven U+FEFF. Pokud obdržíte dokument v utf-16 začínající bajty FF FE, pak víte, že jde o jedno z možných pořadí bajtů. Pokud začíná bajty FE FF, pak víte, že pořadí bajtů je obrácené.

Přesto UTF-16 není zcela ideální. Platí to zvláště v případech, kdy používáte velké množství ASCII znaků. Když o tom popřemýšlíte, dokonce i čínské webové stránky budou obsahovat velké množství ASCII znaků — všechny ty značky a atributy, které obklopují tisknutelné čínské znaky. Pokud umíme najít N-tý znak v konstantním čase, je to fajn. Ale pořád tu máme nepříjemný problém s těmi znaky z astrální roviny. To znamená, že nemůžete zaručit, že každý znak je uložen přesně na dvou bajtech. Takže ve skutečnosti nemůžete N-tý znak najít v konstantním čase — pokud si ovšem neudržujete oddělený index. A mezi námi, ve světě se nachází ohromné množství ASCII textů...

Těmito otázkami se už zabývali jiní a přišli s řešením:

## UTF-8

UTF-8 je kódovací systém s proměnnou délkou. To znamená, že různé Unicode znaky zabírají různý počet bajtů. Pro ASCII znaky (A-Z atd.) používá UTF-8 jen jeden bajt na znak. Ve skutečnosti používá přesně tentýž bajt. Prvních 128 znaků (0–127) se v UTF-8 nedá rozlišit od ASCII. Znaky z "rozšířené latinky", jako jsou ñ a ö, budou zabírat dva bajty. (Bajty zde nevyjadřují kód z Unicode tak jednoduchým způsobem, jako je tomu u UTF-16. Je do toho zataženo trošku složitější hraní si s bity.) Čínské znaky jako  $\oplus$  zabírají tři bajty. Zřídka používané znaky z "astrální roviny" zabírají čtyři bajty.

**Nevýhody:** Protože každý znak zabírá různý počet bajtů, je nalezení N-tého znaku operací o složitosti O(N). To znamená, že čím je řetězec delší, tím déle budeme znak na určené pozici vyhledávat. Při kódování znaků na bajty a dekódování bajtů na znaky se musíme navíc zabývat dalšími manipulacemi s bity.

Výhody: Kódovaní běžných ASCII znaků je extrémně efektivní. Při kódování znaků z rozšířené latinky není horší než UTF-16. Pro čínské znaky je lepší než UTF-32. A díky jednoznačnému způsobu manipulace s bity zde neexistují žádné problémy s pořadím bajtů. (To mi musíte věřit, protože to tady nebudu matematicky zdůvodňovat.) Dokument kódovaný v UTF-8 používá na každém počítači přesně stejnou posloupnost bajtů.

#### 4.3. Ponořme se

V Pythonu 3 jsou všechny řetězce posloupnostmi znaků v Unicode. Nenajdeme zde nic takového jako pythonovský řetězec kódovaný v UTF-8 nebo pythonovský řetězec kódovaný v CP-1252. "Je tento řetězec v UTF-8?" — toto je nesmyslná otázka. UTF-8 představuje způsob kódování znaků do posloupnosti bajtů. Pokud chcete vzít řetězec a přeměnit jej na posloupnost bajtů v určitém znakovém kódování, může vám v tom Python 3 pomoci. Pokud chcete vzít posloupnost bajtů a přeměnit ji na řetězec, pomůže vám s tím Python 3 také. Ale bajty nejsou znaky. Bajty jsou prostě bajty. Znak je abstrakce. A řetězce jsou posloupnostmi těchto abstrakcí.

```
>>> s = '深入 Python' [1]
>>> len(s) [2]
9
>>> s[0] [3]
'深'
>>> s + ' 3' [4]
'深入 Python 3'
```

- [1] Řetězec vytvoříme tak, že posloupnost znaků uzavřeme do uvozovacích znaků. Pythonovské řetězce mohou být definovány uzavřením buď do apostrofů ('; single quotes) nebo do uvozovek ("; double quotes).
- Zabudovaná funkce len() vrací délku řetězce, tj. počet znaků. Je to stejná funkce, jakou používáme pro nalezení délky seznamu, n-tice, množiny nebo slovníku. Řetězec připomíná n-tici znaků.
- [3] S využitím indexové notace můžeme získat jednotlivé znaky řetězce, podobně jako u seznamu.
- [4] Operátor + provádí konkatenaci řetězců (zřetězení, spojení), stejně jako u seznamů.

#### 4.4. Formátovací řetězce

Podívejme se znovu na humansize.py:

# Řetězce definujeme uzavřením do apostrofů nebo do uvozovek.

```
Keyword arguments:
size -- file size in bytes
a_kilobyte_is_1024_bytes -- if True (default), use multiples of 1024
                             if False, use multiples of 1000
Returns: string
                                                                           [3]
if size < 0:
    raise ValueError('number must be non-negative')
                                                                           [4]
multiple = 1024 if a_kilobyte_is_1024_bytes else 1000
for suffix in SUFFIXES[multiple]:
    size /= multiple
    if size < multiple:</pre>
        return '{0:.1f} {1}'.format(size, suffix)
                                                                           [5]
raise ValueError('number too large')
```

- [1] 'KB', 'MB', 'GB'... to všechno jsou řetězce.
- Dokumentační řetězce funkcí jsou řetězce. Tento dokumentační řetězec se rozprostírá přes několik řádků. Proto je použita trojice apostrofů na začátku i na konci řetězce.
- [3] Tato trojice apostrofů ukončuje dokumentační řetězec.
- Zde máme další řetězec, který předáváme objektu výjimky jako lidsky čitelnou podobu chybového hlášení.
- [5] A tady máme... hej, co je sakra tohle?

Python 3 podporuje formátování hodnot do řetězců. Možné jsou i velmi komplikované výrazy, ale nejzákladnější použití spočívá ve vložení hodnoty do řetězce s jednou oblastí náhrad.

```
>>> username = 'mark'
>>> password = 'PapayaWhip' [1]
>>> "{0}'s password is {1}".format(username, password) [2]
"mark's password is PapayaWhip"
```

- [1] Ne, moje heslo doopravdy nezní PapayaWhip.
- Tady se děje spousta věcí. Zaprvé, voláme zde metodu řetězcového literálu. Řetězce jsou objekty a objekty mají metody. Zadruhé, vyhodnocením celého výrazu vznikne řetězec. Zatřetí, {0} a {1} jsou *oblasti náhrad* (replacement fields), do kterých budou dosazeny argumenty předané metodě format().

#### 4.4.1. Složená jména oblastí

Předchozí příklad ukazoval nejjednodušší případ, kdy jsou v oblastech náhrad použita pouze celá čísla. Celá čísla se v oblastech náhrad považují za indexy do seznamu argumentů metody format(). To znamená, že {0} je nahrazena prvním argumentem (v našem případě username), {1} je nahrazena druhým argumentem (password) atd. Můžeme použít tolik pozičních indexů, kolik máme argumentů. A argumentů můžeme mít tolik, kolik chceme. Ale oblasti náhrad jsou ještě mnohem mocnější.

```
>>> import humansize
>>> si_suffixes = humansize.SUFFIXES[1000] [1]
>>> si_suffixes
['KB', 'MB', 'GB', 'TB', 'PB', 'EB', 'ZB', 'YB']
>>> '1000{0[0]} = 1{0[1]}'.format(si_suffixes) [2]
'1000KB = 1MB'
```

- Místo volání funkce z modulu humansize si půjčíme jednu z datových struktur, která je v něm definována: seznam přípon jednotek "SI" (mocniny čísla 1000).
- Vypadá to složitě, ale není to složité. {0} se odkazuje na první argument předaný metodě format(), tedy na si\_suffixes. Ale si\_suffixes má podobu seznamu. Takže {0[0]} odkazuje na první položku seznamu, který je prvním argumentem předaným metodě format(): 'KB'. Podobně {0[1]} odkazuje na druhou položku stejného seznamu: 'MB'. Všechno vně složených závorek včetně 1000, rovnítka a mezer zůstává nedotčeno. Konečným výsledkem je řetězec '1000KB = 1MB'.

## {0} je nahrazena prvním argumentem metody format().{1} je nahrazena druhým argumentem.

Tento příklad ukazuje, že specifikátory formátu mohou pro zpřístupnění položek a vlastností datových struktur používat (téměř) pythonovskou syntaxi. Říká se tomu složená jména oblastí (compound field names).

Funkční jsou následující složená jména oblastí:

- Předání seznamu a zpřístupnění položky seznamu indexem (jako v předchozím příkladu).
- Předání slovníku a zpřístupnění jeho hodnoty uvedením klíče.
- Předání modulu a zpřístupnění jeho proměnných a funkcí jménem.
- Předání instance třídy a zpřístupnění jejích vlastností a metod jménem.
- Libovolná kombinace výše uvedeného.

Abych vás ohromil, tady máte příklad, který vše kombinuje:

```
>>> import humansize
>>> import sys
>>> '1MB = 1000{0.modules[humansize].SUFFIXES[1000][0]}'.format(sys)
'1MB = 1000KB'
```

A teď si popíšeme, jak to funguje:

- Modul sys v sobě udržuje informace o momentálně běžící pythonovské instanci. Protože
  jsme provedli jeho import, můžeme celý modul sys předat jako argument metody format().
  Takže pole náhrad {0} odkazuje na modul sys.
- sys.modules je slovník všech modulů, které byly importovány touto instancí Pythonu. V roli klíčů vystupují jména modulů uvedená jako řetězce. Hodnotami jsou vlastní objekty modulů. Takže oblast náhrad {0.modules} odkazuje na slovník importovaných modulů.
- sys.modules['humansize'] odkazuje na modul humansize module, který jsme právě importovali. Oblast náhrad {0.modules[humansize]} odkazuje na modul humansize. Povšimněte si zde malého rozdílu v syntaxi. Ve skutečném pythonovském kódu jsou klíči slovníku sys.modules řetězce. Abychom se jimi mohli odkázat, musíme jméno modulu uzavřít do apostrofů (jako například 'humansize'). Jenže uvnitř oblasti náhrad apostrofy kolem slovníkového klíče vynecháváme (tj. humansize). Citujme PEP 3101: Advanced String Formatting, "Pravidla pro předávání klíčů položek jsou velmi jednoduchá. Pokud klíč začíná číslicí, bude chápán jako číslo. V ostatních případech bude použit jako řetězec."
- sys.modules['humansize'].SUFFIXES je slovník definovaný na začátku modulu humansize. Odkazuje se na něj oblast náhrad {0.modules[humansize].SUFFIXES}.
- sys.modules['humansize'].SUFFIXES[1000] je seznam přípon jednotek si: ['KB', 'MB', 'GB', 'TB', 'PB', 'EB', 'ZB', 'YB']. Takže oblast náhrad {0.modules[humansize].SUFFIXES[1000]} se odkazuje na zmíněný seznam.
- sys.modules['humansize'].SUFFIXES[1000][0] je první položkou seznamu přípon jednotek si: 'KB'. Z toho plyne, že celá oblast náhrad {0.modules[humansize].SUFFIXES[1000][0]} je nahrazena dvojznakovým řetězcem KB.

### 4.4.2. Specifikátory formátu

Ale počkat! Ono je toho ještě víc! Podívejme se ještě jednou na tento divný řádek kódu ze souboru humansize.py:

```
if size < multiple:
    return '{0:.1f} {1}'.format(size, suffix)</pre>
```

{1} je nahrazena druhým argumentem předaným metodě format(), a tím je suffix. Ale co znamená {0:.1f}? Jde o dvě věci: význam {0} už znáte, ale význam :.1f ještě ne. Druhá část (dvojtečka a to, co následuje) definuje specifikátor formátu (format specifier), který upřesňuje, jak má být dosazovaná hodnota formátována.

> Specifikátory formátu vám dovolí upravit výsledný text do řady užitečných podob — podobně jako funkce printf() v jazyce C. Můžete přidat vycpávku z nul nebo z mezer, zarovnat řetězce, řídit počet desetinných míst a dokonce konvertovat čísla do šestnáctkové soustavy.

Dvojtečka (:) uvnitř oblasti náhrad označuje začátek specifikátoru formátu. Specifikátor ".1" znamená "zaokrouhli na nejbližší desetiny" (tj. zobraz jen jedno místo za desetinnou tečkou). Specifikátor "f" znamená "číslo s pevnou řádovou čárkou" (jako opak k exponenciálnímu zápisu nebo k jiným způsobům reprezentace čísla). Takže pokud má size hodnotu 698.24 a suffix hodnotu 'GB', pak naformátovaný řetězec bude mít podobu '698.2 GB'. Hodnota 698.24 bude zaokrouhlena na jedno desetinné místo a hodnota suffix bude připojena za číslo.

```
>>> '{0:.1f} {1}'.format(698.24, 'GB')
'698.2 GB'
```

Detaily kolem specifikátorů formátů naleznete v oficiální pythonovské dokumentaci, v části <u>Format Specification Mini-Language</u>.

#### 4.5. Další běžné metody řetězců

S řetězci můžeme, kromě formátování, provádět řadu dalších užitečných kousků.

```
>>> s = '''Finished files are the re-
                                          [1]
... sult of years of scientif-
... ic study combined with the
... experience of years.'''
>>> s.splitlines()
                                          [2]
['Finished files are the re-',
 'sult of years of scientif-',
 'ic study combined with the',
 'experience of years.']
>>> print(s.lower())
                                          [3]
finished files are the re-
sult of years of scientif-
ic study combined with the
experience of years.
>>> s.lower().count('f')
                                          [4]
```

V interaktivním pythonovském shellu můžeme zadat i víceřádkové řetězce. Pokud zahájíme víceřádkový řetězec uvedením trojitého uvozovacího znaku, můžeme jednoduše stisknout ENTER a interaktivní shell nás vyzve k zadání pokračování řetězce. Zapsáním uzavírací trojice uvozovacího znaku označíme konec řetězce. Po následném stisku ENTER se příkaz provede.

- (V tomto případě bude řetězec přiřazen do proměnné s).
- Metoda splitlines() přebírá jeden víceřádkový řetězec a vrací seznam řetězců, ve kterém [2] každá položka reprezentuje jeden řádek z originálu. Všimněte si, že znaky konců řádků nejsou do jednotlivých řádků zahrnuty.
- Metoda lower() převádí celý řetězec na malá písmena. (Podobně zase metoda upper() [3] převádí řetězec na velká písmena.)
- Metoda count () vrací počet výskytů zadaného podřetězce. Ano, v uvedené větě je opravdu [4] šest "f"!

Vezměme si další běžný případ. Dejme tomu, že máme seznam dvojic klíč-hodnota ve tvaru key1=value1&key2=value2 a my bychom je chtěli rozdělit a vytvořit z nich slovník v podobě {key1: value1, key2: value2}.

```
>>> query = 'user=pilgrim&database=master&password=PapayaWhip'
>>> a_list = query.split('&')
                                                                           [1]
>>> a_list
['user=pilgrim', 'database=master', 'password=PapayaWhip']
>>> a_list_of_lists = [v.split('=', 1) for v in a_list if '=' in v]
                                                                           [2]
>>> a_list_of_lists
[['user', 'pilgrim'], ['database', 'master'], ['password', 'PapayaWhip']]
>>> a_dict = dict(a_list_of_lists)
                                                                           [3]
>>> a_dict
{'password': 'PapayaWhip', 'user': 'pilgrim', 'database': 'master'}
```

- [1] Řetězcové metodě split() jsme zadali jeden argument, hodnotu oddělovače. Metoda v místech zadaného oddělovače rozdělí řetězec na seznam řetězců. Zde je jako oddělovač použit znak ampersand, ale může to být cokoliv.
- Teď máme seznam řetězců, kde každý obsahuje klíč, následuje znak rovnítka a poté hodnota. [2] K průchodu tímto seznamem a k rozdělení každého řetězce na dva v místě rovnítka můžeme použít generátorovou notaci seznamu (list comprehension). Druhý nepovinný argument metody split() říká, kolikrát chceme dělení řetězce provést. Hodnota 1 znamená "rozdělit jen jednou", takže metoda split() vrátí dvouprvkový seznam. (Hodnota by teoreticky mohla také obsahovat znak rovnítka. Pokud bychom použili pouze 'key=value=foo'.split('='), dostali bychom seznam s třemi prvky ['key', 'value', 'foo'].)
- A nakonec necháme Pythonu převést tento seznam seznamů na slovník jednoduše tím, že jej [3] předáme funkci dict().
- Předchozí příklad se hodně podobá získávání parametrů dotazu uvedeného v URL, ale rozklad > opravdu používaných URL je ve skutečnosti složitější. Pokud se máte zabývat parametry dotazu v URL, pak pro vás bude mnohem lepší, když použijete funkci urllib.parse.parse\_qs(). Ta je schopná zvládnout i některé ne příliš zřejmé hraniční případy.

#### 4.5.1. Vykrajování podřetězců

Jakmile máme vytvořen řetězec, můžeme získat jakoukoliv jeho část v podobě nového řetězce. Anglicky se tomu říká "slicing the string", což můžeme přeložit jako "vykrajování z řetězce" nebo "výřez z řetězce". Vykrajování podřetězců funguje naprosto stejně jako vykrajování podseznamů. Ono to dává smysl, protože řetězce jsou prosté posloupnosti znaků.

- Část řetězce, výřez (slice), můžeme získat zadáním dvou indexů. Návratovou hodnotou je nový řetězec, který obsahuje všechny znaky (při zachování pořadí) počínaje prvním indexem výřezu a konče znakem před druhým indexem.
- Při vykrajování z řetězců můžeme rovněž použít záporné indexy výřezu, stejně jako u seznamu.
- [3] Řetězce se indexují od nuly, takže zápis a\_string[0:2] vrací první dva znaky řetězce počínaje znakem a\_string[0] až po a\_string[2] vyjma (ten už ve výsledku nebude).
- Pokud je levý index výřezu roven nule, můžeme nulu vynechat. Bude dosazena implicitně. Takže zápis a\_string[:18] je stejný jako a\_string[0:18]. Počáteční nula se dosadí jako implicitní hodnota.
- Podobně, pokud by pravý index výřezu měl mít hodnotu rovnou délce řetězce, můžeme jej vynechat. Takže a\_string[18:] je totéž jako a\_string[18:44], protože v tomto řetězci se nachází 44 znaků. A najdeme zde opět potěšitelnou symetrii. Pro tento 44znakový řetězec vrací zápis a\_string[:18] prvních 18 znaků a a\_string[18:] vrací vše kromě prvních 18 znaků. Obecně platí, že a\_string[:n] vždy vrátí prvních n znaků a a\_string[n:] vrátí zbytek nezávisle na délce řetězce.

### 4.6. Řetězce vs. bajty

Bajty jsou bajty, znaky jsou abstrakce. Neměnitelná posloupnost Unicode znaků se nazývá *řetězec*. Neměnitelná posloupnost čísel z intervalu 0–255 se nazývá objekt typu *bytes*.

```
>>> by = b'abcd\x65'
                                   [1]
>>> by
b'abcde'
>>> type(by)
                                   [2]
<class 'bytes'>
>>> len(by)
                                   [3]
>>> by += b'\xff'
                                   [4]
>>> by
b'abcde\xff'
>>> len(by)
                                   [5]
>>> by[0]
                                   [6]
97
>>> by[0] = 102
Traceback (most recent call last):
  File "<stdin>", line 1, in <module>
```

TypeError: 'bytes' object does not support item assignment

- Objekt typu bytes definujeme použitím b'', tedy syntaxe pro "bajtový literál" . Každý bajt uvnitř bajtového literálu může být buď ASCII znak, nebo zakódované šestnáctkové číslo od \x00 do \xff (0–255).
- [2] Bajtový objekt je typu bytes.
- Délku obsahu objektu typu bytes můžeme získat zabudovanou funkcí len(), tedy stejně jako u seznamů a řetězců.
- A stejně jako u seznamů a řetězců, pro konkatenaci (zřetězení, spojení) objektů typu bytes můžeme použít operátor +. Výsledkem je nový objekt typu bytes.
- [5] Zřetězením 5bajtového objektu a jednobajtového objektu typu bytes vznikne 6bajtový objekt typu bytes.
- [6] Stejně jako u seznamů a řetězců můžeme jednotlivé bajty z objektu typu bytes zpřístupnit indexovou notací. Položkami řetězců jsou znaky, položkami objektu typu bytes jsou čísla. Konkrétně jsou to celá čísla z intervalu 0–255.
- Objekt typu bytes je neměnitelný (immutable). Jednotlivým bajtům nemůžeme nic přiřadit. Pokud potřebujete měnit jednotlivé bajty, můžete buď použít výřezy (slicing) a operátor konkatenace (fungují stejně jako u řetězců), nebo můžete objekt typu bytes konvertovat na objekt typu bytearray.

```
>>> by = b'abcd\x65'
>>> barr = bytearray(by) [1]
>>> barr
bytearray(b'abcde')
>>> len(barr) [2]
5
>>> barr[0] = 102 [3]
>>> barr
bytearray(b'fbcde')
```

- Pro konverzi objektu typu bytes na objekt měnitelného typu bytearray použijte zabudovanou funkci bytearray().
- Všechny metody a operace, které můžete provádět s objektem typu bytes, můžete provádět i s objektem typu bytearray.
- Jedním z rozdílů je to, že objektu typu bytearray můžete při využití indexové notace přiřazovat hodnoty jednotlivým bajtům. Přiřazovaná hodnota musí být celé číslo v intervalu 0–255.

Jednou z věcí, které nikdy nemůžete udělat, je míchání bajtů s řetězci.

- [1] Bajty a řetězce nelze spojovat. Jsou různých datových typů.
- Nemůžete spočítat výskyt bajtů v řetězci, protože v řetězci žádné bajty nejsou. Řetězec je posloupností znaků. Možná jste měli na mysli "spočítej výskyty řetězce, který bychom získali po dekódování této posloupnosti bajtů při použití určitého znakového kódování"? V pořádku, ale budete to muset zapsat explicitně. Python 3 neprovádí implicitní konverzi bajtů na řetězce a řetězců na bajty.
- Překvapivou shodou okolností tento řádek kódu říká "spočítej výskyty řetězce, který bychom získali po dekódování této posloupnosti bajtů při určitém znakovém kódování".

A tady máme spojení mezi řetězci a bajty: objekt typu bytes má metodu decode(), která přebírá znakové kódování a vrací řetězce. A řetězce zase mají metodu encode(), která přebírá znakové kódování a vrací objekt typu bytes. V předchozím případě bylo dekódování poměrně přímočaré — co se týká konverze posloupnosti bajtů v kódování ASCII na řetězec znaků. Ale stejný postup funguje pro libovolné kódování, které odpovídá znakům řetězce. Platí to dokonce i pro historická (ne Unicode) kódování.

```
>>> a_string = '深入 Python' [1]
>>> len(a_string)
9
>>> by = a_string.encode('utf-8') [2]
>>> by
b'\xe6\xb7\xb1\xe5\x85\xa5 Python'
```

```
>>> len(by)
13
>>> by = a_string.encode('gb18030') [3]
b'\xc9\xee\xc8\xeb Python'
>>> len(by)
>>> by = a_string.encode('big5')
                                      [4]
>>> by
b'\xb2\\xa4J Python'
>>> len(by)
>>> roundtrip = by.decode('big5')
                                      [5]
>>> roundtrip
'深入 Python'
>>> a_string == roundtrip
True
```

- [1] Toto je řetězec. Má devět znaků.
- Toto je objekt typu bytes. Obsahuje 13 bajtů. Posloupnost bajtů vznikla zakódováním řetězce a\_string do UTF-8.
- Tento objekt typu bytes obsahuje 11 bajtů. Vznikl zakódováním řetězce a\_string v kódování GB18030.
- Toto je objekt typu bytes. Má 11 bajtů. Jde o zcela jinou posloupnost bajtů, která vznikla zakódováním řetězce a\_string v kódování Big5.
- Toto je řetězec. Má devět znaků. Jde o posloupnost znaků, kterou jsme získali, když jsme objekt by dekódovali algoritmem Big5. Shoduje se s původním řetězcem.

#### 4.7. Závěrečná poznámka: Kódování znaků v pythonovském zdrojovém textu

Python 3 předpokládá, že váš zdrojový kód — tj. každý soubor s příponou .py — je uložen v kódování UTF-8.

V Pythonu 2 bylo u souborů s příponou .py výchozím kódováním ASCII. V Pythonu 3 je výchozím kódováním UTF-8.

Pokud byste ve svých zdrojových textech chtěli používat jiné kódování, můžete na první řádek souboru vložit deklaraci použítého kódování. Tato deklarace říká, že soubor .py používá kódování windows-1252:

```
# -*- coding: windows-1252 -*-
```

Z technického pohledu můžete deklaraci použitého kódování umístit i na druhý řádek. Na prvním řádku se může vyskytovat UNIXovský magický příkazový komentář (hash-bang command).

```
#!/usr/bin/python3
# -*- coding: windows-1252 -*-
```

Více informací naleznete v PEP 263: Defining Python Source Code Encodings. (www.python.org/dev/peps/pep-0263/)

#### 4.8. Přečtěte si

O Unicode v jazyce Python:

- Python Unicode HOWTO
  - (http://docs.python.org/py3k/howto/unicode.html)
- What's New In Python 3: Text vs. Data Instead Of Unicode vs. 8-bit (http://docs.python.org/release/3.0.1/whatsnew/3.0.html)
- PEP 261 vysvětluje, jak Python zachází s astrálními znaky mimo Základní vícejazyčnou rovinu (Basic Multilingual Plane), tj. se znaky s ordinální hodnotou větší než 65535. (www.python.org/dev/peps/pep-0261/)

#### O Unicode obecně:

 The Absolute Minimum Every Software Developer Absolutely, Positively Must Know About Unicode and Character Sets (No Excuses!)

(www.joelonsoftware.com/articles/Unicode.html)

- On the Goodness of Unicode
  - (www.tbray.org/ongoing/When/200x/2003/04/06/Unicode)
- On Character Strings
  - (www.tbray.org/ongoing/When/200x/2003/04/13/Strings)
- Characters vs. Bytes
  - (www.tbray.org/ongoing/When/200x/2003/04/26/UTF)

O znakovém kódování v jiných formátech:

- Character encoding in XML
  - (http://feedparser.org/docs/character-encoding.html)
- Character encoding in HTML
  - (http://blog.whatwg.org/the-road-to-html-5-character-encoding)

### O řetězcích a jejich formátování:

- string Common string operations
- Format String Syntax
- Format Specification Mini-Language
  (vše na http://docs.python.org/py3k/library/string.html)
- PEP 3101: Advanced String Formatting (www.python.org/dev/peps/pep-3101/)

"Some people, when confronted with a problem, think "I know, I'll use regular expressions."

Now they have two problems. "

(Když se někteří lidé setkají s problémem, pomyslí si: "Já vím! Použiji regulární výrazy."

V tom okamžiku mají problémy dva.)

- Jamie Zawinski

# 5. Regulární výrazy

5.7.

| э.     | Regulariii vyrazy — 125                  |
|--------|--|
| 5.1.   | Ponořme se — 125                         |
| 5.2.   | Případová studie: Adresa ulice — 129     |
| 5.3.   | Případová studie: Římská čísla — 128     |
| 5.3.1. | Kontrola tisícovek — 128                 |
| 5.3.2. | Kontrola stovek — 129                    |
| 5.4.   | Využití syntaxe {n,m} — 131              |
| 5.4.1. | Kontrola desítek a jednotek — <b>132</b> |
| 5.5.   | Víceslovné regulární výrazy — <b>134</b> |
| 5.6.   | Případová studie:                        |
|        | Analýza telefonních čísel — <b>136</b>   |

Shrnutí — 141

- 5.1. Ponořme se
- 5.2. Případová studie: Adresa ulice

#### 5.1. Ponořme se

Získávání malých kousků textu z velkých bloků textu představuje výzvu. Pythonovské řetězcové objekty poskytují metody pro vyhledávání a náhrady: index(), find(), split(), count(), replace() atd. Ale použití těchto metod je omezeno na nejjednodušší případy. Tak například metoda index() hledá jediný, pevně zadaný řetězec a vyhledávání je vždy citlivé na velikost písmen. Pokud chceme řetězec s vyhledat bez ohledu na velikost písmen, musíme zavolat s.lower() (převod na malá písmena) nebo s.upper() (převod na velká písmena) a zajistit odpovídající převod prohledávaných řetězců. Metody replace() and split() mají stejná omezení.

Pokud svého cíle můžete dosáhnout metodami řetězcového objektu, měli byste je použít. Jsou rychlé, jednoduché a snadno čitelné. O rychlém, jednoduchém a čitelném kódu bychom se mohli bavit ještě dlouho. Ale pokud se přistihnete, že používáte velké množství různých řetězcových funkcí a příkazů if, abyste zvládli speciální případy, nebo pokud musíte kombinovat volání split() a join(), abyste řetězce rozsekávali na kousky a zase je slepovali, v takových případech může být vhodné přejít k regulárním výrazům.

Regulární výrazy představují mocný a (většinou) standardizovaný způsob vyhledávání, náhrad a rozkladu textu se složitými vzorci znaků. Syntaxe regulárních výrazů je sice obtížná a nepodobná normálnímu kódu, ale výsledek může být nakonec *čitelnější* než řešení používající mnoho řetězcových funkcí. Existují dokonce způsoby, jak lze do regulárních výrazů vkládat komentáře. To znamená, že jejich součástí může být podrobná dokumentace.

Pokud už jste regulární výrazy používali v jiných jazycích (jako jsou Perl, JavaScript nebo PHP), bude vám pythonovská syntaxe připadat důvěrně známá. Abyste získali přehled o dostupných funkcích a jejich argumentech, přečtěte si shrnutí v dokumentaci modulu re.

#### 5.2. Případová studie: Adresa ulice

Následující série příkladů byla inspirována problémem, který jsem před několika lety řešil v práci. Potřeboval jsem vyčistit a standardizovat adresy ulic, které byly vyexportované z původního systému, ještě před jejich importem do nového systému. (Vidíte? Já si ty věci jen tak nevymýšlím. Ony jsou ve skutečnosti užitečné.) Tento příklad ukazuje, jak jsem na to šel.

```
>>> s = '100 NORTH MAIN ROAD'
>>> s.replace('ROAD', 'RD.') [1]
'100 NORTH MAIN RD.'
>>> s = '100 NORTH BROAD ROAD'
>>> s.replace('ROAD', 'RD.') [2]
'100 NORTH BRD. RD.'
>>> s[:-4] + s[-4:].replace('ROAD', 'RD.') [3]
'100 NORTH BROAD RD.'
```

```
>>> import re [4]
>>> re.sub('ROAD$', 'RD.', s) [5]
'100 NORTH BROAD RD.'
```

- Mým cílem bylo standardizovat adresu ulice tak, aby se 'ROAD' vždycky zkrátilo na 'RD.'.

  Na první pohled jsem si myslel, že je to dost jednoduché, takže prostě použiji řetězcovou metodu replace(). Koneckonců, všechna data už byla převedena na velká písmena, takže problém citlivosti na velikost písmen odpadl. A vyhledávaný řetězec 'ROAD' je konstantní. A v tomto klamně jednoduchém případě s.replace() samozřejmě funguje.
- Život je ale, naneštěstí, plný protipříkladů a na jeden takový jsem hned narazil. Problém následující adresy spočívá v dvojím výskytu 'ROAD'. Jednou jde o část jména ulice 'BROAD' a jednou o samostatné slovo. Metoda replace() tyto dva výskyty najde a slepě je oba nahradí. A já jen pozoruji, jak se mé adresy kazí.
- Abychom problém adres s více než jedním výskytem podřetězce 'ROAD' vyřešili, můžeme se uchýlit k něčemu takovému: hledání a náhradu 'ROAD' budeme provádět jen v posledních čtyřech znacích adresy (s[-4:]) a zbytek řetězce ponecháme beze změny (s[:-4]). Ale už sami vidíte, že to začíná být těžkopádné. Například už jen to, že řešení závisí na délce řetězce, který nahrazujeme. (Pokud bychom chtěli nahradit 'STREET' zkratkou 'ST.', museli bychom napsat s[:-6] a s[-6:].replace(...).) Líbilo by se vám, kdybyste se k tomu museli za šest měsíců vrátit a hledat chybu? Jsem si jistý, že ne.
- Nastal čas, abychom přešli k regulárním výrazům. Veškerá funkčnost spojená s regulárními výrazy se v Pythonu nachází v modulu re.
- Podívejme se na první parametr: 'ROAD\$'. Jde o jednoduchý regulární výraz, ke kterému 'ROAD' pasuje jen v případě, když se vyskytne na konci řetězce. Znak \$ vyjadřuje "konec řetězce". (Existuje také odpovídající znak, stříška ^, která znamená "začátek řetězce".) Voláním funkce re.sub() hledáme v řetězci s regulární výraz 'ROAD\$' a nahradíme jej řetězcem 'RD.'. Nalezne se tím ROAD na konci řetězce s, ale nenalezne se podřetězec ROAD, který je součástí slova BROAD. To se totiž nachází uprostřed řetězce s.

# odpovídá začátku řetězce.sodpovídá konci řetězce.

Pokračujme v mém příběhu o čištění adres. Brzy jsem zjistil, že předchozí řešení, kdy 'ROAD' lícuje s koncem adresy, není dost dobré. Ne všechny adresy totiž obsahují údaj, že se jedná o ulici. Některé adresy jednoduše končí jménem ulice. Většinou to vyšlo, ale pokud by se ulice jmenovala 'BROAD', pak by regulární výraz pasoval na 'ROAD', které se nachází na konci řetězce, ale je součástí slova 'BROAD'. A to není to, co bych potřeboval.

```
>>> s = '100 BROAD'
>>> re.sub('ROAD$', 'RD.', s)
'100 BRD.'
>>> re.sub('\\bROAD$', 'RD.', s)
                                           [1]
'100 BROAD'
>>> re.sub(r'\bROAD$', 'RD.', s)
                                           [2]
'100 BROAD'
>>> s = '100 BROAD ROAD APT. 3'
>>> re.sub(r'\bROAD$', 'RD.', s)
                                           [3]
'100 BROAD ROAD APT. 3'
>>> re.sub(r'\bROAD\b', 'RD.', s)
                                           [4]
'100 BROAD RD. APT 3'
```

- To, co jsem opravdu chtěl, bylo vyhledání podřetězce 'ROAD', který se nacházel na konci řetězce a navíc tvořil samostatné slovo (a ne část nějakého delšího slova). V regulárním výrazu to vyjádříme zápisem \b, který má význam "hranice slova se musí vyskytnout právě tady" (b jako boundary). V Pythonu je to komplikované skutečností, že znak '\' musíme v řetězci vyjádřit zvláštním způsobem. (Tento znak se anglicky nazývá též "escape character" a používá se pro zápis zvláštních posloupností. Má tedy zvláštní význam. Pokud jej chceme použít v prostém významu, musíme jej také zapsat jako "escape" sekvenci. Prakticky to znamená, že jej musíme zdvojit.) Někdy se to označuje jako mor zpětných lomítek. Je to jeden z důvodů, proč se psaní regulárních výrazů v Perlu jeví snadnější než v jazyce Python. Negativní stránkou Perlu je míchání vlastních regulárních výrazů a odlišností při jejich zápisu. Takže pokud se někde projevuje chyba, dá se někdy obtížně odhadnout, zda je to chyba syntaxe nebo chyba ve vašem regulárním výrazu.
- Mor zpětných lomítek můžeme obejít tím, že uvedením písmene r před uvozovacím znakem použijeme to, čemu se říká surový řetězec (ve smyslu přírodní, nezpracovaný; anglicky raw string). Tím Pythonu říkáme, že se v tomto řetězci nepoužívají speciální posloupnosti (escape sequence). Zápis '\t' vyjadřuje tabulační znak, ale r'\t' se opravdu chápe jako znak \ následovaný písmenem t. Pokud budete pracovat s regulárními výrazy, doporučuji vám vždy používat surové řetězce. V opačném případě dospějete velmi rychle k velkým zmatkům. (Regulární výrazy jsou už i tak dost matoucí.)
- Ach jo. Naneštěstí jsem brzy našel případy, které odporovaly mému přístupu. V tomto případě obsahovala adresa slovo 'ROAD' jako samostatné slovo, ale to se nenacházelo na konci. Za označením ulice se totiž nacházelo číslo bytu. A protože se 'ROAD' nenacházelo na úplném konci řetězce, nepasovalo to s regulárním výrazem, takže celé volání re.sub() neprovedlo vůbec žádnou náhradu a vrátil se původní řetězec, což nebylo to, co jsem chtěl.
- Abych tento problém vyřešil, odstranil jsem znak \$ a přidal jsem další \b. Teď už regulární výraz můžeme číst "vyhledej samostatné slovo 'ROAD' kdekoliv v řetězci", ať už je to na konci, na začátku nebo někde uprostřed.

#### 5.3. Případová studie: Římská čísla

Římská čísla už jste určitě viděli, i když jste je možná nerozpoznali. Mohli jste je vidět u starých filmů nebo televizních pořadů jako "Copyright MCMXLVI" místo "Copyright 1946", nebo na stěnách knihoven a univerzit ("založeno MDCCCLXXXVIII" místo "založeno 1888"). Mohli jste je vidět v různých číslováních a odkazech na literaturu. Jde o systém zápisu čísel, který se opravdu datuje do dob starého římského impéria (proto ten název).

U římských čísel se používá sedm znaků, které se opakují a kombinují různými způsoby, aby vyjádřily číselnou hodnotu.

I = 1

V = 5

X = 10

L = 50

C = 100

D = 500

M = 1000

Následují základní pravidla pro konstrukci římských čísel:

- V některých případech se znaky sčítají. I je 1, II je rovno 2 a III znamená 3. VI se rovná 6 (doslova "5 a 1"), VII je 7 a VIII je 8.
- Desítkové znaky (I, X, C a M) se mohou opakovat nanejvýš třikrát. Hodnotu 4 musíme vyjádřit odečtením od dalšího vyššího pětkového znaku. Hodnotu 4 nemůžeme zapsat jako IIII. Místo toho ji musíme zapsat jako IV ("o 1 méně než 5"). 40 se zapisuje jako XL ("o 10 méně než 50"), 41 jako XLI, 42 jako XLII, 43 jako XLIII a následuje 44 jako XLIV ("o 10 méně než 50 a k tomu o 1 méně než 5").
- Někdy znaky vyjadřují... opak sčítání. Když některé znaky umístíme před jiné, provádíme odčítání od konečné hodnoty. Například hodnotu 9 musíme vyjádřit odečtením od dalšího vyššího desítkového znaku: 8 zapíšeme jako VIII, ale 9 zapíšeme IX ("o 1 méně než 10") a ne jako VIIII (protože znak I nemůžeme opakovat čtyřikrát). 90 je XC, 900 je CM.
- Pětkové znaky se nesmí opakovat. 10 se vždy zapisuje jako X a nikdy jako VV. 100 je vždy C, nikdy LL.
- Římská čísla se čtou zleva doprava, takže na pořadí znaků velmi záleží. DC znamená 600, ale CD je úplně jiné číslo (400, "o 100 méně než 500"). CI je 101; IC není dokonce vůbec platné římské číslo (protože 1 nemůžeme přímo odčítat od 100; musíme to napsat jako XCIX, "o 10 méně než 100 a k tomu o 1 méně než 10").

#### 5.3.1. Kontrola tisícovek

Jak bychom vlastně mohli ověřit, zda je libovolný řetězec platným římským číslem? Podívejme se na to po jednotlivých číslicích. Římské číslice se vždycky píší od největších k nejmenším. Začněme tedy u nejvyšších, na místě tisícovek. U čísel 1000 a vyšších se tisícovky vyjadřují jako řada znaků M.

5.3.

```
>>> import re
>>> pattern = '^M?M?M?$'
                                          [1]
>>> re.search(pattern, 'M')
<_sre.SRE_Match object at 0106FB58>
>>> re.search(pattern, 'MM')
                                          [3]
<_sre.SRE_Match object at 0106C290>
>>> re.search(pattern, 'MMM')
                                          [4]
<_sre.SRE_Match object at 0106AA38>
>>> re.search(pattern, 'MMMM')
                                          [5]
>>> re.search(pattern, '')
                                          [6]
<_sre.SRE_Match object at 0106F4A8>
```

- Tento vzorek má tři části. Znak ^ zajistí vazbu další části výrazu na začátek řetězce. Pokud bychom jej nepoužili, pak by vzorek pasoval nezávisle na tom, kde by se znaky M nacházely. A to bychom nechtěli. Chceme si být jistí ním, že pokud se nějaké znaky M najdou, musí se nacházet na začátku řetězce. Zápis M? odpovídá nepovinnému výskytu jednoho znaku M. A protože se opakuje třikrát, odpovídá výraz výskytu žádného až tří znaků M za sebou. Znak \$ odpovídá konci řetězce. Když to dáme dohromady se znakem ^ na začátku, znamená to, že vzorek musí odpovídat celému řetězci. Znakům M nemůže žádný jiný znak předcházet a ani za nimi nemůže následovat.
- Základem modulu re je funkce search(). Ta přebírá regulární výraz (pattern) a řetězec ('M') a zkusí, jestli k sobě pasují. Pokud je shoda nalezena, vrátí funkce search() objekt, který nabízí různé metody k popisu výsledku. Pokud ke shodě nedojde, vrací funkce search() hodnotu None, což je pythonovská hodnota null (nil, nic). V tomto okamžiku nás zajímá jen to, zda vzorek pasuje. Abychom mohli odpovědět, stačí se podívat na návratovou hodnotu funkce search(). Řetězec 'M' odpovídá regulárnímu výrazu, protože první nepovinný znak M sedí a druhý a třetí nepovinný znak M se ignoruje.
- Řetězec 'MM' vyhovuje, protože první a druhý nepovinný znak M pasují a třetí M se ignoruje.
- [4] Řetězec 'MMM' vyhovuje, protože všechny tři znaky M pasují.
- [5] Řetězec 'MMMM' nevyhovuje. Všechny tři znaky M pasují, ale pak regulární výraz trvá na tom, že řetězec musí skončit (protože je to předepsáno znakem \$). Jenže řetězec ještě nekončí (protože následuje čtvrté M). Takže search() vrací None.
- Zajímavé je, že prázdný řetězec tomuto regulárnímu výrazu vyhovuje, protože všechny znaky M jsou nepovinné.

#### 5.3.2. Kontrola stovek

## ? říká, že vzorek je nepovinný.

Kontrola stovek je obtížnější než kontrola tisícovek. Je to tím, že v závislosti na hodnotě existuje několik vzájemně se vylučujících způsobů, kterými mohou být stovky vyjádřeny.

```
100 = C

200 = CC

300 = CCC

400 = CD

500 = D

600 = DC

700 = DCC

800 = DCCC

900 = CM
```

Takže tu máme čtyři možné vzory:

- CM
- CD
- Žádný až tři znaky C (nula v případě, kdy má být na místě stovek 0).
- D následované žádným až třemi znaky C.

#### Poslední dva vzory můžeme zkombinovat:

- Nepovinné D následované žádným až třemi znaky C.
- Následující příklad ukazuje, jak můžeme u římských čísel ověřit zápis stovek.

```
>>> import re
>>> pattern = '^M?M?M?(CM|CD|D?C?C?C?)$'
                                           [1]
>>> re.search(pattern, 'MCM')
                                           [2]
<_sre.SRE_Match object at 01070390>
>>> re.search(pattern, 'MD')
                                            [3]
<_sre.SRE_Match object at 01073A50>
>>> re.search(pattern, 'MMMCCC')
                                           [4]
<_sre.SRE_Match object at 010748A8>
>>> re.search(pattern, 'MCMC')
                                            [5]
>>> re.search(pattern, '')
                                            [6]
<_sre.SRE_Match object at 01071D98>
```

- Tento vzorek začíná stejně jako u předchozího příkladu. Kontrolujeme hranici začátku řetězce (^) a potom místo pro tisícovky (M?M?M?). V závorkách je poté uvedena nová část, která definuje sadu tří vzájemně výlučných vzorků oddělených svislými čarami: CM, CD a D?C?C?C? (což vyjadřuje nepovinné D následované žádným nebo třemi znaky C). Analyzátor (parser) regulárního výrazu kontroluje každý z těchto vzorků v daném pořadí (zleva doprava), zvolí první, který situaci odpovídá, a ostatní ignoruje.
- Retězec 'MCM' vyhovuje, protože pasuje první M, druhý a třetí znak M vzorku se ignorují. Následující podřetězec CM odpovídá prvnímu vzorku v závorce (takže části vzorku CD a D?C?C?C? se neuvažují). MCM je římské číslo vyjadřující hodnotu 1900.

- [3] Řetězec 'MD' vyhovuje, protože pasuje první M, druhé a třetí M se ignorují. Vzorek D?C?C?C? pasuje k D (každý z následujících tří znaků C je nepovinný, takže se ignorují). MD je římské číslo vyjadřující 1500.
- [4] Řetězec 'MMMCCC' testem prošel. Všechny tři znaky M pasují. Následující vzorek D?C?C?C? pasuje k podřetězci CCC (znak D je nepovinný a ignoruje se). MMMCCC je římské číslo vyjadřující hodnotu 3300.
- Řetězec 'MCMC' nevyhovuje. První znak M pasuje, druhé a třetí M se ignorují. Následující CM [5] vyhovuje, ale poté vzorek předepisuje znak \$, který nesedí, protože ještě nejsme na konci řetězce. (Pořád nám zbývá nezpracovaný znak C.) Poslední znak C nelze napasovat ani na část vzorku D?C?C?C?, protože ta se vzájemně vylučuje s částí vzorku CM, která se již použila.
- [6] Zajímavé je, že tomuto vzorku vyhovuje prázdný řetězec, protože všechny znaky M jsou nepovinné a ignorují se. Prázdný řetězec dále vyhovuje i části vzorku D?C?C?C?, protože všechny znaky jsou nepovinné a ignorují se.

Uffff! Vidíte, jak se mohou regulární výrazy rychle stát nechutnými? A to jsme zatím vyřešili části římských čísel jen pro tisíce a stovky. Ale pokud jste zatím vše sledovali, budou pro vás desítky a jednotky jednoduché, protože u nich použijeme naprosto stejný přístup. Ale podívejme se ještě na další možnost vyjádření vzorku.

#### Využití syntaxe { n, m} 5.4.

### Zápis {1,4} vyjadřuje 1 až 4 výskyty vzorku.

V předcházející podkapitole jsme pracovali se vzorkem, ve kterém se mohly stejné znaky opakovat až třikrát. V regulárních výrazech existuje ještě jiný způsob, jak to vyjádřit. Někteří lidé jej považují za čitelnější. Podívejme se nejdříve na způsoby, které jsme použili v předcházejícím příkladu.

```
>>> import re
>>> pattern = '^M?M?M?$'
>>> re.search(pattern, 'M')
                                         [1]
<_sre.SRE_Match object at 0x008EE090>
>>> re.search(pattern, 'MM')
                                         [2]
<_sre.SRE_Match object at 0x008EEB48>
>>> re.search(pattern, 'MMM')
                                         [3]
<_sre.SRE_Match object at 0x008EE090>
>>> re.search(pattern, 'MMMM')
                                         [4]
>>>
```

- Zde dochází ke shodě se začátkem řetězce a s prvním nepovinným M, ale ne s druhým a s třetím M [1] (což je v pořádku, protože jsou nepovinná). Potom následuje konec řetězce.
- Zde dochází ke shodě se začátkem řetězce a s prvním a druhým nepovinným M, ale ne s třetím M [2] (ale to je v pořádku, protože je nepovinné). Poté pasuje i konec řetězce.

- Zde dochází ke shodě se začátkem řetězce, se všemi třemi nepovinnými M a s koncem řetězce.
- Zde dochází ke shodě se začátkem řetězce a se všemi třemi nepovinnými M, ale poté nenásleduje předepsaný konec řetězce (protože tu máme ještě jedno nepasující M). To znamená, že vzorek nesedí a vrací se None.

```
>>> pattern = '^M{0,3}$' [1]
>>> re.search(pattern, 'M') [2]
<_sre.SRE_Match object at 0x008EEB48>
>>> re.search(pattern, 'MM') [3]
<_sre.SRE_Match object at 0x008EE090>
>>> re.search(pattern, 'MMM') [4]
<_sre.SRE_Match object at 0x008EEDA8>
>>> re.search(pattern, 'MMMM') [5]
>>>
```

- Tento vzorek říká: "Zde musí být začátek řetězce, potom následují nula až tři znaky M a pak musí být konec řetězce." Na místě 0 a 3 mohou být uvedena libovolná čísla. Pokud chceme předepsat "nejméně jeden, ale ne víc než tři znaky M", můžeme napsat M{1,3}.
- Zde dochází ke shodě se začátkem řetězce a pak s jedním ze tří možných M a s koncem řetězce.
- Zde dochází ke shodě se začátkem řetězce a pak s dvěma ze tří možných M a s koncem řetězce.
- Zde dochází ke shodě se začátkem řetězce a pak s třemi ze tří možných M a s koncem řetězce.
- Zde dochází ke shodě se začátkem řetězce a pak s třemi ze tří možných M, ale poté nedochází ke shodě s předpisem pro konec řetězce. Tento regulární výraz předepisuje maximálně tři znaky M následované koncem řetězce, ale řetězec obsahuje čtyři, takže vzorek nepasuje a vrací se None.

#### 5.4.1. Kontrola desítek a jednotek

Rozšiřme tedy regulární výraz pro kontrolu římských čísel o kontrolu na místě desítek a jednotek. Následující příklad ukazuje, jak můžeme kontrolovat desítky.

```
>>> pattern = '^M?M?M?(CM|CD|D?C?C?C?)(XC|XL|L?X?X?X?)$'
>>> re.search(pattern, 'MCMXL')
                                          [1]
<_sre.SRE_Match object at 0x008EEB48>
>>> re.search(pattern, 'MCML')
                                          [2]
<_sre.SRE_Match object at 0x008EEB48>
>>> re.search(pattern, 'MCMLX')
                                          [3]
<_sre.SRE_Match object at 0x008EEB48>
>>> re.search(pattern, 'MCMLXXX')
                                          [4]
<_sre.SRE_Match object at 0x008EEB48>
>>> re.search(pattern, 'MCMLXXXX')
                                          [5]
>>>
```

- [1] Tento řetězec pasuje k předepsanému začátku řetězce, pak k prvnímu nepovinnému M, následuje shoda s CM, poté s XL a s předpisem pro konec řetězce. Připomeňme si, že syntaxe (A|B|C) vyjadřuje "odpovídá právě jednomu z A, B nebo C". Došlo ke shodě s XL, takže se ignorují možnosti XC a L?X?X?X?. Poté byl nalezen konec řetězce. MCMXL je římské číslo vyjadřující hodnotu 1940.
- Tento řetězec vyhovuje předepsanému začátku řetězce, pak prvnímu nepovinnému M, následuje [2] shoda s CM a pak s L?X?X?X?. Co se týká části L?X?X?X?, vyhovuje jí L a přeskakují se všechny tři nepovinné znaky X. Poté se dostáváme ke konci řetězce. MCML je římské číslo vyjadřující hodnotu 1950.
- [3] Tento řetězec pasuje k předepsanému začátku řetězce, pak k prvnímu nepovinnému M, následuje shoda s CM, poté s nepovinným L, s prvním nepovinným X, pak se přeskočí druhé a třetí nepovinné X a následuje očekávaný konec řetězce. MCMLX je římské číslo vyjadřující hodnotu 1960.
- [4] Tento řetězec vyhovuje předepsanému začátku řetězce, pak prvnímu nepovinnému M, potom CM, pak následuje nepovinné L a všechna tři nepovinná X a vyžadovaný konec řetězce. MCMLXXX je římské číslo vyjadřující hodnotu 1980.
- [5] Tento případ vyhovuje předepsanému začátku řetězce, pak prvnímu nepovinnému M, potom CM, pak tu máme nepovinné L a všechna tři nepovinná X, ale poté dochází k selhání předpokladu konce řetězce, protože nám zbývá ještě jedno X, se kterým jsme nepočítali. Takže celý regulární výraz selhává (nepasuje) a vrací se None. MCMLXXXX není platné římské číslo.

(A|B) předepisuje buď shodu se

Výraz pro test jednotek vytvoříme stejným způsobem. Ušetřím vás detailů a ukážu vám jen konečný výsledek.

vzorkem A nebo se vzorkem B, ale ne s oběma najednou.

```
>>> pattern = '^M?M?M?(CM|CD|D?C?C?C?)(XC|XL|L?X?X?X?)(IX|IV|V?I?I?I?)$'
```

Takže jak by to vypadalo, kdybychom použili alternativní syntaxi {n,m}? To nám ukáže následující příklad.

```
>>> pattern = '^M{0,3}(CM|CD|D?C{0,3})(XC|XL|L?X{0,3})(IX|IV|V?I{0,3})$'
>>> re.search(pattern, 'MDLV')
                                             [1]
<_sre.SRE_Match object at 0x008EEB48>
>>> re.search(pattern, 'MMDCLXVI')
                                             [2]
<_sre.SRE_Match object at 0x008EEB48>
>>> re.search(pattern, 'MMMDCCCLXXXVIII')
                                             [3]
<_sre.SRE_Match object at 0x008EEB48>
>>> re.search(pattern, 'I')
                                             [4]
<_sre.SRE_Match object at 0x008EEB48>
```

- Zde dochází ke shodě se začátkem řetězce, pak s jedním ze tří možných znaků M a následně [1] s předpisem D?C{0,3}. U posledního podvýrazu dochází ke shodě s nepovinným D a s nulou ze tří možných znaků C. Posuňme se dál. Zde pasuje podvýraz L?X{0,3}, protože vyhoví nepovinné L a nula ze tří možných znaků X. Další kousek řetězce vyhovuje podvýrazu V?I{0,3}, protože je nalezeno nepovinné V a nula ze tří možných znaků I. A na závěr nastává očekávaný konec řetězce. MDLV je římské číslo vyjadřující hodnotu 1555.
- Zde dochází ke shodě se začátkem řetězce a pak s dvěma ze tří možných znaků M, pak [2] s D?C{0,3} s jedním D a s jedním ze tří možných znaků C. Pokračujeme L?X{0,3} s jedním L a jedním ze tří možných znaků X. A dále tu máme V?I{0,3} s jedním V a jedním ze tří možných znaků I. Pasuje i očekávaný konec řetězce. MMDCLXVI je římské číslo vyjadřující hodnotu 2666.
- Zde dochází ke shodě se začátkem řetězce a pak s třemi ze tří možných znaků M, pak je tu [3] D?C{0,3} s jedním D a s třemi ze tří možných znaků C. Pokračujeme L?X{0,3} s jedním L a s třemi ze tří možných znaků X. A dále se uplatní V?I{0,3} s jedním V a s třemi ze tří možných znaků I. A očekávaný konec řetězce. MMMDCCCLXXXVIII je římské číslo vyjadřující hodnotu 3888. Současně je to největší římské číslo, které můžete napsat bez použití rozšířené syntaxe.
- A teď se pozorně dívejte. (Připadám si jako kouzelník. "Děti, pozorně se dívejte. Teď ze svého [4] klobouku vytáhnu králíka.") Tady nám pasuje začátek řetězce, pak následuje nula ze tří možných znaků M, pak pasuje D?C{0,3} — přeskočení nepovinného D a absence znaku C (nula až tři možné výskyty). Pokračujeme shodou s podvýrazem L?X{0,3} přeskočením nepovinného L a přípustnou absencí znaku X (nula až tři možné výskyty). A dále se uplatní V?I{0,3} přeskočením nepovinného V a shodou jednoho ze tří možných znaků I. A pak je tu konec řetězce. No páni.

Pokud jste to všechno stihli sledovat a rozuměli jste tomu napoprvé, jde vám to líp, než to šlo mně. Teď si představte, že se snažíte porozumět regulárnímu výrazu, který napsal někdo jiný a který se nachází uprostřed kritické funkce rozsáhlého programu. Nebo si představte, že se po několika měsících vracíte ke svému vlastnímu regulárnímu výrazu. Už se mi to stalo a není to pěkný pohled.

Podívejme se na alternativní syntaxi, která nám pomůže zapsat regulární výraz tak, aby se dal udržovat.

#### Víceslovné regulární výrazy 5.5.

Zatím jsme se zabývali tím, čemu budu říkat "kompaktní" regulární výrazy. Jak jste sami viděli, obtížně se čtou. Dokonce i když přijdete na to, co nějaký z nich dělá, není tu žádná záruka, že mu budete rozumět o šest měsíců později. To, co opravdu potřebujeme, je dokumentace připisovaná k danému místu.

V Pythonu toho lze dosáhnout u takzvaných víceslovných regulárních výrazů (verbose regular expressions). Víceslovný regulární výraz se od kompaktního regulárního výrazu liší ve dvou směrech:

Bílé znaky se ignorují. Mezery, tabulátory a přechody na nový řádek se nesnaží napasovat na mezery, tabulátory a přechody na nový řádek. Nepasují vůbec k ničemu. (Pokud chcete ve více-

- slovném regulárním výrazu předepsat shodu s mezerou, musíte před ni napsat zpětné lomítko speciální znak (escape) uvozující sekvenci.)
- Komentáře se ignorují. Komentáře uvnitř víceslovných regulárních výrazů mají podobu běžných
  pythonovských komentářů: začínají znakem # a pokračují do konce řádku. V tomto případě jde
  o komentář uvnitř víceřádkového řetězce a ne uvnitř zdrojového souboru. Ale funguje stejně.

Z dalšího příkladu to bude jasnější. Revidujme kompaktní regulární výraz, s kterým jsme pracovali před chvílí, a převeďme jej na víceslovný regulární výraz. Příklad nám ukáže, jak na to.

```
>>> pattern = '''
    ٨
                        # začátek řetězce
                        # tisíce - 0 až 3 M
    M{0,3}
    (CM|CD|D?C{0,3})
                        # stovky - 900 (CM), 400 (CD), 0-300 (0 až 3 C),
                                  nebo 500-800 (D následované 0 až 3 C)
    (XC|XL|L?X{0,3})
                        # desítky - 90 (XC), 40 (XL), 0-30 (0 až 3 X),
                                 nebo 50-80 (L následované 0 až 3 X)
    (IX|IV|V?I\{0,3\})
                        # jednotky - 9 (IX), 4 (IV), 0-3 (0 až 3 I),
                                 nebo 5-8 (V následované 0 až 3 I)
    $
                        # konec řetězce
>>> re.search(pattern, 'M', re.VERBOSE)
                                                         [1]
<_sre.SRE_Match object at 0x008EEB48>
>>> re.search(pattern, 'MCMLXXXIX', re.VERBOSE)
                                                         [2]
<_sre.SRE_Match object at 0x008EEB48>
>>> re.search(pattern, 'MMMDCCCLXXXVIII', re.VERBOSE)
                                                         [3]
<_sre.SRE_Match object at 0x008EEB48>
>>> re.search(pattern, 'M')
                                                         [4]
```

- Nejdůležitější věcí při práci s víceslovnými regulárními výrazy je to, abychom nezapomněli předat jeden argument navíc: v modulu re je definována konstanta re. VERBOSE, kterou dáváme najevo, že vzorek se má brát jako víceslovný regulární výraz. Jak vidíte, v tomto vzorku se nachází docela hodně bílých znaků (všechny se ignorují) a několik komentářů (opět se všechny ignorují). Pokud budete ignorovat bílé znaky a komentáře, dostanete naprosto stejný regulární výraz, jaký jsme si ukázali v minulé podkapitole. Ale je mnohem čitelnější.
- Zde dochází ke shodě se začátkem řetězce a pak s třemi M, pak s CM, následuje L a tři ze tří možných X, pak IX a konec řetězce.
- Tady pasuje začátek řetězce, pak tři z možných tří M, následuje D a tři ze tří možných C, pak L a tři ze tří možných X, pak V a tři ze tří možných I a konec řetězce.
- Shoda nebyla nalezena. Proč? Protože jsme neuvedli příznak re. VERBOSE. Takže funkce re. search považuje vzorek za kompaktní regulární výraz, ve kterém hrají roli všechny bílé znaky i znaky #. Python nemůže rozpoznávat automaticky, zda je regulární výraz víceslovný nebo ne. Python považuje každý regulární výraz za kompaktní pokud explicitně neřekneme, že je víceslovný.

#### 5.6. Případová studie: Analýza telefonních čísel

Prozatím jsme se soustředili na shodu celých vzorků. Vzorek buď pasuje, nebo ne. Ale regulární výrazy jsou ještě mnohem mocnější. Pokud regulární výraz pasuje, můžeme z řetězce vybrat specifické úseky. Můžeme zjistit, jaká část a kde pasovala.

Následující příklad přinesl opět reálný život. Setkal jsem se s ním o jeden pracovní den dříve než s tím předchozím. Problém: rozklad amerického telefonního čísla. Klient požadoval, aby se číslo dalo zadávat ve volném tvaru (v jednom poli formuláře), ale pak je chtěl mít ve firemní databázi rozdělené

\d vyjadřuje libovolnou číslici (0-9). \D vyjadřuje vše kromě číslice.

na kód oblasti, hlavní linku, číslo a případně klapku. Proštrachal jsem web a našel jsem spoustu příkladů regulárních výrazů, které byly pro tento účel vytvořeny. Ale žádný z nich nebyl dost benevolentní.

Tady máme pár telefonních čísel, která měla být přijata:

```
800-555-1212
800 555 1212
800.555.1212
(800) 555-1212
1-800-555-1212
800-555-1212-1234
800-555-1212x1234
800-555-1212 ext. 1234
work 1-(800) 555.1212 #1234
```

Docela široký záběr, že? V každém z těchto případů jsem potřeboval zjistit, že číslo oblasti bylo 800, číslo hlavní linky bylo 555 a zbytek telefonního čísla byl 1212. U čísel s klapkou (extension, ext.) jsem potřeboval zjistit, že klapka byla 1234.

Takže si projděme vývoj řešení pro analýzu telefonního čísla. Následující příklad ukazuje první krok.

```
>>> phonePattern = re.compile(r'^(d{3})-(d{3})-(d{4}))
                                                              [1]
>>> phonePattern.search('800-555-1212').groups()
                                                              [2]
('800', '555', '1212')
>>> phonePattern.search('800-555-1212-1234')
                                                              [3]
>>> phonePattern.search('800-555-1212-1234').groups()
                                                              [4]
Traceback (most recent call last):
  File "<stdin>", line 1, in <module>
AttributeError: 'NoneType' object has no attribute 'groups'
```

[1] Regulární výraz čteme vždy zleva doprava. Tento odpovídá začátku řetězce a pak následuje (\d{3}). Co to je \d{3}? No, \d vyjadřuje "libovolnou číslici (0 až 9). Společně s {3} znamená "přesně tři číslice". Jde o variaci na syntaxi {n,m}, kterou jsme si ukazovali dříve. Když to vše obalíme do závorek, znamená to "napasuj se přesně na tři číslice *a potom si je zapamatuj jako skupinu, kterou si můžeme vyžádat později*". Pak musí následovat pomlčka. Pak má následovat skupina zase přesně tří číslic. A pak další pomlčka. A další skupina tentokrát čtyř číslic. A poté se očekává konec řetězce.

- Ke skupinám, které se zapamatovaly během analýzy předepsané regulárním výrazem, můžeme přistupovat metodou groups() objektu, který vrátila metoda search(). Vrací tolikačlennou n-tici, kolik skupin bylo v regulárním výrazu definováno. V našem případě jsme definovali tři skupiny: jednu s třemi číslicemi, další s třemi číslicemi a poslední se čtyřmi číslicemi.
- Tento regulární výraz ale není hotový, protože nezvládne telefonní čísla s klapkou na konci. Pro tento účel musíme regulární výraz rozšířit.
- Tento případ ilustruje, proč bychom ve skutečně používaném kódu neměli nikdy "řetězit" použití metod search() a groups(). Pokud metoda search() nevrátí žádnou shodu, vrací None a nikoliv objekt vyjadřující shodu s regulárním výrazem (MatchObject). Volání None. groups() vyvolá naprosto zřejmou výjimku. None totiž žádnou metodu groups() nemá. (Je to samozřejmě méně zjevné v situaci, kdy se taková výjimka vynoří někde z hloubky našeho kódu. Ano, tady mluvím z vlastní zkušenosti.)

```
>>> phonePattern = re.compile(r'^(\d{3})-(\d{4})-(\d+)$') [1]
>>> phonePattern.search('800-555-1212-1234').groups() [2]
('800', '555', '1212', '1234')
>>> phonePattern.search('800 555 1212 1234') [3]
>>>
>>> phonePattern.search('800-555-1212') [4]
```

- Tento regulární výraz se s předchozím téměř shoduje. Také nejdříve předepisuje začátek řetězce, pak se pamatuje skupina tří číslic, pomlčka, pak se pamatuje skupina tří číslic, pomlčka a nakonec se pamatuje skupina čtyř číslic. Nové je tady to, že se očekává další pomlčka, pak se pamatuje skupina jedné nebo více číslic a teprve potom má nastat konec řetězce.
- [2] Metoda groups() teď vrací n-tici se čtyřmi prvky, protože regulární výraz nyní definuje čtyři pamatované skupiny.
- Tento regulární výraz ale, bohužel, také není konečnou odpovědí, protože předpokládá, že jednotlivé části telefonního čísla jsou odděleny pomlčkou. Co kdyby je někdo oddělil mezerami, čárkami nebo tečkami? Potřebujeme obecnější řešení, které by akceptovalo více typů oddělovačů.
- Ouha! Tenhle regulární výraz nejen že nedělá vše, co si přejeme. Je to ve skutečnosti krok zpět, protože teď nejsme schopni analyzovat číslo *bez klapky*. To vůbec není to, co jsme chtěli. Pokud tam klapka je, pak chceme vědět jaká. Pokud tam klapka není, pak chceme znát, jaké byly části hlavního čísla.

Následující příklad ukazuje regulární výraz, který si poradí s různými oddělovači mezi částmi telefonního čísla.

```
>>> phonePattern = re.compile(r'^(\d{3})\D+(\d{4})\D+(\d+)$') [1]
>>> phonePattern.search('800 555 1212 1234').groups() [2]
('800', '555', '1212', '1234')
>>> phonePattern.search('800-555-1212-1234').groups() [3]
('800', '555', '1212', '1234')
>>> phonePattern.search('80055512121234') [4]
>>> phonePattern.search('800-555-1212') [5]
>>> phonePattern.search('800-555-1212')
```

- Držte si klobouky, jedeme z kopce! Očekáváme začátek řetězce, potom skupinu tří číslic, pak \D+. A co je zase tohle? Zápis \D vyjadřuje libovolný znak s výjimkou číslice a + znamená "1 nebo víckrát". Takže \D+ pasuje na jeden nebo více znaků, které nejsou číslicemi. A to je právě to, co použijeme místo přímo zapsané pomlčky a co nám bude pasovat s různými oddělovači.
- Protože používáme \D+ místo -, bude nám regulární výraz pasovat i na telefonní čísla, kde jsou jednotlivé části odděleny mezerami.
- [3] Ale čísla oddělená pomlčkami budou fungovat také.
- Stále to ale ještě, bohužel, není konečná odpověď, protože tam nějaký oddělovač je. Co když někdo zadá telefonní číslo úplně bez mezer nebo jiných oddělovačů?
- Jejda! Pořád ještě není vyřešeno to, že se požaduje zadání klapky. Takže teď máme dva problémy, ale můžeme je oba vyřešit stejnou technikou.

Následující příklad ukazuje regulární výraz pro telefonní čísla bez oddělovačů.

```
>>> phonePattern = re.compile(r'^(\d{3})\D*(\d{4})\D*(\d*)$') [1]
>>> phonePattern.search('80055512121234').groups() [2]
('800', '555', '1212', '1234')
>>> phonePattern.search('800.555.1212 x1234').groups() [3]
('800', '555', '1212', '1234')
>>> phonePattern.search('800-555-1212').groups() [4]
('800', '555', '1212', '')
>>> phonePattern.search('(800)5551212 x1234') [5]
>>>
```

- Jediná věc, kterou jsme od minulého kroku udělali, byla záměna + za \*. Mezi částmi telefonního čísla nyní místo \D+ předepisujeme \D\*. Pamatujete si ještě, že + znamená "jednou nebo víckrát"? Fajn. Takže \* znamená "nula nebo více výskytů". Takže teď bychom měli být schopni zpracovat čísla, která neobsahují vůbec žádný oddělovací znak.
- No podívejme, ono to opravdu funguje! Jak to? Napasovali jsme se na začátek řetězce, pak jsme si zapamatovali skupinu tří číslic (800), potom nula nenumerických znaků, pak následuje zapamatovaná skupina tří číslic (555), pak nula nenumerických znaků, pak zapamatovaná skupina čtyř číslic (1212), pak nula nenumerických znaků, pak zapamatovaná skupina libovolného počtu číslic (1234) a konec řetězce.

- Ostatní obměny teď fungují také: tečky místo pomlček i kombinace mezer a x před klapkou.
- Nakonec se nám podařilo vyřešit i dlouho odolávající problém: klapka už je opět nepovinná. Metoda groups() vrací n-tici se čtyřmi prvky i tehdy, když nebyla nalezena klapka. V takovém případě se ale na místě čtvrtého prvku vrací prázdný řetězec.
- Nechci být poslem špatných zpráv, ale pořád ještě nejsme hotovi. Co je tady špatně? Před kódem oblasti máme znak navíc, ale regulární výraz předpokládá, že na začátku řetězce se má jako první nacházet kód oblasti. Žádný problém. Úvodní znaky před kódem oblasti můžeme přeskočit již dříve představenou technikou "nula nebo více nečíselných znaků".

Další příklad ukazuje, jak bychom si měli počínat.

```
>>> phonePattern = re.compile(r'^\D*(\d{3})\D*(\d{4})\D*(\d*)$') [1]
>>> phonePattern.search('(800)5551212 ext. 1234').groups() [2]
('800', '555', '1212', '1234')
>>> phonePattern.search('800-555-1212').groups() [3]
('800', '555', '1212', '')
>>> phonePattern.search('work 1-(800) 555.1212 #1234')
>>>
```

- Tady je to stejné jako v předchozím příkladu s tou výjimkou, že před první pamatovanou skupinou znaků (před číslem oblasti) předepisuje \D\* nula nebo více nenumerických znaků. Všimněte si, že si tyto nenumerické znaky nepamatujeme (předpis není uzavřen v závorkách). Pokud jsou nějaké nalezeny, jednoduše je přeskočíme a teprve pak si zapamatujeme nalezené číslo oblasti.
- Telefonní číslo se nám podaří úspěšně rozložit i v případě, kdy je před číslem oblasti uvedena levá závorka. (Pravá závorka za číslem oblasti se už zpracovává. Bere se jako nenumerický oddělovač a napasuje se na předpis \D\* nacházející se za první pamatovanou skupinou.)
- Proveďme ještě test funkčnosti (sanity check), abychom se ujistili, že se nepokazilo nic, co dříve fungovalo. Úvodní znaky jsou zcela nepovinné, takže po začátku řetězce se našlo nula nenumerických znaků, pak pamatovaná skupina tří číslic (800), pak jeden nenumerický znak (pomlčka), zapamatovaná skupina tří číslic (555), pak jeden nenumerický znak (pomlčka), poté zapamatovaná skupina čtyř číslic (1212), pak nula nenumerických znaků, pak zapamatovaná skupina nula číslic a na závěr konec řetězce.
- Tak toto je případ, kdy mám v souvislosti s regulárními výrazy chuť vydloubnout si oči tupým předmětem. Proč tohle telefonní číslo nepasuje? Protože se před kódem oblasti vyskytuje 1, ale my jsme předpokládali, že všechny znaky před kódem oblasti budou nenumerické (\D\*). Grrrrr.

Podívejme se na to znovu. Zatím se všechny regulární výrazy chytaly na začátek řetězce. Ale teď vidíme, že se na začátku řetězce může vyskytnout obsah neurčité délky, který bychom chtěli ignorovat. Mohli bychom se sice pokusit o vytvoření předpisu, kterým bychom ten začátek přeskočili, ale zkusme k tomu přistoupit jinak. Nebudeme se vůbec snažit o to, abychom se napasovali na začátek řetězce. Zmíněný přístup je použit v následujícím příkladu.

```
>>> phonePattern = re.compile(r'(\d{3})\D*(\d{4})\D*(\d*)$') [1]
>>> phonePattern.search('work 1-(800) 555.1212 #1234').groups() [2]
('800', '555', '1212', '1234')
>>> phonePattern.search('800-555-1212').groups() [3]
('800', '555', '1212', '')
>>> phonePattern.search('80055512121234').groups() [4]
('800', '555', '1212', '1234')
```

- Všimněte si, že v regulárním výrazu chybí ^. Už se nesnažíme ukotvit na začátek řetězce. Nikde není řečeno, že by se náš regulární výraz měl napasovat na celý vstupní řetězec. Mechanismus, který regulární výraz vyhodnocuje, už si dá tu práci, aby zjistil, od jakého místa vstupního řetězce dochází ke shodě s předpisem, a bude pokračovat odtud.
- Teď už jsme úspěšně rozložili telefonní číslo, které obsahuje úvodní znaky i s nechtěnými čísly a které odděluje skupiny chtěných čísel libovolným počtem libovolných oddělovačů.
- [3] Test funkčnosti (sanity check). Funguje to správně.
- [4] A tohle taky funguje.

Vidíte, jak se může regulární výraz rychle vymknout kontrole? Letmo mrkněte na libovolný z předchozích pokusů. Poznáte snadno rozdíl mezi ním a po něm následujícím?

Takže dokud ještě rozumíme konečnému řešení (a tohle opravdu je konečné řešení; pokud jste objevili případ, který by to nezvládlo, nechci o něm vědět), zapišme ho jako víceslovný regulární výraz. Mohli bychom brzy zapomenout, proč jsme něco zapsali právě takto.

```
>>> phonePattern = re.compile(r'''
                # nevázat se na začátek řetězce, číslo může začít kdekoliv
                # číslo oblasti má 3 číslice (např. '800')
    (\d{3})
                # nepovinný oddělovač - libovolný počet nenumerických znaků
    \D*
    (\d{3})
                # číslo hlavní linky má 3 číslice (např. '555')
    \D*
                # nepovinný oddělovač
                # zbytek čísla má 4 číslice (např. '1212')
    (\d{4})
    \D*
                # nepovinný oddělovač
    (\d*)
                # nepovinná klapka - libovolný počet číslic
                # konec řetězce
    ''', re.VERBOSE)
>>> phonePattern.search('work 1-(800) 555.1212 #1234').groups()
                                                                          [1]
('800', '555', '1212', '1234')
>>> phonePattern.search('800-555-1212')
                                                                           [2]
('800', '555', '1212', '')
```

- Jediným rozdílem proti regulárnímu výrazu z minulého kroku je to, že je vše rozepsáno na více řádcích. Proto není žádným překvapením, že zpracovává vstupy stejným způsobem.
- [2] Konečný test funkčnosti (sanity check). Ano, tohle pořád funguje. Jsme hotovi.

#### 5.7. Shrnutí

Zatím jsme viděli pouhou špičku ledovce z toho, co regulární výrazy zvládnou. Jinými slovy, ačkoliv jimi můžete být momentálně zcela ohromeni, zatím jste neviděli nic. To mi věřte.

Následující věci už by vám neměly být cizí:

- odpovídá začátku řetězce.
- \$ vyjadřuje konec řetězce.
- \b odpovídá hranici slova (word boundary).
- \d odpovídá číslici.
- \D odpovídá znaku jinému než číslice.
- x? odpovídá nepovinnému znaku x (jinými slovy vyjadřuje žádný nebo jeden výskyt x).
- x\* vyjadřuje nula nebo více výskytů x.
- x+ odpovídá x jedenkrát nebo víckrát.
- x{n,m} vyjadřuje znak x opakovaný nejméně n-krát, ale ne více než m-krát.
- (a|b|c) odpovídá přesně jedné z možností a, b nebo c.
- (x) vyjadřuje obecně *zapamatovanou skupinu*. Hodnotu zapamatované skupiny můžeme získat voláním metody groups() objektu, který byl vrácen voláním re.search.

Regulární výrazy jsou velmi mocné, ale jejich použití není správným řešením pro každý problém. Měli byste se o nich naučit tolik, abyste věděli, kdy je jejich použití vhodné, kdy vám pomohou problém vyřešit a kdy naopak způsobí víc problémů, než vyřeší.

6. Kapitola

- "My spelling is Wobbly. It's good spelling but it Wobbles, and the letters get in the wrong places." (Mé jméno je Houpavý. Hláskuji to správně, ale Houpe se to a písmenka se dostávají na špatná místa.)
  - Medvídek Pú

# 6. Uzávěry a generátory

6.7.

#### 6. Uzávěry a generátory — 143 6.1. Ponořme se — 145 Já vím jak na to! Použijeme regulární výrazy! — 146 6.2. Seznam funkcí — 148 6.3. Seznam vzorků — 150 6.4. Soubor vzorků — 152 6.5. Generátory — 154 6.6. 6.6.1. Generátor Fibonacciho posloupnosti — 155 6.6.2. Generátor pravidel pro množné číslo — 156

Přečtěte si — 158

#### 6.1 Ponořme se

Vyrůstal jsem jako syn knihovnice, která vystudovala angličtinu, a vždycky mě fascinovaly jazyky. Nemyslím programovací jazyky. Tedy ano, i programovací jazyky, ale také přirozené jazyky. Dejme tomu angličtina. Angličtina je schizofrenní jazyk, který si slova půjčuje z němčiny, francouzštiny, španělštiny a latiny (když už mám pár vyjmenovat). Slova "půjčuje si" ve skutečnosti nejsou ta pravá, "vykrádá" je přiléhavější. Nebo si je možná "asimiluje" — jako Borg. Jo, to se mi líbí.

My jsme Borg. Zvláštnosti vašeho jazyka a původu slov budou přidány do našeho vlastního. Odpor je marný.

V této kapitole se naučíte něco o anglických podstatných jménech v množném čísle. A také o funkcích, které vracejí jiné funkce, o regulárních výrazech pro pokročilé a o generátorech. Ale nejdříve si řekněme něco o tom, jak se tvoří podstatná jména v množném čísle. (Pokud jste nečetli kapitolu o regulárních výrazech, tak je na to vhodná doba právě teď. V této kapitole se předpokládá, že základům regulárních výrazů už rozumíte, protože se rychle dostaneme k látce pro pokročilé.)

Pokud jste vyrostli v anglicky mluvící zemi nebo pokud jste se angličtinu učili ve školních lavicích, pak pravděpodobně základní pravidla znáte:

- Pokud slovo končí na S, X nebo Z, přidáme ES. Z bass se stává basses, z fax se stává faxes a waltz se mění na waltzes.
- Pokud slovo končí hlasitým H, přidáme ES. Pokud končí tichým H, přidáme jen S. Co to je hlasité H? Když H zkombinujeme s jinými písmeny, vydá zvuk, který slyšíme. Takže coach [kouč] se změní na coaches a z rash [reš] se stane rashes, protože při vyslování slyšíme zvuky pro CH [č] a SH [š]. Ale z cheetah [číta] se stane cheetahs, protože H je zde tiché.
- Pokud slovo končí písmenem Y, které zní jako I, změníme Y na IES. Pokud se Y kombinuje se samohláskou tak, že zní jako něco jiného, pak pouze přidáme S. Vacancy se proto změní na vacancies, ale z day se stane days.
- Pokud všechno selhalo, přidáme S a doufáme, že to projde.

(No ano, existuje spousta výjimek. Z man se stává men a z woman zase women, ale human se mění na humans. Mouse přechází v mice a z louse je zase lice, ale house se mění v houses. Knife přechází v knives a z wife se stávají wives, ale lowlife se mění v lowlifes. A nechtějte, abych začal o slovech, která jsou sama svým množným číslem (tj. pomnožná), jako jsou sheep, deer a haiku.)

V jiných jazycích je to, samozřejmě, úplně jiné.

Pojďme si navrhnout pythonovskou knihovnu, která automaticky převádí anglická podstatná jména do množného čísla. Začneme s uvedenými čtyřmi pravidly. Ale myslete na to, že budeme nevyhnutelně muset přidávat další.

#### 6.2. Já vím jak na to! Použijeme regulární výrazy!

Takže se díváme na slova, což znamená (přinejmenším v angličtině), že se díváme na řetězce znaků. Pak tady máme pravidla, která nám říkají, že potřebujeme najít různé kombinace znaků a podle nich něco udělat. Vypadá to jako práce pro regulární výrazy!

- Kap. [1] Jde o regulární výraz, ale používá syntaxi, se kterou jste se v kapitole <u>Regulární výrazy</u> nesetkali. Hranaté závorky znamenají "napasuj se přesně na jeden z těchto znaků". Takže [sxz] znamená "s nebo x nebo z", ale jenom jeden z nich. Znak \$ by vám měl být povědomý. Vyjadřuje shodu s koncem řetězce. Když to dáme dohromady, pak tento regulární výraz testuje, zda noun (podstatné jméno) končí znakem s, x nebo z.
  - [2] Funkce re.sub() provádí náhrady v řetězci, které jsou založeny na použití regulárního výrazu.

Podívejme se na náhrady předepsané regulárním výrazem podrobněji.

```
>>> import re
>>> re.search('[abc]', 'Mark') [1]
<_sre.SRE_Match object at 0x001C1FA8>
>>> re.sub('[abc]', 'o', 'Mark') [2]
'Mork'
>>> re.sub('[abc]', 'o', 'rock') [3]
'rook'
>>> re.sub('[abc]', 'o', 'caps') [4]
'oops'
```

- Obsahuje řetězec Mark znak a, b nebo c? Ano, obsahuje a.
- [2] Fajn. Teď najdi a, b nebo c a nahraď ho znakem o. Z Mark se stane Mork.
- [3] Stejná funkce změní rock na rook.
- Mohli byste si myslet, že stejná funkce změní caps na oaps, ale není tomu tak. Funkce re.sub nahrazuje všechny shody s regulárním výrazem, nejenom první z nich. Takže tento regulární výraz změní caps na oops, protože jak c, tak a se změní na o.

A teď zpět k funkci plural () (množné číslo)...

```
def plural(noun):
    if re.search('[sxz]$', noun):
        return re.sub('$', 'es', noun) [1]
    elif re.search('[^aeioudgkprt]h$', noun):
        return re.sub('$', 'es', noun)
    elif re.search('[^aeiou]y$', noun):
        return re.sub('y$', 'ies', noun)
    else:
        return noun + 's'
```

- Zde nahrazujeme konec řetězce (shoda s předpisem \$) řetězcem es. Jinými slovy, přidáváme es na konec řetězce. Stejného efektu byste mohli dosáhnout konkatenací řetězců (spojením), například použitím noun + 'es'. Ale z důvodu, které budou jasnější později, jsem se rozhodl každé pravidlo realizovat pomocí regulárního výrazu.
- Teď se pořádně podívejte na následující novinku. Znak ^ uvedený v hranatých závorkách na začátku má speciální význam negaci. Zápis [^abc] znamená "libovolný znak s výjimkou a, b nebo c". Takže [^aeioudgkprt] znamená libovolný znak s výjimkou a, e, i, o, u, d, g, k, p, r nebo t. Tento znak musí být následován znakem h a koncem řetězce. Hledáme slova, která končí písmenem H a ve kterých je H slyšet.
- Stejně postupujeme v tomto případě: napasuj se na slova, která končí písmenem Y, kde předcházejícím znakem není a, e, i, o nebo u. Hledáme slova, která končí písmenem Y, které zní jako I.

Podívejme se na regulární výrazy s negací podrobněji.

```
>>> import re
>>> re.search('[^aeiou]y$', 'vacancy') [1]
<_sre.SRE_Match object at 0x001C1FA8>
>>> re.search('[^aeiou]y$', 'boy') [2]
>>>
>>> re.search('[^aeiou]y$', 'day')
>>>
>>> re.search('[^aeiou]y$', 'pita') [3]
>>>
```

- vacancy tomuto regulárnímu výrazu vyhovuje, protože končí na cy a c nepatří mezi a, e, i, o nebo u.
- boy k regulárnímu výrazu nepasuje, protože končí oy a regulárním výrazem jsme přímo řekli, že před znakem y nemůže být o. Nepasuje ani day, protože končí na ay.
- [3] pita nevyhovuje také, protože nekončí na y.

```
>>> re.sub('y$', 'ies', 'vacancy')
'vacancies'
>>> re.sub('y$', 'ies', 'agency')
'agencies'
>>> re.sub('([^aeiou])y$', r'\lies', 'vacancy')
'vacancies'
```

- Tento regulární výraz mění vacancy na vacancies a agency na agencies, což jsme chtěli. Všimněte si, že by změnil také boy na boies, ale k tomu uvnitř funkce nikdy nedojde, protože provedení re.sub je podmíněno výsledkem předchozího re.search.
- Když už jsme u toho, chtěl bych upozornit, že uvedené dva regulární výrazy (jeden, který rozhoduje o uplatnění pravidla, a druhý, který ho realizuje) můžeme zkombinovat do jednoho. Vypadalo by to nějak takto. S většinou výrazu už byste neměli mít problém. Používáme zapamatovanou skupinu, o které jsme si povídali v případové studii zabývající se analýzou telefonních čísel. Skupina se používá k zapamatování si znaku, který se nachází před písmenem y. V řetězci s náhradou se pak používá nový syntaktický prvek \1, který znamená: "Máš tu první zapamatovanou skupinu? Vlož ji sem." V tomto případě se před y zapamatovalo c. V okamžiku substituce se na místo c vloží c a y se nahradí ies. (Pokud pracujete s více než jednou zapamatovanou skupinou, můžete použít \2 a \3 a tak dále.)

Náhrady pomocí regulárních výrazů jsou velmi mocné a syntaxe \1 je činí ještě mocnějšími. Ale zkombinování celé operace do jednoho regulárního výrazu snižuje čitelnost a navíc toto řešení nevyjadřuje přímočaře způsob popisu pravidla pro vytváření množného čísla. Původně jsme pravidlo vyjádřili ve stylu "pokud slovo končí S, X nebo Z, pak přidáme ES". Když se podíváte na zápis funkce, vidíte dva řádky kódu, které říkají "jestliže slovo končí S, X nebo Z, pak přidej ES". Přímočařeji už to snad ani vyjádřit nejde.

#### 6.3. Seznam funkcí

Teď přidáme úroveň abstrakce. Začali jsme definicí seznamu pravidel: Jestliže platí tohle, udělej tamto, v opačném případě přejdi k dalšímu pravidlu. Dočasně zkomplikujeme jednu část programu, abychom mohli zjednodušit jinou.

```
import re

def match_sxz(noun):
    return re.search('[sxz]$', noun)

def apply_sxz(noun):
    return re.sub('$', 'es', noun)
```

```
def match_h(noun):
    return re.search('[^aeioudgkprt]h$', noun)
def apply_h(noun):
    return re.sub('$', 'es', noun)
def match_y(noun):
                                                [1]
    return re.search('[^aeiou]y$', noun)
def apply_y(noun):
                                                 [2]
    return re.sub('y$', 'ies', noun)
def match_default(noun):
    return True
def apply_default(noun):
    return noun + 's'
rules = ((match_sxz, apply_sxz),
                                                [3]
         (match_h, apply_h),
         (match_y, apply_y),
         (match_default, apply_default)
         )
def plural(noun):
    for matches_rule, apply_rule in rules:
                                                [4]
        if matches_rule(noun):
            return apply_rule(noun)
```

- V tomto okamžiku má každé rozhodovací (match) pravidlo svou vlastní funkci, která vrací výsledek volání funkce re.search().
- [2] Každé aplikační pravidlo má také svou vlastní funkci, která volá funkci re.sub() realizující příslušný způsob vytvoření množného čísla.
- [3] Místo jedné funkce (plural()) s mnoha pravidly teď máme datovou strukturu rules (pravidla), která je posloupností dvojic funkcí.
- A protože pravidla byla rozbita do podoby oddělené datové struktury, může být nová funkce plural() zredukována na pár řádků kódu. V cyklu for můžeme z datové struktury rules po dvojicích vybírat rozhodovací a aplikační pravidla (jedno rozhodovací a jedno aplikační). Při prvním průchodu cyklem for nabude matches\_rule hodnoty match\_sxz a apply\_rule hodnoty apply\_sxz. Při druhém průchodu (za předpokladu, že se tak daleko dostaneme) bude proměnné matches\_rule přiřazena match\_h a proměnné apply\_rule bude přiřazena apply\_h. Je zaručeno, že funkce nakonec něco vrátí, protože poslední rozhodovací funkce (match\_default) vrací prostě True. To znamená, že se provede odpovídající aplikační pravidlo (apply\_default).

#### Proměnná "rules" je posloupností dvojic funkcí.

Funkčnost této techniky je zaručena tím, že v Pythonu je objektem všechno, včetně funkcí. Datová struktura rules obsahuje funkce — nikoliv jména funkcí, ale skutečné objekty funkcí. Když v cyklu for dojde k jejich přiřazení, stanou se z proměnných matches\_rule a apply\_rule skutečné funkce, které

můžeme volat. Při prvním průchodu cyklu for je to stejné, jako kdyby se volala funkce matches\_sxz(noun). A pokud by vrátila objekt odpovídající shodě, zavolala by se funkce apply\_sxz(noun).

Pokud se vám přidaná úroveň abstrakce jeví jako matoucí, zkuste si cyklus uvnitř funkce rozepsat a shodu rozpoznáte snadněji. Celý cyklus for je ekvivalentní následujícímu zápisu:

```
def plural(noun):
    if match_sxz(noun):
        return apply_sxz(noun)
    if match_h(noun):
        return apply_h(noun)
    if match_y(noun):
        return apply_y(noun)
    if match_default(noun):
        return apply_default(noun)
```

Výhodou je, že funkce plural() se zjednodušila. Přebírá sadu pravidel, která mohla být definována kdekoliv, a prochází jimi zobecněným způsobem.

- 1. Získej rozhodovací pravidlo (match rule).
- 2. Došlo ke shodě? Tak volej aplikační pravidlo a vrať výsledek.
- 3. Nedošlo ke shodě? Přejdi ke kroku 1.

Pravidla mohou být definována kdekoliv, jakýmkoliv způsobem. Funkci plural() je to jedno.

Dobrá, ale bylo vůbec přidání úrovně abstrakce k něčemu dobré? No, zatím ne. Zvažme, co to znamená, když k funkci chceme přidat nové pravidlo. V prvním příkladu by to znamenalo přidat do funkce plural() příkaz if. V tomto druhém příkladu by to vyžadovalo přidání dalších dvou funkcí match\_foo() a apply\_foo(). Pak bychom museli určit, do kterého místa posloupnosti rules má být dvojice s rozhodovací a aplikační funkcí zařazena (poloha vůči ostatním pravidlům).

Ale to jsme již jen krůček od následující podkapitoly. Pojďme na to...

#### 6.4. Seznam vzorků

Ono ve skutečnosti není nezbytné, abychom pro každé rozhodovací a aplikační pravidlo definovali samostatné pojmenované funkce. Nikdy je nevoláme přímo. Přidáváme je do posloupnosti rules a voláme je přes tuto strukturu. Každá z těchto funkcí navíc odpovídá jednomu ze dvou vzorů. Všechny rozhodovací funkce volají re.search() a všechny aplikační funkce volají re.sub(). Rozložme tyto vzory tak, abychom si usnadnili budování nových pravidel.

#### import re

```
def build_match_and_apply_functions(pattern, search, replace):
    def matches_rule(word):
        return re.search(pattern, word)
    def apply_rule(word):
        return re.sub(search, replace, word)
    return (matches_rule, apply_rule)
[3]
```

- build\_match\_and\_apply\_functions() je funkce, která vytváří další funkce dynamicky. Přebírá argumenty pattern, search a replace. Pak definuje rozhodovací funkci matches\_rule(), která volá re.search() s vzorkem pattern, který byl předán funkci build\_match\_and\_apply\_functions(), a se slovem word, které se předává právě budované funkci matches\_rule(). Ty jo!
- Aplikační funkce se vytváří stejným způsobem. Aplikační funkce přebírá jeden parametr a volá re.sub() s argumenty search a replace, které byly předány funkci build\_match\_and\_apply\_functions(), a s parametrem word, který se předává právě budované funkci apply\_rule(). Této technice, kdy se uvnitř dynamicky budované funkce použijí vnější hodnoty, se říká uzávěr (closure). Uvnitř budované aplikační funkce v podstatě definujeme konstanty. Funkce přebírá jeden parametr (word), potom se chová podle něj, ale také podle dalších dvou hodnot (search a replace), které platily v době definice aplikační funkce.
- Nakonec funkce build\_match\_and\_apply\_functions() vrátila dvojici hodnot dvě funkce, které jsme právě vytvořili. Konstanty, které jsme uvnitř těchto funkcí definovali (pattern uvnitř funkce matches\_rule() a search a replace uvnitř funkce apply\_rule()), v nich zůstávají uzavřené dokonce i po návratu z funkce build\_match\_and\_apply\_functions(). To je prostě špica!

Pokud se vám to zdá neuvěřitelně matoucí (a to by mělo, protože to je fakt ujeté), může se to vyjasnit, když uvidíte, jak se to používá.

- Naše pravidla (rules) pro tvorbu množného čísla jsou nyní definována jako n-tice trojic řetězců (ne funkcí). Prvním řetězcem v každé skupině je regulární výraz, který se bude používat v re. search() pro rozhodování, zda se toto pravidlo uplatňuje. Druhý a třetí řetězec ve skupině jsou výrazy pro vyhledání a náhradu, které se použijí v re. sub() pro aplikaci pravidla, které sloveso převede do množného čísla.
- U záložního pravidla došlo k drobné změně. Pokud v předchozím příkladu nebylo nalezeno žádné ze specifičtějších pravidel, vracela funkce match\_default() hodnotu True, což znamenalo, že se na konec slova jednoduše přidá s. Tento dosahuje stejné funkčnosti trochu jinak. Poslední regulární výraz zjišťuje, jestli slovo končí (\$ odpovídá konci řetězce). A samozřejmě, každý řetězec končí (dokonce i prázdný řetězec), takže shoda s tímto výrazem je nalezena vždy. Tento přístup tedy plní stejný účel jako funkce match\_default(), která vždycky vracela True. Pokud nepasuje žádné specifičtější pravidlo, zajistí přidání s na konec daného slova.
- Tento řádek je magický. Přebírá řetězce z posloupnosti patterns a mění je na posloupnost funkcí. Jak to dělá? "Zobrazením" řetězců prostřednictvím funkce build\_match\_and\_apply\_functions(). To znamená, že se vezme každá trojice řetězců a ty se předají jako argumenty funkci build\_match\_and\_apply\_functions(). Funkce build\_match\_and\_apply\_functions() vrátí dvojici funkcí. To znamená, že struktura rules získá funkčně shodnou podobu jako v předchozím příkladu seznam dvojic, kde každá obsahuje dvě funkce. První funkce je rozhodovací (match; pasovat) a volá re.search(), druhá funkce je aplikační a volá re.sub().

Skript zakončíme hlavním vstupním bodem, funkcí plural().

```
def plural(noun):
    for matches_rule, apply_rule in rules:
        if matches_rule(noun):
            return apply_rule(noun)
```

A protože je seznam rules stejný jako v předchozím příkladu (a to opravdu je), nemělo by být žádným překvapením, že se funkce plural() vůbec nezměnila. Je zcela obecná. Přebírá seznam funkcí realizujících pravidla a volá je v uvedeném pořadí. Nestará se o to, jak jsou pravidla definována. V předcházejícím příkladu byla definována jako pojmenované funkce. Teď jsou funkce pravidel budovány dynamicky zobrazením řetězců ze vstupního seznamu voláním funkce build\_match\_and\_apply\_functions(). Na tom ale vůbec nezáleží. Funkce plural() pracuje stále stejným způsobem.

#### 6.5. Soubor vzorků

Jsme v situaci, kdy už jsme rozpoznali veškeré duplicity v kódu a přešli jsme na dostatečnou úroveň abstrakce. To nám umožnilo definovat pravidla pro vytváření množného čísla v podobě seznamu řetězců. Další logický krok spočívá v uložení těchto řetězců v odděleném souboru. Pravidla (v podobě řetězců) pak mohou být udržována odděleně od kódu, který je používá.

Nejdříve vytvořme textový soubor, který obsahuje požadovaná pravidla. Nebudeme používat žádné efektní datové struktury. Stačí nám tři sloupce řetězců oddělené bílými znaky (whitespace; zde mezery nebo tabulátory). Soubor nazveme plural4-rules.txt.

Teď se podívejme na to, jak můžeme soubor s pravidly použít.

```
import re
```

Kap.

```
def build_match_and_apply_functions(pattern, search, replace):
                                                                            [1]
    def matches_rule(word):
        return re.search(pattern, word)
    def apply_rule(word):
        return re.sub(search, replace, word)
    return (matches_rule, apply_rule)
rules = []
with open('plural4-rules.txt', encoding='utf-8') as pattern_file:
                                                                            [2]
    for line in pattern_file:
                                                                            [3]
        pattern, search, replace = line.split(None, 3)
                                                                            [4]
        rules.append(build_match_and_apply_functions(
                                                                            [5]
                pattern, search, replace))
```

- Funkce build\_match\_and\_apply\_functions() se nezměnila. Pro dynamické vytvoření funkcí, které používají proměnné definované vnější funkcí, pořád používáme uzávěry.
- Globální funkce open() otvírá soubor a vrací souborový objekt. V tomto případě otvíráme soubor, který obsahuje vzorky řetězců pro převádění podstatných jmen do množného čísla. Příkaz with vytváří takzvaný kontext. Jakmile blok příkazu with skončí, Python soubor automaticky uzavře, a to i v případě, kdyby byla uvnitř bloku with vyvolána výjimka. O blocích with a o souborových objektech se dozvíte více v kapitole Soubory.
- Obrat for line in <souborový\_objekt> čte data z otevřeného souborového objektu řádek po řádku a přiřazuje text do proměnné line (řádek). O čtení ze souboru se dozvíte více v kapitole <u>Soubory</u>.
- [4] Každý řádek souboru obsahuje tři hodnoty, ale jsou oddělené bílými znaky (tabulátory nebo mezerami, na tom nezáleží). Rozdělíme je použitím řetězcové metody split(). Prvním argumentem metody split() je None, což vyjadřuje požadavek "rozdělit v místech posloupností bílých znaků (tabulátorů nebo mezer, na tom nezáleží)". Druhým argumentem je hodnota 3, což znamená "rozdělit na místě bílých znaků maximálně 3krát a zbytek řádku ponechat beze změny". Například řádek [sxz]\$ \$ es bude rozložen na seznam ['[sxz]\$', '\$', 'es']. To znamená,

[5]

že proměnná pattern získá hodnotu '[sxz]\$', proměnná search hodnotu '\$' a proměnná replace hodnotu 'es'. V tak krátkém řádku kódu se skrývá docela hodně síly.

Nakonec předáme pattern, search a replace funkci build\_match\_and\_apply\_functions(), která vrátí dvojici funkcí. Tuto dvojici připojíme na konec seznamu pravidel, takže nakonec bude rules uchovávat seznam rozhodovacích a aplikačních funkcí, které potřebuje funkce plural().

Zdokonalení spočívá v tom, že jsme pravidla pro vytváření množného čísla podstatných jmen oddělili do vnějšího souboru, který může být udržován odděleně od kódu, který pravidla využívá. Kód se stal kódem, z dat jsou data a život je krásnější.

#### 6.6. Generátory

Nebylo by skvělé, kdybychom měli obecnou funkci plural(), která si umí sama zpracovat soubor s pravidly? Získala by pravidla, zkontrolovala by, které se má uplatnit, provedla by příslušné transformace, přešla by k dalšímu pravidlu. To je to, co bychom po funkci plural() chtěli. A to je to, co by funkce plural() měla dělat.

```
def rules(rules_filename):
    with open(rules_filename, encoding='utf-8') as pattern_file:
        for line in pattern_file:
            pattern, search, replace = line.split(None, 3)
            yield build_match_and_apply_functions(pattern, search, replace)

def plural(noun, rules_filename='plural5-rules.txt'):
    for matches_rule, apply_rule in rules(rules_filename):
        if matches_rule(noun):
            return apply_rule(noun)
    raise ValueError('no matching rule for {0}'.format(noun))
```

Jak sakra funguje tohle? Podívejme se nejdříve na interaktivní příklad.

```
entering make_counter
>>> next(counter)
                                            [5]
incrementing x
>>> next(counter)
                                            [6]
incrementing x
4
```

- [1] Přítomnost klíčového slova yield v make\_counter znamená, že nejde o obyčejnou funkci. Jde o speciální druh funkce, která generuje hodnoty jednu po druhé. Můžeme si ji představit jako funkci, která umí při dalším volání pokračovat v činnosti. Když ji zavoláme, vrátí nám generátor, který můžeme použít pro generování posloupnosti hodnot x.
- [2] Instanci generátoru make\_counter vytvoříme tím, že ji zavoláme jako každou jinou funkci. Poznamenejme, že tím ve skutečnosti nedojde k provedení kódu funkce. Jde to poznat i podle toho, že se na prvním řádku funkce make\_counter() volá print(), ale nic se zatím nevytisklo.
- [3] Funkce make\_counter() vrátila objekt generátoru.
- Funkce next() přebírá objekt generátoru a vrací jeho další hodnotu. Při prvním volání funkce [4] next() pro generátor counter se provede kód z make\_counter() až do prvního příkazu yield a vrátí se vyprodukovaná hodnota. V našem případě to bude 2, protože jsme generátor vytvořili voláním make\_counter(2).
- Při opakovaném volání funkce next() pro stejný generátorový objekt se dostáváme přesně do [5] místa, kde jsme minule skončili, a pokračujeme až do místa, kdy znovu narazíme na příkaz yield. Při provedení yield jsou všechny proměnné, lokální stav a další věci uloženy a při dalším volání next() jsou obnoveny. Další řádek kódu, který čeká na provedení, volá funkci print(), která vytiskne incrementing x (zvyšuji hodnotu x). Poté je proveden příkaz x = x + 1. Pak se provede další obrátka cyklu while a hned se narazí na příkaz yield x. Ten uloží stav všeho možného a vrátí aktuální hodnotu proměnné x (v tomto okamžiku 3).
- [6] Při druhém volání next(counter) se vše opakuje, ale tentokrát má x hodnotu 4.

Protože make\_counter definuje nekonečný cyklus, mohli bychom pokračovat teoreticky do nekonečna a docházelo by k neustálému zvyšování proměnné x a vracení její hodnoty. Místo toho se ale podívejme na užitečnější použití generátorů.

#### Generátor Fibonacciho posloupnosti 6.6.1.

```
def fib(max):
    a, b = 0, 1
                                    [1]
    while a < max:
        yield a
                                    [2]
         a, b = b, a + b
                                    [3]
```

- Fibonacciho posloupnost je řada čísel, kde každé další číslo je součtem dvou předchozích. Začíná hodnotami 0 a 1, zpočátku roste pomalu a pak rychleji a rychleji. Na začátku potřebujeme dvě proměnné: a s počáteční hodnotou 0 a b s počáteční hodnotou 1.
- Proměnná a obsahuje aktuální číslo posloupnosti, takže hodnotu vyprodukujeme (yield).
- Proměnná b představuje další číslo v posloupnosti, takže je přiřadíme do a, ale současně vypočteme další hodnotu (a + b) a přiřadíme ji do b pro pozdější použití. Poznamenejme, že se to děje paralelně. Pokud má a hodnotu 3 a b hodnotu 5, pak a, b = b, a + b nastaví a na 5 (předchozí hodnota b) a b na 8 (součet předchozí hodnoty a a b).

#### "yield" funkci zastaví. "next()" pokračuje od místa zastavení.

Dostali jsme funkci, která postupně chrlí Fibonacciho čísla. Mohli byste to popsat i rekurzivním řešením, ale tento způsob je čitelnější. A navíc dobře funguje při použití v cyklech for.

- Generátor jako fib() můžete v cyklu for použít přímo. Cyklus for automaticky získává hodnoty generátoru fib() voláním funkce next() a přiřazuje je do proměnné cyklu n.
- Při každé obrátce cyklu for získává proměnná n novou hodnotu, která je uvnitř fib() produkována příkazem yield. Stačí ji jen vytisknout. Jakmile fib() dojdou čísla (a nabude hodnoty větší než max, což je v našem případě 1000), cyklus for elegantně skončí.
- Toto je užitečný obrat. Funkci list() předáme generátor. Funkce projde (iteruje přes) všechny jeho hodnoty (stejně jako tomu bylo v předchozím příkladu u cyklu for) a vrátí seznam všech generovaných hodnot.

#### 6.6.2. Generátor pravidel pro množné číslo

Vraťme se k plural5. py a podívejme se, jak tato verze funkce plural() pracuje.

```
def rules(rules_filename):
    with open(rules_filename, encoding='utf-8') as pattern_file:
        for line in pattern_file:
            pattern, search, replace = line.split(None, 3) [1]
            yield build_match_and_apply_functions(pattern, search, replace) [2]
```

```
def plural(noun, rules_filename='plural5-rules.txt'):
    for matches_rule, apply_rule in rules(rules_filename):
        if matches_rule(noun):
            return apply_rule(noun)
        raise ValueError('no matching rule for {0}'.format(noun))
```

- Není v tom žádná magie. Vzpomeňte si, že řádky souboru s pravidly obsahují vždy tři hodnoty oddělené bílými znaky. Takže použijeme line.split(None, 3) k získání tří "sloupců" a jejich hodnoty přiřadíme do tří lokálních proměnných.
- A pak vyprodukujeme výsledek (yield). Jaký výsledek? Dvojici funkcí, které byly dynamicky vytvořeny naší starou známou funkcí build\_match\_and\_apply\_functions() (je stejná jako v předchozích příkladech). Řečeno jinak, rules() je generátor, který na požádání produkuje rozhodovací a aplikační funkce.
- Protože rules() je generátor, můžeme jej přímo použít v cyklu for. Při první obrátce cyklu for zavoláme funkci rules(), která otevře soubor se vzorky, načte první řádek, na základě vzorků uvedených na řádku dynamicky vybuduje rozhodovací funkci a aplikační funkci a tyto funkce vrátí (yield). Ale během druhé obrátky cyklu for se dostáváme přesně do místa, kde jsme kód rules() opustili (což je uprostřed cyklu for line in pattern\_file). První věcí, která se provede, bude načtení řádku souboru (který je pořád otevřen). Na základě vzorků z tohoto řádku souboru se dynamicky vytvoří další rozhodovací a aplikační funkce a tato dvojice se vrátí (yield).

Co jsme vlastně proti verzi 4 získali navíc? Startovací čas. Ve verzi 4 se při importu modulu plural4 — než jsme mohli vůbec uvažovat o volání funkce plural() — načítal celý soubor vzorků a budoval se seznam všech možných pravidel. Při použití generátorů můžeme vše dělat na poslední chvíli. Přečteme si první pravidlo, vytvoříme funkce a vyzkoušíme je. Pokud to funguje, nemusíme číst zbytek souboru nebo vytvářet další funkce.

A co jsme ztratili? Výkonnost! Generátor rules() startuje znovu od začátku pokaždé, když voláme funkci plural(). To znamená, že soubor se vzorky musí být znovu otevřen a musíme číst od začátku, jeden řádek po druhém.

Chtělo by to nějak získat to nejlepší z obou řešení: minimální čas při startu (žádné provádění kódu při import) a maximální výkonnost (žádné opakované vytváření funkcí). Ale pokud nebudeme muset číst stejné řádky dvakrát, bylo by dobré, aby pravidla mohla zůstat v odděleném souboru (protože kód je kód a data jsou data).

Abychom toho dosáhli, budeme muset vytvořit svůj vlastní iterátor. Ale předtím se musíme naučit něco o pythonovských třídách.

### 6.7. Přečtěte si

- PEP 255: Simple Generators
  - (www.python.org/dev/peps/pep-0255/)
- Understanding Python's "with" statement
  - (http://effbot.org/zone/python-with-statement.htm)
- Closures in Python
  - (http://ynniv.com/blog/2007/08/closures-in-python.html)
- Fibonacci numbers
  - (http://en.wikipedia.org/wiki/Fibonacci\_number)
- English Irregular Plural Nouns

(www2.gsu.edu/~wwwesl/egw/crump.htm)

7. Kapitola

- "East is East, and West is West, and never the twain shall meet." (Východ je východ, západ je západ a ta dvojice se nikdy nesetká.)
  - Rudyard Kipling

# 7. Třídy a iterátory

#### 7. Třídy a iterátory — 159

- 7.1. Ponořme se **161**
- 7.2. Definice <u>tříd</u> **161**
- 7.2.1. Metoda \_\_init\_\_() 162
- 7.3. Vytváření instancí tříd 163
- 7.4. Členské proměnné 163
- 7.5. Fibonacciho iterátor 164
- 7.6. Iterátor pro pravidla množného čísla **166**
- 7.7. Přečtěte si **172**

- 7.1 Ponořme se
- 7.2. Definice tříd

#### 7.1 Ponořme se

Iterátory jsou "tajnou omáčkou" Pythonu 3. Jsou všude, vše je na nich založeno, vždy zůstávají v pozadí, Kap. neviditelné. <u>Generátorové notace</u> jsou jednoduchou formou *iterátor*ů. Generátory jsou jednoduchou formou *iterátor*ů. Funkce, která produkuje hodnoty příkazem yield, je ukázkou pěkného a kompaktního způsobu vytvoření iterátoru, aniž bychom museli iterátor tvořit. Ukážu vám, co tím míním.

Vzpomínáte si na Fibonacciho generátor? Tady ho máme v podobě iterátoru vytvořeného od základu:

```
class Fib:
    '''iterator that yields numbers in the Fibonacci sequence'''

def __init__(self, max):
    self.max = max

def __iter__(self):
    self.a = 0
    self.b = 1
    return self

def __next__(self):
    fib = self.a
    if fib > self.max:
        raise StopIteration
    self.a, self.b = self.b, self.a + self.b
    return fib
```

Proberme si jeho kód řádek po řádku.

class Fib:

class? Česky se tomu říká třída. Ale co to je?

#### 7.2. Definice tříd

Python je plně objektově orientovaný. Můžete definovat své vlastní třídy, dědit ze svých vlastních nebo ze zabudovaných tříd a z definovaných tříd můžete vytvářet instance.

Třídu definujeme v Pythonu jednoduše. Nepoužívá se zde oddělená definice rozhraní — je to jako u funkcí. Prostě definujeme třídu a začneme psát její kód. Pythonovská třída začíná vyhrazeným slovem class, za kterým následuje jméno třídy. Z technického pohledu je to vše, co se vyžaduje, protože třída nemusí dědit z žádné jiné třídy.

class PapayaWhip: [1] pass [2]

- Inéno této třídy je PapayaWhip. Není odvozena od žádné jiné třídy. Jména tříd se obvykle zapisují s velkými písmeny u slov názvu, KazdeSlovoNazvuTakto. Ale je to jen konvence, není to závazné.
- Asi už jste odhadli, že vše uvnitř třídy je odsazené podobně jako kód uvnitř funkce, v příkazu if, u cyklu for nebo v případě jakéhokoliv jiného bloku kódu. Řádek, který není odsazen, už do třídy nepatří.

Třída PapayaWhip nedefinuje žádnou metodu ani atributy, ale ze syntaktických důvodů v definici něco být musí. Proto jsme zde použili příkaz pass. V Pythonu je toto slovo vyhrazeno a znamená "pokračuj dál, tady není nic k vidění". Je to příkaz, který nic nedělá. Hodí se nám právě v případech, kdy potřebujeme napsat funkci nebo třídu, která existuje, ale nic nedělá.

> Příkaz pass znamená v Pythonu totéž co prázdné složené závorky ({}) v jazycích Java nebo C.

Mnohé třídy dědí z jiných tříd, ale to není náš případ. Mnohé třídy definují metody, ale tato ne. Pythonovská třída nemusí mít nic, jen jméno. Obzvláště programátorům v C++ může přijít divné, že pythonovské třídy nemají explicitní konstruktory a destruktory. Ačkoliv se to nevyžaduje, pythonovské třídy mohou mít něco, co se konstruktoru podobá. Je to metoda \_\_init\_\_().

#### 7.2.1. Metoda \_\_init\_\_()

Následující příklad ukazuje inicializaci třídy Fib s využitím metody \_\_init\_\_.

#### class Fib:

```
'''iterator that yields numbers in the Fibonacci sequence'''

def __init__(self, max): [2]
```

- Třídy mohou (a měly by) mít své dokumentační řetězce stejně jako moduly a funkce.
- Metoda \_\_init\_\_() je zavolána bezprostředně po vytvoření instance třídy. Svádí nás to, abychom ji nazývali "konstruktorem" třídy, ale z technického hlediska to není pravda. Svádí nás to, protože vypadá jako C++ konstruktor (konvence říká, že by metoda \_\_init\_\_() měla být v definici třídy uvedena jako první), chová se jako konstruktor (je to první kousek kódu, který se v nově vytvořené instanci třídy provádí) a vůbec. Chyba! V době volání metody \_\_init\_\_() už byl objekt zkonstruován (už existoval) a na novou instanci třídy už máme platný odkaz.

Prvním argumentem metody třídy je vždy odkaz na aktuální instanci třídy a platí to i pro metodu \_\_init\_\_(). Podle konvence je tento argument pojmenován self. Plní roli vyhrazeného slova, jakým je this v jazycích c++ nebo Java, ale v Pythonu není self vyhrazeným slovem. Je to jen konvenční pojmenování. Přesto jej, prosím vás, nenazývejte nikdy jinak než self. Jde o velmi silnou konvenci.

#### 7.4. Členské proměnné

Uvnitř metody \_\_init\_\_() odkazuje self na nově vytvořený objekt. U ostatních metod třídy odkazuje na instanci třídy, jejíž metoda byla zavolána. V okamžiku definice metody musíme uvést self explicitně. Ale v okamžiku volání metody už tento argument neuvádíme. Python ho přidá za nás automaticky.

#### 7.3. Vytváření instancí tříd

Vytváření instancí tříd je v Pythonu přímočaré. Jednoduše zavoláme třídu, jako kdyby to byla funkce, a předáme jí argumenty, které vyžaduje metoda \_\_init\_\_(). Vrátí se nám nově vytvořený objekt.

- Vytváříme instanci třídy Fib (definované v modulu fibonacci2) a nově vytvořenou instanci přiřazujeme do proměnné fib. Předáváme jeden parametr (100), který se při volání metody \_\_init\_\_() třídy Fib stane jejím argumentem max.
- [2] fib je nyní instancí třídy Fib.
- Každá instance třídy má zabudovaný atribut \_\_class\_\_, který odkazuje na třídu objektu. Programátoři v Javě možná znají třídu Class. Ta poskytuje metody jako getName() a getSuperclass(), které nám zpřístupňují metainformace o objektu. V Pythonu je tento druh metadat přístupný prostřednictvím atributů, ale základní myšlenka je stejná.
- Dokumentační řetězec instance můžeme zpřístupnit stejně jako u funkce nebo u modulu. Všechny instance třídy sdílejí stejný docstring.
- > Novou instanci třídy v Pythonu vytvoříme jednoduše zavoláním třídy, jako kdyby to byla funkce. Nenajdeme zde žádný explicitní operátor new, jako je tomu u jazyků c++ nebo Java.

## 7.4. Členské proměnné

Pokračujeme k dalšímu řádku:

```
class Fib:
    def __init__(self, max):
        self.max = max [1]
```

[1] Co to je self.max? Jde o členskou proměnnou (nebo také instanční proměnnou nebo proměnnou instance). Je to něco zcela jiného než argument max, který byl předán metodě \_\_init\_\_(). self. max je "globální" v rámci instance. To znamená, že k této proměnné můžeme přistupovat z jiných metod.

```
class Fib:
    def __init__(self, max):
        self.max = max
                                   [1]
    def __next__(self):
        fib = self.a
        if fib > self.max:
                                   [2]
      self.max je definována metodou __init__()...
[1]
[2]
      ...a odkazujeme se na ni v metodě __next__().
```

Členské proměnné jsou pro každou instanci třídy specifické. Pokud například vytvoříme dvě instance třídy Fib s různými hodnotami maxima, bude si každá z nich pamatovat svou vlastní hodnotu.

```
>>> import fibonacci2
>>> fib1 = fibonacci2.Fib(100)
>>> fib2 = fibonacci2.Fib(200)
>>> fib1.max
100
>>> fib2.max
200
```

#### 7.5. Fibonacciho iterátor

Všechny tři z uvedených metod třídy, \_\_init\_\_, \_\_iter\_\_ a \_\_next\_\_, začínají a končí dvojicí znaků podtržení (\_). Proč zrovna takhle? Není v tom nic magického, ale obvykle to naznačuje, že jde o "speciální metody". Jedinou "speciální" věcí je na těchto speciálních metodách to, že se nevolají přímo. Python je volá, když použijete nějaký jiný syntaktický obrat pro třídu nebo pro instanci třídy. Více o speciálních metodách v kapitole Jména speciálních metod.

Až teď jsme připraveni se naučit, jak se vytváří interátor. Iterátor je jednoduše třída, která definuje metodu \_\_iter\_\_().

```
class Fib:
                                                              [1]
    def __init__(self, max):
                                                              [2]
        self.max = max
    def __iter__(self):
                                                              [3]
        self.a = 0
        self.b = 1
        return self
    def __next__(self):
                                                              [4]
        fib = self.a
        if fib > self.max:
             raise StopIteration
                                                              [5]
        self.a, self.b = self.b, self.a + self.b
        return fib
                                                              [6]
```

- Abychom vybudovali iterátor od základů, musíme z Fib udělat třídu, a ne funkci.
- "Volání" Fib(max) ve skutečnosti znamená vytvoření instance této třídy a zavolání její metody \_\_init\_\_() s argumentem max. Metoda \_\_init\_\_() uloží maximální hodnotu do členské proměnné, takže se na ni mohou později odkazovat ostatní metody.
- Metoda \_\_iter\_\_() se volá, kdykoliv někdo zavolá iter(fib). (Jak uvidíme za minutku, cyklus for ji volá automaticky. Ale vy sami ji můžete volat také, ručně.) Po provedení inicializace na začátku iterace (v tomto případě jde o nastavení počátečního stavu dvou počítadel self.a a self.b) může metoda \_\_iter\_\_() vrátit libovolný objekt, který implementuje metodu \_\_next\_\_(). V našem případě (a ve většině případů) metoda \_\_iter\_\_() vrátí jednoduše self, protože tato třída implementuje svou vlastní metodu \_\_next\_\_().
- [4] Metoda \_\_next\_\_() se volá vždy, když někdo zavolá funkci next() s iterátorem instance třídy. Za minutku to bude dávat větší smysl.
- Když metoda \_\_next\_\_() vyvolá výjimku StopIteration, signalizuje tím volajícímu, že iterace skončila. Na rozdíl od většiny jiných výjimek se zde nesignalizuje chyba. Jde o běžnou situaci, která prostě znamená, že iterátor už nemá žádná data, která by generoval. Pokud je volajícím cyklus for, bude výjimka StopIteration zachycena a cyklus bude bezproblémově ukončen. (Jinými slovy, cyklus výjimku spolkne.) Toto malé kouzlo je ve skutečnosti klíčem k použití iterátorů v cyklech for.
- Vyprodukování další hodnoty provede iterátor tak, že metoda \_\_next\_\_() hodnotu jednoduše vrátí příkazem return. Nepoužívejte zde příkaz yield. Ten je pouze syntaktickým cukrátkem a má význam pouze v souvislosti s generátory. Zde vytváříme od základů svůj vlastní iterátor, proto budeme používat return.

Už jste úplně zmatení? Výborně. Podívejme se, jak budeme iterátor volat:

```
>>> from fibonacci2 import Fib
>>> for n in Fib(1000):
... print(n, end=' ')
0 1 1 2 3 5 8 13 21 34 55 89 144 233 377 610 987
```

Cože? Vždyť je to úplně stejné! V každém bajtu se to shoduje s voláním generátoru Fibonacciho posloupnosti (až na rozdíl jednoho velkého písmene). Ale jak je to možné?

Cykly for v sobě skrývají trochu magie. Odehrává se v nich následující:

- Cyklus for volá Fib(1000), jak je vidět z kódu. Vrací se instance třídy Fib. Říkejme jí třeba fib\_inst.
- Cyklus for potají a docela chytře volá funkci iter(fib\_inst), která vrátí objekt iterátoru.
   Říkejme mu třeba fib\_iter. V našem případě platí fib\_iter == fib\_inst, protože metoda \_\_iter\_\_() vrací self. Ale o tom cyklus for neví (a je mu to jedno).
- Za účelem "průchodu hodnotami" iterátoru volá cyklus for funkci next(fib\_iter), která
  zase volá metodu \_\_next\_\_() objektu fib\_iter. Ta provede výpočet dalšího Fibonacciho čísla
  a vrací hodnotu. Cyklus for hodnotu převezme, přiřadí ji do proměnné n a s touto hodnotou
  v n provede tělo cyklu.
- Jak cyklus for ví, kdy má skončit? To jsem rád, že jste se zeptali! Když next(fib\_iter) vyvolá
  výjimku StopIteration, cyklus for ji spolkne a spořádaně se ukončí. (Jakákoliv jiná výjimka
  se propustí a projeví se obvyklým způsobem.) A kde jsme zahlédli výjimku StopIteration?
  No přece v metodě \_\_next\_\_()!

#### 7.6. Iterátor pro pravidla množného čísla

```
Přišel čas na finále. Přepišme generátor pravidel pro množné číslo do podoby iterátoru.

class LazyRules:
    rules_filename = 'plural6-rules.txt'

def __init__(self):
    self.pattern_file = open(self.rules_filename, encoding='utf-8')
    self.cache = []

def __iter__(self):
    self.cache_index = 0
    return self
```

```
def __next__(self):
        self.cache_index += 1
        if len(self.cache) >= self.cache_index:
            return self.cache[self.cache_index - 1]
        if self.pattern_file.closed:
            raise StopIteration
        line = self.pattern_file.readline()
        if not line:
            self.pattern_file.close()
            raise StopIteration
        pattern, search, replace = line.split(None, 3)
        funcs = build_match_and_apply_functions(
            pattern, search, replace)
        self.cache.append(funcs)
        return funcs
rules = LazyRules()
```

Tohle je tedy třída, která implementuje metody \_\_iter\_\_() a \_\_next\_\_(), takže ji můžeme použít jako iterátor. Za koncem její definice se vytvoří instance třídy a přiřadí se do rules. To se stane jen jednou, při importu.

Proberme si zmíněnou třídu po kouscích.

```
class LazyRules:
    rules_filename = 'plural6-rules.txt'

def __init__(self):
    self.pattern_file = open(self.rules_filename, encoding='utf-8')
    self.cache = []
[1]
```

- [1] Když vytvoříme instanci třídy LazyRules (líná pravidla), otevře se soubor s definicemi vzorků, ale nic se z něj nečte. (K tomu dojde později.)
- Po otevření souboru se inicializuje vyrovnávací paměť (cache). Budeme ji používat později, během čtení řádků ze souboru vzorků (v metodě \_\_next\_\_()).

Než budeme pokračovat, podívejme se podrobněji na rules\_filename. Tato proměnná není definována uvnitř metody \_\_init\_\_(). Ve skutečnosti není definována uvnitř *žádné* metody. Je definována na úrovni třídy. Jde o *proměnnou třídy*. Ačkoliv k ní můžeme přistupovat stejným způsobem jako k nějaké členské proměnné (self.rules\_filename), sdílí ji všechny instance třídy LazyRules.

```
>>> import plural6
>>> r1 = plural6.LazyRules()
>>> r2 = plural6.LazyRules()
>>> r1.rules_filename
                                                           [1]
'plural6-rules.txt'
>>> r2.rules_filename
'plural6-rules.txt'
>>> r2.rules_filename = 'r2-override.txt'
                                                           [2]
>>> r2.rules_filename
'r2-override.txt'
>>> r1.rules_filename
'plural6-rules.txt'
>>> r2.__class__.rules_filename
                                                            [3]
'plural6-rules.txt'
>>> r2.__class__.rules_filename = 'papayawhip.txt'
                                                            [4]
>>> r1.rules_filename
'papayawhip.txt'
>>> r2.rules_filename
                                                            [5]
'r2-overridetxt'
```

- [1] Každá instance třídy dědí atribut rules\_filename s hodnotou definovanou na úrovni třídy.
- [2] Když změníme hodnotu tohoto atributu v jedné instanci, neovlivníme tím ostatní instance...
- ...a ani neovlivníme atribut třídy. K atributu třídy (v protikladu k atributu jednotlivých instancí) můžeme přistupovat prostřednictvím speciálního atributu \_\_class\_\_, který zpřístupňuje třídu jako takovou.
- Pokud změníte hodnotu atributu třídy, pak to ovlivní všechny instance, které tuto hodnotu dosud dědí (zde r1).
- [5] Instance, které tento atribut přepsaly (zde r2), ovlivněny nebudou.

#### Ale zpět k naší ukázce.

```
def __iter__(self): [1]
    self.cache_index = 0
    return self [2]
```

- [1] Metoda \_\_iter\_\_() bude volána pokaždé, když někdo (dejme tomu cyklus for) zavolá iter(rules).
- Jednou z věcí, kterou musí každá metoda \_\_iter\_\_() udělat, je vrácení iterátoru. V tomto případě se vrací self, čímž dáváme najevo, že tato třída definuje nějakou metodu \_\_next\_\_(), která se postará o vracení hodnot během iterace.

- [1] Metoda \_\_next\_\_() bude volána pokaždé, když někdo (dejme tomu cyklus for) zavolá next(rules). Smysl této metody pochopíme, když začneme od jejího konce a půjdeme pozpátku. Takže pojďme na to.
- Poslední část této funkce by vám měla být přinejmenším povědomá. Funkce build\_match\_and\_apply\_functions() se nezměnila. Je pořád stejná, jako vždycky byla.
- Jediný rozdíl spočívá v tom, že před vrácením rozhodovací a aplikační funkce (jsou uloženy v dvojici funcs) je nejdříve uložíme do self.cache.

#### Posuňme se zpět...

```
def __next__(self):
    .
    .
    .
    line = self.pattern_file.readline() [1]
    if not line: [2]
        self.pattern_file.close()
        raise StopIteration [3]
    .
    .
    .
    .
    .
    .
```

- Tady použijeme fintu se souborem pro trošku pokročilejší. Metoda readline() (poznámka: jednotné číslo, nikoliv množné readlines()) přečte z otevřeného souboru přesně jeden řádek. Přesněji řečeno, přečte další řádek. (Souborové objekty jsou také iterátory! Iterátory jsou všude, až po základy...)
- Pokud mohla readline() přečíst řádek do proměnné line, bude to neprázdný řetězec. Dokonce i kdyby soubor obsahoval prázdný řádek, skončí line jako jednoznakový řetězec '\n' (znak konce řádku). Pokud se v proměnné line opravdu nachází prázdný řetězec, znamená to, že soubor už neobsahuje žádné další řádky ke čtení.
- Když dosáhneme konce souboru, měli bychom soubor zavřít a vyvolat magickou výjimku
  StopIteration. Připomeňme si, že do tohoto bodu jsme se dostali, protože jsme potřebovali
  rozhodovací a aplikační funkci pro další pravidlo. Další pravidlo je definované dalším řádkem

7.6.

souboru... Ale další řádek už nemáme! Takže už nemáme co vrátit. Iterace skončila. (The iteration is over.  $\square$  The party's over...  $\square$ )

A jdeme pozpátku až k začátku metody \_\_next\_\_()...

- self.cache bude mít podobu seznamu funkcí, které potřebujeme pro rozhodování a aplikaci jednotlivých pravidel. (Přinejmenším tohle by vám mělo být povědomé!) V self.cache\_index se pamatuje, která další (už zapamatovaná) položka se má vrátit příště. Pokud jsme dosud nevyčerpali prostor se zapamatovanými položkami (tj. pokud je délka self.cache větší než self.cache\_index), pak jsme ji našli (cache hit)! Hurá! Rozhodovací a aplikační funkci můžeme vrátit z vyrovnávací paměti a nemusíme je budovat znovu.
- Na druhou stranu, pokud jsme na položku ve vyrovnávací paměti nenarazili a zároveň je souborový objekt už uzavřen (což se níže v kódu metody může stát jak jsme viděli v předcházející ukázce), pak už nemůžeme nic víc dělat. Pokud je soubor uzavřen, znamená to, že jsme jeho obsah vyčerpali. Už jsme přečetli každý jeho řádek a vybudovali jsme funkce pro rozhodování a pro aplikaci pro každý vzorek a uložili jsme je do vyrovnávací paměti. Soubor je vyčerpaný, vyrovnávací paměť je vyčerpaná, já jsem vyčerpaný. Počkat! Co? "Выдержай пионер" [vyděržaj pijaněr], už je to skoro hotové.

Když to dáme všechno dohromady, provádí se následující:

- V okamžiku importu modulu se vytvoří jediná instance třídy LazyRules, která je nazvaná rules (pravidla). Tato instance otevřela soubor se vzorky, ale nečetla z něj.
- V okamžiku, kdy se požaduje první dvojice funkcí pro rozhodování a pro aplikaci, dojde
  ke kontrole vyrovnávací paměti, ale zjistí se, že je prázdná. Takže se ze souboru přečte jeden
  řádek se vzorky, vybudují se podle něj funkce pro rozhodování a pro aplikaci a uloží se
  do vyrovnávací paměti.
- Dejme tomu, že vyhovělo úplně první pravidlo. Pokud tomu tak je, žádné další funkce pro rozhodování a aplikaci se nevytvářejí a ze souboru se nečtou žádné další řádky.
- Dále dejme tomu, že volající zavolá funkci plural() znovu, protože chce převést do množného čísla jiné slovo. Cyklus for ve funkci plural() zavolá iter(rules), což vede k nastavení inde-

- xu vyrovnávací paměti na začátek, ale nedojde k resetování otevřeného souborového objektu.
- Při prvním průchodu požádá cyklus for o hodnotu ze struktury rules, což vede k zavolání jeho metody \_\_next\_\_(). Ale v tomto okamžiku už vyrovnávací paměť obsahuje jediný pár funkcí pro rozhodování a pro aplikaci odpovídají vzorkům z prvního řádku souboru. Protože už byly vytvořeny a uloženy do vyrovnávací paměti při zpracování minulého slova, jsou z ní vybrány. Index do vyrovnávací paměti se zvýší a otevřený soubor zůstane nedotčen.
- Dejme tomu, že první pravidlo tentokrát nevyhovělo. Cyklus for udělá další obrátku a zeptá se na další hodnotu ze seznamu rules. Tím se podruhé aktivuje metoda \_\_next\_\_(). Tentokrát je ale vyrovnávací paměť vyčerpána, protože obsahovala jen jednu položku a my jsme požádali o druhou. Takže metoda \_\_next\_\_() pokračuje v činnosti. Z otevřeného souboru přečte další řádek, vybuduje podle něj rozhodovací a aplikační funkci a dvojici uloží do vyrovnávací paměti.
- Pokud pravidla budovaná z načítaných řádků souboru pro zadané slovo nevyhovují, pokračuje proces fázemi "přečti, vybuduj, ulož" dál. Jakmile se nalezne vhodné pravidlo před koncem souboru, jednoduše se použije a další načítání se zastaví. Soubor zůstane otevřený. Ukazatel do souboru zůstane tam, kde jsme přestali číst, a bude se čekat na další příkaz readline(). Ve vyrovnávací paměti se teď nachází více položek. Pokud znovu zahájíme vytváření množného čísla pro nové slovo, vyzkoušíme před případným čtením dalšího řádku souboru nejdříve všechny položky z vyrovnávací paměti.

Dosáhli jsme "množnočíselné" nirvány.

- 1. **Minimální startovací čas**. Jediné činnosti, které se při příkazu import provedou, jsou vytvoření jediné instance třídy a otevření souboru (ale nečte se z něj).
- 2. Maximální výkonnost. U předcházejícího příkladu bychom četli ze souboru a dynamicky budovali funkce pokaždé, když bychom chtěli vytvořit množné číslo zadaného slova. V této verzi dochází hned po vybudování funkcí k jejich uložení do vyrovnávací paměti a v nejhorším případě dojde k přečtení celého souboru jednou nezávisle na tom, z kolika slov tvoříme množné číslo.
- Oddělení kódu a dat. Všechny vzorky jsou uložené v odděleném souboru. Kód je kód, data jsou data a ta dvojice se nikdy nesetká.
- Je to opravdu nirvána? Inu, ano i ne. U příkladu s LazyRules musíme počítat s následujícím: soubor se vzorky se otevře (během \_\_init\_\_()) a zůstane otevřen, dokud nebude dosaženo posledního pravidla. Soubor se nakonec uzavře při ukončení Pythonu nebo po zrušení poslední instance třídy LazyRules, ale může to trvat velmi dlouho. Pokud je tato třída součástí dlouho běžícího procesu, nemusí interpret Pythonu skončit nikdy a také objekt třídy LazyRules nemusí být nikdy zrušen.

Dá se to obejít různými způsoby. Místo toho, aby byl soubor otevřen během \_\_init\_\_() a ponechán v otevřeném stavu pro čtení po jednom řádku, můžeme soubor otevřít, přečíst všechny řádky a soubor hned zavřít. Nebo můžeme soubor otevřít, přečíst jeden řádek s pravidlem, uložit pozici v souboru zjištěnou metodou tell() a soubor uzavřít. Později jej znovu otevřeme,

použijeme metodu seek() a pokračujeme ve čtení tam, kde jsme skončili. A nebo si s tím nebudeme dělat těžkou hlavu a prostě necháme soubor otevřený, jako to dělá tento příklad. Programování úzce souvisí s návrhem a návrh je založen na kompromisech a omezeních. Pokud bude soubor ponechán v otevřeném stavu příliš dlouho, může to vést k problému. Pokud místo toho vytvoříte komplikovanější kód, může to také vést k problému. Který z těchto problémů je větší, záleží na vašem vývojovém týmu, na vaší aplikaci a na provozním prostředí.

#### 7.7. Přečtěte si

- Iterator types
  - (http://docs.python.org/py3k/library/stdtypes.html)
- PEP 234: Iterators (www.python.org/dev/peps/pep-0234/)
- PEP 255: Simple Generators (www.python.org/dev/peps/pep-0255/)
- Generator Tricks for Systems Programmers (www.dabeaz.com/generators/)

"Great fleas have little fleas upon their backs to bite 'em, And little fleas have lesser fleas, and so ad infinitum."

(Veliké blechy maj malé své blechy, aby je kousaly do jejich zad, Hle, malé si nesou své o něco menší; konce to nemá — podivný řád.)

— Augustus De Morgan

## 8. Iterátory pro pokročilé

| 0.    | iteratory pro pokrocne — 1/3                 |
|-------|--|
| 8.1.  | Ponořme se — 175                             |
| 8.2.  | Nalezení všech výskytů vzorku — 176          |
| 8.3.  | Nalezení jedinečných prvků                   |
|       | posloupnosti — 177                           |
| 8.4.  | Činíme předpoklady — 178                     |
| 8.5.  | Generátorové výrazy — 179                    |
| 8.6.  | Výpočet permutací (pro lenochy) — <b>180</b> |
| 8.7.  | Další legrácky v modulu itertools — 18       |
| 8.8.  | Nový způsob úpravy řetězce — <b>185</b>      |
| 8.9.  | Vyhodnocování libovolných řetězců            |
|       | zachycujících pythonovské výrazy — $187$     |
| 8.10. | Spojme to všechno dohromady — 190            |

Přečtěte si — 191

8.11.

#### 8.1 Ponořme se

Jestliže přirovnáme regulární výrazy ke steroidům pro řetězce, pak modul itertools představuje steroidy pro iterátory. Ale nejdříve si ukážeme jednu klasickou hádanku.

```
HAWAII + IDAHO + IOWA + OHIO == STATES

510199 + 98153 + 9301 + 3593 == 621246

H = 5

A = 1

W = 0

I = 9

D = 8

O = 3

S = 6

T = 2

E = 4
```

Pro hádanky tohoto typu se používají anglické názvy *cryptarithms* nebo *alphametics*. Písmena jsou složena do skutečných slov, ale pokud každé z nich nahradíte číslicí 0–9, pak tvoří aritmetickou rovnici. Úkol spočívá v nalezení dvojic písmeno/číslice. Všechny výskyty stejného písmene se musí dát nahradit stejnou číslicí. Žádná číslice se nesmí opakovat a žádné "slovo" nesmí začínat číslicí 0.

#### Nejznámější alfametickou hádankou je SEND + MORE = MONEY.

V této kapitole se ponoříme do neuvěřitelného pythonovského programu, který původně napsal Raymond Hettinger. Program řeší alfametické hádanky *na pouhých 14 řádcích* kódu.

```
digits = tuple(ord(c) for c in '0123456789')
zero = digits[0]
for guess in itertools.permutations(digits, len(characters)):
    if zero not in guess[:n]:
        equation = puzzle.translate(dict(zip(characters, guess)))
        if eval(equation):
            return equation

if __name__ == '__main__':
    import sys
    for puzzle in sys.argv[1:]:
        print(puzzle)
        solution = solve(puzzle)
        if solution:
            print(solution)
```

Program můžeme spustit z příkazového řádku. Pod Linuxem to bude vypadat nějak takto. (V závislosti na rychlosti vašeho počítače to může zabrat nějaký čas a není zde žádný indikátor průběhu výpočtu. Buďte trpěliví.)

```
you@localhost:~/diveintopython3/examples$ python3 alphametics.py "HAWAII + IDAHO + IOWA + OHIO == STATES"
HAWAII + IDAHO + IOWA + OHIO = STATES
510199 + 98153 + 9301 + 3593 == 621246
you@localhost:~/diveintopython3/examples$ python3 alphametics.py "I + LOVE + YOU == DORA"
I + LOVE + YOU == DORA
1 + 2784 + 975 == 3760
you@localhost:~/diveintopython3/examples$ python3 alphametics.py "SEND + MORE == MONEY"
SEND + MORE == MONEY
9567 + 1085 == 10652
```

#### 8.2. Nalezení všech výskytů vzorku

Program pro řešení alfametiky ze všeho nejdřív hledá v hádance písmena (A–Z).

```
>>> import re
>>> re.findall('[0-9]+', '16 2-by-4s in rows of 8')
['16', '2', '4', '8']
>>> re.findall('[A-Z]+', 'SEND + MORE == MONEY')
['SEND', 'MORE', 'MONEY']
[2]
```

Modul re implementuje v Pythonu regulární výrazy. Najdeme v něm i šikovnou funkci nazvanou findall(), které zadáváme vzorek pro regulární výraz a řetězec. Funkce v zadaném řetězci nalezne všechny výskyty vzorku. V tomto případě vzorek pasuje na posloupnosti číslic. Funkce findall() vrací seznam všech podřetězců, které vzorku vyhovují. 8.3.

Zde regulární výraz popisuje posloupnosti písmen. Návratovou hodnotou je opět seznam, jehož prvky jsou řetězce, které pasovaly k regulárnímu výrazu.

Následuje další příklad, který vám trochu procvičí mozek.

```
>>> re.findall(' s.*? s', "The sixth sick sheikh's sixth sheep's sick.")
[' sixth s', " sheikh's s", " sheep's s"]
```

# Tohle je nejtěžší jazykolam, jaký v anglickém jazyce najdete.

Překvapeni? Regulární výraz hledá mezeru, znak s, pak nejkratší možnou posloupnost libovolných znaků (.\*?), pak mezeru a další s. Když se tak dívám na vstupní řetězec, vidím pět pasujících podřetězců:

```
The <u>sixth sick</u> sheikh's sixth sheep's sick. The sixth <u>sick sheikh's</u> sixth sheep's sick. The sixth sick <u>sheikh's sixth</u> sheep's sick. The sixth sick sheikh's <u>sixth sheep's</u> sick. The sixth sick sheikh's sixth <u>sheep's sick</u>.
```

Ale funkce re. findall() vrátila jen tři shody. Konkrétně vrátila jen první, třetí a pátou. Proč jen tři? *Protože nevrací překrývající se shody se vzorkem*. První shoda se překrývá s druhou, takže první se vrací a druhá se přeskakuje. Pak se třetí shoda překrývá se čtvrtou, takže třetí se vrací a čtvrtá se přeskakuje. A nakonec je tu pátá shoda, která se vrací. Najdou se tedy tři výskyty a ne pět.

Tahle poznámka neměla s řešením alfametiky nic společného. Prostě mi to připadlo zajímavé.

#### 8.3. Nalezení jedinečných prvků posloupnosti

Jedinečné hodnoty z posloupnosti můžeme snadno najít pomocí množin (set).

- Pokud máme seznam s několika řetězci, pak nám z něj funkce set() vytvoří množinu jedinečných řetězců. Dá se to snadno pochopit, když si to představíte jako cyklus for. Vezmeme první položku ze seznamu a vložíme ji do množiny. Pak druhou. A třetí. Čtvrtou. Pátou... Počkat!

  Ta už v množině je, takže se bude vypisovat jen jednou, protože množiny v Pythonu neumožňují existenci duplicit. A šestou. Sedmou a znovu duplicita, takže se pak objeví jen jednou. A jaký je konečný výsledek? Z původního seznamu zbyly jen jedinečné položky bez duplicit. Původní seznam ani nemusíme předem seřadit.
- [2] Stejná technika funguje i pro řetězce, protože řetězce jsou posloupnostmi znaků.
- Pokud máme seznam řetězců, pak ''. join(a\_list) spojí všechny řetězce do jednoho.
- Takže pokud máme seznam řetězců, tento řádek kódu vrátí jedinečné znaky nacházející se ve všech řetězcích. Bez duplicit.

Program pro řešení alfametik tuto techniku používá pro vytvoření množiny všech jedinečných znaků v zadání.

```
unique_characters = set(''.join(words))
```

Program postupně prochází všemi možnými řešeními a tuto množinu používá pro přiřazení číslic jednotlivým znakům.

#### 8.4. Činíme předpoklady

V Pythonu, stejně jako v mnoha jiných programovacích jazycích, najdeme příkaz assert. Funguje následovně.

- Za příkaz assert uvedeme libovolný platný pythonovský výraz. V tomto případě se výraz 1 + 1 == 2 vyhodnotí jako True, takže příkaz assert nedělá nic.
- Pokud se ale pythonovský výraz vyhodnotí jako False, vyvolá příkaz assert výjimku AssertionError.
- Za výraz můžeme uvést také lidsky čitelnou zprávu, která se v případě vyvolání výjimky AssertionError zobrazí.

Takže následující řádek kódu:

```
assert len(unique_characters) <= 10, 'Too many letters'
...je ekvivalentem zápisu:
if len(unique_characters) > 10:
    raise AssertionError('Too many letters')
```

Program řešící alfametiku používá přesně takový příkaz assert k předčasnému ukončení činnosti v případě, kdy hádanka obsahuje víc než deset jedinečných znaků. Protože každému písmenu přiřazujeme jedinečnou číslici a číslic máme jen deset, hádanka s více než deseti jedinečnými znaky nemůže mít řešení.

#### 8.5. Generátorové výrazy

Generátorový výraz se podobá generátorové funkci, ale funkce to není.

- [1] Generátorový výraz se chová jako anonymní funkce, která produkuje hodnoty. Výraz samotný se podobá generátorové notaci seznamu (list comprehension), ale místo do hranatých závorek je uzavřen v kulatých závorkách.
- [2] Generátorový výraz vrací... iterátor.
- [3] Při volání next(gen) se nám vrací další hodnota iterátoru.
- Pokud chcete, můžete iterovat přes všechny hodnoty a vrátit n-tici, seznam nebo množinu tím, že generátorový výraz použijete v roli argumentu tuple(), list() nebo set(). V takovém případě nemusíte používat sadu kulatých závorek navíc. Funkci tuple() stačí předat "holý" výraz ord(c) for c in unique\_characters a Python už pozná, že jde o generátorový výraz.
- > Když místo generátorové notace seznamu použijete generátorový výraz, ušetříte jak CPU, tak RAM. Pokud konstruujete seznam jen proto, abyste ho zase zahodili (tj. když ho například chcete předat do tuple() nebo set()), použijte raději generátorový výraz!

Následující ukázka dosahuje stejného efektu s použitím generátorové funkce:

```
def ord_map(a_string):
    for c in a_string:
        yield ord(c)

gen = ord_map(unique_characters)
```

Generátorový výraz je kompaktnější, ale funguje stejně.

#### 8.6. Výpočet permutací (pro lenochy)

Ze všeho nejdříve se podívejme, co to vlastně jsou permutace? Permutace jsou matematický koncept. (Ve skutečnosti existuje několik definicí v závislosti na tom, jakým druhem matematiky se zabýváte. Zde se dotkneme kombinatoriky. Ale pokud vám to nic neříká, nedělejte si s tím starosti. Tak jako vždy, vaším kamarádem je Wikipedie.)

Základní myšlenka spočívá v tom, že vezmeme seznam věcí (mohou to být čísla, písmenka nebo tancující medvídci) a najdeme všechny možné způsoby, jak z něj udělat menší seznamy. (Poznámka překladatele: V našich školách se pro označení tohoto úkonu používá pojem variace k-té třídy z n prvků bez opakování. Pojem permutace bez opakování se u nás používá jen pro speciální případ, kdy k je rovno n. V dalším textu zůstanu u chápání pojmu z originální publikace také z důvodu pojmenování příslušné funkce.) Všechny menší seznamy mají mít stejnou velikost, která může být od 1 až po celkový počet prvků. A nic se nesmí opakovat. Matematici by řekli "najděme permutace dvojic z tří různých prvků" (u nás "najděte variace druhé třídy z tří prvků bez opakování"). To znamená, že máme posloupnost tří prvků a chceme nalézt všechny možné uspořádané dvojice.

```
>>> import itertools
                                                              [1]
>>> perms = itertools.permutations([1, 2, 3], 2)
                                                              [2]
>>> next(perms)
                                                              [3]
(1, 2)
>>> next(perms)
(1, 3)
>>> next(perms)
(2, 1)
                                                              [4]
>>> next(perms)
(2, 3)
>>> next(perms)
(3, 1)
>>> next(perms)
>>> next(perms)
                                                              [5]
```

```
Traceback (most recent call last):
   File "<stdin>", line 1, in <module>
StopIteration
```

- [1] Modul itertools obsahuje celou řadu zábavných věcí, včetně funkce permutations(), která nás při hledání permutací zbaví veškeré námahy.
- Funkce permutations() přebírá posloupnost (zde jde o seznam tří čísel) a požadovaný počet prvků v menších skupinách. Funkce vrací iterátor, který můžeme použít v cyklu for nebo na jakémkoliv starém známém místě, ve kterém se iteruje (tj. prochází všemi prvky). Zde budeme provádět kroky iterátoru ručně, abychom si všechny hodnoty ukázali.
- První permutací ze seznamu [1, 2, 3] je dvojice (1, 2).
- Poznamenejme, že permutace jsou uspořádané: (2, 1) je něco jiného než (1, 2).
- Tak to jsou ony! Tohle jsou permutace všech dvojic z [1, 2, 3]. Dvojice jako (1, 1) nebo (2, 2) zde nikdy neuvidíte, protože obsahují opakující se prvky. Takže nejde o platné permutace. Pokud už více permutací neexistuje, iterátor vyvolá výjimku StopIteration.

#### Modul itertools obsahuje všemožné zábavné věci.

Funkci permutations() nemusíme předávat jen seznam. Může přebírat jakoukoliv posloupnost, dokonce i řetězec.

```
>>> import itertools
>>> perms = itertools.permutations('ABC', 3)
                                                  [1]
>>> next(perms)
('A', 'B', 'C')
                                                  [2]
>>> next(perms)
('A', 'C', 'B')
>>> next(perms)
('B', 'A', 'C')
>>> next(perms)
('B', 'C', 'A')
>>> next(perms)
('C', 'A', 'B')
>>> next(perms)
('C', 'B', 'A')
>>> next(perms)
Traceback (most recent call last):
 File "<stdin>", line 1, in <module>
StopIteration
>>> list(itertools.permutations('ABC', 3))
                                                  [3]
[('A', 'B', 'C'), ('A', 'C', 'B'),
 ('B', 'A', 'C'), ('B', 'C', 'A'),
 ('C', 'A', 'B'), ('C', 'B', 'A')]
```

- [1] Řetězec je jen posloupností znaků. Takže pro účely hledání permutací je řetězec 'ABC' ekvivalentem k seznamu ['A', 'B', 'C'].
- První permutací trojic z tří prvků ['A', 'B', 'C'] je ('A', 'B', 'C'). Pro stejné znaky existuje pět dalších myslitelných uspořádání, tedy permutací.
- Funkce permutations() vrací vždy iterátor. Snadný způsob zviditelnění všech permutací při ladění spočívá ve vytvoření jejich seznamu předáním iterátoru do zabudované funkce list().

#### 8.7. Další legrácky v modulu itertools

```
>>> import itertools
>>> list(itertools.product('ABC', '123')) [1]
[('A', '1'), ('A', '2'), ('A', '3'),
    ('B', '1'), ('B', '2'), ('B', '3'),
    ('C', '1'), ('C', '2'), ('C', '3')]
>>> list(itertools.combinations('ABC', 2))
[('A', 'B'), ('A', 'C'), ('B', 'C')]
```

- [1] Funkce itertools.product() vrací iterátor, který vytváří kartézský součin dvou posloupností.
- Funkce itertools.combinations() vrací iterátor, který vytváří všechny možné kombinace dané délky z dané posloupnosti. Podobá se funkci itertools.permutations() s tou výjimkou, že kombinace nezahrnují výsledky, které vzniknou pouhou změnou uspořádání položek jiného výsledku. Takže itertools.permutations('ABC', 2) vrátí jak ('A', 'B'), tak ('B', 'A') (mimo jiné), ale itertools.combinations('ABC', 2) nevrátí ('B', 'A'), protože jde o duplicitu vytvořenou změnou pořadí položek ('A', 'B').

```
>>> names = list(open('examples/favorite-people.txt', encoding='utf-8'))
                                                                                   [1]
>>> names
['Dora\n', 'Ethan\n', 'Wesley\n', 'John\n', 'Anne\n',
'Mike\n', 'Chris\n', 'Sarah\n', 'Alex\n', 'Lizzie\n']
>>> names = [name.rstrip() for name in names]
                                                                                   [2]
['Dora', 'Ethan', 'Wesley', 'John', 'Anne',
'Mike', 'Chris', 'Sarah', 'Alex', 'Lizzie']
>>> names = sorted(names)
                                                                                   [3]
>>> names
['Alex', 'Anne', 'Chris', 'Dora', 'Ethan',
'John', 'Lizzie', 'Mike', 'Sarah', 'Wesley']
>>> names = sorted(names, key=len)
                                                                                   [4]
>>> names
['Alex', 'Anne', 'Dora', 'John', 'Mike',
'Chris', 'Ethan', 'Sarah', 'Lizzie', 'Wesley']
```

- [1] Tento obrat vrací seznam všech řádků v textovém souboru.
- Naneštěstí (pro tento příklad) obrat list(open(filename)) vrací na konci každého řádku i znak konce řádku. V této generátorové notaci seznamu použijeme metodu řetězce rstrip(), která z konce každého řádku odstraní koncové bílé znaky. (Řetězce definují též metodu lstrip(), která odstraňuje úvodní bílé znaky, a metodu strip(), která odstraňuje bílé znaky z obou konců.)
- [3] Funkce sorted() přebírá seznam a vrací nový, seřazený. Neřekneme-li jinak, řadí se podle abecedy.
- Ale funkci sorted() můžeme parametrem key předat funkci a pak se provede řazení podle jejích výsledků. V tomto případě byla předána funkce len(), takže řazení probíhá podle výsledků funkce len(položka). Nejkratší jména se dostanou na začátek, pak budou následovat delší a delší.

A co to má společného s modulem itertools? To jsem rád, že se ptáte.

```
...pokračování v předchozí práci s interaktivním shellem...
>>> import itertools
>>> groups = itertools.groupby(names, len)
                                                          [1]
>>> groups
<itertools.groupby object at 0x00BB20C0>
>>> list(groups)
[(4, <itertools._grouper object at 0x00BA8BF0>),
 (5, <itertools._grouper object at 0x00BB4050>),
 (6, <itertools._grouper object at 0x00BB4030>)]
>>> groups = itertools.groupby(names, len)
                                                          [2]
>>> for name_length, name_iter in groups:
        print('Names with {0:d} letters:'.format(name_length))
        for name in name_iter:
            print(name)
. . .
Names with 4 letters:
Alex
Anne
Dora
John
Mike
Names with 5 letters:
Chris
Ethan
Sarah
Names with 6 letters:
Lizzie
Wesley
```

- Fukce itertools.groupby() přebírá posloupnost a funkci klíče. Vrací iterátor, který vytváří [1] dvojice. Každá dvojice obsahuje jednak výsledek funkce\_klic(každá položka) a jednak další iterátor, který prochází všemi položkami se stejným výsledkem funkce klíče.
- Voláním funkce list() jsme iterátor "vyčerpali". To znamená, že jsme při vytváření seznamu vy-[2] generovali každou položku iterátoru. Iterátor nemá žádné tlačítko "reset". Jakmile jsme posloupnost jednou vyčerpali, nemůžeme začít znovu. Pokud chceme hodnoty projít znovu (dejme tomu v dalším cyklu for), musíme znovu zavolat itertools.groupby() a vytvořit nový iterátor.
- Za předpokladu, že už máme seznam jmen seřazený podle jejich délek, přidělí itertools. [3] groupby (names, len) všem jménům délky 4 jeden iterátor, všem jménům délky 5 druhý iterátor atd. Funkce groupby() je zcela obecná. Řetězce můžeme seskupit podle prvního písmene, čísla podle počtu jejich prvočinitelů nebo podle jakékoliv myslitelné funkce klíče.
- Funkce itertools.groupby() funguje jen v případě, kdy je vstupní posloupnost již seřazená > podle sdružovací funkce. Ve výše uvedeném příkladu jsme seznam jmen seskupili podle funkce len(). Fungovalo to jen díky tomu, že byl vstupní seznam již seřazen podle délky položek.

#### Díváte se pozorně?

```
>>> list(range(0, 3))
[0, 1, 2]
>>> list(range(10, 13))
[10, 11, 12]
>>> list(itertools.chain(range(0, 3), range(10, 13)))
                                                                   [1]
[0, 1, 2, 10, 11, 12]
>>> list(zip(range(0, 3), range(10, 13)))
                                                                   [2]
[(0, 10), (1, 11), (2, 12)]
>>> list(zip(range(0, 3), range(10, 14)))
                                                                   [3]
[(0, 10), (1, 11), (2, 12)]
>>> list(itertools.zip_longest(range(0, 3), range(10, 14)))
                                                                   [4]
[(0, 10), (1, 11), (2, 12), (None, 13)]
```

- Funkce itertools.chain() přebírá dva iterátory a vrací iterátor, který vytváří posloupnost všech [1] položek nejdříve z prvního iterátoru a pak všech položek z druhého iterátoru. (Ve skutečnosti můžeme předat libovolný počet iterátorů a tato funkce zřetězí všechny jejich hodnoty v pořadí, v jakém jsme je funkci předali.)
- Funkce zip() dělá něco docela obyčejného, ale ukazuje se, že je velmi užitečná. Přebírá libo-[2] volný počet posloupností a vrací iterátor, který vytváří n-tice z prvních položek každé posloupnosti, pak z druhých položek, pak z třetích atd.
- Funkce zip() zastaví na konci nejkratší posloupnosti. Funkce range(10, 14) produkuje 4 položky [3] (10, 11, 12 a 13), ale range (0, 3) jen 3. Takže funkce zip() vrátí iterátor produkující 3 položky.
- Naopak funkce itertools.zip\_longest() zastaví až na konci nejdelší posloupnosti. Místo chy-[4] bějících položek kratších posloupností doplní hodnoty None.

No dobrá, tohle všechno je sice velmi zajímavé, ale jak se to vztahuje k programu na řešení alfametik? Takto:

```
>>> characters = ('S', 'M', 'E', 'D', '0', 'N', 'R', 'Y')
>>> guess = ('1', '2', '0', '3', '4', '5', '6', '7')
>>> tuple(zip(characters, guess))
(('S', '1'), ('M', '2'), ('E', '0'), ('D', '3'),
('0', '4'), ('N', '5'), ('R', '6'), ('Y', '7'))
>>> dict(zip(characters, guess))
[2]
{'E': '0', 'D': '3', 'M': '2', '0': '4',
'N': '5', 'S': '1', 'R': '6', 'Y': '7'}
```

- Máme-li dán seznam písmen a seznam číslic (každá z nich je v něm reprezentována jako jednoznakový řetězec), pak nám funkce zip spáruje písmena a číslice v uvedeném pořadí.
- A proč by to mělo být nějak zvlášť výhodné? Protože shodou okolností je taková datová struktura přesně tou správnou datovou strukturou, kterou můžeme předat funkci dict(), aby vytvořila slovník, který používá písmena jako klíče a k nim přidružené číslice jako hodnoty. (Není to, samozřejmě, jediný způsob, jak toho můžeme dosáhnout. Slovník bychom mohli vytvořit přímo, pomocí generátorové notace.) Ačkoliv textová reprezentace obsahu slovníku zobrazuje dvojice v jiném pořadí (slovníky samy o sobě nedefinují "pořadí"), vidíme, že každé písmeno má k sobě číslici přidruženou na základě původních posloupností characters a guess.

Program pro řešení alfametik tuto techniku používá pro vytvoření slovníku, který převádí písmena z hádanky na čísla v řešení — pro každé možné řešení.

Ale co je za metodu ta translate()? Teď se dostáváme k opravdu zábavné části.

#### 8.8. Nový způsob úpravy řetězce

Teď se dostáváme k *opravdu* zábavné části.

Pythonovské řetězce definují mnoho metod. O některých z nich jsme se učili v kapitole Řetězce: lower(), count() a format(). Teď si představíme mocnou, ale málo známou techniku pro manipulaci s řetězcem. Jde o metodu translate().

```
>>> translation_table = {ord('A'): ord('0')}
>>> translation_table
{65: 79}
>>> 'MARK'.translate(translation_table)
'MORK'
[1]
[2]
[3]
```

- Překlad řetězce začíná naplněním překladové tabulky, což je prostě slovník, který zobrazuje jeden znak na jiný. Pojem "znak" je zde vlastně uveden chybně. Překladová tabulka ve skutečnosti zobrazuje bajty na jiné bajty.
- Připomeňme si, že bajty jsou v Pythonu 3 celá čísla. Funkce ord() vrací ASCII hodnotu daného znaku. V případě znaků A–Z to budou vždy bajty od 65 do 90.
- [3] Metoda řetězcového objektu translate() přebírá překladovou tabulku a obsah řetězce přes ni propasíruje. To znamená, že nahradí všechny výskyty klíčů z překladové tabulky odpovídajícími hodnotami. V tomto případě se MARK "přeloží" na MORK.

Ale co to má společného s řešením alfametických hádanek? Jak se ukáže za chvílli, všechno.

```
>>> characters = tuple(ord(c) for c in 'SMEDONRY') [1]
>>> characters
(83, 77, 69, 68, 79, 78, 82, 89)
>>> guess = tuple(ord(c) for c in '91570682') [2]
>>> guess
(57, 49, 53, 55, 48, 54, 56, 50)
>>> translation_table = dict(zip(characters, guess)) [3]
>>> translation_table
{68: 55, 69: 53, 77: 49, 78: 54, 79: 48, 82: 56, 83: 57, 89: 50}
>>> 'SEND + MORE == MONEY'.translate(translation_table) [4]
'9567 + 1085 == 10652'
```

- Prostřednictvím generátorového výrazu pro každý znak řetězce rychle vypočteme hodnotu odpovídajícího bajtu. Obsah proměnné characters je příkladem obsahu proměnné sorted\_characters z funkce alphametics.solve().
- Pomocí dalšího generátorového výrazu rychle vypočítáme hodnoty bajtů reprezentujících každou číslici řetězce. Výsledek v proměnné guess (tj. odhad) má podobu vrácenou funkcí itertools.permutations() viz funkce alphametics.solve()
- Překladová tabulka se generuje zipováním posloupností characters a guess dohromady a použitím výsledné posloupnosti dvojic pro vybudování slovníku. Přesně tohle dělá funkce alphametics.solve() uvnitř cyklu for.
- Nakonec překladovou tabulku předáme metodě translate() původního řetězce hádanky.

  Tím se každý znak řetězce přeloží na odpovídající číslici (podle písmen v characters a číslic v guess). Výsledkem je platný pythonovský výraz v řetězcové podobě.

To je docela efektní. Ale co můžeme dělat s řetězcem, který shodou okolností zachycuje platný pythonovský výraz?

#### 8.9. Vyhodnocování libovolných řetězců zachycujících pythonovské výrazy

Tohle je poslední kousek skládanky (nebo spíše poslední kousek programu pro řešení hádanky). Po všech těch efektních manipulacích s řetězci jsme skončili u řetězce, jako je '9567 + 1085 == 10652'. Ale je to jen řetězec. A k čemu je nám řetězec dobrý? Seznamte se s eval(), s univerzálním pythonovským vyhodnocovacím nástrojem.

```
>>> eval('1 + 1 == 2')
True
>>> eval('1 + 1 == 3')
False
>>> eval('9567 + 1085 == 10652')
True
```

Ale počkejte! Je toho ještě víc! Funkce eval () se neomezuje jen na booleovské výrazy. Zvládne *libovolný* pythonovský výraz a vrací *libovolný* datový typ.

```
>>> eval('"A" + "B"')
'AB'
>>> eval('"MARK".translate({65: 79})')
'MORK'
>>> eval('"AAAAA".count("A")')
5
>>> eval('["*"] * 5')
['*', '*', '*', '*', '*']
```

Ale počkejte, to ještě není vše!

```
>>> x = 5
>>> eval("x * 5") [1]
25
>>> eval("pow(x, 2)") [2]
25
>>> import math
>>> eval("math.sqrt(x)") [3]
2.2360679774997898
```

- Výraz předávaný funkci eval() se může odkazovat na globální proměnné definované vně eval(). A pokud se volá uvnitř funkce, může se odkazovat i na lokální proměnné.
- [2] A funkce.
- [3] A moduly.

Hej, zastav na minutku...

```
>>> import subprocess
>>> eval("subprocess.getoutput('ls ~')") [1]
'Desktop Library Pictures \
Documents Movies Public \
Music Sites'
>>> eval("subprocess.getoutput('rm /some/random/file')") [2]
```

- [1] Modul subprocess vám dovolí spustit libovolný shellovský příkaz a získat výsledek v podobě pythonovského řetězce.
- [2] Jenže libovolný shellovský příkaz může vést k trvalým následkům.

A je to dokonce ještě horší, protože existuje globální funkce \_\_import\_\_(), která přebírá jméno modulu v řetězcové podobě, importuje ho a vrací na něj odkaz. Když to zkombinujeme se silou funkce eval(), můžeme vytvořit výraz, který smaže všechny vaše soubory:

```
>>> eval("__import__('subprocess').getoutput('rm /some/random/file')") [1]
```

A teď si představte výstup příkazu 'rm -rf ~'. Ve skutečnosti žádný výstup neuvidíte. Ale neuvidíte už ani své soubory.

## eval() is EVIL

(tj. eval() je zlý, špatný, zlověstný). Tou zlou stránkou je vyhodnocování libovolných výrazů pocházejících z nedůvěryhodných zdrojů. Funkci eval() byste měli používat výhradně pro vstup z důvěryhodných zdrojů. Problém je v tom, jak určit, co je "důvěryhodný" zdroj. Ale něco vím určitě. Určitě byste NEMĚLI vzít tento program pro řešení alfametik a zveřejnit jej na internetu v podobě malé webovské služby. A nemyslete si: "Vždyť ta funkce dělá tolik řetězcových operací, než se vůbec dostane k vyhodnocení. Nedovedu si představit, jak by toho někdo mohl zneužít." Někdo přijde na to, jak propašovat nějaký nebezpečný kód všemi těmi řetězcovými manipulacemi (už se staly divnější věci). A pak už můžete svému serveru poslat jen polibek na rozloučenou.

Ale existuje vůbec nějaký způsob, jak výrazy vyhodnotit bezpečně? Lze nějak eval() umístit na pískoviště, odkud nemá přístup k okolnímu světu a nemůže mu škodit? Hmm, ano i ne.

```
>>> x = 5
>>> eval("x * 5", {}, {})
Traceback (most recent call last):
  File "<stdin>", line 1, in <module>
  File "<string>", line 1, in <module>
```

```
NameError: name 'x' is not defined
>>> eval("x * 5", {"x": x}, {}) [2]
25
>>> import math
>>> eval("math.sqrt(x)", {"x": x}, {}) [3]
Traceback (most recent call last):
   File "<stdin>", line 1, in <module>
   File "<string>", line 1, in <module>
NameError: name 'math' is not defined
```

- Druhý a třetí parametr předávaný funkci eval () se chovají jako globální a lokální prostor jmen. Tyto prostory se používají při vyhodnocování výrazu. V tomto případě jsou oba prázdné. To znamená, že při vyhodnocování řetězce "x \* 5" neexistuje žádný odkaz na x ani v globálním ani v lokálním prostoru jmen. Takže eval () vyvolá výjimku.
- Do globálního prostoru jmen můžeme vložit výběr určitých hodnot tím, že je jednotlivě vyjmenujeme. Během vyhodnocování pak budou k dispozici tyto a jen tyto proměnné.
- Ačkoliv jste zrovna importovali modul math, nevložili jsme jej do prostoru jmen, který předáváme funkci eval (). V důsledku toho vyhodnocení selhalo.

Tý jo. Tak to bylo jednoduché. Teď si udělám webovskou službu pro řešení alfametik!

```
>>> eval("pow(5, 2)", {}, {}) [1]
25
>>> eval("__import__('math').sqrt(5)", {}, {}) [2]
2.2360679774997898
```

- Ačkoliv jste v roli globálního a lokálního prostoru jmen předali prázdné slovníky, během vyhodnocování jsou stále dostupné všechny zabudované pythonovské funkce. Takže pow(5, 2) funguje, protože 5 a 2 jsou literály a pow() je zabudovaná funkce.
- Naneštěstí (a pokud netušíte, proč naneštěstí, čtěte dál) je funkce \_\_import\_\_() také zabudovanou funkcí, takže také funguje.

Ano, to znamená, že můžete pořád dělat odporné věci, i když jste při volání eval () pro globální a lokální prostor jmen explicitně nastavili prázdné slovníky:

```
>>> eval("__import__('subprocess').getoutput('rm /some/random/file')", {}, {})
```

A do prčic! Jsem rád, že jsem z modulu alphametics neudělal webovou službu. Je zde vůbec *nějaký* způsob, kterým bychom mohli eval() používat bezpečně? Ano i ne.

```
>>> eval("__import__('math').sqrt(5)",
... {"__builtins__":None}, {}) [1]
Traceback (most recent call last):
    File "<stdin>", line 1, in <module>
    File "<string>", line 1, in <module>
NameError: name '__import__' is not defined
>>> eval("__import__('subprocess').getoutput('rm -rf /')",
... {"__builtins__":None}, {}) [2]
Traceback (most recent call last):
    File "<stdin>", line 1, in <module>
    File "<string>", line 1, in <module>
NameError: name '__import__' is not defined
```

- Abyste mohli výrazy z nedůvěryhodných zdrojů vyhodnocovat bezpečně, musíte definovat slovník pro globální prostor jmen, který mapuje "\_\_builtins\_\_" na None, tedy na pythonovskou hodnotu null (nic, nil). "Zabudované" funkce jsou totiž vnitřně uzavřeny do pseudomodulu nazvaného "\_\_builtins\_\_". Tento pseudomodul (tj. množina zabudovaných funkcí) je vyhodnocovaným výrazům zpřístupněn pokud jej explicitně nepotlačíte.
- Ujistěte se, že předefinováváte \_\_builtins\_\_. Žádné \_\_builtin\_\_, \_\_built-ins\_\_ nebo nějakou podobnou variantu. Ono by to fungovalo bez problémů, ale vystavilo by vás to riziku katastrofy.

Takhle už je eval () bezpečný? Nu, ano i ne.

```
>>> eval("2 ** 2147483647",
... {"__builtins__":None}, {}) [1]
```

I bez přístupu k \_\_builtins\_\_ můžete stále spustit útok typu odmítnutí služby. Pokud se například pokusíte o umocnění 2 na 2147483647, využití procesoru vašeho serveru stoupne na 100 % na pěkně dlouhou dobu. (Pokud to zkoušíte v interaktivním shellu, můžete ho přerušit, když několikrát stisknete Ctrl-C.) Technicky vzato, tento výraz nakonec vrátí nějakou hodnotu, ale do té doby bude server dělat spoustu zbytečné práce.

Takže nakonec *je možné* bezpečně vyhodnocovat pythonovské výrazy z nedůvěryhodných zdrojů. Vyžaduje to ale určitou definici pojmu "bezpečně", která v reálném životě není zas tak užitečná. Dobré je, když si hrajete někde poblíž. Dobré taky je, když připustíte jen důvěryhodný vstup. Cokoliv jiného znamená, že si koledujete o malér.

#### 8.10. Spojme to všechno dohromady

Rekapitulace: Tento program řeší alfametické hádanky hrubou silou, tj. vyčerpávajícím hledáním všech možných řešení. Program za tím účelem...

- 1. Nalezne v zadání všechna písmena voláním funkce re.findall().
- 2. Nalezne všechna jedinečná písmena hádanky s využitím množiny a funkce set().
- 3. **Zkontroluje příkazem** assert, **zda se v zadání nevyskytuje více než 10 jedinečných znaků** (což by znamenalo, že hádanka je neřešitelná).
- 4. Převede znaky na jejich ASCII hodnoty použitím objektu generátoru.
- 5. **Počítá všechna možná řešení** pomocí funkce itertools.permutations().
- Převádí každé možné řešení na pythonovský výraz pomocí metody řetězcového objektu translate().
- 7. **Testuje každé možné řešení vyhodnocením pythonovského výrazu** voláním funkce eval ().
- 8. Vrací první řešení, které se vyhodnotí jako True.

...to vše na pouhých 14 řádcích kódu.

#### 8.11. Přečtěte si

- itertools module
  - (http://docs.python.org/py3k/library/itertools.html)
- itertools Iterator functions for efficient looping (www.doughellmann.com/PyMOTW/itertools/)
- Podívejte se na přednášku Raymonda Hettingera "Easy AI with Python" na PyCon 2009 (www.doughellmann.com/PyMOTW/itertools/)
- **Recipe 576615: Alphametics solver**, původní program Raymonda Hettingera pro Python 2. (http://code.activestate.com/recipes/576615/)
- Další recepty od Raymonda Hettingera v ActiveState Code repository (archiv kódu).
   (http://code.activestate.com/recipes/users/178123/)
- Alphametics on Wikipedia
  - (http://en.wikipedia.org/wiki/Verbal\_arithmetic)
- Alphametics Index, včetně mnoha zadání a generátoru vašich vlastních zadání. (www.tkcs-collins.com/truman/alphamet/index.shtml)

Mnohokrát děkuji Raymondu Hettingerovi za souhlas s úpravou licence jeho kódu, abych ho mohl přepsat pro Python 3 a použít jako základ této kapitoly.

9. Kapitola

- "Certitude is not the test of certainty. We have been cocksure of many things that were not so."

  (Pocit jistoty není měřítkem jistoty. Byli jsme si skálopevně jisti mnoha věcmi, které takové nebyly.)
  - Oliver Wendell Holmes, Jr.

# 9. Unit Testing

#### 9. Unit Testing — 193 9.1. (Ne)ponořme se - 195 9.2. Jediná otázka — 196 "Zastav a začni hořet" — **202** 9.3. Více zastávek, více ohně — 206 9.4. 9.5. A ještě jedna věc... — 209 9.6. Symetrie, která potěší — 211 9.7. Více špatných vstupů — 215

#### 9.1. (Ne)ponořme se

Ta dnešní mládež. Jsou tak zkažení těmi rychlými počítači a módními "dynamickými" jazyky. Rychle napsat, pak dodat a ladit až nakonec (jestli vůbec). Za mých časů jsme dodržovali disciplínu. Říkám disciplínu! Museli jsme psát programy *ručně*, na *papír* a cpát je do počítače na *děrných štítcích*. A ono se nám to *líbilo*! A cože? Že je ten nadpis anglicky? Buďte rádi, že není v ruštině. Mnozí z vás ani neví, jak přečíst jednotlivá písmenka azbuky. No dobrá, trochu zvážním. Dá se to přeložit jako "testování jednotek" nebo "jednotkové testování". Ještě se k tomu dostaneme.

V této kapitole si napíšeme a odladíme pár pomocných funkcí pro konverzi na a z římských čísel. Způ
sob tvorby a ověřování římských čísel jsme si ukázali v podkapitole <u>Případová studie: Římská čísla</u>. Teď

si poodstoupíme a zvážíme, kolik by dalo práce rozšířit původní kód na obousměrné pomocné funkce.

Pravidla pro římská čísla vedla k řadě zajímavých postřehů:

- 1. Existuje jen jeden správný způsob vyjádření konkrétního čísla římskými číslicemi.
- 2. Platí také opak. Pokud je řetězec znaků platným římským číslem, reprezentuje jen jedno možné číslo (to znamená, že řetězec může být interpretován jen jedním způsobem).
- 3. Římskými čísly lze vyjádřit jen omezený rozsah čísel, konkrétně od 1 do 3999. Římané používali několik způsobů vyjádření větších čísel. Tak například pruhem nad římským číslem vyjadřovali, že jeho číselná hodnota musí být vynásobená tisícem. Pro účely této kapitoly budeme uvažovat jen římská čísla od 1 do 3999.
- 4. Neexistuje způsob, jak římskými číslicemi vyjádřit nulu.
- 5. Neexistuje způsob, jak římskými číslicemi vyjádřit záporná čísla.
- 6. Neexistuje způsob, jak římskými číslicemi vyjádřit zlomky nebo neceločíselné hodnoty.

Začněme mapovat, co by takový modul roman.py měl dělat. Bude obsahovat dvě hlavní funkce, to\_roman() (na římské číslo) a from\_roman() (z římského čísla). Funkce to\_roman() by měla převzít celé číslo v intervalu od 1 do 3999 a vrátit jeho reprezentaci římskými číslicemi jako řetězec...

Hned tady se zastavíme. Teď uděláme něco trošku neočekávaného. Napíšeme si testovací příklad, který kontroluje, zda funkce to\_roman() dělá to, co po ní chceme. Čtete dobře. Jdeme psát kód, který testuje jiný kód, který jsme ještě nenapsali.

Říká se tomu *vývoj řízený testy (test-driven development)* nebo TDD. (V anglické literatuře si potrpí na zavádění a používání zkratek.) Dvojice převodních funkcí — to\_roman() a později from\_roman() — může být napsána a testována jako *jednotka* (unit), odděleně od jakéhokoliv většího programu, který funkce importuje. V Pythonu najdeme rámec (framework) pro unit testing (tedy testování jednotek), který má podobu příhodně nazvaného modulu unittest.

Unit testing (testování jednotek) představuje důležitou součást celkové vývojové strategie založené na testování. Pokud testy jednotek píšete, je důležité, abyste je napsali brzy a abyste je udržovali v závislosti na změnách kódu a požadavků. Mnozí lidé se přimlouvají za to, aby se testy psaly dříve

než kód, který mají testovat. V této kapitole si takový přístup předvedeme. Ale testy jednotek mají své výhody nezávisle na tom, kdy je napíšete.

- Napsání jednotkových testů (i takto se to dá překládat) ještě před napsáním kódu vás účelným způsobem donutí upřesnit své požadavky
- Při vlastním psaní kódu vás pak jednotkové testy brzdí před psaním nadbytečných věcí. Jakmile všechny testy projdou, dosáhli jste úplné funkčnosti.
- Při provádění refaktorizace kódu vám testy jednotek pomohou prokázat, že se nová verze chová stejným způsobem jako ta stará.
- Při údržbě kódu vám existence testů pomůže krýt záda (v originále se mluví o té části těla, kde záda
  ztrácejí své slušné jméno) v situaci, kdy na vás někdo přiletí a řve, že vaše poslední změny pokazily
  jejich původní kód. ("Ale pane, ale když jsem změny zveřejňoval, všechny unit testy prošly...")
- Pokud píšeme kód v týmu, pak existence společné sady testů dramaticky snižuje možnost, že by váš kód způsobil nefunkčnost kódu někoho jiného. Jejich testy jednotek totiž můžete spustit jako první. (Tenhle druh závodů v psaní kódu už jsem zažil. Tým si zadání rozdělí, každý si převezme specifikace svého úkolu, napíše pro něj jednotkové testy a pak je dá k dispozici ostatním členům týmu. Při takovém postupu nikdo nezabloudí tak daleko, že by jím vyvíjený kód nespolupracoval s výsledky ostatních.)

#### 9.2. Jediná otázka

### Každý test je ostrov.

Testovací případ (test case) odpovídá na jedinou otázku, která se testovaného kódu týká. Testovací případ by měl být schopen...

- ...běžet zcela samostatně, bez jakéhokoliv lidského zásahu. Unit testing (testování jednotek) souvisí s automatizací.
- ...sám rozhodnout o tom, zda testovaná funkce prošla nebo selhala bez nutnosti posuzování výsledků člověkem.
- ...běžet izolovaně, odděleně od jakýchkoliv jiných testovacích případů (dokonce i když testují stejnou funkci). Každý testovací případ je ostrov.

S ohledem na uvedené předpoklady začněme budovat testovací případ pro první požadavek:

Funkce to\_roman() by měla vracet reprezentaci římského čísla pro všechna celá čísla v intervalu 1 až 3999.

V prvním okamžiku není zřejmé, jak následující kód dělá... no vlastně *cokoliv*. Definuje třídu, která nemá žádnou metodu \_\_init\_\_(). Třída sice *má* nějakou metodu, ale ta se nikdy nevolá. Celý skript obsahuje blok \_\_main\_\_, ale nenajdeme v něm odkaz ani na třídu, ani na její metodu. Ale on opravdu něco dělá. Za to ručím.

```
import roman1
import unittest
class KnownValues(unittest.TestCase):
                                                                             [1]
    known_values = ((1, 'I'),
                      (2, 'II'),
                      (3, 'III'),
                      (4, 'IV'),
                      (5, 'V'),
                      (6, 'VI'),
                      (7, 'VII'),
                      (8, 'VIII'),
                      (9, 'IX'),
                      (10, 'X'),
                      (50, 'L'),
                      (100, 'C'),
                      (500, 'D'),
                      (1000, 'M'),
                      (31, 'XXXI'),
                      (148, 'CXLVIII'),
                      (294, 'CCXCIV'),
                      (312, 'CCCXII'),
                      (421, 'CDXXI'),
                      (528, 'DXXVIII'),
                      (621, 'DCXXI'),
                      (782, 'DCCLXXXII'),
                      (870, 'DCCCLXX'),
                      (941, 'CMXLI'),
                      (1043, 'MXLIII'),
                      (1110, 'MCX'),
                      (1226, 'MCCXXVI'),
                      (1301, 'MCCCI'),
                      (1485, 'MCDLXXXV'),
                      (1509, 'MDIX'),
                      (1607, 'MDCVII'),
                      (1754, 'MDCCLIV'),
                      (1832, 'MDCCCXXXII'),
                      (1993, 'MCMXCIII'),
                      (2074, 'MMLXXIV'),
                      (2152, 'MMCLII'),
                      (2212, 'MMCCXII'),
                      (2343, 'MMCCCXLIII'),
```

(2499, 'MMCDXCIX'),

```
(2574, 'MMDLXXIV'),
                      (2646, 'MMDCXLVI'),
                      (2723, 'MMDCCXXIII'),
                      (2892, 'MMDCCCXCII'),
                      (2975, 'MMCMLXXV'),
                      (3051, 'MMMLI'),
                      (3185, 'MMMCLXXXV'),
                      (3250, 'MMMCCL'),
                      (3313, 'MMMCCCXIII'),
                      (3408, 'MMMCDVIII'),
                      (3501, 'MMMDI'),
                      (3610, 'MMMDCX'),
                      (3743, 'MMMDCCXLIII'),
                      (3844, 'MMMDCCCXLIV'),
                      (3888, 'MMMDCCCLXXXVIII'),
                      (3940, 'MMMCMXL'),
                      (3999, 'MMMCMXCIX'))
                                                                             [2]
    def test_to_roman_known_values(self):
                                                                             [3]
        '''to_roman should give known result with known input'''
        for integer, numeral in self.known_values:
            result = roman1.to_roman(integer)
                                                                             [4]
            self.assertEqual(numeral, result)
                                                                             [5]
if __name__ == '__main__':
    unittest.main()
```

- Když chceme napsat nějaký testovací případ (test case), musíme nejdříve vytvořit třídu odvozenou od třídy TestCase z modulu unittest. Uvedená třída nám poskytuje řadu užitečných metod, které můžeme v našem testovacím případě využít pro testování specifických podmínek.
- Tohle je seznam dvojic s celým číslem a s římským číslem, které jsem ověřil ručně. Obsahuje deset nejmenších čísel, největší číslo, každé číslo, které se vyjadřuje jednoznakovým římským číslem, a náhodnou sadu dalších platných čísel. Nemusíme testovat každý možný vstup, ale měli bychom se pokusit otestovat všechny zřejmé hraniční případy.
- Pro každý jednotlivý test je vytvořena jeho vlastní metoda. Metoda testu nemá žádné parametry, nevrací žádnou hodnotu a její jméno musí začínat čtyřmi písmeny test. Pokud testovací metoda skončí normálně, bez vyvolání výjimky, pokládáme test za úspěšný. Pokud metoda vyvolá výjimku, považujeme to za selhání testu.
- Tady voláme skutečnou funkci to\_roman(). (Tu funkci jsme zatím nenapsali, ale jakmile ji jednou napíšeme, tento řádek ji zavolá.) Všimněte si, že jsme v tomto okamžiku pro funkci to\_roman() definovali aplikační programové rozhraní (API). Musí přebírat celé číslo (převáděné číslo) a vrací řetězec (reprezentaci římského čísla). Pokud by rozhraní funkce bylo jiné, test by selhal. Všimněte si také, že při volání to\_roman() žádnou výjimku neodchytáváme. Je to

záměrné. Funkce to\_roman() by při volání s platným vstupem žádnou výjimku vyvolat neměla a uvedené vstupní hodnoty jsou všechny platné. Pokud to\_roman() vyvolá výjimku, bude se to považovat za selhání tohoto testu.

Dejme tomu, že funkce to\_roman() byla korektně definována, korektně volána, úspěšně skončila a vrátila výsledek. Pak nám jako poslední krok zbývá zkontrolovat, zda vrátila správnou hodnotu. Jde o obecně používaný dotaz. Ke kontrole, zda se dvě hodnoty shodují, poskytuje třída TestCase metodu assertEqual. Pokud výsledek (result) vrácený funkcí to\_roman() neodpovídá očekávané známé hodnotě (numeral), vyvolá assertEqual výjimku a test selže. Pokud se ty dvě hodnoty shodují, neudělá assertEqual nic. Pokud všechny hodnoty vrácené funkcí to\_roman() odpovídají očekávaným hodnotám, assertEqual nikdy výjimku nevyvolá, takže metoda test\_to\_roman\_known\_values nakonec normálně skončí. To znamená, že funkce to\_roman() testem prošla.

## Napište test, který selže, a pak programujte, dokud neprojde.

Jakmile máme vytvořen testovací případ, začneme psát funkci to\_roman(). Nejdříve ji nahradíme prázdnou funkcí a ověříme si, že test selhává. Pokud by test prošel, aniž jsme napsali nějaký kód, pak by testy náš kód vůbec netestovaly! Unit testing je jako tanec: testy vedou, kód následuje. Napište test, který selže, a pak programujte, dokud neprojde.

```
# roman1.py

def to_roman(n):
    '''convert integer to Roman numeral'''
    pass [1]
```

V této fázi bychom rádi definovali rozhraní funkce to\_roman(), ale nechceme zatím psát žádný kód. (Náš test musí nejdříve selhat.) Prázdné funkčnosti dosáhneme použitím pythonovského vyhrazeného slova pass, které dělá doslova nic.

Spuštění testu zajistíme provedením romantest1. py z příkazového řádku. Pokud jej zavoláme s volbou -v, dosáhneme podrobnějšího výstupu, takže přesně uvidíme, co se při běhu každého testovacího případu děje. S trochou štěstí by váš výstup měl vypadat nějak takto:

```
you@localhost:~/diveintopython3/examples$ python3 romantest1.py -v

test_to_roman_known_values (__main__.KnownValues) [1]

to_roman should give known result with known input ... FAIL [2]

FAIL: to_roman should give known result with known input

Traceback (most recent call last):

File "romantest1.py", line 73, in test_to_roman_known_values

self.assertEqual(numeral, result)
```

- Když skript spustíme, spustí se funkce unittest.main(), která zajistí provedení každého testovacího případu. Každý testovací případ je metodou třídy z romantest1.py. U testovacích tříd se nevyžaduje nějaká zvláštní organizace. Každá z nich může obsahovat jedinou metodu, nebo můžeme mít jednu třídu, která obsahuje množství testovacích metod. Jediným požadavkem je to, že každá testovací třída musí dědit z třídy unittest.TestCase.
- Pro každý testovací případ modul unittest vytiskne docstring metody a to, zda test prošel (pass) nebo selhal (fail). Tento test podle očekávání selhal.
- Pro každý testovací případ, který selhal, zobrazí unittest trasovací informaci, která přesně ukazuje, co se stalo. V tomto případě vyvolala metoda assertEqual() výjimku AssertionError, protože se očekávalo, že funkce to\_roman(1) vrátí 'I', ale nevrátila. (Protože jsme v ní explicitně neuvedli příkaz return, vrátila funkce hodnotu None, což je pythonovský ekvivalent hodnoty null.)
- Po detailních výpisech každého testu zobrazí unittest souhrnně, kolik testů se provádělo a jak dlouho to trvalo.
- Testovací běh celkově selhal, protože minimálně jeden test neprošel. Pokud testovací případ neprojde, rozlišuje unittest mezi selháním (failure) a chybou (error). Selhání (failure) je důsledkem volání metody assertXYZ, jako je například assertEqual nebo assertRaises, která selhala, protože neplatí předepsaná podmínka nebo nebyla vyvolána očekávaná výjimka. Za chybu (error) se považuje jakýkoliv jiný druh výjimky, která vznikla uvnitř testované kódu nebo v kódu testovacího případu.

A teď už můžeme konečně napsat funkci to\_roman().

```
roman_numeral_map = (('M', 1000),
	('CM', 900),
	('D', 500),
	('CD', 400),
	('C', 100),
	('XC', 90),
	('L', 50),
	('XL', 40),
	('X', 10),
	('IX', 9),
	('IX', 9),
	('IV', 5),
	('IV', 4),
	('I', 1))
```

```
def to_roman(n):
    '''convert integer to Roman numeral'''
    result = ''
    for numeral, integer in roman_numeral_map:
        while n >= integer:
            result += numeral
            n -= integer
    return result
```

- roman\_numeral\_map je n-tice n-tic, které definují tři věci: znakovou reprezentaci nejzákladnějších římských čísel, pořadí římských čísel (sestupně od M až po I), hodnotu každého římského čísla. Každá vnitřní n-tice je dvojicí (římské číslo, hodnota). Nejsou zde jen jednoznaková římská čísla. Jsou zde definována i dvojznaková čísla jako CM ("o jedno sto méně než jeden tisíc"). Tím se kód funkce to\_roman() zjednoduší.
- Zde je to místo, kde se bohatá datová struktura roman\_numeral\_map uplatní, protože díky ní k realizaci odečítacího pravidla nepotřebujeme žádnou speciální logiku. Při převodu na římské číslo jednoduše procházíme strukturou roman\_numeral\_map a hledáme největší celočíselnou hodnotu, která je menší nebo rovna vstupu. Jakmile ji nalezneme, přidáme její reprezentaci římským číslem na konec výstupu, odečteme odpovídající celočíselnou hodnotu od vstupu, namydlíme, opláchneme, zopakujeme.

Pokud vám pořád není jasné, jak funkce to\_roman() pracuje, přidejte na konec cyklu while volání funkce print():

```
while n >= integer:
    result += numeral
    n -= integer
    print('subtracting {0} from input, adding {1} to output'.format(integer, numeral))
```

S ladicími příkazy print() vypadá výstup takto:

```
>>> import roman1
>>> roman1.to_roman(1424)
subtracting 1000 from input, adding M to output
subtracting 400 from input, adding CD to output
subtracting 10 from input, adding X to output
subtracting 10 from input, adding X to output
subtracting 4 from input, adding IV to output
'MCDXXIV'
```

Takže se zdá, že funkce to\_roman() pracuje přinejmenším v tomto ručně zkoušeném případě. Ale projde testovacím případem, který jsme napsali?

OK

Hurá! Funkce to\_roman() prošla testovacím případem nazvaným "známé hodnoty". Není sice všeobsažný, ale prověřil schopnosti funkce celou škálou vstupů, včetně vstupů, které produkují každé jednoznakové římské číslo, největší možný vstup (3999), a vstupu, který produkuje nejdelší možné římské číslo (3888). V tomto okamžiku už můžeme docela důvěřovat tomu, že funkce pracuje pro libovolnou správnou vstupní hodnotu, kterou bychom mohli zadat.

"Správný" vstup? Hmm. A co takhle chybný vstup?

#### 9.3. "Zastav a začni hořet"

# Pythonovská signalizace typu "zastav a začni hořet" spočívá ve vyvolání výjimky.

Ono ale nestačí, když funkce uspějí při zadání správného vstupu. Musíme otestovat také to, že při chybném vstupu dojde k jejich selhání. Ale nemůže jít o jakýkoliv způsob selhání. Funkce musí selhat očekávaným způsobem.

Tohle určitě není to, co jsme chtěli. Vždyť se dokonce nejedná ani o platné římské číslo! Každé z těchto čísel leží ve skutečnosti mimo rozsah přijatelných vstupů, ale funkce pro ně stejně vrací falešné, vykonstruované hodnoty. Pokud potichu vracíme špatné hodnoty, je to *velmi špatné*. Pokud má program selhat, pak je mnohem lepší, když selže rychle a nahlas. Jak se říká, "zastav a začni hořet". (Jde o překlad anglické fráze "Halt And Catch Fire", která se při práci na úrovních blízkých hardwaru vztahuje k mechanismu velmi dobře pozorovatelného projevu nějaké neočekávané chyby. Vysvětlení původu této hlášky se různí, od skutečně kouřících přežhavených drátků feritové paměti při dynamické realizaci instrukce HALT, až po speciální

nedokumentované strojové instrukce, které uvedou procesor do testovacího režimu.) Pythonovská signalizace typu "zastav a začni hořet" spočívá ve vyvolání výjimky.

Měli byste si položit otázku: "Jak bychom to mohli vyjádřit formou testovatelného požadavku?" Co kdybychom začali nějak takto:

Pokud funkci to\_roman() zadáme celé číslo větší než 3999, měla by vyvolat výjimku OutOfRangeError.

Jak by vypadal příslušný test?

```
class ToRomanBadInput(unittest.TestCase):
    def test_too_large(self):
        '''to_roman should fail with large input'''
        self.assertRaises(roman2.OutOfRangeError, roman2.to_roman, 4000) [3]
```

- Podobně jako v předchozím testovacím případě vytvoříme třídu, která dědí z unittest.TestCase.

  Jedna třída sice může obsahovat více než jeden test (jak si ukážeme v této kapitole později), ale
  já jsem se rozhodl, že vytvořím novou třídu, protože tento test dělá něco jiného než ten minulý.

  Všechny testy správných vstupů budeme udržovat v jedné třídě a o všechny testy chybných vstupů se bude starat druhá třída.
- Vlastní test, stejně jako v předchozím testovacím případě, má podobu metody třídy. Její jméno začíná písmeny test.
- Třída unittest.TestCase poskytuje metodu assertRaises, která přebírá následující argumenty: očekávanou výjimku, testovanou funkci a argumenty, které jí chceme předat. (Pokud testovaná funkce očekává více než jeden argument, předejte je metodě assertRaises všechny v daném pořadí. Ona už se postará o jejich předání testované funkci.)

Věnujte zvláštní pozornost tomu poslednímu řádku kódu. Místo toho, abychom volali to\_roman(), přímo a ručně zkontrolovali, že vyvolává konkrétní výjimku (obalením do bloku try...except), metoda assertRaises to vše udělá za nás. Musíme jí jen říct, jakou výjimku očekáváme (roman2.OutOfRangeError), předat funkci (to\_roman()) a její argumenty (4000). Metoda assertRaises se postará o zavolání to\_roman() a o kontrolu toho, že vyvolala výjimku roman2.OutOfRangeError.

Poznamenejme také, že funkci to\_roman() předáváme jako argument. Nevoláme ji a ani nepředáváme její jméno jako řetězec. Zmínil jsem se už dříve o tom, jak je šikovné, že v Pythonu je vše objektem?

Takže co se stane, když spustíme sadu testů doplněnou o tento nový test?

```
you@localhost:~/diveintopython3/examples$ python3 romantest2.py -v
test_to_roman_known_values (__main__.KnownValues)
to_roman should give known result with known input ... ok
test_too_large (__main__.ToRomanBadInput)
```

- Asi jste očekávali, že dojde k selhání (protože zatím jsme nenapsali žádný kód, aby to prošlo), ale... ono to ve skutečnosti "neselhalo" (fail). Místo toho došlo k "chybě" (error). Je to sice jemný, ale důležitý rozdíl. Jednotkový test má ve skutečnosti *tři návratové hodnoty*: prošel (pass), selhal (fail) a chyba (error). "Pass" (prošel) samozřejmě znamená, že test prošel. Kód dělá to, co jsme očekávali. "Fail" (selhal) vyjadřuje to, co udělal minulý test (než jsme napsali kód, díky kterému prošel). Kód se provedl, ale výsledek neodpovídá tomu, co jsme očekávali. "Error" (chyba) se objeví, když kód ani správně nedoběhl.
- A proč vlastně kód správně neproběhl? Vše se dozvíme z trasovacího hlášení. Testovaný modul vůbec nedefinuje výjimku zvanou OutOfRangeError (tj. hodnota mimo platný rozsah). Připomeňme si, že uvedenou výjimku jsme předali metodě assertRaises(), protože právě tohle má být výjimka, kterou má funkce vyvolat, když zadáme vstup mimo platný rozsah. Ale tato výjimka vůbec neexistuje, takže volání metody assertRaises() selhalo. Metoda neměla vůbec šanci otestovat funkci to\_roman(). Tak daleko se vůbec nedostala.

K vyřešení zmíněného problému musíme v roman2. py doplnit definici výjimky OutOfRangeError.

```
class OutOfRangeError(ValueError): [1]
  pass [2]
```

- Výjimky mají podobu tříd. Chyba "mimo platný rozsah" je druhem chyby hodnoty. Hodnota argumentu se nachází mimo přijatelné meze. Z tohoto důvodu výjimka dědí ze zabudované výjimky ValueError. Není to nezbytně nutné (mohli bychom prostě dědit od bázové třídy Exception, tj. obecná výjimka), ale zdá se to být správné.
- Výjimky samy o sobě ve skutečnosti nic nedělají, ale potřebujete nejméně jeden řádek kódu, abychom definovali třídu. Volání pass sice nic nedělá, ale je to řádek pythonovského kódu, který zajistí, že třída vznikne.

Teď spustíme sadu testů znovu.

```
you@localhost:~/diveintopython3/examples$ python3 romantest2.py -v
test_to_roman_known_values (__main__.KnownValues)
to_roman should give known result with known input ... ok
test_too_large (__main__.ToRomanBadInput)
to_roman should fail with large input ... FAIL
                                                            [1]
______
FAIL: to_roman should fail with large input
______
Traceback (most recent call last):
 File "romantest2.py", line 78, in test_too_large
   self.assertRaises(roman2.OutOfRangeError, roman2.to_roman, 4000)
AssertionError: OutOfRangeError not raised by to_roman
                                                            [2]
Ran 2 tests in 0.016s
FAILED (failures=1)
```

- Nový test sice stále neprošel, ale už také nevrací chybu. Místo toho došlo k selhání testu. To je pokrok! To znamená, že volání metody assertRaises() tentokrát prošlo a rámec pro testování jednotek (unit test framework) skutečně testoval funkci to\_roman().
- Funkce to\_roman() zatím, samozřejmě, nevyvolává právě definovanou výjimku 0ut0fRangeError, protože jsme jí ještě neřekli, že to má dělat. To je ale výborná zpráva! Znamená to, že máme platný testovací případ selhává (fails) před napsáním kódu, který zajistí, že projde.

Teď napíšeme kód, který zajistí, aby funkce testem prošla.

```
def to_roman(n):
    '''convert integer to Roman numeral'''
    if n > 3999:
        raise OutOfRangeError('number out of range (must be less than 4000)') [1]

    result = ''
    for numeral, integer in roman_numeral_map:
        while n >= integer:
            result += numeral
            n -= integer
    return result
```

Přímočaré řešení: Pokud je daný vstup (n) větší než 3999, vyvolej výjimku OutOfRangeError. Tento jednotkový test nekontroluje, zda výjimku doprovází lidsky čitelný řetězec. Mohli bychom napsat další test, který by to kontroloval (ale pozor na problémy s internacionalizací; řetězce se mohou lišit v závislosti na jazyku uživatele a v závislosti na prostředí).

Vede úprava k tomu, že test projde? Pojďme to zjistit.

```
you@localhost:~/diveintopython3/examples$ python3 romantest2.py -v
test_to_roman_known_values (__main__.KnownValues)
to_roman should give known result with known input ... ok
test_too_large (__main__.ToRomanBadInput)
to_roman should fail with large input ... ok

[1]
Ran 2 tests in 0.000s
```

Hurá! Oba testy prošly. Protože jsme pracovali po krocích (přebíhali jsme mezi testováním a psaním kódu), můžeme si být jisti, že ty dva řádky kódu, které jsme právě napsali, byly příčinou toho, že se výsledek testu změnil z "fail" (selhal) na "pass" (prošel). Tento druh (sebe)důvěry sice nebyl zadarmo, ale během života našeho kódu se ještě vyplatí.

#### 9.4. Více zastávek, více ohně

>>> import roman2

Spolu s testováním čísel, která jsou příliš velká, bychom měli testovat i čísla, která jsou příliš malá. Přesně jak jsme poznamenali v našich požadavcích na funkčnost, římská čísla nemohou vyjádřit nulu nebo záporná čísla.

```
>>> roman2.to_roman(0)
>>> roman2.to_roman(-1)
Hmm, tohle není dobré. Přidejme testy pro každou z těchto podmínek.
class ToRomanBadInput(unittest.TestCase):
    def test_too_large(self):
        '''to_roman should fail with large input'''
        self.assertRaises(roman3.OutOfRangeError, roman3.to_roman, 4000)
                                                                                    [1]
    def test_zero(self):
        '''to_roman should fail with 0 input'''
        self.assertRaises(roman3.OutOfRangeError, roman3.to_roman, 0)
                                                                                    [2]
    def test_negative(self):
        '''to_roman should fail with negative input'''
        self.assertRaises(roman3.OutOfRangeError, roman3.to_roman, -1)
                                                                                    [3]
```

- [1] Metoda test\_too\_large() se od minulého kroku nezměnila. Ponechal jsem ji zde, abych ukázal, kam nový kód zapadá.
- Máme tu nový test, metodu test\_zero(). Je to stejné jako u metody test\_too\_large(). [2] Metodě assertRaises() z třídy unittest. TestCase říkáme, aby zavolala naši funkci to\_roman() s parametrem 0 a zkontrolovala, zda vyvolá příslušnou výjimku OutOfRangeError.
- Metoda test\_negative() je téměř shodná až na to, že funkci to\_roman() předává hodnotu -1. [3] Pokud kterýkoliv z těchto nových testů nevyvolá výjimku OutOfRangeError (protože funkce buď vrátí nějakou skutečnou hodnotu nebo vyvolá nějakou jinou výjimku), bude se to považovat za selhání testu.

Teď zkontrolujme, že testy selhávají:

```
you@localhost:~/diveintopython3/examples$ python3 romantest3.py -v
test_to_roman_known_values (__main__.KnownValues)
to_roman should give known result with known input ... ok
test_negative (__main__.ToRomanBadInput)
to_roman should fail with negative input ... FAIL
test_too_large (__main__.ToRomanBadInput)
to_roman should fail with large input ... ok
test_zero (__main__.ToRomanBadInput)
to_roman should fail with 0 input ... FAIL
______
FAIL: to_roman should fail with negative input
Traceback (most recent call last):
 File "romantest3.py", line 86, in test_negative
   self.assertRaises(roman3.OutOfRangeError, roman3.to_roman, -1)
AssertionError: OutOfRangeError not raised by to_roman
______
FAIL: to_roman should fail with 0 input
______
Traceback (most recent call last):
 File "romantest3.py", line 82, in test_zero
   self.assertRaises(roman3.OutOfRangeError, roman3.to_roman, 0)
AssertionError: OutOfRangeError not raised by to_roman
Ran 4 tests in 0.000s
FAILED (failures=2)
```

9.4.

Výborně. Oba testy podle očekávání selhaly. Teď se přepněme na psaní kódu a uvidíme, co můžeme dělat, aby testy prošly.

- Tohle je pěkná pythonovská zkratka více porovnání najednou. Je to ekvivalentní zápisu if not ((0 < n) and (n < 4000)), ale je to mnohem čitelnější. Tento řádek kódu by měl zachytit vstupy, které jsou příliš velké, záporné nebo nulové.
- Pokud podmínky změníte, nezapomeňte odpovídajícím způsobem upravit i lidsky čitelný řetězec. Rámci unittest je to jedno. Pokud by ale váš kód vyvolával nesprávně popsané výjimky, ztížilo by se tím ruční ladění.

Mohl bych vám ukázat celou sérii nesouvisejících příkladů, které ukazují, že zkratka umožňující několik porovnání najednou funguje. Místo toho ale spustím testy jednotek a dokážu vám to.

```
you@localhost:~/diveintopython3/examples$ python3 romantest3.py -v test_to_roman_known_values (__main__.KnownValues) to_roman should give known result with known input ... ok test_negative (__main__.ToRomanBadInput) to_roman should fail with negative input ... ok test_too_large (__main__.ToRomanBadInput) to_roman should fail with large input ... ok test_zero (__main__.ToRomanBadInput) to_roman should fail with 0 input ... ok
```

OK

#### 9.5. A ještě jedna věc...

Mezi požadavky na převod na římská čísla byl ještě jeden, který se týkal neceločíselného vstupu.

```
>>> import roman3
>>> roman3.to_roman(0.5) [1]
''
>>> roman3.to_roman(1.0) [2]
'I'
```

- [1] A jéje, to je špatné.
- Jejda, tohle je ještě horší. V obou uvedených případech by měla být vyvolána výjimka. Místo toho produkují falešné výstupy.

Testování na neceločíselný vstup není obtížné. Nejdříve si definujeme výjimku NotIntegerError.

```
# roman4.py
class OutOfRangeError(ValueError): pass
class NotIntegerError(ValueError): pass
```

Dále napíšeme testovací případ, který kontroluje výskyt výjimky NotIntegerError.

```
class ToRomanBadInput(unittest.TestCase):
    .
    .
    def test_non_integer(self):
        '''to_roman should fail with non-integer input'''
    self.assertRaises(roman4.NotIntegerError, roman4.to_roman, 0.5)
```

Teď zkontrolujme, zda test správně selhává.

```
you@localhost:~/diveintopython3/examples$ python3 romantest4.py -v test_to_roman_known_values (__main__.KnownValues) to_roman should give known result with known input ... ok test_negative (__main__.ToRomanBadInput) to_roman should fail with negative input ... ok test_non_integer (__main__.ToRomanBadInput) to_roman should fail with non-integer input ... FAIL test_too_large (__main__.ToRomanBadInput) to_roman should fail with large input ... ok test_zero (__main__.ToRomanBadInput) to_roman should fail with 0 input ... ok
```

```
FAIL: to_roman should fail with non-integer input
_____
Traceback (most recent call last):
  File "romantest4.py", line 90, in test_non_integer
   self.assertRaises(roman4.NotIntegerError, roman4.to_roman, 0.5)
AssertionError: NotIntegerError not raised by to_roman
Ran 5 tests in 0.000s
FAILED (failures=1)
Napíšeme kód, který má zajistit, aby test prošel.
def to_roman(n):
    '''convert integer to Roman numeral'''
   if not (0 < n < 4000):
       raise OutOfRangeError('number out of range (must be 1..3999)')
   if not isinstance(n, int):
                                                                     [1]
       raise NotIntegerError('non-integers can not be converted')
                                                                     [2]
   result = ''
   for numeral, integer in roman_numeral_map:
       while n >= integer:
           result += numeral
           n -= integer
   return result
```

\_\_\_\_\_

- Zabudovaná funkce isinstance() testuje, zda je daná proměnná určitého typu (nebo, z technického hlediska, nějakého z něj odvozeného typu).
- Pokud argument n není typu int, vyvolej naši zbrusu novou výjimku NotIntegerError.

Nakonec zkontrolujeme, že tento kód zajistil průchod testem.

```
you@localhost:~/diveintopython3/examples$ python3 romantest4.py -v test_to_roman_known_values (__main__.KnownValues) to_roman should give known result with known input ... ok test_negative (__main__.ToRomanBadInput) to_roman should fail with negative input ... ok test_non_integer (__main__.ToRomanBadInput) to_roman should fail with non-integer input ... ok test_too_large (__main__.ToRomanBadInput) to_roman should fail with large input ... ok
```

Funkce to\_roman() prošla všemi testy a žádné další testy mě nenapadají. Takže nastal čas, abychom se přesunuli k from\_roman().

#### 9.6. Symetrie, která potěší

Převod řetězce vyjadřujícího římské číslo na číselnou hodnotu vypadá složitěji než převod čísla na římské číslo. Určitě budeme muset zajistit ověření platnosti. Zkontrolovat, zda je číslo rovno nule, je snadné. O něco obtížněji se kontroluje, zda je řetězec platným římským číslem. Jenže my už jsme zkonstruovali regulární výraz, který zkontroluje, zda jde o římské číslo. Takže tuhle část už máme hotovou.

Zbývá nám problém samotné konverze řetězce. Jak za chvíli uvidíme, díky existenci datové struktury, kterou jsme definovali pro převod určitých římských čísel na celočíselné hodnoty, bude jádro funkce from\_roman() stejně přímočaré jako u funkce to\_roman().

Ale nejdříve testy. Pro ověření správnosti konkrétních hodnot budeme potřebovat test "známých hodnot". Naše testovací sada již tabulku známých hodnot obsahuje, takže ji využijme.

```
def test_from_roman_known_values(self):
    '''from_roman should give known result with known input'''
    for integer, numeral in self.known_values:
        result = roman5.from_roman(numeral)
        self.assertEqual(integer, result)
```

Najdeme zde potěšitelnou symetrii. Funkce to\_roman() a from\_roman() jsou vzájemně inverzní. První z nich převádí čísla na zvláštně formátované řetězce a druhá převádí zvláštně formátované řetězce na celá čísla. Teoreticky bychom měli být schopni dospět ke zvolenému číslu oklikou tak, že je nejdříve předáme funkci to\_roman(). Získaný řetězec předáme funkci from\_roman() a výsledné číslo by se mělo shodovat s počátečním.

```
n = from_roman(to_roman(n)) pro všechny hodnoty n
```

V tomto případě "všechny hodnoty" znamená jakoukoliv hodnotu 1..3999, protože toto je platný rozsah vstupů pro funkci to\_roman(). Tuto symetrii můžeme vyjádřit testovacím případem, který prochází všechny hodnoty 1..3999, volá to\_roman(), volá from\_roman() a kontroluje, zda se výstup shoduje s původním vstupem.

```
class RoundtripCheck(unittest.TestCase):
   def test_roundtrip(self):
       '''from_roman(to_roman(n))==n for all n'''
       for integer in range(1, 4000):
           numeral = roman5.to_roman(integer)
           result = roman5.from_roman(numeral)
           self.assertEqual(integer, result)
Tyto nové testy zatím ani neselžou (fail). Zatím jsme vůbec nedefinovali funkci from_roman(), takže
způsobí chyby (errors).
you@localhost:~/diveintopython3/examples$ python3 romantest5.py
E.E...
_____
ERROR: test_from_roman_known_values (__main__.KnownValues)
from_roman should give known result with known input
Traceback (most recent call last):
 File "romantest5.py", line 78, in test_from_roman_known_values
   result = roman5.from_roman(numeral)
AttributeError: 'module' object has no attribute 'from_roman'
______
ERROR: test_roundtrip (__main__.RoundtripCheck)
from_roman(to_roman(n))==n for all n
Traceback (most recent call last):
 File "romantest5.py", line 103, in test_roundtrip
   result = roman5.from_roman(numeral)
AttributeError: 'module' object has no attribute 'from_roman'
Ran 7 tests in 0.019s
FAILED (errors=2)
Problém vyřešíme rychlým vytvořením náhradní funkce.
# roman5.py
def from_roman(s):
    '''convert Roman numeral to integer'''
```

(Hej, všimli jste si toho? Definoval jsem funkci, která neobsahuje nic než docstring (dokumentační řetězec). Tohle je v Pythonu legální. Někteří programátoři vás ve skutečnosti zapřísahají: "Nepište náhrady. Dokumentujte!")

Teď už testovací případy opravdu selžou (fail).

```
you@localhost:~/diveintopython3/examples$ python3 romantest5.py
F.F...
______
FAIL: test_from_roman_known_values (__main__.KnownValues)
from_roman should give known result with known input
Traceback (most recent call last):
 File "romantest5.py", line 79, in test_from_roman_known_values
   self.assertEqual(integer, result)
AssertionError: 1 != None
______
FAIL: test_roundtrip (__main__.RoundtripCheck)
from_roman(to_roman(n))==n for all n
Traceback (most recent call last):
 File "romantest5.py", line 104, in test_roundtrip
   self.assertEqual(integer, result)
AssertionError: 1 != None
Ran 7 tests in 0.002s
FAILED (failures=2)
Nastal čas napsat funkci from_roman().
def from_roman(s):
   """convert Roman numeral to integer"""
   result = 0
   index = 0
   for numeral, integer in roman_numeral_map:
       while s[index:index+len(numeral)] == numeral:
                                                         [1]
          result += integer
          index += len(numeral)
   return result
```

Základní vzorec je zde stejný jako u funkce to\_roman(). Procházíme datovou strukturou s římskými čísly (n-tice n-tic), ale místo hledání nejvyšších možných číselných hodnot se snažíme hledat řetězec znaků s "nejvyšším" možným římským číslem.

Pokud vám pořád není jasné, jak funkce from\_roman() pracuje, přidejte na konec cyklu while volání funkce print:

```
def from_roman(s):
    """convert Roman numeral to integer"""
    result = 0
    index = 0
    for numeral, integer in roman_numeral_map:
        while s[index:index+len(numeral)] == numeral:
            result += integer
            index += len(numeral)
            print('found', numeral, 'of length', len(numeral), ', adding', integer)
>>> import roman5
>>> roman5.from_roman('MCMLXXII')
found M of length 1, adding 1000
found CM of length 2, adding 900
found L of length 1, adding 50
found X of length 1, adding 10
found X of length 1, adding 10
found I of length 1, adding 1
found I of length 1, adding 1
1972
Nastal opět čas ke spuštění testů.
you@localhost:~/diveintopython3/examples$ python3 romantest5.py
Ran 7 tests in 0.060s
```

Máme tady dvě vzrušující zprávy. Ta první je, že funkce from\_roman() funguje pro správné vstupy — přinejmenším pro všechny známé hodnoty. Ta druhá zpráva je, že test "kruhovým voláním" (round trip test) také prošel. Když to zkombinujeme dohromady, můžeme si být docela jistí tím, že jak funkce to\_roman(), tak funkce from\_roman() pracují správně pro všechny možné správné hodnoty. (Není to ale zaručeno. Teoreticky je možné, že to\_roman() obsahuje chybu, která pro určité hodnoty vstupů produkuje špatná římská čísla, a současně funkce from\_roman() obsahuje obrácenou chybu, která pro-

OK

dukuje stejná, ale špatná čísla přesně pro tu množinu římských čísel, která funkce to\_roman() vygenerovala nesprávně. V závislosti na vaší aplikaci a na požadavcích by vám to mohlo dělat starosti. Pokud tomu tak je, napište obsažnější testovací případy, které vaše starosti rozptýlí.)

#### 9.7. Více špatných vstupů

Teď, když už funkce from\_roman() pracuje správně pro korektní vstup, nastal čas k umístění posledního kousku skládanky — zajištění správné funkce pro špatné vstupy. To znamená, že musíme najít způsob, jak se podívat na řetězec a určit, zda je platným římským číslem. To už je ze své podstaty obtížnější než ověřování správnosti číselného vstupu ve funkci to\_roman(). Ale máme k dispozici mocný nástroj — regulární výrazy. (Pokud regulární výrazy neznáte, pak je vhodná doba na to, abyste si přečetli kapitolu <u>o regulárních výrazech</u>.)

V podkapitole <u>Případová studie</u>: <u>Římská čísla</u> jsme viděli, že existuje několik jednoduchých pravidel pro konstrukci římského čísla, která jsou založena na využití písmen M, D, C, L, X, V a I. Pojďme si tato pravidla zopakovat:

V některých případech se znaky sčítají. I je 1, II je rovno 2 a III znamená 3. VI se rovná 6 (doslova "5 a 1"), VII je 7 a VIII je 8.

- Desítkové znaky (I, X, C a M) se mohou opakovat nanejvýš třikrát. Hodnotu 4 musíme vyjádřit odečtením od dalšího vyššího pětkového znaku. Hodnotu 4 nemůžeme zapsat jako IIII. Místo toho ji musíme zapsat jako IV ("o 1 méně než 5"). 40 se zapisuje jako XL ("o 10 méně než 50"), 41 jako XLI, 42 jako XLII, 43 jako XLIII a následuje 44 jako XLIV ("o 10 méně než 50 a k tomu o 1 méně než 5").
- Někdy znaky vyjadřují... opak sčítání. Když některé znaky umístíme před jiné, provádíme odčítání od konečné hodnoty. Například hodnotu 9 musíme vyjádřit odečtením od dalšího vyššího desítkového znaku: 8 zapíšeme jako VIII, ale 9 zapíšeme IX ("o 1 méně než 10") a ne jako VIIII (protože znak I nemůžeme opakovat čtyřikrát). 90 je XC, 900 je CM.
- Pětkové znaky se nesmí opakovat. 10 se vždy zapisuje jako X a nikdy jako VV. 100 je vždy C,
- Římská čísla se čtou zleva doprava, takže na pořadí znaků velmi záleží. DC znamená 600, ale CD je úplně jiné číslo (400, "o 100 méně než 500"). CI je 101, ale IC není dokonce vůbec platné římské číslo (protože 1 nemůžeme přímo odčítat od 100; musíme to napsat jako XCIX, "o 10 méně než 100 a k tomu o 1 méně než 10").

Takže jeden z užitečných testů bude ověřovat, že by funkce from\_roman() měla selhat (fail) v případě, kdy jí předáme řetězec s příliš mnoha opakujícími se římskými číslicemi. Co znamená "příliš mnoho", závisí na konkrétní číslici.

```
class FromRomanBadInput(unittest.TestCase):
    def test_too_many_repeated_numerals(self):
        '''from_roman should fail with too many repeated numerals'''
        for s in ('MMMM', 'DD', 'CCCC', 'LL', 'XXXX', 'VV', 'IIII'):
            self.assertRaises(roman6.InvalidRomanNumeralError, roman6.from_roman, s)
```

Další užitečný test bude založen na kontrole, že se neopakují některé vzory. Například IX je 9, ale IXIX je vždy neplatné.

```
def test_repeated_pairs(self):
    '''from_roman should fail with repeated pairs of numerals'''
    for s in ('CMCM', 'CDCD', 'XCXC', 'XLXL', 'IXIX', 'IVIV'):
        self.assertRaises(roman6.InvalidRomanNumeralError, roman6.from_roman, s)
```

Třetí test by mohl kontrolovat, zda se číslice objevují ve správném pořadí, od nejvyšších k nejnižším hodnotám. Například CL je 150, ale LC je vždy neplatné, protože číslice pro 50 se nesmí nikdy vyskytovat před číslicí pro 100. Tento test zahrnuje náhodně zvolenou množinu nesprávných předchůdců: I před M, V před X a tak dále.

Každý z těchto testů spoléhá na to, že funkce from\_roman() vyvolává novou výjimku InvalidRoman-NumeralError, kterou jsme ještě nedefinovali.

```
# roman6.py
class InvalidRomanNumeralError(ValueError): pass
```

Všechny tři testy by měly selhat (fail), protože funkce from\_roman() momentálně neprovádí žádnou kontrolu platnosti. (Pokud by neselhaly teď, tak co by vlastně testovaly?)

```
Traceback (most recent call last):
 File "romantest6.py", line 113, in test_malformed_antecedents
   self.assertRaises(roman6.InvalidRomanNumeralError, roman6.from_roman, s)
AssertionError: InvalidRomanNumeralError not raised by from_roman
______
FAIL: test_repeated_pairs (__main__.FromRomanBadInput)
from_roman should fail with repeated pairs of numerals
______
Traceback (most recent call last):
 File "romantest6.py", line 107, in test_repeated_pairs
   self.assertRaises(roman6.InvalidRomanNumeralError, roman6.from_roman, s)
AssertionError: InvalidRomanNumeralError not raised by from_roman
______
FAIL: test_too_many_repeated_numerals (__main__.FromRomanBadInput)
from_roman should fail with too many repeated numerals
Traceback (most recent call last):
 File "romantest6.py", line 102, in test_too_many_repeated_numerals
   self.assertRaises(roman6.InvalidRomanNumeralError, roman6.from_roman, s)
AssertionError: InvalidRomanNumeralError not raised by from_roman
Ran 10 tests in 0.058s
FAILED (failures=3)
Fajn. Teď už do funkce from_roman() potřebujeme přidat jen regulární výraz, který testuje platnost
římských čísel.
roman_numeral_pattern = re.compile('''
                     # začátek řetězce
   M\{0,3\}
                     # tisíce - 0 až 3 M
   (CM|CD|D?C{0,3})
                     # stovky - 900 (CM), 400 (CD), 0-300 (0 až 3 C),
                              nebo 500-800 (D následované 0 až 3 C)
                     # desítky - 90 (XC), 40 (XL), 0-30 (0 až 3 X),
   (XC|XL|L?X{0,3})
                             nebo 50-80 (L následované 0 až 3 X)
   (IX|IV|V?I\{0,3\})
                     # jednotky - 9 (IX), 4 (IV), 0-3 (0 až 3 I),
                             nebo 5-8 (V následované 0 až 3 I)
                     # konec řetězce
   ''', re.VERBOSE)
```

A cenu za zklamání roku dostává... slovo "OK", které modul unittest zobrazí poté, co všechny testy prošly.

- "After one has played a vast quantity of notes and more notes, it is simplicity that emerges as the crowning reward of art."

  (Poté, co jste zahráli ohromné množství not a ještě více not, se jako vrcholná odměna umění objeví jednoduchost.)
  - Frédéric Chopin

# 10. Refaktorizace

# Refaktorizace — 219 Ponořme se — 221 Zvládání měnících se požadavků — 223 Refaktorizace — 228 Shrnutí — 232

#### 10.1. Ponořme se

K chybám dochází, ať se vám to líbí nebo ne. Chyby se objeví navzdory vašemu nejlepšímu úsilí o vytvoření všezahrnujících testů jednotek (unit test). Co vlastně myslím slovem "chyba"? Chybou rozumím testovací případ (test case), který jste ještě nenapsali.

```
>>> import roman7
>>> roman7.from_roman('')
0
```

Tohle je chyba. Prázdný řetězec by měl vyvolat výjimku InvalidRomanNumeralError stejně jako jiné posloupnosti znaků, které nevyjadřují platné římské číslo.

Jakmile chybu umíte navodit, měli byste napsat testovací případ (test case) ještě dříve, než ji opravíte. Tím chybu popíšete.

```
class FromRomanBadInput(unittest.TestCase):
    .
    .
    def testBlank(self):
     '''from_roman should fail with blank string'''
    self.assertRaises(roman6.InvalidRomanNumeralError, roman6.from_roman, '') [1]
```

Je to docela jednoduché. Voláme funkci from\_roman() s prázdným řetězcem a ujišťujeme se, že vyvolává výjimku InvalidRomanNumeralError. Nalezení chyby je obtížnou částí úkolu. Pokud už o ní víme, představuje její otestování snadnou část úkolu.

Protože náš kód obsahuje chybu a protože už máme k dispozici testovací případ, který ji popisuje, dojde k jeho selhání:

```
you@localhost:~/diveintopython3/examples$ python3 romantest8.py -v from_roman should fail with blank string ... FAIL from_roman should fail with malformed antecedents ... ok from_roman should fail with repeated pairs of numerals ... ok from_roman should fail with too many repeated numerals ... ok from_roman should give known result with known input ... ok to_roman should give known result with known input ... ok from_roman(to_roman(n))==n for all n ... ok to_roman should fail with negative input ... ok to_roman should fail with non-integer input ... ok to_roman should fail with large input ... ok to_roman should fail with large input ... ok
```

```
FAIL: from_roman should fail with blank string
Traceback (most recent call last):
  File "romantest8.py", line 117, in test_blank
    self.assertRaises(roman8.InvalidRomanNumeralError, roman8.from_roman, '')
AssertionError: InvalidRomanNumeralError not raised by from_roman
Ran 11 tests in 0.171s
FAILED (failures=1)
Teď už chybu můžeme opravit.
def from_roman(s):
    '''convert Roman numeral to integer'''
                                                                                   [1]
        raise InvalidRomanNumeralError('Input can not be blank')
    if not re.search(romanNumeralPattern, s):
        raise InvalidRomanNumeralError('Invalid Roman numeral: {}'.format(s))
                                                                                   [2]
    result = 0
    index = 0
    for numeral, integer in romanNumeralMap:
        while s[index:index+len(numeral)] == numeral:
            result += integer
            index += len(numeral)
    return result
```

\_\_\_\_\_

- [1] Musíme přidat jen dva řádky kódu: explicitní kontrolu na prázdný řetězec a příkaz raise.
- Myslím, že o tomhle jsem se v této knize zatím ještě nezmínil. Nechť to slouží jako závěrečná lekce z formátování řetězců. Počínaje verzí Python 3.1 můžete při specifikaci formátu vynechat čísla pozičních indexů. To znamená, že místo specifikátoru {0}, kterým se odkazujeme na první parametr metody format(), můžeme jednoduše použít {} a Python doplní správný poziční index za nás. Funguje to pro libovolný počet argumentů. První {} se chápe jako {0}, druhý výskyt {} znamená {1} a tak dále.

```
you@localhost:~/diveintopython3/examples$ python3 romantest8.py -v
from_roman should fail with blank string ... ok
from_roman should fail with malformed antecedents ... ok
from_roman should fail with repeated pairs of numerals ... ok
from_roman should fail with too many repeated numerals ... ok
```

OK

```
from_roman should give known result with known input ... ok
to_roman should give known result with known input ... ok
from_roman(to_roman(n))==n for all n ... ok
to_roman should fail with negative input ... ok
to_roman should fail with non-integer input ... ok
to_roman should fail with large input ... ok
to_roman should fail with 0 input ... ok

To_roman should fail with 0 input ... ok
```

[1] Testovací případ pro prázdný řetězec prošel, takže chyba je opravena.

Všechny ostatní testovací případy prošly také. To znamená, že jsme opravou chyby nic jiného nepokazili. Přestaňte psát kód.

[2]

Tento přístup k programování opravu chyb nijak neusnadňuje. Jednoduché chyby (jako je tato) vyžadují jednodušší testovací případy, složité chyby povedou k složitým testovacím případům. V prostředí soustředěném kolem testů se může zdát, že oprava chyby trvá déle. Musíme chybu přesně popsat v kódu (tj. musíme napsat testovací případ) a teprve potom ji opravit. Pokud testovací případ hned neprojde, musíme zjistit, zda jsme udělali chybu v opravě, nebo zda je chyba v kódu testovacího případu. Ale z dlouhodobého hlediska se střídavá tvorba testovacího a testovaného kódu vyplatí, protože se tím zvyšuje pravděpodobnost správné opravy chyb napoprvé. S vaším novým testem se také snadno opakovaně spouštějí *všechny* testy. Proto je málo pravděpodobné, že opravou nového kódu pokazíte původní kód. Dnešní test jednotky (unit test) je zítřejším regresním testem.

## 10.2. Zvládání měnících se požadavků

Navzdory vašemu nejlepšímu úsilí o připíchnutí zákazníka k zemi, poté co z něj při bolestivé proceduře zahrnující hrůzné odpornosti (jako jsou nůžky a horký vosk) vytáhnete přesné požadavky... ty požadavky se změní. Většina zákazníků neví, co chce, dokud to neuvidí. A dokonce když už to vidí, nejsou dost dobří na to, aby vyjádřili, co chtějí, tak přesně, aby to k něčemu bylo. A dokonce i když se vyjádří přesně, v příští verzi toho stejně budou chtít víc. Takže v souvislosti s měnícími se požadavky buďte připraveni na úpravy svých testovacích případů (test case).

Dejme tomu, že bychom například chtěli rozšířit rozsah funkce pro převod římských čísel. V římských číslech se žádný znak nemůže opakovat víc než třikrát. Ale Římané byli ochotni připustit výjimku z tohoto pravidla a reprezentovat hodnotu 4000 uvedením čtyř M za sebou. Pokud takovou změnu provedeme, budeme schopni rozšířit rozsah převáděných čísel z 1..3999 na 1..4999. Ale nejdříve provedeme úpravy testovacích případů.

```
class KnownValues(unittest.TestCase):
   known_values = ((1, 'I'),
                     (3999, 'MMMCMXCIX'),
                     (4000, 'MMMM'),
                                                                          [1]
                     (4500, 'MMMMD'),
                     (4888, 'MMMMDCCCLXXXVIII'),
                     (4999, 'MMMMCMXCIX') )
class ToRomanBadInput(unittest.TestCase):
   def test_too_large(self):
        '''to_roman should fail with large input'''
        self.assertRaises(roman8.OutOfRangeError, roman8.to_roman, 5000) [2]
class FromRomanBadInput(unittest.TestCase):
   def test_too_many_repeated_numerals(self):
        '''from_roman should fail with too many repeated numerals'''
        for s in ('MMMMM', 'DD', 'CCCC', 'LL', 'XXXX', 'VV', 'IIII'):
            self.assertRaises(roman8.InvalidRomanNumeralError, roman8.from_roman, s)
class RoundtripCheck(unittest.TestCase):
   def test_roundtrip(self):
        '''from_roman(to_roman(n))==n for all n'''
        for integer in range(1, 5000):
                                                                          [4]
            numeral = roman8.to_roman(integer)
            result = roman8.from_roman(numeral)
            self.assertEqual(integer, result)
```

- Stávající známé hodnoty se nemění (pořád jde o rozumné testovací hodnoty), ale potřebujeme přidat pár dalších v rozsahu od 4000. Přidali jsme 4000 (nejkratší), 4500 (druhé nejkratší), 4888 (nejdelší) a 4999 (největší).
- Změnila se definice "velké vstupní hodnoty". U tohoto testu se při volání to\_roman() s hodnotou 4000 očekávala chyba. Teď se ale rozsah 4000-4999 považuje za správné hodnoty, proto musíme hranici zvýšit na 5000.

- Změnila se také definice "příliš mnoho opakujících se znaků". U tohoto testu se při volání tfrom\_roman() se vstupem 'MMMM' očekávala chyba. Teď je MMMM považováno za platné římské číslo. Testovací hodnotu musíme zvětšit na 'MMMMM'.
- Test funkčnosti procházel v cyklu každým číslem z intervalu 1 až 3999. Rozsah se teď rozšířil, takže cyklus for musíme upravit, aby se dostal až k 4999.

Teď máme testovací případy upraveny ve shodě s novými požadavky, ale kód zatím ne. Takže se dá čekat, že některé z testů selžou.

```
you@localhost:~/diveintopython3/examples$ python3 romantest9.py -v
from_roman should fail with blank string ... ok
from_roman should fail with malformed antecedents ... ok
from_roman should fail with non-string input ... ok
from_roman should fail with repeated pairs of numerals ... ok
from_roman should fail with too many repeated numerals ... ok
from_roman should give known result with known input ... ERROR
                                                                    [1]
to_roman should give known result with known input ... ERROR
                                                                    [2]
from_roman(to_roman(n))==n for all n ... ERROR
                                                                    [3]
to_roman should fail with negative input ... ok
to_roman should fail with non-integer input ... ok
to_roman should fail with large input ... ok
to_roman should fail with 0 input ... ok
ERROR: from_roman should give known result with known input
______
Traceback (most recent call last):
 File "romantest9.py", line 82, in test_from_roman_known_values
   result = roman9.from_roman(numeral)
 File "C:\home\diveintopython3\examples\roman9.py", line 60, in from_roman
   raise InvalidRomanNumeralError('Invalid Roman numeral: {0}'.format(s))
roman9.InvalidRomanNumeralError: Invalid Roman numeral: MMMM
______
ERROR: to_roman should give known result with known input
Traceback (most recent call last):
 File "romantest9.py", line 76, in test_to_roman_known_values
   result = roman9.to_roman(integer)
 File "C:\home\diveintopython3\examples\roman9.py", line 42, in to_roman
   raise OutOfRangeError('number out of range (must be 0..3999)')
roman9.OutOfRangeError: number out of range (must be 0..3999)
```

```
ERROR: from_roman(to_roman(n))==n for all n

Traceback (most recent call last):
   File "romantest9.py", line 131, in testSanity
        numeral = roman9.to_roman(integer)
   File "C:\home\diveintopython3\examples\roman9.py", line 42, in to_roman
        raise OutOfRangeError('number out of range (must be 0..3999)')

roman9.OutOfRangeError: number out of range (must be 0..3999)

Ran 12 tests in 0.171s

FAILED (errors=3)
```

- Test známých hodnot pro from\_roman() selže v okamžiku, kdy se dostane k hodnotě 'MMMM'. Funkce from\_roman() si totiž pořád myslí, že jde o neplatné římské číslo.
- Test známých hodnot pro to\_roman() selže v okamžiku, kdy se narazí na hodnotu 4000, protože to\_roman() ji stále považuje za hodnotu mimo rozsah.
- [3] Kruhový test selže rovněž u hodnoty 4000, protože to\_roman() ji považuje za hodnotu mimo rozsah.

Máme tedy testovací případy, které selhávají v důsledku nových požadavků, a můžeme uvažovat o opravení kódu do odpovídajícího stavu. (Když s psaním testů jednotek (unit test) začínáte, můžete mít divný pocit, že testovaný kód nikdy "nepředbíhá" testovací případy. Dokud je pozadu, máme pořád nějakou práci před sebou. Jakmile doběhne testovací případy, přestaneme jej upravovat. Jakmile si na to jednou zvyknete, budete se divit, jak jste vůbec dříve mohli programovat bez testů.)

```
roman_numeral_pattern = re.compile('''
                        # začátek řetězce
    M\{0,4\}
                        # tisíce - 0 až 4 M
                                                                           [1]
                        # stovky - 900 (CM), 400 (CD), 0-300 (0 až 3 C),
    (CM|CD|D?C{0,3})
                                 nebo 500-800 (D následované 0 až 3 C)
                        # desítky - 90 (XC), 40 (XL), 0-30 (0 až 3 X),
    (XC|XL|L?X{0,3})
                                 nebo 50-80 (L následované 0 až 3 X)
    (IX|IV|V?I{0,3})
                        # jednotky - 9 (IX), 4 (IV), 0-3 (0 až 3 I),
                                 nebo 5-8 (V následované 0 až 3 I)
                        # konec řetězce
    ''', re.VERBOSE)
```

- Funkci from\_roman() nemusíme vůbec upravovat. Změna se týká jen vzorku roman\_numeral\_ pattern. Při podrobnějším pohledu zjistíte, že jsem v první části regulárního výrazu změnil maximální počet nepovinných znaků M z 3 na 4. Tím povolíme čísla odpovídající hodnotě až 4999 místo původní 3999. Samotná funkce from\_roman() je zcela obecná. Zkrátka jen hledá opakující se znaky římského čísla a sčítá odpovídající hodnoty. Nestará se o to, kolikrát se opakují. Dříve nezvládala 'MMMM' pouze z toho důvodu, že jsme ji explicitně zastavili na základě porovnání s regulárním výrazem.
- Funkce to\_roman() si vyžádá jen jednu malou změnu v místě kontroly rozsahu. Kde jsme dříve testovali 0 < n < 4000, budeme teď kontrolovat 0 < n < 5000. A hlášení o chybě vyvolávané příkazem raise změníme tak, aby odpovídalo novému povolenému rozsahu (1..4999 místo 1..3999). Zbytek funkce nemusíme měnit. Nové případy zvládá. (Vesele přidává 'M' pro každou nalezenou tisícovku. Když dostane 4000 vychrlí 'MMMM'. Dříve tento případ nezvládala jen proto, že jsme ji explicitně zastavili při kontrole rozsahu.)

Možná pochybujete o tom, že by tyhle dvě malé změny vyřešily vše, co potřebujeme. Nemusíte mi to věřit. Zkontrolujte si to sami.

```
you@localhost:~/diveintopython3/examples$ python3 romantest9.py -v from_roman should fail with blank string ... ok from_roman should fail with malformed antecedents ... ok from_roman should fail with non-string input ... ok from_roman should fail with repeated pairs of numerals ... ok from_roman should fail with too many repeated numerals ... ok from_roman should give known result with known input ... ok
```

[1] Všechny testovací případy prošly. Přestaňte psát kód.

Při používání obsáhlých testů jednotek nemusíte spoléhat na programátora, který říká: "Věř mi."

#### 10.3. Refaktorizace

Na komplexním používání testů jednotek (unit testing) není nejlepší to, jak se cítíte, když všechny testovací případy nakonec projdou, dokonce ani to, jak se cítíte, když vás někdo nařkne, že jste mu pokazili jeho kód, a vy ve skutečnosti můžete *dokázat*, že tomu tak není. Na testech jednotek je nejlepší věcí to, že vám dává volnost nemilosrdně refaktorizovat.

Refaktorizace je činností, kdy vezmete fungující kód a uděláte z něj ještě lepší. "Lepší" obvykle znamená "rychlejší", ale může to taky znamenat "používající méně paměti" nebo "používající menší diskový prostor" nebo je prostě "elegantnější". Refaktorizace je z hlediska dlouhodobého zdraví každého programu důležitá, ať už to znamená cokoliv pro vás, pro váš projekt nebo pro vaše okolí.

V případě našeho kódu bude "lepší" znamenat jak "rychlejší", tak "snadněji udržovatelný". Konkrétně funkce from\_roman() je pomalejší a složitější, než by se mi líbilo. Je to dáno oním velkým, hnusným regulárním výrazem, který se používá pro ověřování, zda jde o římské číslo. Teď si možná pomyslíte: "No jo. Ten regulární výraz sice je velký a střapatý, ale jak jinak by se dalo ověřit, zda je libovolný řetězec platným římským číslem?"

Odpověď zní: Těch čísel je jen 5000. Proč bychom pro ně prostě nemohli vytvořit vyhledávací tabulku? Ta myšlenka se vám bude líbit ještě víc, když zjistíte, že *vůbec nebudeme potřebovat regulární výrazy*. Při budování vyhledávací tabulky pro převod čísel na římská čísla můžeme současně vytvářet opačnou vyhledávací tabulku pro konverzi římských čísel na celá čísla. Při testu, zda je libovolný řetězec platným římským číslem, budeme mít k dispozici všechna platná římská čísla. "Ověření platnosti" se redukuje na jedno vyhledání ve slovníku.

A ze všeho nejlepší je, že už máme k dispozici úplnou sadu testů jednotek (unit test). V modulu můžeme vyměnit klidně polovinu kódu, ale testy jednotek zůstanou stejné. To znamená, že můžete dokázat — sami sobě a ostatním —, že nový kód funguje stejně dobře jako ten původní.

```
class OutOfRangeError(ValueError): pass
class NotIntegerError(ValueError): pass
class InvalidRomanNumeralError(ValueError): pass
roman_numeral_map = (('M', 1000),
                     ('CM', 900),
                     ('D', 500),
                     ('CD', 400),
                     ('C', 100),
                     ('XC', 90),
                     ('L', 50),
                     ('XL', 40),
                     ('X', 10),
                     ('IX', 9),
                     ('V', 5),
                     ('IV', 4),
                     ('I', 1))
to_roman_table = [ None ]
from_roman_table = {}
def to_roman(n):
    '''convert integer to Roman numeral'''
    if not (0 < n < 5000):
        raise OutOfRangeError('number out of range (must be 1..4999)')
    if int(n) != n:
        raise NotIntegerError('non-integers can not be converted')
    return to_roman_table[n]
def from_roman(s):
    '''convert Roman numeral to integer'''
    if not isinstance(s, str):
        raise InvalidRomanNumeralError('Input must be a string')
    if not s:
        raise InvalidRomanNumeralError('Input can not be blank')
    if s not in from_roman_table:
        raise InvalidRomanNumeralError('Invalid Roman numeral: {0}'.format(s))
    return from_roman_table[s]
```

```
def build_lookup_tables():
    def to_roman(n):
        result = ''
        for numeral, integer in roman_numeral_map:
            if n >= integer:
                result = numeral
                n -= integer
                break
        if n > 0:
            result += to_roman_table[n]
        return result
    for integer in range(1, 5000):
        roman_numeral = to_roman(integer)
        to_roman_table.append(roman_numeral)
        from_roman_table[roman_numeral] = integer
build_lookup_tables()
```

Rozdělme si to na stravitelné kousky. Prokazatelně nejdůležitějším řádkem je ten poslední:

```
build_lookup_tables()
```

Jistě si všimnete, že jde o volání funkce. Ale není tu žádný obalující příkaz if. Tady nejde o blok uvnitř if \_\_name\_\_ == '\_\_main\_\_'. Funkce se zavolá v okamžiku importu modulu. (Zde je důležité vědět, že se moduly importují jen jednou a poté se pamatují ve vyrovnávací paměti (cache). Pokud importujeme už jednou importovaný modul, nic se neděje. Takže uvedený kód bude zavolán jen při prvním importu tohoto modulu.)

Co vlastně funkce build\_lookup\_tables() dělá? To jsem rád, že se ptáte.

```
if n > 0:
    result += to_roman_table[n]
return result

for integer in range(1, 5000):
    roman_numeral = to_roman(integer) [2]
    to_roman_table.append(roman_numeral) [3]
    from_roman_table[roman_numeral] = integer
```

- Tohle je takový chytrý programátorský obrat... možná až příliš chytrý. Funkce to\_roman() je definována výše. Vyhledává hodnoty ve vyhledávací tabulce a vrací je. Ale funkce build\_lookup\_tables() si pro realizaci převodu vytváří svou vlastní definici funkce to\_roman() (stejnou, jaká se používala v předchozích případech, než jsme přidali vyhledávací tabulku). Uvnitř funkce build\_lookup\_tables() se bude volat ta redefinovaná verze funkce to\_roman(). Jakmile funkce build\_lookup\_tables() skončí, redefinovaná verze zmizí. Její definice je platná jen lokálně, uvnitř funkce build\_lookup\_tables().
- Na tomto řádku kódu se volá redefinovaná funkce to\_roman(), která ve skutečnosti vytváří římské číslo.
- Jakmile máme k dispozici výsledek (redefinované funkce to\_roman()), přidáme číslo a jemu odpovídající římské číslo do obou vyhledávacích tabulek.

Jakmile jsou vyhledávací tabulky naplněny, je zbývající kód jednoduchý a rychlý.

```
def to_roman(n):
    '''convert integer to Roman numeral'''
    if not (0 < n < 5000):
        raise OutOfRangeError('number out of range (must be 1..4999)')
    if int(n) != n:
        raise NotIntegerError('non-integers can not be converted')
    return to_roman_table[n]
                                                                                   [1]
def from_roman(s):
    '''convert Roman numeral to integer'''
    if not isinstance(s, str):
        raise InvalidRomanNumeralError('Input must be a string')
    if not s:
        raise InvalidRomanNumeralError('Input can not be blank')
    if s not in from_roman_table:
        raise InvalidRomanNumeralError('Invalid Roman numeral: {0}'.format(s))
    return from_roman_table[s]
                                                                                   [2]
```

Funkce to\_roman() provede stejné kontroly hraničních případů (jako dříve) a potom jednoduše najde odpovídající hodnotu ve vyhledávací tabulce a vrátí ji.

Také funkce from\_roman() je redukována na kontroly a jeden řádek kódu. Už žádné regulární výrazy. Už žádné cykly. Převod na a z římského čísla se složitostí O(1) — tj. v konstantním čase.

Ale funguje to? Proč se ptáte? Jasně že funguje. A můžu to dokázat.

```
you@localhost:~/diveintopython3/examples$ python3 romantest10.py -v from_roman should fail with blank string ... ok from_roman should fail with malformed antecedents ... ok from_roman should fail with non-string input ... ok from_roman should fail with repeated pairs of numerals ... ok from_roman should fail with too many repeated numerals ... ok from_roman should give known result with known input ... ok to_roman should give known result with known input ... ok from_roman(to_roman(n))==n for all n ... ok to_roman should fail with negative input ... ok to_roman should fail with non-integer input ... ok to_roman should fail with large input ... ok
To_roman should fail with large input ... ok
To_roman should fail with 0 input ... ok
To_roman should fail with 0 input ... ok
```

OK

Tedy, ne že byste se ptali, ale ono je to taky rychlé! Skoro 10krát rychlejší. Není to, samozřejmě, úplně férové srovnání, protože u této verze trvá déle import (budují se vyhledávací tabulky).

Ale protože se import dělá jen jednou, rozpustí se nákladnost při startu mezi volání funkcí to\_roman() a from\_roman(). A protože se při testech provádí několik tisíc volání funkcí (jen samotný kruhový test jich provede 10 000), úspory se rychle nasčítají!

[1]

#### A jak zní ponaučení?

- V jednoduchosti je síla.
- Zvláště tehdy, když jsou do toho zapletené regulární výrazy.
- Díky testům jednotek (unit test) získáte sebedůvěru a odvahu k provádění rozsáhlé refaktorizace.

#### 10.4. Shrnutí

Unit testing (testování jednotek) představuje mocný koncept, který při správné implementaci vede u dlouhodobých projektů jak k redukci nákladů na údržbu, tak ke zvýšení pružnosti. Současně si ale musíme uvědomit, že testování jednotek není všelék. Napsat dobré testové případy není jednoduchá věc a udržet je v aktuálním stavu vyžaduje disciplínu (zvlášť když zákazníci vřískají, aby byly opra-

veny kritické chyby). Unit testing není náhradou ostatních forem testování, zahrnujících testování funkčnosti celého systému, integrační testování (tj. test spolupráce jednotek) a uživatelské akceptační testy. Testy jednotek jsou ale přesto rozumné, fungují, a když už je jednou uvidíte v činnosti, budete se divit, jak jste se bez nich mohli obejít.

V pár posledních kapitolách jsme se šířeji zabývali základy, z nichž mnohé dokonce nejsou specifické jen pro Python. Rámce pro testování jednotek (unit testing frameworks) jsou dostupné pro mnoho jazyků a všechny vyžadují, abyste porozuměli týmž konceptům:

- Návrh testovacích případů (test case), které jsou specifické, automatizované a nezávislé.
- Napsání testovacích případů před psaním kódu, který mají testovat.
- Psaní testů, které testují správné vstupy a kontrolují očekávané výsledky.
- Psaní testů, které testují chybné vstupy a kontrolují očekávané chybové reakce.
- Psaní a aktualizace testovacích případů tak, aby odrážely nové požadavky.
- Nemilosrdná refaktorizace za účelem zvýšení výkonnosti, škálovatelnosti, čitelnosti, udržovatelnosti a jakýchkoliv jiných -ostí, po kterých toužíte.

- "A nine mile walk is no joke, especially in the rain." (Jít devět mil není žádná legrace, zvlášť v dešti.)
- Harry Kemelman, The Nine Mile Walk

# 11. Soubory

| 11.     | Soubory — 235   |
|---------|---|
| 11.1.   | Ponořme se — 237  |
| 11.2.   | Čtení z textových souborů — 237                         |
| 11.2.1. | Kódování znaků vystrkuje svou ošklivou hlavu — 23       |
| 11.2.2. | Objekty typu stream — 238                               |
| 11.2.3. | Čtení dat z textového souboru — 239                     |
| 11.2.4. | Zavírání souborů — <b>241</b>                           |
| 11.2.5. | Automatické zavírání souborů — <b>242</b>               |
| 11.2.6. | Čtení dat po řádcích — 243                              |
| 11.3.   | Zápis do textových souborů — <b>245</b>                 |
| 11.3.1. | A znovu kódování znaků — <b>246</b>                     |
| 11.4.   | Binární soubory — <b>246</b>                            |
| 11.5.   | Objekty typu stream z nesouborových zdrojů — <b>247</b> |
| 11.5.1. | Práce s komprimovanými soubory — <b>249</b>             |
| 11.6.   | Standardní vstup, výstup a chybový výstup — <b>250</b>  |
| 11.6.1. | Přesměrování standardního výstupu — <b>251</b>          |

Přečtěte si — **254** 

11.7.

- 11.1. Ponořme se
- 11.2. Čtení z textových souborů

#### 11.1. Ponořme se

Než jsem začal instalovat první aplikaci, obsahovaly Windows na mém laptopu 38 493 souborů. Po instalaci Pythonu 3 k nim přibylo téměř 3000 dalších. Každý významnější operační systém považuje soubory za základ ukládání dat. Koncepce souborů je tak zakořeněná, že by představa jiné možnosti dělala většině lidí problémy. Obrazně řečeno, váš počítač se topí v souborech.

## 11.2. Čtení z textových souborů

Než můžeme ze souboru číst, musíme jej otevřít. Otvírání souborů v Pythonu už nemohlo být jednodušší.

```
a_file = open('examples/chinese.txt', encoding='utf-8')
```

V Pythonu najdeme zabudovanou funkci open(), která přebírá jméno souboru jako argument. Jménem souboru je zde 'examples/chinese.txt'. Na uvedeném jméně souboru najdeme pět zajímavostí:

- Není to pouhé jméno souboru. Je to kombinace adresářové cesty a jména souboru. Hypotetická funkce pro otvírání souboru by mohla požadovat dva argumenty adresářovou cestu a jméno souboru. Ale funkce open() požaduje jen jeden. Kdykoliv se po vás v Pythonu požaduje "jméno souboru", můžete do něj zahrnout také celou adresářovou cestu nebo její část.
- 2. Uvedená adresářová cesta používá normální lomítko, ale neupřesnil jsem, jaký operační systém používám. Windows používají pro oddělování podadresářů zpětná lomítka, zatímco Mac OS X a Linux používají obyčejná lomítka. Ale v Pythonu fungují obyčejná lomítka i pod Windows.
- 3. Uvedená adresářová cesta nezačíná lomítkem nebo písmenem disku, takže ji nazýváme *relativní cesta*. Mohli byste se zeptat relativní k čemu? Zachovejte klid.
- 4. Je to řetězec. Všechny moderní operační systémy (dokonce i Windows!) ukládají jména souborů a adresářů v Unicode. Python 3 plně podporuje jména cest, která nemusí být výhradně v ASCII.
- 5. A nemusí vést jen na váš lokální disk. Můžete mít připojený síťový disk. Daný "soubor" může být fiktivní součástí zcela virtuálního souborového systému. Pokud jej váš počítač považuje za soubor a může k němu jako k souboru přistupovat, může jej Python otevřít také.

Ale volání funkce open() nekončí zadáním jména souboru. Máme zde další argument nazvaný encoding (kódování). No nazdar. To zní příšerně povědomě.

## 11.2.1. Kódování znaků vystrkuje svou ošklivou hlavu

Bajty jsou bajty, znaky jsou abstrakce. Řetězec je posloupností znaků v Unicode. Ale soubor na disku není posloupností Unicode znaků. Soubor na disku je posloupností bajtů. Takže jak Python převádí posloupnost bajtů na posloupnost znaků, když čteme "textový soubor" z disku? Dekóduje bajty podle určitého algoritmu pro kódování znaků a vrací posloupnost znaků v Unicode (známou také jako řetězec).

```
# Tento příklad byl vytvořen pod Windows. Z důvodů popsaných
# níže se na ostatních platformách může chovat jinak.
>>> file = open('examples/chinese.txt')
>>> a_string = file.read()
Traceback (most recent call last):
   File "<stdin>", line 1, in <module>
   File "C:\Python31\lib\encodings\cp1252.py", line 23, in decode
        return codecs.charmap_decode(input,self.errors,decoding_table)[0]
UnicodeDecodeError: 'charmap' codec can't decode byte 0x8f in position 28: character maps to <undefined>
>>>
```

# Výchozí kódování je závislé na platformě.

Co se to vlastně stalo? Neurčili jsme znakové kódování, takže Python byl donucen použít výchozí kódování. Co to je výchozí kódování? Pokud se pořádně podíváme na trasovací výpis, vidíme, že skončil uvnitř cp1252. py. To znamená, že Python použil jako výchozí kódování CP-1252. (CP-1252 je běžné kódování, které se používá na počítačích s Micro-

soft Windows. To se týká západní Evropy. Čeština a slovenština používají kódování CP-1250.) Znaková sada CP-1252 nepodporuje znaky, které se v souboru nacházejí, takže čtení selhává s nepěknou chybou UnicodeDecodeError.

Ale počkejte. Ono je to ještě horší! Výchozí kódování je *závislé na platformě*, takže stejný kód by na vašem počítači fungovat *mohl* (pokud by vaším výchozím kódováním bylo UTF-8). Ale pokud program přenesete k někomu jinému (kdo používá jiné výchozí kódování, jako třeba CP-1252), dojde k selhání.

Pokud potřebujete zjistit výchozí znakové kódování, importujte modul locale a zavolejte locale.getpreferredencoding(). Na mém laptopu s Windows funkce vrací 'cp1252', ale na mém linuxovém stroji v horním pokoji se vrací 'UTF8'. Nejsem schopen udržet shodu dokonce ani ve svém vlastním domě! Ve vašem případě mohou být výsledky jiné (dokonce i pod Windows) v závislosti na verzi operačního systému, který jste nainstalovali, a na konfiguraci regionálních a jazykových nastavení. To je důvod, proč je tak důležité uvádět kódování pokaždé, když otvíráme soubor.

#### 11.2.2. Objekty typu stream

Zatím víme jen to, že Python má zabudovanou funkci zvanou open(). Funkce open() vrací *objekt typu stream* (čti [strím], proud dat), který poskytuje metody a atributy pro získávání informací o proudu znaků a pro manipulaci s ním.

```
>>> a_file = open('examples/chinese.txt', encoding='utf-8')
>>> a_file.name [1]
'examples/chinese.txt'
>>> a_file.encoding [2]
'utf-8'
>>> a_file.mode [3]
```

- Atribut name zachycuje jméno, které jsme při otvírání souboru předali funkci open(). Není upraveno do podoby absolutní cesty.
- Podobně atribut encoding zachycuje kódování, které jsme při otvírání souboru předali funkci open(). Pokud byste při otvírání souboru kódování neuvedli (nepořádný vývojář!), pak by atribut encoding odpovídal výsledku locale.getpreferredencoding().
- Z atributu mode poznáme, v jakém režimu byl soubor otevřen. Funkci open() můžeme předat nepovinný parametr mode (režim). Při otvírání tohoto souboru jsme režim neurčili, takže Python použije výchozí hodnotu 'r', která má význam "otevřít jen pro čtení, v textovém režimu". Jak uvidíme v této kapitole později, plní režim otevření souboru několik účelů. Různé režimy nám umožní do souboru zapisovat, připojovat na konec souboru nebo otvírat soubor v binárním režimu (ve kterém místo s řetězci pracujeme s bajty).
- > Seznam všech možných režimů najdete v dokumentaci pro funkci open().

#### 11.2.3. Čtení dat z textového souboru

Po otevření souboru pro čtení z něj pravděpodobně v určitém místě budete chtít číst.

```
>>> a_file = open('examples/chinese.txt', encoding='utf-8')
>>> a_file.read() [1]
'Dive Into Python 是为有经验的程序员编写的一本 Python 书。\n'
>>> a_file.read() [2]
```

- Jakmile soubor otevřeme (při zadání správného kódování), spočívá čtení z něj v prostém volání metody read() objektu typu stream. Výsledkem je řetězec.
- Trochu překvapující je možná to, že další čtení ze souboru nevyvolá výjimku. Python nepovažuje čtení za koncem souboru za chybu. Vrátí se jednoduše prázdný řetězec.

————— A co kdybychom chtěli soubor číst znovu?

# Při otvírání souboru vždy uvádějte parametr encoding.

```
# pokračování předchozího příkladu
>>> a_file.read()
                                                     [1]
>>> a_file.seek(0)
                                                     [2]
>>> a_file.read(16)
                                                     [3]
'Dive Into Python'
>>> a_file.read(1)
                                                     [4]
>>> a_file.read(1)
'是'
>>> a_file.tell()
                                                     [5]
20
```

- Protože jsme ještě pořád na konci souboru, další volání metody read() vrací prázdný řetězec. [1]
- Metoda seek() zajistí přesun v souboru na určenou bajtovou pozici. [2]
- [3] Metodě read() můžeme zadat nepovinný parametr, který určuje počet znaků, které se mají načíst.
- Pokud budeme chtít, můžeme číst klidně i po jednom znaku. [4]
- $16 + 1 + 1 = \dots 20$ ? [5]

#### Zkusme to znovu.

```
# pokračování předchozího příkladu
>>> a_file.seek(17)
                                                     [1]
17
>>> a_file.read(1)
                                                     [2]
'是'
>>> a_file.tell()
                                                     [3]
20
```

- Přesuneme se na 17. bajt. [1]
- Přečteme jeden znak. [2]
- A najednou jsme na 20. bajtu. [3]

Už jste na to přišli? Metody seek() a tell() počítají vždy po bajtech, ale protože jsme soubor otevřeli v textovém režimu, čte metoda read() po znacích. Pro zakódování čínských znaků v UTF-8 potřebujeme více bajtů. Pro každý anglický znak potřebujeme v souboru jen jeden bajt, takže by vás to mohlo svést k mylnému závěru, že metody seek() a read() počítají stejné jednotky. To ale platí jen pro některé znaky.

Ale moment, začíná to být ještě horší!

- [1] Přesuneme se na 18. bajt a zkusíme přečíst jeden znak.
- Proč to selhalo? Protože na 18. bajtu není znak. Nejbližší znak začíná na 17. bajtu (a zabírá tři bajty).
  Pokus o čtení znaku od středu jeho kódované posloupnosti vede k chybě UnicodeDecodeError.

#### 11.2.4. Zavírání souborů

Otevřené soubory zabírají systémové prostředky a v závislosti na režimu otevření souboru k nim některé programy nemusí být schopny přistupovat. Proto je důležité, abychom soubory zavírali hned poté, co s nimi přestaneme pracovat.

```
# pokračování předchozího příkladu
>>> a_file.close()
```

Tak tohle bylo zklamání.

Objekt a\_file typu stream pořád existuje. Volání jeho metody close() nevede k jeho zrušení. Ale už není nějak zvlášť užitečný.

```
# pokračování předchozího příkladu
>>> a_file.read() [1]
Traceback (most recent call last):
    File "<pyshell#24>", line 1, in <module>
        a_file.read()
ValueError: I/O operation on closed file.
>>> a_file.seek(0) [2]
Traceback (most recent call last):
    File "<pyshell#25>", line 1, in <module>
        a_file.seek(0)
ValueError: I/O operation on closed file.
>>> a_file.tell() [3]
```

```
Traceback (most recent call last):
  File "<pyshell#26>", line 1, in <module>
    a_file.tell()
ValueError: I/O operation on closed file.
>>> a_file.close()
                                                   [4]
>>> a_file.closed
                                                   [5]
True
```

- Ze zavřeného objektu nemůžeme číst. Vyvolá se tím výjimka I0Error. [1]
- V zavřeném souboru nemůžeme ani přesunovat pozici (seek). [2]
- U zavřeného souboru neexistuje žádná aktuální pozice, takže metoda tell() také selže. [3]
- Překvapením možná je, že volání metody close() pro objekt typu stream, jehož soubor byl už [4] zavřený, nevyvolá výjimku. Jde o prázdnou operaci.
- [5] Zavřený objekt typu stream má přece jen jeden užitečný atribut. Atribut closed potvrzuje, že soubor byl uzavřen.

#### 11.2.5. Automatické zavírání souborů

Objekty typu stream mají explicitní metodu close(), ale co se stane, když je ve vašem programu chyba a zhavaruje předtím, než zavoláte close()? Soubor by teoreticky mohl zůstat otevřený mnohem déle, než bychom potřebovali. Pokud zrovna něco ladíte na svém lokálním počítači, není to takový problém. Ale na používaném serveru už možná ano.

## Konstrukce try..finally je dobrá. with je lepší.

Python 2 pro tento případ nabízel řešení v podobě bloku try. . finally. V Pythonu 3 tento obrat stále funguje. Proto se s ním můžete setkat v kódu některých programátorů nebo ve starším kódu, který byl převeden pro Python 3. Ale Python 2.6 zavedl čistší řešení, které se v Pythonu 3 stalo preferovaným. Jde o příkaz with.

```
with open('examples/chinese.txt', encoding='utf-8') as a_file:
   a_file.seek(17)
   a_character = a_file.read(1)
   print(a_character)
```

V tomto kódu se volá open(), ale nikde se v něm nevolá a\_file.close(). Příkaz with zahajuje blok kódu podobně, jako je tomu u příkazu if nebo u cyklu for. Uvnitř bloku kódu můžeme používat proměnnou a\_file, kterou objekt typu stream vrátil jako výsledek volání open(). K dispozici máme všechny obvyklé metody objektu typu stream, jako jsou seek(), read() a všechny ostatní. Když blok with skončí, Python automaticky zavolá a\_file.close().

Kap

Když to shrneme, Python soubor uzavře nezávisle na tom, jak a kdy blok with skončí... i kdyby "skončil" v důsledku neošetřené výjimky. Tak to opravdu je. I v případě, kdy kód vyvolá výjimku a celý váš program se skřípěním zastaví, dotčený soubor bude uzavřen. Je to zaručeno.

Z technického pohledu příkaz with vytváří operační kontext (runtime context). Objekt typu stream je v těchto příkladech využit jako správce kontextu (context manager). Python vytvoří objekt a\_file typu stream a řekne mu, že vstupuje do operačního kontextu. Jakmile blok příkazu with skončí, Python sdělí objektu typu stream, že opouští operační kontext a objekt zavolá svou vlastní metodu close(). Detaily hledejte v příloze B, "Třídy, které mohou být použity v bloku with".

Příkaz wi th není nijak zvlášť zaměřen na soubory. Je to prostě obecný rámec pro vytvoření operačního kontextu. Objekt se dozví, že vstupuje do operačního kontextu nebo že z něj vystupuje. Pokud je dotčený objekt typu stream, pak provede užitečné "souborové" věci (jako je například automatické uzavření souboru). Ale toto chování je definováno uvnitř objektu typu stream a ne v příkazu with. Správce kontextu může být použit mnoha jinými způsoby, které nemají se soubory nic společného. Můžete si dokonce vytvořit svého vlastního správce kontextu. Ukážeme si to o něco později, ale ještě v této kapitole.

## 11.2.6. Čtení dat po řádcích

"Řádek" textového souboru je to, co si myslíte, že by to mělo být — napíšete pár slov, stisknete ENTER a najednou jste na novém řádku. Řádek textu je posloupnost znaků oddělená... čím vlastně? Ono je to komplikované, protože textové soubory mohou pro označení konce řádků použít několik různých znaků. Každý operační systém má svou vlastní konvenci. Některé používají znak návratu vozíku (carriage return), jiné používají znak přechodu na nový řádek (line feed) a některé používají na konci každého řádku oba zmíněné znaky.

Teď si můžete s úlevou oddechnout, protože Python zpracovává konce řádků automaticky. Pokud řeknete "chci přečíst tento textový soubor řádek po řádku", Python zjistí, který typ konců řádků se v textovém souboru používá, a zařídí, že to prostě bude fungovat.

Pokud potřebujete získat detailní kontrolu nad tím, co se považuje za konec řádku, můžete funkci > open() předat nepovinný parametr newline. Detaily najdete v dokumentaci funkce open().

Takže jak se to vlastně dělá? Čtěte ze souboru po řádcích. Je to tak jednoduché. V jednoduchosti je krása.

```
line_number = 0
with open('examples/favorite-people.txt', encoding='utf-8') as a_file:
                                                                            [1]
    for a_line in a_file:
                                                                            [2]
        line_number += 1
        print('{:>4} {}'.format(line_number, a_line.rstrip()))
                                                                            [3]
```

- Použitím vzoru with dosáhneme bezpečného otevření souboru a necháme Python, aby ho za-[1] vřel za nás.
- Pro čtení souboru po řádcích využijeme cyklus for. To je vše. Objekty typu stream podporují [2] metody jako read(), ale kromě toho je objekt typu stream také iterátorem, který vrátí jeden řádek pokaždé, když jej požádáte o další hodnotu.
- Číslo řádku a řádek samotný můžeme zobrazit s využitím řetězcové metody format(). Speci-[3] fikátor formátu {:>4} říká "vytiskni tento argument zarovnaný doprava na šířku čtyř pozic". Proměnná a\_line obsahuje celý řádek, včetně znaků ukončujících řádek. Řetězcová metoda rstrip() odstraní všechny koncové bílé znaky (whitespace) včetně znaků ukončujících řádek.

you@localhost:~/diveintopython3\$ python3 examples/oneline.py

- 1 Dora
- 2 Ethan
- 3 Wesley
- 4 John
- 5 Anne
- 6 Mike
- 7 Chris
- 8 Sarah
- 9 Alex
- 10 Lizzie

Setkali jste se s následující chybou?

```
you@localhost:~/diveintopython3$ python3 examples/oneline.py
Traceback (most recent call last):
  File "examples/oneline.py", line 4, in <module>
    print('{:>4} {}'.format(line_number, a_line.rstrip()))
ValueError: zero length field name in format
```

Pokud ano, pravděpodobně používáte Python 3.0. Měli byste provést aktualizaci na Python 3.1.

Python 3.0 sice podporuje nový způsob formátování řetězců, ale vyžaduje explicitní formátování specifikátorů formátu. Python 3.1 vám umožní ve specifikátorech formátu indexy argumentů vynechávat. Verze kompatibilní s Pythonem 3.0 je pro porovnání zde:

```
print('{0:>4} {1}'.format(line_number, a_line.rstrip()))
```

# 11.3. Zápis do textových souborů

# Soubor prostě otevřete a začněte zapisovat.

Do souborů můžeme zapisovat velmi podobným způsobem, jakým z nich čteme. Soubor nejdříve otevřeme a získáme objekt typu stream. Pro zápis do souboru použijeme jeho metody. Nakonec soubor zavřeme.

Při otvírání souboru pro zápis použijeme funkci open() a předepíšeme režim zápisu. U souborů můžeme použít dva režimy zápisu:

- Režim "write" (zápis) vede k přepsání obsahu souboru. Funkci open() předáme mode='w'.
- Režim "append" přidává data na konec souboru. Funkci open() předáme mode='a'.

Pokud soubor dosud neexistuje, bude při obou uvedených režimech vytvořen automaticky. To znamená, že se nikdy nemusíme piplat s funkčností jako "pokud soubor ještě neexistuje, vytvoř nový, prázdný soubor, abychom jej mohli poprvé otevřít". Prostě soubor otevřeme a začneme zapisovat.

Jakmile zápis do souboru dokončíme, měli bychom jej vždy zavřít, aby došlo k uvolnění deskriptoru souboru (file handle) a abychom zajistili, že došlo ke skutečnému zápisu dat na disk. Stejně jako v případě čtení dat můžeme soubor zavřít voláním metody close() objektu typu stream nebo můžeme použít příkaz with a předat starost o zavření souboru Pythonu. Vsadím se, že uhodnete, kterou techniku doporučuji.

```
>>> with open('test.log', mode='w', encoding='utf-8') as a_file: [1]
... a_file.write('test succeeded') [2]
>>> with open('test.log', encoding='utf-8') as a_file:
... print(a_file.read())
test succeeded
>>> with open('test.log', mode='a', encoding='utf-8') as a_file: [3]
... a_file.write('and again')
>>> with open('test.log', encoding='utf-8') as a_file:
... print(a_file.read())
test succeededand again [4]
```

- Začali jsme odvážně vytvořením nového souboru test.log (nebo přepsáním existujícího souboru) a jeho otevřením pro zápis. Parametr mode='w' znamená "otevři soubor pro zápis". Ano, je to opravdu tak nebezpečné, jak to zní. Doufám, že vám na dřívějším obsahu tohoto souboru nezáleželo (pokud existoval), protože jeho obsah právě zmizel.
- Do nově otevřeného souboru můžeme data přidávat metodou write() objektu, který vrátila funkce open(). Jakmile blok with skončí, Python soubor automaticky uzavře.
- To bylo zábavné. Zkusme to znovu. Ale tentokrát použijeme mode='a', abychom místo přepsání souboru připojili data na jeho konec. Připsání na konec (append) *nikdy* nezničí existující obsah souboru.

Jak původně zapsaný řádek, tak druhý řádek, který jsme připojili teď, se nacházejí v souboru test. log. Všimněte si také, že nepřibyly žádné znaky pro návrat vozíku nebo pro odřádkování. Soubor je neobsahuje, protože jsme je do něj ani při jedné příležitosti explicitně nezapsali. Znak pro návrat vozíku (carriage return) můžeme zapsat jako '\r', znak pro odřádkování (line feed) můžeme zapsat '\n'. Protože jsme nic z toho neudělali, skončilo vše, co jsme zapsali do souboru, na jediném řádku.

#### 11.3.1. A znovu kódování znaků

Všimli jste si parametru encoding, který jsme při otvírání souboru pro zápis předávali funkci open()? Je důležitý. Nikdy ho nevynechávejte! Jak jsme si ukázali na začátku kapitoly, soubory neobsahují řetězce. Soubory obsahují bajty. Z textového souboru můžeme číst "řetězce" jen díky tomu, že jsme Pythonu řekli, jaké má při převodu proudu bajtů na řetězec použít kódování. Zápis textu do souboru představuje stejný problém, jen z opačné strany. Do souboru nemůžeme zapisovat znaky, protože znaky jsou abstraktní. Při zápisu do souboru musí Python vědět, jak má řetězce převádět na posloupnost bajtů. Jediný způsob, jak se ujistit, že se provede správný převod, spočívá v uvedení parametru encoding při otvírání souboru pro zápis.

#### 11.4. Binární soubory

Všechny soubory neobsahují text. Některé mohou obsahovat obrázky mého psa.

```
>>> an_image = open('examples/beauregard.jpg', mode='rb') [1]
>>> an_image.mode
'rb'
>>> an_image.name [3]
'examples/beauregard.jpg'
>>> an_image.encoding [4]
Traceback (most recent call last):
    File "<stdin>", line 1, in <module>
AttributeError: '_io.BufferedReader' object has no attribute 'encoding'
```

- Otevření souboru v binárním režimu je jednoduché, ale záludné. Ve srovnání s otvíráním v textovém režimu spočívá jediný rozdíl v tom, že parametr mode obsahuje znak 'b'.
- Objekt typu stream, který získáme otevřením souboru v binárním režimu, má mnoho stejných atributů, včetně atributů mode, který odpovídá stejnojmennému parametru předanému funkci open().
- Binární objekty typu stream mají také atribut name stejně jako textové objekty typu stream.
- Ale jeden rozdíl tady přesto je. Binární objekty typu stream nemají atribut encoding. Dává to smysl, že? Čteme (nebo zapisujeme) bajty a ne řetězce. Python tedy nemusí dělat žádný převod. Z binárního souboru dostaneme přesně to, co jsme do něj vložili. Žádná konverze není nutná.

Už jsem řekl, že čteme bajty? Ano, je to tak.

```
# pokračování předchozího příkladu
>>> an_image.tell()
0
>>> data = an_image.read(3) [1]
>>> data
b'\xff\xd8\xff'
>>> type(data) [2]
<class 'bytes'>
>>> an_image.tell() [3]
3
>>> an_image.seek(0)
0
>>> data = an_image.read()
>>> len(data)
3150
```

- Stejně jako v případě textových souborů také z binárních souborů můžeme číst po kouscích. Ale je tu jeden zásadní rozdíl...
- ... čteme bajty, ne řetězce. Protože jsme soubor otevřeli v binárním režimu, přebírá metoda read() jako argument počet bajtů, které se mají načíst, a ne počet znaků.
- To znamená, že zde nikdy nedojde k neočekávanému nesouladu mezi číslem, které jsme předali metodě read(), a pozičním indexem, který nám vrací metoda tell(). Metoda read() čte bajty a metody seek() a tell() sledují počet přečtených bajtů. U binárních souborů budou vždy v souladu.

## 11.5. Objekty typu stream z nesouborových zdrojů

Představte si, že píšete knihovnu a jedna z vašich knihovních funkcí má číst data ze souboru. Funkce by mohla jednoduše převzít jméno souboru v řetězcové podobě, otevřít soubor pro čtení, přečíst jeho obsah a před skončením funkce jej uzavřít. Ale takhle byste to dělat neměli. Místo toho by rozhraní vaší funkce (API) mělo přebírat libovolný objekt typu stream.

# Z předstíraného souboru čteme jednoduše voláním read().

V nejjednodušším případě je objektem typu stream cokoliv, co má metodu read(), která přebírá nepovinný parametr size (velikost) a vrací řetězec. Pokud je metoda read() zavolána bez uvedení parametru size, měla by ze zdroje informací přečíst všechna zbývající data a vrátit je jako jednu hodnotu. Pokud je metoda zavolána s paramet-

rem size, přečte ze zdroje požadované množství dat a vrátí je. Pokud je zavolána znovu, pokračuje od místa, kde se čtením přestala, a vrací další část dat.

Vypadá to, jako kdybychom používali objekt typu stream vzniklý otevřením skutečného souboru. Rozdíl je v tom, že se neomezujeme na skutečné soubory. Zdrojem informací, ze kterého "čteme", může být cokoliv: webová stránka, řetězec v paměti nebo dokonce výstup z jiného programu. Pokud vaše funkce přebírá objekt typu stream a jednoduše volá jeho metodu read(), můžete zpracovávat libovolný zdroj informací, který se tváří jako soubor, aniž byste museli pro každý druh vstupu psát různý kód.

```
>>> a_string = 'PapayaWhip is the new black.'
>>> import io
                                                    [1]
>>> a_file = io.StringIO(a_string)
                                                    [2]
>>> a_file.read()
                                                    [3]
'PapayaWhip is the new black.'
>>> a_file.read()
                                                    [4]
>>> a_file.seek(0)
                                                    [5]
>>> a_file.read(10)
                                                    [6]
'PapayaWhip'
>>> a_file.tell()
10
>>> a_file.seek(18)
18
>>> a_file.read()
'new black.'
```

- [1] Modul io definuje třídu StringIO, kterou můžeme dosáhnout toho, aby se řetězec v paměti choval jako soubor.
- Když chceme z řetězce vytvořit objekt typu stream, vytvoříme instanci třídy io.StringIO() a předáme jí řetězec, který chceme použít jako zdroj "souborových" dat. Teď máme k dispozici objekt typu stream a můžeme s ním dělat všechny možné odpovídající věci.
- Voláním metody read() "přečteme" celý "soubor". V takovém případě objekt třídy StringIO jednoduše vrátí původní řetězec.
- Opakované volání metody read() vrací prázdný řetězec stejně jako u opravdového souboru.
- Použitím metody seek() objektu třídy StringIO se můžeme explicitně nastavit na začátek řetězce stejně jako při volání téže metody u opravdového souboru.
- [6] Pokud metodě read() předáme parametr size, můžeme číst po větších kouscích i z řetězce.
- > Třída io.StringIO vám umožní chovat se k řetězci jako k textovému souboru. Existuje také třída io.BytesIO, která vám umožní chovat se k poli bajtů jako k binárnímu souboru.

### 11.5.1. Práce s komprimovanými soubory

Pythonovská standardní knihovna obsahuje moduly, které podporují čtení a zápis komprimovaných souborů. Různých komprimačních schémat existuje celá řada. Mezi newindowsovskými systémy patří mezi dva nejpopulárnější gzip a bzip2. (Mohli jste se setkat také s archivy PKZIP a s archivy GNU Tar. V Pythonu najdete moduly i pro tyto dva.)

Modul gzip nám umožní vytvořit objekt typu stream pro čtení a zápis souborů komprimovaných algoritmem gzip. Příslušný objekt podporuje metodu read() (pokud jsme jej otevřeli pro čtení) nebo metodu write() (pokud jsme jej otevřeli pro zápis). To znamená, že *k přímému zápisu nebo čtení souborů komprimovaných algoritmem gzip* můžeme použít metody, které jsme se už naučili používat s normálními soubory. Nemusíme vytvářet pomocné soubory k ukládání dekomprimovaných dat.

Jako bonus navíc podporuje modul gzip i příkaz with, takže uzavření komprimovaného souboru můžete ponechat na Pythonu.

```
you@localhost:~$ python3
```

- [1] Soubory zabalené gzip bychom měli vždy otvírat v binárním režimu. (Všimněte si znaku 'b' v argumentu mode.)
- Tento příklad jsem vytvořil na Linuxu. Pokud vám tento příkazový řádek nic neříká, zobrazuje výpis položky souboru "v dlouhém formátu" (v pracovním adresáři). Soubor jsme právě vytvořili v pythonovském shellu s využitím komprese gzip. Tento soubor ukazuje, že soubor existuje (fajn) a že má velikost 79 bajtů. Ve skutečnosti je větší než řetězec, se kterým jsme začali! Soubor ve formátu gzip zahrnuje hlavičku pevné délky, která obsahuje nějaké informace o souboru. Pro velmi malé soubory je to tedy neefektivní.
- Příkaz gunzip (vyslovuje se "dží anzip") dekomprimuje daný soubor a ukládá jeho obsah do nového souboru se stejným jménem, ale bez přípony .gz.
- Příkaz cat zobrazuje obsah souboru. Soubor obsahuje řetězec, který jsme původně zapsali v pythonovském shellu přímo do komprimovaného souboru out.log.gz.

Setkali jste se s následující chybou?

```
>>> with gzip.open('out.log.gz', mode='wb') as z_file:
...     z_file.write('A nine mile walk is no joke, especially in the
rain.'.encode('utf-8'))
...
Traceback (most recent call last):
File "<stdin>", line 1, in <module>
AttributeError: 'GzipFile' object has no attribute '__exit__'
```

Pokud ano, pravděpodobně používáte Python 3.0. Měli byste provést aktualizaci na Python 3.1.

V Pythonu 3.0 se sice modul gzip nacházel, ale nepodporoval použití objektů komprimovaných souborů jako správců kontextu. V Pythonu 3.1 byla přidána možnost používat objekty gzip souborů i v příkazu with.

## 11.6. Standardní vstup, výstup a chybový výstup

Machři na práci přes příkazový řádek už koncept standardního vstupu, standardního výstupu a standardního chybového výstupu znají. Tato podkapitola je určena těm ostatním.

sys.stdin, sys.stdout, sys.stderr. Standardní výstup a standardní chybový výstup (běžně se zkracují jako stdout a stderr) jsou roury (pipe), které jsou zabudovány do každého systému, který je odvozen od UNIXU. Platí to i pro Mac OS X a pro Linux. Pokud voláte funkci print(), tištěný obsah je odeslán do roury stdout. Pokud váš program zhavaruje a tiskne trasovací výpis, posílá jej do roury stderr. Ve výchozím stavu jsou

obě uvedené roury napojeny na terminálové okno, ve kterém pracujete. Když váš program něco tiskne, zobrazuje se jeho výstup ve vašem terminálovém okně. Když program zhavaruje, vidíte trasovací výpis také ve svém terminálovém okně. V grafickém pythonovském shellu jsou roury stdout and stderr přesměrovány do vašeho "interaktivního okna".

```
>>> for i in range(3):
... print('PapayaWhip')
PapayaWhip
PapayaWhip
PapayaWhip
>>> import sys
>>> for i in range(3):
```

```
... l = sys.stdout.write('is the')
is theis theis the
>>> for i in range(3):
... l = sys.stderr.write('new black')
new blacknew blacknew black
[3]
```

- [1] Funkce print() volaná v cyklu. Tady nic překvapujícího nenajdeme.
- stdout je definován v modulu sys a jde o objekt typu stream. Když zavoláme jeho metodu write(), vytiskne každý řetězec, který jí předáme. Funkce print ve skutečnosti dělá právě tohle. Na konec každého tištěného řetězce přidá znak ukončující řádek a pak volá sys.stdout.write.
- V nejjednodušším případě posílají sys.stdout a sys.stderr výstup do stejného místa:
  do pythonovského integrovaného vývojového prostředí (IDE, pokud v něm pracujeme) nebo
  do terminálového okna (pokud Python spouštíme z příkazového řádku). Standardní chybový
  výstup (stejně jako standardní výstup) přechod na nový řádek nepřidávají. Pokud chceme přejít
  na nový řádek, musíme zapsat příslušné znaky pro přechod na nový řádek.

sys.stdout a sys.stderr jsou objekty typu stream, ale dá se do nich pouze zapisovat. Pokus o volání jejich metody read() vždy vyvolá výjimku IOError.

```
>>> import sys
>>> sys.stdout.read()
Traceback (most recent call last):
   File "<stdin>", line 1, in <module>
IOError: not readable
```

#### 11.6.1. Přesměrování standardního výstupu

sys. stdout a sys. stderr jsou objekty typu stream, i když podporují pouze zápis. Ale nejsou konstantní. Jde o proměnné. To znamená, že do nich můžeme přiřadit novou hodnotu — nějaký jiný objekt typu stream — a přesměrovat jejich výstup.

```
import sys

class RedirectStdoutTo:
    def __init__(self, out_new):
        self.out_new = out_new

def __enter__(self):
        self.out_old = sys.stdout
        sys.stdout = self.out_new
```

```
11.6. Standardní vstup, výstup a chybový výstup
```

```
def __exit__(self, *args):
        sys.stdout = self.out_old
print('A')
with open('out.log', mode='w', encoding='utf-8') as a_file, RedirectStdoutTo(a_file):
    print('B')
print('C')
Podívejte se na tohle:
you@localhost:~/diveintopython3/examples$ python3 stdout.py
Α
С
you@localhost:~/diveintopython3/examples$ cat out.log
В
Setkali jste se s následující chybou?
you@localhost:~/diveintopython3/examples$ python3 stdout.py
  File "stdout.py", line 15
    with open('out.log', mode='w', encoding='utf-8') as a_file, RedirectStdoutTo(a_file):
SyntaxError: invalid syntax
Pokud ano, pravděpodobně používáte Python 3.0. Měli byste provést aktualizaci na Python 3.1.
Python 3.0 podporoval příkaz with, ale každý příkaz mohl používat jen jednoho správce kontextu.
Python 3.1 umožňuje použít v jednom příkazu with více správců kontextu.
Podívejme se nejdříve na poslední část.
print('A')
with open('out.log', mode='w', encoding='utf-8') as a_file, RedirectStdoutTo(a_file):
    print('B')
print('C')
Tenhle příkaz with je docela komplikovaný. Přepíšu ho do trochu srozumitelnější podoby.
with open('out.log', mode='w', encoding='utf-8') as a_file:
    with RedirectStdoutTo(a_file):
        print('B')
```

Z přepisu je vidět, že ve skutečnosti jde o dva příkazy with, z nichž jeden je zanořen do druhého. "Vnější" příkaz with by nám měl být povědomý. Otvírá textový soubor zakódovaný v UTF-8 a pojmenovaný out.log pro zápis a přiřazuje objekt typu stream do proměnné pojmenované a\_file. Ale je tu ještě jedna zvláštnost.

```
with RedirectStdoutTo(a_file):
```

Kdepak je část as? Příkaz with ji ve skutečnosti nevyžaduje. Podobně, jako když voláte funkci a ignorujete její návratovou hodnotu, můžete použít i příkaz with, který nepřiřazuje kontext příkazu with do nějaké proměnné. V tomto případě nás zajímají pouze vedlejší efekty kontextu RedirectStdoutTo.

A jaké jsou ty vedlejší efekty? Nahlédněme do třídy RedirectStdoutTo. Tato třída je uživatelsky definovaným správcem kontextu. Roli správce kontextu může hrát každá funkce, která definuje speciální metody \_\_enter\_\_() a \_\_exit\_\_().

```
class RedirectStdoutTo:
```

```
def __init__(self, out_new):
    self.out_new = out_new

def __enter__(self):
    self.out_old = sys.stdout
    sys.stdout = self.out_new

def __exit__(self, *args):
    sys.stdout = self.out_old
```

- Metoda \_\_init\_\_() se volá bezprostředně po vytvoření instance. Přebírá jeden parametr objekt typu stream, který chceme po dobu životnosti kontextu používat jako standardní výstup. Metoda uloží odkaz na objekt typu stream do instanční proměnné, aby jej mohly později používat ostatní metody.
- Metoda \_\_enter\_\_() patří mezi speciální metody třídy. Python ji volá v okamžiku vstupu do kontextu (tj. na začátku příkazu with). Metoda ukládá aktuální hodnotu sys.stdout do self.out\_old a poté přesměruje standardní výstup přiřazením self.out\_new do sys.stdout.
- [3] Metoda \_\_exit\_\_() je další speciální metodou třídy. Python ji volá při opouštění kontextu (tj. na konci příkazu with). Metoda obnoví původní nasměrování standardního výstupu přiřazením uložené hodnoty self.out\_old do sys.stdout.

Spojme to všechno dohromady:

```
print('A')
with open('out.log', mode='w', encoding='utf-8') as a_file, RedirectStdoutTo(a_file): [2]
    print('B')
print('C')
[4]
```

- Výsledek se vytiskne v "interaktivním okně" IDE (nebo v terminálovém okně, pokud skript spouštíme z příkazového řádku).
- Tento příkaz with přebírá *čárkou oddělený seznam kontextů*. Uvedený seznam se chová jako posloupnost vnořených bloků with. První kontext v seznamu je chápán jako "vnější" blok, poslední jako "vnitřní" blok. První kontext otvírá soubor, druhý kontext přesměrovává sys. stdout do objektu typu stream, který byl vytvořen v prvním kontextu.
- Funkce print() je provedena v kontextu vytvořeném příkazem with, a proto nebude tisknout na obrazovku. Místo toho provede zápis do souboru out.log.
- Blok kódu v příkazu with skončil. Python každému správci kontextu oznámil, že má udělat to, co se má udělat při opouštění kontextu. Správci kontextu jsou uloženi v zásobníku (LIFO). Druhý kontext při ukončování změnil obsah sys. stdout zpět na původní hodnotu a potom první kontext uzavřel soubor pojmenovaný out.log. A protože bylo přesměrování standardního výstupu obnoveno na původní hodnotu, bude funkce print() tisknout zase na obrazovku.

Přesměrování standardního chybového výstupu funguje naprosto stejně. Jen se místo sys. stdout použije sys. stderr.

### 11.7. Přečtěte si (vše anglicky)

- Reading and writing files v oficiální učebnici Python.org (http://docs.python.org/py3k/tutorial/inputoutput.html#reading-and-writing-files)
- io module standardní dokumentace (http://docs.python.org/py3k/library/io.html)
- **Stream objects** standardní dokumentace (http://docs.python.org/py3k/library/stdtypes.html)
- Context manager types standardní dokumentace (http://docs.python.org/py3k/library/stdtypes.html)
- sys.stdout and sys.stderr standardní dokumentace (http://docs.python.org/py3k/library/sys.html)
- FUSE na Wikipedii (anglicky; lze přepnout na odpovídající české heslo) (http://en.wikipedia.org/wiki/Filesystem\_in\_Userspace)

- "In the archonship of Aristaechmus,
  Draco enacted his ordinances."
  (Za vlády Aristaechma uzákonil
  Drakon svá pravidla.)
  - Aristoteles

## 12. XML

| 12.     | AML — 255  |
|---------|--|
| 12.1.   | Ponořme se — <b>257</b>                            |
| 12.2.   | Pětiminutový rychlokurz XML — <b>258</b>           |
| 12.3.   | Struktura Atom Feed — 261                          |
| 12.4.   | Analýza XML — <b>263</b>                           |
| 12.4.1. | Elementy jsou reprezentovány seznamy — 264         |
| 12.4.2. | Atributy jsou reprezentovány slovníky — <b>264</b> |
| 12.5.   | Vyhledávání uzlů v XML dokumentu — <b>265</b>      |
| 12.6.   | lxml jde ještě dál — 268                           |
| 12.7.   | Generování XML — 270                               |
| 12.8.   | Analýza porušeného XML — <b>273</b>                |

Přečtěte si — **275** 

12.9.

### 12.1. Ponořme se

Téměř všechny kapitoly této knihy se točí kolem příkladů kódu. XML nesouvisí s kódem, ale s daty. Jedním z míst, kde se XML běžně používá, je "publikovaný obsah" (syndication feeds), ve kterém se udržuje seznam posledních článků blogu, fóra nebo jiného, často aktualizovaného obsahu webového místa. Nejpopulárnější blogovací programy vytvářejí obsah (feed), a kdykoliv je publikován nový článek, diskusní vlákno nebo zpráva na blogu, tento obsah aktualizují. Blog můžeme sledovat tak, že se "přihlásíme k odběru" jeho obsahu (feed). Více blogů můžeme sledovat tak, že použijeme k tomu určený "nástroj pro sdružování obsahu (feed aggregator)", jako je například Google Reader.

V této kapitole budeme pracovat s následujícími XML daty. Jde o publikovaný obsah (feed) — konkrétně o Atom syndication feed.

```
<?xml version='1.0' encoding='utf-8'?>
<feed xmlns='http://www.w3.org/2005/Atom' xml:lang='en'>
  <title>dive into mark</title>
  <subtitle>currently between addictions</subtitle>
  <id>tag:diveintomark.org,2001-07-29:/</id>
  <updated>2009-03-27T21:56:07Z</updated>
  <link rel='alternate' type='text/html' href='http://diveintomark.org/'/>
  <link rel='self' type='application/atom+xml' href='http://diveintomark.org/feed/'/>
  <entry>
    <author>
      <name>Mark</name>
      <uri>http://diveintomark.org/</uri>
    </author>
    <title>Dive into history, 2009 edition</title>
    <link rel='alternate' type='text/html'</pre>
      href='http://diveintomark.org/archives/2009/03/27/dive-into-history-2009-edition'/>
    <id>tag:diveintomark.org, 2009-03-27:/archives/20090327172042</id>
    <updated>2009-03-27T21:56:07Z</updated>
    <published>2009-03-27T17:20:42Z</published>
    <category scheme='http://diveintomark.org' term='diveintopython'/>
    <category scheme='http://diveintomark.org' term='docbook'/>
    <category scheme='http://diveintomark.org' term='html'/>
  <summary type='html'>Putting an entire chapter on one page sounds
    bloated, but consider this & mdash; my longest chapter so far
    would be 75 printed pages, and it loads in under 5 seconds& hellip;
    On dialup.</summary>
  </entry>
  <entry>
    <author>
      <name>Mark</name>
```

```
<uri>http://diveintomark.org/</uri>
    </author>
    <title>Accessibility is a harsh mistress</title>
    <link rel='alternate' type='text/html'</pre>
     href='http://diveintomark.org/archives/2009/03/21/accessibility-is-a-harsh-mistress'/>
    <id>tag:diveintomark.org,2009-03-21:/archives/20090321200928</id>
    <updated>2009-03-22T01:05:37Z</updated>
    <published>2009-03-21T20:09:28Z</published>
    <category scheme='http://diveintomark.org' term='accessibility'/>
    <summary type='html'>The accessibility orthodoxy does not permit people to
     question the value of features that are rarely useful and rarely used.</summary>
  </entry>
  <entry>
    <author>
     <name>Mark</name>
    </author>
    <title>A gentle introduction to video encoding, part 1: container formats</title>
    <link rel='alternate' type='text/html'</pre>
     href='http://diveintomark.org/archives/2008/12/18/give-part-1-container-formats'/>
    <id>tag:diveintomark.org, 2008-12-18:/archives/20081218155422</id>
    <updated>2009-01-11T19:39:22Z</updated>
    <published>2008-12-18T15:54:22Z</published>
    <category scheme='http://diveintomark.org' term='asf'/>
    <category scheme='http://diveintomark.org' term='avi'/>
    <category scheme='http://diveintomark.org' term='encoding'/>
    <category scheme='http://diveintomark.org' term='flv'/>
    <category scheme='http://diveintomark.org' term='GIVE'/>
    <category scheme='http://diveintomark.org' term='mp4'/>
    <category scheme='http://diveintomark.org' term='ogg'/>
    <category scheme='http://diveintomark.org' term='video'/>
    <summary type='html'>These notes will eventually become part of a
     tech talk on video encoding.</summary>
  </entry>
</feed>
```

### 12.2. Pětiminutový rychlokurz XML

Pokud už o XML něco víte, můžete tuto podkapitolu přeskočit.

XML představuje zobecněný způsob popisu hierarchických strukturovaných dat. XML-dokument obsahuje jeden nebo více elementů, které jsou ohraničeny počátečními a koncovými značkami (tag). Tohle je kompletní (i když poněkud nudný) XML dokument:

```
<foo>
                                                    [1]
</foo>
                                                    [2]
```

- [1] Toto je počáteční značka elementu foo.
- Toto je odpovídající koncová značka elementu foo. Každá počáteční značka musí být uzavřena [2] (spárována s) odpovídající koncovou značkou stejně, jako musíme párovat závorky v matematice nebo v textu.

Elementy lze zanořovat do libovolné hloubky. O elementu bar uvnitř elementu foo se říká, že je subelementem nebo potomkem (child) elementu foo.

```
<foo>
  <bar></bar>
</foo>
```

Prvnímu elementu v každém XML dokumentu se říká kořenový element (root element). XML dokument může mít jen jeden kořenový element. Následující text není XML dokumentem, protože obsahuje dva kořenové elementy:

```
<foo></foo>
<bar></bar>
```

Elementy mohou nést atributy, což jsou dvojice jméno-hodnota. Atributy se uvádějí uvnitř počáteční značky elementu a oddělují se bílými znaky. Uvnitř jednoho elementu se jména atributů nesmějí opakovat. Hodnoty atributů musí být uzavřeny v uvozovkách nebo v apostrofech.

```
<foo lang='en'>
  <bar id='papayawhip' lang="fr"></bar>
</foo>
```

- Element foo má jeden atribut pojmenovaný lang. Hodnotou jeho atributu lang je en. [1]
- Element bar má dva atributy pojmenované id a lang. Jeho atribut lang má hodnotu fr. Nedochá-[2] zí vůbec k žádnému konfliktu s elementem foo. Každý element má svou vlastní sadu atributů.

Pokud je v jednom elementu uvedeno víc atributů, pak jejich pořadí není významné. Atributy elementu tvoří neuspořádanou množinu dvojic klíčů a hodnot — jako pythonovský slovník. Počet atributů, které můžeme u každého elementu definovat, není nijak omezen.

Elementy mohou obsahovat text.

```
<foo lang='en'>
  <bar lang='fr'>PapayaWhip</bar>
</foo>
```

Elementy, které neobsahují žádný text a nemají žádné potomky, jsou prázdné.

```
<foo></foo>
```

Prázdné elementy můžeme zapisovat zkráceně. Když do počáteční značky umístíme znak /, můžeme koncovou značku úplně vynechat. XML dokument z předchozího příkladu můžeme zkráceně zapsat takto:

```
<foo/>
```

Podobně jako můžeme pythonovské funkce deklarovat v různých modulech, XML elementy můžeme deklarovat v různých prostorech jmen. Prostory jmen se obvykle podobají zápisu URL. Výchozí prostor jmen definujeme pomocí deklarace xmlns. Deklarace prostoru jmen vypadá podobně jako zápis atributu, ale plní odlišný účel.

```
<feed xmlns='http://www.w3.org/2005/Atom'> [1]
<title>dive into mark</title> [2]
</feed>
```

- [1] Element feed se nachází v prostoru jmen http://www.w3.org/2005/Atom.
- Element title se také nachází v prostoru jmen http://www.w3.org/2005/Atom. Deklarace prostoru jmen ovlivní element, ve kterém se deklarace nachází, a dále všechny jeho dětské elementy (potomky).

Při deklaraci prostoru jmen můžeme použít také zápis xmlns: prefix, čímž prostor jmen spřáhneme se zadaným *prefixem*. V takovém případě musí být každý element tohoto prostoru jmen explicitně deklarován se stejným prefixem.

```
<atom:feed xmlns:atom='http://www.w3.org/2005/Atom'> [1]
<atom:title>dive into mark</atom:title> [2]
</atom:feed>
```

- [1] Element feed se nachází v prostoru jmen http://www.w3.org/2005/Atom.
- [2] Element title se také nachází v prostoru jmen http://www.w3.org/2005/Atom.

Z pohledu syntaktického analyzátoru pro XML jsou přecházející dva XML dokumenty *identické*. Prostor jmen + jméno elementu = XML identita. Prefixy se používají pouze k odkazu na prostor jmen. To znamená, že konkrétní jméno prefixu (atom:) je nepodstatné. Prostory jmen pasují, jména elementů se shodují, atributy (nebo neuvedení atributů) sedí, textový obsah každého elementu se také shoduje. To znamená, že se jedná o stejné XML dokumenty.

Na závěr uveďme, že XML dokumenty mohou na prvním řádku, před kořenovým elementem, uvádět informaci o znakovém kódování. (Pokud vás zajímá, jak může dokument obsahovat informaci, která musí být známa předtím, než se dokument zpracovává, pak detaily řešení této Hlavy XXII hledejte v sekci F specifikace XML (anglicky).)

```
<?xml version='1.0' encoding='utf-8'?>
```

Tak a teď už o XML víte dost na to, abyste mohli být nebezpeční!

### 12.3. Struktura Atom Feed

Vezměme si nějaký weblog nebo v podstatě libovolný webový server s často aktualizovaným obsahem, jako je například CNN.com. Server má svůj nadpis ("CNN.com"), podnadpis ("Breaking News, U.S., World, Weather, Entertainment & Video News"), datum poslední aktualizace ("updated 12:43 p.m. EDT, Sat May 16, 2009") a seznam článků zveřejněných v různých časech. Každý článek má také nadpis, datum prvního zveřejnění (a možná také datum poslední aktualizace, pokud zveřejnili upřesnění nebo opravili překlep) a jedinečné URL.

The Atom syndication format je navržen tak, aby všechny tyto informace zachytil ve standardním tvaru. Můj weblog a CNN.com se sice velmi liší v návrhu, rozsahu a v návštěvnosti, ale oba mají stejnou základní strukturu. CNN.com má nadpis, můj blog má nadpis. CNN.com zveřejňuje články, já zveřejňuji články.

Na nejvyšší úrovni se nachází *kořenový element*, který používají všechny "Atom feed" — element feed v prostoru jmen http://www.w3.org/2005/Atom.

```
<feed xmlns='http://www.w3.org/2005/Atom' [1] xml:lang='en'> [2]
```

- [1] http://www.w3.org/2005/Atom je prostor jmen pro Atom.
- Libovolný element může obsahovat atribut xml:lang, který deklaruje jazyk elementu a jeho potomků. V tomto případě je atribut xml:lang deklarován jen jednou, v kořenovém elementu. To znamená, že celý obsah (feed) je v angličtině.

Atom feed (chápejte tento název jako pojem) obsahuje pár informací i o dokumentu samotném (tedy o sobě). Jsou deklarovány jako potomci kořenového elementu feed.

- [1] Nadpis obsahu je dive into mark.
- [2] Podnadpis obsahu je currently between addictions.

- [3] Každý obsah (feed) potřebuje globálně jednoznačný identifikátor. V dokumentu RFC 4151 najdete, jak se dá vytvořit.
- Tento obsah byl naposledy aktualizován 27. března 2009 v 21.56 GMT. Obvykle se shoduje s časem poslední modifikace nejnovějšího článku.
- Teď to začne být zajímavé. Tento element link nemá žádný textový obsah, ale má tři atributy: rel, type a href. Hodnota atributu rel říká, jakého druhu odkaz je. Hodnota rel='alternate' vyjadřuje, že jde o odkaz na alternativní reprezentaci tohoto obsahu (feed). Atribut type='text/html' říká, že jde o odkaz na HTML stránku. Cíl odkazu je uveden v atributu href.

Teď už víme, že jde o obsah (feed) pro místo zvané "dive into mark", které se nachází na http://diveintomark.org/ a bylo naposledy aktualizováno 27. března 2009.

> Ačkoliv v některých XML dokumentech může být pořadí elementů důležité, pro Atom feed to neplatí.

Po metadatech vázaných na celý dokument (feed) se nachází seznam nejnovějších článků. Článek vypadá takto:

```
<entry>
  <author>
                                                                                    [1]
    <name>Mark</name>
    <uri>http://diveintomark.org/</uri>
  </author>
  <title>Dive into history, 2009 edition</title>
                                                                                    [2]
  <link rel='alternate' type='text/html'</pre>
                                                                                    [3]
    href='http://diveintomark.org/archives/2009/03/27/dive-into-history-2009-edition'/>
  <id>tag:diveintomark.org, 2009-03-27:/archives/20090327172042</id>
                                                                                    [4]
  <updated>2009-03-27T21:56:07Z</updated>
                                                                                    [5]
  <published>2009-03-27T17:20:42Z</published>
  <category scheme='http://diveintomark.org' term='diveintopython'/>
                                                                                    [6]
  <category scheme='http://diveintomark.org' term='docbook'/>
  <category scheme='http://diveintomark.org' term='html'/>
  <summary type='html'>Putting an entire chapter on one page sounds
                                                                                    [7]
    bloated, but consider this & mdash; my longest chapter so far
    would be 75 printed pages, and it loads in under 5 seconds& hellip;
    On dialup.</summary>
</entry>
                                                                                    [8]
```

Element author říká, kdo článek napsal: nějaký maník jménem Mark, který se poflakuje někde na http://diveintomark.org/. (Je to stejná hodnota, jako alternativní odkaz v metadatech k feed, ale nemusí tomu tak být. Mnoho weblogů využívá více autorů najednou a každý z nich mívá jiný osobní webový server.)

- [2] Element title nese název článku "Dive into history, 2009 edition".
- [3] Element link obsahuje adresu HTML verze tohoto článku, podobně jako v případě alternativního odkazu na úrovni celého obsahu (feed).
- [4] Položky (entry), stejně jako celý obsah (feed), potřebují jednoznačný identifikátor.
- Položky nesou dvě data: datum prvního zveřejnění (published) a datum poslední modifikace (updated).
- Položky mohou nést libovolný počet kategorií (category). Tento článek je zařazen pod diveintopython, docbook a HTML.
- Element summary nese stručné shrnutí obsahu článku. (Existuje i element content tj. obsah —, který zde není použit. Je určen pro vložení celého textu článku.) Tento element summary nese atribut type='html', který je specifický pro Atom. Říká, že uvedené shrnutí není prostý text, ale úryvek ve formátu HTML. Ta informace je důležitá, protože se v něm nacházejí věci specifické pro HTML (— a …), které se nemají zviditelňovat jako text, ale jako "-" a "…".
- [8] A na závěr je tu koncová značka elementu entry, která signalizuje konec metadat pro tento článek.

### 12.4. Analýza XML

Python dovede analyzovat XML dokumenty několika způsoby. Najdeme zde tradiční syntaktické analyzátory (také parsery) dom a sax. My se ale zaměříme na jinou knihovnu zvanou ElementTree.

```
>>> import xml.etree.ElementTree as etree
[1]
>>> tree = etree.parse('examples/feed.xml')
>>> root = tree.getroot()
>>> root
[4]
<Element {http://www.w3.org/2005/Atom}feed at cd1eb0>
```

- [1] Knihovna ElementTree je součástí standardní pythonovské knihovny. Nachází se v xml.etree.ElementTree.
- Primárním vstupním bodem knihovny ElementTree je funkce parse(), která přebírá buď jméno souboru nebo souboru se podobající objekt. Funkce zpracuje celý dokument najednou. Pokud chceme šetřit pamětí, existují způsoby, jak můžeme XML dokument zpracovávat postupně.
- Funkce parse() vrací objekt, který reprezentuje celý dokument. Ale *není* to kořenový element. Pokud chceme získat odkaz na kořenový element, zavoláme metodu getroot().
- Jak se dalo čekat, kořenovým elementem je element feed, který se nachází v prostoru jmen http://www.w3.org/2005/Atom. Řetězcová reprezentace tohoto objektu v nás posiluje důležitý pohled: XML element je kombinací svého prostoru jmen a jména své značky (která se též nazývá lokální jméno). Každý element tohoto dokumentu se nachází v prostoru jmen Atom, takže kořenový element je reprezentován jako {http://www.w3.org/2005/Atom}feed.
- > ElementTree reprezentuje XML elementy jako {prostor\_jmen}lokální\_jméno. Tento formát uvidíme a budeme používat na mnoha místech aplikačního rozhraní ElementTree.

### 12.4.1. Elementy jsou reprezentovány seznamy

V aplikačním rozhraní ElementTree se elementy chovají jako seznamy. Položkami seznamu jsou elementy potomků (child).

```
# pokračování předchozího příkladu
>>> root.tag
                                          [1]
'{http://www.w3.org/2005/Atom}feed'
>>> len(root)
                                          [2]
>>> for child in root:
                                          [3]
      print(child)
                                          [4]
<Element {http://www.w3.org/2005/Atom}title at e2b5d0>
<Element {http://www.w3.org/2005/Atom}subtitle at e2b4e0>
<Element {http://www.w3.org/2005/Atom}id at e2b6c0>
<Element {http://www.w3.org/2005/Atom}updated at e2b6f0>
<Element {http://www.w3.org/2005/Atom}link at e2b4b0>
<Element {http://www.w3.org/2005/Atom}entry at e2b720>
<Element {http://www.w3.org/2005/Atom}entry at e2b510>
<Element {http://www.w3.org/2005/Atom}entry at e2b750>
```

- [1] Pokračujme v předchozím příkladu. Kořenový element je {http://www.w3.org/2005/Atom}feed.
- "Délkou" kořenového elementu rozumíme počet dětských elementů (potomků, child).
- Objekt elementu můžeme použít jako iterátor, který zajistí průchod všemi svými dětskými elementy.
- [4] Na výstupu vidíme, že obsahuje očekávaných 8 potomků: metadata patřící k feed (title, subtitle, id, updated a link) následovaná třemi elementy entry.

Asi už jste to odhadli, ale zdůrazněme to ještě explicitně: seznam dětských elementů zahrnuje pouze přímé potomky. Každý z elementů entry obsahuje své vlastní potomky, ale ti v tomto seznamu uvedeni nejsou. Jako dětské elementy jsou součástí seznamů elementů entry, ale nejsou zahrnuty mezi potomky elementu feed. Existují způsoby, jak můžeme elementy vyhledat nezávisle na tom, jak hluboko jsou zanořené. Na dva takové způsoby se v této kapitole podíváme později.

### 12.4.2. Atributy jsou reprezentovány slovníky

XML není jen kolekcí elementů. Každý element má svou vlastní sadu atributů. Jakmile máme odkaz na konkrétní element, můžeme jeho atributy snadno získat jako pythonovský slovník.

```
# pokračování předchozího příkladu
>>> root.attrib
                                                           [1]
{'{http://www.w3.org/XML/1998/namespace}lang': 'en'}
>>> root[4]
                                                           [2]
<Element {http://www.w3.org/2005/Atom}link at e181b0>
>>> root[4].attrib
                                                           [3]
{'href': 'http://diveintomark.org/',
 'type': 'text/html',
 'rel': 'alternate'}
>>> root[3]
                                                           [4]
<Element {http://www.w3.org/2005/Atom}updated at e2b4e0>
>>> root[3].attrib
                                                           [5]
{}
```

- Vlastnost attrib je slovníkem atributů elementu. Původní značka vypadala takto: 
  <feed xmlns='http://www.w3.org/2005/Atom' xml:lang='en'>. Prefix xml: se vztahuje k zabudovanému prostoru jmen, který můžeme používat v každém XML dokumentu, aniž bychom jej museli deklarovat.
- [2] Pátým potomkem [4] odpovídá indexování seznamu od nuly je element link.
- [3] Element link má tři atributy: href, type a rel.
- [4] Čtvrtým potomkem [3] odpovídá indexování seznamu od nuly je element updated.
- [5] Element updated nemá žádné atributy, takže jeho vlastnost .attrib je prostě prázdný slovník.

### 12.5. Vyhledávání uzlů v XML dokumentu

Zatím jsme s uvedeným XML dokumentem pracovali "shora dolů". Začali jsme u kořenového elementu, zpřístupnili jsme si elementy jeho potomků a tak dále napříč dokumentem. Ale při mnoha použitích XML se požaduje nalezení určitého elementu. Etree to umí také.

```
>>> import xml.etree.ElementTree as etree
>>> tree = etree.parse('examples/feed.xml')
>>> root = tree.getroot()
>>> root.findall('{http://www.w3.org/2005/Atom}entry')
                                                                  [1]
[<Element {http://www.w3.org/2005/Atom}entry at e2b4e0>,
 <Element {http://www.w3.org/2005/Atom}entry at e2b510>,
 <Element {http://www.w3.org/2005/Atom}entry at e2b540>]
>>> root.tag
'{http://www.w3.org/2005/Atom}feed'
>>> root.findall('{http://www.w3.org/2005/Atom}feed')
                                                                  [2]
>>> root.findall('{http://www.w3.org/2005/Atom}author')
                                                                  [3]
```

- [1] Metoda findall() najde všechny dětské elementy, které odpovídají určitému dotazu. (O formátu dotazu si řekneme za minutku.)
- [2] Každý element včetně kořenového elementu, ale také dětských elementů má metodu findall(). Ta mezi potomky najde všechny odpovídající elementy. Ale proč tu nejsou žádné výsledky? Ačkoliv to nemusí být úplně zřejmé, tento dotaz prohledává jen elementy potomků. A protože kořenový element feed nemá žádného potomka jménem feed, vrací dotaz prázdný seznam.
- Tento výsledek vás možná také překvapí. V tomto dokumentu se nachází element author. Ve skutečnosti jsou v něm tři (jeden v každém elementu entry). Ale elementy author nejsou přímými potomky kořenového elementu. Jsou to jeho "vnuci" (doslova potomci potomků). Pokud hledáte elementy author na libovolné úrovni zanoření, je to možné provést, ale formát dotazu se mírně liší.

- Z praktických důvodů má objekt tree (vracený funkcí etree.parse()) několik metod, které odpovídají metodám kořenového elementu. Výsledky jsou stejné, jako kdybychom zavolali metodu tree.getroot().findall().
- Tento dotaz, možná trošku překvapivě, v dokumentu nenajde elementy author. Proč ne? Protože je to zkratka pro tree.getroot().findall('{http://www.w3.org/2005/Atom}author'), což znamená "najdi všechny elementy author, které jsou potomky kořenového elementu". Elementy author nejsou potomky kořenového elementu. Jsou to potomci elementů entry. Takže uvedený dotaz nenajde žádnou shodu.

Existuje také metoda find(), která vrací první vyhovující element. Hodí se v situacích, kdy očekáváme pouze jeden výskyt, nebo když je výskytů víc, ale zajímá nás jen první.

```
>>> entries = tree.findall('{http://www.w3.org/2005/Atom}entry') [1]
>>> len(entries)
3
>>> title_element = entries[0].find('{http://www.w3.org/2005/Atom}title') [2]
>>> title_element.text
'Dive into history, 2009 edition'
>>> foo_element = entries[0].find('{http://www.w3.org/2005/Atom}foo') [3]
>>> foo_element
>>> type(foo_element)
<class 'NoneType'>
```

- [1] Tohle jsme viděli v předchozím příkladu. Naleznou se všechny elementy atom: entry.
- [2] Metoda find() přebírá dotaz a vrací první vyhovující element.
- Uvnitř elementu nejsou žádné položky nazvané foo, takže se vrací None.
- S metodou find() je spojen "chyták", který vás jednou dostane. Objekt elementu z ElementTree se v booleovském kontextu vyhodnocuje jako False v případě, kdy neobsahuje žádné potomky (tj. jestliže len(element) je rovno nule). To znamená, že zápis if element.find('...') netestuje, zda metoda find() nalezla vyhovující element. Testuje, zda vyhovující element má nějaké potomky! Pokud chceme testovat, zda metoda find() vrátila nějaký element, musíme použít zápis if element.find('...') is not None.

On ale existuje způsob, jak najít elementy veškerých *příbuzných potomků*, tj. dětí, vnuků a dalších elementů na libovolné úrovni zanoření.

```
>>> all_links = tree.findall('//{http://www.w3.org/2005/Atom}link')
                                                                            [1]
>>> all_links
[<Element {http://www.w3.org/2005/Atom}link at e181b0>,
 <Element {http://www.w3.org/2005/Atom}link at e2b570>,
 <Element {http://www.w3.org/2005/Atom}link at e2b480>,
 <Element {http://www.w3.org/2005/Atom}link at e2b5a0>]
>>> all_links[0].attrib
                                                                            [2]
{'href': 'http://diveintomark.org/',
 'type': 'text/html',
 'rel': 'alternate'}
>>> all_links[1].attrib
{'href': 'http://diveintomark.org/archives/2009/03/27/dive-into-history-2009-edition',
 'type': 'text/html',
 'rel': 'alternate'}
>>> all_links[2].attrib
{'href': 'http://diveintomark.org/archives/2009/03/21/accessibility-is-a-harsh-mistress',
 'type': 'text/html',
 'rel': 'alternate'}
>>> all_links[3].attrib
{'href': 'http://diveintomark.org/archives/2008/12/18/give-part-1-container-formats',
 'type': 'text/html',
 'rel': 'alternate'}
```

Tento dotaz — //{http://www.w3.org/2005/Atom}link — je těm z předchozích příkladů velmi podobný. Jedinou odlišností jsou dvě lomítka na začátku dotazu. Tato dvě lomítka znamenají: "Nedívej se jen na přímé potomky. Chci najít *jakékoliv* elementy, nezávisle na úrovni zanoření." Takže výsledkem je seznam čtyř elementů link a nejen jednoho.

- První výsledek je přímým potomkem kořenového elementu. Jak vidíme z jeho atributů, jde o alternativní odkaz z úrovně celého obsahu (feed). Odkazuje na HTML verzi webového místa, které zveřejňovaný obsah popisuje.
- Ostatní tři výsledky jsou alternativní odkazy z každého elementu entry. Každý element entry obsahuje jeden dětský element link. A protože je na začátku dotazu uvedena dvojice lomítek, najde dotaz všechny.

Celkově vzato je metoda findall() objektu třídy ElementTree velmi mocným nástrojem, ale dotazovací jazyk může přinést pár překvapení. Oficiálně se o něm píše jako o "omezené podpoře výrazů XPath". XPath je W3C standardem pro dotazování v XML dokumentech. Dotazovací jazyk implementovaný třídou ElementTree se XPath podobá do té míry, že se hodí pro základní vyhledávání. Ale pokud už znáte XPath, mohou vás rozdíly rozčilovat. Teď se podíváme na XML knihovnu třetí strany, která rozšiřuje aplikační rozhraní ElementTree o plnou podporu XPath.

### 12.6. lxml jde ještě dál

1xml je open source knihovna třetí strany, která je vybudována nad populárním parserem 1ibxml2. Poskytuje aplikační rozhraní, které je 100% slučitelné s ElementTree a rozšiřuje ho o plnou podporu XPath 1.0 a o pár dalších vylepšení. K dispozici jsou instalátory pro Windows. Uživatelé Linuxu by měli zkusit nainstalovat předkompilovaný binární tvar z archivů prostřednictvím nástrojů příslušné distribuce, jako je třeba yum nebo apt-get. Pokud by to nešlo, museli byste 1xml nainstalovat ručně.

- Jakmile 1xml naimportujeme, máme k dispozici stejné aplikační rozhraní jako u zabudované knihovny ElementTree.
- [2] Funkce parse() stejná jako u ElementTree.
- [3] Metoda getroot() také stejná.
- [4] Metoda findall() naprosto stejná.

Pro velké xml dokumenty je 1xml výrazně rychlejší než zabudovaná knihovna ElementTree. Pokud používáte pouze aplikační rozhraní ElementTree a chcete používat nejrychlejší dostupnou implementaci, můžete vyzkoušet naimportovat 1xml se záchranou v podobě zabudované ElementTree.

```
try:
    from lxml import etree
except ImportError:
    import xml.etree.ElementTree as etree
```

Ale 1xml je víc než pouhá rychlejší podoba ElementTree. Její implementace metody findal1() podporuje komplikovanější výrazy.

```
>>> import lxml.etree
                                                                                          [1]
>>> tree = lxml.etree.parse('examples/feed.xml')
>>> tree.findall('//{http://www.w3.org/2005/Atom}*[@href]')
                                                                                          [2]
[<Element {http://www.w3.org/2005/Atom}link at eeb8a0>,
 <Element {http://www.w3.org/2005/Atom}link at eeb990>,
 <Element {http://www.w3.org/2005/Atom}link at eeb960>,
 <Element {http://www.w3.org/2005/Atom}link at eeb9c0>]
>>> tree.findall("//{http://www.w3.org/2005/Atom}*[@href='http://diveintomark.org/']")
[<Element {http://www.w3.org/2005/Atom}link at eeb930>]
>>> NS = '{http://www.w3.org/2005/Atom}'
>>> tree.findall('//{NS}author[{NS}uri]'.format(NS=NS))
                                                                                          [4]
[<Element {http://www.w3.org/2005/Atom}author at eeba80>,
 <Element {http://www.w3.org/2005/Atom}author at eebba0>]
```

- V tomto příkladu provedeme import lxml.etree. Chceme zde zdůraznit, že jde o vlastnosti specifické pro lxml (takže nenapíšeme, dejme tomu, from lxml import etree).
- Tento dotaz najde všechny elementy z prostoru jmen Atom, které mají atribut href
   ať už se nacházejí v dokumentu kdekoliv. Dvě lomítka (//) na začátku dotazu znamenají
  "elementy nacházející se kdekoliv (ne jenom potomci nebo kořenový element)".
  {http://www.w3.org/2005/Atom} znamená "jen elementy z prostoru jmen Atom".
  \* znamená "elementy s libovolným lokálním jménem". A [@href] znamená, "které mají
  atribut href".
- [3] Tento dotaz najde všechny elementy z Atom, které mají href s hodnotou http://diveintomark.org/.
- S využitím jednoduchého formátovacího řetězce (protože jinak by se tyto složené dotazy staly neúnosně dlouhé) získáme dotaz, který v prostoru Atom hledá elementy author, které mají mezi svými potomky element uri. Vrátí se jen dva elementy author jen z prvního a druhého elementu entry. Element author v posledním entry obsahuje jen name uri mu chybí.

Ještě toho nemáte dost? Do 1xml je zahrnuta i podpora pro libovolné výrazy XPath 1.0. Nebudu se do hloubky zabývat syntaxí XPath. To by samo o sobě vydalo na celou knihu! Ale ukážeme si, jakým způsobem je podpora XPath do 1xml zahrnuta.

```
>>> import lxml.etree
>>> tree = lxml.etree.parse('examples/feed.xml')
>>> NSMAP = {'atom': 'http://www.w3.org/2005/Atom'} [1]
>>> entries = tree.xpath("//atom:category[@term='accessibility']/..", [2]
... namespaces=NSMAP)
>>> entries [3]
[<Element {http://www.w3.org/2005/Atom}entry at e2b630>]
>>> entry = entries[0]
>>> entry.xpath('./atom:title/text()', namespaces=NSMAP) [4]
['Accessibility is a harsh mistress']
```

- Abychom mohli provádět dotazy XPath nad elementy z nějakého prostoru jmen, musíme definovat zobrazení prefixu na prostor jmen. Je to prostě pythonovský slovník.
- Tady máme dotaz v XPath. Výraz v XPath hledá elementy category (z prostoru jmen Atom), které obsahují atribut term s hodnotou accessibility. To ale ještě není výsledkem dotazu. Podívejte se na úplný konec řetězce dotazu. Všimli jste si úseku /..? Ten znamená "a vrať k právě nalezenému elementu category jeho rodičovský element". Takže tento jediný dotaz XPath najde všechny elementy potomky <category term='accessibility'>.
- Funkce xpath() vrací seznam objektů třídy ElementTree. V tomto dokumentu se nachází jediný záznam obsahující category, jehož term má hodnotu accessibility.
- XPath výraz nevrací vždycky seznam elementů. DOM (Document Object Model; objektový model dokumentu), který vznikl na základě zpracování (parsing) XML dokumentu, neobsahuje z technického hlediska elementy, ale uzly. Uzly mohou (podle typu) reprezentovat elementy, atributy nebo dokonce textový obsah. Výsledkem XPath dotazu je seznam uzlů. Tento dotaz vrací seznam textových uzlů: textový obsah (text()) elementu title (atom: title), který je potomkem aktuálního elementu (./).

### 12.7. Generování XML

Podpora XML v Pythonu není omezena na analýzu (parsing) existujících dokumentů. Můžeme také vytvářet XML dokumenty zcela od základů.

```
>>> import xml.etree.ElementTree as etree
>>> new_feed = etree.Element('{http://www.w3.org/2005/Atom}feed', [1]
... attrib={'{http://www.w3.org/XML/1998/namespace}lang': 'en'}) [2]
>>> print(etree.tostring(new_feed)) [3]
<ns0:feed xmlns:ns0='http://www.w3.org/2005/Atom' xml:lang='en'/>
```

Nový element vznikne vytvořením instance třídy Element. Jako první argument předáváme jméno elementu (prostor jmen + lokální jméno). Tímto příkazem se vytvoří element feed v prostoru jmen Atom. To bude kořenový element našeho nového dokumentu.

- Atributy k nově vytvořenému elementu přidáme předáním slovníku se jmény a hodnotami atributů argumentem attrib. Poznamenejme, že jména atributů musí být uvedena ve tvaru pro ElementTree {prostor jmen}lokální jméno.
- [3] Kterýkoliv element (a jeho potomky) můžeme kdykoliv převést na řetězec (serializovat) voláním funkce tostring() z ElementTree.

Jste výsledkem serializace překvapeni? Způsob, jakým ElementTree serializuje XML elementy s prostorem jmen, je sice z technického hlediska přesný, ale není optimální. Vzorový XML dokument ze začátku této kapitoly definoval *výchozí prostor jmen* (xmlns='http://www.w3.org/2005/Atom'). U dokumentů, kde se všechny elementy nacházejí ve stejném prostoru jmen — jako u Atom feeds — je definice výchozího prostoru jmen užitečná, protože ji uvedeme jen jednou a elementy pak můžeme deklarovat jen jejich lokálním jménem (<feed>, , <entry>). Pokud nepotřebujeme deklarovat elementy z jiného prostoru jmen, nemusíme prefixy uvádět.

XML parser "nevidí" mezi XML dokumentem s výchozím prostorem jmen a mezi XML dokumentem s prefixovaným prostorem jmen žádný rozdíl. Výsledný DOM s následující serializací:

```
<ns0:feed xmlns:ns0='http://www.w3.org/2005/Atom' xml:lang='en'/>
je totožný s DOM s touto serializací:
<feed xmlns='http://www.w3.org/2005/Atom' xml:lang='en'/>
```

Jediný praktický rozdíl spočívá v tom, že druhá serializace je o pár znaků kratší. Kdybychom chtěli celý vzorek našeho obsahu (feed) přepsat s prefixem ns0: v každé počáteční a koncové značce, přidalo by to 4 znaky na každou značku × 79 značek + 4 znaky pro vlastní deklaraci prostoru jmen, to je celkem 320 znaků. Za předpokladu, že používáme kódování UTF-8, to je 320 bajtů navíc. (Po zabalení pomocí gzip se rozdíl zmenší na 21 bajtů, ale 21 bajtů je pořád 21 bajtů.) Pro vás to možná nic neznamená, ale pro něco takového jako je Atom feed, který může být stahován několikatisíckrát, kdykoliv dojde ke změně, se může úspora pár bajtů na dotaz rychle nasčítat.

Zabudovaná knihovna ElementTree tak jemné ovládání serializace elementů z prostoru jmen nenabízí, ale 1xml ano.

```
>>> import lxml.etree
>>> NSMAP = {None: 'http://www.w3.org/2005/Atom'} [1]
>>> new_feed = lxml.etree.Element('feed', nsmap=NSMAP) [2]
>>> print(lxml.etree.tounicode(new_feed)) [3]
<feed xmlns='http://www.w3.org/2005/Atom'/>
>>> new_feed.set('{http://www.w3.org/XML/1998/namespace}lang', 'en') [4]
>>> print(lxml.etree.tounicode(new_feed))
<feed xmlns='http://www.w3.org/2005/Atom' xml:lang='en'/>
```

- Začneme tím, že definujeme zobrazení prostorů jmen v podobě slovníku. Hodnotami slovníku [1] jsou prostory jmen, klíči jsou požadované prefixy. Použitím None v roli klíče definujeme výchozí prostor jmen.
- Když teď při vytváření elementu předáme slovník argumentem nsmap (je specifický pro 1xm1), [2] bude lxml respektovat prefixy prostorů jmen, které jsme definovali.
- Tato serializace podle očekávání definuje prostor jmen Atom jako výchozí prostor jmen a dekla-[3] ruje element feed bez prefixu prostoru jmen.
- Jejda! Zapomněli jsme přidat atribut xml: lang. Libovolný atribut můžeme k libovolnému elemen-[4] tu přidat metodou set (). Přebírá dva argumenty: jméno atributu ve formátu pro ElementTree a hodnotu atributu. (Tato metoda není specifická pro 1xml. Jedinou částí specifickou pro 1xml byl v tomto příkladu argument nsmap, který v serializovaném výstupu ovládá prefixování prostorem jmen.)

Může se v XML dokumentech vyskytovat jen jeden element na dokument? Samozřejmě že ne. Snadno můžeme vytvořit i elementy potomků.

```
>>> title = lxml.etree.SubElement(new_feed, 'title',
                                                                         [1]
        attrib={'type':'html'})
                                                                         [2]
>>> print(lxml.etree.tounicode(new_feed))
<feed xmlns='http://www.w3.org/2005/Atom' xml:lang='en'><title type='html'/></feed>
>>> title.text = 'dive into …'
                                                                         [4]
>>> print(lxml.etree.tounicode(new_feed))
                                                                         [5]
<feed xmlns='http://www.w3.org/2005/Atom' xml:lang='en'><title type='html'>dive into
…</title></feed>
>>> print(lxml.etree.tounicode(new_feed, pretty_print=True))
                                                                         [6]
<feed xmlns='http://www.w3.org/2005/Atom' xml:lang='en'>
<title type='html'>dive into&amp;hellip;</title>
</feed>
```

- [1] Při vytváření dětského elementu k existujícímu elementu vytváříme instanci třídy SubElement. Jedinými povinnými argumenty jsou zde rodičovský element (v našem případě new\_feed) a jméno nového elementu. Protože má dětský element dědit mapování (zobrazení) prostoru jmen od svého rodiče, nemusíme zde prostoj jmen nebo prefix znovu deklarovat.
- Můžeme také předat slovník atributů. Klíče hrají roli jmen atributů, hodnoty jsou hodnotami [2] atributů.
- Podle očekávání byl v prostoru jmen Atom vytvořen element title a byl vložen jako potomek [3] do elementu feed. Protože element title neobsahoval žádný text a neměl své vlastní potomky, serializuje jej 1xml jako prázdný element (zkrácený zápis s /> na konci).
- Pokud chceme elementu nastavit textový obsah, přiřadíme jej jednoduše do vlastnosti .text. [4]
- Teď už se element title serializuje i se svým textovým obsahem. Každý text, který obsahuje [5] znaky menší než nebo ampersand, musí být při serializaci převeden na speciální posloupnosti. 1xml se o to postará automaticky.

- Při serializaci můžeme předepsat také "tisk v pěkném tvaru". Za koncové značky a za počáteční značky elementů, které obsahují potomky, ale ne text, se vloží přechody na nový řádek. Vyjádřeno technickými pojmy, 1xml přidá "nevýznamné bílé znaky" za účelem zvýšení čitelnosti výstupu.
- > Možná byste se chtěli mrknout také na xmlwitch, což je další knihovna třetí strany pro generování XML. Aby byl kód pro generování XML čitelnější, široce se v ní využívá příkazu with.

### 12.8. Analýza porušeného XML

Specifikace XML nařizuje, aby všechny XML parsery, které chtějí specifikaci vyhovět, používaly "drakonickou obsluhu chyb". To znamená, že musí s výrazným efektem zastavit, jakmile v XML dokumentu narazí na jakýkoliv prohřešek proti korektní podobě. Prohřešky proti správné formě zahrnují nespárované počáteční a koncové značky, nedefinované entity (speciální posloupnosti pro znaky), nelegální Unicode znaky a řadu dalších esoterických pravidel. To je v příkrém kontrastu s jinými běžnými formáty, jako je například HTML. Váš prohlížeč nepřestane zobrazovat stránku, ve které zapomenete uvést uzavírací značku HTML nebo když zapomenete zapsat ampersand v atributu jako speciální sekvenci. (Běžným omylem je, že HTML nemá definováno ošetření chyb. Ošetřování chyb v HTML je ve skutečnosti definováno velmi dobře, ale je výrazně komplikovanější, než "zastav a začni hořet" v okamžiku, kdy se narazí na první chybu.)

Někteří lidé věří (a já patřím mezi ně), že požadavek na drakonickou obsluhu chyb byl ze strany tvůrců XML nepřiměřený. Nechápejte mě špatně. Zjednodušení pravidel pro ošetření chyb má své kouzlo. Ale v praxi je koncepce "korektnosti formátu" ošidnější, než to vypadá — zvlášť u XML (jako je Atom feeds), které jsou zveřejňovány na webu a zpřístupňovány protokolem HTTP. I přes vyzrálost formátu XML, který standardizoval drakonická pravidla pro ošetřování chyb v roce 1997, průzkumy stále ukazují, že významná část dokumentů Atom feeds nacházejících se na webu je zamořena chybami formátu.

Takže mám jak teoretické, tak praktické důvody ke zpracování (parse) XML dokumentů "za každou cenu". To znamená, že *nechci* s kraválem zastavit při prvním prohřešku proti korektnosti formátu. Pokud zjistíte, že to cítíte podobně, může vám pomoci LXML.

Tady máme kousek porušeného XML dokumentu. Prohřešky proti korektnosti jsem zvýraznil.

```
<?xml version='1.0' encoding='utf-8'?>
<feed xmlns='http://www.w3.org/2005/Atom' xml:lang='en'>
    <title>dive into &hellip;</title>
...
</feed>
```

Tak tohle je chyba, protože entita … není v XML definována. (Je definována v HTML.) Pokud se takto porušený obsah (feed) pokusíte zpracovat (parse), 1xml se zakucká na nedefinované entitě.

```
>>> import lxml.etree
>>> tree = lxml.etree.parse('examples/feed-broken.xml')
Traceback (most recent call last):
   File "<stdin>", line 1, in <module>
   File "lxml.etree.pyx", line 2693, in lxml.etree.parse (src/lxml/lxml.etree.c:52591)
   File "parser.pxi", line 1478, in lxml.etree._parseDocument (src/lxml/lxml.etree.c:75665)
   File "parser.pxi", line 1507, in lxml.etree._parseDocumentFromURL (src/lxml/lxml.etree.c:75993)
   File "parser.pxi", line 1407, in lxml.etree._parseDocFromFile (src/lxml/lxml.etree.c:75002)
   File "parser.pxi", line 965, in lxml.etree._BaseParser._parseDocFromFile (src/lxml/lxml.etree.c:72023)
   File "parser.pxi", line 539, in lxml.etree._ParserContext._handleParseResultDoc (src/lxml/lxml.etree.c:67830)
   File "parser.pxi", line 625, in lxml.etree._handleParseResult (src/lxml/lxml.etree.c:68877)
   File "parser.pxi", line 565, in lxml.etree._raiseParseError (src/lxml/lxml.etree.c:68125)
lxml.etree.XMLSyntaxError: Entity 'hellip' not defined, line 3, column 28
```

Abychom byli schopni takto porušený XML dokument zpracovat (navzdory prohřešku proti korektnímu formátu), musíme vytvořit vlastní XML parser.

```
>>> parser = lxml.etree.XMLParser(recover=True)
                                                                             [1]
>>> tree = lxml.etree.parse('examples/feed-broken.xml', parser)
                                                                             [2]
>>> parser.error_log
                                                                             [3]
examples/feed-broken.xml:3:28:FATAL:PARSER:ERR_UNDECLARED_ENTITY: Entity 'hellip' not defined
>>> tree.findall('{http://www.w3.org/2005/Atom}title')
[<Element {http://www.w3.org/2005/Atom}title at ead510>]
>>> title = tree.findall('{http://www.w3.org/2005/Atom}title')[0]
>>> title.text
                                                                             [4]
'dive into '
>>> print(lxml.etree.tounicode(tree.getroot()))
                                                                             [5]
<feed xmlns='http://www.w3.org/2005/Atom' xml:lang='en'>
  <title>dive into </title>
 [zbývající serializace pro stručnost vynechány]
```

- Uživatelský parser (syntaktický analyzátor) vznikne vytvořením instance třídy lxml.etree.

  XMLParser. Lze jí předat celou řadu pojmenovaných argumentů. Nás momentálně zajímá argument recover. Pokud jej nastavíme na hodnotu True, XML parser udělá, co je v jeho silách, aby se z chyb proti korektnímu formátu "zotavil".
- Náš XML dokument zpracujeme pomocí uživatelského parseru tak, že objekt parser předáme funkci parse() jako druhý argument. Všimněte si, že 1xml kvůli nedefinované entitě … nevyvolal žádnou výjimku.

- Syntaktický analyzátor veškeré prohřešky proti korektnímu formátu zaznamenává. (Ve skutečnosti je zaznamenává nezávisle na tom, zda jsme mu nastavili zotavovací režim po chybě nebo ne.)
- Protože nevěděl, co má s nedefinovanou entitou … dělat, parser ji jednoduše vypustil. Takže textový obsah, který se nachází za elementem title, se změní na 'dive into '.
- Jak vidíte ze serializované hodnoty, entita … se nikam nepřesunula. Byla jednoduše vypuštěna.

Pokud používáme syntaktické analyzátory XML se "zotavením", pak je nutné znovu zopakovat, že neexistuje **žádná záruka vzájemné součinnosti**. Jiný parser se mohl rozhodnout, že jde o entitu … z HTML, a nahradí ji posloupností & hellip;. Je to "lepší"? Možná. Je to "správnější"? Ne. Oba případy jsou stejně nesprávné. Správné chování (podle specifikace XML) spočívá v tom, že parser "zastaví a začne hořet". Pokud jste se rozhodli, že to neuděláte, je to vaše věc.

### 12.9. Přečtěte si

XML na Wikipedia.org

(http://en.wikipedia.org/wiki/XML) (česky zde http://cs.wikipedia.org/wiki/Extensible\_Markup\_Language)

- The ElementTree XML API
  - (http://docs.python.org/py3k/library/xml.etree.elementtree.html)
- Elements and Element Trees
  - (http://effbot.org/zone/element.htm)
- XPath Support in ElementTree
  - (http://effbot.org/zone/element-xpath.htm)
- The ElementTree iterparse Function
  - (http://effbot.org/zone/element-iterparse.htm)
- 1xml
  - (http://codespeak.net/lxml/)
- Parsing XML and HTML with 1xml
  - (http://codespeak.net/lxml/1.3/parsing.html)
- XPath and XSLT with 1xml
  - (http://codespeak.net/lxml/1.3/xpathxslt.html)
- xmlwitch
  - (https://github.com/galvez/xmlwitch)

"Every Saturday since we've lived in this apartment, I have awakened at 6:15, poured myself a bowl of cereal, added a quarter-cup of 2% milk, sat on this end of this couch, turned on BBC America, and watched Doctor Who."

(Každou sobotu, od té doby co žiji v tomto bytě, jsem vstal v 6.15, nasypal do sebe misku cereálií, přidal jsem hrnek 2% mléka, sedl jsem si na tento konec této pohovky, zapnul jsem BBC America a díval jsem se na Doctor Who.)

- Sheldon, The Big Bang Theory

# 13. Serializace pythonovských objektů

Načítání dat z JSON souboru — 293

Přečtěte si — 295

13.11.

13.12.

### 13.1. Ponořme se

Myšlenka serializace vypadá na první pohled jednoduše. Máme datovou strukturu v paměti, kterou chceme uložit, znovu použít nebo zaslat někomu jinému. Jak bychom to udělali? Záleží to na tom, jak ji chceme uložit, jak ji chceme znovu použít a komu ji chceme poslat. Mnoho her umožňuje, abyste si při ukončení uložili stav a při příštím spuštění pokračovali od tohoto místa dál. (Ve skutečnosti to umožňuje i mnoho aplikací, které nemají s hrami nic společného.) V takovém případě musí být datová struktura, která zachycuje "váš dosavadní pokrok", při ukončení uložena na disk a při opětném spuštění z disku načtena. Data jsou určena jen pro použití se stejným programem, který je vytvořil. Nikdy se neposílají po síti a nikdy je nečte nic jiného než program, který je vytvořil. To znamená, že záležitost součinnosti se omezuje pouze na to, aby byla následující verze programu schopna načíst data zapsaná předchozími verzemi.

Pro tyto případy se ideálně hodí modul pickle. Je součástí pythonovské standardní knihovny, takže je kdykoliv k dispozici. Je rychlý. Jeho větší část je napsána v jazyce C, stejně jako vlastní interpret Pythonu. Dokáže uložit libovolně složité pythonovské datové struktury.

Co vlastně modul pickle dokáže uložit?

- Všechny Pythonem podporované přirozené datové typy: boolean, celá i reálná čísla, komplexní čísla, řetězce, objekty typu bytes, pole bajtů a None.
- Seznamy, n-tice, slovníky a množiny, které obsahují libovolnou kombinaci přirozených datových typů.
- Seznamy, n-tice, slovníky a množiny, které obsahují libovolnou kombinaci seznamů, n-tic, slovníků a množin, které obsahují libovolnou kombinaci přirozených datových typů (a tak dále až do maximální hloubky zanoření, kterou Python podporuje).
- Funkce, třídy a instance tříd (s upozorněním na určitá nebezpečí).
- A pokud se vám to zdá málo, modul pickle je navíc rozšiřitelný. Pokud vás možnost rozšiřitelnosti zajímá, podívejte se na odkazy v podkapitole Přečtěte si na konci kapitoly.

### 13.1.1. Stručná poznámka k příkladům v této kapitole

Tato kapitola vypráví příběh s dvěma pythonovskými shelly. Všechny příklady v kapitole jsou částí jedné linie příběhu. Během předvádění modulů pickle a json budeme přecházet z jednoho pythonovského shellu do druhého.

Abychom oba od sebe poznali, otevřete jeden pythonovský shell a definujte následující proměnnou:

```
>>> shell = 1
```

Okno nechejte otevřené. Teď otevřete druhý pythonovský shell a definujte proměnnou:

```
>>> shell = 2
```

Během kapitoly budeme používat proměnnou shell k indikaci toho, který pythonovský shell se u každého příkladu používá.

### 13.2. Uložení dat do "pickle souboru"

Modul pickle pracuje s datovými strukturami. Jednu takovou si připravíme.

```
>>> shell
                                                                                       [1]
>>> entry = {}
                                                                                       [2]
>>> entry['title'] = 'Dive into history, 2009 edition'
>>> entry['article_link'] = 'http://diveintomark.org/archives/2009/03/27/dive-into-history-2009-edition'
>>> entry['comments_link'] = None
>>> entry['internal_id'] = b'\xDE\xD5\xB4\xF8'
>>> entry['tags'] = ('diveintopython', 'docbook', 'html')
>>> entry['published'] = True
>>> import time
>>> entry['published_date'] = time.strptime('Fri Mar 27 22:20:42 2009')
                                                                                       [3]
>>> entry['published_date']
time.struct_time(tm_year=2009, tm_mon=3, tm_mday=27, tm_hour=22, tm_min=20, tm_sec=42, tm_wday=4,
tm_yday=86, tm_isdst=-1)
```

- [1] Budeme pracovat v pythonovském shellu č. 1.
- Základní myšlenka spočívá ve vytvoření pythonovského slovníku, který reprezentuje něco užitečného, jako například záznam v Atom feed. Ale současně by měl obsahovat několik různých typů dat, abychom mohli modul pickle předvést. Nestudujte uvedené hodnoty zbytečně podrobně.
- Modul time definuje datovou strukturu (struct\_time), která se používá k reprezentaci času (s přesností na milisekundy), a funkce, které s touto strukturou manipulují. Funkce strptime() přebírá formátovaný řetězec a převádí jej do podoby struct\_time. Tento řetězec je ve výchozím tvaru, ale můžete jej ovlivnit formátovacími značkami. Podrobnosti hledejte v dokumentaci k modulu time.

Takže tu máme krásně vypadající pythonovský slovník. Uložme jej do souboru.

```
>>> shell [1]
1
>>> import pickle
>>> with open('entry.pickle', 'wb') as f: [2]
... pickle.dump(entry, f) [3]
```

- Pořád se nacházíme v pythonovském shellu č. 1. [1]
- K otevření souboru použijeme funkci open(). Režim souboru nastavíme na 'wb', abychom jej [2] otevřeli pro zápis v binárním režimu. Zabalíme jej do příkazu with, abychom zajistili, že se po dokončení prací sám zavře.
- Funkce dump() z modulu pickle přebírá pythonovskou serializovatelnou datovou strukturu, [3] serializuje ji do binárního podoby (je specifická pro Python a používá poslední verzi protokolu pro pickle) a uloží ji do otevřeného souboru.

### Poslední věta je velmi důležitá.

- Modul pickle přebírá pythonovskou datovou strukturu a uloží ji do souboru.
- Aby to mohl udělat, serializuje datovou strukturu s využitím datového formátu zvaného "pickle protokol". (Poznámka překladatele: Miluju anglicky mluvící tvůrce, kteří dávají konstrukcím a mechanismům "roztomilá" jména. Pravděpodobně základním významem anglického pickle je "nálev" a má také řadu dalších významů. Jenže zkuste to napasovat na český text věnovaný programovacímu jazyku. Jediné, co mi spolehlivě přichází na mysl, jsou úryvky písničky... "Kujme pikle, pikle kujme, spekulujme, intrikujme, lepšího nic není nad pořádný piklení." Kdo neví, gůůůglí.)
- Pickle protokol je specifický pro Python. Žádná záruka mezijazykové kompatibility neexistuje. Pravděpodobně není možné, abyste vzali soubor entry pickle, který jsme zrovna vytvořili, a udělali s ním něco rozumného v Perlu, v PHP, v Javě nebo v nějakém jiném jazyce.
- Modul pickle nedokáže serializovat každou pythonovskou datovou strukturu. Pickle protokol se několikrát změnil s tím, jak byly do jazyka Python přidávány nové datové typy. Ale některá omezení přetrvávají.
- Výsledkem těchto změn je i to, že neexistuje žádná záruka kompatibility dokonce ani mezi různými verzemi Pythonu. Novější verze Pythonu podporují starší serializační formáty, ale starší verze Pythonu nepodporují nové formáty (protože nepodporují novější datové typy).
- Pokud neurčíte jinak, budou funkce z modulu pickle používat poslední verze pickle protokolu. Tím je zajištěna maximální pružnost z hlediska typů serializovatelných dat, ale také to znamená, že výsledný soubor nebude čitelný staršími verzemi Pythonu, které poslední verzi pickle protokolu nepodporují.
- Poslední verze pickle protokolu používá binární formát. Ujistěte se, že soubory pro "piklení" otvíráte v binárním režimu. V opačném případě dojde během zápisu k porušení dat.

#### Načítání dat z "pickle souboru" 13.3.

Teď se přepneme do druhého pythonovského shellu — tj. do toho, ve kterém jsme nevytvářeli slovník entry.

```
>>> shell
                                                   [1]
2
>>> entry
                                                   [2]
Traceback (most recent call last):
  File "<stdin>", line 1, in <module>
NameError: name 'entry' is not defined
>>> import pickle
>>> with open('entry.pickle', 'rb') as f:
                                                   [3]
        entry = pickle.load(f)
                                                   [4]
. . .
>>> entry
                                                   [5]
{'comments_link': None,
 'internal_id': b'\xDE\xD5\xB4\xF8',
 'title': 'Dive into history, 2009 edition',
 'tags': ('diveintopython', 'docbook', 'html'),
 'article_link':
 'http://diveintomark.org/archives/2009/03/27/dive-into-history-2009-edition',
 'published_date': time.struct_time(tm_year=2009, tm_mon=3, tm_mday=27, tm_hour=22,
tm_min=20, tm_sec=42, tm_wday=4, tm_yday=86, tm_isdst=-1),
 'published': True}
```

- [1] Tohle je pythonovský shell č. 2.
- Není zde definována žádná proměnná entry. Proměnnou entry jsme definovali v pythonovském shellu č. 1, ale ten se nachází v úplně jiném prostředí a udržuje svůj vlastní stav.
- Otevřeme soubor entry. pickle, který jsme vytvořili v pythonovském shellu č. 1. Modul pickle používá binární datový formát, takže byste jej měli vždy otvírat v binárním režimu.
- [4] Funkce pickle.load() přebírá objekt typu stream, čte z něj serializovaná data, vytváří nový pythonovský objekt, rekonstruuje v něm serializovaná data a nový pythonovský objekt vrací.
- Nyní proměnná entry obsahuje slovník s důvěrně známými klíči a hodnotami.

Kroky pickle.dump() / pickle.load() vedou k vytvoření nové datové struktury, která se shoduje s původní datovou strukturou.

```
>>> shell [1]
1
>>> with open('entry.pickle', 'rb') as f: [2]
... entry2 = pickle.load(f) [3]
...
>>> entry2 == entry [4]
True
>>> entry2 is entry [5]
False
>>> entry2['tags'] [6]
```

```
('diveintopython', 'docbook', 'html')
>>> entry2['internal_id']
b'\xDE\xD5\xB4\xF8'
```

- [1] Přepneme se zpět do pythonovského shellu č. 1.
- [2] Otevřeme soubor entry.pickle.
- [3] Načteme serializovaná data do nové proměnné entry2.
- Python potvrzuje, že se slovníky entry a entry2 shodují. V tomto shellu jsme strukturu entry vybudovali od základů. Začali jsme prázdným slovníkem a ručně jsme jednotlivým klíčům přiřadili určité hodnoty. Slovník jsme serializovali a uložili do souboru entry.pickle. Teď jsme serializovaná data z uvedeného souboru načetli a vytvořili jsme perfektní repliku původní datové struktury.
- [5] Shodnost ale nezaměňujme za totožnost. Řekl jsem, že jsme vytvořili *perfektní repliku* původní datové struktury, což je pravda. Ale pořád je to jen kopie.
- Z důvodů, které budou objasněny v této kapitole později, chci upozornit na to, že klíči 'tags' byla přiřazena hodnota v podobě n-tice a klíči 'internal\_id' byl přiřazen objekt typu bytes.

### 13.4. "Piklení" bez souboru

Serializaci pythonovských objektů přímo do souboru na disk jsme si ukázali na příkladech v předchozí podkapitole. Ale co když soubor nechceme nebo nepotřebujeme? Serializaci můžeme provést také do objektu typu bytes, který se nachází v paměti.

```
>>> shell
1
>>> b = pickle.dumps(entry) [1]
>>> type(b) [2]
<class 'bytes'>
>>> entry3 = pickle.loads(b) [3]
>>> entry3 == entry [4]
True
```

- Funkce pickle.dumps() (všimněte si 's' na konci jména funkce) provádí stejnou serializaci jako funkce pickle.dump(). Ale nepřevezme objekt typu stream a serializovaná data nezapíše do souboru na disk. Místo toho serializovaná data jednoduše vrátí.
- A protože pickle protokol používá binární datový formát, vrátí funkce pickle.dumps() objekt typu bytes.
- Funkce pickle.loads() (opět si všimněte 's' na konci jména funkce) provádí stejnou deserializaci jako funkce pickle.load(). Místo čtení serializovaných dat ze souboru (přes objekt typu stream) přebírá objekt typu bytes, který serializovaná data obsahuje — takový, jaký vrátila funkce pickle.dumps().
- [4] Konečný výsledek je stejný: perfektní replika původního slovníku.

- 13.5. Bajty a řetězce znovu zvedají své ošklivé hlavy
- 13.6. Ladění "pickle souborů"

### 13.5. Bajty a řetězce znovu zvedají své ošklivé hlavy

Pickle protokol se používá už celou řadu let a vyspíval spolu s dospíváním Pythonu. V současnosti existují čtyři různé verze pickle protokolu.

- Python 1.x používal dva pickle protokoly: textový formát ("verze 0") a binární formát ("verze 1").
- Python 2.3 zavedl nový pickle protokol ("verze 2"), který se vyrovnával s novou funkčností v pythonovských objektech tříd. Jeho formát je binární.
- Python 3.0 zavedl další pickle protokol ("verze 3") s explicitní podporou pro objekty typu bytes a pro pole bajtů. Jeho formát je binární.

Pozor, rozdíl mezi bajty a řetězci zase vystrkuje svou ošklivou hlavu. (Pokud jste dávali pozor, nejste překvapeni.) V praxi to znamená, že zatímco Python 3 umí číst data serializovaná protokolem verze 2, Python 2 neumí číst data "zapiklená" protokolem verze 3.

### 13.6. Ladění "pickle souborů"

Jak vlastně pickle protokol vypadá? Vyskočme na chvíli z pythonovského shellu a podívejme se na soubor entry.pickle, který jsme vytvořili.

```
you@localhost:~/diveintopython3/examples$ ls -l entry.pickle
-rw-r--r-- 1 you you 358 Aug 3 13:34 entry.pickle
you@localhost:~/diveintopython3/examples$ cat entry.pickle
comments_linkqNXtagsqXdiveintopythonqXdocbookqXhtmlq?qX publishedq?
XlinkXJhttp://diveintomark.org/archives/2009/03/27/dive-into-history-2009-edition
q    Xpublished_dateq
ctime
struct_time
?qRqXtitleqXDive into history, 2009 editionqu.
```

No, moc nám to tedy nepomohlo. Vidíme řetězce, ale ostatní datové typy končí jako netisknutelné (nebo přinejmenším nečitelné) znaky. Pole zjevně nejsou oddělena mezerami nebo tabulátory. Není to zrovna formát, který bychom chtěli analyzovat sami.

```
5: (
          MARK
  6: X
              BINUNICODE 'published_date'
 25: q
              BINPUT
 27: c
              GLOBAL
                          'time struct_time'
 45: q
              BINPUT
 47: (
              MARK
 48: M
                   BININT2
                              2009
 51: K
                   BININT1
                              3
 53: K
                   BININT1
                              27
 55: K
                   BININT1
                              22
 57: K
                   BININT1
                              20
 59: K
                              42
                   BININT1
 61: K
                   BININT1
                              4
 63: K
                   BININT1
                              86
 65: J
                   BININT
                              -1
 70: t
                   TUPLE
                              (MARK at 47)
 71: q
              BINPUT
                          3
 73: }
               EMPTY_DICT
 74: q
              BINPUT
 76: \x86
               TUPLE2
 77: q
              BINPUT
                          5
 79: R
               REDUCE
 80: q
              BINPUT
                          6
 82: X
              BINUNICODE 'comments_link'
100: q
              BINPUT
                          7
102: N
              NONE
103: X
              BINUNICODE 'internal_id'
              BINPUT
119: q
                          8
121: C
               SHORT_BINBYTES 'ÞÕ'ø'
127: q
              BINPUT
                          9
129: X
              BINUNICODE 'tags'
138: q
              BINPUT
140: X
              BINUNICODE 'diveintopython'
159: q
              BINPUT
                          11
161: X
              BINUNICODE 'docbook'
173: q
              BINPUT
                          12
175: X
              BINUNICODE 'html'
              BINPUT
184: q
                          13
186: \x87
              TUPLE3
187: q
               BINPUT
                          14
189: X
              BINUNICODE 'title'
199: q
               BINPUT
              BINUNICODE 'Dive into history, 2009 edition'
201: X
```

```
237: q
              BINPUT
                         16
239: X
              BINUNICODE 'article_link'
256: q
              BINPUT
                         17
258: X
              BINUNICODE 'http://diveintomark.org/archives/2009/03/27/dive-into-history-2009-edition'
337: q
              BINPUT
339: X
              BINUNICODE 'published'
353: q
              BINPUT
                          19
355: \x88
              NEWTRUE
356: u
              SETITEMS
                         (MARK at 5)
357: .
          STOP
```

highest protocol among opcodes = 3

Nejzajímavější informaci v tomto reverzním překladu najdeme na posledním řádku. Obsahuje totiž verzi pickle protokolu, kterým byl tento soubor vytvořen. Pickle protokol neobsahuje žádnou explicitní značku, která by určovala verzi. Abychom verzi protokolu určili, musíme prohlížet značky ("operační kódy") uvnitř serializovaných dat a řídit se podle toho, který operační kód byl zaveden jakou verzí pickle protokolu. Přesně to dělá funkce pickle.dis(). Výsledek vytiskne na posledním řádku reverzního překladu. Tady máme funkci, která vrátí číslo verze, aniž by něco tiskla:

```
import pickletools

def protocol_version(file_object):
    maxproto = -1
    for opcode, arg, pos in pickletools.genops(file_object):
        maxproto = max(maxproto, opcode.proto)
    return maxproto

A tady ji vidíme v akci:

>>> import pickleversion
>>> with open('entry.pickle', 'rb') as f:
...    v = pickleversion.protocol_version(f)
>>> v
3
```

### 13.7. Serializace pythonovských objektů pro čtení z jiných jazyků

Datový formát používaný modulem pickle je specifický pro Python. Nijak se nepokouší o kompatibilitu s jinými programovacími jazyky. Pokud je vaším cílem mezijazyková kompatibilita, pak se musíte poohlédnout po jiných serializačních formátech. Jedním z nich je JSON. Zkratka "JSON" znamená "JavaScript Object Notation", ale nenechte se tím jménem zmást. JSON je explicitně navržen pro použití napříč různými programovacími jazyky.

V Pythonu 3 je modul json součástí standardní knihovny. Modul json má (stejně jako modul pick-le) funkce pro serializaci datových struktur, pro ukládání serializovaných dat na disk, pro načítání serializovaných dat z disku a pro deserializaci dat zpět do podoby nového pythonovského objektu. Ale najdeme zde také důležité odlišnosti. Ze všeho nejdřív uveďme, že datový formát JSON je textový a ne binární. Formát json a způsob kódování různých typů dat je definován v RFC 4627. Například booleovská hodnota je uložena buď jako pětiznakový řetězec 'false' nebo jako čtyřznakový řetězec 'true'. Všechny hodnoty používané v json jsou citlivé na velikost písmen.

Za druhé tu máme — jako u všech textových formátů — problém s bílými znaky (whitespace). JSON dovoluje, aby se mezi hodnotami vyskytovalo libovolné množství bílých znaků (mezery, tabulátory, návrat vozíku CR, přechod na nový řádek LF). Tyto bílé znaky jsou nevýznamné. To znamená, že kodéry JSON mohou přidat bílé znaky dle vlastního uvážení. Po dekodérech JSON se požaduje, aby bílé znaky mezi hodnotami ignorovaly. To umožňuje, aby byla json data "pěkně naformátována" (pretty-print). Hodnoty mohou být pěkně vnořeny do jiných hodnot při použití různých úrovní odsazení, takže data budou dobře čitelná v textovém editoru nebo ve standardním prohlížeči. V pythonovském modulu json najdeme volbu, která při procesu kódování zajistí "pěkné formátování".

Za třetí tu máme přetrvávající problém s kódováním znaků. json kóduje hodnoty do podoby prostého textu, ale my už víme, že nic jako "prostý text" neexistuje. json musí být uložen v kódování Unicode (v UTF-32, v UTF-16 nebo ve výchozím UTF-8). Sekce 3 dokumentu RFC 4627 definuje, jak máme říct, které kódování je použito.

### 13.8. Uložení dat do JSON souboru

JSON se nápadně podobá datovým strukturám, které byste mohli ručně definovat v JavaScriptu. Není to žádná náhoda. Ve skutečnosti můžete pro "dekódování" dat serializovaných do JSON použít javascriptovou funkci eval (). (Platí zde obvyklá výstraha o nedůvěryhodných zdrojích, ale věc se má tak, že json opravdu je platný JavaScript.) V tomto smyslu už se vám JSON může zdát důvěrně známý.

[1] Místo znovupoužití existující datové struktury entry si teď vytvoříme novou datovou strukturu.

Později si v této kapitole ukážeme, co se stane, když se do JSON pokusíme zakódovat složitější datovou strukturu.

- JSON je textový formát, což znamená, že soubor musíme otevřít v textovém režimu a musíme určit znakové kódování. Nikdy neuděláte chybu, když použijete UTF-8.
- Modul JSON (stejně jako modul pickle) definuje funkci dump(), která přebírá pythonovskou datovou strukturu a objekt typu stream připravený pro zápis. Funkce dump() serializuje pythonovskou datovou strukturu a zapíše ji do objektu typu stream. Vložením volání do příkazu with zajistíme, že po dokončení operace bude soubor korektně uzavřen.

Takže jak vlastně výsledek serializace do json vypadá?

```
you@localhost:~/diveintopython3/examples$ cat basic.json
{"published": true, "tags": ["diveintopython", "docbook", "html"], "comments_link": null,
"id": 256, "title": "Dive into history, 2009 edition"}
```

Tak tohle je určitě mnohem čitelnější než "zapiklený" soubor. Navíc JSON může mezi hodnotami obsahovat libovolné bílé znaky a modul json nabízí snadný způsob, jak toho využít. Díky tomu můžeme vytvořit ještě mnohem čitelnější JSON soubory.

```
>>> shell
1
>>> with open('basic-pretty.json', mode='w', encoding='utf-8') as f:
... json.dump(basic_entry, f, indent=2) [1]
```

Pokud funkci json.dump() předáme parametr indent (tj. odsazení), může být výsledný JSON soubor mnohem čitelnější — za cenu zvětšení velikosti souboru. Parametr indent je celé číslo. O znamená "umísti každou hodnotu na zvláštní řádek". Číslo větší než O znamená "umísti každou hodnotu na zvláštní řádek a použij tento počet mezer pro odsazování zanořených datových struktur".

A takhle vypadá výsledek:

```
you@localhost:~/diveintopython3/examples$ cat basic-pretty.json
{
    "published": true,
    "tags": [
        "diveintopython",
        "docbook",
        "html"
],
    "comments_link": null,
    "id": 256,
    "title": "Dive into history, 2009 edition"
}
```

- 13.9. Zobrazení pythonovských datových typů do JSON
- 13.10. Serializace datových typů, které JSON nepodporuje

# 13.9. Zobrazení pythonovských datových typů do JSON

Protože json není určen pro Python, najdeme při zobrazování pythonovských datových typů určité nesrovnalosti. Některé z nich jsou jen rozdíly v názvech, ale dva důležité pythonovské datové typy v něm úplně chybí. Schválně, jestli si jich všimnete:

| Poznámky | JSON         | Python 3 |
|----------|--------------|----------|
|          | objekt       | slovník  |
|          | pole         | seznam   |
|          | řetězec      | řetězec  |
|          | integer      | integer  |
|          | reálné číslo | float    |
| *        | true         | True     |
| *        | false        | False    |
| *        | null         | None     |

\* Všechny hodnoty používané v JSON jsou citlivé na velikost písmen.

Všimli jste si, co chybí? N-tice a bajty! JSON definuje typ pole, které modul JSON zobrazuje na pythonovský seznam, ale nedefinuje oddělený typ pro "zmrazená pole" (n-tice). A ačkoliv JSON docela pěkně podporuje řetězce, nepodporuje objekty typu bytes nebo pole bajtů.

### 13.10. Serializace datových typů, které JSON nepodporuje

I když JSON nemá žádnou zabudovanou podporu pro bajty, neznamená to, že bychom objekty typu bytes nemohli serializovat. Modul json poskytuje rozšiřující rozhraní (extensibility hooks) pro kódování a dekódování neznámých datových typů. (Slovem "neznámý" rozumějme "nedefinovaný v JSON". Modul json zjevně pole bajtů zná, ale je svázán omezeními specifikace JSON.) Pokud chceme zakódovat bajty nebo jiné datové typy, které JSON v základu nepodporuje, musíme pro ně dodat uživatelské kodéry a dekodéry.

```
'published_date': time.struct_time(tm_year=2009, tm_mon=3, tm_mday=27, tm_hour=22,
tm_min=20, tm_sec=42, tm_wday=4, tm_yday=86, tm_isdst=-1),
 'published': True}
>>> import json
>>> with open('entry.json', 'w', encoding='utf-8') as f:
                                                                           [2]
        json.dump(entry, f)
                                                                           [3]
. . .
Traceback (most recent call last):
  File "<stdin>", line 5, in <module>
  File "C:\Python31\lib\json\__init__.py", line 178, in dump
    for chunk in iterable:
  File "C:\Python31\lib\json\encoder.py", line 408, in _iterencode
    for chunk in _iterencode_dict(o, _current_indent_level):
  File "C:\Python31\lib\json\encoder.py", line 382, in _iterencode_dict
    for chunk in chunks:
  File "C:\Python31\lib\json\encoder.py", line 416, in _iterencode
    o = _default(o)
  File "C:\Python31\lib\json\encoder.py", line 170, in default
    raise TypeError(repr(o) + " is not JSON serializable")
```

TypeError: b'\xDE\xD5\xB4\xF8' is not JSON serializable

- Nastal čas k tomu, abychom se znovu podívali na datovou strukturu entry. Obsahuje následující: booleovskou hodnotu, hodnotu None, řetězec, n-tici řetězců, objekt typu bytes a strukturu time.
- Já vím. Říkal jsem to už dříve, ale stojí to za zopakování: JSON je textový formát. JSON soubory se musí otvírat vždy v textovém režimu a se znakovým kódováním UTF-8.
- [3] Hmm, tohle není dobré. Co se to vlastně stalo?

Stalo se následující: funkce json.dump() se pokusila o serializaci objektu typu bytes s hodnotou b'\xDE\xD5\xB4\xF8', ale selhala, protože v JSON podpora objektů typu bytes chybí. Pokud je ale pro nás ukládání bajtů důležité, můžeme si definovat náš vlastní "miniserializační formát".

Abychom definovali vlastní "miniserializační formát" pro datový typ, který JSON přirozeně nepodporuje, musíme definovat funkci, která přebírá pythonovský objekt jako parametr. Tímto pythonovským objektem bude skutečný objekt, který funkce json.dump() není schopna sama serializovat. V našem případě je to objekt typu bytes s hodnotou b '\xDE\xD5\xB4\xF8'.

- Naše uživatelská serializační funkce by měla zkontrolovat typ pythonovského objektu, který jí předala funkce json.dump(). Pokud funkce serializuje jen jeden datový typ, není to nezbytně nutné. Na druhou stranu se tím vyjasňuje, čím se funkce zabývá. A pokud budeme později potřebovat přidat serializaci pro více datových typů, půjde to snadněji.
- V tomto případě jsem se rozhodl převést objekt typu bytes na slovník. Klíč \_\_class\_\_ bude obsahovat původní datový typ (v řetězcové podobě, 'bytes') a klíč \_\_value\_\_ bude obsahovat aktuální hodnotu. Nemůže to, samozřejmě, být objekt typu bytes. Celý vtip spočívá v převodu na něco, co může být serializováno v JSON! Objekt typu bytes je posloupností celých čísel, kde každé číslo nabývá hodnot z rozsahu 0–255. Pro převod objektu typu bytes na seznam čísel můžeme použít funkci list(). Takže z b'\xDE\xD5\xB4\xF8' se stane [222, 213, 180, 248]. (Počítejte! Funguje to! Bajt zapsaný šestnáctkově \xDE je dekadicky 222, \xD5 je 213 a tak dále.)
- Tento řádek je důležitý. Datová struktura, kterou serializujete, může obsahovat typy, které nejsou ani zabudované do serializátoru json a nezvládne je ani náš uživatelský serializátor. V takovém případě musí náš uživatelský serializátor vyvolat výjimku TypeError, aby se funkce json.dump() dozvěděla, že náš uživatelský serializátor daný typ nezná.

A to je vše. Nemusíme dělat nic jiného. Konkrétně tato uživatelská serializační funkce *vrací pythonov-ský slovník* a ne řetězec. Nemusíme sami realizovat celou "serializaci do JSON". Provedeme pouze část "konverze na podporovaný datový typ". Funkce json.dump() udělá zbytek.

```
>>> shell
1
>>> import customserializer
                                                                                  [1]
>>> with open('entry.json', 'w', encoding='utf-8') as f:
                                                                                  [2]
        json.dump(entry, f, default=customserializer.to_json)
                                                                                  [3]
Traceback (most recent call last):
 File "<stdin>", line 9, in <module>
    json.dump(entry, f, default=customserializer.to_json)
  File "C:\Python31\lib\json\__init__.py", line 178, in dump
    for chunk in iterable:
 File "C:\Python31\lib\json\encoder.py", line 408, in _iterencode
    for chunk in _iterencode_dict(o, _current_indent_level):
 File "C:\Python31\lib\json\encoder.py", line 382, in _iterencode_dict
    for chunk in chunks:
 File "C:\Python31\lib\json\encoder.py", line 416, in _iterencode
    o = _default(o)
 File "/Users/pilgrim/diveintopython3/examples/customserializer.py", line 12, in to_json
    raise TypeError(repr(python_object) + ' is not JSON serializable')
TypeError: time.struct_time(tm_year=2009, tm_mon=3, tm_mday=27, tm_hour=22, tm_min=20,
tm_sec=42, tm_wday=4, tm_yday=86, tm_isdst=-1) is not JSON serializable
```

- Jméno customserializer patří modulu, ve kterém jsme (v předchozím příkladu) definovali funkci to\_json().
- Textový režim, kódování UTF-8 atd., atd. (Jednou na to zapomenete! Já na to taky občas zapomenu! A všechno bude fungovat správně až do chvíle, kdy se to pokazí. Ale pak se to pokazí se vší parádou.)
- Tohle je důležitá část. Abychom navěsili svou převodní funkci na funkci json.dump(), předáme ji při volání funkce json.dump() jako hodnotu parametru default. (Hurá! V Pythonu je objektem všechno.)
- [4] No dobrá, ono to všechno nefunguje. Ale podívejte se na výjimku. Funkce json.dump() už si nestěžuje na to, že není schopna serializovat objekt typu bytes. Teď už si stěžuje na úplně jiný objekt time.struct\_time.

Mohlo by se zdát, že výskyt jiné výjimky není známkou pokroku. Jenže on opravdu je známkou pokroku! Bude stačit jedno malé pošťouchnutí a překonáme i tohle.

- Při rozšiřování existující funkce customserializer.to\_json() potřebujeme zkontrolovat, zda je pythonovský objekt (s kterým má funkce json.dump() potíže) typu time.struct\_time.
- Pokud tomu tak je, uděláme podobný převod jako v případě objektu typu bytes. Objekt typu time.struct\_time převedeme na slovník, který bude obsahovat pouze hodnoty, které lze serializovat do JSON. V našem případě je nejsnadnější způsob převodu data a času na hodnotu serializovatelnou do JSON založen na převodu na řetězec pomocí funkce time.asctime(). Funkce time.asctime() převádí odporně vypadající time.struct\_time na řetězec 'Fri Mar 27 22:20:42 2009'.

Při použití těchto dvou uživatelských konverzí proběhne serializace celé datové struktury entry do JSON bez dalších problémů.

```
>>> shell
1
>>> with open('entry.json', 'w', encoding='utf-8') as f:
... json.dump(entry, f, default=customserializer.to_json)
...
```

```
you@localhost:~/diveintopython3/examples$ ls -l example.json
-rw-r--r-- 1 you you 391 Aug 3 13:34 entry.json
you@localhost:~/diveintopython3/examples$ cat example.json
{"published_date": {"__class__": "time.asctime", "__value__": "Fri Mar 27 22:20:42 2009"},
"comments_link": null, "internal_id": {"__class__": "bytes", "__value__": [222, 213, 180, 248]},
"tags": ["diveintopython", "docbook", "html"], "title": "Dive into history, 2009 edition",
"article_link": "http://diveintomark.org/archives/2009/03/27/dive-into-history-2009-edition",
"published": true}
```

### 13.11. Načítání dat z JSON souboru

Modul json obsahuje (stejně jako modul pickle) funkci load(), která přebírá objekt typu stream, čte z něj data v notaci JSON a vytváří nový pythonovský objekt, který odráží datovou strukturu JSON.

```
>>> shell
>>> del entry
                                                                    [1]
>>> entry
Traceback (most recent call last):
 File "<stdin>", line 1, in <module>
NameError: name 'entry' is not defined
>>> import json
>>> with open('entry.json', 'r', encoding='utf-8') as f:
        entry = json.load(f)
                                                                    [2]
>>> entry
                                                                    [3]
{'comments_link': None,
 'internal_id': {'__class__': 'bytes', '__value__': [222, 213, 180, 248]},
 'title': 'Dive into history, 2009 edition',
 'tags': ['diveintopython', 'docbook', 'html'],
 'article_link': 'http://diveintomark.org/archives/2009/03/27/dive-into-history-2009-edition',
 'published_date': {'__class__': 'time.asctime', '__value__': 'Fri Mar 27 22:20:42 2009'},
 'published': True}
```

- Pro demonstrační účely se přepneme do pythonovského shellu č. 2 a zrušíme tam datovou strukturu entry, kterou jsme v této kapitole vytvořili dříve, použitím modulu pickle.
- V nejjednodušším případě pracuje funkce json.load() stejně jako funkce pickle.load(). Předáme jí objekt typu stream a vrací nový pythonovský objekt.
- Mám pro vás dobrou a špatnou zprávu. Nejdříve tu dobrou. Funkce json.load() úspěšně přečetla soubor entry.json, který jsme vytvořili v pythonovském shellu č. 1, a vytvořila nový pythonovský objekt, který data obsahuje. Teď ta špatná zpráva. Nevznikla tím původní datová struktura entry. Hodnoty 'internal\_id' a 'published\_date' byly vytvořeny jako slovníky.

funkcí to\_json().

13.11.

Jde konkrétně o slovníky obsahující hodnoty slučitelné s JSON, které jsme vytvořili převodní

Funkce json.load() neví nic o konverzních funkcích, které jste mohli předat funkci json.dump(). Potřebujeme vytvořit funkci, která je opakem k funkci to\_json(). Potřebujeme funkci, která převezme uživatelsky převedený objekt JSON a konvertuje jej zpět na původní pythonovský datový typ.

```
# do customserializer.py přidejte následující

def from_json(json_object): [1]
   if '__class__' in json_object: [2]
      if json_object['__class__'] == 'time.asctime':
            return time.strptime(json_object['__value__']) [3]
      if json_object['__class__'] == 'bytes':
            return bytes(json_object['__value__']) [4]
      return json_object
```

- Tato převodní funkce také přebírá jeden parametr a vrací jednu hodnotu. Ale parametrem není řetězec. Je jím pythonovský objekt, který je výsledkem deserializace řetězce v notaci JSON do pythonovského objektu.
- Potřebujeme pouze zkontrolovat, zda tento objekt obsahuje klíč '\_\_class\_\_', který vytvořila funkce to\_json(). Pokud tomu tak je, říká hodnota klíče '\_\_class\_\_', jak máme hodnotu dekódovat zpět na původní pythonovský datový typ.
- [3] K dekódování řetězce s časem, který vrátila funkce time.asctime(), použijeme funkci time.strptime(). Tato funkce přebírá naformátovaný řetězec s datem a časem (v upravitelném formátu, ale s výchozím tvarem stejným, jaký používá funkce time.asctime()) a vrací time.struct\_time.
- Pro převod seznamu celých čísel na objekt typu bytes můžeme použít funkci bytes().

A je to. Ve funkci to\_json() se upravovaly jen dva datové typy. Stejné datové typy jsme teď zpracovali funkcí from\_json(). A takhle vypadá výsledek:

```
>>> shell
2
>>> import customserializer
>>> with open('entry.json', 'r', encoding='utf-8') as f:
... entry = json.load(f, object_hook=customserializer.from_json) [1]
...
>>> entry
{'comments_link': None,
   'internal_id': b'\xDE\xD5\xB4\xF8',
   'title': 'Dive into history, 2009 edition',
   'tags': ['diveintopython', 'docbook', 'html'],
   'article_link': 'http://diveintomark.org/archives/2009/03/27/dive-into-history-2009-edition',
```

```
'published_date': time.struct_time(tm_year=2009, tm_mon=3, tm_mday=27, tm_hour=22, tm_min=20, tm_sec=42, tm_wday=4, tm_yday=86, tm_isdst=-1), 'published': True}
```

- Funkci from\_json() k deserializačnímu procesu připojíme tím, že ji předáme jako parametr object\_hook funkci json.load(). Funkce, která přebírá funkci. Jak šikovné!
- Datová struktura entry teď obsahuje klíč 'internal\_id', jehož hodnotou je objekt typu bytes.

  Obsahuje také klíč 'published\_date', jehož hodnotou je objekt typu time.struct\_time.

Ale má to ještě jednu mouchu.

```
>>> shell
1
>>> import customserializer
>>> with open('entry.json', 'r', encoding='utf-8') as f:
... entry2 = json.load(f, object_hook=customserializer.from_json)
...
>>> entry2 == entry
False
>>> entry['tags']
('diveintopython', 'docbook', 'html')
>>> entry2['tags']
['diveintopython', 'docbook', 'html']
[3]
```

- Dokonce ani po připojení funkce to\_json() k serializaci a připojení funkce from\_json() k deserializaci se nám stále nepodařilo vytvořit dokonalou repliku původní datové struktury. Proč tomu tak je?
- [2] V původní datové struktuře entry byla hodnotou klíče 'tags' n-tice tří řetězců (tedy trojice řetězců).
- Ale v datové struktuře entry2, kterou jsme dostali převodem tam a zase zpět, má klíč 'tags' hodnotu seznamu těchto tří řetězců. JSON nedělá rozdíl mezi n-ticemi a seznamy. Zná jen jeden seznamu se podobající datový typ typ pole. Modul json během serializace potichu konvertuje jak n-tice, tak seznamy na pole v JSON. Při většině použití můžete rozdíl mezi n-ticemi a seznamy ignorovat. Ale pokud pracujete s modulem json, měli byste na to myslet.

# 13.12. Přečtěte si

Nada článků o modulu pickle se odkazuje na cPickle. V Pythonu 2 existovaly dvě implementace modulu pickle. Jedna byla napsána v Pythonu a druhá v jazyce C (ale dala se volat z Pythonu). V Pythonu 3 byly tyto moduly spojeny, takže pokaždé provádíme jen import pickle. Zmíněné články mohou být užitečné, ale informaci o cPickle (která je nyní zastaralá) byste měli ignorovat.

# O "piklení" s modulem pickle:

pickle module

(http://docs.python.org/py3k/library/pickle.html)

• pickle and cPickle — Python object serialization (http://www.doughellmann.com/PyMOTW/pickle)

• Using pickle

(http://wiki.python.org/moin/UsingPickle)

• Python persistence management

(www.ibm.com/developerworks/library/l-pypers.html)

### O JSON a o modulu json:

 json — JavaScript Object Notation Serializer (www.doughellmann.com/PyMOTW/json/)

• JSON encoding and ecoding with custom objects in Python (http://blog.quaternio.net/2009/07/16/json-encoding-and-decoding-with-custom-objects-in-python/)

### O rozšiřitelnosti modulu pickle:

- Pickling class instances
- Persistence of external objects
- Handling stateful objects

(vše na http://docs.python.org/py3k/library/pickle.html)

"A ruffled mind makes a restless pillow." (Rozbouřená mysl je nepohodlný polštář.)

— Charlotte Bronteová

# 14. Webové služby nad HTTP

Za hranicemi HTTP POST — 326

Přečtěte si — 328

14.7.

14.8.

# 14.1. Ponořme se

Z filozofického hlediska můžeme webové služby nad HTTP (HyperText Transfer Protocol) popsat devíti slovy: výměna dat se vzdálenými servery pouze s použitím operací protokolu HTTP. Pokud chceme ze serveru získat data, použijeme HTTP GET. Pokud chceme nová data na server zaslat, použijeme HTTP POST. Některá pokročilejší aplikační rozhraní (API) webových služeb nad HTTP umožňují také vytváření, modifikaci a rušení dat použitím http PUT a HTTP DELETE. To je vše. Žádné registry, žádné obálky, žádný obalující kód, žádné tunelování. "Slovesa", která jsou součástí http protokolu (GET, POST, PUT a DELETE) přímo odpovídají operacím na aplikační úrovni pro získávání, vytváření, modifikaci a rušení dat.

Hlavní výhodou tohoto přístupu je jednoduchost a právě jednoduchost vedla k jeho oblibě. Data — obvykle XML nebo JSON — mohou být vytvořena a uložena jako statická, nebo mohou být generována dynamicky, skriptem na straně serveru. Všechny hlavní programovací jazyky (samozřejmě včetně Pythonu) umožňují stahování těchto dat prostřednictvím svých HTTP-knihoven. Jednodušší je i ladění. Každý prostředek (resource) webové služby nad HTTP má jednoznačnou adresu v podobě URL. Po zadání do webového prohlížeče dojde k načtení a hned vidíte surová data.

Příklady webových služeb nad HTTP:

- Aplikační rozhraní Google Data vám umožní uživatelsky pracovat s celou řadou služeb Google, včetně Blogger a YouTube.
- Flickr Services vám umožní odesílat a stahovat fotografie z Flickr.
- Twitter API vám umožní zveřejňovat krátké zprávy na Twitter.
- ...a řada dalších

Pro interakci s webovými službami nad HTTP jsou v Pythonu 3 k dispozici dvě různé knihovny:

- http.client je nízkoúrovňová knihovna, která implementuje RFC 2616, tedy HTTP-protokol.
- urllib.request je knihovna na vyšší úrovni abstrakce, vybudovaná nad http.client. Poskytuje standardní aplikační rozhraní pro zpřístupňování jak HTTP, tak FTP serverů, automaticky následuje přesměrování HTTP a podporuje některé běžné formy autentizace v HTTP.

Takže který mám použít? Z těchto dvou žádný. Místo toho byste měli použít httplib2, což je open source knihovna třetí strany, která implementuje HTTP do větších detailů než http.client. Současně používá lepší abstrakce než urllib.request.

Abyste porozuměli tomu, proč je httplib2 tou správnou volbou, musíte nejdříve porozumět HTTP.

### 14.2. Vlastnosti HTTP

Každý HTTP klient by měl podporovat pět důležitých vlastností.

# 14.2.1. Používání mezipaměti

# Cache-Control: max-age znamená "neotravujte mě až do příštího týdne"..

Nejdůležitější věcí, které musíme v souvislosti s libovolným typem webové služby rozumět, je to, že přístup k síti je velmi drahý. Nemám na mysli cenu "v penězích" (i když šířka přenosového pásma není zadarmo). Mám na mysli to, že hrozně dlouhou dobu zabere otevření spojení, odeslání požadavku a získání odezvy ze vzdáleného serveru. Dokonce i v případě nejrychlejšího dostupného

spojení může být *latence* (tj. čas mezi zasláním požadavku a zahájením přijímání dat odpovědi) vyšší, než byste předpokládali. Směrovače mohou zafungovat divně, paket se ztratí, na mezilehlý server někdo zaútočil... Na veřejné internetové síti není nikdy klidná chvilka a nic s tím nenaděláte.

Při návrhu HTTP se počítalo s využíváním mezipaměti (cache). Existuje dokonce samostatná třída zařízení (zvaných "mezipaměťové proxy-servery", anglicky "chaching proxies"), jejichž jedinou prací je ležet mezi vámi a zbytkem světa a minimalizovat zatěžování sítě. Vaše firma nebo váš poskytovatel připojení (ISP) téměř jistě mezipaměťové proxy-servery udržuje, i když si toho nemusíte být vědomi. Fungují, protože používání mezipaměti (caching) je součástí HTTP protokolu.

Následuje konkrétní příklad toho, jak to funguje. Prostřednictvím svého prohlížeče navštívíte diveintomark.org. Uvedená stránka používá pro pozadí obrázek wearehugh.com/m. jpg. Když váš prohlížeč obrázek stáhne, server k němu přiloží následující HTTP hlavičky:

HTTP/1.1 200 OK

Date: Sun, 31 May 2009 17:14:04 GMT

Server: Apache

Last-Modified: Fri, 22 Aug 2008 04:28:16 GMT

ETag: "3075-ddc8d800" Accept-Ranges: bytes Content-Length: 12405

Cache-Control: max-age=31536000, public Expires: Mon, 31 May 2010 17:14:04 GMT

Connection: close

Content-Type: image/jpeg

Hlavičky Cache-Control a Expires říkají vašemu prohlížeči (a všem mezipaměťovým proxy-serverům mezi vámi a serverem), že se tento obrázek může získávat z mezipaměti až jeden rok. *Celý rok!* A pokud

někdy v příštím roce navštívíte jinou stránku, která také obsahuje odkaz na tento obrázek, váš prohlížeč jej načte ze své mezipaměti, *aniž by vyvolal jakoukoliv síťovou aktivitu*.

Ale počkejte, bude to ještě lepší. Dejme tomu, že váš prohlížeč obrázek z lokální mezipaměti z nějakého důvodu odstraní. Možná mu došlo místo na disku, možná jste mezipaměť vyprázdnili ručně. Z jakéhokoliv důvodu. Ale HTTP hlavičky říkají, že tato data mohou být uchovávána veřejnými mezipaměťovými proxy-servery. (Z technického pohledu je důležité, co hlavičky *neříkají*. Hlavička Cache-Control neuvádí klíčové slovo private, takže data mohou být uložena v mezipaměti automaticky.) Mezipaměťové proxy-servery jsou navrženy tak, že mají k dispozici obrovské množství úložného prostoru — pravděpodobně ho mají mnohem více, než má vyhrazeno váš lokální prohlížeč.

Pokud vaše firma nebo váš poskytovatel připojení spravuje mezipaměťový proxy-server, může se v jeho mezipaměti obrázek pořád ještě nacházet. Pokud navštívíte diveintomark. org znovu, podívá se váš prohlížeč po obrázku do lokální mezipaměti, ale nenajde jej. Takže vytvoří síťový požadavek a pokusí se obrázek stáhnout ze vzdáleného serveru. Pokud ale mezipaměťový proxy-server pořád má kopii uvedeného obrázku, váš požadavek zachytí a dodá vám obrázek ze své mezipaměti. To znamená, že se váš požadavek ke vzdálenému serveru nikdy nedostane. Ve skutečnosti nemusí opustit vaši firemní síť. Získání obrázku je rychlejší (méně skoků po síti) a vaše firma ušetří peníze (z vnějšího světa se stahuje méně dat).

Použití mezipamětí v HTTP funguje, pokud všechny strany dělají, co mají. Na jedné straně musí servery v odpovědích posílat správné hlavičky. Na druhé straně musí klienti hlavičkám rozumět, respektovat je a nežádat stejná data dvakrát. Mezilehlé proxy-servery nejsou všelékem. Mohou být "chytré" jen do té míry, do jaké jim to servery a klienti umožní.

Standardní pythonovské knihovny pro HTTP používání mezipaměti nepodporují, ale httplib2 ano.

### 14.2.2. Kontrola Last-Modified

Některá data se nemění nikdy, zatímco jiná data se mění pořád. A mezi tím je obrovské množství dat, která se mohla změnit, ale nezměnila se. Publikovaný obsah (feed) serveru CNN.com se mění každých pár minut, ale publikovaný obsah mého weblogu se nemusí změnit celé dny nebo týdny. I kdyby to byl ten druhý případ, nechci klientům říct, aby si můj publikovaný obsah brali z mezipaměti celé týdny, protože pokud bych doopravdy něco nového zveřejnil, lidé by se o tom celé týdny nedozvěděli (protože by respektovali mé hlavičky týkající se mezipaměti, které říkají "neobtěžujte se s kontrolou tohoto publikovaného obsahu po celé týdny"). Na druhou stranu zase nechci, aby klienti stahovali celý publikovaný obsah (feed) každou hodinu, pokud se vůbec nezměnil!

304: Not Modified znamená "stejné nesmysly, jiný den".

HTTP nabízí řešení i pro tento případ. Pokud o data žádáme poprvé, server může zpět poslat hlavičku Last-Modified (naposledy změněno). Je to přesně to, jak to vypadá:

datum a čas, kdy se data naposledy změnila. Obrázek pozadí, na který vedl odkaz z diveintomark. org, doprovázela hlavička Last-Modified.

HTTP/1.1 200 OK

Date: Sun, 31 May 2009 17:14:04 GMT

Server: Apache

Last-Modified: Fri, 22 Aug 2008 04:28:16 GMT

ETag: "3075-ddc8d800" Accept-Ranges: bytes Content-Length: 12405

Cache-Control: max-age=31536000, public Expires: Mon, 31 May 2010 17:14:04 GMT

Connection: close

Content-Type: image/jpeg

Pokud požadujeme stejná data podruhé (nebo potřetí nebo počtvrté), můžeme v dotazu poslat hlavičku If-Modified-Since (pokud bylo změněno od) s hodnotou data a času, které jsme od serveru dostali minule. Pokud se data od té doby změnila, pak server vrátí nová data doplněná o stavový kód 200. Ale pokud se data od té doby nezměnila, server pošle zpět speciální stavový kód protokolu HTTP — 304. Ten říká "od doby, kdy ses naposledy ptal, se tato data nezměnila". Z příkazového řádku si to můžeme ověřit nástrojem curl:

you@localhost:~\$ curl -I -H "If-Modified-Since: Fri, 22 Aug 2008 04:28:16 GMT" http://wearehugh.com/m.jpg

HTTP/1.1 304 Not Modified

Date: Sun, 31 May 2009 18:04:39 GMT

Server: Apache Connection: close ETag: "3075-ddc8d800"

Expires: Mon, 31 May 2010 18:04:39 GMT Cache-Control: max-age=31536000, public

A proč by to mělo být vylepšení? Protože když server pošle 304, neposílá data znovu. Dostaneme pouze stavový kód. Kontrola poslední modifikace zajistí, že se nezměněná data nebudou stahovat podruhé i v případě, kdy došlo k vypršení platnosti kopie v lokální mezipaměti. (Jako bonus navíc obsahuje odpověď 304 také hlavičky pro mezipaměť. Proxy-servery si kopii dat drží, dokonce i když oficiálně "expirovala", v naději, že se data ve skutečnosti nezměnila a že další požadavek povede k odpovědi se stavovým kódem 304 a s aktualizovanými informacemi pro mezipaměť.)

Standardní pythonovské knihovny pro HTTP nepodporují kontrolu data poslední modifikace, ale httplib2 ano.

# 14.2.3. Kontrola ETag

ETagy (tag = značka) představují alternativní způsob dosažení stejného efektu jako v případě kontroly last-modified. Při použití ETagů posílá server spolu s požadovanými daty v hlavičce ETag s heš-kódem (hash). (Jak se přesně heš-hodnota určí, to závisí zcela na serveru. Jediný požadavek je takový, aby se změnila, pokud se změní data.) Obrázek pozadí, na který vedl odkaz z diveintomark.org, doprovázela hlavička ETag.

HTTP/1.1 200 OK

Date: Sun, 31 May 2009 17:14:04 GMT

Server: Apache

Last-Modified: Fri, 22 Aug 2008 04:28:16 GMT

ETag: "3075-ddc8d800"
Accept-Ranges: bytes
Content-Length: 12405

Cache-Control: max-age=31536000, public Expires: Mon, 31 May 2010 17:14:04 GMT

Connection: close
Content-Type: image/jpeg

# ETag vyjadřuje "nic nového pod sluncem".

Pokud stejná data požadujeme podruhé, přiložíme hešhodnotu v hlavičce pořadavku If-None-Match (pokud žádná data neodpovídají). Pokud se data nezměnila, server pošle zpět stavový kód 304. Server — stejně jako v případě kontroly založené na čase poslední modifikace — pošle zpět pouze stavový kód 304. Stejná data znovu neposílá.

Přiložením heš-hodnoty v ETagu při druhém požadavku serveru říkáme, že při shodě heše není nutné posílat stejná data znovu, protože je pořád máme schovaná od minula.

Opět vyzkoušíme pomocí curl:

you@localhost:~\$ curl -I -H "If-None-Match: \"3075-ddc8d800\"" http://wearehugh.com/m.jpg [1]

HTTP/1.1 304 Not Modified

Date: Sun, 31 May 2009 18:04:39 GMT

Server: Apache Connection: close ETag: "3075-ddc8d800"

Expires: Mon, 31 May 2010 18:04:39 GMT Cache-Control: max-age=31536000, public

ETagy se běžně uzavírají do uvozovek, ale *tyto uvozovky jsou součástí hodnoty*. To znamená, že v hlavičce If-None-Match musíme serveru poslat zpět i uvozovky.

Standardní pythonovské knihovny pro HTTP používání ETagů nepodporují, ale httplib2 ano.

# 14.2.4. Komprese

Pokud se bavíme o webových službách nad HTTP, pak se téměř vždy bavíme o přesunování textových dat po drátech tam a zase zpět. Možná jsou ve formátu XML, možná jsou v JSON, možná je to prostý text. Text se dá dobře komprimovat nezávisle na použitém formátu. Příklad publikovaného obsahu (feed) z kapitoly XML má nekomprimovaný 3070 bajtů, ale po kompresi algoritmem gzip má 941 bajtů. To je jen 30 % původní velikosti!

HTTP podporuje několik komprimačních algoritmů. Mezi dva nejběžnější patří gzip a deflate. Pokud přes HTTP požadujeme nějaký prostředek (resource), můžeme serveru říci, aby ho poslal v komprimovaném formátu. Do požadavku vložíme hlavičku Accept-encoding, ve které vyjmenujeme námi podporované komprimační algoritmy. Pokud server některý z těchto algoritmů podporuje, pošle nám zpět komprimovaná data (s hlavičkou Content-encoding, která říká, jaký algoritmus byl použit). O dekompresi se už musíme postarat sami.

Důležitý tip pro vývojáře kódu na straně serveru: Ujistěte se, že komprimovaná podoba zdroje dostane přidělenou jinou značku Etag než nekomprimovaná verze. V opačném případě by došlo ke zmatení mezipaměťových proxy-serverů a ty by mohly klientům vracet komprimovanou verzi, se kterou by si klient nemusel poradit. Více detailů o této delikátní záležitosti si můžete přečíst v diskusi Apache bug 39727.

Standardní pythonovské knihovny pro HTTP kompresi nepodporují, ale httplib2 ano.

### 14.2.5. Přesměrování

Senzační URI se nemění, ale mnohá uri jsou opravdu... nesenzační. Webová místa se reorganizují, stránky se přesouvají na nové adresy. Dokonce i webové služby mohou být reorganizovány. Publikovaný obsah (syndicated feed) mohl být přesunut z http://example.com/index.xml do http://example.com/xml/atom.xml.

Nebo se při rozšiřování a reorganizaci firmy mohla přesunout celá doména. Z http://www.example.com/index.xml se mění na http://server-farm-1.example.com/index.xml.

# Location znamená "podívej se támhle"!

Pokaždé, když HTTP server požádáme o nějaký zdroj (resource), vrací v odpovědi stavový kód. Stavový kód 200 znamená "vše v pořádku, tady je požadovaná stránka". Stavový kód 404 znamená "stránka nenalezena". (Chybu 404 jste už asi při brouzdání po webu viděli.) Stavové kódy ve skupině 300 vyjadřují nějakou formu přesměrování.

HTTP nabízí několik způsobů, jakými se dá oznámit, že se požadované zdroje přesunuly. Dvě nejběžnější techniky používají stavové kódy 302 a 301. Stavový kód 302 označuje dočasné přesměrování. Znamená "ejhle, je to dočasně přesunuté" (a v hlavičce Location se vrátí dočasná adresa). Stavový kód 301 označuje trvalé přesměrování. Znamená "ejhle, je to trvale přesunuté" (a v hlavičce Location se vrací nová adresa). Pokud obdržíte stavový kód 302 a novou adresu, pak máte podle specifikace HTTP pro požadovanou věc použít novou adresu. Ale až se budete na stejný zdroj informací ptát příště, máte to znovu zkusit s původní adresou. Pokud ale obdržíte stavový kód 301 a k němu novou adresu, očekává se od vás, že od toho okamžiku začnete používat novou adresu.

Modul urllib.request při obdržení příslušného stavového kódu od HTTP serveru sice "následuje" přesměrování, ale neřekne vám, že tato situace nastala. Dostanete data, která jste požadovali, ale nikdy se nedozvíte, že se použitá knihovna zachovala "užitečně" a následovala přesměrování za vás. Takže pořád bušíte na staré adrese a pokaždé jste serverem přesměrováni na novou adresu a modul urllib.request pokaždé "užitečně" následuje přesměrování. Jinými slovy, tato knihovna se k trvalému přesměrování chová stejně jako k dočasnému přesměrování. To znamená, že se místo jednoho kola provedou vždycky dvě. To je špatné jak pro server, tak pro vás.

Knihovna httplib2 trvalé přesměrování zvládá. Nejen že vám řekne, že nastalo trvalé přesměrování, ale lokálně si je poznamená a přesměrovaná URL automaticky přepíše dříve, než vznese příslušný požadavek.

#### Jak se nedostat k datům přes HTTP 14.3.

Dejme tomu, že přes HTTP chceme stáhnout informační zdroj, jako je například Atom feed. Protože jde o publikovaný obsah (feed), nebudeme jej stahovat jen jednou. Budeme jej stahovat opakovaně, pořád dokola. (Většina čteček publikovaného obsahu (feed reader) kontroluje změny každou hodinu.) Nejdříve vyzkoušíme "rychlý a špinavý" způsob a pak se podíváme, jak bychom to mohli provádět lépe.

```
>>> import urllib.request
>>> a_url = 'http://diveintopython3.org/examples/feed.xml'
>>> data = urllib.request.urlopen(a_url).read()
                                                                          [1]
>>> type(data)
                                                                          [2]
<class 'bytes'>
>>> print(data)
<?xml version='1.0' encoding='utf-8'?>
<feed xmlns='http://www.w3.org/2005/Atom' xml:lang='en'>
  <title>dive into mark</title>
  <subtitle>currently between addictions</subtitle>
  <id>tag:diveintomark.org,2001-07-29:/</id>
  <updated>2009-03-27T21:56:07Z</updated>
  <link rel='alternate' type='text/html' href='http://diveintomark.org/'/>
```

14.4.

- Stažení čehokoliv přes HTTP je v Pythonu neuvěřitelně jednoduché. Dá se to ve skutečnosti napsat na jeden řádek. Modul urllib. request nabízí šikovnou funkci urlopen(), která přebírá adresu požadované stránky a vrací objekt typu stream, ze kterého získáme celý obsah stránky prostým zavoláním metody read(). Už to asi nemůže být jednodušší.
- Metoda urlopen().read() vrací vždy objekt typu bytes a ne řetězec. Vzpomeňte si bajty jsou bajty, znaky jsou abstrakce. HTTP servery nepracují s abstrakcemi. Kdykoliv požádáme o nějaký zdroj (resource), dostaneme bajty. Pokud z toho chceme udělat řetězec, musíme zjistit znakové kódování a provést explicitní převod na řetězec.

A co na tom je špatného? Při rychlém, jednorázovém přístupu během ladění a vývoje na tom není špatného nic. Dělám to takhle pořád. Chtěl jsem publikovaný obsah (feed), dostal jsem publikovaný obsah. Stejná technika funguje pro libovolné webové stránky. Ale jakmile o tom začneme uvažovat z pohledu webové služby, která se má využívat pravidelně (tj. požadavek na získání publikovaného obsahu každou hodinu), pak by to bylo neefektivní a my bychom byli nezdvořilí.

### 14.4. Co že to máme na drátě?

Abychom viděli, proč je to neefektivní a nezdvořilé, obrátíme se na ladicí prostředky pythonovské knihovny pro HTTP a uvidíme, co běhá "po drátech" (tj. co se přenáší v síti).

```
>>> from http.client import HTTPConnection
>>> HTTPConnection.debuglevel = 1
                                                                             [1]
>>> from urllib.request import urlopen
>>> response = urlopen('http://diveintopython3.org/examples/feed.xml')
                                                                             [2]
send: b'GET /examples/feed.xml HTTP/1.1
                                                                             [3]
Host: diveintopython3.org
                                                                             [4]
Accept-Encoding: identity
                                                                             [5]
User-Agent: Python-urllib/3.1'
                                                                             [6]
Connection: close
reply: 'HTTP/1.1 200 OK'
...další ladicí informace vypuštěny...
```

- Jak už jsem se zmínil na začátku této kapitoly, urllib.request spoléhá na další standardní pythonovskou knihovnu, http.client. S knihovnou http.client za normálních okolností do přímého styku nepřicházíte. (Modul urllib.request ji importuje automaticky.) Ale my si ji importujeme ručně, abychom mohli nastavit příznak ladění u třídy HTTPConnection, kterou modul urllib.request používá pro připojení k HTTP serveru.
- Když teď máme ladicí příznak nastaven, budou se informace o HTTP požadavku a o odpovědi na něj tisknout v reálném čase. Když si vyžádáme Atom feed, je vidět, že modul urllib.request posílá serveru pět řádků.
- [3] První řádek uvádí používané HTTP sloveso (metodu; zde GET) a cestu ke zdroji (bez uvedení jména domény).
- [4] Druhý řádek uvádí doménu, ze které byl požadavek na feed vznesen.

- Třetí řádek uvádí komprimační algoritmy, které klient podporuje. Jak bylo uvedeno výše, urllib.request standardně kompresi nepodporuje.
- [6] Čtvrtý řádek uvádí jméno knihovny, jejímž prostřednictvím byl požadavek vznesen. Výchozí hodnotou je Python-urllib a číslo verze. Jak urllib.request, tak httplib2 podporují změnu identifikace zprostředkovatele tím, že se do požadavku jednoduše přidá hlavička User-Agent, která přepíše výchozí hodnotu.

Teď se podívejme na to, jakou odpověď poslal server zpět.

# Stahovali jsme 3070 bajtů, i když bychom mohli stahovat pouhých 941.

# pokračování předchozího příkladu

>>> print(response.headers.as\_string()) [1]
Date: Sun, 31 May 2009 19:23:06 GMT [2]
Server: Apache
Last-Modified: Sun, 31 May 2009 06:39:55 GMT [3]
ETag: "bfe-93d9c4c0" [4]
Accept-Ranges: bytes
Content-Length: 3070 [5]
Cache-Control: max-age=86400 [6]
Expires: Mon, 01 Jun 2009 19:23:06 GMT

Vary: Accept-Encoding Connection: close

Content-Type: application/xml
>>> data = response.read()

>>> len(data)

3070

Odpověď (response) vrácená funkcí urllib.request.urlopen() obsahuje všechny HTTP hlavičky, které server poslal zpět. Obsahuje také metody pro stahování skutečných dat. K tomu se dostaneme za minutku.

[7]

- [2] Server říká, kdy zpracoval náš požadavek.
- [3] Odpověď obsahuje i hlavičku Last-Modified.
- [4] Odpověď obsahuje také hlavičku ETag.
- Data mají velikost 3070 bajtů. Všimněte si, že zde *není* hlavička Content-encoding. V požadavku jsme uvedli, že přijímáme jen nekomprimovaná data (Accept-encoding: identity), takže jsme tím pádem dostali nekomprimovaná data.
- V odpovědi se nacházejí hlavičky pro mezipaměti, které říkají, že publikovaný obsah (feed) může být brán z mezipaměti po dobu 24 hodin (86 400 sekund).
- [7] A nakonec stáhneme skutečná data voláním response.read(). Z výsledku funkce len() vidíme, že se stáhlo všech 3070 bajtů najednou.

Jak sami vidíte, tento kód je už teď neefektivní. Požadoval (a obdržel) nekomprimovaná data. Určitě vím, že uvedený server podporuje kompresi gzip, ale v HTTP se komprese zapíná na vyžádání. Nepožádali jsme o ni, tak jsme ji nedostali. To znamená, že jsme stahovali 3070 bajtů v situaci, kdy jsme mohli stahovat pouhých 941. Zlobivý pejsek, žádná sušenka.

Ale moment, začíná to být ještě horší! Abychom viděli, jak neefektivní ten kód je, požádáme o stejný publikovaný obsah (feed) podruhé.

```
# pokračování předchozího příkladu
>>> response2 = urlopen('http://diveintopython3.org/examples/feed.xml')
send: b'GET /examples/feed.xml HTTP/1.1
Host: diveintopython3.org
Accept-Encoding: identity
User-Agent: Python-urllib/3.1'
Connection: close
reply: 'HTTP/1.1 200 OK'
...další ladicí informace vypuštěny...
```

Všimli jste si na tom požadavku něčeho zvláštního? Vůbec se nezměnil! Je naprosto stejný jako ten předchozí. Žádná známka použití hlavičky If-Modified-Since. Žádná známka použití hlavičky If-None-Match. Žádný respekt k hlavičkám mezipaměti. Ještě pořád žádná komprese.

A co se stane, když uděláme stejnou věc dvakrát? Dostaneme stejnou odpověď. Dvakrát.

```
# pokračování předchozího příkladu
>>> print(response2.headers.as_string())
                                                  [1]
Date: Mon, 01 Jun 2009 03:58:00 GMT
Server: Apache
Last-Modified: Sun, 31 May 2009 22:51:11 GMT
ETag: "bfe-255ef5c0"
Accept-Ranges: bytes
Content-Length: 3070
Cache-Control: max-age=86400
Expires: Tue, 02 Jun 2009 03:58:00 GMT
Vary: Accept-Encoding
Connection: close
Content-Type: application/xml
>>> data2 = response2.read()
>>> len(data2)
                                                  [2]
3070
>>> data2 == data
                                                  [3]
True
```

14.5.

- Server pořád posílá stejné pole "chytrých" hlaviček: Cache-Control a Expires pro mezipaměť [1] (cache), Last-Modified a ETag pro sledování "nezměněho stavu". A dokonce hlavičku Vary: Accept-Encoding, kterou server dává najevo, že by mohl podporovat kompresi, kdybychom si o ni řekli. Ale my jsme to neudělali.
- A ještě jednou, při získávání dat se stáhlo všech 3070 bajtů... [2]
- ...stejných 3070 bajtů, které jsme stáhli už minule. [3]

Protokol HTTP je navržen, aby pracoval lepším způsobem. Knihovna urllib umí HTTP asi tak, jak já umím španělsky — dost na to, abych se dostal z problémů, ale ne dost k vedení konverzace. A HTTP se týká konverzace. Je čas přejít ke knihovně, která protokolem HTTP mluví plynule.

#### Představujeme httplib2 14.5.

c:\Users\pilgrim\Downloads> dir

Než začneme knihovnu httplib2 používat, musíme ji nainstalovat. Navštivte stránku code.google.com /p/httplib2/ a stáhněte poslední verzi. httplib2 je k dispozici pro Python 2.x a pro Python 3.x. Ujistěte se, že jde o verzi pro Python 3. Jmenuje se podobně jako httplib2-python3-0.5.0. zip. (V době překladu už to bylo jinak: httplib2-0.6.0.zip; uvnitř jsou obě verze.)

Rozbalte archiv, otevřete terminálové okno a přejděte do nově vytvořeného adresáře httplib2. Pod Windows otevřete menu Start, vyberte Run..., napište cmd.exe a stiskněte ENTER.

```
Volume in drive C has no label.
 Volume Serial Number is DED5-B4F8
 Directory of c:\Users\pilgrim\Downloads
07/28/2009 12:36 PM
                       <DIR>
07/28/2009 12:36 PM
                        <DIR>
07/28/2009 12:36 PM
                        <DIR>
                                      httplib2-python3-0.5.0
07/28/2009 12:33 PM
                               18,997 httplib2-python3-0.5.0.zip
                                18,997 bytes
              1 File(s)
              3 Dir(s) 61,496,684,544 bytes free
c:\Users\pilgrim\Downloads> cd httplib2-python3-0.5.0
c:\Users\pilgrim\Downloads\httplib2-python3-0.5.0> c:\python31\python.exe setup.py install
running install
running build
running build_py
running install_lib
creating c:\python31\Lib\site-packages\httplib2
```

```
copying build\lib\httplib2\iri2uri.py -> c:\python31\Lib\site-packages\httplib2 copying build\lib\httplib2\__init__.py -> c:\python31\Lib\site-packages\httplib2 byte-compiling c:\python31\Lib\site-packages\httplib2\iri2uri.py to iri2uri.pyc byte-compiling c:\python31\Lib\site-packages\httplib2\__init__.py to __init__.pyc running install_egg_info
Writing c:\python31\Lib\site-packages\httplib2-python3_0.5.0-py3.1.egg-info
```

V Mac OS X spusťte aplikaci Terminal.app, kterou najdete ve složce /Applications/Utilities/. V Linuxuspusťte aplikaci Terminal, kterou obvykle najdete v menu Applications pod Accessories nebo System.

```
you@localhost:~/Desktop$ unzip httplib2-python3-0.5.0.zip
Archive: httplib2-python3-0.5.0.zip
  inflating: httplib2-python3-0.5.0/README
  inflating: httplib2-python3-0.5.0/setup.py
  inflating: httplib2-python3-0.5.0/PKG-INFO
  inflating: httplib2-python3-0.5.0/httplib2/__init__.py
  inflating: httplib2-python3-0.5.0/httplib2/iri2uri.py
you@localhost:~/Desktop$ cd httplib2-python3-0.5.0/
you@localhost:~/Desktop/httplib2-python3-0.5.0$ sudo python3 setup.py install
running install
running build
running build_py
creating build
creating build/lib.linux-x86_64-3.1
creating build/lib.linux-x86_64-3.1/httplib2
copying httplib2/iri2uri.py -> build/lib.linux-x86_64-3.1/httplib2
copying httplib2/__init__.py -> build/lib.linux-x86_64-3.1/httplib2
running install_lib
creating /usr/local/lib/python3.1/dist-packages/httplib2
copying build/lib.linux-x86_64-3.1/httplib2/iri2uri.py -> /usr/local/lib/python3.1/dist-packages/httplib2
copying build/lib.linux-x86_64-3.1/httplib2/__init__.py -> /usr/local/lib/python3.1/dist-packages/
httplib2
byte-compiling /usr/local/lib/python3.1/dist-packages/httplib2/iri2uri.py to iri2uri.pyc
byte-compiling /usr/local/lib/python3.1/dist-packages/httplib2/__init__.py to __init__.pyc
running install_egg_info
Writing /usr/local/lib/python3.1/dist-packages/httplib2-python3_0.5.0.egg-info
```

Abychom mohli httplib2 používat, vytvoříme instanci třídy httplib2. Http.

```
>>> import httplib2
>>> h = httplib2.Http('.cache')
                                                                                      [1]
>>> response, content = h.request('http://diveintopython3.org/examples/feed.xml')
>>> response.status
                                                                                      [3]
200
>>> content[:52]
                                                                                      [4]
b"<?xml version='1.0' encoding='utf-8'?>\r\n<feed xmlns="
>>> len(content)
3070
```

- Primárním rozhraním k httplib2 je objekt třídy Http. Z důvodů, které si ukážeme v další pod-[1] kapitole, bychom při vytváření objektu třídy Http měli vždy předávat jméno adresáře. Adresář nemusí existovat. V případě potřeby si jej httplib2 vytvoří.
- [2] Jakmile máme objekt třídy Http k dispozici, můžeme data získat jednoduše tím, že zavoláme metodu request() a předáme jí adresu dat. Pro dané url se tím vytvoří požadavek HTTP GET. (Později v této kapitole si ukážeme, jak můžeme vytvořit jiné HTTP požadavky, jako například POST.)
- [3] Metoda request() vrací dvě hodnoty. První hodnotou je objekt třídy httplib2. Response, který obsahuje všechny HTTP hlavičky vrácené serverem. Například hodnota stavového kódu (status) 200 indikuje, že byl dotaz proveden úspěšně.
- [4] Proměnná content obsahuje data, která HTTP server vrátil. Data se vracejí jako objekt typu bytes, nikoliv jako řetězec. Pokud z toho chceme udělat řetězec, musíme zjistit znakové kódování a převést si je sami.
- Pravděpodobně budete potřebovat jen jeden objekt třídy httplib2. Http. Existují rozumné > důvody pro vytváření více než jednoho objektu, ale měli byste to dělat jen v případě, kdy víte, proč je potřebujete. "Potřebuji získávat data ze dvou různých URL" takovým důvodem není. Použijte objekt třídy Http znovu — prostě zavolejte metodu request() dvakrát.

# 14.5.1. Krátká odbočka vysvětlující, proč httplib2 vrací bajty místo řetězců

Bajty. Řetězce. To je bolest. Proč httplib2 nemůže "jednoduše" provést konverzi za nás? No, ono je to komplikované, protože pravidla pro zjištění znakového kódování jsou specifická v závislosti na tom, jaký zdroj (resource) požadujeme. Jak by mohla httplib2 vědět, jaký druh zdroje požadujeme? Obvykle bývá uveden v HTTP hlavičce Content-Type, ale tato hlavička je v HTTP nepovinná a ne všechny HTTP servery ji vkládají. Pokud tato hlavička není součástí HTTP odpovědi, ponechává se odhad na klientovi. (Říká se tomu anglicky "content sniffing" čili "čmuchání v obsahu". Výsledek není nikdy perfektní.)

Pokud víme, jaký druh dat očekáváme (v našem případě XML dokument), mohli bychom "jednoduše" předat objekt typu bytes funkci xml.etree.ElementTree.parse(). To by fungovalo, kdyby XML dokument obsahoval informaci o svém vlastním kódování znaků (jako je tomu v tomto případě). Ale jde o nepovinný údaj a ne všechny XML dokumenty ho používají. Pokud XML dokument informaci o kódování neobsahuje, měl by se klient podívat na transportní obálku — tj. na HTTP hlavičku Content-Type, která by mohla parametr charset obsahovat.

Ale ono je to ještě horší. Teď už může být informace o kódování uvedena na dvou místech: uvnitř samotného XML dokumentu a uvnitř HTTP hlavičky Content-Type. Jenže když je tato informace uvedena na obou místech, které z nich vyhraje? Podle RFC 3023 platí (a přísahám, to jsem si nevymyslel): pokud je v HTTP hlavičce Content-Type uveden typ média application/xml, application/xml-dtd, application/xml-external-parsed-entity nebo libovolný z podtypů application/xml, jako je application/atom+xml nebo application/rss+xml nebo dokonce application/rdf+xml, pak je kódování rovno

- 1. kódování zadanému parametrem charset v HTTP hlavičce Content-Type nebo
- 2. kódování zadanému atributem encoding v XML deklaraci uvnitř dokumentu nebo
- 3. UTF-8

Na druhou stranu, pokud je v HTTP hlavičce Content-Type uveden typ média text/xml, text/xml-external-parsed-entity nebo podtyp jako text/AnythingAtAll+xml, pak se atribut uvádějící kódování v XML deklaraci uvnitř dokumentu zcela ignoruje a kódování je rovno

- 1. kódování zadanému parametrem charset v HTTP hlavičce Content-Type nebo
- 2. us-ASCII

A to se bavíme jen o XML dokumentech. Pro HTML dokumenty vytvořily webové prohlížeče taková byzantská pravidla pro zjišťování obsahu (content-sniffing) [PDF], že se stále ještě snažíme všechna zjistit.

"Opravy jsou vítány."

# 14.5.2. Jak httplib2 zachází s mezipamětí

Vzpomínáte si, že jsem vás v předchozí podkapitole nabádal, abyste vždy vytvářeli objekt třídy httplib2. Http se zadaným jménem adresáře? Důvod se jmenuje mezipaměť (cache).

```
# pokračování z předchozího příkladu
>>> response2, content2 = h.request('http://diveintopython3.org/examples/feed.xml') [1]
>>> response2.status [2]
200
>>> content2[:52] [3]
b"<?xml version='1.0' encoding='utf-8'?>\r\n<feed xmlns="
>>> len(content2)
3070
```

- Tohle by vás nemělo moc překvapit. Stejnou věc už jsme dělali naposledy s tou výjimkou, že [1] výsledek ukládáme do dvou nových proměnných.
- HTTP opět vrací stavový kód (status) 200, jako minule. [2]
- [3] Stažený obsah je také stejný jako minule.

Takže... koho to zajímá? Ukončete pythonovský interaktivní shell a spusťte nové sezení. Hned vám to ukážu.

```
# toto NENÍ pokračování z předchozího příkladu!
# Ukončete, prosím, interaktivní shell
# a spusťte nový.
>>> import httplib2
>>> httplib2.debuglevel = 1
                                                                                      [1]
>>> h = httplib2.Http('.cache')
                                                                                      [2]
>>> response, content = h.request('http://diveintopython3.org/examples/feed.xml')
>>> len(content)
                                                                                      [4]
3070
>>> response.status
                                                                                      [5]
200
>>> response.fromcache
                                                                                      [6]
True
```

- Zapněme ladění a podívejme se, co nám lítá po drátech. Takto se v httplib2 zapíná ladicí režim [1] (srovnejte se zapínáním v http.client). httplib2 vytiskne všechna data, která se posílají na server, a některé klíčové informace, které se posílají zpět.
- Vytvoříme objekt třídy httplib2. Http se stejným jménem adresáře jako minule. [2]
- Vyžádáme si stejné URL jako minule. Zdá se, že se nic nestalo. Přesněji řečeno, nic se neposílá [3] na server a ze serveru se nic nevrací. Na síti nepozorujeme vůbec žádnou aktivitu.
- Přesto jsme nějaká data "přijali" ve skutečnosti jsme dostali všechno. [4]
- A "přijali" jsme také stavový kód protokolu HTTP, který říká, že "požadavek" byl úspěšný.
- Tady je důvod: "odpověď" byla vygenerována z lokální mezipaměti httplib2. Adresář, jehož [6] jméno jsme zadávali při vytváření objektu třídy httplib2. Http, slouží knihovně httplib2 jako mezipaměť (cache) pro všechny operace, které se kdy provedly.
- Pokud chcete v httplib2 zapnout ladicí režim, musíte nastavit konstantu na úrovni modulu > (httplib2.debuglevel) a potom vytvořit nový objekt třídy httplib2.Http. Pokud chcete ladicí režim vypnout, musíte změnit tutéž konstantu na úrovni modulu a potom vytvořit nový objekt třídy httplib2.Http.

Minule jsme požadovali data z konkrétního URL. Požadavek byl úspěšný (status: 200). Odpověď zahrnovala nejen data publikovaného obsahu, ale také množinu hlaviček pro mezipaměť (caching headers). Ty každému příjemci říkají, že si tento zdroj může pamatovat po dobu až 24 hodin (Cache-Control: max-age=86400, což je 24 hodin v sekundách). httplib2 hlavičkám pro mezipaměť rozumí a respektuje je.

# Co se děje na drátě? Vůbec nic.

Předchozí odpověď byla uložena do adresáře .cache (jehož jméno jsme zadali při vytváření objektu třídy Http). Platnost obsahu mezipaměti zatím nevypršela, takže když data ze stejného URL požadujeme podruhé, httplib2 jednoduše vrátí zapamatovaný výsledek, aniž by došlo ke komunikaci po síti.

Říkám "jednoduše", ale za touto jednoduchostí je evidentně skryto hodně složitostí. Knihovna httplib2 zvládá používání mezipaměti v HTTP *automaticky a aniž se o to musíme starat.* Pokud z nějakého důvodu potřebujeme vědět, zda odpověď přichází z mezipaměti, můžeme zkontrolovat response. fromcache. Z jiného pohledu... prostě to funguje.

Dejme tomu, že teď máme data v mezipaměti, ale chceme ji obejít a znovu si je vyžádat od vzdáleného serveru. Prohlížeče to někdy dělají, když si to uživatel vyžádá. Například stisk F5 obnoví aktuální stránku, ale stiskem Ctrl+F5 se obejde mezipaměť a aktuální stránka se znovu vyžádá ze vzdáleného serveru. Možná si myslíte "aha, prostě smažu data ze své lokální mezipaměti a provedu požadavek znovu". Tohle byste udělat mohli. Ale vzpomeňte si, že se to může týkat více stran než jen vás a vzdáleného serveru. Což takhle mezilehlé proxy-servery? Ty jsou zcela mimo vaši kontrolu a pořád mohou uchovávat ona data ve své mezipaměti. A s radostí vám je vrátí, protože obsah jejich mezipaměti je (z jejich pohledu) stále platný.

Takže místo toho, abyste manipulovali s lokální mezipamětí a doufali v nejlepší, měli byste využít vlastností HTTP k zajištění toho, že se váš požadavek skutečně dostal až ke vzdálenému serveru.

```
# pokračování předchozího příkladu
>>> response2, content2 = h.request('http://diveintopython3.org/examples/feed.xml',
        headers={'cache-control':'no-cache'})
                                                           [1]
connect: (diveintopython3.org, 80)
                                                           [2]
send: b'GET /examples/feed.xml HTTP/1.1
Host: diveintopython3.org
user-agent: Python-httplib2/$Rev: 259 $
accept-encoding: deflate, gzip
cache-control: no-cache'
reply: 'HTTP/1.1 200 OK'
...další ladicí informace vypuštěny...
>>> response2.status
200
>>> response2.fromcache
                                                           [3]
False
>>> print(dict(response2.items()))
                                                           [4]
{'status': '200',
 'content-length': '3070',
```

```
'content-location': 'http://diveintopython3.org/examples/feed.xml',
'accept-ranges': 'bytes',
'expires': 'Wed, 03 Jun 2009 00:40:26 GMT',
'vary': 'Accept-Encoding',
'server': 'Apache',
'last-modified': 'Sun, 31 May 2009 22:51:11 GMT',
'connection': 'close',
'-content-encoding': 'gzip',
'etag': '"bfe-255ef5c0"',
'cache-control': 'max-age=86400',
'date': 'Tue, 02 Jun 2009 00:40:26 GMT',
'content-type': 'application/xml'}
```

- httplib2 vám umožní přidat k jakémukoliv odcházejícímu požadavku libovolné HTTP hlavičky. Abychom obešli *všechny* mezipaměti (nejen lokální diskovou, ale také mezipaměťové proxy-servery mezi námi a vzdáleným serverem), přidáme do slovníku headers hlavičku no-cache.
- Teď vidíme, že httplib2 zahajuje síťový požadavek. httplib2 rozumí hlavičkám pro mezipaměť a respektuje je v obou směrech jako součást přicházející odpovědi i jako součást odcházejícího požadavku. Knihovna si všimla, že jsme přidali hlavičku no-cache, takže úplně obešla své lokální mezipaměti. Potom ale nemá na výběr a musí odeslat požadavek na data do sítě.
- Tato odpověď *nebyla* generovaná z naší lokální mezipaměti. To samozřejmě víme, protože jsme viděli ladicí informaci týkající se odcházejícího požadavku. Ale je dobré, že si to můžeme ověřit v programu.
- Požadavek byl úspěšný. Opět jsme ze vzdáleného serveru stáhli celý publikovaný obsah (feed). Server samozřejmě poslal zpět s požadovanými daty (feed) i celou sadu HTTP hlaviček. Jsou mezi nimi i hlavičky pro mezipaměť, které httplib2 použije pro aktualizaci své lokální mezipaměti v naději, že se při *příštím* požadavku na stejná data bude moci vyhnout přístupu na síť. Návrh používání mezipamětí v HTTP je zcela podřízen maximalizaci úspěšnosti mezipamětí (cache hit) a minimalizaci přístupu k síti. I když jsme tentokrát mezipaměti obešli, vzdálený server by opravdu ocenil, kdybychom si výsledek do mezipaměti uložili s ohledem na příští možný dotaz.

# 14.5.3. Jak httplib2 zachází s hlavičkami Last-Modified a ETag

Hlavičky mezipaměti Cache-Control a Expires se nazývají *indikátory čerstvosti* (freshness indicators). Říkají mezipamětem jasným způsobem, že se do vypršení platnosti obsahu mezipaměti můžeme zcela vyhnout přístupu k síti. Přesně takové chování jsme viděli v předchozí podkapitole: pokud je indikována čerstvost, httplib2 při vrácení dat z mezipaměti *negeneruje ani bajt síťové aktivity* (pokud ovšem explicitně nepředepíšeme obejití mezipaměti).

Ale jak to bude vypadat v případě, kdy se data *mohla* změnit, ale přitom se nezměnila? Pro tento účel HTTP definuje hlavičky Last-Modified a Etag. Těmto hlavičkám se říká *validátory*. Pokud už lokální mezipaměť není čerstvá, může klient s dalším dotazem zaslat validátory, aby si ověřil, zda se data skutečně změnila. Pokud se data nezměnila, server pošle zpět stavový kód 304 a *žádná data*. Takže tu sice stále dochází ke vzájemné komunikaci po síti, ale výsledkem je stahování menšího množství bajtů.

```
>>> import httplib2
>>> httplib2.debuglevel = 1
>>> h = httplib2.Http('.cache')
>>> response, content = h.request('http://diveintopython3.org/')
                                                                            [1]
connect: (diveintopython3.org, 80)
send: b'GET / HTTP/1.1
Host: diveintopython3.org
accept-encoding: deflate, gzip
user-agent: Python-httplib2/$Rev: 259 $'
reply: 'HTTP/1.1 200 OK'
>>> print(dict(response.items()))
                                                                            [2]
{'-content-encoding': 'gzip',
 'accept-ranges': 'bytes',
 'connection': 'close',
 'content-length': '6657',
 'content-location': 'http://diveintopython3.org/',
 'content-type': 'text/html',
 'date': 'Tue, 02 Jun 2009 03:26:54 GMT',
 'etag': '"7f806d-1a01-9fb97900"',
 'last-modified': 'Tue, 02 Jun 2009 02:51:48 GMT',
 'server': 'Apache',
 'status': '200',
 'vary': 'Accept-Encoding, User-Agent'}
>>> len(content)
                                                                            [3]
6657
```

- Místo publikovaného obsahu (feed) budeme tentokrát stahovat domácí stránku webového místa (home page), která je v HTML. Protože tuto stránku požadujeme úplně poprvé, nemůže httplib2 s požadavkem nic moc udělat a odešle s ním minimum hlaviček.
- Odpověď obsahuje velké množství HTTP hlaviček... ale žádné informace pro mezipaměť. Ale obsahuje jak hlavičku ETag, tak hlavičku Last-Modified.
- V době vytváření příkladu měla stránka 6657 bajtů. Od té doby už se pravděpodobně změnila, ale tím se nebudeme zatěžovat.

```
# pokračování z předchozího příkladu
>>> response, content = h.request('http://diveintopython3.org/')
                                                                             [1]
connect: (diveintopython3.org, 80)
send: b'GET / HTTP/1.1
Host: diveintopython3.org
if-none-match: "7f806d-1a01-9fb97900"
                                                                             [2]
if-modified-since: Tue, 02 Jun 2009 02:51:48 GMT
                                                                             [3]
accept-encoding: deflate, gzip
user-agent: Python-httplib2/$Rev: 259 $'
reply: 'HTTP/1.1 304 Not Modified'
                                                                             [4]
>>> response.fromcache
                                                                             [5]
True
>>> response.status
                                                                             [6]
200
>>> response.dict['status']
                                                                             [7]
'304'
>>> len(content)
                                                                             [8]
6657
```

- O stejnou stránku jsme požádali znovu, prostřednictvím stejného objektu třídy Http (a se stejnou lokální mezipamětí).
- [2] httplib2 pošle serveru zpět validátor ETag jako obsah hlavičky If-None-Match.
- [3] httplib2 pošle zpět serveru také validátor Last-Modified jako hodnotu hlavičky If-Modified-Since.
- [4] Server se podívá na zaslané validátory, podívá se na požadovanou stránku a zjistí, že se stránka od posledního požadavku nezměnila. Proto pošle zpět stavový kód 304 a *žádná data*.
- [4] A zpět ke klientovi. httplib2 obdrží stavový kód 304 a načte obsah stránky ze své mezipaměti.
- Tohle může být trošku matoucí. Ve skutečnosti tu máme dva stavové kódy 304 (který vrátil server teď a který způsobil, že httplib2 použije svou mezipaměť) a 200 (který vrátil server minule a který je spolu s daty uložen v mezipaměti pro httplib2). response. status vrací stavový kód odpovědi z mezipaměti.
- Pokud chceme zjistit surový stavový kód vrácený serverem, můžeme jej zjistit nahlédnutím do response.dict, což je slovník aktuálních hlaviček vrácených serverem.
- Ať je to jakkoliv, data opět získáte v proměnné content. Obecně vzato, nepotřebujeme vědět, proč byl požadavek obsloužen z mezipaměti. (Dokonce nás nemusí vůbec zajímat, že byl obsloužen z mezipaměti. To je v pořádku. Knihovna httplib2 je dost chytrá na to, abychom si mohli hrát na hlupáky.) V tomto okamžiku už metoda request() vrátila řízení volajícímu kódu. httplib2 už aktualizovala svou mezipaměť a vrátila nám data.

# 14.5.4. Jak http2lib pracuje s kompresí

"We have both kinds of music, country AND western." (Máme oba druhy hudby, country i western.) HTTP podporuje několik typů komprese. Dva nejpoužívanější typy jsou gzip a deflate. httplib2 podporuje oba.

```
>>> response, content = h.request('http://diveintopython3.org/')
connect: (diveintopython3.org, 80)
send: b'GET / HTTP/1.1
Host: diveintopython3.org
accept-encoding: deflate, gzip
                                                                   [1]
user-agent: Python-httplib2/$Rev: 259 $'
reply: 'HTTP/1.1 200 OK'
>>> print(dict(response.items()))
{'-content-encoding': 'gzip',
                                                                   [2]
 'accept-ranges': 'bytes',
 'connection': 'close',
 'content-length': '6657',
 'content-location': 'http://diveintopython3.org/',
 'content-type': 'text/html',
 'date': 'Tue, 02 Jun 2009 03:26:54 GMT',
 'etag': '"7f806d-1a01-9fb97900"',
 'last-modified': 'Tue, 02 Jun 2009 02:51:48 GMT',
 'server': 'Apache',
 'status': '304',
 'vary': 'Accept-Encoding, User-Agent'}
```

- Pokaždé když httplib2 odešle požadavek, vloží do něj hlavičku Accept-Encoding, kterou serveru oznámí, že zvládá jak kompresi deflate, tak gzip.
- V tomto případě server odpověděl daty komprimovanými algoritmem gzip. V tomto okamžiku metoda request() vrací řízení, httplib2 dekomprimovala (rozbalila) tělo odpovědi a umístila je do proměnné content. Pokud jste zvědaví, jestli odpověď přišla komprimovaná, můžete zkontrolovat response['-content-encoding']. Ale jinak si s tím nemusíte dělat starosti.

# 14.5.5. Jak httplib2 řeší přesměrování

HTTP definuje dva druhy přesměrování: dočasné a trvalé. U dočasných přesměrování se nedělá nic zvláštního až na to, že se mají následovat (follow), což httplib2 provede automaticky.

```
>>> import httplib2
>>> httplib2.debuglevel = 1
>>> h = httplib2.Http('.cache')
>>> response, content = h.request('http://diveintopython3.org/examples/feed-302.xml')
connect: (diveintopython3.org, 80)
send: b'GET /examples/feed-302.xml HTTP/1.1
                                                                                         [2]
Host: diveintopython3.org
accept-encoding: deflate, gzip
user-agent: Python-httplib2/$Rev: 259 $'
reply: 'HTTP/1.1 302 Found'
                                                                                         [3]
send: b'GET /examples/feed.xml HTTP/1.1
                                                                                         [4]
Host: diveintopython3.org
accept-encoding: deflate, gzip
user-agent: Python-httplib2/$Rev: 259 $'
reply: 'HTTP/1.1 200 OK'
```

- Na tomto URL není žádný publikovaný obsah. Nastavil jsem svůj server, aby signalizoval dočasné přesměrování na správnou adresu.
- [2] Tady je náš požadavek.
- A tady je odpověď: 302 Found. I když se to zde nezobrazuje, odpověď obsahuje také hlavičku Location, která ukazuje na skutečné URL.
- [4] httplib2 se ihned otočí a "následuje" přesměrování vydáním dalšího požadavku na URL, které je uvedeno v hlavičce Location: http://diveintopython3.org/examples/feed.xml

"Následování" přesměrování není nic jiného, než co ukazuje tento příklad. httplib2 pošle požadavek pro URL, které jsme požadovali. Server odvětí odpovědí, která říká: "Ne ne. Místo toho se podívejte támhle." httplib2 odešle další požadavek pro nové URL.

```
# pokračování z předchozího příkladu
>>> response
                                                                            [1]
{'status': '200',
 'content-length': '3070',
 'content-location': 'http://diveintopython3.org/examples/feed.xml',
                                                                            [2]
 'accept-ranges': 'bytes',
 'expires': 'Thu, 04 Jun 2009 02:21:41 GMT',
 'vary': 'Accept-Encoding',
 'server': 'Apache',
 'last-modified': 'Wed, 03 Jun 2009 02:20:15 GMT',
 'connection': 'close',
 '-content-encoding': 'gzip',
                                                                            [3]
 'etag': '"bfe-4cbbf5c0"',
 'cache-control': 'max-age=86400',
                                                                            [4]
 'date': 'Wed, 03 Jun 2009 02:21:41 GMT',
 'content-type': 'application/xml'}
```

- Odpověď (response), kterou jste obdrželi z jediného volání metody request(), je odpovědí z konečného URL.
- [2] httplib2 přidá konečné URL do slovníku response jako content-location. Nejde o hlavičku, která by přišla ze serveru. Je to záležitost specifická pro httplib2.
- [3] Jen abych nezapomněl, tento feed je komprimovaný.
- [4] A uchovatelný v mezipaměti (cacheable). (To je důležité jak uvidíme za minutku.)

Slovník response, který se nám vrátí, poskytuje informace o *konečném* URL. A co když chceme informace o přechodných URL, tedy o těch, která byla přesměrována na konečné URL? httplib2 nám umožní i to.

```
# pokračování z předchozího příkladu
>>> response.previous
                                                                            [1]
{'status': '302',
 'content-length': '228',
 'content-location': 'http://diveintopython3.org/examples/feed-302.xml',
 'expires': 'Thu, 04 Jun 2009 02:21:41 GMT',
 'server': 'Apache',
 'connection': 'close',
 'location': 'http://diveintopython3.org/examples/feed.xml',
 'cache-control': 'max-age=86400',
 'date': 'Wed, 03 Jun 2009 02:21:41 GMT',
 'content-type': 'text/html; charset=iso-8859-1'}
>>> type(response)
                                                                            [2]
<class 'httplib2.Response'>
>>> type(response.previous)
<class 'httplib2.Response'>
>>> response.previous.previous
                                                                            [3]
>>>
```

- Atribut response. previous uchovává referenci na předchozí objekt odpovědi, který httplib2 následovala, aby získala současný objekt odpovědi.
- [2] Jak response, tak response.previous jsou objekty třídy httplib2.Response.
- To znamená, že můžeme řetězec přesměrování sledovat zpětně ještě dál kontrolou response.previous.previous. (Scénář: jedno URL je přesměrováno na druhé URL, které je přesměrováno na třetí URL. To se opravdu může stát!) V tomto případě už jsme dosáhli začátku řetězce přesměrování, takže atribut má hodnotu None.

Co se stane, když si vyžádáme stejné URL znovu?

```
# pokračování z předchozího příkladu
>>> response2, content2 = h.request('http://diveintopython3.org/examples/feed-302.xml') [1]
connect: (diveintopython3.org, 80)
send: b'GET /examples/feed-302.xml HTTP/1.1 [2]
Host: diveintopython3.org
accept-encoding: deflate, gzip
user-agent: Python-httplib2/$Rev: 259 $'
reply: 'HTTP/1.1 302 Found' [3]
>>> content2 == content [4]
```

- [1] Stejné URL, stejný objekt třídy httplib2. Http (a tím pádem stejná mezipaměť).
- [2] Odpověď 302 nebyla v mezipaměti, takže httplib2 pošle pro stejné URL další požadavek.
- A ještě jednou, server odpovídá kódem 302. Ale všimněte si, co se nestalo: chybí druhý dotaz na konečné URL, http://diveintopython3.org/examples/feed.xml. Tato odpověď byla v mezipaměti (vzpomeňte si na hlavičku Cache-Control, kterou jsme viděli v předchozím příkladu). Jakmile httplib2 obdržela kód 302 Found, zkontrolovala si před vydáním dalšího požadavku obsah mezipaměti. Mezipaměť obsahovala čerstvou kopii http://diveintopython3.org/examples/feed.xml, takže nebylo nutné žádat o data znovu.
- V tomto okamžiku dochází k návratu z metody request(). Přečetla data publikovaného obsahu (feed) z mezipaměti a vrátila je. Jde samozřejmě o stejná data, která jsme obdrželi minule.

Jinými slovy, při dočasném přesměrování nemusíme dělat nic zvláštního. httplib2 je bude následovat automaticky. Skutečnost, že je jedno URL přesměrováno na jiné, nemá na httplib2 žádné dopady z hlediska podpory komprese, použití mezipaměti, ETagů nebo jakýchkoliv jiných rysů HTTP.

Trvalá přesměrování jsou ve své jednoduchosti podobná.

```
# pokračování z předchozího příkladu
>>> response, content = h.request('http://diveintopython3.org/examples/feed-301.xml') [1]
connect: (diveintopython3.org, 80)
send: b'GET /examples/feed-301.xml HTTP/1.1
Host: diveintopython3.org
accept-encoding: deflate, gzip
user-agent: Python-httplib2/$Rev: 259 $'
reply: 'HTTP/1.1 301 Moved Permanently' [2]
>>> response.fromcache [3]
```

Ještě jednou. Toto URL ve skutečnosti neexistuje. Nastavil jsem svůj server, aby produkoval trvalé přesměrování na http://diveintopython3.org/examples/feed.xml.

- A tady to máme: stavový kód 301. Ale znovu si všimněte, co se *nestalo*: neobjevil se žádný požadavek na přesměrované URL. Proč ne? Protože už se nachází v lokální mezipaměti.
- [3] httplib2 "následovala" přesměrování přímo do své mezipaměti.

Ale počkejte! Ono je toho ještě víc!

```
# pokračování z předchozího příkladu
>>> response2, content2 = h.request('http://diveintopython3.org/examples/feed-301.xml') [1]
>>> response2.fromcache [2]
True
>>> content2 == content [3]
True
```

- Tady je ten rozdíl mezi dočasným a trvalým přesměrováním: jakmile jednou httplib2 následuje trvalé přesměrování, všechny další požadavky se stejným URL budou transparentně přepsány na cílové URL *aniž se kvůli originálnímu* URL *komunikuje po síti*. Připomeňme si, že ladicí režim je pořád zapnutý. Přesto nevidíme vůbec žádný výstup síťové aktivity.
- [2] Ano, tato odpověď byla vytažena z lokální mezipaměti.
- [3] Ano, dostali jsme celý publikovaný obsah (z mezipaměti).

HTTP. Funguje.

### 14.6. Za hranicemi HTTP GET

Webové služby nad HTTP se neomezují jen na požadavky typu GET. Co kdybychom chtěli vytvořit něco nového? Kdykoliv přidáte komentář do diskusního fóra, aktualizujete weblog, upravujete svůj stav na mikroblogové službě, jakou je **Twitter** nebo **Identi.ca**, používáte pravděpodobně HTTP POST.

Jak Twitter, tak Identi.ca nabízejí pro zveřejňování a aktualizaci vašeho stavu, popsaného 140 nebo méně znaky, jednoduché rozhraní založené na HTTP. Podívejme se na dokumentaci aplikačního rozhraní pro aktualizaci vašeho stavu v systému Identi.ca.

Jak to funguje? Když chceme na Identi.ca zveřejnit novou zprávu, musíme zaslat požadavek typu HTTP POST na http://identi.ca/api/statuses/update.format. (Část format nepatří k URL. Nahrazuje se datovým formátem, v jakém nám má server vrátit odpověď na náš požadavek. Takže pokud požadujeme odpověď v XML, musíme zaslat požadavek na https://identi.ca/api/statuses/update.xml.) Požadavek musí obsahovat parametr nazvaný status, který obsahuje text pro aktualizaci našeho stavu. A požadavek musí být autentizován.

# Identi.ca REST API Metoda: statuses/update

Aktualizuje stav autentizovaného uživatele. Vyžaduje parametr status, popsaný níže. Požadavek musí být typu POST.

```
URL
```

```
https://identi.ca/api/statuses/update.format
Formáty
xml, json, rss, atom
HTTP metod(y)
POST
Vyžaduje autentizaci
ano
```

Parametry

status. Povinný. Text aktualizace vašeho stavu. Kódované URL podle potřeby.

Autentizován? Jistě. Když chceme na Identi.ca aktualizovat svůj stav, musíme prokázat svou totožnost. Identi.ca není jako wiki. Svůj vlastní stav můžeme aktualizovat jen my. Pro účel bezpečné a snadno použitelné autentizace používá Identi.ca HTTP **Basic Authentication** (základní autentizaci; známou také jako **RFC 2617**) přes SSL. httplib2 podporuje jak SSL, tak HTTP Basic Authentication, takže tahle část bude snadná.

Požadavek POST se od požadavku GET liší, protože nese *náklad*. Nákladem jsou data, která chceme poslat na server. Částí dat, kterou toto aplikační rozhraní metody *vyžaduje*, je status (stav) a měl by mít podobu *kódovaného* URL. Je to velmi jednoduchý serializační formát. Vstupem je množina dvojic klíč-hodnota (tj. slovník) a výsledkem je řetězec.

```
>>> from urllib.parse import urlencode [1]
>>> data = {'status': 'Test update from Python 3'} [2]
>>> urlencode(data) [3]
'status=Test+update+from+Python+3'
```

- V Pythonu pro zakódování slovníku do podoby URL najdeme pomocnou funkci: urllib.parse.urlencode().
- Aplikační rozhraní systému Identi.ca očekává zhruba takovýto slovník. Obsahuje jeden klíč, status, jehož hodnotou je text jedné aktualizace stavu.
- A takto vypadá řetězec kódovaného URL. To je *náklad*, který bude požadavkem HTTP POST odeslán "po drátě" na server s aplikačním rozhraním Identi.ca.

```
>>> from urllib.parse import urlencode
>>> import httplib2
>>> httplib2.debuglevel = 1
>>> h = httplib2.Http('.cache')
>>> data = {'status': 'Test update from Python 3'}
>>> h.add_credentials('diveintomark', 'MY_SECRET_PASSWORD', 'identi.ca') [1]
>>> resp, content = h.request('https://identi.ca/api/statuses/update.xml',
... 'POST', [2]
... urlencode(data), [3]
... headers={'Content-Type': 'application/x-www-form-urlencoded'}) [4]
```

- Tímto způsobem httplib2 pracuje s autentizací. Jméno a heslo uložíme metodou add\_credentials(). Když se httplib2 pokusí o vydání požadavku, server odpoví stavovým kódem 401 Unauthorized (neautorizováno) a připojí seznam autentizačních metod, které podporuje (v hlavičce WWW-Authenticate). httplib2 automaticky vytvoří hlavičku Authorization a pošle požadavek s URL znovu.
- [2] Druhý parametr uvádí typ HTTP požadavku. V tomto případě je to POST.
- Třetím parametrem je *náklad*, který se serveru posílá. Posíláme slovník se stavovou zprávou zakódovaný do podoby URL.
- Nakonec musíme serveru říct, že náklad má podobu dat zakódovaných do podoby URL.
- > Třetím parametrem metody add\_credentials() je doména, ve které osobní údaje platí. Měli byste ji vždy uvádět! Pokud doménu vynecháte a později znovu použijete objekt třídy httplib2.Http pro jiné autentizované místo, mohla by httplib2 způsobit únik jména a hesla z jednoho místa na druhé místo (site).

# A o čem zpívají dráty:

```
# pokračování z předchozího příkladu
send: b'POST /api/statuses/update.xml HTTP/1.1
Host: identi.ca
Accept-Encoding: identity
Content-Length: 32
content-type: application/x-www-form-urlencoded
user-agent: Python-httplib2/$Rev: 259 $
status=Test+update+from+Python+3'
reply: 'HTTP/1.1 401 Unauthorized'
                                                                  [1]
send: b'POST /api/statuses/update.xml HTTP/1.1
                                                                   [2]
Host: identi.ca
Accept-Encoding: identity
Content-Length: 32
content-type: application/x-www-form-urlencoded
authorization: Basic SECRET_HASH_CONSTRUCTED_BY_HTTPLIB2
                                                                   [3]
user-agent: Python-httplib2/$Rev: 259 $
```

```
status=Test+update+from+Python+3'
reply: 'HTTP/1.1 200 OK' [4]
```

- Po prvním požadavku odpoví server stavovým kódem 401 Unauthorized. httplib2 nikdy neposílá autentizační hlavičky, pokud si o ně server explicitně neřekne. Server si o ně říká tímto způsobem.
- [2] httplib2 okamžitě zareaguje opakovaným odesláním požadavku se stejným URL.
- Tentokrát obsahuje jméno a heslo, která jsme přidali metodou add\_credentials().
- [4] Funguje to!

A co vlastně server posílá po úspěšném požadavku zpět? To zcela závisí na aplikačním rozhraní příslušné webové služby. V některých protokolech (jako například Atom Publishing Protocol) posílá server zpět stavový kód 201 Created spolu s umístěním nově vytvořeného zdroje (resource) v hlavičce Location. Identi.ca posílá zpět 200 OK a XML dokument, který obsahuje informace o nově vytvořeném zdroji.

```
# pokračování z předchozího příkladu
>>> print(content.decode('utf-8'))
                                                          [1]
<?xml version="1.0" encoding="UTF-8"?>
<status>
<text>Test update from Python 3</text>
                                                          [2]
<truncated>false</truncated>
 <created_at>Wed Jun 10 03:53:46 +0000 2009</created_at>
<in_reply_to_status_id></in_reply_to_status_id>
<source>api</source>
<id>5131472</id>
                                                          [3]
<in_reply_to_user_id></in_reply_to_user_id>
<in_reply_to_screen_name></in_reply_to_screen_name>
<favorited>false</favorited>
 <user>
 <id>3212</id>
 <name>Mark Pilgrim</name>
 <screen_name>diveintomark</screen_name>
 <location>27502, US</location>
 <description>tech writer, husband, father</description>
 <prefile_image_url>http://avatar.identi.ca/3212-48-20081216000626.png/profile_image_url>
 <url>http://diveintomark.org/</url>
 cted>false
 <followers_count>329</followers_count>
 cprofile_background_color>
 file_text_color>file_text_color>
 file_link_color>file_link_color>
 file_sidebar_fill_color>
 cprofile_sidebar_border_color>
 <friends_count>2</friends_count>
```

- Připomeňme si, že data vracená httplib2 jsou vždy bajty a ne řetězce. Abychom je mohli převést na řetězec, musíme je dekódovat s použitím příslušného znakového kódování. Aplikační rozhraní systému Identi.ca vždy vrací výsledky v UTF-8. Takže tato část je snadná.
- [2] Zde je text stavové zprávy, kterou jsme právě zveřejnili.
- Toto je unikátní identifikátor nové stavové zprávy. Identi.ca jej používá pro konstrukci URL, které se dá použít pro zobrazení zprávy na webu.

#### A tady ji máme:



#### 14.7. Za hranicemi HTTP POST

HTTP se neomezuje jen na GET a POST. Nepochybně jde o nejběžnější typy dotazů, obzvlášť ze strany webových prohlížečů. Ale rozhraní webových služeb může jít za hranice GET a POST — a knihovna httplib2 je na to připravená.

```
# pokračování z předchozího příkladu
>>> from xml.etree import ElementTree as etree
>>> tree = etree.fromstring(content)
                                                                                       [1]
>>> status_id = tree.findtext('id')
                                                                                       [2]
>>> status id
'5131472'
>>> url = 'https://identi.ca/api/statuses/destroy/{0}.xml'.format(status_id)
                                                                                       [3]
>>> resp, deleted_content = h.request(url, 'DELETE')
                                                                                       [4]
      Sever vrátil XML, že ano? A my už víme, jak XML zpracovat.
[1]
      Metoda findtext() najde první objekt odpovídající zadanému výrazu a extrahuje jeho textový
[2]
       obsah. V tomto případě hledáme element <id>.
      Z textového obsahu elementu <id> můžeme zkonstruovat URL pro vymazání stavové zprávy,
[3]
      kterou jsme zrovna zveřejnili.
      Zprávu vymažeme tím, že pro zmíněné URL vytvoříme požadavek HTTP DELETE.
[4]
```

#### Po drátech běhá následující:

```
send: b'DELETE /api/statuses/destroy/5131472.xml HTTP/1.1
                                                                              [1]
Host: identi.ca
Accept-Encoding: identity
user-agent: Python-httplib2/$Rev: 259 $
reply: 'HTTP/1.1 401 Unauthorized'
                                                                              [2]
send: b'DELETE /api/statuses/destroy/5131472.xml HTTP/1.1
                                                                              [3]
Host: identi.ca
Accept-Encoding: identity
authorization: Basic SECRET_HASH_CONSTRUCTED_BY_HTTPLIB2
                                                                              [4]
user-agent: Python-httplib2/$Rev: 259 $
reply: 'HTTP/1.1 200 OK'
                                                                              [5]
>>> resp.status
200
[1]
       "Odstraň tuto stavovou zprávu."
       "Je mi líto, Dave [dejve]. Obávám se, že to nemohu udělat."
[2]
      "Neautorizováno? Hmmm. Odstraň tu stavovou zprávu, prosím...
[3]
      ...a tady je mé jméno a heslo."
[4]
       "Považuj to za hotovou věc!"
[5]
```

## Puf a je to pryč.



#### 14.8. Přečtěte si

#### httplib2:

- Stránka projektu httplib2 (anglicky) (http://code.google.com/p/httplib2/)
- Další příklady kódu využívajícího httplib2 (anglicky)
   (http://code.google.com/p/httplib2/wiki/ExamplesPython3)
- Doing HTTP Caching Right: Introducing httplib2 (anglický článek)
   (www.xml.com/pub/a/2006/02/01/doing-http-caching-right-introducing-httplib2.html)
- httplib2: HTTP Persistence and Authentication (anglický článek)
   (www.xml.com/pub/a/2006/03/29/httplib2-http-persistence-and-authentication.html)

#### Práce HTTP s mezipamětí:

- HTTP Tutorial napsal Mark Nottingham (www.mnot.net/cache\_docs/)
- How to control caching with HTTP headers (anglický článek o Google Doctype)
   (http://code.google.com/p/doctype/wiki/ArticleHttpCaching)

# RFC:

- RFC 2616: HTTP
  - (www.ietf.org/rfc/rfc2616.txt)
- RFC 2617: HTTP Basic Authentication (www.ietf.org/rfc/rfc2617.txt)
- RFC 1951: DEFLATE compression (www.ietf.org/rfc/rfc1951.txt)
- RFC 1952: GZIP compression (www.ietf.org/rfc/rfc1952.txt)

"Words, words. They're all we have to go on." (Slova, slova. Jsou vším, čeho se musíme držet.)

— Rosencrantz a Guildenstern jsou mrtvi

# 15. Případová studie:Přepis chardet pro Python 3

15.

#### Případová studie: Přepis chardet pro Python 3 - 329 Ponořme se — 331 15.1. 15.2. Co se rozumí autodetekcí znakového kódování? — 331 15.2.1. Není to náhodou neproveditelné? — 331 15.2.2. Existuje takový algoritmus? — 332 15.3. Úvod do modulu chardet — 332 15.3.1. UTF-N s BOM — 332 Kódování escape sekvencemi — 333 15.3.2. 15.3.3. Vícebajtová kódování — 333 15.3.4. Jednobajtová kódování — 334 windows-1252 — 334 15.3.5. 15.4. Spouštíme 2to3 — 335 15.5. Krátká odbočka k vícesouborovým modulům — 338 15.6. Opravme, co 2to3 neumí — 340 False je syntaktická chyba — 340 15.6.1. 15.6.2. Nenalezen modul constants — 341 Jméno 'file' není definováno — 342 15.6.3. 15.6.4. Řetězcový vzorek nelze použít pro bajtové objekty — 343 Objekt typu 'bytes' nelze implicitně 15.6.5. převést na str - 345 15.6.6. Nepodporované typy operandů pro +: 'int' a 'bytes' - 348 15.6.7. Funkce ord() očekávala řetězec o délce 1, ale byl nalezen int — 350 Neuspořádatelné datové typy: int() >= str() — 352 15.6.8. Globální jméno 'reduce' není definováno — 355 15.6.9.

Shrnutí — 357

15.7.

- 15.1. Ponořme se
- 15.2. Co se rozumí autodetekcí znakového kódování?

#### 15.1. Ponořme se

Otázka: Co je příčnou č. 1 vedoucí ke zmatenému textu na webu, ve vaší poštovní schránce a ve všech dokumentech, které kdy byly napsány, napříč všemi počítačovými systémy? Je to kódování znaků. V kapitole Řetězce jsme se bavili o historii kódování znaků a o vytvoření Unicode — "jedno kódování vládne všem". Moc bych si přál, kdybych se na webových stránkách nikdy víc nesetkával se zmatenými znaky, protože by všechny systémy pro vytváření textu ukládaly přesnou informaci o kódování a protože by byly všechny přenosové protokoly připravené na používání Unicode a každý systém pro zpracování textu by při konverzi mezi kódováními zachovával perfektní věrnost.

Rád bych taky poníka.

Unicode poníka.

Kdyby to tak byl Uniponík.

Budu si muset osedlat autodetekci znakového kódování.

#### 15.2. Co se rozumí autodetekcí znakového kódování?

Rozumí se tím to, že vezmeme posloupnost bajtů v neznámém znakovém kódování a pokoušíme se kódování zjistit, abychom si text mohli přečíst. Podobá se to lámání kódu v situaci, kdy nemáme dešifrovací klíč.

#### 15.2.1. Není to náhodou neproveditelné?

Z obecného pohledu to opravdu je nemožné. Ale některá kódování jsou optimalizována pro určité jazyky a jazyky nejsou náhodné. Některé posloupnosti znaků se objevují neustále, zatímco jiné posloupnosti nedávají žádný smysl. Když osoba plynně ovládající angličtinu otevře noviny a najde "txzqJv 2!dasd0a QqdKjvz", okamžitě pozná, že nejde o angličtinu (i když se text skládá pouze z písmen, která se v angličtině používají). Na základě studia velkého množství "typického" textu může počítačový algoritmus simulovat zmíněný druh plynné znalosti a může provést kvalifikovaný odhad týkající se jazyka textu.

Jinými slovy, detekce kódování je ve skutečnosti detekcí jazyka, která se kombinuje se znalostí tendence jazyka používat určité znakové kódování.

# 15.2.2. Existuje takový algoritmus?

Jak se ukazuje, tak ano. Všechny nejpoužívanější prohlížeče mají autodetekci kódování zabudovanou, protože web je plný stránek, které neobsahují vůbec žádnou informaci o kódování. **Mozilla Firefox** obsahuje knihovnu pro autodetekci kódování, která je open source. Knihovnu jsem přenesl do **Pythonu 2** a modul jsem nazval chardet. V této kapitole vás krok za krokem provedu procesem přepisování modulu chardet z Pythonu 2 pro Python 3.

# 15.3. Úvod do modulu chardet

Detekce kódování je ve skutečnosti v závěsu za detekcí jazyka. Než se do přepisu kódu pustíme, bylo by dobré, kdybyste rozuměli, jak funguje! Toto je stručná příručka pro usnadnění orientace ve vlastním kódu. Knihovna chardet je příliš velká na to, abych její kód vložil do textu této knihy. Ale můžete si ji stáhnout z chardet. feedparser.org.

Hlavním vstupním bodem detekčního algoritmu je universaldetector. py. Obsahuje jednu třídu, UniversalDetector. (Možná jste mysleli, že hlavním vstupním bodem je funkce detect z chardet/\_\_init\_\_.py. To je ale jen funkce pro zvýšení pohodlí, která vytvoří objekt třídy UniversalDetector, zavolá jej a vrátí jeho výsledek.)

UniversalDetector zvládá pět kategorií kódování:

- 1. UTF-N s Byte Order Mark (BOM; znak pro určení pořadí bajtů). Zahrnuje UTF-8, obě varianty UTF-16 (Big-Endian a Little-Endian) a všechny 4 varianty pořadí bajtů UTF-32.
- Kódování s únikovými znaky (escape encodings), která jsou zcela kompatibilní se 7bitovým ASCII. Znaky spadající mimo ASCII začínají únikovými sekvencemi (escape sequence). Příklady: ISO-2022-JP (japonština) a HZ-GB-2312 (čínština).
- Vícebajtová kódování, ve kterých je každý znak reprezentován proměnným počtem bajtů.
   Příklady: BIG5 (čínština), SHIFT\_JIS (japonština), EUC-KR (korejština) a UTF-8 bez BOM.
- 4. Jednobajtová kódování, ve kterých je každý znak reprezentován jedním bajtem. Příklady: KOI8-R (ruština), WINDOWS-1255 (hebrejština) a TIS-620 (thajština).
- 5. WINDOWS-1252, která používají především (v Microsoft Windows) střední manažeři, kteří nerozpoznají znakové kódování od díry v zemi.

#### 15.3.1. UTF-N s BOM

Pokud text začíná značkou BOM, můžeme rozumně předpokládat, že je zakódován v UTF-8, UTF-16 nebo UTF-32. (Značka bom nám přesně řekne, o které kódování jde. Byla pro tento účel navržena.) To se děje přímo v UniversalDetectoru, který vrátí výsledek okamžitě, bez dalšího zpracovávání textu.

## 15.3.2. Kódování escape sekvencemi

Pokud text obsahuje rozpoznatelné posloupnosti s únikovými znaky (escape sequence), může to být příznakem použití kódování, kterému se v angličtině říká escaped encoding. UniversalDetector vytvoří EscCharSetProber (je definován v escprober.py) a přivede do něj text.

EscCharSetProber vytvoří sadu konečných automatů, které vycházejí z modelů pro HZ-GB-2312, ISO-2022-CN, ISO-2022-JP a ISO-2022-KR (jsou definovány v escsm.py). EscCharSetProber přivádí text do každého z těchto konečných automatů — bajt po bajtu. Pokud některý z konečných automatů skončí s jednoznačnou identifikací kódování, vrátí EscCharSetProber okamžitě pozitivní výsledek objektu třídy UniversalDetector, který jej vrátí volajícímu. Pokud kterýkoliv z konečných automatů narazí na nepřípustnou posloupnost, je vyřazen a další zpracování pokračuje jen s ostatními konečnými automaty.

#### 15.3.3. Vícebajtová kódování

Za předpokladu, že není použita značka BOM, UniversalDetector zkontroluje, zda text obsahuje nějaké znaky s nastaveným osmým bitem. Pokud tomu tak je, vytvoří sérii "detekčních zařízení" (prober) pro rozpoznání vícebajtových kódování, jednobajtových kódování a nakonec, jako poslední možnost, pro WINDOWS-1252.

Detekční objekt pro vícebajtová kódování, MBCSGroupProber (třída je definována v mbcsgroupprober.py), je ve skutečnosti jen obálkou. Ovládá ostatní detekční objekty, po jednom pro každé vícebajtové kódování: BIG5, GB2312, EUC-TW, EUC-KR, EUC-JP, SHIFT\_JIS a UTF-8. MBCSGroupProber směřuje text do každého z těchto specializovaných detekčních objektů a kontroluje výsledky. Pokud nějaký detekční objekt hlásí, že nalezl nepřípustnou posloupnost bajtů, je vyřazen z dalšího zpracování (takže například libovolné následné volání metody UniversalDetector.feed() vyřazený detekční objekt přeskočí). Pokud detekční objekt hlásí, že si je poměrně jistý rozpoznáním kódování, oznámí MBCSGroupProber tento pozitivní výsledek objektu UniversalDetector, který oznámí výsledek volajícímu.

Většina z detekčních objektů pro vícebajtová kódování je odvozena z MultiByteCharSetProber (definována v mbcharsetprober.py) a jednoduše se navěsí na příslušný konečný automat a analyzátor rozložení. Zbytek práce nechá na MultiByteCharSetProber. MultiByteCharSetProber prohání text přes konečné automaty specializované na jednotlivá kódování — bajt po bajtu. Vyhledává posloupnosti bajtů, které by indikovaly průkazné pozitivní nebo negativní výsledky. MultiByteCharSetProber současně posílá text do analyzátoru rozložení, který je specifický pro každé kódování.

Analyzátory rozložení (jsou definovány v chardistribution.py) používají jazykově specifické modely nejčastěji se vyskytujících znaků. Jakmile MultiByteCharSetProber předá analyzátorům rozložení dostatečný objem textu, vypočítá ohodnocení spolehlivosti, které je založeno na počtu často používaných znaků, na celkovém počtu znaků a na jazykově závislém rozložení. Pokud je spolehlivost dostatečně velká, vrátí MultiByteCharSetProber výsledek do MBCSGroupProber, který jej vrátí do UniversalDetectoru, který jej vrátí volajícímu.

Případ japonštiny je obtížnější. Analýza rozložení podle jednotlivých znaků nevede vždy k rozlišení EUC-JP a SHIFT\_JIS, takže SJISProber (definován v sjisprober.py) používá také dvojznakovou analýzu rozložení. SJISContextAnalysis a EUCJPContextAnalysis (definice se v obou případech nacházejí v jpcntx.py a obě třídy dědí ze společné třídy JapaneseContextAnalysis) v textu kontrolují frekvenci výskytů slabičných znaků hiragana. Jakmile bylo zpracováno dostatečné množství textu, vracejí úroveň spolehlivosti do SJISProber, který zkontroluje oba analyzátory a vrátí výsledek s vyšší úrovní spolehlivosti do MBCSGroupProber.

#### 15.3.4. Jednobajtová kódování

Detekční objekt pro jednobajtové kódování, SBCSGroupProber (třída je definována v sbcsgroupprober.py) je rovněž obálkou, která ovládá skupinu jiných detekčních objektů — jeden pro každou kombinaci

# Vážně, kde je můj Unicode poník?

jednobajtového kódování a jazyka: WINDOWS-1251, KOI8-R, ISO-8859-5, MacCyrillic, IBM855 a IBM866 (ruština); ISO-8859-7 a WINDOWS-1253 (řečtina); ISO-8859-5 a WINDOWS-1251 (bulharština); ISO-8859-2 a WINDOWS-1250 (čeština, maďarština, slovenština a další); TIS-620 (thajština); WINDOWS-1255 a ISO-8859-8 (hebrejština).

SBCSGroupProber předává text do každého z těchto detekčních objektů a kontroluje výsledky. Všechny tyto detekční objekty jsou implementovány v jedné třídě, SingleByteCharSetProber (definována v sbcharsetprober.py), která prostřednictvím argumentu přebírá jazykový model. Jazykový model definuje, jak často se v typickém textu vyskytují dvojznakové posloupnosti. SingleByteCharSetProber zpracovává text a zjišťuje nejčastěji se vyskytující dvojznakové posloupnosti. Jakmile byl zpracován dostatečný objem textu, vypočítá úroveň spolehlivosti, která je založena na počtu často se vyskytujících posloupností, na celkovém počtu znaků a na jazykově závislém rozložení.

Hebrejština se řeší jako zvláštní případ. Pokud se text na základě analýzy rozložení dvojznakových posloupností jeví jako hebrejština, snaží se HebrewProber (třída definována v hebrewprober .py) rozlišit mezi vizuální hebrejštinou (kdy je text uložen ve skutečnosti "pozpátku" řádek po řádku a poté je zobrazen "normálně", takže může být čten zprava doleva) a logickou hebrejštinou (kdy je zdrojový text uložen v pořadí čtení a klientský program ho vykresluje zprava doleva). Protože se některé znaky kódují jinak podle toho, zda se nacházejí uprostřed slova nebo na jeho konci, můžeme rozumně odhadnout směr zdrojového textu a vrátit příslušné kódování (windows-1255 pro logickou hebrejštinu nebo ISO-8859-8 pro vizuální hebrejštinu).

#### 15.3.5. windows-1252

Pokud UniversalDetector v textu detekuje znaky s nastaveným osmým bitem a žádný z vícebajtových nebo jednobajtových detekčních objektů nevrátil spolehlivý výsledek, vytvoří Latin1Prober (třída je definována v latin1prober.py) a snaží se detekovat anglický text v kódování windows-1252.

Tato detekce je ze své podstaty nespolehlivá, protože anglické znaky se kódují stejným způsobem v mnoha různých kódováních. Jediný způsob, jak lze kódování windows-1252 rozpoznat, je založen na běžně používaných symbolech, jako jsou střídavé uvozovky (smart quotes; knižní, jiný znak na začátku a jiný na konci), kulaté apostrofy, symbol copyright a podobně. Latin1Prober automaticky redukuje ohodnocení své spolehlivosti, aby umožnil přesnějším detektorům vyhrát, pokud je to vůbec možné.

#### 15.4. Spouštíme 2to3

Jsme připraveni k přenesení modulu chardet z Pythonu 2 do Pythonu 3. Python 3 se dodává s pomocným skriptem nazvaným 2to3, který jako vstup přebírá zdrojový kód napsaný pro Python 2 a automaticky převádí vše, co dovede, do podoby pro Python 3. V některých případech je to snadné — funkce se přejmenovala nebo se přesunula do jiného modulu —, ale v ostatních případech to může být docela složité. Abyste získali představu, co vše *umí* převést, podívejte se na přílohu Přepis kódu do Python 3 s využitím 2to3. V této kapitole začneme spuštěním 2to3 pro balík chardet. Ale jak brzy uvidíte, po provedení kouzel automatickými nástroji nám zbude ještě spousta práce.

Hlavní balík chardet je rozdělen do několika různých souborů. Všechny se nacházejí ve stejném adresáři. Skript 2to3 převod více souborů najednou usnadňuje. Jako argument na příkazovém řádku stačí předat jméno adresáře a 2to3 převede každý ze souborů, které se v něm nacházejí.

```
C:\home\chardet> python c:\Python30\Tools\Scripts\2to3.py -w chardet\
RefactoringTool: Skipping implicit fixer: buffer
RefactoringTool: Skipping implicit fixer: idioms
RefactoringTool: Skipping implicit fixer: set_literal
RefactoringTool: Skipping implicit fixer: ws_comma
--- chardet\__init__.py (original)
+++ chardet\__init__.py (refactored)
@@ -18,7 +18,7 @@
 _{-}version_{-} = "1.0.1"
def detect(aBuf):
    import universaldetector
    from . import universaldetector
    u = universaldetector.UniversalDetector()
    u.reset()
    u.feed(aBuf)
--- chardet\big5prober.py (original)
+++ chardet\big5prober.py (refactored)
@ -25,10 +25,10 @
# 02110-1301 USA
```

```
-from mbcharsetprober import MultiByteCharSetProber
-from codingstatemachine import CodingStateMachine
-from chardistribution import Big5DistributionAnalysis
-from mbcssm import Big5SMModel
+from .mbcharsetprober import MultiByteCharSetProber
+from .codingStatemachine import CodingStateMachine
+from .chardistribution import Big5DistributionAnalysis
+from .mbcssm import Big5SMModel
class Big5Prober(MultiByteCharSetProber):
     def __init__(self):
--- chardet\chardistribution.py (original)
+++ chardet\chardistribution.py (refactored)
@ -25,12 +25,12 @@
 # 02110-1301 USA
 -import constants
-from euctwfreq import EUCTWCharToFreqOrder, EUCTW_TABLE_SIZE, EUCTW_TYPICAL_DISTRIBUTION_RATIO
-from euckrfreq import EUCKRCharToFreqOrder, EUCKR_TABLE_SIZE, EUCKR_TYPICAL_DISTRIBUTION_RATIO
-from gb2312freq import GB2312CharToFreqOrder, GB2312_TABLE_SIZE, GB2312_TYPICAL_DISTRIBUTION_RATIO
-from big5freq import Big5CharToFreqOrder, BIG5_TABLE_SIZE, BIG5_TYPICAL_DISTRIBUTION_RATIO
-from jisfreq import JISCharToFreqOrder, JIS_TABLE_SIZE, JIS_TYPICAL_DISTRIBUTION_RATIO
+from . import constants
+from .euctwfreq import EUCTWCharToFreqOrder, EUCTW_TABLE_SIZE, EUCTW_TYPICAL_DISTRIBUTION_RATIO
+from .euckrfreq import EUCKRCharToFreqOrder, EUCKR_TABLE_SIZE, EUCKR_TYPICAL_DISTRIBUTION_RATIO
+from .gb2312freq import GB2312CharToFreqOrder, GB2312_TABLE_SIZE, GB2312_TYPICAL_DISTRIBUTION_RATIO
+from .big5freq import Big5CharToFreqOrder, BIG5_TABLE_SIZE, BIG5_TYPICAL_DISTRIBUTION_RATIO
+from .jisfreq import JISCharToFreqOrder, JIS_TABLE_SIZE, JIS_TYPICAL_DISTRIBUTION_RATIO
 ENOUGH_DATA_THRESHOLD = 1024
 SURE_YES = 0.99
 (takhle to chvíli pokračuje)
RefactoringTool: Files that were modified:
RefactoringTool: chardet\__init__.py
RefactoringTool: chardet\big5prober.py
RefactoringTool: chardet\chardistribution.py
RefactoringTool: chardet\charsetgroupprober.py
RefactoringTool: chardet\codingstatemachine.py
```

```
RefactoringTool: chardet\constants.py
RefactoringTool: chardet\escprober.py
RefactoringTool: chardet\escsm.py
RefactoringTool: chardet\eucjpprober.py
RefactoringTool: chardet\euckrprober.py
RefactoringTool: chardet\euctwprober.py
RefactoringTool: chardet\gb2312prober.py
RefactoringTool: chardet\hebrewprober.py
RefactoringTool: chardet\jpcntx.py
RefactoringTool: chardet\langbulgarianmodel.py
RefactoringTool: chardet\langcyrillicmodel.py
RefactoringTool: chardet\langgreekmodel.py
RefactoringTool: chardet\langhebrewmodel.py
RefactoringTool: chardet\langhungarianmodel.py
RefactoringTool: chardet\langthaimodel.py
RefactoringTool: chardet\latin1prober.py
RefactoringTool: chardet\mbcharsetprober.py
RefactoringTool: chardet\mbcsgroupprober.py
RefactoringTool: chardet\mbcssm.py
RefactoringTool: chardet\sbcharsetprober.py
RefactoringTool: chardet\sbcsgroupprober.py
RefactoringTool: chardet\sjisprober.py
RefactoringTool: chardet\universaldetector.py
RefactoringTool: chardet\utf8prober.py
Teď spustíme skript 2to3 na testovací skript test.py.
C:\home\chardet> python c:\Python30\Tools\Scripts\2to3.py -w test.py
RefactoringTool: Skipping implicit fixer: buffer
RefactoringTool: Skipping implicit fixer: idioms
RefactoringTool: Skipping implicit fixer: set_literal
RefactoringTool: Skipping implicit fixer: ws_comma
--- test.py (original)
+++ test.py (refactored)
@@ -4,7 +4,7 @@
 count = 0
 u = UniversalDetector()
 for f in glob.glob(sys.argv[1]):
     print f.ljust(60),
    print(f.ljust(60), end=' ')
     u.reset()
     for line in file(f, 'rb'):
         u.feed(line)
```

```
@@ -12,8 +12,8 @@
    u.close()
    result = u.result
    if result['encoding']:
-        print result['encoding'], 'with confidence', result['confidence']
+        print(result['encoding'], 'with confidence', result['confidence'])
    else:
-        print '******** no result'
+        print('******** no result')
        count += 1
-print count, 'tests'
+print(count, 'tests')
RefactoringTool: Files that were modified:
RefactoringTool: test.py
```

No vida. Nebylo to tak hrozné. Konvertovalo se jen pár importů a příkazů print. Když už o tom mluvíme, *jaký byl* problém se všemi těmi příkazy import? Abychom na to mohli odpovědět, musíme rozumět tomu, jak se modul chardet dělí na více souborů.

#### 15.5. Krátká odbočka k vícesouborovým modulům

chardet je vícesouborový modul. Mohl jsem se rozhodnout, že veškerý kód uložím do jednoho souboru (pojmenovaného chardet.py), ale neudělal jsem to. Místo toho jsem vytvořil adresář (pojmenovaný chardet) a v něm jsem vytvořil soubor \_\_init\_\_.py. Pokud Python najde v adresáři soubor \_\_init\_\_.py, předpokládá, že všechny ostatní soubory ve stejném adresáři jsou součástí stejného modulu. Jméno adresáře je jménem modulu. Soubory v adresáři se mohou odkazovat na ostatní soubory ve stejném adresáři nebo dokonce v jeho podadresářích. (Více si o tom řekneme za minutku.) Ale celá kolekce souborů se okolnímu pythonovskému kódu jeví jako jediný modul — jako kdyby všechny funkce a třídy byly definovány v jediném souboru s příponou .py.

A co je vlastně v souboru \_\_init\_\_.py? Nic. Všechno. Něco mezi tím. Soubor \_\_init\_\_.py nemusí definovat vůbec nic. Může to být doslova prázdný soubor. Nebo jej můžeme použít k definici funkcí, které jsou našimi hlavními vstupními body. Nebo do něj můžeme umístit všechny naše funkce. Podstatná je jediná věc.

Adresář se souborem \_\_init\_\_.py se vždy považuje za vícesouborový modul. Pokud v adresáři není umístěn soubor \_\_init\_\_.py, považuje se prostě za adresář, který nemá k souborům s příponou .py žádný vztah.

Podívejme se, jak to funguje v praxi.

```
>>> import chardet
>>> dir(chardet) [1]
['__builtins__', '__doc__', '__file__', '__name__',
    '__package__', '__path__', '__version__', 'detect']
>>> chardet [2]
<module 'chardet' from 'C:\Python31\lib\site-packages\chardet\__init__.py'>
```

- Pokud neuvažujeme obvyklé atributy tříd, najdeme v modulu chardet jedinou věc a tou je funkce detect().
- Tady máme první stopu, která říká, že modul chardet je víc než jen obyčejným souborem: u slova "module" se ve výpisu objevuje soubor \_\_init\_\_.py umístěný v adresáři chardet/.

Nahlédněme do souboru \_\_init\_\_.py.

```
def detect(aBuf): [1]
    from . import universaldetector [2]
    u = universaldetector.UniversalDetector()
    u.reset()
    u.feed(aBuf)
    u.close()
    return u.result
```

- V souboru \_\_init\_\_.py je definována funkce detect(), která je hlavním bodem knihovny chardet.
- Ale funkce detect() neobsahuje skoro žádný kód! Ve skutečnosti pouze importuje modul universaldetector a začíná jej používat. Ale kde je definován universaldetector?

Odpověď je skryta v tomto divně vypadajícím příkazu import:

```
from . import universaldetector
```

V překladu do češtiny to znamená "importuj modul universaldetector, který je umístěn ve stejném adresáři, jako já". Tím "já" se myslí soubor chardet/\_\_init\_\_.py. Říká se tomu relativní import. Představuje způsob, jakým se mohou soubory ve vícesouborovém modulu na sebe vzájemně odkazovat, aniž by se musely starat o konflikty jmen s jinými moduly, které můžeme mít nainstalované v naší vyhledávací cestě pro import. Uvedený příkaz import bude modul universaldetector hledat pouze uvnitř adresáře chardet/.

Zmíněné dva koncepty — \_\_init\_\_.py a relativní importy — znamenají, že náš modul můžeme rozbít na tolik kousků, kolik si přejeme. Modul chardet se skládá z 36 souborů s příponou .py — z 36! A přitom vše, co musíme udělat, když jej chceme začít používat, je import chardet. Pak můžeme zavolat hlavní funkci chardet.detect(). Aniž o tom náš kód ví, funkce detect() je ve skutečnosti definována v souboru chardet/\_\_init\_\_.py. A aniž o tom musíme vědět my, funkce detect()

používá k odkazu na třídu definovanou uvnitř chardet/universaldetector.py mechanismus relativního importu, který zase používá relativní import pěti dalších souborů, které se rovněž nacházejí v adresáři chardet/.

Kdykoliv se přistihnete, že v Pythonu píšete rozsáhlou knihovnu (nebo, což je pravděpodobnější, když zjistíte, že se vaše malá knihovna rozrostla ve velkou), udělejte si čas na refaktorizaci a změňte ji na vícesouborový modul. Je to jedna z mnoha věcí, ve kterých je Python dobrý. Takže té výhody využijte.

#### 15.6. Opravme, co 2to3 neumí

# 15.6.1. False je syntaktická chyba

Teď zkusíme skutečný test. Spustíme testovací sadu (test suite) na zkušební skript (test harness). Protože je testovací sada navržena tak, aby pokryla všechny možné cesty, kudy se běh programu může kódem ubírat, jde o dobrý způsob, jak ověřit, že v našem přeneseném

kódu někde nejsou skryté chyby.

Píšete testy, že?

```
C:\home\chardet> python test.py tests\*\*
Traceback (most recent call last):
 File "test.py", line 1, in <module>
   from chardet.universaldetector import UniversalDetector
 File "C:\home\chardet\chardet\universaldetector.py", line 51
   self.done = constants.False
```

SyntaxError: invalid syntax

Hmm, to je jen drobnost. V Pythonu 3 je False vyhrazeným slovem, takže je nemůžeme použít jako jméno proměnné. Podíváme se do constants. py na to, kde je proměnná definována. Tady máme původní verzi z constants.py předtím, než ji skript 2to3 změnil:

```
import __builtin__
if not hasattr(__builtin__, 'False'):
    False = 0
    True = 1
else:
    False = __builtin__.False
    True = __builtin__.True
```

Tento kus kódu byl navržen, aby knihovna běžela ve starších verzích Pythonu 2. Před Pythonem 2.3 neexistoval zabudovaný typ bool. Uvedený kód detekuje nepřítomnost zabudovaných konstant True a False a v případě potřeby je definuje.

Ale v Pythonu 3 je typ bool přítomen vždy, takže je celý úryvek kódu zbytečný. Nejjednodušší řešení spočívá v nahrazení všech výskytů constants. True a constants. False hodnotami True a False. Pak z constants. py odstraníme onen mrtvý kód.

Takže následující řádek v universaldetector.py

```
self.done = constants.False
se změní na
self.done = False
```

Ách, nebylo to uspokojující? Kód je teď kratší a čitelnější.

#### 15.6.2. Nenalezen modul constants

Nastal čas spustit znovu test.py. Uvidíme, jak daleko se dostaneme.

```
C:\home\chardet> python test.py tests\*\*
Traceback (most recent call last):
    File "test.py", line 1, in <module>
        from chardet.universaldetector import UniversalDetector
    File "C:\home\chardet\chardet\universaldetector.py", line 29, in <module>
        import constants, sys
ImportError: No module named constants
```

Co to říká? Jaképak "No module named constants" (doslova "žádný modul jménem constants")? Modul constants tam samozřejmě je! Je přímo tady v chardet/constants.py.

Vzpomínáte si, jak skript 2to3 opravil všechny ty příkazy import? Tato knihovna používá množství relativních importů — moduly, které importují jiné moduly nacházející se uvnitř stejné knihovny —, ale *v Pythonu 3 se změnila logika relativních importů.* V Pythonu 2 jsme mohli jednoduše provést import constants a Python by nejdříve prohledával adresář chardet/. V Pythonu 3 jsou všechny příkazy import absolutní. Pokud chceme v Pythonu 3 provést relativní import, musíme to říct explicitně:

```
from . import constants
```

No moment. Neměl se o tohle postarat skript 2to3 za nás? No, on to udělal. Ale tento konkrétní příkaz import kombinoval dva typy importu na jednom řádku: relativní import modulu constants, který se nachází uvnitř knihovny, a absolutní import modulu sys, který je předinstalován jako součást pythonovské standardní knihovny. V Pythonu 2 jsme je mohli zkombinovat do jednoho řádku příkazu import. V Pythonu 3 to nejde a skript 2to3 není dost chytrý na to, aby příkaz import rozdělil na dva.

Řešení spočívá v ručním rozdělení příkazu import. Takže tento import "dva v jednom"...

```
import constants, sys
```

... musíme změnit na dva oddělené importy:

```
from . import constants import sys  \\
```

Variace tohoto problému jsou rozesety po celé knihovně chardet. Na některých místech je to "import constants, sys", jinde je to "import constants, re". Oprava je stejná. Ručně rozdělíme příkaz import na dva řádky. Na jednom uvedeme relativní import, na druhém absolutní import.

Kupředu!

#### 15.6.3. Jméno 'file' není definováno

A zase jdeme na to. Spouštíme test.py, abychom provedli naše testovací případy...

```
C:\home\chardet> python test.py tests\*\*
tests\ascii\howto.diveintomark.org.xml
Traceback (most recent call last):
   File "test.py", line 9, in <module>
      for line in file(f, 'rb'):
NameError: name 'file' is not defined
```

# open() je novým file(). PapayaWhip je nová černá.

Tak tohle mě překvapilo, protože tento obrat jsem používal, co mi paměť sahá. V Pythonu 2 byla globální funkce file() jiným jménem (alias) pro funkci open(), která představovala standardní způsob otvírání textových souborů pro čtení. V Pythonu 3 už globální funkce file() neexistuje, ale funkce open() je tu nadále.

Takže nejjednodušší řešení problému chybějící funkce file() spočívá v jejím nahrazení voláním funkce open():

```
for line in open(f, 'rb'):
```

A to je vše, co o tom můžu říct.

# 15.6.4. Řetězcový vzorek nelze použít pro bajtové objekty

Teď se začnou dít zajímavé věci. Slůvkem "zajímavé" rozumím "pekelně matoucí".

```
C:\home\chardet> python test.py tests\*\*
tests\ascii\howto.diveintomark.org.xml
Traceback (most recent call last):
    File "test.py", line 10, in <module>
        u.feed(line)
    File "C:\home\chardet\chardet\universaldetector.py", line 98, in feed
    if self._highBitDetector.search(aBuf):
TypeError: can't use a string pattern on a bytes-like object

Abychom to odladili, podívejme se, co je self._highBitDetector. Je to definováno v metodě
    __init___ třídy UniversalDetector:
    def __init___(self):
        self._highBitDetector = re.compile(r'[\x80-\xFF]')
```

Jde o předkompilovaný regulární výraz, který má hledat znaky mimo ASCII, tj. v rozsahu 128–255 (0x80–0xFF). Počkat, tohle není úplně správně. Musíme použít přesnější terminologii. Tento vzorek je navržen pro hledání bajtů s hodnotou mimo ascii, tedy v rozsahu 128–255.

A v tom je ten problém.

V Pythonu 2 byl řetězec polem bajtů. Jeho kódování znaků bylo zachyceno odděleně. Pokud jsme po Pythonu 2 chtěli, aby znakové kódování udržoval u řetězce, museli jsme použít Unicode řetězec (u''). Ale v Pythonu 3 je řetězec vždy tím, co Python 2 nazýval Unicode řetězec — to znamená polem Unicode znaků (které mohou být vyjádřeny různým počtem bajtů). A protože je tento regulární výraz definován řetězcovým vzorkem, může být použit jen pro prohledávání řetězců, což je pole znaků. Ale my nechceme prohledávat řetězec. Prohledáváme pole bajtů. Pohledem na trasovací výpis zjistíme, že k chybě došlo v universaldetector.py:

```
def feed(self, aBuf):
    .
    .
    .
    if self._mInputState == ePureAscii:
        if self._highBitDetector.search(aBuf):
```

A co je to aBuf? Podívejme se ještě o kousek zpět, na místo, kde se volá UniversalDetector.feed(). Jedno z míst, kde se volá, se nachází v testovacím kódu (test harness) test.py.

```
u = UniversalDetector()
.
.
.
for line in open(f, 'rb'):
    u.feed(line)
```

# Není to pole znaků, ale pole bajtů.

A tady máme odpověď: aBuf je řádek načítaný v metodě UniversalDetector.feed() ze souboru na disku. Podívejte se pořádně na parametry, které se používají při otvírání souboru: 'rb'. 'r' znamená "read" (čtení). No dobrá, to je toho. Čteme ze souboru. No jo! 'b' znamená "binárně". Bez příznaku 'b' by cyklus for četl soubor po řádcích

a každý řádek by převáděl na řetězec — tedy na pole Unicode znaků — s využitím systémového výchozího znakového kódování. Ale s příznakem 'b' čte cyklus for ze souboru po řádcích a každý řádek ukládá do pole bajtů přesně v takovém tvaru, v jakém se nachází v souboru. Výsledné pole bajtů se předává do UniversalDetector.feed() a nakonec se dostane až k předkompilovanému regulárnímu výrazu self.\_highBitDetector, aby se našly osmibitové... znaky. Ale my nemáme znaky. My máme bajty. A do prčic.

Potřebujeme, aby tento regulární výraz nehledal v poli znaků, ale v poli bajtů.

Když už jsme na to přišli, bude náprava jednoduchá. Regulární výrazy definované řetězci mohou hledat v řetězcích. Regulární výrazy definované poli bajtů mohou hledat v polích bajtů. Abychom definovali vzorek polem bajtů, jednoduše změníme typ argumentu, který používáme pro definici regulárního výrazu, na pole bajtů. (Hned na následujícím řádku je další případ téhož problému.)

```
class UniversalDetector:
    def __init__(self):
        self._highBitDetector = re.compile(r'[\x80-\xFF]')
-        self._escDetector = re.compile(r'(\033|~{})')
+        self._highBitDetector = re.compile(b'[\x80-\xFF]')
+        self._escDetector = re.compile(b'(\033|~{})')
        self._mEscCharSetProber = None
        self._mCharSetProbers = []
        self.reset()
```

Když necháme ve všech zdrojových textech vyhledat použití modulu re, objevíme další dva případy v charsetprober.py. Jde opět o případy, kdy jsou regulární výrazy definovány jako řetězce, ale používáme je pro aBuf, což je pole bajtů. Řešení je stejné: definujeme vzorky regulárních výrazů jako pole bajtů.

```
class CharSetProber:
    .
    .
    def filter_high_bit_only(self, aBuf):
        aBuf = re.sub(r'([\x00-\x7F])+', ' ', aBuf)
        aBuf = re.sub(b'([\x00-\x7F])+', b' ', aBuf)
        return aBuf

def filter_without_english_letters(self, aBuf):
        aBuf = re.sub(r'([A-Za-z])+', ' ', aBuf)
        aBuf = re.sub(b'([A-Za-z])+', b' ', aBuf)
        return aBuf
```

# 15.6.5. Objekt typu 'bytes' nelze implicitně převést na str

Divoucnější a divoucnější...

```
C:\home\chardet> python test.py tests\*\*
tests\ascii\howto.diveintomark.org.xml
Traceback (most recent call last):
    File "test.py", line 10, in <module>
        u.feed(line)
    File "C:\home\chardet\chardet\universaldetector.py", line 100, in feed
        elif (self._mInputState == ePureAscii) and self._escDetector.search(self._mLastChar + aBuf):
TypeError: Can't convert 'bytes' object to str implicitly
```

Zde dochází k nešťastné kolizi mezi stylem zápisu zdrojového textu a interpretem Pythonu. Chyba TypeError se může vázat na kteroukoliv část řádku, ale trasovací výpis nám neříká, kde přesně je. Může to být v první nebo v druhé části podmínky, ale z trasovacího výpisu se to nepozná. Abychom prostor pro hledání zúžili, měli bychom řádek rozdělit:

```
elif (self._mInputState == ePureAscii) and \
    self._escDetector.search(self._mLastChar + aBuf):
```

A znovu spustíme test:

```
C:\home\chardet> python test.py tests\*\*
tests\ascii\howto.diveintomark.org.xml
Traceback (most recent call last):
   File "test.py", line 10, in <module>
        u.feed(line)
   File "C:\home\chardet\chardet\universaldetector.py", line 101, in feed        self._escDetector.search(self._mLastChar + aBuf):
TypeError: Can't convert 'bytes' object to str implicitly
```

Aha! Problém se nevyskytoval v první části podmínky (self.\_mInputState == ePureAscii), ale v druhé. Takže co zde vlastně způsobuje chybu TypeError? Možná si myslíte, že metoda search() očekává hodnotu odlišného typu. To by ale nevygenerovalo takový trasovací výpis. Pythonovské funkce mohou přebírat libovolné hodnoty. Pokud předáme správný počet argumentů, funkce se provede. Pokud bychom předali hodnotu jiného typu, než funkce očekává, mohla by havarovat. Ale pokud by se tak stalo, trasovací výpis by ukazoval na místo někde uvnitř funkce. Jenže tento trasovací výpis říká, že se nikdy nedošlo tak daleko, aby se metoda search() zavolala. Takže problém musí být skryt v operaci +, protože ta se snaží o zkonstruování hodnoty, která bude nakonec předána metodě search().

Z předchozího ladění víme, že aBuf je polem bajtů. A co je tedy self.\_mLastChar? Jde o členskou proměnnou definovanou v metodě reset(), která je ve skutečnosti volána z metody \_\_init\_\_().

```
class UniversalDetector:
    def __init__(self):
        self._highBitDetector = re.compile(b'[\x80-\xFF]')
        self._escDetector = re.compile(b'(\033|~{\)'})
        self._mEscCharSetProber = None
        self._mCharSetProbers = []
        self.reset()

def reset(self):
        self.result = {'encoding': None, 'confidence': 0.0}
        self.done = False
        self._mStart = True
        self._mGotData = False
        self._mInputState = ePureAscii
        self._mLastChar = ''
```

A tady máme odpověď. Vidíte to? self.\_mLastChar je řetězec, ale aBuf je pole bajtů. Konkatenaci (zřetězení, spojení) nelze provádět pro řetězec a pole bajtů — ani když jde o řetězec nulové délky.

No dobrá, ale k čemu je tedy self.\_mLastChar? V metodě feed(), jen pár řádků pod místem označeným v trasovacím výpisu, vidíme...

```
if self._mInputState == ePureAscii:
    if self._highBitDetector.search(aBuf):
        self._mInputState = eHighbyte
    elif (self._mInputState == ePureAscii) and \
            self._escDetector.search(self._mLastChar + aBuf):
        self._mInputState = eEscAscii

self._mLastChar = aBuf[-1]
```

Volající funkce volá metodu feed() pořád dokola s tím, že jí pokaždé předá pár bajtů. Metoda zpracuje zadané bajty (dostává je v aBuf) a potom uloží poslední bajt do self.\_mLastChar pro případ, že by jej potřebovala při dalším volání. (Při použití vícebajtového kódování by metoda feed() mohla být zavolána pro polovinu znaku a pak by mohla být volána pro jeho druhou polovinu.) Ale protože je teď aBuf místo řetězce polem bajtů, musíme udělat pole bajtů i z self.\_mLastChar. Takže:

```
def reset(self):
    .
    .
    .
    self._mLastChar = ''
    self._mLastChar = b''
```

Když ve všech zdrojových souborech vyhledáme "mLastChar", najdeme podobný problém v mbcharsetprober. py. Ale místo uchovávání posledního znaku se uchovávají poslední dva znaky. Třída MultiByteCharSetProber používá k uchovávání posledních dvou znaků seznam jednoznakových řetězců. V Pythonu 3 musíme použít seznam celých čísel, protože ve skutečnosti neuchováváme znaky, ale bajty. (Bajty jsou prostě celá čísla v intervalu 0-255.)

```
class MultiByteCharSetProber(CharSetProber):
    def __init__(self):
        CharSetProber.__init__(self)
        self._mDistributionAnalyzer = None
        self._mCodingSM = None
        self._mLastChar = ['\x00', '\x00']
+ self._mLastChar = [0, 0]

def reset(self):
        CharSetProber.reset(self)
        if self._mCodingSM:
            self._mCodingSM.reset()
        if self._mDistributionAnalyzer:
            self._mDistributionAnalyzer.reset()
- self._mLastChar = ['\x00', '\x00']
+ self._mLastChar = [0, 0]
```

# 15.6.6. Nepodporované typy operandů pro +: 'int' a 'bytes'

Mám jednu dobrou a jednu špatnou zprávu. Ta dobrá je, že děláme pokroky...

...Ta špatná je, že to někdy tak nevypadá.

Ale on to je pokrok! Opravdu! I když trasovací výpis označuje stejný řádek kódu, je to jiná chyba, než se hlásila dříve. Pokrok! Takže kdepak máme problém teď? Když jsme to kontrolovali minule, nesnažil se tento řádek řetězit int s polem bajtů (bytes). Ve skutečnosti jsme strávili dost času tím, abychom zajistili, že self.\_mLastChar bude pole bajtů. Jak se mohlo změnit na int?

Odpověď není skrytá v předchozích řádcích kódu, ale v následujících.

```
if self._mInputState == ePureAscii:
    if self._highBitDetector.search(aBuf):
        self._mInputState = eHighbyte
    elif (self._mInputState == ePureAscii) and \
            self._escDetector.search(self._mLastChar + aBuf):
        self._mInputState = eEscAscii

self._mLastChar = aBuf[-1]
```

Každý prvek řetězce je řetězcem. Každý prvek z pole bajtů je celé číslo. Tato chyba se nevyskytne při prvním volání metody feed(). Vyskytne se *při druhém volání* poté, co byl proměnné self.\_mLastChar přiřazen poslední bajt aBuf. No a v čem je tedy problém? Když z bajtového pole získáme jeden prvek, dostaneme celé číslo a ne bajtové pole. Abychom ten rozdíl viděli, ukážeme si to v interaktivním shellu:

```
>>> aBuf = b'\xEF\xBB\xBF'
                                                   [1]
>>> len(aBuf)
3
>>> mLastChar = aBuf[-1]
>>> mLastChar
                                                   [2]
191
>>> type(mLastChar)
                                                   [3]
<class 'int'>
>>> mLastChar + aBuf
                                                   [4]
Traceback (most recent call last):
 File "<stdin>", line 1, in <module>
TypeError: unsupported operand type(s) for +: 'int' and 'bytes'
>>> mLastChar = aBuf[-1:]
                                                   [5]
>>> mLastChar
b'\xbf'
>>> mLastChar + aBuf
                                                   [6]
b'\xbf\xef\xbb\xbf'
```

- [1] Definujeme pole bajtů o délce 3.
- [2] Poslední prvek pole bajtů má hodnotu 191.
- [3] Je to celé číslo (integer).
- Zřetězení pole bajtů s celým číslem nefunguje. Právě jsme navodili chybu, kterou jsme pozorovali v universaldetector.py.
- A tady máme nápravu. Místo získávání posledního prvku z pole bajtů použijeme operaci pro získání výřezu (slicing). Vytvoříme jí nové pole bajtů, které obsahuje jen poslední prvek. To znamená, že začneme posledním prvkem a pokračujeme v tvorbě výřezu (slice), dokud nedosáhneme konce pole bajtů. Teď je mLastChar polem bajtů o délce 1.
- [6] Zřetězením pole bajtů o délce 1 s polem bajtů o délce 3 dostaneme nové pole bajtů o délce 4.

Takže abychom zajistili, že bude metoda feed() v universaldetector.py pokračovat v činnosti nezávisle na tom, jak často je volána, musíme inicializovat self.\_mLastChar polem bajtů o nulové délce a potom musíme zajistit, aby tato proměnná zůstala polem bajtů.

```
self._escDetector.search(self._mLastChar + aBuf):
    self._mInputState = eEscAscii

- self._mLastChar = aBuf[-1]
+ self._mLastChar = aBuf[-1:]
```

# 15.6.7. Funkce ord() očekávala řetězec o délce 1, ale byl nalezen in

Jste už unaveni? Už to máme skoro hotové...

```
C:\home\chardet> python test.py tests\*\*
tests\ascii\howto.diveintomark.org.xml
                                                             ascii with confidence 1.0
tests\Big5\0804.blogspot.com.xml
Traceback (most recent call last):
 File "test.py", line 10, in <module>
   u.feed(line)
 File "C:\home\chardet\chardet\universaldetector.py", line 116, in feed
   if prober.feed(aBuf) == constants.eFoundIt:
 File "C:\home\chardet\chardet\charsetgroupprober.py", line 60, in feed
   st = prober.feed(aBuf)
 File "C:\home\chardet\chardet\utf8prober.py", line 53, in feed
    codingState = self._mCodingSM.next_state(c)
 File "C:\home\chardet\codingstatemachine.py", line 43, in next_state
   byteCls = self._mModel['classTable'][ord(c)]
TypeError: ord() expected string of length 1, but int found
OK, takže c je typu int, ale funkce ord() očekávala jednoznakový řetězec. No dobrá. Kde je definována
```

proměnná c?

```
# codingstatemachine.py
def next_state(self, c):
   # for each byte we get its class
   # if it is first byte, we also get byte length
   byteCls = self._mModel['classTable'][ord(c)]
```

To nám nepomůže. Tady se jen předává funkci. Podívejme se hlouběji do zásobníku.

```
# utf8prober.py
def feed(self, aBuf):
    for c in aBuf:
        codingState = self._mCodingSM.next_state(c)
```

Vidíte to? V Pythonu 2 byla proměnná aBuf řetězcem, takže proměnná c byla jednoznakovým řetězcem. (Ten dostáváme, když iterujeme přes řetězec — všechny znaky, jeden po druhém.) Ale teď je aBuf polem bajtů, takže c je typu int a ne jednoznakový řetězec. Jinými slovy, už nepotřebujeme volat funkci ord(), protože c už je typu int!

```
Takže:
```

```
def next_state(self, c):
      # for each byte we get its class
      # if it is first byte, we also get byte length
      byteCls = self._mModel['classTable'][ord(c)]
      byteCls = self._mModel['classTable'][c]
Vyhledáním "ord(c)" ve všech zdrojových textech odhalíme podobné problémy
v sbcharsetprober.py...
# sbcharsetprober.py
def feed(self, aBuf):
    if not self._mModel['keepEnglishLetter']:
        aBuf = self.filter_without_english_letters(aBuf)
    aLen = len(aBuf)
    if not aLen:
        return self.get_state()
    for c in aBuf:
        order = self._mModel['charToOrderMap'][ord(c)]
... a v latin1prober.py...
# latin1prober.py
def feed(self, aBuf):
    aBuf = self.filter_with_english_letters(aBuf)
    for c in aBuf:
        charClass = Latin1_CharToClass[ord(c)]
```

Proměnná c iteruje přes aBuf, což znamená, že v ní bude celé číslo a ne jednoznakový řetězec. Řešení je stejné: ord(c) změníme na prosté c.

```
# sbcharsetprober.py
def feed(self, aBuf):
    if not self._mModel['keepEnglishLetter']:
        aBuf = self.filter_without_english_letters(aBuf)
    aLen = len(aBuf)
    if not aLen:
        return self.get_state()
    for c in aBuf:
        order = self._mModel['charToOrderMap'][ord(c)]
        order = self._mModel['charToOrderMap'][c]
```

```
# latin1prober.py
def feed(self, aBuf):
    aBuf = self.filter_with_english_letters(aBuf)
    for c in aBuf:
        charClass = Latin1_CharToClass[ord(c)]
        charClass = Latin1_CharToClass[c]
```

## 15.6.8. Neuspořádatelné datové typy: int() >= str()

A spustme to znovu.

```
C:\home\chardet> python test.py tests\*\*
                                                             ascii with confidence 1.0
tests\ascii\howto.diveintomark.org.xml
tests\Big5\0804.blogspot.com.xml
Traceback (most recent call last):
 File "test.py", line 10, in <module>
   u.feed(line)
 File "C:\home\chardet\chardet\universaldetector.py", line 116, in feed
    if prober.feed(aBuf) == constants.eFoundIt:
 File "C:\home\chardet\chardet\charsetgroupprober.py", line 60, in feed
   st = prober.feed(aBuf)
 File "C:\home\chardet\chardet\sjisprober.py", line 68, in feed
   self._mContextAnalyzer.feed(self._mLastChar[2 - charLen :], charLen)
 File "C:\home\chardet\chardet\jpcntx.py", line 145, in feed
   order, charLen = self.get_order(aBuf[i:i+2])
 File "C:\home\chardet\chardet\jpcntx.py", line 176, in get_order
   if ((aStr[0] >= '\x81') and (aStr[0] <= '\x9F')) or \
TypeError: unorderable types: int() >= str()
```

A co se děje zase tady? "Unorderable types" čili neuspořádatelné typy? (Neuspořádatelné ve smyslu, že mezi těmito hodnotami nelze určit pořadí.) A rozdíl mezi bajty a řetězci znovu vystrkuje svou ošklivou hlavu. Ale podívejte se na kód:

```
class SJISContextAnalysis(JapaneseContextAnalysis):
    def get_order(self, aStr):
        if not aStr: return -1, 1
        # find out current char's byte length
        if ((aStr[0] >= '\x81') and (aStr[0] <= '\x9F')) or \
              ((aStr[0] >= '\xE0') and (aStr[0] <= '\xFC')):
              charLen = 2
        else:
              charLen = 1</pre>
```

A odkud se vzala proměnná aStr? Podívejme se hlouběji do zásobníku:

```
def feed(self, aBuf, aLen):
    .
    .
    .
    i = self._mNeedToSkipCharNum
    while i < aLen:
        order, charLen = self.get_order(aBuf[i:i+2])</pre>
```

Hele, podívejme. To je náš starý přítel aBuf. Jak už jste mohli odhadnout ze všech předchozích problémů, se kterými jsme se v této kapitole setkali, aBuf je pole bajtů. V tomto místě je metoda feed() nepředává jako celek. Vytváří z něj výřez. Ale jak jsme viděli v této kapitole o něco dříve, výřezem z pole bajtů vznikne pole bajtů. Takže parametr aStr, který přebírá metoda get\_order(), je pořád pole bajtů.

A co se tento kód s aStr pokouší dělat? Získává první prvek z pole bajtů a srovnává jej s jednozna-kovým řetězcem. V Pythonu 2 to fungovalo, protože aStr a aBuf byly řetězce a aStr[0] by byl taky řetězec. U řetězců můžeme zjišťovat, zda jsou různé. Ale v Pythonu 3 jsou proměnné aStr a aBuf poli bajtů a aStr[0] je celé číslo. Číslo a řetězec nemůžeme porovnávat na neshodu, aniž jednu z hodnot explicitně nepřevedeme na stejný typ.

V tomto případě nemusíme kód komplikovat přidáváním explicitního převodu typu. aStr[0] je celé číslo. Vše, s čím ho srovnáváme, jsou konstanty. Můžeme je změnit z jednoznakových řetězců na čísla. A když už to děláme, změňme také identifikátor aStr na aBuf, protože to ve skutečnosti není řetězec (string).

```
class SJISContextAnalysis(JapaneseContextAnalysis):
    def get_order(self, aStr):
        if not aStr: return -1, 1
        # def get_order(self, aBuf):
        if not aBuf: return -1, 1
        # find out current char's byte length
        if ((aStr[0] >= '\x81') and (aStr[0] <= '\x9F')) or \
              ((aBuf[0] >= '\xE0') and (aBuf[0] <= '\xFC')):
        if ((aBuf[0] >= 0x81) and (aBuf[0] <= 0x9F)) or \
              ((aBuf[0] >= 0xE0) and (aBuf[0] <= 0xFC)):
              charLen = 2
        else:
              charLen = 1</pre>
```

```
15.6.
```

```
# return its order if it is hiragana
     if len(aStr) > 1:
            if (aStr[0] == '\202') and \
               (aStr[1] >= ' \x9F') and \
               (aStr[1] <= '\xF1'):
               return ord(aStr[1]) - 0x9F, charLen
     if len(aBuf) > 1:
            if (aBuf[0] == 202) and \
               (aBuf[1] \geq= 0x9F) and \
               (aBuf[1] \le 0xF1):
               return aBuf[1] - 0x9F, charLen
        return -1, charLen
class EUCJPContextAnalysis(JapaneseContextAnalysis):
   def get_order(self, aStr):
    if not aStr: return -1, 1
   def get_order(self, aBuf):
     if not aBuf: return -1, 1
        # find out current char's byte length
        if (aStr[0] == '\x8E') or \
          ((aStr[0] >= '\xA1') and (aStr[0] <= '\xFE')):
        if (aBuf[0] == 0x8E) or \
          ((aBuf[0] \ge 0xA1) \text{ and } (aBuf[0] \le 0xFE)):
            charLen = 2
        elif aStr[0] == '\x8F':
        elif aBuf[0] == 0x8F:
            charLen = 3
        else:
            charLen = 1
      # return its order if it is hiragana
   if len(aStr) > 1:
          if (aStr[0] == '\xA4') and \
             (aStr[1] >= '\xA1') and \
             (aStr[1] \leftarrow '\xF3'):
                return ord(aStr[1]) - 0xA1, charLen
   if len(aBuf) > 1:
          if (aBuf[0] == 0xA4) and \
             (aBuf[1] \ge 0xA1) and \
             (aBuf[1] \le 0xF3):
              return aBuf[1] - 0xA1, charLen
      return -1, charLen
```

Hledáním výskytu funkce ord() ve zdrojových textech odkryjeme stejný problém v chardistribution.py (konkrétně ve třídách EUCTWDistributionAnalysis, EUCKRDistributionAnalysis, GB2312DistributionAnalysis, Big5DistributionAnalysis, SJISDistributionAnalysis a EUCJPDistributionAnalysis). Ve všech případech se oprava podobá změnám, které jsme provedli v třídách EUCJPContextAnalysis a SJISContextAnalysis v souboru jpcntx.py.

#### 15.6.9. Globální jméno 'reduce' není definováno

Ještě jedna trhlina...

Podle oficiálního průvodce What's New In Python 3.0 byla funkce reduce() vyňata z globálního prostoru jmen a přesunuta do modulu functools. Citujme z průvodce: "Pokud opravdu potřebujete functools. reduce(), použijte ji. Ale v 99 procentech případů je explicitní cyklus for čitelnější." O tomto rozhodnutí se dočtete více na weblogu Guida van Rossuma: The fate of reduce() in Python 3000 (Osud reduce v Pythonu 3000).

```
def get_confidence(self):
    if self.get_state() == constants.eNotMe:
        return 0.01

total = reduce(operator.add, self._mFreqCounter)
```

Funkce reduce() přebírá dva argumenty — funkci a seznam (přesněji řečeno, může to být libovolný iterovatelný objekt) — a kumulativně aplikuje zadanou funkci na každý z prvků seznamu. Jinými slovy, jde o efektní a nepřímý způsob realizace součtu všech prvků seznamu.

Tato obludnost byla tak běžná, že byla do Pythonu přidána globální funkce sum().

```
def get_confidence(self):
    if self.get_state() == constants.eNotMe:
        return 0.01

total = reduce(operator.add, self._mFreqCounter)
total = sum(self._mFreqCounter)
```

Protože jsme přestali používat modul operator, můžeme také ze začátku souboru odstranit příslušný příkaz import.

```
from .charsetprober import CharSetProber
from . import constants
- import operator
```

A tož, možeme to otestovať?

```
C:\home\chardet> python test.py tests\*\*
tests\ascii\howto.diveintomark.org.xml
                                                              ascii with confidence 1.0
tests\Big5\0804.blogspot.com.xml
                                                             Big5 with confidence 0.99
tests\Big5\blog.worren.net.xml
                                                             Big5 with confidence 0.99
                                                             Big5 with confidence 0.99
tests\Big5\carbonxiv.blogspot.com.xml
tests\Big5\catshadow.blogspot.com.xml
                                                             Big5 with confidence 0.99
tests\Big5\coolloud.org.tw.xml
                                                             Big5 with confidence 0.99
tests\Big5\digitalwall.com.xml
                                                             Big5 with confidence 0.99
tests\Big5\ebao.us.xml
                                                             Big5 with confidence 0.99
tests\Big5\fudesign.blogspot.com.xml
                                                             Big5 with confidence 0.99
tests\Big5\kafkatseng.blogspot.com.xml
                                                             Big5 with confidence 0.99
tests\Big5\ke207.blogspot.com.xml
                                                             Big5 with confidence 0.99
tests\Big5\leavesth.blogspot.com.xml
                                                             Big5 with confidence 0.99
tests\Big5\letterlego.blogspot.com.xml
                                                             Big5 with confidence 0.99
tests\Big5\linyijen.blogspot.com.xml
                                                             Big5 with confidence 0.99
tests\Big5\marilynwu.blogspot.com.xml
                                                             Big5 with confidence 0.99
tests\Big5\myblog.pchome.com.tw.xml
                                                             Big5 with confidence 0.99
tests\Big5\oui-design.com.xml
                                                             Big5 with confidence 0.99
tests\Big5\sanwenji.blogspot.com.xml
                                                             Big5 with confidence 0.99
tests\Big5\sinica.edu.tw.xml
                                                             Big5 with confidence 0.99
                                                             Big5 with confidence 0.99
tests\Big5\sylvia1976.blogspot.com.xml
tests\Big5\tlkkuo.blogspot.com.xml
                                                             Big5 with confidence 0.99
tests\Big5\tw.blog.xubg.com.xml
                                                             Big5 with confidence 0.99
tests\Big5\unoriginalblog.com.xml
                                                             Big5 with confidence 0.99
tests\Big5\upsaid.com.xml
                                                             Big5 with confidence 0.99
tests\Big5\willythecop.blogspot.com.xml
                                                             Big5 with confidence 0.99
tests\Big5\ytc.blogspot.com.xml
                                                             Big5 with confidence 0.99
```

```
tests\EUC-JP\aivy.co.jp.xml
tests\EUC-JP\akaname.main.jp.xml
tests\EUC-JP\arclamp.jp.xml
.
.
.
.
```

EUC-JP with confidence 0.99 EUC-JP with confidence 0.99 EUC-JP with confidence 0.99

No to mě podrž, ono to funguje! /me si trošku zatancuje.

#### 15.7. Shrnutí

Co jsme se naučili?

- 1. Přepisování jakéhokoliv netriviálního kódu z Pythonu 2 do Pythonu 3 bude bolestivé. Nedá se to obejít. Je to obtížné.
- 2. Automatický nástroj 2to3 nám částečně pomůže, ale postará se jen o snadnější části přejmenování funkcí, přejmenování modulů, úpravy syntaxe. Jde o impozantní kus inženýrské práce, ale koneckonců jde jen o inteligentního robota provádějícího vyhledávání a náhrady.
- 3. Problémem č. 1 při přepisování této knihovny byl rozdíl mezi řetězci a bajty. V tomto případě se to zdá být zřejmé, protože hlavním účelem knihovny chardet je převod proudu bajtů na řetězec. Ale "s proudem bajtů" se setkáváme častěji, než byste si mysleli. Čtete soubor v "binárním" režimu? Dostáváte proud bajtů. Získáváte obsah webovské stránky? Voláte webové aplikační rozhraní? Také se vrací proud bajtů.
- 4. Programu musíte rozumět vy. Skrz naskrz. Především protože jste ho napsali, ale musíte se vyrovnat se všemi jeho triky a zatuchlými kouty. Chyby jsou všude.
- 5. Testovací případy jsou nepostradatelné. Pokud je nemáte, nic nepřepisujte. *Jediný* důvod, proč věřím tomu, že chardet funguje v Pythonu 3, spočívá v tom, že jsem začal s testovací sadou, která prověřovala všechny hlavní cesty, kudy se kód ubírá. Pokud žádné testy nemáte, napište je dříve, než začnete přenos do Pythonu 3 realizovat. Pokud máte jen pár testů, napište jich víc. Pokud máte hodně testů, pak teprve může začít opravdová legrace.

"You'll find the shame is like the pain; you only feel it once."

(Zjistíte, že stud je jako bolest; ale cítíte ho jen jednou.)

— Markýza de Merteuil, *Dangerous Liaisons* (*Nebezpečné známosti*)

# 16. Balení pythonovských knihoven

16.12.

Přečtěte si — 375

#### 16.1. Ponořme se

Opravdoví umělci prodávají. Alespoň takhle to říká Steve Jobs. Chcete vydat pythonovský skript, knihovnu, rámec (framework) nebo aplikaci? Výborně. Svět potřebuje více pythonovského kódu. Python 3 se dodává s rámcem pro vytváření balíčků zvaným Distutils. Distutils v sobě skrývá mnoho věcí: nástroj pro sestavení (build tool; pro vás), instalační nástroj (pro vaše uživatele), formát metadat balíčků (pro vyhledávače) a další. Tvoří celek s **Python Package Index** ("PyPI"), což je centrální archiv pythonovských open-source knihoven.

Všechny uvedené stránky nástroje Distutils jsou soustředěny kolem *instalačního skriptu*, který se tradičně nazývá setup. py. Ve skutečnosti už jste v této knize několik instalačních skriptů vytvořených nástrojem Kap. Distutils viděli. Distutils jste použili k instalaci httplib2 v kapitole <u>Webové služby nad HTTP</u> a znovu kap. k instalaci chardet v <u>Případové studii: Přepis chardet pro Python 3.</u>

V této kapitole si prostudujeme, jak instalační skripty pro chardet a pro httplib2 pracují, a projdeme si procesem vydání vašeho vlastního pythonovského softwaru.

```
# chardet's setup.py
from distutils.core import setup
setup(
   name = "chardet",
    packages = ["chardet"],
    version = "1.0.2",
    description = "Universal encoding detector",
    author = "Mark Pilgrim",
    author_email = "mark@diveintomark.org",
    url = "http://chardet.feedparser.org/",
    download_url = "http://chardet.feedparser.org/download/python3-chardet-1.0.1.tgz",
    keywords = ["encoding", "i18n", "xml"],
    classifiers = [
        "Programming Language :: Python",
        "Programming Language :: Python :: 3",
        "Development Status :: 4 - Beta",
        "Environment :: Other Environment",
        "Intended Audience :: Developers",
        "License :: OSI Approved :: GNU Library or Lesser General Public License (LGPL)",
        "Operating System :: OS Independent",
        "Topic :: Software Development :: Libraries :: Python Modules",
        "Topic :: Text Processing :: Linguistic",
    long_description = """\
Universal character encoding detector
```

-----

```
Detects
```

```
- ASCII, UTF-8, UTF-16 (2 variants), UTF-32 (4 variants)
- Big5, GB2312, EUC-TW, HZ-GB-2312, ISO-2022-CN (Traditional and Simplified Chinese)
- EUC-JP, SHIFT_JIS, ISO-2022-JP (Japanese)
- EUC-KR, ISO-2022-KR (Korean)
- KOI8-R, MacCyrillic, IBM855, IBM866, ISO-8859-5, windows-1251 (Cyrillic)
- ISO-8859-2, windows-1250 (Hungarian)
- ISO-8859-5, windows-1251 (Bulgarian)
- windows-1252 (English)
- ISO-8859-7, windows-1253 (Greek)
- ISO-8859-8, windows-1255 (Visual and Logical Hebrew)
- TIS-620 (Thai)

This version requires Python 3 or later; a Python 2 version is available separately.
```

> chardet a httplib2 jsou open source, ale neexistuje žádný požadavek na to, abyste své vlastní pythonovské knihovny vydávali pod nějakou konkrétní licencí. Proces popisovaný v této kapitole bude fungovat pro libovolný pythonovský software, nezávisle na licenci.

## 16.2. Věci, které za nás Distutils neudělají

Vypuštění vašeho prvního pythonovského balíčku je skličující proces. (Uvolnění vašeho druhého balíčku je o něco snazší.) Distutils se celý proces snaží zautomatizovat, jak jen to je možné. Ale některé věci prostě musíte udělat sami.

- Vybrat licenci. Tohle je komplikované téma, zatížené politikou a rizikem. Pokud svůj software
  chcete zveřejnit jako open source, skromně doporučuji pět následujících rad:
  - 1. Nepište svou vlastní licenci.
  - 2. Nepište svou vlastní licenci.
  - 3. Nepište svou vlastní licenci.
  - 4. Nemusí to být zrovna gpl, ale měla by být s GPL slučitelná.
  - 5. Nepište svou vlastní licenci.
- **Zařadte svůj software** pomocí klasifikačního systému PyPI. Později v této kapitole vysvětlím, co to znamená.
- Napište soubor "read me" (čti mne). Tohle neodflákněte. Vaši uživatelé by se z něj měli
  dozvědět přinejmenším to, co váš software dělá a jak se instaluje.

#### 16.3. Struktura adresáře

Vytváření balíčku pro váš pythonovský software začíná tím, že si musíte udělat pořádek v souborech a v adresářích. Adresář httplib2 vypadá takto:

```
httplib2/ [1]
|
+--README.txt [2]
+--setup.py [3]
|
+--httplib2/ [4]
|
+--__init__.py
|
+--iri2uri.py
```

- Vytvořte kořenový adresář, ve kterém bude všechno. Dejte mu stejné jméno, jaké má váš pythonovský modul.
- Abyste se přizpůsobili uživatelům Windows, měl by váš soubor "read me" použít příponu .txt a měl by používat windowsovské konce řádků. To, že vy používáte nějaký fantastický editor, který se dá spouštět z příkazového řádku a má i svůj makro jazyk, neznamená, že byste měli ztěžovat život svým uživatelům. (Vaši uživatelé používají "Notepad", česky "Poznámkový blok". Je to smutné, ale je to tak.) Váš oblíbený editor má nepochybně volbu pro ukládání souborů s windowsovskými konci řádků i když pracujete v Linuxu nebo s Mac OS X.
- Váš instalační skript využívající Distutils by měl být pojmenován setup.py pokud nemáte dobrý důvod pro to, aby se jmenoval jinak. A vy nemáte dobrý důvod, aby se jmenoval jinak.
- Pokud se váš pythonovský software skládá z jediného souboru s příponou .py, měli byste jej umístit do kořenového adresáře spolu se svým souborem "read me" a se svým instalačním skriptem. Ale httplib2 se neskládá z jediného .py souboru. Je to vícesouborový modul. Ale to je v pořádku! Adresář httplib2 umístěte do kořenového adresáře, takže budete mít soubor \_\_init\_\_.py umístěn v adresáři httplib2/ v kořenovém adresáři httplib2/. Nehledejte v tom problém. Ve skutečnosti to zjednoduší proces vytváření balíčku.

Adresář chardet vypadá trochu jinak. Stejně jako u httplib2 jde o vícesouborový modul, takže tu máme adresář chardet/ uvnitř kořenového adresáře chardet/. K souboru README. txt má chardet navíc HTML dokumentaci, umístěnou v adresáři docs/. Adresář docs/ obsahuje několik souborů s příponami .html a .css a podadresář images/, který obsahuje několik souborů s příponami .png a .gif. (To bude důležité později.) V souladu s konvencemi pro software s licencí (L)GPL obsahuje také samostatný soubor zvaný COPYING. txt, který obsahuje kompletní text LGPL.

## 16.4. Píšeme svůj instalační skript

Instalační skript pro Distutils je pythonovský skript. Teoreticky by mohl dělat vše, co lze dělat v pythonovských skriptech. Prakticky by toho měl dělat co nejméně a co nejstandardnějším způsobem. Instalační skript by měl být nudný. Čím exotičtější bude váš instalační proces, tím exotičtější budou hlášení o chybách.

První řádek každého instalačního skriptu pro Distutils je vždycky stejný:

```
from distutils.core import setup
```

Importujeme funkci setup(), která je hlavním vstupním bodem rámce Distutils. 95 % všech distutilsovských skriptů se skládá z jediného volání funkce setup() a z ničeho jiného. (Tuhle statistiku jsem si právě vymyslel, ale pokud váš distutilsovský skript dělá něco víc než volání funkce setup() z Distutils, měli byste pro to mít dobrý důvod. A máte pro to dobrý důvod? Myslím, že ne.)

Funkce setup() přebírá celou řadu parametrů. V zájmu zachování duševního zdraví všech zúčastněných musíte pro každý parametr používat pojmenované argumenty. Není to jen nějaká konvence. Je to tvrdý požadavek. Pokud se pokusíte o volání funkce setup() s nepojmenovanými argumenty, váš instalační skript zhavaruje.

Následující pojmenované argumety jsou povinné:

- name jméno balíčku.
- version verze balíčku.
- author vaše celé jméno.
- author\_email vaše e-mailová adresa.
- url domácí stránka vašeho projektu. Pokud pro projekt nemáte vyhrazen zvláštní webový server, můžete zde uvést stránku svého balíčku v PyPI.

Ačkoliv to není povinné, doporučuji, abyste ve svém instalačním skriptu uvedli také následující:

- description, jednořádkový popis projektu.
- long\_description, víceřádkový řetězec ve formátu reStructuredText. PyPI ho převede do HTML a zobrazí ho na stránce pro váš balíček.
- classifiers, seznam zvláštním způsobem formátovaných řetězců, které si popíšeme v následující podkapitole.
- > Metadata instalačního skriptu jsou definována v PEP 314.

Teď se podíváme na instalační skript pro chardet. Používá všechny zmíněné povinné a doporučené parametry a ještě jeden, o kterém jsem se zatím nezmínil: packages.

```
from distutils.core import setup
setup(
   name = 'chardet',
   packages = ['chardet'],
   version = '1.0.2',
   description = 'Universal encoding detector',
   author='Mark Pilgrim',
   ...
)
```

Parametr packages zvýrazňuje jedno nešťastné překrývání významů slov během distribučního procesu. O slově "balíček/balík" (package) jsme se bavili jako o něčem, co vytváříme (a co se potenciálně vypisuje v seznamu PyPI). Jenže to není tím, na co se parametr packages odkazuje. Vztahuje se ke skutečnosti, že chardet je vícesouborovým modulem, kterému se také někdy říká... "package" (balíček). Parametr packages nástroji Distutils říká, aby do procesu zahrnul adresář chardet/, jeho soubor \_\_init\_\_.py a všechny ostatní soubory s příponou .py, ze kterých se modul chardet skládá. To je docela důležité. Veškerá radostná rozprava o dokumentaci a metadatech je k ničemu, pokud zapomenete přibalit skutečný kód!

#### 16.5. Přidáváme klasifikaci našeho balíčku

The Python Package Index ("PyPI") obsahuje tisíce pythonovských knihoven. Ostatní lidé najdou váš balíček snadněji, když použijete správná klasifikační metadata. PyPI vám umožní prohlížet balíčky uspořádané podle klasifikátorů. Pro zúžení nabídky při vyhledávání můžete vybrat dokonce více klasifikátorů. Klasifikátory prostě nejsou jen neviditelná metadata, která byste mohli ignorovat!

Klasifikaci svého softwaru provedete předáním parametru classifiers distutilovské funkci setup(). Parametr classifiers má podobu seznamu řetězců. Ale tyto řetězce *nemají* volný formát. Všechny klasifikační řetězce by měly pocházet z tohoto seznamu na PyPI.

Klasifikátory jsou nepovinné. Můžete napsat distutilovský instalační skript bez jakýchkoliv klasifikátorů. **Nedělejte to**. Měli byste vždy uvést alespoň následující klasifikátory:

- Programming Language (programovací jazyk). Konkrétně by měl zahrnovat jak "Programming Language :: Python", tak "Programming Language :: Python :: 3". Pokud je neuvedete, nebude se váš balíček ukazovat v tomto seznamu knihoven kompatibilních s Pythonem 3, na který se dostanete přes odkaz uvedený v bočním sloupku na každé stránce z pypi.python.org.
- License (licence). Pokud zkouším nějakou knihovnu třetí strany, je to absolutně první věc, na kterou se dívám. Nechtějte po mně, abych tuto životně důležitou informaci musel někde hledat. Pokud se váš software nedodává pod více licencemi, neuvádějte víc než jeden licenční klasifikátor. (A pokud k tomu nejste nějak nuceni, nevydávejte svůj software pod více licencemi. A nenuťte k tomu ostatní lidi. Licencování stačí k bolení hlavy už i tak. Nedělejte to ještě horší.)
- Operating System (operační systém). Pokud váš software běží pouze pod Windows (nebo jen pod Mac OS X nebo jen pod Linuxem), rád bych se to dozvěděl raději dřív než později. Pokud váš software běží kdekoliv, aniž by potřeboval nějaký platformově závislý kód, použijte klasifikátor "Operating System :: OS Independent". Použití více klasifikátorů Operating System je nezbytné pouze v případě, kdy váš software vyžaduje pro každou platformu specifickou podporu. (Běžně tomu tak nebývá.)

Doporučuji, abyste uvedli i následující klasifikátory:

- **Development Status** (stav vývoje). Lze kvalitu vašeho softwaru ohodnotit přívlastkem beta? Alfa? Nebo se nachází ještě v ranějším stadiu (pre-alpha)? Jednu z možností uveďte. Buďte upřímní.
- Intended Audience (zamýšlená skupina uživatelů). Kdo by mohl chtít stahovat váš software? Nejpoužívanější volby jsou Developers (vývojáři), End Users/Desktop (koncoví uživatelé), Science/Research (věda a výzkum), and System Administrators (správci systémů).
- Framework (rámec). Pokud lze váš software považovat za zásuvný modul (plugin) pro větší
  pythonovské rámce, jako jsou například Django nebo Zope, uveďte příslušný klasifikátor
  Framework. Pokud tomu tak není, neuvádějte jej.
- Topic (tematická oblast). Zde naleznete velké množství oblastí, ze kterých si můžete vybrat.
   Uveďte všechny, které vašemu softwaru odpovídají.

#### 16.5.1. Příklady dobrých klasifikátorů balíčků

Jako příklad uveďme klasifikátory pro Django, což je multiplatformní aplikační rámec (framework), který můžete spouštět na svém webovém serveru. Dodává se pod licencí BSD a je využitelný pro ostrý provoz (production-ready). (Django zatím není kompatibilní s Pythonem 3, takže není uveden klasifikátor Programming Language :: Python :: 3.)

```
Programming Language :: Python
License :: OSI Approved :: BSD License
Operating System :: OS Independent
Development Status :: 5 - Production/Stable
Environment :: Web Environment
Framework :: Django
Intended Audience :: Developers
Topic :: Internet :: WWW/HTTP
Topic :: Internet :: WWW/HTTP :: Dynamic Content
Topic :: Internet :: WWW/HTTP :: WSGI
Topic :: Software Development :: Libraries :: Python Modules
```

Tady jsou klasifikátory pro chardet, což je knihovna pro detekci znakového kódování, kterou jsme se Kap. zabývali v <u>Případové studii: Přepis chardet pro Python 3</u>. chardet je ve stadiu beta, je multiplatformní, kompatibilní s Pythonem 3, pod licencí LGPL a je určena pro vývojáře, kteří ji mohou začlenit do svých vlastních produktů.

```
Programming Language :: Python

Programming Language :: Python :: 3

License :: OSI Approved :: GNU Library or Lesser General Public License (LGPL)

Operating System :: OS Independent

Development Status :: 4 - Beta

Environment :: Other Environment

Intended Audience :: Developers

Topic :: Text Processing :: Linguistic

Topic :: Software Development :: Libraries :: Python Modules
```

Kap. A tady jsou klasifikátory pro httplib2, což je knihovna, o které jsme se bavili v kapitole <u>Webové služby nad HTTP</u>. httplib2 je ve stadiu beta, multiplatformní, pod licencí MIT a je učena pro pythonovské vývojáře.

Programming Language :: Python
Programming Language :: Python :: 3
License :: OSI Approved :: MIT License
Operating System :: OS Independent
Development Status :: 4 - Beta
Environment :: Web Environment
Intended Audience :: Developers
Topic :: Internet :: WWW/HTTP

Topic :: Software Development :: Libraries :: Python Modules

## 16.6. Určení dalších souborů prostřednictvím manifestu

Pokud neurčíme jinak, zahrnou Distutils do vašeho instalačního balíčku následující soubory:

- README.TXT
- setup.py
- Soubory s příponou .py, které se používají ve vícesouborových modulech uvedených v seznamu parametru packages.
- Jednotlivé soubory s příponou .py, které jsou uvedeny v seznamu parametru py\_modules.

Tímto způsobem lze pokrýt všechny soubory projektu httplib2. Ale u projektu chardet potřebujeme zařadit i licenční soubor COPYING. txt a celý adresář docs/, který obsahuje obrázky a HTML soubory. Pokud chceme Distutils říci, aby byly při tvorbě instalačního balíčku chardet zařazeny i tyto dodatečné soubory a adresáře, musíme použít soubor s manifestem (manifest file).

Soubor s manifestem je textový soubor s názvem MANIFEST.in. Umístíme jej do kořenového adresáře projektu, vedle souborů README.txt a setup.py. Soubory s manifestem *nejsou* pythonovské skripty. Jsou to textové soubory, které obsahují posloupnosti "příkazů" ve formátu pro Distutils. Příkazy manifestu nám umožňují zahrnovat nebo vyřazovat konkrétní soubory a adresáře.

Následuje celý obsah souboru manifestu pro projekt chardet:

```
include COPYING.txt [1]
recursive-include docs *.html *.css *.png *.gif [2]
```

- První řádek je samovysvětlující: vložit soubor COPYING. txt z kořenového adresáře projektu.
- Druhý řádek je trochu složitější. Příkaz recursive-include přebírá jméno adresáře a jedno nebo víc jmen souborů. Jména souborů nemusí být uvedena explicitně. Mohou být vyjádřena zástupnými znaky (wildcards). Tento řádek znamená: "Vidíš adresář docs/ v kořenovém adresáři projektu? Najdi v něm (rekurzivně) soubory s příponami .html, .css, .png a .gif. Chci, aby byly všechny zařazeny do instalačního balíčku."

- 16.7. Kontrola chyb v našem instalačním skriptu
- 16.8. Vytvoření distribuce obsahující zdrojové texty

Všechny příkazy manifestu zachovávají strukturu adresářů, která je vytvořena v kořenovém adresáři projektu. Uvedený příkaz recursive-include nenacpe všechny .html a .png soubory do kořenového adresáře instalačního balíčku. Dodrží existující strukturu adresáře docs/, ale zařadí do ní jen ty soubory, které odpovídají zadaným maskám se zástupnými znaky. (Dříve jsem se o tom nezmiňoval, ale dokumentace chardet je ve skutečnosti napsaná v XML a do HTML je převedena samostatným skriptem. Do instalačního balíčku nechci zařazovat zdrojové XML soubory, ale jen výsledné HTML soubory a obrázky.)

> Soubory s manifestem mají svůj specifický formát. Detaily hledejte v dokumentech **Specifying** the files to distribute a The manifest template commands.

Zopakujme si to: soubor s manifestem musíme vytvářet jen v případě, kdy chceme zahrnout i soubory, které nástroj Distutils nevkládá automaticky. Pokud potřebujeme použít soubor s manifestem, měl by obsahovat jen jména souborů, která by jinak nástroj Distutils nenašel sám.

## 16.7. Kontrola chyb v našem instalačním skriptu

Musíme myslet na spoustu věcí. Distutils mají zabudovaný validační příkaz, který kontroluje, že náš instalační skript obsahuje všechna povinná metadata. Pokud například zapomeneme uvést parametr version, Distutils nám to připomenou.

```
c:\Users\pilgrim\chardet> c:\python31\python.exe setup.py check
running check
warning: check: missing required meta-data: version
```

Jakmile parametr version uvedeme (a všechny ostatní povinné části metadat), příkaz check dopadne takto:

```
c:\Users\pilgrim\chardet> c:\python31\python.exe setup.py check
running check
```

#### 16.8. Vytvoření distribuce obsahující zdrojové texty

Distutils podporují tvorbu mnoha typů distribučních balíčků. Přinejmenším bychom měli vytvořit "distribuci zdrojů" (source distribution), která obsahuje naše zdrojové texty s kódem, instalační skript pro Distutils, soubor "read me" a jakékoliv další soubory, které chceme do distribuce zahrnout. Distribuci zdrojů vytvoříme tím, že instalačnímu skriptu Distutils zadáme příkaz sdist.

```
c:\Users\pilgrim\chardet> c:\python31\python.exe setup.py sdist
running sdist
running check
reading manifest template 'MANIFEST.in'
```

```
writing manifest file 'MANIFEST'
creating chardet-1.0.2
creating chardet-1.0.2\chardet
creating chardet-1.0.2\docs
creating chardet-1.0.2\docs\images
copying files to chardet-1.0.2...
copying COPYING -> chardet-1.0.2
copying README.txt -> chardet-1.0.2
copying setup.py -> chardet-1.0.2
copying chardet\__init__.py -> chardet-1.0.2\chardet
copying chardet\big5freq.py -> chardet-1.0.2\chardet
copying chardet\universaldetector.py -> chardet-1.0.2\chardet
copying chardet\utf8prober.py -> chardet-1.0.2\chardet
copying docs\faq.html -> chardet-1.0.2\docs
copying docs\history.html -> chardet-1.0.2\docs
copying docs\how-it-works.html -> chardet-1.0.2\docs
copying docs\index.html -> chardet-1.0.2\docs
copying docs\license.html -> chardet-1.0.2\docs
copying docs\supported-encodings.html -> chardet-1.0.2\docs
copying docs\usage.html -> chardet-1.0.2\docs
copying docs\images\caution.png -> chardet-1.0.2\docs\images
copying docs\images\important.png -> chardet-1.0.2\docs\images
copying docs\images\note.png -> chardet-1.0.2\docs\images
copying docs\images\permalink.gif -> chardet-1.0.2\docs\images
copying docs\images\tip.png -> chardet-1.0.2\docs\images
copying docs\images\warning.png -> chardet-1.0.2\docs\images
creating dist
creating 'dist\chardet-1.0.2.zip' and adding 'chardet-1.0.2' to it
adding 'chardet-1.0.2\COPYING'
adding 'chardet-1.0.2\PKG-INFO'
adding 'chardet-1.0.2\README.txt'
adding 'chardet-1.0.2\setup.py'
adding 'chardet-1.0.2\chardet\big5freq.py'
adding 'chardet-1.0.2\chardet\big5prober.py'
. . .
adding 'chardet-1.0.2\chardet\universaldetector.py'
adding 'chardet-1.0.2\chardet\utf8prober.py'
adding 'chardet-1.0.2\chardet\__init__.py'
adding 'chardet-1.0.2\docs\faq.html'
adding 'chardet-1.0.2\docs\history.html'
adding 'chardet-1.0.2\docs\how-it-works.html'
adding 'chardet-1.0.2\docs\index.html'
```

```
adding 'chardet-1.0.2\docs\license.html'
adding 'chardet-1.0.2\docs\supported-encodings.html'
adding 'chardet-1.0.2\docs\usage.html'
adding 'chardet-1.0.2\docs\images\caution.png'
adding 'chardet-1.0.2\docs\images\note.png'
adding 'chardet-1.0.2\docs\images\permalink.gif'
adding 'chardet-1.0.2\docs\images\permalink.gif'
adding 'chardet-1.0.2\docs\images\tip.png'
adding 'chardet-1.0.2\docs\images\warning.png'
removing 'chardet-1.0.2\docs\images\warning.png'
```

Tady bychom se měli zmínit o několika věcech:

- Distutils si všimly souboru s manifestem (MANIFEST.in).
- Distutils soubor s manifestem úspěšně zpracovaly a přidaly předepsané soubory COPYING. txt a HTML soubory a soubory s obrázky v adresáři docs/.
- Pokud se podíváme do adresáře projektu, uvidíme, že Distutils vytvořily adresář dist/.
   V adresáři dist/ se nachází soubor s příponou .zip, který můžeme distribuovat.

#### <u>16.9. Vytvoření grafického instalačního programu</u>

Podle mého názoru si každá pythonovská knihovna zaslouží, aby byl pro uživatele Windows k dispozici grafický instalační program. Dá se udělat snadno (i když sami Windows nepoužíváte) a uživatelé Windows to ocení.

Distutils dovedou vytvořit grafický instalační program pro Windows za nás. Stačí, když instalačnímu skriptu pro Distutils zadáme příkaz bdist\_wininst.

```
c:\Users\pilgrim\chardet> c:\python31\python.exe setup.py bdist_wininst
running bdist_wininst
running build
running build_py
creating build
creating build\lib
creating build\lib\chardet
copying chardet\big5freq.py -> build\lib\chardet
copying chardet\big5prober.py -> build\lib\chardet
copying chardet\universaldetector.py -> build\lib\chardet
copying chardet\utf8prober.py -> build\lib\chardet
copying chardet\__init__.py -> build\lib\chardet
installing to build\bdist.win32\wininst
running install_lib
creating build\bdist.win32
creating build\bdist.win32\wininst
creating build\bdist.win32\wininst\PURELIB
creating build\bdist.win32\wininst\PURELIB\chardet
copying build\lib\chardet\big5freq.py -> build\bdist.win32\wininst\PURELIB\chardet
copying build\lib\chardet\big5prober.py -> build\bdist.win32\wininst\PURELIB\chardet
. . .
copying build\lib\chardet\universaldetector.py -> build\bdist.win32\wininst\PURELIB\chardet
copying build\lib\chardet\utf8prober.py -> build\bdist.win32\wininst\PURELIB\chardet
copying build\lib\chardet\__init__.py -> build\bdist.win32\wininst\PURELIB\chardet
running install_egg_info
Writing build\bdist.win32\wininst\PURELIB\chardet-1.0.2-py3.1.egg-info
creating 'c:\users\pilgrim\appdata\local\temp\tmp2f4h7e.zip' and adding '.' to it
adding 'PURELIB\chardet-1.0.2-py3.1.egg-info'
adding 'PURELIB\chardet\big5freq.py'
adding 'PURELIB\chardet\big5prober.py'
adding 'PURELIB\chardet\universaldetector.py'
adding 'PURELIB\chardet\utf8prober.py'
adding 'PURELIB\chardet\__init__.py'
removing 'build\bdist.win32\wininst' (and everything under it)
c:\Users\pilgrim\chardet> dir dist
c:\Users\pilgrim\chardet>dir dist
 Volume in drive C has no label.
 Volume Serial Number is AADE-E29F
 Directory of c:\Users\pilgrim\chardet\dist
```

```
07/30/2009 10:14 PM
                       <DIR>
                       <DIR>
07/30/2009 10:14 PM
07/30/2009 10:14 PM
                               371,236 chardet-1.0.2.win32.exe
07/30/2009 06:29 PM
                               206,440 chardet-1.0.2.zip
              2 File(s)
                               577,676 bytes
              2 Dir(s) 61,424,070,656 bytes free
```

## 16.9.1. Tvorba instalačních balíčků pro jiné operační systémy

Distutils nám mohou pomoci vytvořit instalační balíčky pro uživatele Linuxu. Ale podle mého názoru to nestojí za tu námahu. Pokud chcete svůj software distribuovat v Linuxu, měli byste svůj čas raději věnovat spolupráci se skupinou lidí, kteří se specializují na vytváření softwarových balíčků pro hlavní distribuce Linuxu.

Například moji knihovnu chardet najdete v archivech pro Debian GNU/Linux (a tím pádem i v archivech pro Ubuntu). Nemusel jsem se o to vůbec starat. Balíčky se tam jednoho dne prostě objevily. Komunita kolem distribuce Debian má svá vlastní pravidla pro balení pythonovských knihoven a balíček python-chardet pro Debian je navržen tak, aby tyto konvence splňoval. A protože jsou balíčky umístěny v archivech Debianu, získávají uživatelé Debianu bezpečnostní aktualizace a/nebo nové verze podle toho, jaká systémová nastavení si pro údržbu svých počítačů zvolili.

Linuxovské balíčky vytvářené nástrojem Distutils žádnou z těchto výhod nenabízejí. Bude lepší, když svůj čas strávíte jiným způsobem.

## 16.10. Přidání našeho softwaru do Python Package Index

Nahrání našeho softwaru do Python Package Index představuje proces o třech krocích.

- 1. Zaregistrujeme se.
- 2. Zaregistrujeme svůj software.
- 3. Uložíme (upload) balíčky, které jsme vytvořili příkazy setup.py sdist a setup.py bdist\_\*.

Registraci své osoby provedeme prostřednictvím registrační stránky pro uživatele PyPI. Vložíme své uživatelské jméno a heslo, poskytneme platnou e-mailovou adresu a klikneme na tlačítko Register. (Pokud máte klíč PGP nebo GPG, můžete jej uvést také. Pokud jej nemáte nebo nevíte, co to znamená, nedělejte si s tím starosti.) Zkontrolujeme svůj e-mail. Během několika minut bychom měli obdržet zprávu od PyPI s potvrzovacím odkazem. Registrační proces dokončíme tím, že na odkaz klikneme.

Teď zaregistrujeme u PyPI náš software a nahrajeme jej (upload). To vše můžeme provést v jediném kroku.

c:\Users\pilgrim\chardet> c:\python31\python.exe setup.py register sdist bdist\_wininst upload [1] running register We need to know who you are, so please choose either: 1. use your existing login, 2. register as a new user, 3. have the server generate a new password for you (and email it to you), or 4. quit Your selection [default 1]: 1 [2] Username: MarkPilgrim [3] Password: Registering chardet to http://pypi.python.org/pypi [4] Server response (200): OK running sdist [5] ... výstup pro stručnost vypuštěn ... running bdist\_wininst [6] ... výstup pro stručnost vypuštěn ... running upload [7] Submitting dist\chardet-1.0.2.zip to http://pypi.python.org/pypi Server response (200): OK Submitting dist\chardet-1.0.2.win32.exe to http://pypi.python.org/pypi Server response (200): OK

Když svůj projekt zveřejníme poprvé, přidají Distutils náš software do Python Package Index a přidělí mu jeho vlastní URL. Při dalších přístupech jednoduše aktualizují metadata projektu podle změn, které uvedeme v parametrech našeho setup. py. Poté se vytvoří distribuce zdrojů (source distribution; sdist) a instalátor pro Windows (bdist\_wininst) a nahrají se do PyPI (upload).

[8]

- Vybereme "use your existing login" (použij svůj existující účet) napsáním 1, nebo prostě stiskneme ENTER.
- Napíšeme uživatelské jméno a heslo, která jsme si zvolili na registrační stránce PyPI. Distutils neopisují zadávané heslo. Místo zadávaných znaků nevypisují ani hvězdičky. Prostě napíšeme heslo a stiskneme ENTER.
- [4] Distutils zaregistrují náš balíček v archivu Python Package Index...

I can store your PyPI login so future submissions will be faster.

(the login will be stored in c:\home\.pypirc)

Save your login (y/N)?n

- [5] ...vytvoří distribuci našich zdrojů (source distribution)...
- [6] ...vytvoří instalátor pro Windows...
- [7] ...a nahrají (upload) oba do Python Package Index.
- Pokud chceme proces zveřejňování nových verzí zautomatizovat, musíme uložit osobní údaje pro PyPI do lokálního souboru. Je to zcela proti zásadám bezpečnosti a zcela nepovinné.

- 16.11. Více možných budoucností balení pythonovských produktů
- 16.12. Přečtěte si

Gratuluji. Teď už máte svoji vlastní stránku na Python Package Index!

Její adresa je http://pypi.python.org/pypi/JMENO, kde JMENO je řetězec, který jste předali parametrem name ve svém souboru setup.py.

Pokud chceme zveřejnit novou verzi, upravíme ve svém souboru setup. py číslo verze a spustíme proces nahrávání (upload) znovu:

c:\Users\pilgrim\chardet> c:\python31\python.exe setup.py register sdist bdist\_wininst upload

## 16.11. Více možných budoucností balení pythonovských produktů

Distutils nejsou jediným nástrojem pro vytváření pythonovských balíčků, ale v době psaní tohoto textu (srpen 2009) to byl jediný rámec pro vytváření instalačních balíčků, který fungoval v Pythonu 3. Pro Python 2 existuje řada dalších rámců. Některé se soustředí na instalaci, jiné na testování a distribuci (deployment). Některé z nich možná budou přepsány pro Python 3.

Následující rámce (frameworks) jsou zaměřeny na instalaci:

- Setuptools
- Pip
- Distribute

Následující se zaměřují na testování a distribuci:

- virtualenv
- zc.buildout
- Paver
- Fabric
- py2exe

#### 16.12. Přečtěte si

#### O Distutils:

- Distributing Python Modules with Distutils (http://docs.python.org/py3k/distutils/)
- Core Distutils functionality uvádí všechny možné argumenty funkce setup()
   (http://docs.python.org/py3k/distutils/apiref.html)
- Distutils Cookbook (http://wiki.python.org/moin/Distutils/Cookbook)

### • PEP 370: Per user site-packages directory

(www.python.org/dev/peps/pep-0370/)

## • PEP 370 and "environment stew"

(http://jessenoller.com/2009/07/19/pep-370-per-user-site-packages-and-environment-stew/)

#### O ostatních rámcích pro vytváření balíčků:

## The Python packaging ecosystem

(http://groups.google.com/group/django-developers/msg/5407cdb400157259)

#### On packaging

(www.b-list.org/weblog/2008/dec/14/packaging/)

## A few corrections to "On packaging"

(http://blog.ianbicking.org/2008/12/14/a-few-corrections-to-on-packaging/)

## • Why I like Pip

(www.b-list.org/weblog/2008/dec/15/pip/)

## Python packaging: a few observations

(http://cournape.wordpress.com/2009/04/01/python-packaging-a-few-observations-cabal-for-a-solution/)

#### Nobody expects Python packaging!

(http://jacobian.org/writing/nobody-expects-python-packaging/)

"Life is pleasant. Death is peaceful. It's the transition that's troublesome." (Život je zábavný. Smrt je klidná. Nepříjemný je ten přechod.)

— Isaac Asimov (připsáno)

# A. Přepis kódu do Pythonu 3 s využitím 2to3

| A.     | Přepis kódu do Pythonu 3                      | A.30.   | Oktalo |
|--------|---|---------|--------|
|        | s využitím 2to3 — 377                         | A.31.   | sys.ma |
| A.1.   | Ponořme se — <b>379</b>                       | A.32.   | Globá  |
| A.2.   | Příkaz print — <b>379</b>                     | A.33.   | Globá  |
| A.3.   | Literály Unicode řetězců — 380                | A.34.   | Výjim  |
| A.4.   | Globální funkce unicode() — <b>380</b>        | A.35.   | Konst  |
| A.5.   | Datový typ long — <b>380</b>                  | A.36.   | Globá  |
| A.6.   | Porovnání <> — 381                            | A.37.   | Datov  |
| A.7.   | Slovníková metoda has_key() — <b>381</b>      | A.38.   | itert  |
| A.8.   | Slovníkové metody, které vracejí              | A.39.   | sys.ex |
|        | seznamy — 382                                 |         | sys.ex |
| A.9.   | Moduly, které byly přejmenovány               | A.40.   | Gener  |
|        | nebo reorganizovány — 383                     | A.41.   | Funko  |
| A.9.1. | http — <b>383</b>                             | A.42.   | Metati |
| A.9.2. | urllib — 384                                  | A.43.   | Věci t |
| A.9.3. | dbm — 385                                     | A.43.1. | Množ   |
| A.9.4. | xmlrpc — <b>385</b>                           | A.43.2. | Globá  |
| A.9.5. | Ostatní moduly — 386                          | A.43.3. | Bílé z |
| A.10.  | Relativní importy uvnitř balíčku — <b>387</b> | A.43.4. | Běžné  |
| A.11.  | Metoda iterátoru next() — 388                 |         |        |
| A.12.  | Globální funkce filter() — 388                |         |        |
| A.13.  | Globální funkce map() — <b>389</b>            |         |        |
| A.14.  | Globální funkce reduce() — <b>390</b>         |         |        |
| A.15.  | Globální funkce apply() — <b>390</b>          |         |        |
| A.16.  | Globální funkce intern() — 390                |         |        |
| A.17.  | Příkaz exec — <b>391</b>                      |         |        |
| A.18.  | Příkaz execfile — <b>391</b>                  |         |        |
| A.19.  | repr literály (zpětné apostrofy) — <b>392</b> |         |        |
| A.20.  | Příkaz tryexcept — <b>392</b>                 |         |        |
| A.21.  | Příkaz raise — <b>393</b>                     |         |        |
| A.22.  | Metoda generátorů throw — <b>393</b>          |         |        |
| A.23.  | Globální funkce xrange() — <b>394</b>         |         |        |
| A.24.  | Globální funkce raw_input()                   |         |        |
|        | a input() — <b>395</b>                        |         |        |
| A.25.  | Atributy funkcí func_* — <b>395</b>           |         |        |
| A.26.  | Metoda xreadlines() V/V objektů — <b>396</b>  |         |        |
| A.27.  | lambda funkce, které akceptují                |         |        |
|        | n-tici místo více parametrů — <b>396</b>      |         |        |
| A.28.  | Atributy speciálních metod — <b>397</b>       |         |        |
| A.29.  | Speciální metodanonzero — <b>397</b>          |         |        |

```
ové literály — <mark>398</mark>
axint — 398
lní funkce callable() — 399
lní funkce zip() — 399
ka StandardError — 399
anty modulu types — 400
lní funkce isinstance() — 400
ý typ basestring — 401
ools module — 401
xc_type, sys.exc_value,
xc_traceback — 401
átory seznamů nad n-ticemi — 402
ce os.getcwdu() — 402
řídy — 402
ýkající se stylu — 403
inové literály (set(); explicitně) — 403
lní funkce buffer() (explicitně) — 403
naky kolem čárek (explicitně) — 404
obraty (explicitně) — 404
```

- A.1. Ponořme se
- A.2. Příkaz print

#### A.1. Ponořme se

Mezi Pythonem 2 a Pythonem 3 se toho změnilo tolik, že najdete jen mizivé procento programů, které bez úprav běží v obou verzích. Ale nepropadejte zoufalství! K usnadnění přechodu se Python 3 dodává s pomocným skriptem nazvaným 2to3. Když mu předáte svůj zdrojový soubor napsaný pro Python 2 jako vstup, převede automaticky do podoby pro Python 3 vše, co dovede. <u>Případová studie: Přepis chardet pro Python 3</u> popisuje, jak se skript 2to3 spouští. Ukazuje také věci, které se automaticky neopraví. V této příloze najdete dokumentaci toho, co dovede opravit automaticky.

## A.2. Příkaz print

V Pythonu 2 byl print příkazem. Pokud jsme cokoliv chtěli vytisknout, jednoduše jsme to připsali za klíčové slovo print. V Pythonu 3 je print() funkcí. Pokud chceme cokoliv vytisknout, předáme to funkci print() stejně jako každé jiné funkci.

| Poznámky | Python 2                    | Python 3                                   |
|----------|-----------------------------|--|
| [1]      | print print()               |  |
| [2]      | print 1                     | print(1)                                   |
| [3]      | print 1, 2                  | print(1, 2)                                |
| [4]      | print 1, 2,                 | print(1, 2, end=' ')                       |
| [5]      | print >>sys.stderr, 1, 2, 3 | <pre>print(1, 2, 3, file=sys.stderr)</pre> |

- [1] Prázdný řádek vytiskneme voláním print() bez zadání argumentů.
- [2] Jednu hodnotu vytiskneme voláním print() s jedním argumentem.
- Dvě hodnoty oddělené mezerou vytiskneme voláním print() s dvěma argumenty.
- V tomhle je malá finta. Pokud jsme v Pythonu 2 ukončili příkaz print čárkou, vytiskly se hodnoty oddělené mezerou, pak se vytiskla ještě jedna koncová mezera a tisk skončil bez generování přechodu na nový řádek. (Z technického hlediska je to o něco komplikovanější. Příkaz print v Pythonu 2 používal nyní již nežádoucí (deprecated) atribut zvaný softspace. Místo skutečného tisku mezery nastavil Python 2 sys.stdout.softspace na 1. Znak mezery ve skutečnosti nebyl vytištěn, dokud se nemělo na stejný řádek tisknout něco dalšího. Pokud další příkaz print tiskl přechod na nový řádek, byl atribut sys.stdout.softspace nastaven na 0 a mezera se nikdy nevytiskla. Tohoto rozdílu byste si pravděpodobně nikdy nevšimli, pokud by vaše aplikace nebyla citlivá na přítomnost nebo nepřítomnost koncových bílých znaků ve výstupu, který byl vygenerován příkazem print.) V Pythonu 3 dosáhneme stejného efektu tím, že funkci print() předáme pojmenovaný argument s hodnotou end=' '. Výchozí hodnotou argumentu end je '\n' (přechod na nový řádek), takže po vytisknutí ostatních argumentů jeho přepsáním potlačíme přechod na nový řádek.
- V Pythonu 2 jsme mohli výstup přesměrovat do roury (pipe) například na sys.stderr uvedením zápisu >> jméno\_roury. V Pythonu 3 dosáhneme stejného efektu předáním odkazu na rouru pojmenovaným argumentem file. Výchozí hodnotou argumentu file je sys.stdout (standardní výstup), takže přepsáním této hodnoty dosáhneme přesměrování do jiné roury.

- A.3. Literály Unicode řetězců A.4. Globální funkce unicode()
- A.5. Datový typ long

# A.3. Literály Unicode řetězců

Python 2 pracoval s dvěma typy řetězců: s Unicode řetězci a s ne-Unicode řetězci. Python 3 podporuje jediný řetězcový typ: Unicode řetězce.

| Poznámky | Python 2           | Python 3          |
|----------|--------------------|-------------------|
| [1]      | u'PapayaWhip'      | 'PapayaWhip'      |
| [2]      | ur'PapayaWhip\foo' | r'PapayaWhip\foo' |

- [1] Řetězcové literály s prefixem Unicode jsou jednoduše převedeny na obyčejné řetězcové literály, které v Pythonu 3 vždy vyjadřují Unicode řetězce.
- Surové Unicode řetězce (raw; ve kterých Python neprovádí interpretaci zpětného lomítka jako zahájení escape posloupnosti) jsou převedeny na surové řetězce. V Pythonu 3 jsou surové řetězce vždy v Unicode.

## A.4. Globální funkce unicode()

V Pythonu 2 se pro převod objektů na řetězec používaly dvě globální funkce: unicode() pro převod na Unicode řetězce a str() pro převod na ne-Unicode řetězce. Python 3 má jediný řetězcový typ, Unicode řetězce, takže vše, co potřebujeme, je funkce str(). (Funkce unicode() už neexistuje.)

| Poznámky | Python 2         | Python 3     |
|----------|------------------|--------------|
|          | unicode(cokoliv) | str(cokoliv) |

#### A.5. Datový typ long

Python 2 používal pro celá čísla dva datové typy: int a long. Hodnota typu int nemohla být větší než konstanta sys.maxint, která byla závislá na platformě. "Dlouhá" čísla byla definována přidáním L na konec čísla a mohla nabývat větších hodnot než čísla typu int. V Pythonu 3 je jen jeden celočíselný typ, který se jmenuje int a většinou se chová jako typ long v Pythonu 2. Protože už neexistují dva typy, nemusí se používat speciální syntaxe pro jejich rozlišení.

#### Přečtěte si:

PEP 237: Unifying Long Integers and Integers.

(www.python.org/dev/peps/pep-0237/)

| Poznámky | Python 2            | Python 3           |
|----------|---------------------|--------------------|
| [1]      | x = 100000000000L   | x = 1000000000000  |
| [2]      | x = 0xFFFFFFFFFFFL  | x = 0xFFFFFFFFFFF  |
| [3]      | long(x)             | int(x)             |
| [4]      | type(x) is long     | type(x) is int     |
| [5]      | isinstance(x, long) | isinstance(x, int) |

- Z desítkových číselných literálů pro "dlouhý" integer (long) se staly desítkové literály pro typ integer.
- Z šestnáctkových číselných literálů pro "dlouhý" integer (long) se staly šestnáctkové literály pro typ integer.
- V Pythonu 3 přestala existovat původní funkce long(), protože přestal existovat typ long (dlouhý integer). K převodu proměnné na celé číslo použijeme funkci int().
- Pokud chceme zkontrolovat, zda je proměnná typu integer, zjistíme její typ a porovnáváme ho s int (nikoliv s long).
- Ke kontrole datového typu můžeme použít i funkci isinstance(). Při zjišťování, zda jde o celočíselný typ, se opět odkážeme na int a ne na long.

#### A.6. Porovnání <>

Python 2 podporoval operátor <> jako synonymum pro != (porovnání na různost). Python 3 podporuje pouze operátor != a přestal podporovat <>.

| Poznámky | Python 2        | Python 3        |
|----------|-----------------|-----------------|
| [1]      | if x <> y:      | if x != y:      |
| [2]      | if x <> y <> z: | if x != y != z: |

- [1] Jednoduché porovnání.
- [2] Složitější porovnání mezi třemi hodnotami.

## A.7. Slovníková metoda has\_key()

V Pythonu 2 používaly slovníky metodu has\_key() (doslova "má klíč") pro testování, zda se ve slovníku nachází zadaný klíč. V Pythonu 3 tato metoda přestala existovat. Místo ní musíme používat operátor in.

| Poznámky | Python 2                           | Python 3                               |
|----------|------------------------------------|--|
| [1]      | a_dictionary.has_key('PapayaWhip') | 'PapayaWhip' in a_dictionary           |
| [2]      | a_dictionary.has_key(x) or         | x in a_dictionary or y in a_dictionary |
|          | a_dictionary.has_key(y)            |  |
| [3]      | a_dictionary.has_key(x or y)       | (x or y) in a_dictionary               |
| [4]      | a_dictionary.has_key(x + y)        | (x + y) in a_dictionary                |
| [5]      | x + a_dictionary.has_key(y)        | x + (y in a_dictionary)                |

- [1] Nejjednodušší forma.
- Operátor in má vyšší prioritu než operátor or, takže podvýrazy x in a\_dictionary a y in a\_dictionary nemusíme uzavírat do závorek.
- Ale na druhou stranu zde ze stejného důvodu *musíme* uzavřít do závorek x or y in má vyšší prioritu než or. (Poznámka: Tento kód se od předchozího řádku zcela liší. Python interpretuje nejdříve x or y. Výsledkem je buď x (pokud se x interpretuje v booleovském kontextu jako true), nebo y. Potom pro výslednou hodnotu kontroluje, zda se ve slovníku a\_dictionary vyskytuje jako klíč.)
- Operátor + má vyšší prioritu než operátor in. Z technického hlediska by tento zápis nemusel používat závorky kolem x + y, ale 2to3 je stejně přidává.
- U tohoto zápisu musí být kolem y in a\_dictionary závorky určitě uvedeny, protože operátor + má vyšší prioritu než operátor in.

## A.8. Slovníkové metody, které vracejí seznamy

V Pythonu 2 mnohé slovníkové metody vracely seznamy. Mezi nejpoužívanější metody patřily keys(), items() a values(). V Pythonu 3 všechny tyto metody vracejí dynamické pohledy (view). V některých situacích to nečiní žádný problém. Pokud je návratová hodnota těchto metod ihned předána jiné funkci, která iteruje přes celou posloupnost, bude jedno, zda je skutečným typem seznam nebo pohled (view). V jiném kontextu to ale může mít velký vliv. Pokud očekáváme kompletní seznam s jednotlivě adresovatelnými prvky, náš kód se zakucká, protože pohledy nepodporují indexování (tj. zpřístupňování prvku přes index).

| Poznámky | Python 2  | Python 3                         |
|----------|---|----------------------------------|
| [1]      | a_dictionary.keys()                             | list(a_dictionary.keys())        |
| [2]      | a_dictionary.items()                            | list(a_dictionary.items())       |
| [3]      | a_dictionary.iterkeys()                         | iter(a_dictionary.keys())        |
| [4]      | <pre>[i for i in a_dictionary.iterkeys()]</pre> | [i for i in a_dictionary.keys()] |
| [5]      | <pre>min(a_dictionary.keys())</pre>             | žádná změna                      |

Skript 2to3 se přiklání k bezpečnému řešení. Voláním funkce list() převádí hodnotu vracenou metodou keys() na statický seznam. Bude to fungovat vždycky, ale někdy to bude méně

- efektivní než použití pohledu (view). Převedený kód byste si měli prohlédnout a zvážit, zda je statický seznam nezbytně nutný, nebo zda by nestačil pohled.
- Další konverze pohledu na seznam tentokrát u metody items(). Stejnou věc provede 2to3 s metodou values().
- Python 3 už nepodporuje metodu iterkeys(). Použijte keys(), a pokud je to nezbytné, udělejte z pohledu iterátor voláním funkce iter().
- [4] 2to3 pozná, když je metoda iterkeys() použita uvnitř generátorové notace seznamu. Převede ji na metodu keys() (neobaluje ji ještě jedním voláním iter()). Funguje to, protože přes pohledy (view) lze iterovat.
- [5] 2to3 pozná případ, kdy je metoda keys() předána funkci, která iteruje celou posloupností. V takovém případě se návratová hodnota nemusí konvertovat na seznam. Funkce min() bude vesele iterovat i přes pohled. Týká se to funkcí min(), max(), sum(), list(), tuple(), set(), sorted(), any() a all().

## A.9. Moduly, které byly přejmenovány nebo reorganizovány

Několik modulů standardní pythonovské knihovny bylo přejmenováno. Několik vzájemně souvisejících modulů bylo spojeno dohromady nebo bylo reorganizováno tak, aby byly jejich vztahy logičtější.

#### A.9.1. http

V Pythonu 3 bylo několik modulů souvisejících s HTTP spojeno do jednoho balíku nazvaného http.

| Poznámky | Python 2                | Python 3              |
|----------|-------------------------|-----------------------|
| [1]      | import httplib          | import http.client    |
| [2]      | import Cookie           | import http.cookies   |
| [3]      | import cookielib        | import http.cookiejar |
| [4]      | import BaseHTTPServer   | import http.server    |
|          | import SimpleHTTPServer |                       |
|          | import CGIHttpServer    |                       |

- [1] Modul http.client implementuje nízkoúrovňovou knihovnu, která vytváří požadavky na HTTP zdroje a interpretuje související HTTP odpovědi.
- [2] Modul http.cookies poskytuje pythonovské rozhraní pro cookies prohlížeče, které se posílají v HTTP hlavičce HTTP hlavička.
- Modul HTTP.COOKIEJAR manipuluje se soubory na disku, které oblíbené webové prohlížeče používají k ukládání cookies.
- [4] Modul http. server implementuje jednoduchý HTTP server.

#### A.9.2. urllib

Python 2 obsahoval změť překrývajících se modulů pro rozklad (parse) a kódování URL a pro získávání příslušného obsahu. V Pythonu 3 byly moduly refaktorizovány a sloučeny do jednoho balíku urllib.

| Poznámky | Python 2                          | Python 3  |
|----------|-----------------------------------|---|
| [1]      | import urllib                     | import urllib.request, urllib.parse, urllib.error |
| [2]      | import urllib2                    | import urllib.request, urllib.error               |
| [3]      | import urlparse                   | import urllib.parse                               |
| [4]      | import robotparser                | import urllib.robotparser                         |
| [5]      | from urllib import FancyURLopener | from urllib.request import FancyURLopener         |
|          | from urllib import urlencode      | from urllib.parse import urlencode                |
| [6]      | from urllib2 import Request       | from urllib.request import Request                |
|          | from urllib2 import HTTPError     | from urllib.error import HTTPError                |

- Starý modul urllib v Pythonu 2 obsahoval řadu funkcí včetně urlopen() pro načítání dat a splittype(), splithost() a splituser() pro rozklad URL na podstatné části. Uvnitř nového balíku urllib byly tyto funkce logičtěji přeorganizovány. Skript 2to3 také změní všechna volání těchto funkcí, aby zohlednil nové schéma pojmenování.
- Původní modul urllib2 z Pythonu 2 byl v Pythonu 3 vložen do balíčku urllib. Všechny oblíbené věci z urllib2 metoda build\_opener(), třídy Request a HTTPBasicAuthHandler a související věci jsou stále k dispozici.
- [3] Modul urllib.parse z Pythonu 3 obsahuje všechny funkce z původního modulu urlparse z Pythonu 2.
- [4] Modul urllib.robotparser zpracovává soubory robots.txt.
- Třída FancyURLopener, která obsluhuje HTTP přesměrování a další stavové kódy, je v novém modulu urllib.request stále k dispozici. Funkce urlencode() se přesunula do urllib.parse.
- Třída Request je v urllib.request stále k dispozici, ale konstanty jako HTTPError byly přesunuty do urllib.error.

Zmínil jsem se o tom, že 2to3 přepíše také volání vašich funkcí? Pokud například v kódu pro Python 2 importujete modul urllib a získáváte data voláním urllib.urlopen(), skript 2to3 opraví jak příkaz import, tak volání funkce.

| Python 2                               | Python 3   |
|--|--|
| import urllib                          | import urllib.request, urllib.parse, urllib.error                |
| print urllib.urlopen                   | <pre>print(urllib.request.urlopen('http://diveintopython3.</pre> |
| ('http://diveintopython3.org/').read() | org/').read())   |

#### A.9.3. dbm

Všechny klony DBM se nyní nacházejí jediném balíku dbm. Pokud potřebujeme použít nějakou specifickou variantu, jako například GNU DBM, můžeme importovat příslušný modul z balíku dbm.

| Python 2       | Python 3        |
|----------------|-----------------|
| import dbm     | import dbm.ndbm |
| import gdbm    | import dbm.gnu  |
| import dbhash  | import dbm.bsd  |
| import dumbdbm | import dbm.dumb |
| import anydbm  | import dbm      |
| import whichdb |                 |

## A.9.4. xmlrpc

XML-RPC je odlehčená (lightweight) metoda pro provádění RPC (vzdálené volání procedur) přes HTTP. Klientská knihovna pro XML-RPC a několik implementací XML-RPC serveru jsou nyní zkombinovány do jednoho balíčku xmlrpc.

| Python 2                  | Python 3             |
|---------------------------|----------------------|
| import xmlrpclib          | import xmlrpc.client |
| import DocXMLRPCServer    | import xmlrpc.server |
| import SimpleXMLRPCServer |                      |

### A.9.5. Ostatní moduly

| Poznámky | Python 2                     | Python 3            |
|----------|------------------------------|---------------------|
| [1]      | try:                         | import io           |
|          | import cStringIO as StringIO |                     |
|          | except ImportError:          |                     |
|          | import StringIO              |                     |
| [2]      | try:                         | import pickle       |
|          | import cPickle as pickle     |                     |
|          | except ImportError:          |                     |
|          | import pickle                |                     |
| [3]      | importbuiltin                | import builtins     |
| [4]      | import copy_reg              | import copyreg      |
| [5]      | import Queue                 | import queue        |
| [6]      | import SocketServer          | import socketserver |
| [7]      | import ConfigParser          | import configparser |
| [8]      | import repr                  | import reprlib      |
| [9]      | import commands              | import subprocess   |

- Mezi běžné obraty v Pythonu 2 patřil pokus o import cStringIO as StringIO. Pokud operace selhala, provedl se místo toho příkaz import StringIO. V Pythonu 3 už to nedělejte. Modul io to udělá za vás. Nalezne nejrychlejší dostupnou implementaci a použije ji automaticky.
- Podobný obrat se používal pro importování nejrychlejší implementace pickle. V Pythonu 3 už to nedělejte. Modul pickle to udělá za vás.
- [3] Modul builtins obsahuje globální funkce, třídy a konstanty, které se používají napříč celým jazykem Python. Redefinicí funkce v modulu builtins provedete redefinici globální funkce úplně všude. Je to přesně tak mocné a děsivé, jak to zní.

Modul copyreg přidává podporu "piklení" pro uživatelské typy definované v C.

Modul queue implementuje frontu pro více producentů a více konzumentů.

Modul socketserver poskytuje obecné (generické) bázové třídy pro implementaci různých druhů soketových serverů.

Modul configparser zpracovává konfigurační soubory ve stylu INI.

Modul reprlib reimplementuje zabudovanou funkci repr() s přidaným ovládáním. Lze předepsat, jak dlouhé mohou reprezentace být, než dojde k jejich ořezání.

Modul subprocess umožňuje vytvářet procesy, připojovat se k jejich rourám (pipe) a získávat jejich návratové kódy.

## A.10. Relativní importy uvnitř balíčku

Balíček je skupina souvisejících modulů, které se používají jako celek. Pokud se v Pythonu 2 moduly uvnitř balíčku potřebovaly odkazovat jeden na druhý, používali jsme příkaz import foo nebo from foo import Bar. V Pythonu 2 interpret hledal foo. py nejdříve uvnitř aktuálního balíčku a teprve potom prohledával ostatní adresáře z pythonovské vyhledávací cesty (sys. path). Python 3 funguje trošku jinak. Místo prohledávání aktuálního balíčku začne přímo pythonovskou vyhledávací cestou. Pokud chceme, aby jeden modul uvnitř balíčku importoval jiný modul ze stejného balíčku, musíme explicitně zadat relativní cestu mezi uvedenými moduly.

Dejme tomu, že bychom měli následující balíček s více soubory ve stejném adresáři:

```
chardet/
|
+--__init__.py
|
+--constants.py
|
+--mbcharsetprober.py
|
+--universaldetector.py
```

Teď předpokládejme, že universaldetector.py potřebuje importovat celý soubor constants.py a jednu třídu z mbcharsetprober.py. Jak to vlastně uděláme?

| Poznámky | Python 2                    | Python 3                     |
|----------|-----------------------------|------------------------------|
| [1]      | import constants            | from . import constants      |
| [2]      | from mbcharsetprober import | from .mbcharsetprober import |
|          | MultiByteCharSetProber      | MultiByteCharsetProber       |

- Pokud potřebujeme importovat celý modul odněkud z našeho balíčku, použijeme novou syntaxi from . import. Tečka ve skutečnosti označuje relativní cestu od tohoto souboru (universaldetector.py)
  - k souboru, který chceme importovat (constants.py). V tomto případě se nacházejí ve stejném adresáři, takže použijeme jednu tečku. Importovat můžeme i z rodičovského adresáře (from . . import jinymodul) nebo z podadresáře.
- Pokud chceme importovat určitou třídu nebo funkci z jiného modulu přímo do prostoru jmen našeho modulu, přidáme k cílovému modulu jako prefix relativní cestu bez koncového lomítka. V tomto případě se mbcharsetprober. py nachází ve stejném adresáři jako universaldetector. py, takže cestu vyjádříme jednou tečkou. Importovat můžeme i z rodičovského adresáře (from ...jinymodul import JinaTrida) nebo z podadresáře.

## A.11. Metoda iterátoru next()

V Pythonu 2 měly iterátory metodu next(), která vracela další položku z posloupnosti. V Pythonu 3 to stále platí, ale máme k dispozici také globální funkci next(), která přebírá iterátor jako argument.

| Poznámky | Python 2  | Python 3                                       |
|----------|---|--|
| [1]      | anIterator.next()                               | next(anIterator)                               |
| [2]      | <pre>funkce_ktera_vraci_iterator().next()</pre> | <pre>next(funkce_ktera_vraci_iterator())</pre> |
| [3]      | class A:  | class A:                                       |
|          | <pre>def next(self):</pre>                      | <pre>defnext(self):</pre>                      |
|          | pass  | pass   |
| [4]      | class A:  | žádná změna                                    |
|          | <pre>def next(self, x, y):</pre>                |  |
|          | pass  |  |
| [5]      | next = 42                                       | next = 42                                      |
|          | for an_iterator in a_sequence_of_iterators:     | for an_iterator in a_sequence_of_iterators:    |
|          | an_iterator.next()                              | an_iteratornext()                              |

- V nejjednodušším případě nyní místo volání metody iterátoru next() předáváme iterátor globální funkci next().
- Pokud máme funkci, která vrací iterátor, zavoláme ji a výsledek předáme funkci next(). (Skript 2to3 je dost chytrý na to, aby to převedl správně.)
- Pokud definujeme svou vlastní třídu a míníme ji použít jako iterátor, definujeme speciální metodu \_\_next\_\_().
- Pokud definujeme svou vlastní třídu a ta shodou okolností obsahuje metodu pojmenovanou next(), která přebírá jeden nebo víc argumentů, nechá ji skript 2to3 beze změny. Tato třída nemůže být použita jako iterátor, protože její metoda next() vyžaduje argumenty.
- Tohle je trošku ošemetné. Pokud máme lokální proměnnou pojmenovanou next, pak bude mít přednost před novou globální funkcí next(). V takovém případě budeme muset pro získání dalšího prvku posloupnosti volat speciální metodu iterátoru \_\_next\_\_(). (Alternativně bychom mohli refaktorizovat kód tak, že by lokální proměnná nebyla pojmenována next, ale to za nás 2to3 automaticky neudělá.)

## A.12. Globální funkce filter()

V Pythonu 2 vracela funkce filter() seznam, který byl výsledkem filtrování posloupnosti přes funkci, která pro každý prvek posloupnosti vracela hodnotu True nebo False. V Pythonu 3 funkce filter() nevrací seznam, ale iterátor.

| Λ | -1 | 0 |
|---|----|---|
|   |    |   |

| Poznámky | Python 2                                    | Python 3                             |
|----------|---|--------------------------------------|
| [1]      | filter(a_function, a_sequence)              | list(filter(a_function, a_sequence)) |
| [2]      | list(filter(a_function, a_sequence))        | žádná změna                          |
| [3]      | filter(None, a_sequence)                    | [i for i in a_sequence if i]         |
| [4]      | for i in filter(None, a_sequence):          | žádná změna                          |
| [5]      | [i for i in filter(a_function, a_sequence)] | žádná změna                          |

- V nejzákladnějším případě obalí skript 2to3 volání funkce filter() voláním funkce list(). [1] Tím se provede průchod přes všechny hodnoty a vrátí se skutečný seznam.
- Pokud je ale volání funkce filter() už obaleno v list(), nebude 2to3 dělat nic, protože [2] skutečnost, že filter() vrací iterátor v takovém případě není důležitá.
- Speciální syntaxi filter (None, ...) skript 2to3 nahradí použitím sémanticky shodné [3] generátorové notace seznamu.
- V kontextu podobajícímu se cyklům for, kdy stejně dochází k průchodu celou posloupností, [4] není nutné provádět žádné změny.
- Ani zde se nemusí dělat žádné změny, protože generátorová notace seznamu bude iterovat [5] přes všechny prvky posloupnosti, a to může udělat, ať už filter() vrací iterátor nebo seznam.

#### A.13. Globální funkce map()

Funkce map() nyní vrací iterátor. Jde o stejný případ jako u funkce filter(). (V Pythonu 2 se vracel seznam.)

| Poznámky | Python 2                                 | Python 3                            |
|----------|--|-------------------------------------|
| [1]      | map(a_function, 'PapayaWhip')            | list(map(a_function, 'PapayaWhip')) |
| [2]      | map(None, 'PapayaWhip')                  | list('PapayaWhip')                  |
| [3]      | map(lambda x: x+1, range(42))            | [x+1 for x in range(42)]            |
| [4]      | for i in map(a_function, a_sequence):    | žádná změna                         |
| [5]      | [i for i in map(a_function, a_sequence)] | žádná změna                         |

- Stejně jako u filter() v nejzákladnějším případě obalí skript 2to3 volání funkce map() voláním [1]
- Speciální syntaxi map(None, ...), vyjadřující funkci identity, převede skript 2to3 na ekvivalent-[2] ní volání list().
- Pokud je prvním argumentem map() lambda funkce, převede 2to3 zápis s využitím odpovídající [3] generátorové notace seznamu.
- V kontextu jako u cyklů for, které stejně procházejí celou posloupností, není nutné provádět změny. [4]
- Ani zde se nemusí dělat žádné změny, protože generátorová notace seznamu předepisuje prů-[5] chod přes všechny prvky posloupnosti, a to může udělat, ať už map() vrací iterátor nebo seznam.

A.14. Globální funkce reduce() A.15. Globální funkce apply() A.16. Globální funkce intern()

## A.14. Globální funkce reduce()

V Pythonu 3 byla funkce reduce() vyňata z globálního prostoru jmen a umístěna do modulu functools.

| Python 2        | Python 3                     |
|-----------------|------------------------------|
| reduce(a, b, c) | from functools import reduce |
|                 | reduce(a, b, c)              |

## A.15. Globální funkce apply()

V Pythonu 2 existovala globální funkce apply(), která přebírala funkci f a seznam [a, b, c] a vrátila f(a, b, c). Stejné věci můžeme dosáhnout tím, že funkci zavoláme přímo a před předávaný seznam argumentů připíšeme hvězdičku. V Pythonu 3 již funkce apply() neexistuje. Musíme použít zápis s hvězdičkou.

| Poznámky | Python 2                                  | Python 3                            |
|----------|---|-------------------------------------|
| [1]      | apply(a_function, a_list_of_args)         | a_function(*a_list_of_args)         |
| [2]      | apply(a_function, a_list_of_args,         | a_function(*a_list_of_args,         |
|          | a_dictionary_of_named_args)               | **a_dictionary_of_named_args)       |
| [3]      | apply(a_function, a_list_of_args + z)     | a_function(*a_list_of_args + z)     |
| [4]      | apply(aModule.a_function, a_list_of_args) | aModule.a_function(*a_list_of_args) |

- V nejjednodušším případě můžeme funkci při volání předat seznam argumentů (skutečný seznam, jako například [a, b, c]) přidáním hvězdičky před seznam (\*). Jde o přesný ekvivalent staré funkce apply() z Pythonu 2.
- V Pythonu 2 může funkce apply() ve skutečnosti přebírat tři parametry: funkci, seznam argumentů a slovník s pojmenovanými argumenty. V Pythonu 3 můžeme téhož dosáhnout přidáním hvězdičky před seznam argumentů (\*) a přidáním dvou hvězdiček před slovník pojmenovaných argumentů (\*\*).
- Zde se operátor + používá pro zřetězení seznamů. Operátor + má vyšší prioritu než operátor \*, takže kolem a\_list\_of\_args + z nemusíme přidávat závorky.
- [4] Skript 2to3 je dost chytrý na to, aby převedl i složitá volání apply(), včetně volání funkcí z importovaných modulů.

#### A.16. Globální funkce intern()

V Pythonu 2 bylo možné "internovat" řetězec voláním funkce intern(), čímž došlo k optimalizaci výkonu při práci s tímto řetězcem. V Pythonu 3 byla funkce intern() přesunuta do modulu sys.

| Python 2        | Python 3            |
|-----------------|---------------------|
| intern(aString) | sys.intern(aString) |

#### A.17. Příkaz exec

Příkaz exec se v Pythonu 3 změnil na funkci stejně, jako se na funkci změnil příkaz print. Funkce exec() přebírá řetězec, který obsahuje libovolný pythonovský kód, a provede jej, jako kdyby to byl nějaký příkaz nebo výraz. Funkce exec() se podobá eval(), ale je ještě mocnější a zlověstnější. Funkce eval() může vyhodnocovat jediný výraz, ale funkce exec() může provést více příkazů, importů, deklarací funkcí — v podstatě celý pythonovský program, předaný jako řetězec.

| Poznámky | Python 2                               | Python 3  |
|----------|--|---|
| [1]      | exec codeString                        | exec(codeString)                                |
| [2]      | exec codeString in a_global_namespace  | exec(codeString, a_global_namespace)            |
| [3]      | exec codeString in a_global_namespace, | <pre>exec(codeString, a_global_namespace,</pre> |
|          | a_local_namespace                      | a_local_namespace)                              |

- V nejjednodušším případě skript 2to3 prostě uzavře kód v podobě řetězce do závorek, protože exec() je teď funkce a ne příkaz.
- Původní příkaz exec mohl přebírat prostor jmen v podobě soukromého prostředí s globálními jmény, ve kterém se měl kód v podobě řetězce provádět. V Pythonu 3 lze dělat totéž. Prostor jmen se funkci exec() jednoduše předá jako druhý parametr.
- Původní příkaz exec umožňoval dokonce přebírat lokální prostor jmen (podobající se prostoru proměnných definovaných uvnitř nějaké funkce). V Pythonu 3 to funkce exec() dokáže také.

#### A.18. Příkaz execfile

Původní příkaz execfile, podobně jako původní příkaz exec, spouštěl řetězce, ve kterých byl uložen pythonovský kód. Tam, kde exec přebíral řetězec, execfile přebíral jméno souboru. Z Pythonu 3 byl příkaz execfile vyřazen. Pokud opravdu chcete použít soubor s pythonovským kódem a spustit jej (ale nechcete jej přitom jednoduše importovat), můžete stejné funkčnosti dosáhnout otevřením souboru, načtením jeho obsahu, zavoláním globální funkce compile() (aby byl pythonovský interpret donucen kód přeložit) a nakonec zavoláním nové funkce exec().

| Python 2               | Python 3   |
|------------------------|--|
| execfile('a_filename') | <pre>exec(compile(open('a_filename').read(),</pre> |
|                        | 'a_filename', 'exec'))                             |

## A.19 repr-literály (zpětné apostrofy)

V Pythonu 2 bylo možné získat reprezentaci objektu použitím speciální syntaxe, kdy se libovolný objekt obalil zpětnými apostrofy (backticks; jako například 'x'). V Pythonu 3 tato schopnost stále existuje, ale už ji nemůžeme vyvolat použitím zpětných apostrofů. Místo nich musíme použít globální funkci repr().

| Poznámky | Python 2             | Python 3                     |
|----------|----------------------|------------------------------|
| [1]      | 'x'                  | repr(x)                      |
| [2]      | \'PapayaWhip' + \2\\ | repr('PapayaWhip' + repr(2)) |

- Připomeňme si, že x může být cokoliv třída, funkce, modul, primitivní datový typ atd. Funkce repr() funguje na všechno.
- V Pythonu 2 mohly být zpětné apostrofy zanořeny, což vedlo k tomuto druhu matoucích (ale platných) výrazů. Skript 2to3 je dost chytrý na to, aby zápis převedl na zanořené volání repr().

#### A.20. Příkaz try...except

Syntaxe pro odchytávání výjimek se mezi verzemi Python 2 a Python 3 mírně změnila.

| Poznámky | Python 2                              | Python 3                                |
|----------|---------------------------------------|---|
| [1]      | try:                                  | try:                                    |
|          | import mymodule                       | import mymodule                         |
|          | except ImportError, e                 | except ImportError as e:                |
|          | pass                                  | pass                                    |
| [2]      | try:                                  | try:                                    |
|          | import mymodule                       | import mymodule                         |
|          | except (RuntimeError, ImportError), e | except (RuntimeError, ImportError) as e |
|          | pass                                  | pass                                    |
| [3]      | try:                                  | žádná změna                             |
|          | import mymodule                       |   |
|          | except ImportError:                   |   |
|          | pass                                  |   |
| [4]      | try:                                  | žádná změna                             |
|          | import mymodule                       |   |
|          | except:                               |   |
|          | pass                                  |   |

- [1] Místo čárky se za typem výjimky v Pythonu 3 používá nové klíčové slovo as.
- [2] Klíčové slovo as funguje i pro odchytávání více typů výjimek najednou.
- Pokud výjimku jen odchytíme, ale ve skutečnosti nás nezajímá možnost přistupování k samotnému objektu výjimky, pak se syntaxe používaná v Pythonu 2 shoduje se syntaxí v Pythonu 3.
- [4] Podobně, pokud používáme záchranu v podobě odchytávání všech výjimek, je syntaxe identická.
- > Nouzové odchytávání všech výjimek byste nikdy neměli používat při importování modulů (ani ve většině ostatních případů). Tímto způsobem odchytíte i věci jako KeyboardInterrupt (pokud se uživatel pokoušel o přerušení činnosti programu stiskem Ctrl-C) a ztížíte si tím ladění.

## A.21. Příkaz raise

Syntaxe pro vyvolávání našich vlastních výjimek se mezi verzemi Python 2 a Python 3 mírně změnila.

| Poznámky | Python 2                            | Python 3                            |
|----------|-------------------------------------|-------------------------------------|
| [1]      | raise MyException                   | žádná změna                         |
| [2]      | raise MyException, 'error message'  | raise MyException('error message')  |
| [3]      | raise MyException, 'error message', | raise MyException('error message'). |
|          | a_traceback                         | with_traceback(a_traceback)         |
| [4]      | raise 'error message'               | nepodporováno                       |

- Při použití nejjednodušší formy, vyvolání výjimky bez uživatelské chybové zprávy, se syntaxe nezměnila.
- Změny si povšimneme, když chceme vyvolat výjimku s uživatelským chybovým hlášením. Python 2 odděloval třídu výjimky a uživatelskou zprávu čárkou. Python 3 předává chybovou zprávu jako parametr.
- Python 2 podporoval při složitější syntaxi vyvolání výjimky s uživatelským zpětným trasováním (stack trace). V Pythonu 3 toho můžeme dosáhnout také, ale syntaxe se docela liší.
- V Pythonu 2 jsme mohli vyvolat výjimku, aniž jsme zadávali třídu výjimky. Stačilo zadat chybovou zprávu. V Pythonu 3 to již není možné. Skript 2to3 vás bude varovat, že nebyl schopen tuto situaci opravit automaticky.

#### A.22. Metoda generátorů throw

V Pythonu 2 definovaly generátory metodu throw(). Volání a\_generator.throw() vyvolá výjimku v místě, kde se generátor zastavil. Potom se vrací další hodnota, která je vyprodukována (yield) generátorovou funkcí. V Pythonu 3 je uvedená funkčnost stále k dispozici, ale syntaxe se trochu změnila.

| Poznámky | Python 2                           | Python 3                             |
|----------|------------------------------------|--------------------------------------|
| [1]      | a_generator.throw(MyException)     | žádná změna                          |
| [2]      | a_generator.throw(MyException,     | a_generator.throw(MyException('error |
|          | 'error message')                   | message'))                           |
| [3]      | a_generator.throw('error message') | nepodporováno                        |

- [1] V nejjednodušším případě generátor vyvolává výjimku bez uživatelské chybové zprávy. V tomto případě se syntaxe v Pythonu 3 vůči Pythonu 2 nezměnila.
- Pokud generátor vyvolává výjimku s uživatelskou chybovou zprávou, musíme řetězec se zprávou [2] předat vytvářenému objektu výjimky.
- Python 2 podporoval vyvolání výjimky, která byla tvořena pouze uživatelským chybovým hláše-[3] ním. Python 3 toto chování nepodporuje a skript 2to3 zobrazí varování, které říká, že to budete muset opravit ručně.

#### Globální funkce xrange() A.23.

V Pythonu 2 existovaly dva způsoby získávání hodnot intervalu čísel: funkce range() vracela seznam a funkce xrange(), vracela iterátor. V Pythonu 3 funkce range() vrací iterátor a funkce xrange() už neexistuje.

| Poznámky | Python 2                | Python 3                 |
|----------|-------------------------|--------------------------|
| [1]      | xrange(10)              | range(10)                |
| [2]      | a_list = range(10)      | a_list = list(range(10)) |
| [3]      | [i for i in xrange(10)] | [i for i in range(10)]   |
| [4]      | for i in range(10):     | žádná změna              |
| [5]      | sum(range(10))          | žádná změna              |

- V nejjednodušším případě skript 2to3 jednoduše změní xrange() na range(). [1]
- Pokud kód pro Python 2 používal range(), pak skript 2to3 neví, zda jsme skutečně potřebovali [2] seznam, nebo zda by vyhověl iterátor. V rámci opatrnosti se vracená hodnota převádí na seznam voláním funkce list().
- Pokud by byla funkce xrange() použita uvnitř generátorového zápisu seznamu, pak je skript [3] 2to3 dost chytrý na to, aby funkci range() neobalil voláním list(). Generátorový zápis seznamu bude bez problémů fungovat s iterátorem, který je funkcí range() vrácen.
- Bez problémů bude s iterátorem fungovat i cyklus for, takže ani zde není nutné nic měnit. [4]
- Funkce sum() pracuje s iterátorem také, takže 2to3 nemusí nic měnit ani zde. Uvedený přístup [5] se, stejně jako v případě metod slovníku, které vracejí pohledy (view) místo seznamů, aplikuje i u funkci min(), max(), sum(), list(), tuple(), set(), sorted(), any() a all().

## A.24. Globální funkce raw\_input() a input()

Python 2 poskytoval pro vyžádání si uživatelského vstupu z příkazové řádky dvě globální funkce. První z nich, zvaná input(), očekávala, že uživatel vloží pythonovský výraz (vrací se jeho výsledek). Druhá z nich, zvaná raw\_input(), vracela to, co uživatel napsal. Začátečníky to velmi mátlo a považovalo se to za "bradavici" (wart) na jazyce. Python 3 tuto nepěknost řeší přejmenováním raw\_input() na input(), takže to funguje způsobem, který většina naivně očekává.

| Poznámky | Python 2            | Python 3                   |
|----------|---------------------|----------------------------|
| [1]      | raw_input()         | input()                    |
| [2]      | raw_input('prompt') | <pre>input('prompt')</pre> |
| [3]      | input()             | eval(input())              |

- [1] V nejjednodušším případě se raw\_input() mění na input().
- V Pythonu 2 mohla funkce raw\_input() přebírat vyzývací řetězec jako parametr. Tato možnost je zachována i v Pythonu 3.
- Pokud chcete, aby se opravdu vyhodnocoval pythonovský výraz zadaný uživatelem, použijte funkci input() a předejte její výsledek funkci eval().

## A.25. Atributy funkcí func\_\*

V Pythonu 2 může kód uvnitř funkce přistupovat ke speciálním atributům, které se týkají funkce samotné. V Pythonu 3 byly tyto speciální atributy funkcí přejmenovány, aby se dostaly do souladu s ostatními atributy.

| Poznámky | Python 2                 | Python 3           |
|----------|--------------------------|--------------------|
| [1]      | a_function.func_name     | a_functionname     |
| [2]      | a_function.func_doc      | a_functiondoc      |
| [3]      | a_function.func_defaults | a_functiondefaults |
| [4]      | a_function.func_dict     | a_functiondict     |
| [5]      | a_function.func_closure  | a_functionclosure  |
| [6]      | a_function.func_globals  | a_functionglobals  |
| [7]      | a_function.func_code     | a_functioncode     |

- [1] Atribut \_\_name\_\_ (dříve func\_name) obsahuje jméno funkce.
- [2] Atribut \_\_doc\_\_ (dříve func\_doc) obsahuje *dokumentační řetězec*, který byl definován ve zdrojovém textu funkce.
- Atribut \_\_defaults\_\_ (dříve func\_defaults) je n-tice obsahující výchozí hodnoty argumentů pro ty z argumentů, pro které byly výchozí hodnoty definovány.

- [4] Atribut \_\_dict\_\_ (dříve func\_dict) je prostor jmen uchovávající libovolné atributy funkce.
- Atribut \_\_closure\_\_ (dříve func\_closure) je n-tice buněk, které obsahují vazby (bindings) na volné proměnné, které se ve funkci používají.
- Atribut \_\_globals\_\_ (dříve func\_globals) je odkaz na globální prostor jmen modulu, ve kterém byla funkce definována.
- Atribut \_\_code\_\_ (dříve func\_code) je objekt kódu (code object), reprezentující přeložené tělo funkce.

## A.26. Metoda xreadlines() V/V objektů

V Pythonu 2 měly souborové objekty metodu xreadlines(), která vracela iterátor procházející souborem po řádcích. Kromě jiného se to hodilo pro cykly for. Ve skutečnosti to byla tak užitečná metoda, že pozdější verze Pythonu 2 přidaly schopnost iterovat samotným souborovým objektům.

V Pythonu 3 přestala metoda xreadlines() existovat. Skript 2to3 je schopen převést jednoduché případy, ale v hraničních situacích po vás bude vyžadovat ruční zásah.

| Poznámky | Python 2                          | Python 3                              |
|----------|-----------------------------------|---------------------------------------|
| [1]      | for line in a_file.xreadlines():  | for line in a_file:                   |
| [2]      | for line in a_file.xreadlines(5): | žádná změna (vede k nefunkčnímu kódu) |

- Pokud jste byli zvyklí volat xreadlines() bez argumentů, převede toto volání skript 2to3 jen na souborový objekt. V Pythonu 3 zajistí tento zápis stejnou funkčnost: čte se ze souboru řádek po řádku a provádí se tělo cyklu for.
- Pokud jste byli zvyklí volat xreadlines() s argumentem (počet řádků, které se mají načíst najednou), pak to skript 2to3 neopraví a váš kód selže s vysvětlením AttributeError: '\_io.

  TextIOWrapper' object has no attribute 'xreadlines'. Opravu pro Python 3 můžete ručně provést změnou xreadlines() na readlines(). (Metoda readlines() teď vrací iterátor, takže je to stejně efektivní, jako bylo xreadlines() v Pythonu 2.)

#### A.27. ambda funkce, které akceptují n-tici místo více parametrů

V Pythonu 2 jsme mohli definovat anonymní lambda funkci, která přebírá více parametrů, tím, že jsme ji definovali jako funkci, která přebírá n-tici s určeným počtem položek. V důsledku toho Python 2 "rozbalil" n-tici do pojmenovaných argumentů, na které jsme se pak mohli uvnitř lambda funkce odkazovat jménem. V Pythonu 3 můžeme lambda funkci také předávat n-tici, ale pythonovský interpret ji nerozbalí do pojmenovaných argumentů. Místo toho se budeme muset na jednotlivé argumenty odkazovat pozičním indexem.

| Poznámky | Python 2                      | Python 3                             |
|----------|-------------------------------|--------------------------------------|
| [1]      | lambda $(x,): x + f(x)$       | lambda x1: x1[0] + f(x1[0])          |
| [2]      | lambda (x, y): x + f(y)       | lambda x_y: x_y[0] + f(x_y[1])       |
| [3]      | lambda (x, (y, z)): x + y + z | lambda x_y_z: x_y_z[0] + x_y_z[1][0] |
|          |                               | + x_y_z[1][1]                        |
| [4]      | lambda x, y, z: x + y + z     | žádná změna                          |

- Pokud jsme definovali lambda funkci, která přebírá n-tici s jedním prvkem, stane se z ní v Pythonu 3 lambda funkce, která se odkazuje na x1[0]. Jméno x1 je generováno skriptem 2to3 automaticky, na základě pojmenovaných argumentů původní n-tice.
- lambda funkce s dvouprvkovou n-ticí (x, y) bude převedena na x\_y s pozičními argumenty  $x_y[0]$  a  $x_y[1]$ .
- Skript 2to3 zvládne dokonce 1ambda funkce s vnořenými n-ticemi pojmenovaných argumentů. Výsledný kód v Pythonu 3 je poněkud nečitelný, ale funguje stejným způsobem, jakým fungoval původní kód v Pythonu 2.
- [4] Můžeme definovat lambda funkce, které přebírají víc argumentů. Pokud kolem argumentů neuvedeme závorky, chová se Python 2 k zápisu jako k lambda funkci s více argumenty. Uvnitř lambda funkce se na pojmenované argumenty odkazujeme jménem jako v každé jiné funkci. V Pythonu 3 tato syntaxe pořád funguje.

#### A.28. Atributy speciálních metod

V Pythonu 2 se mohly metody tříd odkazovat na objekt třídy, ve které jsou definovány, a také na samotný objekt metody. Reference im\_self odkazovala na objekt instance třídy, im\_func na objekt funkce a im\_class se odkazuje na třídu objektu im\_self. V Pythonu 3 byly tyto speciální atributy metod přejmenovány, aby se dostaly do souladu s pojmenováním ostatních atributů.

| Python 2                             | Python 3                             |
|--------------------------------------|--------------------------------------|
| aClassInstance.aClassMethod.im_func  | aClassInstance.aClassMethodfunc      |
| aClassInstance.aClassMethod.im_self  | aClassInstance.aClassMethodself      |
| aClassInstance.aClassMethod.im_class | aClassInstance.aClassMethodselfclass |

#### A.29. Speciální metoda \_\_nonzero\_\_

V Pythonu 2 jsme mohli vytvářet své vlastní třídy, které se daly používat v booleovském kontextu. Mohli jsme například vytvořit instanci takové třídy a pak ji použít v příkazu if. Dělalo se to tak, že jsme definovali speciální metodu \_\_nonzero\_\_(), která vracela True nebo False. Ta se volala, kdykoliv byla instance použita v booleovském kontextu. V Pythonu 3 lze dělat totéž, ale jméno metody bylo změněno na \_\_bool\_\_().

| Poznámky | Python 2                | Python 3                  |
|----------|-------------------------|---------------------------|
| [1]      | class A:                | class A:                  |
|          | defnonzero(self):       | <pre>defbool(self):</pre> |
|          | pass                    | pass                      |
| [2]      | class A:                | žádná změna               |
|          | defnonzero(self, x, y): |                           |
|          | pass                    |                           |

- Při vyhodnocování instance v booleovském kontextu se v Pythonu 3 místo \_\_nonzero\_\_() volá metoda \_\_bool\_\_().
- Pokud ale máme definovánu metodu \_\_nonzero\_\_(), která vyžaduje nějaké argumenty, bude nástroj 2to3 předpokládat, že jsme ji používali pro nějaký jiný účel, a neprovede žádné změny.

#### A.30. Oktalové literály

Syntaxe pro zápis čísel v osmičkové soustavě (tj. oktalových) se mezi Pythonem 2 a Pythonem 3 mírně změnila.

| Python 2 | Python 3  |
|----------|-----------|
| x = 0755 | x = 00755 |

#### A.31. sys.maxint

V souvislosti se sloučením typů long a int pozbyla konstanta sys.maxint vypovídací přesnost. Tato hodnota může být stále užitečná při zjišťování schopností závislých na platformě. Proto byla v Pythonu ponechána, ale byla přejmenována na sys.maxsize.

| Poznámky | Python 2               | Python 3                |
|----------|------------------------|-------------------------|
| [1]      | from sys import maxint | from sys import maxsize |
| [2]      | a_function(sys.maxint) | a_function(sys.maxsize) |

- [1] Z maxint se stává maxsize.
- [2] Jakékoliv použití sys.maxint se mění na sys.maxsize.

A.32. Globální funkce callable()A.33. Globální funkce zip()A.34. Výjimka StandardError

#### A.32. Globální funkce callable()

V Pythonu 2 jsme mohli voláním globální funkce callable() zkontrolovat, zda se dá objekt volat (jako funkce). Z Pythonu 3 byla tato globální funkce vyřazena. Pokud chceme zjistit, zda se dá objekt volat, musíme zkontrolovat, zda má speciální metodu \_\_call\_\_().

| Python 2           | Python 3                  |
|--------------------|---------------------------|
| callable(anything) | hasattr(anything, 'call') |

#### A.33. Globální funkce zip()

V Pythonu 2 přebírala globální funkce zip() libovolný počet posloupností a vracela seznam n-tic. První n-tice obsahovala první položky ze všech posloupností, druhá n-tice obsahovala druhé položky ze všech posloupností a tak dále. V Pythonu 3 vrací funkce zip() místo seznamu iterátor.

| Poznámky | Python 2             | Python 3           |
|----------|----------------------|--------------------|
| [1]      | zip(a, b, c)         | list(zip(a, b, c)) |
| [2]      | d.join(zip(a, b, c)) | žádná změna        |

- Nejjednodušší způsob dosažení původního chování funkce zip() spočívá v obalení návratové hodnoty voláním list(). Tím dojde k průchodu všemi hodnotami iterátoru vraceného funkcí zip() a vytvoří se skutečný seznam výsledků.
- V kontextu, kde se již využívá iterace přes všechny položky posloupnosti (jako například při volání této metody join()), funguje iterátor vracený funkcí zip() bez problémů. Skript 2to3 je dost chytrý na to, aby takové případy detekoval a neprováděl ve vašem kódu žádné změny.

#### A.34. Výjimka StandardError

V Pythonu 2 byla StandardError bázovou třídou všech zabudovaných výjimek — až na StopIteration, GeneratorExit, KeyboardInterrupt a SystemExit. V Pythonu 3 byla třída StandardError zrušena. Místo ní se používá třída Exception.

| Python 2                   | Python 3               |
|----------------------------|------------------------|
| x = StandardError()        | x = Exception()        |
| x = StandardError(a, b, c) | x = Exception(a, b, c) |

### A.35. Konstanty modulu types

Modul types obsahuje širokou paletu konstant, které nám pomáhají určovat typ objektu. V Pythonu 2 obsahoval konstanty pro všechny primitivní typy, jako jsou dict a int. Z Pythonu 3 byly tyto konstanty odstraněny. Místo nich se používá jméno primitivního typu.

| Python 2                 | Python 3             |
|--------------------------|----------------------|
| types.UnicodeType        | str                  |
| types.StringType         | bytes                |
| types.DictType           | dict                 |
| types.IntType            | int                  |
| types.LongType           | int                  |
| types.ListType           | list                 |
| types.NoneType           | type(None)           |
| types.BooleanType        | bool                 |
| types.BufferType         | memoryview           |
| types.ClassType          | type                 |
| types.ComplexType        | complex              |
| types.EllipsisType       | type(Ellipsis)       |
| types.FloatType          | float                |
| types.ObjectType         | object               |
| types.NotImplementedType | type(NotImplemented) |
| types.SliceType          | slice                |
| types.TupleType          | tuple                |
| types.TypeType           | type                 |
| types.XRangeType         | range                |

> types.StringType se převádí na bytes a ne na str, protože "řetězec" v Pythonu 2 (ne Unicode řetězec, ale obyčejný řetězec) je ve skutečnosti jen posloupností bajtů odpovídajících určitému znakovému kódování.

#### A.36. Globální funkce isinstance()

Funkce isinstance() kontroluje, zda je objekt instancí určité třídy nebo typu. V Pythonu 2 jsme mohli předat n-tici typů a isinstance() vrátila True, pokud byl objekt jedním z uvedených typů. V Pythonu 3 lze dělat totéž, ale předávání stejného typu dvakrát se považuje za nežádoucí (deprecated).

| Python 2                                    | Python 3                    |
|---|-----------------------------|
| <pre>isinstance(x, (int, float, int))</pre> | isinstance(x, (int, float)) |

- A.37. Datový typ basestring
- A.38. itertools module
- A.39. sys.exc\_type, sys.exc\_value, sys.exc\_traceback

#### A.37. Datový typ basestring

Python 2 pracoval s dvěma typy řetězců: Unicode a ne-Unicode. Ale existoval v něm ještě jeden typ, basestring. Jednalo se o abstraktní typ, nadtřídu jak pro typ str, tak pro typ unicode. Nebylo možné ji volat nebo z ní vytvářet instanci přímo, ale mohli jste ji předat globální funkci isinstance(), když jste chtěli zkontrolovat, zda je objekt buď Unicode, nebo ne-Unicode řetězcem. V Pythonu 3 existuje jediný řetězcový typ, takže důvod k existenci typu basestring pominul.

| Python 2                  | Python 3           |
|---------------------------|--------------------|
| isinstance(x, basestring) | isinstance(x, str) |

#### A.38. itertools module

Python 2.3 zavedl modul itertools, který definoval varianty globálních funkcí zip(), map() a filter(), které místo seznamu vracely iterátory. V Pythonu 3 tyto globální funkce vracejí iterátory, takže uvedené funkce byly z modulu itertools odstraněny. (V modulu itertools je stále mnoho užitečných funkcí, nejen ty právě zmíněné.)

| Poznámky | Python 2                              | Python 3                  |
|----------|---------------------------------------|---------------------------|
| [1]      | itertools.izip(a, b)                  | zip(a, b)                 |
| [2]      | itertools.imap(a, b)                  | map(a, b)                 |
| [3]      | itertools.ifilter(a, b)               | filter(a, b)              |
| [4]      | from itertools import imap, izip, foo | from itertools import foo |

- [1] Místo itertools.izip() použijte jednoduše globální funkci zip().
- [2] Místo itertools.imap() použijte jednoduše map().
- [3] Z itertools.ifilter() se stává filter().
- [4] Modul itertools v Pythonu 3 pořád existuje. Jen v něm chybí funkce, které byly přesunuty do globálního prostoru jmen. Skript 2to3 je dost chytrý na to, aby odstranil importy, které neexistují, a ponechal ostatní importy nedotčené.

#### A.39. sys.exc\_type, sys.exc\_value, sys.exc\_traceback

U Pythonu 2 se v modulu sys nacházely tři proměnné, které jsme mohli používat během obsluhy výjim-ky: sys.exc\_type, sys.exc\_value, sys.exc\_traceback. (Ve skutečnosti mají původ už v Pythonu 1.) Už od Pythonu 1.5 bylo používání těchto proměnných považováno za nežádoucí (deprecated) ve prospěch sys.exc\_info(), což je funkce vracející n-tici se všemi třemi hodnotami. V Pythonu 3 byly tyto tři individuální proměnné nakonec odstraněny. Musíme používat funkci sys.exc\_info().

- A.40. Generátory seznamů nad n-ticemi
- A.41. Funkce os.getcwdu()
- A.42. Metatřídy

| Python 2          | Python 3          |
|-------------------|-------------------|
| sys.exc_type      | sys.exc_info()[0] |
| sys.exc_value     | sys.exc_info()[1] |
| sys.exc_traceback | sys.exc_info()[2] |

#### A.40. Generátory seznamů nad n-ticemi

Pokud jsme v Pythonu 2 chtěli použít generátorovou notaci seznamu, která předepisovala iteraci přes n-tici, nemuseli jsme hodnoty n-tice uzavírat do kulatých závorek. V Pythonu 3 se explicitní závorky vyžadují.

| Python 2          | Python 3            |  |
|-------------------|---------------------|--|
| [i for i in 1, 2] | [i for i in (1, 2)] |  |

#### A.41. Funkce os.getcwdu()

V Pythonu 2 byla k dispozici funkce pojmenovaná os.getcwd(), která vracela aktuální pracovní adresář jako (ne-Unicode) řetězec. Protože moderní souborové systémy umí pracovat se jmény adresářů v libovolném znakovém kódování, zavedl Python 2.3 funkci os.getcwdu(). Funkce os.getcwdu() vracela aktuální pracovní adresář jako Unicode řetězec. V Pythonu 3 existuje jediný řetězcový typ (Unicode), takže os.getcwd() je vším, co potřebujeme.

| Python 2     | Python 3    |
|--------------|-------------|
| os.getcwdu() | os.getcwd() |

#### A.42. Metatřídy

V Pythonu 2 jsme mohli metatřídy vytvářet buď definicí argumentu metaclass v deklaraci třídy, nebo definicí speciálního atributu \_\_metaclass\_\_ na úrovni třídy. V Pythonu 3 byl tento atribut třídy odstraněn.

| Poznámky | Python 2                       | Python 3  |  |  |
|----------|--------------------------------|---|--|--|
| [1]      | class C(metaclass=PapayaMeta): | žádná změna                                     |  |  |
|          | pass                           |   |  |  |
| [2]      | class Whip:                    | class Whip(metaclass=PapayaMeta):               |  |  |
|          | metaclass = PapayaMeta         | pass  |  |  |
| [3]      | class C(Whipper, Beater):      | class C(Whipper, Beater, metaclass=PapayaMeta): |  |  |
|          | metaclass = PapayaMeta         | pass  |  |  |

- Deklarace metatřídy v místě deklarace třídy fungovala v Pythonu 2 a funguje stejně i v Pythonu 3. [1]
- Deklarace metatřídy pomocí atributu třídy fungovala v Pythonu 2, ale v Pythonu 3 již ne. [2]
- Skript 2to3 je dost chytrý na to, aby zkonstruoval platnou deklaraci třídy dokonce i v přípa-[3] dech, kdy třída dědí z jedné nebo více bázových tříd.

#### A.43. Věci týkající se stylu

Zbytek zde popsaných "oprav" ve skutečnosti nejsou opravy jako takové. Tyto úpravy nemění podstatu, ale styl. Jde o věci, které fungují jak v Pythonu 2, tak v Pythonu 3. Vývojáři Pythonu ale mají zájem na tom, aby byl pythonovský kód tak jednotný, jak je to jen možné. Z tohoto pohledu existuje oficiální Python style guide (Průvodce stylem jazyka Python), který popisuje — až do nesnesitelnosti — všechny možné detaily, které vás téměř určitě nezajímají. A když už 2to3 vytváří tak mohutnou infrastrukturu pro konverzi pythonovského kódu z jedné podoby do druhé, vzali si autoři za své přidat pár nepovinných rysů, které by zlepšily čitelnost vašich pythonovských programů.

#### A.43.1. Množinové literály (set(); explicitně)

V Pythonu 2 bylo jediným možným vyjádřením definice množinového literálu volání set(posloupnost). V Pythonu 3 tato možnost stále funguje, ale čistší způsob spočívá v použití nového zápisu množinového literálu: složené závorky. Funguje to pro všechny množiny s výjimkou prázdné množiny. Je to tím, že slovníky používají složené závorky také a zápis {} byl již vyhrazen pro prázdný slovník a ne pro prázdnou množinu.

> Skript 2to3 standardně množinové literály zapsané pomocí set() neupravuje. Pokud chceme tuto úpravu povolit, uvedeme při volání 2to3 na příkazovém řádku -f set\_literal (f jako fix).

| Před                         | Po                      |
|------------------------------|-------------------------|
| set([1, 2, 3])               | {1, 2, 3}               |
| set((1, 2, 3))               | {1, 2, 3}               |
| set([i for i in a_sequence]) | {i for i in a_sequence} |

#### A.43.2. Globální funkce buffer() (explicitně)

Pythonovské objekty implementované v jazyce C exportují takzvané "rozhraní bloku paměti" (buffer interface), které umožňuje ostatnímu pythonovskému kódu přímo číst blok paměti a zapisovat do něj. (Je to přesně tak mocné a děsivé, jak to zní.) V Pythonu 3 byla funkce buffer () přejmenována na memoryview(). (Ve skutečnosti je to sice o něco komplikovanější, ale rozdíly můžete téměř určitě ignorovat.)

> Skript 2to3 standardně funkci buffer() neopravuje. Pokud chceme tuto úpravu povolit, uvedeme při volání 2to3 na příkazovém řádku -f buffer.

| Před          | Po                |  |
|---------------|-------------------|--|
| x = buffer(y) | x = memoryview(y) |  |

#### A.43.3. Bílé znaky kolem čárek (explicitně)

Navzdory drakonickým pravidlům pro používání bílých znaků (whitespace) při odsazování a předsazování se Python chová docela volně k používání bílých znaků v jiných oblastech. Uvnitř seznamů, n-tic, množin a slovníků se mohou bílé znaky objevit před a za čárkami bez škodlivých účinků. Jenže Průvodce stylem jazyka Python říká, že před čárkami se nemá psát žádná mezera a za čárkou se má psát jedna. Ačkoliv se zde jedná o čistě estetickou záležitost (kód funguje tak jako tak, v Pythonu 2 i v Pythonu 3), skript 2to3 tuto věc může volitelně opravit.

> Skript 2to3 standardně psaní bílých znaků kolem čárek neupravuje. Pokud chceme tuto úpravu povolit, uvedeme při volání 2to3 na příkazovém řádku -f wscomma.

| Před   | Po     |
|--------|--------|
| a ,b   | a, b   |
| {a :b} | {a: b} |

#### A.43.3. Běžné obraty (explicitně)

V pythonovské komunitě postupně vznikla celá řada používaných obratů. Některé se datují až k Pythonu 1, jako například cyklus while 1:. (Až do verze 2.3 neměl Python opravdový booleovský typ, takže vývojáři místo pravdivostních hodnot používali 1 a 0.) Moderní pythonovští programátoři by své mozky měli natrénovat na modernější podobu takových obratů.

Skript 2to3 standardně opravu běžných obratů neprovádí. Pokud chceme tuto úpravu povolit, uvedeme při volání 2to3 na příkazovém řádku -f idioms.

| Před                        | Ро                          |
|-----------------------------|-----------------------------|
| while 1:                    | while True:                 |
| <pre>do_stuff()</pre>       | do_stuff()                  |
| type(x) == T                | isinstance(x, T)            |
| type(x) is T                | isinstance(x, T)            |
| a_list = list(a_sequence)   | a_list = sorted(a_sequence) |
| a_list.sort()               | <pre>do_stuff(a_list)</pre> |
| <pre>do_stuff(a_list)</pre> |                             |

- "My specialty is being right when other people are wrong." (Mou specialitou je mít pravdu, když se ostatní lidé mýlí.)
  - George Bernard Shaw

## B. Jména speciálních metod

| Jme | éna | spec | iáln | ích | met | tod | l — 4 | 105 |
|-----|-----|------|------|-----|-----|-----|-------|-----|
|-----|-----|------|------|-----|-----|-----|-------|-----|

- B.1. Ponořme se **407**
- B.2. Základy **407**
- B.3. Třídy, které se chovají jako iterátory 407
- B.4. Vypočítávané atributy 408
- B.5. Třídy, které se chovají jako funkce 411
- B.6. Třídy, které se chovají jako množiny 412
- B.7. Třídy, které se chovají jako slovníky 413
- B.8. Třídy, které se chovají jako čísla **414**
- B.9. Třídy, které se dají porovnávat 417
- B.10. Třídy, které podporují serializaci 418
- B.11. Třídy, které mohou být použity
  - v bloku with 418
- B.12. Opravdu esoterické věci 420
- B.13. Přečtěte si **420**

- B.1. Ponořme se
- B.2. Základy
- B.3. Třídy, které se chovají jako iterátory

#### B.1. Ponořme se

V celé knize jsme se setkávali s příklady "speciálních metod" — v jistém smyslu "magických" metod, které Python vyvolává, když použijeme určitou syntaxi. Pokud vaše třídy použijí speciální metody, mohou se chovat jako množiny, jako slovníky, jako funkce, jako iterátory nebo dokonce jako čísla. Tato příloha slouží jako referenční příručka ke speciálním metodám, se kterými jsme se už setkali, a jako stručný úvod k některým esoteričtějším speciálním metodám.

#### B.2. Základy

Pokud jste už četli úvod k třídám, už jste se setkali s nejběžnější speciální metodou, s metodou \_\_init\_\_(). Většina tříd, které píšeme, nakonec potřebuje nějakou inicializaci. Existuje několik dalších základních speciálních metod, které jsou zvlášť užitečné při ladění našich uživatelsky definovaných tříd.

| Poznámky | To, co chceme                      | Takže napíšeme                    | A Python zavolá      |  |
|----------|------------------------------------|-----------------------------------|----------------------|--|
| [1]      | inicializace instance              | x = MyClass()                     | xinit()              |  |
| [2]      | "oficiální" řetězcová reprezentace | repr(x)                           | xrepr()              |  |
| [3]      | "neformální" řetězcová podoba      | str(x)                            | xstr()               |  |
| [4]      | "neformální" podoba v poli bajtů   | bytes(x)                          | xbytes()             |  |
| [5]      | hodnota jako naformátovaný         | <pre>format(x, format_spec)</pre> | xformat(format_spec) |  |
|          | řetězec                            |                                   |                      |  |

- [1] Metoda \_\_init\_\_() se volá až poté, co byla instance vytvořena. Pokud chceme ovládat proces skutečného vytváření instance, musíme použít metodu \_\_new\_\_().
- [2] Metoda \_\_repr\_\_() by podle konvence měla vracet řetězec, který je platným pythonovským výrazem.
- [3] Metoda \_\_str\_\_() se volá také v případě, kdy použijeme print(x).
- [4] Novinka v Pythonu 3, která souvisí se zavedením typu bytes.
- Podle konvence by měl být format\_spec v souladu s minijazykem pro specifikaci formátu.

  Modul decimal.py z pythonovské standardní knihovny má svou vlastní metodu \_\_format\_\_().

#### B.3. Třídy, které se chovají jako iterátory

V kapitole o iterátorech jsme si ukázali, jak můžeme vytvořit iterátor od základů s využitím metod \_\_iter\_\_() a \_\_next\_\_().

| Poznámky | To, co chceme  | Takže napíšeme | A Python zavolá |
|----------|--|----------------|-----------------|
| [1]      | iterování přes posloupnost                             | iter(seq)      | seqiter()       |
| [2]      | získání další hodnoty iterátoru                        | next(seq)      | seqnext()       |
| [3]      | vytvoření iterátoru procházejícího<br>v opačném pořadí | reversed(seq)  | seqreversed()   |

- Metoda \_\_iter\_\_() se volá, kdykoliv vytváříme nový iterátor. Je to dobré místo pro nastavení [1] počátečních hodnot iterátoru.
- Metoda \_\_next\_\_() se volá, kdykoliv se snažíme o získání nové hodnoty iterátoru. [2]
- [3] Metoda \_\_reversed\_\_() se běžně nepoužívá. Vezme existující posloupnost a vrací iterátor, který produkuje prvky posloupnosti v opačném pořadí, tj. od posledního k prvnímu.

Jak jsme si ukázali v kapitole o iterátorech, cyklus for se může chovat jako iterátor. V následujícím cyklu:

```
for x in seq:
    print(x)
```

Python 3 vytvoří iterátor voláním seq.\_\_iter\_\_() a potom bude získávat hodnoty x voláním jeho metody \_\_next\_\_(). Jakmile metoda \_\_next\_\_() vyvolá výjimku StopIteration, cyklus for spořádaně skončí.

#### B.4. Vypočítávané atributy

| Poznámky | To, co chceme                        | Takže napíšeme        | A Python zavolá         |
|----------|--------------------------------------|-----------------------|-------------------------|
| 1]       | získat vypočítaný atribut            | x.my_property         | xgetattribute           |
|          | (nepodmíněně)                        |                       | ('my_property')         |
| [2]      | získat vypočítaný atribut (fallback) | x.my_property         | xgetattr('my_property') |
| [3]      | nastavit hodnotu atributu            | x.my_property = value | xsetattr('my_property', |
|          |                                      |                       | value)                  |
| [4]      | zrušit atribut                       | del x.my_property     | xdelattr('my_property') |
| [5]      | vypsat seznam atributů a metod       | dir(x)                | xdir()                  |

- Pokud třída definuje metodu \_\_getattribute\_\_(), zavolá ji Python při každém odkazu na [1] libovolný atribut nebo jméno metody (s výjimkou jmen speciálních metod, protože by tím vznikl nepříjemný nekonečný cyklus).
- Pokud třída definuje metodu \_\_getattr\_\_(), bude ji Python volat až poté, co atribut nenajde [2] na některém z běžných míst. Pokud instance x definuje atribut color, nepovede použití x.color k volání x.\_\_getattr\_\_('color'). Jednoduše se vrátí již definovaná hodnota x.color.
- Metoda \_\_setattr\_\_() se volá, kdykoliv chceme atributu přiřadit nějakou hodnotu. [3]
- Metoda \_\_delattr\_\_() se volá, kdykoliv chceme atribut zrušit. [4]
- [5] Metoda \_\_dir\_\_() je užitečná v případech, kdy definujeme metodu \_\_getattr\_\_() nebo metodu \_\_getattribute\_\_(). Normálně bychom voláním funkce dir(x) získali jen seznam běžných atributů a metod. Pokud například metoda \_\_getattr\_\_() vytváří atribut color dynamicky, nevypisoval by se color v seznamu vraceném funkcí dir(x) jako jeden z dostupných atributů. Předefinování metody \_\_dir\_\_() nám umožní vypsat color jako dostupný atribut. Může to být užitečné pro jiné programátory, kteří si přejí používat naši třídu, aniž by museli zkoumat její vnitřní možnosti.

Rozdíl mezi metodami \_\_getattr\_\_() a \_\_getattribute\_\_() je jemný, ale důležitý. Vysvětlíme si ho na dvou příkladech:

```
class Dynamo:
    def __getattr__(self, key):
        if key == 'color':
                                           [1]
            return 'PapayaWhip'
        else:
            raise AttributeError
                                           [2]
>>> dyn = Dynamo()
>>> dyn.color
                                           [3]
'PapayaWhip'
>>> dyn.color = 'LemonChiffon'
>>> dyn.color
                                           [4]
'LemonChiffon'
```

- Jméno atributu se předá metodě \_\_getattr\_\_() jako řetězec. Pokud je jméno rovno 'color', [1] vrátí metoda hodnotu. (V tomto případě se jedná o pevně zadaný řetězec, ale normálně bychom zde provedli nějaký výpočet a vrátili bychom řetězec.)
- Pokud jméno atributu neznáme, musí metoda \_\_getattr\_\_() vyvolat výjimku AttributeError. [2] V opačném případě by náš kód při přístupu k nedefinovanému atributu potichu selhal. (Pokud metoda nevyvolá výjimku nebo explicitně nevrátí nějakou hodnotu, pak — z technického hlediska — vrací None, což je pythonovská hodnota null. To znamená, že by všechny atributy, které by nebyly explicitně definovány, nabývaly hodnoty None. To téměř určitě nechceme.)
- Instance dyn nemá atribut jménem color, takže se zavolá metoda \_\_getattr\_\_(), která vrátí [3] vypočítanou hodnotu.
- Jakmile explicitně nastavíme dyn. color, přestane se metoda \_\_getattr\_\_() pro získání hodnoty [4] dyn. color volat, protože atribut dyn. color už je v instanci definován.

Ve srovnání s tím je metoda \_\_getattribute\_\_() absolutní a nepodmíněná.

```
class SuperDynamo:
    def __getattribute__(self, key):
        if key == 'color':
            return 'PapayaWhip'
        else:
            raise AttributeError
```

```
>>> dyn = SuperDynamo()
>>> dyn.color
                                           [1]
'PapayaWhip'
>>> dyn.color = 'LemonChiffon'
>>> dyn.color
                                           [2]
'PapayaWhip'
```

- Pro získání hodnoty dyn.color se volá metoda \_\_getattribute\_\_(). [1]
- Dokonce i když explicitně nastavíme dyn. color, bude se pro získávání hodnoty dyn. color [2] stále volat metoda \_\_getattribute\_\_(). Pokud je metoda \_\_getattribute\_\_() definována, volá se nepodmíněně při hledání každého atributu nebo metody. Platí to i pro atributy, které jsme po vytvoření instance explicitně nastavili (a tím vytvořili).
- Pokud vaše třída definuje metodu \_\_getattribute\_\_(), pak pravděpodobně chcete definovat > také metodu \_\_setattr\_\_(). Pro udržení přehledu o hodnotách atributů musíte mezi těmito metodami zajistit spolupráci. V opačném případě by se atributy nastavené po vytvoření instance ztrácely v černé díře.

U metody \_\_getattribute\_\_() musíme být velmi pečliví, protože ji Python používá i při hledání jmen metod třídy.

```
class Rastan:
```

```
def __getattribute__(self, key):
        raise AttributeError
                                          [1]
    def swim(self):
        pass
>>> hero = Rastan()
>>> hero.swim()
                                          [2]
Traceback (most recent call last):
  File "<stdin>", line 1, in <module>
  File "<stdin>", line 3, in __getattribute__
AttributeError
```

- Tato třída definuje metodu \_\_getattribute\_\_(), která vždy vyvolá výjimku AttributeError. [1] Hledání každého atributu nebo metody skončí neúspěšně.
- Pokud zavoláme hero.swim(), začne Python v třídě Rastan hledat metodu swim(). Hledání [2] prochází metodou \_\_getattribute\_\_(), protože hledání všech atributů a metod prochází metodou \_\_getattribute\_\_(). V tomto případě metoda \_\_getattribute\_\_() vyvolá výjimku AttributeError, takže hledání metody selže a tím pádem selže i její volání.

#### B.5. Třídy, které se chovají jako funkce

Pokud třída definuje metodu \_\_call\_\_(), můžeme instanci třídy volat (callable), jako kdyby to byla funkce.

| To, co chceme               | Takže napíšeme           | A Python zavolá              |  |
|-----------------------------|--------------------------|------------------------------|--|
| "volat" instaci jako funkci | <pre>my_instance()</pre> | <pre>my_instancecall()</pre> |  |

Modul zipfile tento způsob používá pro definici třídy, která umí zadaným heslem dešifrovat (decrypt) zašifrovaný (encrypted) zip soubor. Dešifrovací algoritmus pro zip vyžaduje, aby se během dešifrování ukládal stav. Pokud dešifrátor (decryptor) definujeme jako třídu, může si stav uchovávat uvnitř instance své třídy. Stav se inicializuje v metodě \_\_init\_\_() a aktualizuje se během dešifrování souboru. Ale protože je třída definována jako "volatelná" (jako funkce), můžeme instanci třídy předat jako první argument funkce map() takto:

```
# výňatek ze zipfile.py
class _ZipDecrypter:
    def __init__(self, pwd):
        self.key0 = 305419896
                                                   [1]
        self.key1 = 591751049
        self.key2 = 878082192
        for p in pwd:
            self._UpdateKeys(p)
    def __call__(self, c):
                                                   [2]
        assert isinstance(c, int)
        k = self.key2 \mid 2
        c = c ^ (((k * (k^1)) >> 8) & 255)
        self._UpdateKeys(c)
        return c
zd = _ZipDecrypter(pwd)
                                                   [3]
bytes = zef_file.read(12)
h = list(map(zd, bytes[0:12]))
                                                   [4]
```

Třída \_ZipDecryptor udržuje stav v podobě tří rotujících klíčů, které se později aktualizují metodou \_UpdateKeys() (zde neukázána).

- Třída definuje metodu \_\_call\_\_(), která způsobuje, že instance třídy můžeme volat, jako kdyby to byly funkce. V tomto případě metoda \_\_call\_\_() dešifruje jeden bajt ze zip souboru a potom aktualizuje rotující klíče podle hodnoty dešifrovaného bajtu.
- zd je instancí třídy \_ZipDecryptor. Proměnná pwd (password; heslo) je předána metodě \_\_init\_\_(), která její obsah uloží a použije jej pro první aktualizaci rotujících klíčů.
- [4] Máme prvních 12 bajtů zip souboru. Dešifrujeme je zobrazením bajtů přes zd. To znamená, že se 12krát "volá" zd, což znamená, že se 12krát volá metoda \_\_call\_\_(), která aktualizuje vnitřní stav instance a 12krát vrací výsledný bajt.

#### B.6. Třídy, které se chovají jako množiny

Pokud se naše třída chová jako kontejner pro množinu hodnot — tj. pokud má smysl ptát se, zda naše třída "obsahuje" hodnotu — , pak by pravděpodobně měla definovat následující speciální metody, které způsobí, že se bude chovat jako množina.

| To, co chceme                                     | Takže napíšeme | A Python zavolá |
|---|----------------|-----------------|
| počet položek                                     | len(s)         | slen()          |
| test, zda posloupnost obsahuje<br>určitou hodnotu | x in s         | scontains(x)    |

Modul cgi tyto metody používá ve své třídě FieldStorage, která reprezentuje všechna pole formuláře nebo parametry dotazu, které byly zaslány na dynamickou webovou stránku.

```
# Skript, který reaguje na http://example.com/search?q=cgi
import cgi
fs = cgi.FieldStorage()
if 'q' in fs:
                                                                   [1]
 do_search()
# Výňatek z cgi.py, který vysvětluje, jak to funguje
class FieldStorage:
    def __contains__(self, key):
                                                                   [2]
        if self.list is None:
            raise TypeError('not indexable')
        return any(item.name == key for item in self.list)
                                                                    [3]
    def __len__(self):
                                                                    [4]
        return len(self.keys())
                                                                    [5]
```

[1]

- zda se v řetězci s dotazem nachází určitý parametr.

  Kouzlem, které to umožní, je metoda \_\_contains\_\_(). Pokud napíšeme if 'q' in fs, hledá

  Python metodu \_\_contains\_\_() objektu fs, který je definován v cgi.py. Hodnota 'q' je předána metodě \_\_contains\_\_() jako argument key.

Jakmile vytvoříme instanci třídy cgi. FieldStorage, můžeme použít operátor "in" pro ověření,

- Funkce any() přebírá generátorový výraz a vrací True, pokud generátor vrátí alespoň jeden prvek. Navíc je dost chytrá, aby skončila s testováním hned, jak se podaří podmínku splnit.
- Stejná třída FieldStorage podporuje také vracení své délky, takže můžeme napsat len(fs) a zavolá se metoda \_\_len\_\_() třídy FieldStorage, která vrátí počet rozpoznaných parametrů dotazu.
- [5] Metoda self.keys() kontroluje, zda self.list is None (zda seznam vůbec existuje), takže metoda \_\_len\_\_ nemusí uvedenou kontrolu chyb dublovat.

#### B.7. Třídy, které se chovají jako slovníky

Když předchozí možnosti trošku rozšíříme, můžeme definovat třídy, které nejenže reagují na operátor "in" a na funkci len(), ale které se mohou chovat jako plnohodnotné slovníky vracející hodnoty vázané na klíče.

| To, co chceme                    | Takže napíšeme     | A Python zavolá           |
|----------------------------------|--------------------|---------------------------|
| získat hodnotu podle klíče       | x[key]             | xgetitem(key)             |
| nastavit hodnotu vázanou na klíč | x[key] = value     | xsetitem(key, value)      |
| zrušit dvojici klíč-hodnota      | del x[key]         | xdelitem(key)             |
| vrátit výchozí hodnotu           | x[nonexistent_key] | xmissing(nonexistent_key) |
| pro chybějící klíče              |                    |                           |

Třída FieldStorage z modulu cgi definuje rovněž tyto speciální metody, což znamená, že můžeme dělat například následující věci:

```
# Skript, který reaguje na http://example.com/search?q=cgi
import cgi
fs = cgi.FieldStorage()
if 'q' in fs:
    do_search(fs['q']) [1]

# Výňatek z cgi.py, který ukazuje, jak to funguje
class FieldStorage:
.
.
.
. def __getitem__(self, key):
    if self.list is None:
        raise TypeError('not indexable')
```

```
found = []
for item in self.list:
    if item.name == key: found.append(item)
if not found:
    raise KeyError(key)
if len(found) == 1:
    return found[0]
else:
    return found
```

- Objekt fs je instancí cgi.FieldStorage, ale přesto můžeme používat výrazy jako fs['q'].
- [2] fs['q'] zavolá metodu \_\_getitem\_\_() s parametrem key nastaveným na 'q'. Potom se ve vnitřním seznamu parametrů dotazu (self.list) hledá položka, jejíž atribut .name je roven zadanému klíči.

#### B.8. Třídy, které se chovají jako čísla

Při použití příslušných speciálních metod můžeme definovat své vlastní třídy, které se chovají jako čísla. To znamená, že je můžeme sčítat, odčítat a provádět s nimi další matematické operace. Tímto způsobem jsou implementovány věci v modulu fractions — třída Fraction implementuje speciální metody, které nám umožňují provádět takovéto věci:

```
>>> from fractions import Fraction
>>> x = Fraction(1, 3)
>>> x / 3
Fraction(1, 9)
```

Zde je úplný seznam speciálních metod, které musí implementovat třída chovající se jako číslo.

| To, co chceme                       | Takže napíšeme | A Python zavolá |
|-------------------------------------|----------------|-----------------|
| sčítání                             | x + y          | xadd(y)         |
| odčítání                            | x - y          | xsub(y)         |
| násobení                            | x * y          | xmul(y)         |
| dělení                              | x / y          | xtruediv(y)     |
| celočíselné dělení (floor division) | x // y         | xfloordiv(y)    |
| modulo (zbytek)                     | x % y          | xmod(y)         |
| celočíselné dělení a zbytek         | divmod(x, y)   | xdivmod(y)      |
| umocnění na                         | x ** y         | xpow(y)         |
| bitový posun doleva                 | x << y         | xlshift(y)      |
| bitový posun doprava                | x >> y         | xrshift(y)      |
| logický součin po bitech (and)      | x & y          | xand(y)         |
| xor po bitech                       | x ^ y          | xxor(y)         |
| logický součet po bitech (or)       | x   y          | xor(y)          |

Pokud je x instancí třídy, která tyto metody implementuje, bude to fungovat bez problémů. Ale co když třída některou z těchto metod neimplementuje? Nebo ještě hůř — co když je implementuje, ale neporadí si s některými druhy argumentů? Například:

```
>>> from fractions import Fraction
>>> x = Fraction(1, 3)
>>> 1 / x
Fraction(3, 1)
```

Tohle není případ, kdy se vezme Fraction a dělí se celým číslem (jako v předchozím příkladu). Minulý příklad byl přímočarý: x / 3 volá x. \_\_truediv\_\_(3) a metoda \_\_truediv\_\_() třídy Fraction provede matematickou operaci. Ale objekty typu celé číslo (int) "neumí" dělat aritmetické operace se zlomky. Takže jak je možné, že ten příklad funguje?

Existuje druhá sada aritmetických speciálních metod *s obrácenými operandy* (reflected operands). Pokud matematická operace vyžaduje dva operandy (například x / y), dá se to řešit dvěma způsoby:

- 1. Řekneme x, aby podělilo samo sebe hodnotou y, nebo
- 2. řekneme y, aby se zachovalo jako dělitel hodnoty x.

Výše uvedená sada speciálních metod používá první přístup: pokud máme x / y, poskytují metody způsob, jak může x říci: "Já vím, jak vydělit sebe hodnotou y." Následující sada speciálních metod se pouští do druhého přístupu — metody poskytují způsob, jakým může y vyjádřit: "Já vím, jak být dělitelem a podělit sebou hodnotu x."

| To, co chceme                       | Takže napíšeme | A Python zavolá |
|-------------------------------------|----------------|-----------------|
| sčítání                             | x + y          | yradd(x)        |
| odčítání                            | x - y          | yrsub(x)        |
| násobení                            | x * y          | yrmul(x)        |
| dělení                              | x / y          | yrtruediv(x)    |
| celočíselné dělení (floor division) | x // y         | yrfloordiv(x)   |
| modulo (zbytek)                     | x % y          | yrmod(x)        |
| celočíselné dělení a zbytek         | divmod(x, y)   | yrdivmod(x)     |
| umocnění na                         | x ** y         | yrpow(x)        |
| bitový posun doleva                 | x << y         | yrlshift(x)     |
| bitový posun doprava                | x >> y         | yrrshift(x)     |
| logický součin po bitech (and)      | x & y          | yrand(x)        |
| xor po bitech                       | x ^ y          | yrxor(x)        |
| logický součet po bitech (or)       | x   y          | yror(x)         |

Ale moment! Ono je toho ještě víc! Pokud provádíme operace "přímo nad proměnnou" (in-place, in situ, na místě samém), jako například x/=3, můžeme definovat ještě další speciální metody.

| To, co chceme                    | Takže napíšeme | A Python zavolá |
|----------------------------------|----------------|-----------------|
| sčítání nad proměnnou            | x += y         | xiadd(y)        |
| odčítání nad proměnnou           | x -= y         | xisub(y)        |
| násobení nad proměnnou           | x *= y         | ximul(y)        |
| dělení nad proměnnou             | x /= y         | xitruediv(y)    |
| celočíselné dělení nad proměnnou | x //= y        | xifloordiv(y)   |
| (floor division)                 |                |                 |
| modulo nad proměnnou             | x %= y         | ximod(y)        |
| umocnění nad proměnnou           | x **= y        | xipow(y)        |
| bitový posun doleva              | x <<= y        | xilshift(y)     |
| nad proměnnou                    |                |                 |
| bitový posun doprava             | x >>= y        | xirshift(y)     |
| nad proměnnou                    |                |                 |
| logický součin po bitech         | x &= y         | xiand(y)        |
| nad proměnnou (and)              |                |                 |
| xor po bitech nad proměnnou      | x ^= y         | xixor(y)        |
| logický součet po bitech         | x  = y         | xior(y)         |
| nad proměnnou (or)               |                |                 |

Poznámka: Ve většině případů se implementace "in situ" metod nevyžaduje. Pokud pro určitou operaci příslušnou "in situ" metodu (tj. nad proměnnou) nedefinujeme, Python se ji pokusí nahradit. Například při provádění výrazu x /= y Python...

- 1. Vyzkouší zavolat x.\_\_itruediv\_\_(y). Pokud je metoda definována a vrátila hodnotu jinou než NotImplemented, je to hotové.
- Vyzkouší zavolat x.\_\_truediv\_\_(y). Pokud je metoda definována a vrátila hodnotu jinou než NotImplemented, je původní hodnota x zahozena a je nahrazena výslednou hodnotou jako kdybychom místo toho napsali x = x / y.
- 3. Vyzkouší zavolat y.\_\_rtruediv\_\_(x). Pokud je metoda definována a vrátila hodnotu jinou než NotImplemented, je původní hodnota x zahozena a je nahrazena výslednou hodnotou.

Takže "in situ" metodu jako \_\_itruediv\_\_() definujeme jen v případech, kdy chceme pro in situ operandy provádět nějakou speciální optimalizaci. V opačném případě Python v podstatě přeformuluje požadavek provedení operandu nad proměnnou na běžnou podobu operandu s přiřazením výsledku do proměnné.

Objekty, které se chovají jako číslo, mohou nad sebou provádět také pár "unárních" matematických operací.

| Poznámky | To, co chceme                  | Takže napíšeme | A Python zavolá |
|----------|--------------------------------|----------------|-----------------|
|          | unární minus (záporné číslo)   | -х             | xneg()          |
|          | unární plus (kladné číslo)     | +χ             | xpos()          |
|          | absolutní hodnota              | abs(x)         | xabs()          |
|          | inverze                        | ~x             | xinvert()       |
|          | převod na komplexní číslo      | complex(x)     | xcomplex()      |
|          | převod na celé číslo           | int(x)         | xint()          |
|          | převod na reálné číslo         | float(x)       | xfloat()        |
|          | převod na nejbližší celé číslo | round(x)       | xround()        |
|          | zaokrouhlením                  |                |                 |
|          | převod na nejbližší číslo      | round(x, n)    | xround(n)       |
|          | zaokrouhlením na n desetinných |                |                 |
|          | míst                           |                |                 |
|          | nejmenší celé číslo >= x       | math.ceil(x)   | xceil()         |
|          | největší celé číslo <= x       | math.floor(x)  | xfloor()        |
|          | odseknutí x na nejbližší celé  | math.trunc(x)  | xtrunc()        |
|          | číslo směrem k 0               |                |                 |
| PEP 357  | číslo jako index seznamu       | a_list[x]      | a_list[xindex   |

#### B.9. Třídy, které se dají porovnávat

Tuto část jsem od předchozí oddělil, protože porovnání se neomezuje jen na čísla. Porovnávat se dají hodnoty mnoha datových typů — řetězce, seznamy a dokonce i slovníky. Pokud vytváříme svou vlastní třídu a má smysl uvažovat o porovnávání našeho objektu s jinými objekty, můžeme porovnání implementovat následujícími speciálními metodami.

| To, co chceme          | Takže napíšeme | A Python zavolá |
|------------------------|----------------|-----------------|
| rovnost                | x == y         | xeq(y)          |
| různost (nerovnost)    | x != y         | xne(y)          |
| menší než              | x < y          | xlt(y)          |
| menší než nebo rovno   | x <= y         | xle(y)          |
| větší než              | x > y          | xgt(y)          |
| větší než nebo rovno   | x >= y         | xge(y)          |
| pravdivostní hodnota   | if x:          | xbool()         |
| v booleovském kontextu |                |                 |

Pokud definujeme metodu \_\_lt\_\_(), ale nedefinujeme metodu \_\_gt\_\_(), použije Python metodu \_\_lt\_\_() s přehozenými operandy. Ale Python neprovádí kombinaci metod. Pokud například definujeme metodu \_\_lt\_\_() a metodu \_\_eq\_\_() a pokusíme se otestovat, zda je x <= y, Python nezavolá postupně \_\_lt\_\_() a \_\_eq\_\_(). Zavolá pouze metodu \_\_le\_\_().

#### B.10. Třídy, které podporují serializaci

Python podporuje serializaci a deserializaci libovolných objektů. (Většina pythonovských příruček tento proces nazývá "pickling" a "unpickling".) Může to být užitečné pro uložení stavu objektu do souboru a jeho pozdější obnovení. Všechny přirozené datové typy již "piklení" podporují. Pokud vytvoříte uživatelskou třídu a chcete ji umět serializovat, přečtěte si něco o pickle protokolu, abyste věděli, kdy a jak se volají následující speciální metody.

| Poznámky | To, co chceme                    | Takže napíšeme                  | A Python zavolá     |
|----------|----------------------------------|---------------------------------|---------------------|
|          | uživatelská kopie objektu        | copy.copy(x)                    | xcopy()             |
|          | uživatelská kopie objektu        | copy.deepcopy(x)                | xdeepcopy()         |
|          | do hloubky (deep copy)           |                                 |                     |
| *        | zjištění stavu objektu           | <pre>pickle.dump(x, file)</pre> | xgetstate()         |
|          | před serializací                 |                                 |                     |
| *        | serializace objektu              | <pre>pickle.dump(x, file)</pre> | xreduce()           |
| *        | serializace objektu (nový        | <pre>pickle.dump(x, file,</pre> | xreduce_ex(protocol |
|          | serializační protokol)           | protocol_version)               | _version)           |
| *        | kontrola nad vytvářením objektu  | x = pickle.load(file)           | xgetnewargs()       |
|          | během deserializace (unpickling) |                                 |                     |
| *        | obnovení stavu objektu           | x = pickle.load(file)           | xsetstate()         |
|          | po deserializaci                 |                                 |                     |

\* Při znovuvytváření serializovaného objektu musí Python nejdříve vytvořit nový objekt, který vypadá jako ten serializovaný, a potom musí nastavit hodnoty všech jeho atributů. Metoda \_\_getnewargs\_\_() řídí způsob vytváření objektu. Metoda \_\_setstate\_\_() poté řídí obnovení hodnot atributů.

#### B.11. Třídy, které mohou být použity v bloku with

Blok with definuje operační kontext (runtime context). "Vstupujeme" do něj (enter) v okamžiku provádění příkazu with a "vystupujeme" z něj (exit) po provedení posledního příkazu v jeho bloku.

| To, co chceme            | Takže napíšeme | A Python zavolá            |
|--------------------------|----------------|----------------------------|
| udělej něco speciálního  | with x:        | xenter()                   |
| při vstupu do bloku with |                |                            |
| udělej něco speciálního  | with x:        | xexit(exc_type, exc_value, |
| při opouštění bloku with |                | traceback)                 |

B.11. Třídy, které mohou být použity v bloku with

Obrat with soubor funguje následovně:

```
# výňatek z io.py
def _checkClosed(self, msg=None):
    '''Internal: raise an ValueError if file is closed
    if self.closed:
        raise ValueError('I/O operation on closed file.'
                         if msg is None else msg)
def __enter__(self):
    '''Context management protocol. Returns self.'''
    self._checkClosed()
                                                          [1]
    return self
                                                           [2]
def __exit__(self, *args):
    '''Context management protocol. Calls close()'''
    self.close()
                                                          [3]
```

- Objekt souboru definuje jak metodu \_\_enter\_\_(), tak metodu \_\_exit\_\_(). Metoda \_\_enter\_\_() kontroluje, zda je soubor otevřen. Pokud ne, vyvolá metoda \_checkClosed() výjimku.
- Metoda \_\_enter\_\_() by měla téměř vždy vrátit self, což je objekt, který bude v bloku with použit pro práci s vlastnostmi (properties) a k volání metod.
- Po ukončení bloku with se souborový objekt automaticky uzavře. Jak se to udělá? V metodě \_\_exit\_\_() se zavolá self.close().
- Metoda \_\_exit\_\_() se zavolá vždy, dokonce i když je uvnitř bloku with vyvolána výjimka. Ve skutečnosti je to tak, že při vyvolání výjimky je informace o výjimce předána metodě \_\_exit\_\_(). Další detaily naleznete ve standardní dokumentaci: With Statement Context Managers (správci kontextu příkazu with).

Kap. O správcích kontextu se dozvíte víc v části <u>Automatické zavírání souborů</u> a <u>Přesměrování standardního výstupu</u>.

#### B.12. Opravdu esoterické věci

Pokud víme, co děláme, můžeme získat téměř úplnou kontrolu nad tím, jak jsou třídy porovnávány, jak jsou definovány atributy a jaký druh tříd se považuje za podtřídy naší třídy.

| Poznámky | To, co chceme                      | Takže napíšeme       | A Python zavolá         |
|----------|------------------------------------|----------------------|-------------------------|
|          | konstruktor třídy                  | x = MyClass()        | xnew()                  |
| *        | destruktor třídy                   | del x                | xdel()                  |
|          | definovat jen určité atributy      |                      | xslots()                |
|          | uživatelská heš-hodnota            | hash(x)              | xhash()                 |
|          | získat hodnotu vlastnosti          | x.color              | type(x)dict['color'].   |
|          | (property)                         |                      | get(x, type(x))         |
|          | nastavit hodnotu vlastnosti        | x.color =            | type(x)dict['color'].   |
|          |                                    | 'PapayaWhip'         | set(x, 'PapayaWhip')    |
|          | zrušit vlastnost                   | del x.color          | type(x)dict['color'].   |
|          |                                    |                      | del(x)                  |
|          | zkontrolovat, zda je nějaký objekt | isinstance           | MyClassinstancecheck(x) |
|          |                                    | (x, MyClass)         |                         |
|          | instancí naší třídy                |                      |                         |
|          | zkontrolovat, zda je nějaká třída  | issubclass           | MyClasssubclasscheck(C) |
|          | podtřídou naší třídy               | (C, MyClass)         |                         |
|          | zkontrolovat, zda je nějaká třída  | issubclass(C, MyABC) | MyABCsubclasshook(C)    |
|          | podtřídou naší abstraktní          |                      |                         |
|          | bázové třídy                       |                      |                         |

\* Okolnosti toho, kdy přesně Python volá speciální metodu \_\_del\_\_(), jsou neuvěřitelně komplikované. Abyste tomu porozuměli úplně, musíte vědět, jakým způsobem Python sleduje objekty v paměti. Tady najdete dobrý článek o mechanismu automatického uvolňování paměti (garbage collection) a o destruktorech tříd v jazyce Python (anglicky). Měli byste si také přečíst o slabých referencích (weak references), o modulu weakref a navrch pravděpodobně také o modulu gc.

#### B.13. Přečtěte si

Moduly zmíněné v této příloze (standardní dokumentace):

- Modul zipfile
  - (http://docs.python.org/py3k/library/zipfile.html)
- Modul cgi
  - (http://docs.python.org/py3k/library/cgi.html)
- Modul collections
  - (http://docs.python.org/py3k/library/collections.html)

- Modul math
  - (http://docs.python.org/py3k/library/math.html)
- Modul pickle
  - (http://docs.python.org/py3k/library/pickle.html)
- Modul copy
  - (http://docs.python.org/py3k/library/copy.html)
- Modul abc ("Abstract Base Classes"; abstraktní bázové třídy) (http://docs.python.org/py3k/library/abc.html)

#### Další lehké čtení (standardní dokumentace):

- Format Specification Mini-Language (minijazyk pro specifikaci formátu) (http://docs.python.org/release/3.1/library/string.html)
- Python data model (pythonovský datový model)
   (http://docs.python.org/release/3.1/reference/datamodel.html)
- **Built-in types** (zabudované typy) (http://docs.python.org/release/3.1/library/stdtypes.html)
- PEP 357: Allowing Any Object to be Used for Slicing (jak umožnit každému objektu být použit pro řezy)
   (www.python.org/dev/peps/pep-0357/)
- PEP 3119: Introducing Abstract Base Classes (úvod do abstraktních bázových tříd) (www.python.org/dev/peps/pep-3119/)

- "Go forth on your path, as it exists only through your walking." (Jdi dál svou cestou, protože ta existuje jen pod tvými kroky.)
  - Sv. Augustin z Hippo (připisováno)

# C. Čím pokračovat

Obsah přílohy

- C. Čím pokračovat 423
- C.1. Doporučuji k přečtení **425**
- C.2. Kde hledat kód kompatibilní s Pythonem 3 **426**

#### C.1. Doporučuji k přečtení

V této knize se bohužel nemůžu zabývat všemi stránkami jazyka Python 3. Naštěstí můžete všude najít mnoho nádherných, volně dostupných učebnic.

#### Dekorátory:

- Function Decorators Ariel Ortiz (dekorátory funkcí)
   (http://programmingbits.pythonblogs.com/27\_programmingbits/archive/50\_function\_decorators.html)
- More on Function Decorators Ariel Ortiz (více o dekorátorech funkcí)
   (http://programmingbits.pythonblogs.com/27\_programmingbits/archive/51\_more\_on\_function\_decorators.html)
- Charming Python: Decorators make magic easy David Mertz (dekorátory s magickou lehkostí) (www.ibm.com/developerworks/linux/library/l-cpdecor.html)
- Function Definitions (definice funkcí) v oficiální pythonovské dokumentaci (http://docs.python.org/reference/compound\_stmts.html#function)

#### Vlastnosti (properties):

- The Python property builtin Adam Gomaa (http://adam.gomaa.us/blog/2008/aug/11/the-python-property-builtin/)
- **Getters/Setters/Fuxors** Ryan Tomayko (http://tomayko.com/writings/getters-setters-fuxors)
- property() function v oficiální pythonovské dokumentaci (http://docs.python.org/library/functions.html#property)

#### Deskriptory:

- How-To Guide For Descriptors Raymond Hettinger (http://users.rcn.com/python/download/Descriptor.htm)
- Charming Python: Python elegance and warts, Part 2 David Mertz (www.ibm.com/developerworks/linux/library/l-python-elegance-2.html)
- $\begin{array}{ll} \bullet & \textbf{Python Descriptors} \textbf{Mark Summerfield} \\ & (www.informit.com/articles/printerfriendly.aspx?p=1309289) \end{array}$
- Invoking Descriptors v oficiální pythonovské dokumentaci (http://docs.python.org/py3k/reference/datamodel.html)

#### Vlákna a multiprocesing:

- Modul threading
  - (http://docs.python.org/py3k/library/threading.html)
- threading Manage concurrent threads (www.doughellmann.com/PyMOTW/threading/)
- Modul multiprocessing
   (http://docs.python.org/py3k/library/multiprocessing.html)

- multiprocessing Manage processes like threads (http://www.doughellmann.com/PyMOTW/multiprocessing/)
- Python threads and the Global Interpreter Lock Jesse Noller (http://jessenoller.com/2009/02/01/python-threads-and-the-global-interpreter-lock/)
- Inside the Python GIL (video) David Beazley (http://blip.tv/file/2232410)

#### Metatřídy:

- Metaclass programming in Python David Mertz a Michele Simionato (www.ibm.com/developerworks/linux/library/l-pymeta.html)
- Metaclass programming in Python, Part 2 David Mertz a Michele Simionato (www.ibm.com/developerworks/linux/library/l-pymeta2/)
- Metaclass programming in Python, Part 3 David Mertz a Michele Simionato (www.ibm.com/developerworks/linux/library/l-pymeta3.html)

A navíc fantastický průvodce mnoha moduly ze standardní pythonovské knihovny od Douga Hellmana — **Python Module of the Week** (http://www.doughellmann.com/PyMOTW/contents.html).

## C.2. Kde hledat kód kompatibilní s Pythonem 3

Python 3 je relativně nový, takže o kompatibilní knihovny je nouze. Tady jsou nějaká místa, kde můžete hledat kód, který funguje s Pythonem 3 (vše anglicky).

- **Python Package Index:** seznam balíčků pro Python 3 (http://pypi.python.org/pypi?:action=browse&c=533&show=all)
- Python Cookbook: seznam receptů označkovaných "python3" (http://code.activestate.com/recipes/langs/python/tags/python3/)
- Google Project Hosting: seznam projektů označkovaných "python3" (http://code.google.com/hosting/search?q=label:python3)
- **SourceForge:** seznam projektů vyhledaných podle "Python 3" (http://sourceforge.net/search/?words=%22python+3%22)
- **GitHub:** seznam projektů vyhledaných podle "python3" (a také podle "python 3") (https://github.com/search?type=Repositories&language=python&q=python3) (https://github.com/search?type=Repositories&language=python&q=python+3)
- **BitBucket:** seznam projektů vyhledaných podle "python3" (a podle "python 3") (http://bitbucket.org/repo/all/?name=python3) (http://bitbucket.org/repo/all/?name=python+3)

"Where's the ANY key?"
(Kde je LIBOVOLNÁ klávesa?)

— připisováno kdekomu

# D. Odstraňování problémů

Obsah přílohy

- D. Odstraňování problémů 427
- D.1. Ponořme se **429**
- D.2. Jak se dostat k příkazovému řádku **429**
- D.3. Spuštění Pythonu z příkazového řádku **429**

- D.1. Ponořme se
- D.2. Jak se dostat k příkazovému řádku
- D.3. Spuštění Pythonu z příkazového řádku

#### D.1. Ponořme se

DOPSAT

#### D.2. Jak se dostat k příkazovému řádku

V celé knize se setkáváme s příklady spouštění Pythonu z příkazového řádku. Ale jak se máte k příkazovému řádku dostat?

V Linuxu se podívejte do menu Applications a hledejte program zvaný Terminal. (Může se nacházet v podmenu jako Accessories nebo System.)

V Mac OS X naleznete v adresáři /Application/Utilities/ aplikaci nazvanou Terminal.app. Dostanete se tam tak, že kliknete na pracovní plochu, otevřete menu Go, vyberete Go to folder... (přejít do adresáře) a napíšete /Applications/Utilities/. Nakonec poklepete na program Terminal.

Ve Windows kliknete na Start, vyberete položku Spustit..., napíšete cmd a stisknete ENTER.

#### D.3. Spuštění Pythonu z příkazového řádku

Jakmile se dostanete na příkazový řádek, měli byste být schopni spustit pythonovský interaktivní shell. V Linuxu nebo v Mac OS X napište na příkazový řádek python3 a stiskněte ENTER. Ve Windows napište na příkazový řádek c:\python31\python a stiskněte ENTER. Pokud půjde vše dobře, měli byste vidět něco takového:

```
you@localhost:~$ python3
Python 3.1 (r31:73572, Jul 28 2009, 06:52:23)
[GCC 4.2.4 (Ubuntu 4.2.4-1ubuntu4)] on linux2
Type "help", "copyright", "credits" or "license" for more information.
>>>
```

(Až budete chtít pythonovský interaktivní shell opustit a vrátit se na příkazový řádek, napište exit() a stiskněte ENTER. Tento obrat funguje na všech platformách.)

Pokud zpozorujete chybu "příkaz nenalezen" (command not found), znamená to, že pravděpodobně nemáte Python 3 nainstalován.

```
you@localhost:~$ python3
bash: python3: command not found
```

Pokud se do pythonovského interaktivního shellu dostanete, ale číslo verze neodpovídá vašemu očekávání, máte možná nainstalovánu více než jednu verzi Pythonu. Stává se to spíš na systémech Linux a Mac OS X, kde může být starší verze Pythonu předinstalována. Poslední verzi můžete nainstalovat, aniž byste museli starší verzi mazat (mohou být bez problémů instalovány vedle sebe), ale při spouštění Pythonu z příkazového řádku se pak musíte vyjádřit přesněji.

Například na svém domácím linuxovém stroji mám nainstalováno několik verzí Pythonu, abych na nich mohl otestovat software, který vytvářím. Když chci spustit určitou verzi, můžu napsat python3.0, python3.1 nebo python2.6.

```
mark@atlantis:~$ python3.0
Python 3.0.1+ (r301:69556, Apr 15 2009, 17:25:52)
[GCC 4.3.3] on linux2
Type "help", "copyright", "credits" or "license" for more information.
>>> exit()
mark@atlantis:~$ python3.1
Python 3.1 (r31:73572, Jul 28 2009, 06:52:23)
[GCC 4.2.4 (Ubuntu 4.2.4-1ubuntu4)] on linux2
Type "help", "copyright", "credits" or "license" for more information.
>>> exit()
mark@atlantis:~$ python2.6
Python 2.6.5 (r265:79063, Apr 16 2010, 13:57:41)
[GCC 4.4.3] on linux2
Type "help", "copyright", "credits" or "license" for more information.
>>> exit()
```

© 2010 Mark Pilgrim

Ponořme se do Python(u) 3

Dive Into Python 3

<u>Layout</u> Jan Svoboda — *Selftone* 

Vydal CZ.NIC, z. s. p. o. Americká 23, 120 00 Praha 2 www.nic.cz

ISBN: 978-80-904248-2-1

Edice CZ.NIC

Knihu je možné objednat na **knihy.nic.cz** 





O autorovi Mark Pilgrim se nesmazatelně zapsal do povědomí pythonovské komunity už svojí knihou "Dive Into Python", ve které originálním a nezapomenutelným způsobem přiblížil čtenářům osobitý styl programování v tomto jazyce, aby se o několik let později připomenul ještě výrazněji s knihou "Dive Into Python 3", která je stejně originálním a zábavným způsobem věnována jeho nejnovější verzi. S podobným nadšením se však zabývá i dalšími tématy, jeho nejnovější kniha "HTML5: Up & Running" je čtivým úvodem do problematiky posledního hitu na poli předávání informací na Internetu – standardu HTML5.

O edici Edice CZ.NIC je jedním z osvětových projektů správce české domény nejvyšší úrovně. Cílem tohoto projektu je vydávat odborné, ale i populární publikace spojené s internetem a jeho technologiemi. Kromě tištěných verzí vychází v této edici současně i elektronická podoba knih. Ty je možné najít na stránkách knihv.nic.cz